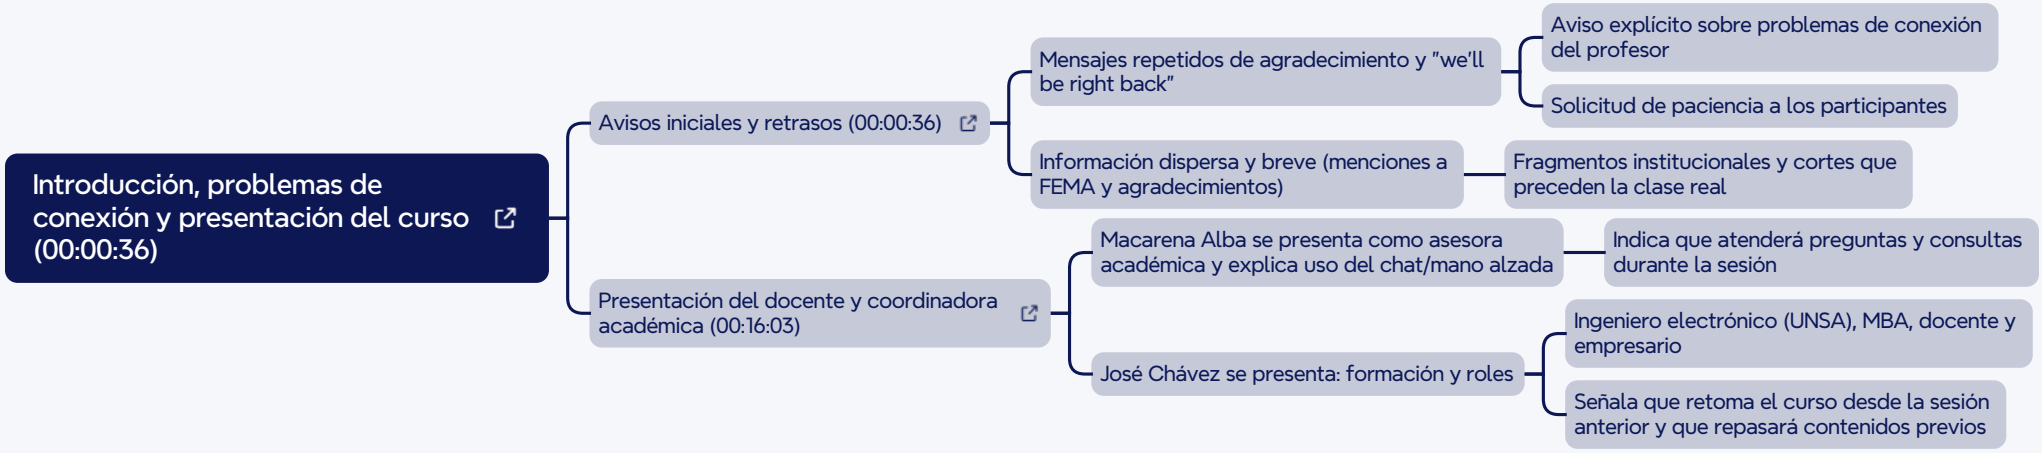
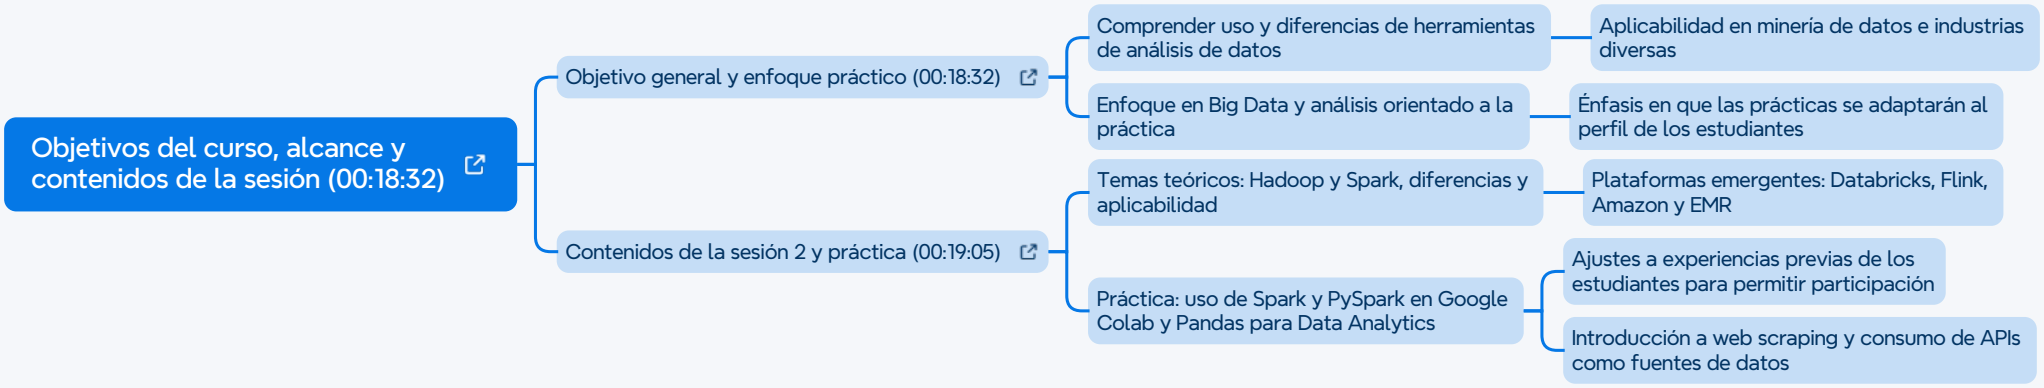
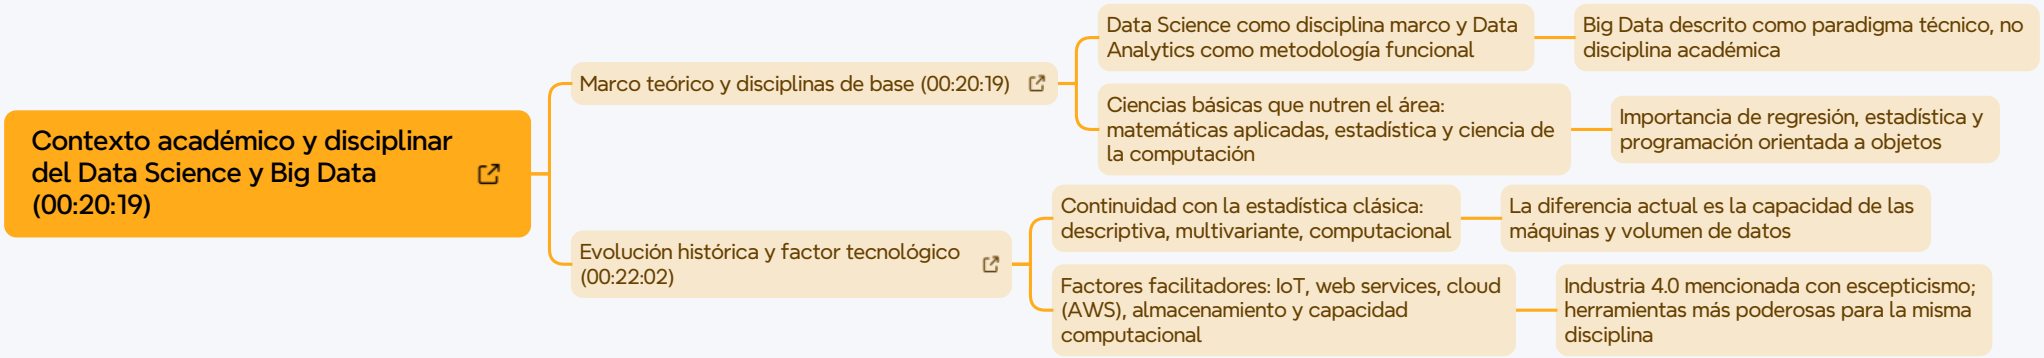
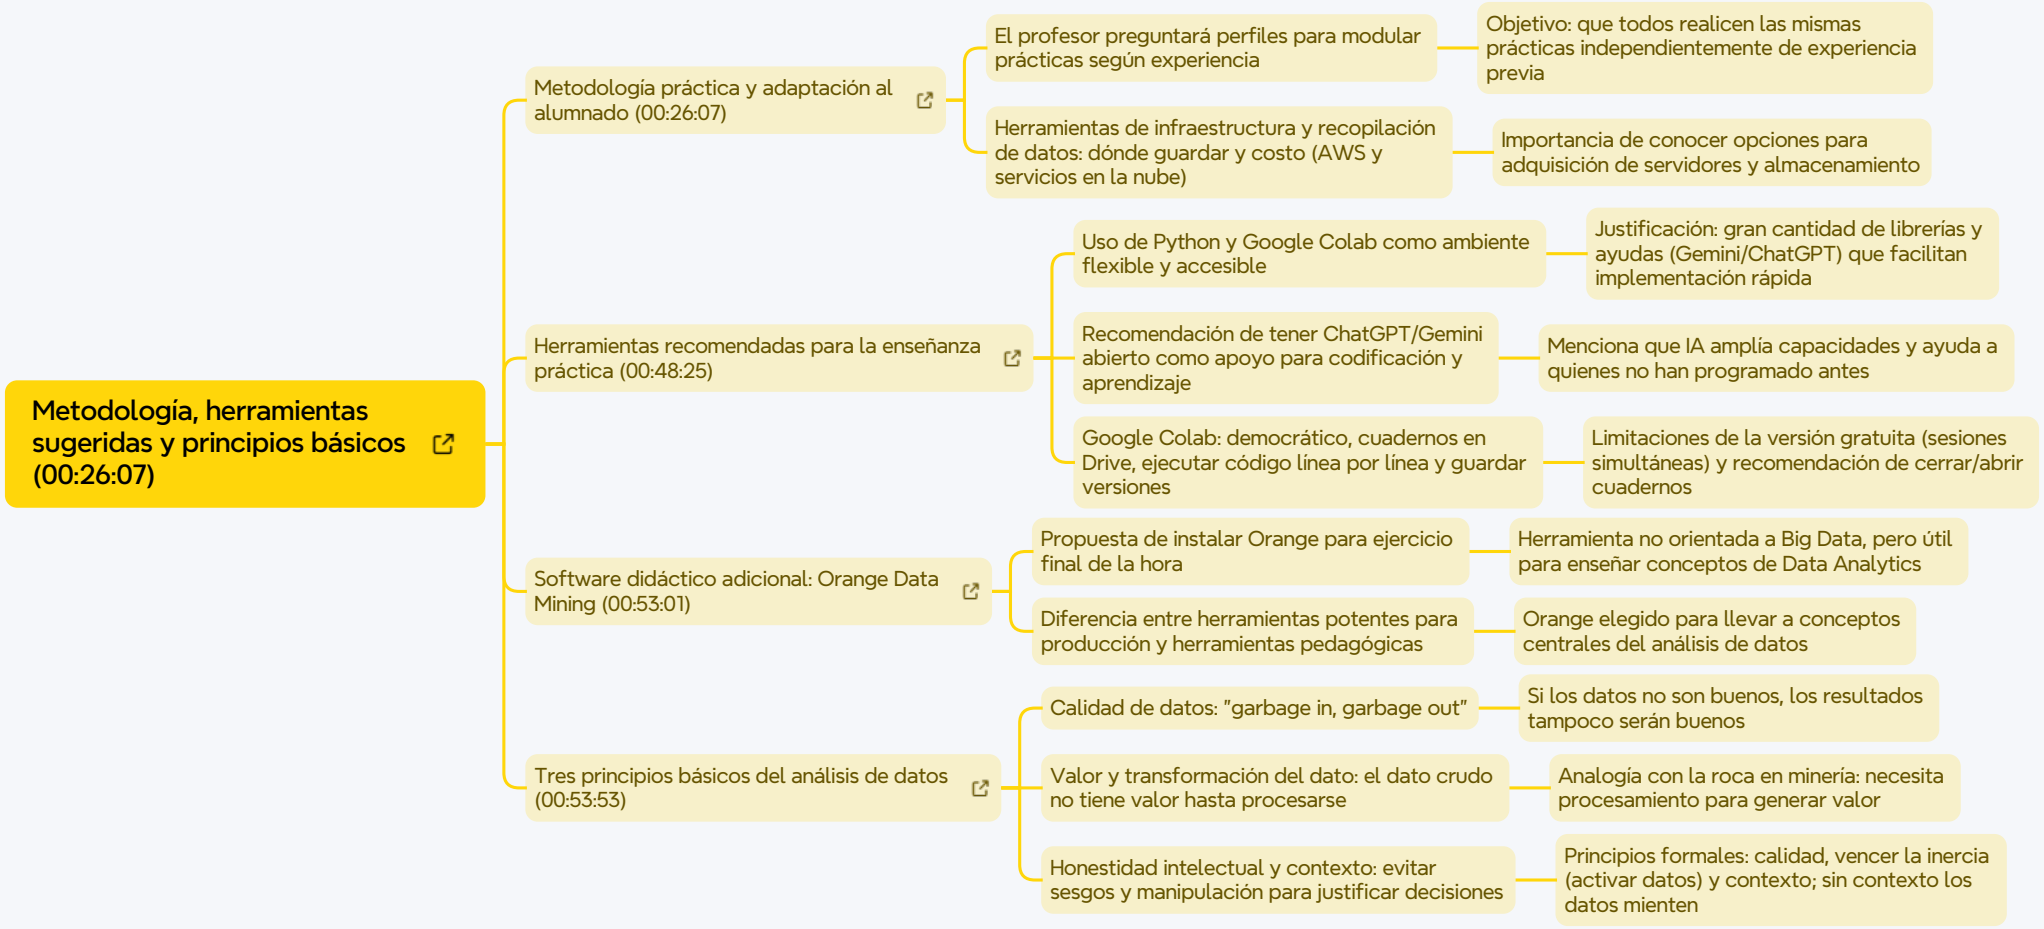
EDU MIN

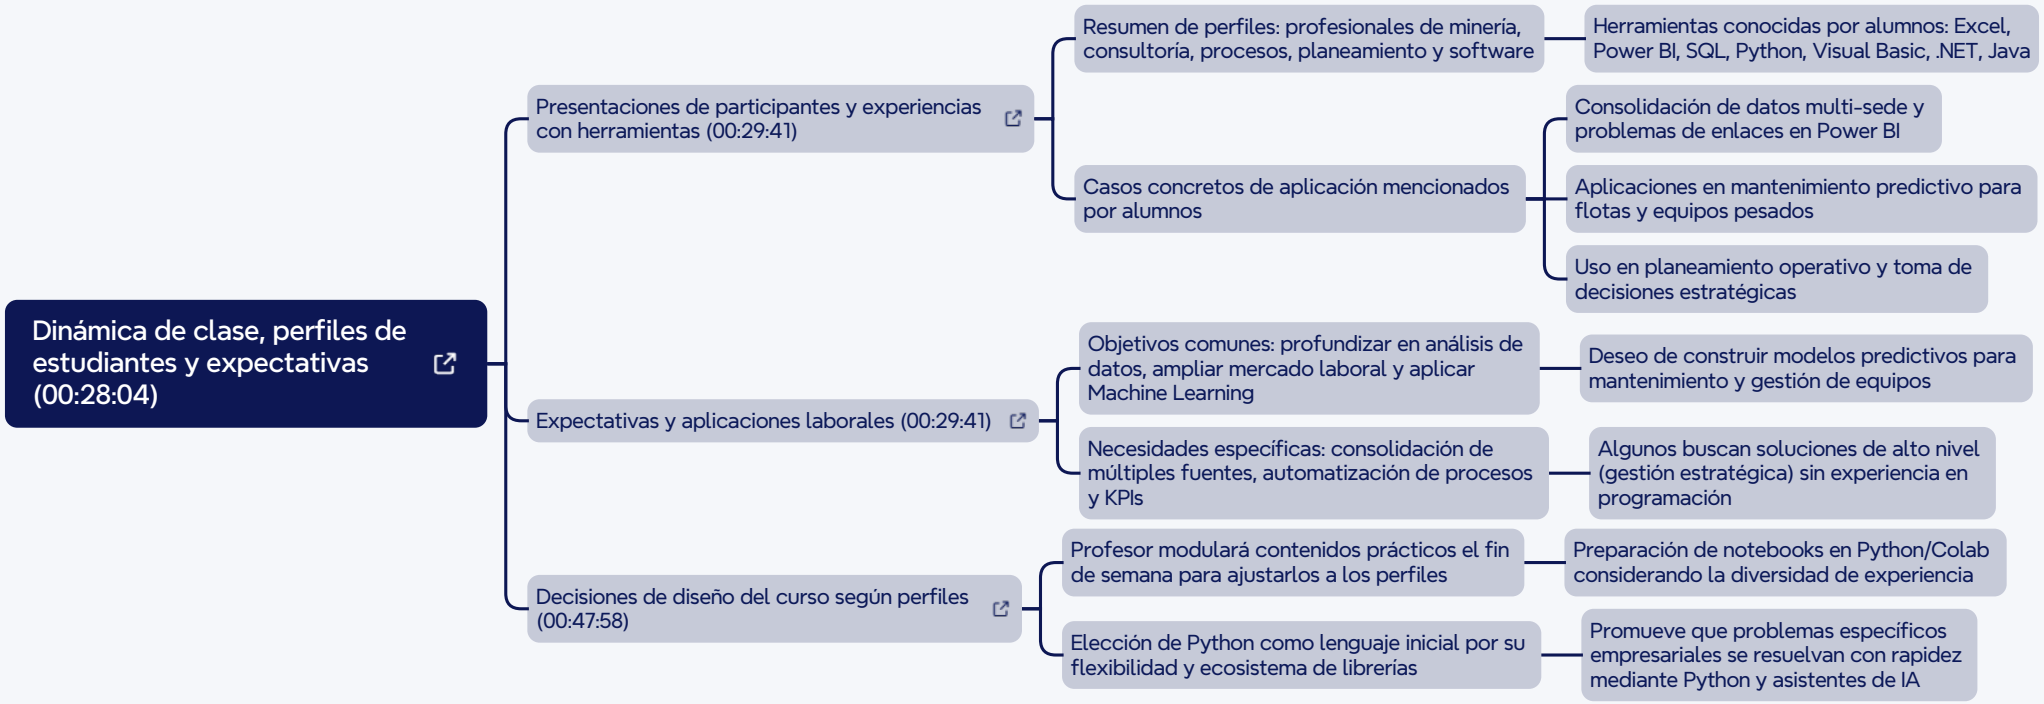

CLASE 02: ESTRATEGIAS AVANZADAS DE RECOLECCIÓN Y CAPTURA DE DATOS - 2DA PARTE
Introducción, problemas de conexión y presentación del curso (00:00:36)
12
Objetivos del curso, alcance y contenidos de la sesión (00:18:32)
11
Contexto académico y disciplinar del Data Science y Big Data (00:20:19)
10
Metodología, herramientas sugeridas y principios básicos (00:26:07)
24
Dinámica de clase, perfiles de estudiantes y expectativas (00:28:04)
17
Big Data: Hadoop, Spark y elección de herramientas (01:00:04)
20
Captura de datos: IoT, web scraping y APIs (01:02:03)
9
Orange / Data Mining práctico y ejercicios (02:18:49)
11
Práctica: creación de hash y demostración en Colab (02:10:41)
10
Seguridad integral, cumplimiento en la nube y verificación de datos (02:06:56)
16
Privacidad, integridad y seguridad de los datos (01:55:20)
17
Principios de cierre, roadmap y siguientes pasos (01:54:42)
17
Principios de MapReduce y flujo lógico común (01:14:10)
9
Prácticas en Google Colab: Pandas y PySpark (01:11:51)
15

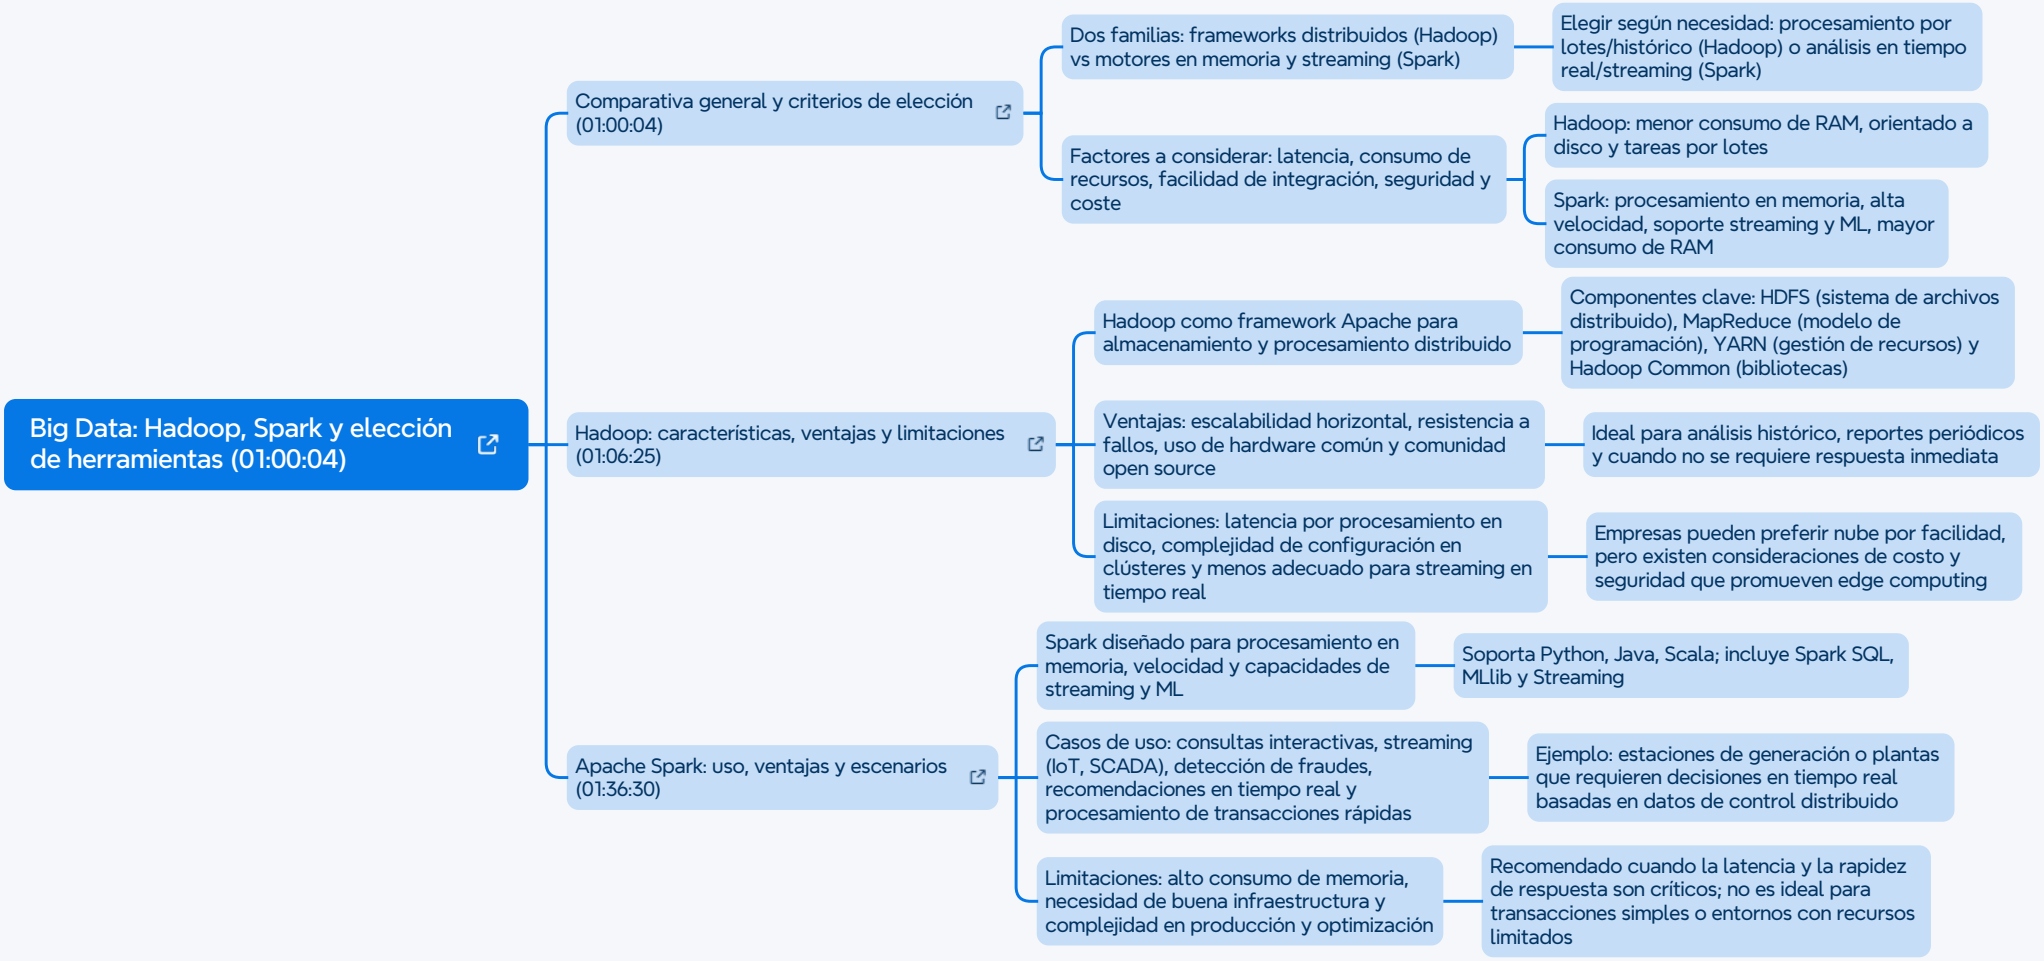

Introducción, problemas de conexión y presentación del curso (00:00:36)
Avisos iniciales y retrasos (00:00:36)
Mensajes repetidos de agradecimiento y "we'll be right back"
Aviso explícito sobre problemas de conexión del profesor
Solicitud de paciencia a los participantes
Información dispersa y breve (menciones a FEMA y agradecimientos)
Fragmentos institucionales y cortes que preceden la clase real
Presentación del docente y coordinadora académica (00:16:03)
Macarena Alba se presenta como asesora académica y explica uso del chat/mano alzada
Indica que atenderá preguntas y consultas durante la sesión
José Chávez se presenta: formación y roles
Ingeniero electrónico (UNSA), MBA, docente y empresario
Señala que retoma el curso desde la sesión anterior y que repasará contenidos previos

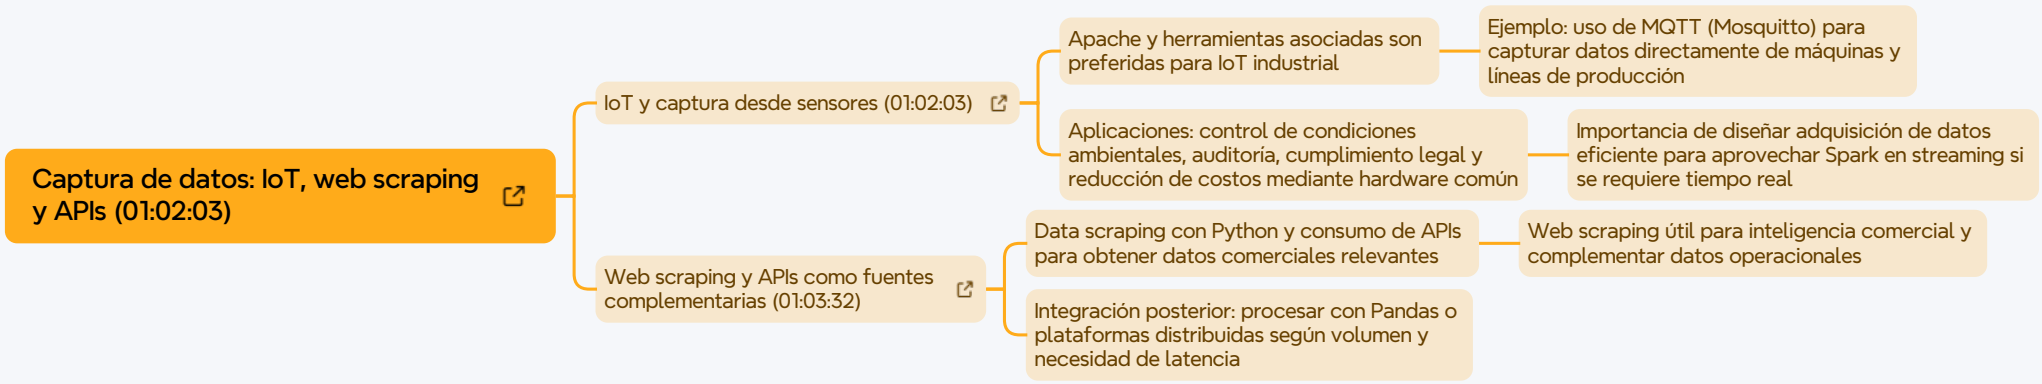

Objetivos del curso, alcance y contenidos de la sesión (00:18:32)
Objetivo general y enfoque práctico (00:18:32)
Comprender uso y diferencias de herramientas de análisis de datos
Aplicabilidad en minería de datos e industrias diversas
Enfoque en Big Data y análisis orientado a la práctica
Énfasis en que las prácticas se adaptarán al perfil de los estudiantes
Contenidos de la sesión 2 y práctica (00:19:05)
Temas teóricos: Hadoop y Spark, diferencias y aplicabilidad
Plataformas emergentes: Databricks, Flink, Amazon y EMR
Práctica: uso de Spark y PySpark en Google Colab y Pandas para Data Analytics
Ajustes a experiencias previas de los estudiantes para permitir participación
Introducción a web scraping y consumo de APIs como fuentes de datos

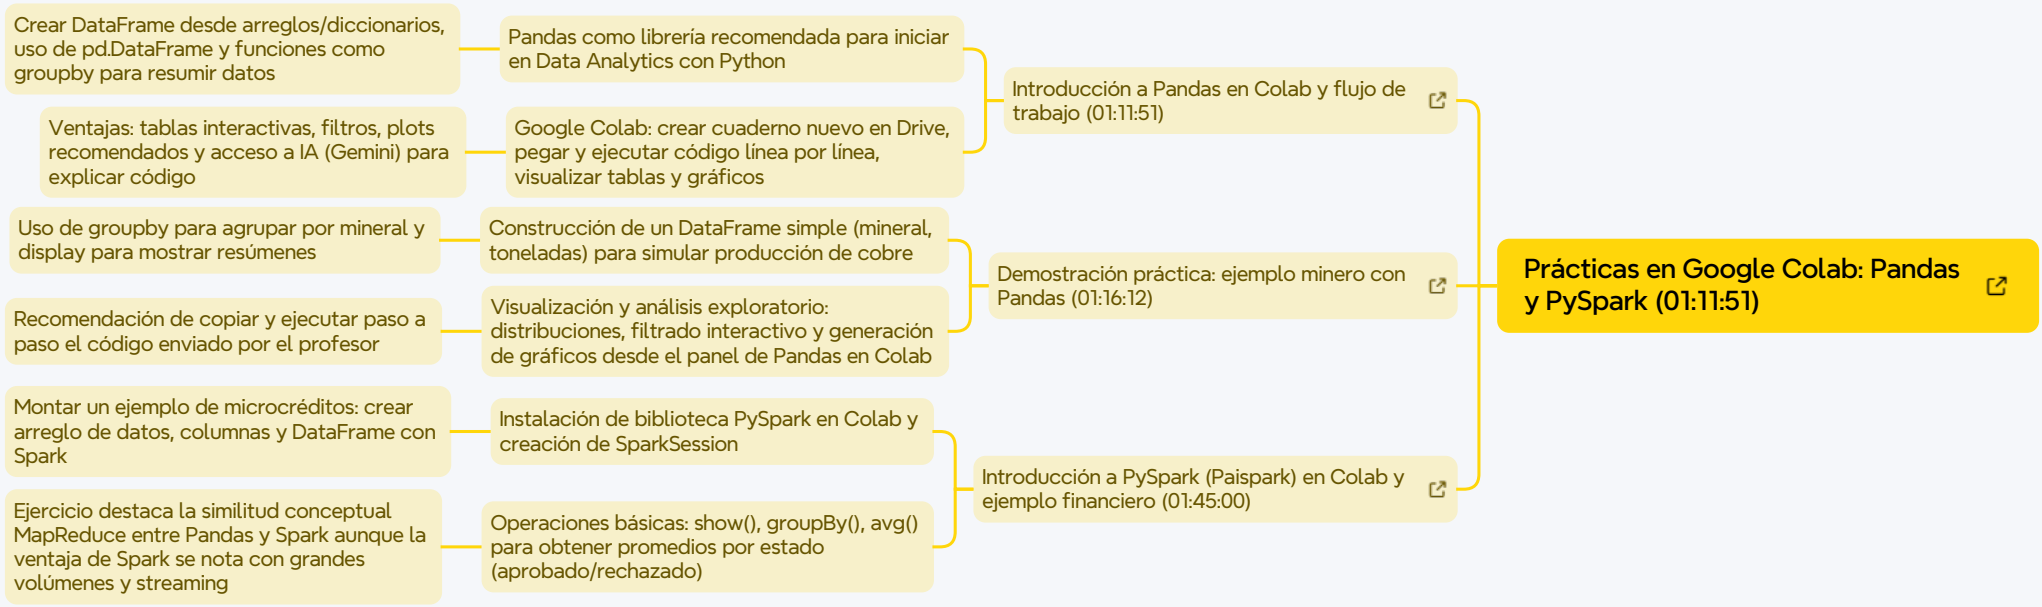

Contexto académico y disciplinar del Data Science y Big Data (00:20:19)
Marco teórico y disciplinas de base (00:20:19)
Data Science como disciplina marco y Data Analytics como metodología funcional
Big Data descrito como paradigma técnico, no disciplina académica
Ciencias básicas que nutren el área: matemáticas aplicadas, estadística y ciencia de la computación
Importancia de regresión, estadística y programación orientada a objetos
Evolución histórica y factor tecnológico (00:22:02)
Continuidad con la estadística clásica: descriptiva, multivariante, computacional
La diferencia actual es la capacidad de las máquinas y volumen de datos
Factores facilitadores: IoT, web services, cloud (AWS), almacenamiento y capacidad computacional
Industria 4.0 mencionada con escepticismo; herramientas más poderosas para la misma disciplina

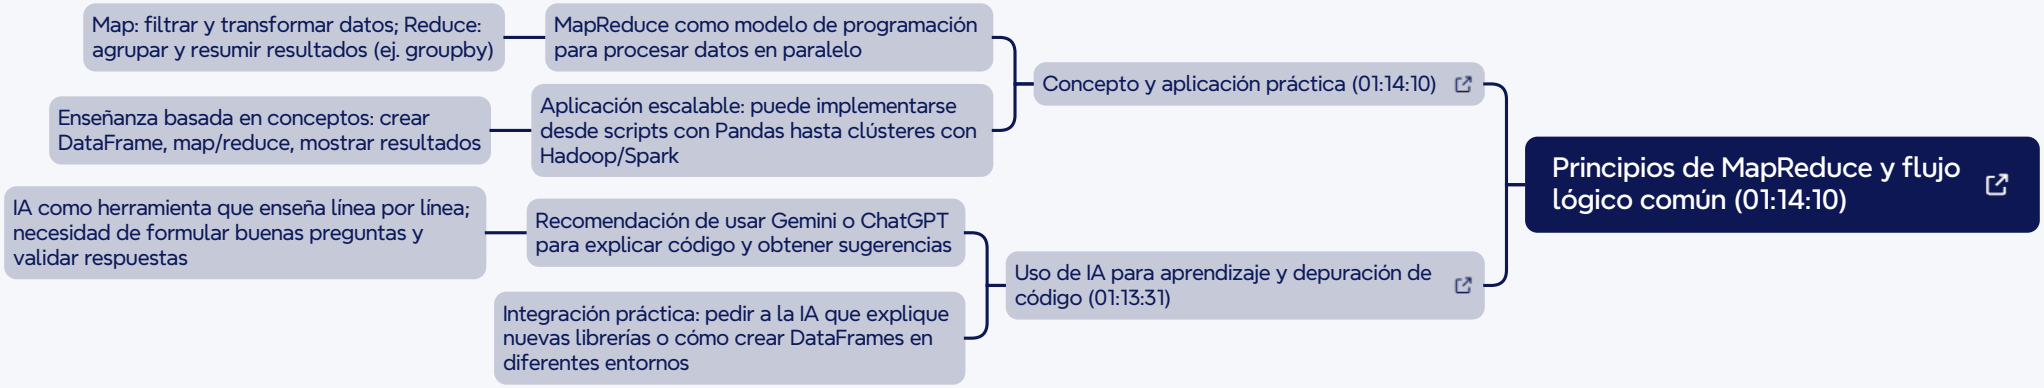

Metodología, herramientas sugeridas y principios básicos (00:26:07)
Metodología práctica y adaptación al alumnado (00:26:07)
El profesor preguntará perfiles para modular prácticas según experiencia
Objetivo: que todos realicen las mismas prácticas independientemente de experiencia previa
Herramientas de infraestructura y recopilación de datos: dónde guardar y costo (AWS y servicios en la nube)
Importancia de conocer opciones para adquisición de servidores y almacenamiento
Herramientas recomendadas para la enseñanza práctica (00:48:25)
Uso de Python y Google Colab como ambiente flexible y accesible
Justificación: gran cantidad de librerías y ayudas (Gemini/ChatGPT) que facilitan implementación rápida
Recomendación de tener ChatGPT/Gemini abierto como apoyo para codificación y aprendizaje
Menciona que IA amplía capacidades y ayuda a quienes no han programado antes
Google Colab: democrático, cuadernos en Drive, ejecutar código línea por línea y guardar versiones
Limitaciones de la versión gratuita (sesiones simultáneas) y recomendación de cerrar/abrir cuadernos
Software didáctico adicional: Orange Data Mining (00:53:01)
Propuesta de instalar Orange para ejercicio final de la hora
Herramienta no orientada a Big Data, pero útil para enseñar conceptos de Data Analytics
Diferencia entre herramientas potentes para producción y herramientas pedagógicas
Orange elegido para llevar a conceptos centrales del análisis de datos
Tres principios básicos del análisis de datos (00:53:53)
Calidad de datos: "garbage in, garbage out"
Si los datos no son buenos, los resultados tampoco serán buenos
Valor y transformación del dato: el dato crudo no tiene valor hasta procesarse
Analogía con la roca en minería: necesita procesamiento para generar valor
Honestidad intelectual y contexto: evitar sesgos y manipulación para justificar decisiones
Principios formales: calidad, vencer la inercia (activar datos) y contexto; sin contexto los datos mienten

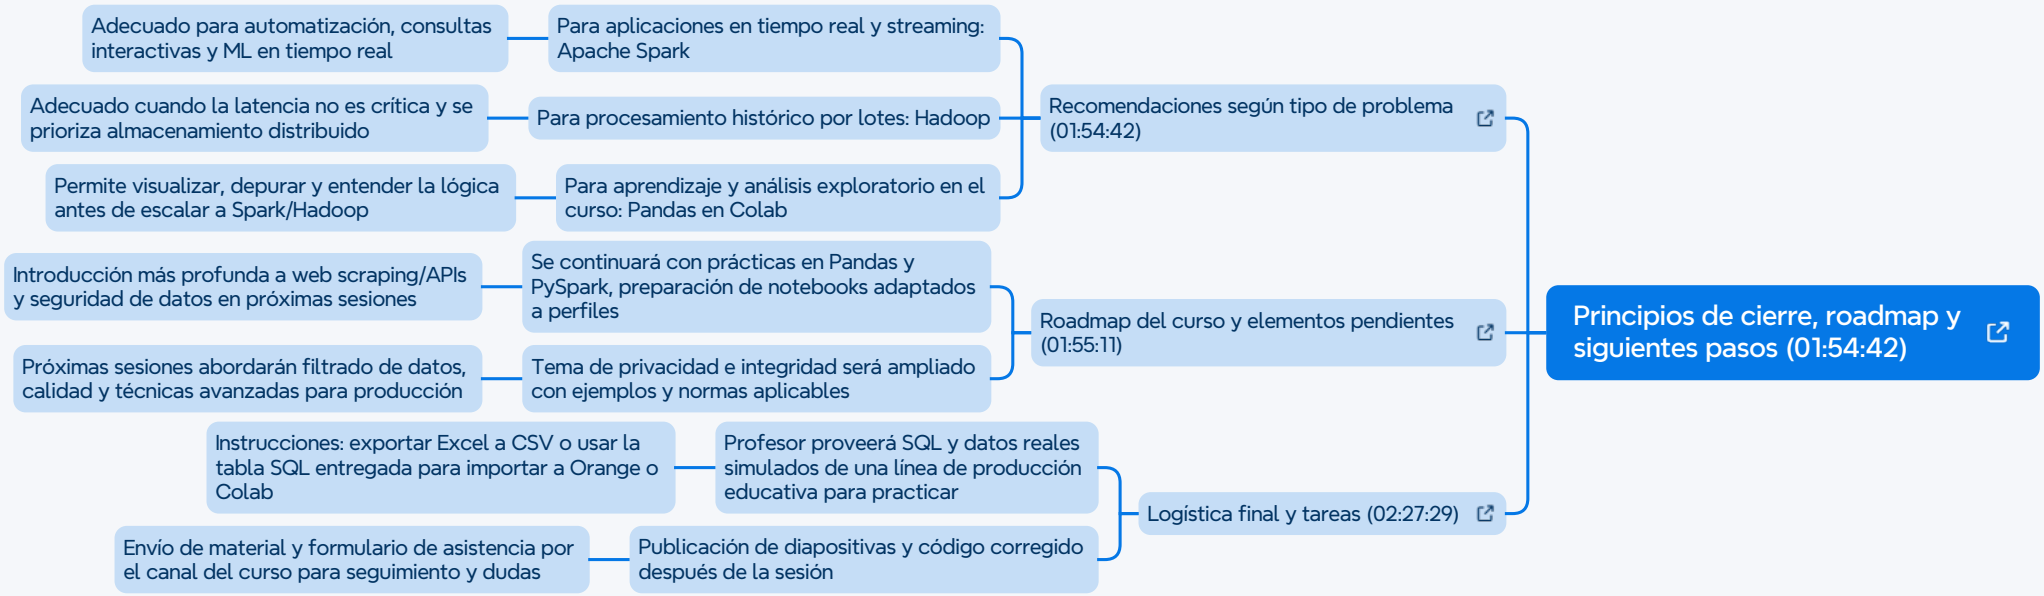

Dinámica de clase, perfiles de estudiantes y expectativas (00:28:04)
Presentaciones de participantes y experiencias con herramientas (00:29:41)
Resumen de perfiles: profesionales de minería, consultoría, procesos, planeamiento y software
Herramientas conocidas por alumnos: Excel, Power BI, SQL, Python, Visual Basic, .NET, Java
Casos concretos de aplicación mencionados por alumnos
Consolidación de datos multi-sede y problemas de enlaces en Power BI
Aplicaciones en mantenimiento predictivo para flotas y equipos pesados
Uso en planeamiento operativo y toma de decisiones estratégicas
Expectativas y aplicaciones laborales (00:29:41)
Objetivos comunes: profundizar en análisis de datos, ampliar mercado laboral y aplicar Machine Learning
Deseo de construir modelos predictivos para mantenimiento y gestión de equipos
Necesidades específicas: consolidación de múltiples fuentes, automatización de procesos y KPIs
Algunos buscan soluciones de alto nivel (gestión estratégica) sin experiencia en programación
Decisiones de diseño del curso según perfiles (00:47:58)
Profesor modulará contenidos prácticos el fin de semana para ajustarlos a los perfiles
Preparación de notebooks en Python/Colab considerando la diversidad de experiencia
Elección de Python como lenguaje inicial por su flexibilidad y ecosistema de librerías
Promueve que problemas específicos empresariales se resuelvan con rapidez mediante Python y asistentes de IA

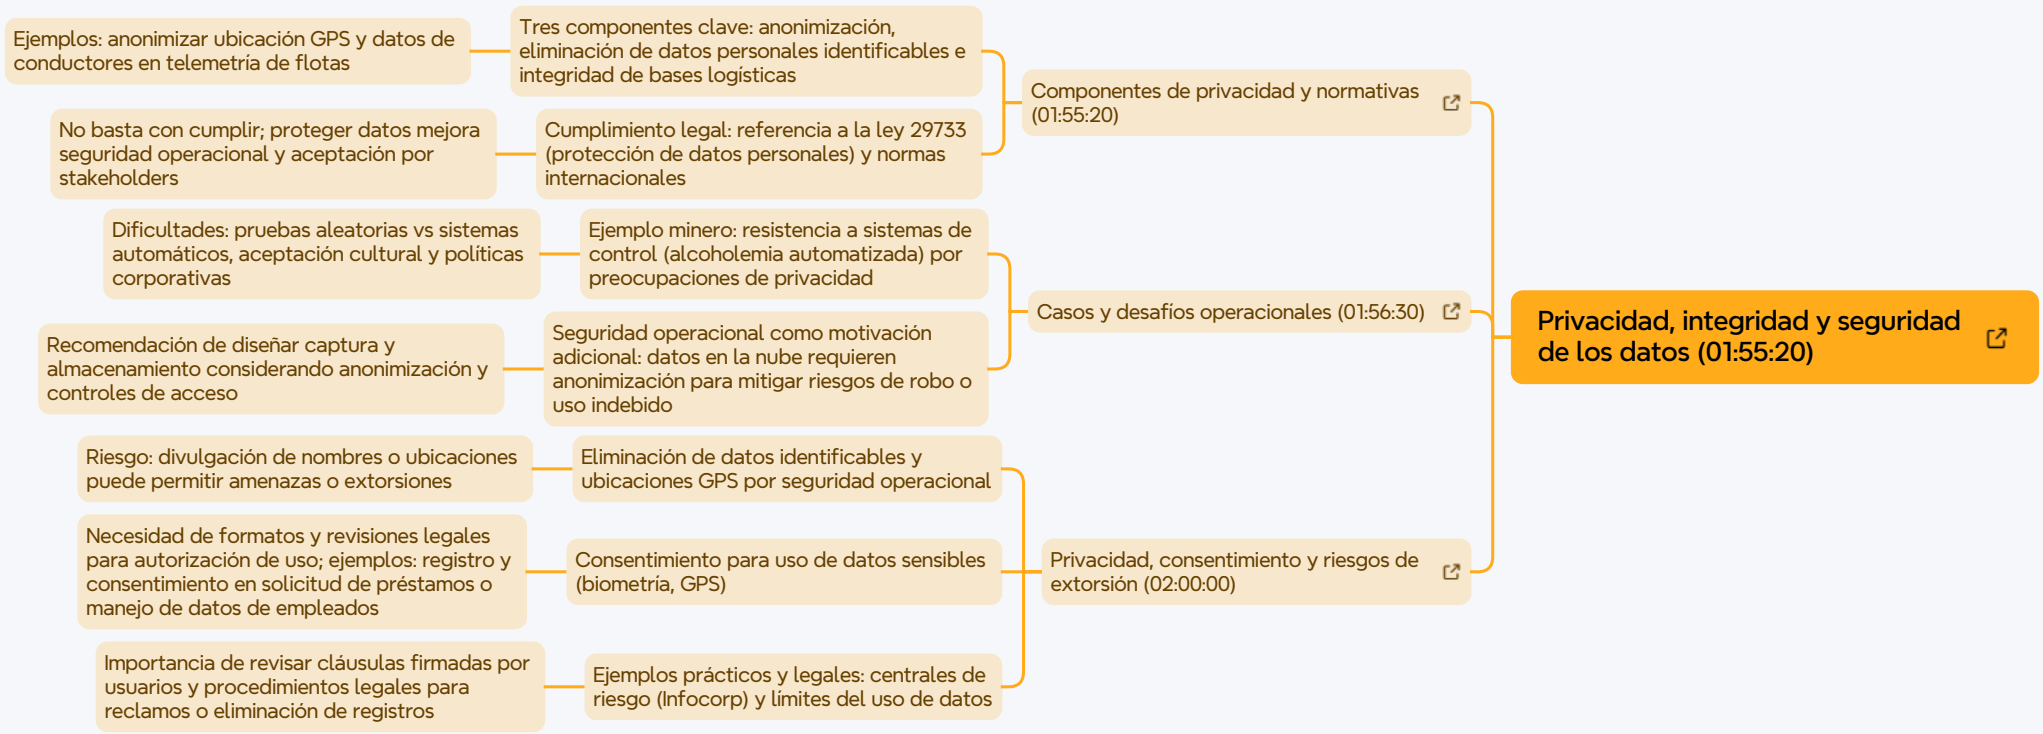

Big Data: Hadoop, Spark y elección de herramientas (01:00:04)
Comparativa general y criterios de elección (01:00:04)
Dos familias: frameworks distribuidos (Hadoop) vs motores en memoria y streaming (Spark)
Elegir según necesidad: procesamiento por lotes/histórico (Hadoop) o análisis en tiempo real/streaming (Spark)
Factores a considerar: latencia, consumo de recursos, facilidad de integración, seguridad y coste
Hadoop: menor consumo de RAM, orientado a disco y tareas por lotes
Spark: procesamiento en memoria, alta velocidad, soporte streaming y ML, mayor consumo de RAM
Hadoop: características, ventajas y limitaciones (01:06:25)
Hadoop como framework Apache para almacenamiento y procesamiento distribuido
Componentes clave: HDFS (sistema de archivos distribuido), MapReduce (modelo de programación), YARN (gestión de recursos) y Hadoop Common (bibliotecas)
Ventajas: escalabilidad horizontal, resistencia a fallos, uso de hardware común y comunidad open source
Ideal para análisis histórico, reportes periódicos y cuando no se requiere respuesta inmediata
Limitaciones: latencia por procesamiento en disco, complejidad de configuración en clústeres y menos adecuado para streaming en tiempo real
Empresas pueden preferir nube por facilidad, pero existen consideraciones de costo y seguridad que promueven edge computing
Apache Spark: uso, ventajas y escenarios (01:36:30)
Spark diseñado para procesamiento en memoria, velocidad y capacidades de streaming y ML
Soporta Python, Java, Scala; incluye Spark SQL, MLlib y Streaming
Casos de uso: consultas interactivas, streaming (IoT, SCADA), detección de fraudes, recomendaciones en tiempo real y procesamiento de transacciones rápidas
Ejemplo: estaciones de generación o plantas que requieren decisiones en tiempo real basadas en datos de control distribuido
Limitaciones: alto consumo de memoria, necesidad de buena infraestructura y complejidad en producción y optimización
Recomendado cuando la latencia y la rapidez de respuesta son críticos; no es ideal para transacciones simples o entornos con recursos limitados

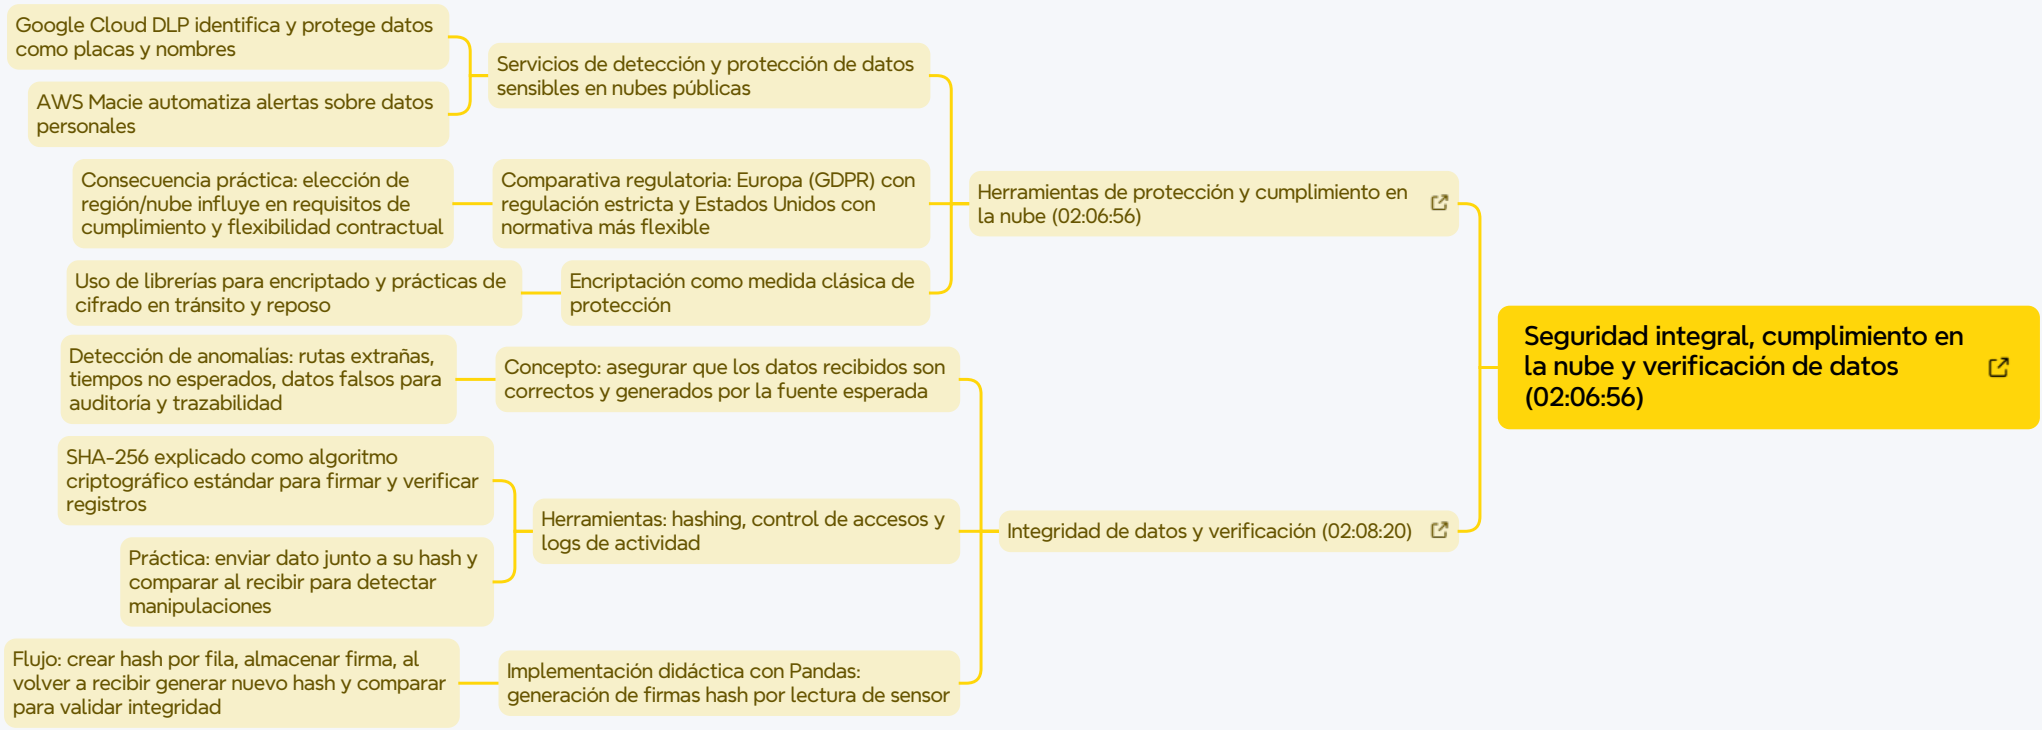

Captura de datos: IoT, web scraping y APIs (01:02:03)
IoT y captura desde sensores (01:02:03)
Apache y herramientas asociadas son preferidas para IoT industrial
Ejemplo: uso de MQTT (Mosquitto) para capturar datos directamente de máquinas y líneas de producción
Aplicaciones: control de condiciones ambientales, auditoría, cumplimiento legal y reducción de costos mediante hardware común
Importancia de diseñar adquisición de datos eficiente para aprovechar Spark en streaming si se requiere tiempo real
Web scraping y APIs como fuentes complementarias (01:03:32)
Data scraping con Python y consumo de APIs para obtener datos comerciales relevantes
Web scraping útil para inteligencia comercial y complementar datos operacionales
Integración posterior: procesar con Pandas o plataformas distribuidas según volumen y necesidad de latencia

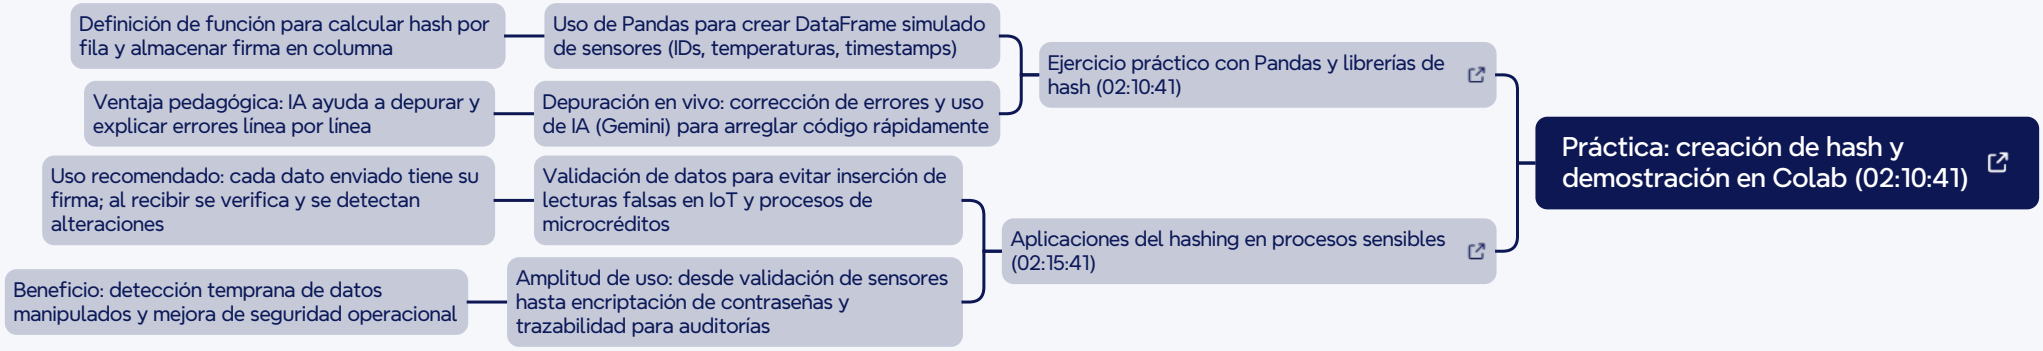

Prácticas en Google Colab: Pandas y PySpark (01:11:51)
Introducción a Pandas en Colab y flujo de trabajo (01:11:51)
Pandas como librería recomendada para iniciar en Data Analytics con Python
Crear DataFrame desde arreglos/diccionarios, uso de pd.DataFrame y funciones como groupby para resumir datos
Google Colab: crear cuaderno nuevo en Drive, pegar y ejecutar código línea por línea, visualizar tablas y gráficos
Ventajas: tablas interactivas, filtros, plots recomendados y acceso a IA (Gemini) para explicar código
Demostración práctica: ejemplo minero con Pandas (01:16:12)
Construcción de un DataFrame simple (mineral, toneladas) para simular producción de cobre
Uso de groupby para agrupar por mineral y display para mostrar resúmenes
Visualización y análisis exploratorio: distribuciones, filtrado interactivo y generación de gráficos desde el panel de Pandas en Colab
Recomendación de copiar y ejecutar paso a paso el código enviado por el profesor
Introducción a PySpark (Paispark) en Colab y ejemplo financiero (01:45:00)
Instalación de biblioteca PySpark en Colab y creación de SparkSession
Montar un ejemplo de microcréditos: crear arreglo de datos, columnas y DataFrame con Spark
Operaciones básicas: show(), groupBy(), avg() para obtener promedios por estado (aprobado/rechazado)
Ejercicio destaca la similitud conceptual MapReduce entre Pandas y Spark aunque la ventaja de Spark se nota con grandes volúmenes y streaming

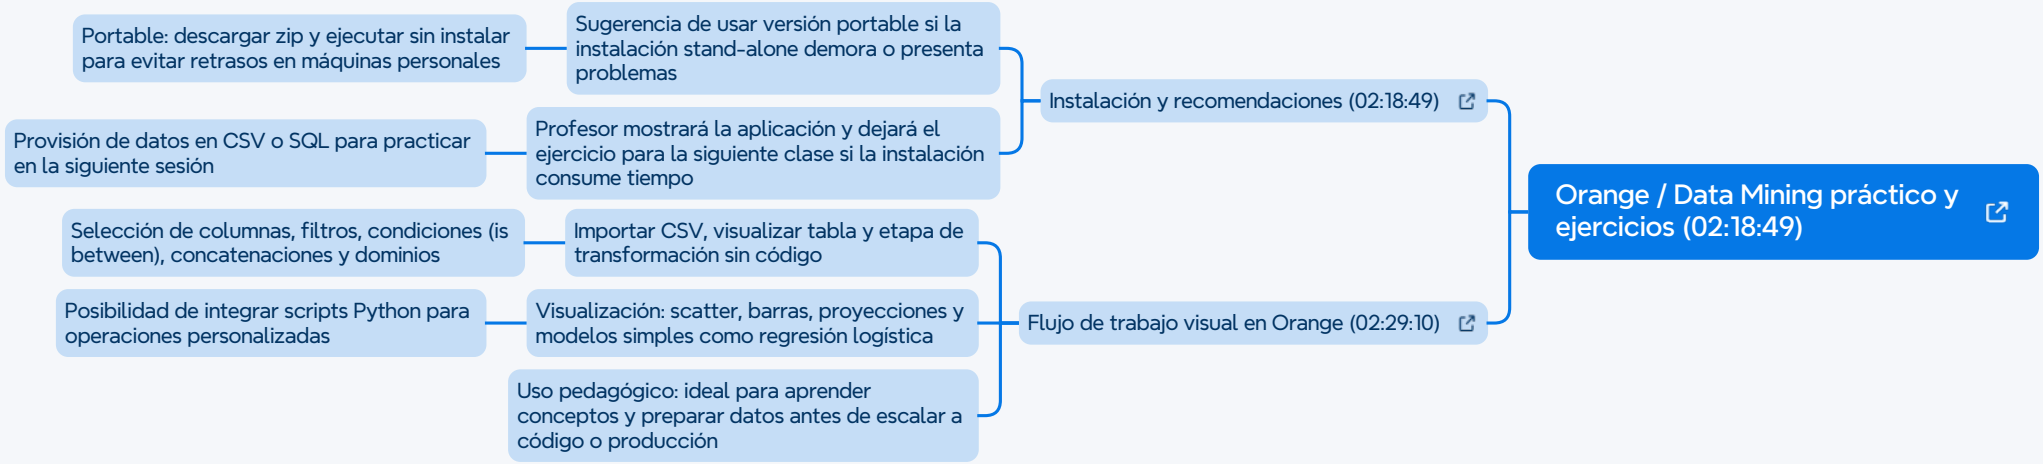

Principios de MapReduce y flujo lógico común (01:14:10)
Concepto y aplicación práctica (01:14:10)
MapReduce como modelo de programación para procesar datos en paralelo
Map: filtrar y transformar datos; Reduce: agrupar y resumir resultados (ej. groupby)
Aplicación escalable: puede implementarse desde scripts con Pandas hasta clústeres con Hadoop/Spark
Enseñanza basada en conceptos: crear DataFrame, map/reduce, mostrar resultados
Uso de IA para aprendizaje y depuración de código (01:13:31)
Recomendación de usar Gemini o ChatGPT para explicar código y obtener sugerencias
IA como herramienta que enseña línea por línea; necesidad de formular buenas preguntas y validar respuestas
Integración práctica: pedir a la IA que explique nuevas librerías o cómo crear DataFrames en diferentes entornos


Principios de cierre, roadmap y siguientes pasos (01:54:42)
Recomendaciones según tipo de problema (01:54:42)
Para aplicaciones en tiempo real y streaming: Apache Spark
Adecuado para automatización, consultas interactivas y ML en tiempo real
Para procesamiento histórico por lotes: Hadoop
Adecuado cuando la latencia no es crítica y se prioriza almacenamiento distribuido
Para aprendizaje y análisis exploratorio en el curso: Pandas en Colab
Permite visualizar, depurar y entender la lógica antes de escalar a Spark/Hadoop
Roadmap del curso y elementos pendientes (01:55:11)
Se continuará con prácticas en Pandas y PySpark, preparación de notebooks adaptados a perfiles
Introducción más profunda a web scraping/APIs y seguridad de datos en próximas sesiones
Tema de privacidad e integridad será ampliado con ejemplos y normas aplicables
Próximas sesiones abordarán filtrado de datos, calidad y técnicas avanzadas para producción
Logística final y tareas (02:27:29)
Profesor proveerá SQL y datos reales simulados de una línea de producción educativa para practicar
Instrucciones: exportar Excel a CSV o usar la tabla SQL entregada para importar a Orange o Colab
Publicación de diapositivas y código corregido después de la sesión
Envío de material y formulario de asistencia por el canal del curso para seguimiento y dudas


Privacidad, integridad y seguridad de los datos (01:55:20)
Componentes de privacidad y normativas (01:55:20)
Tres componentes clave: anonimización, eliminación de datos personales identificables e integridad de bases logísticas
Ejemplos: anonimizar ubicación GPS y datos de conductores en telemetría de flotas
Cumplimiento legal: referencia a la ley 29733 (protección de datos personales) y normas internacionales
No basta con cumplir; proteger datos mejora seguridad operacional y aceptación por stakeholders
Casos y desafíos operacionales (01:56:30)
Ejemplo minero: resistencia a sistemas de control (alcoholemia automatizada) por preocupaciones de privacidad
Dificultades: pruebas aleatorias vs sistemas automáticos, aceptación cultural y políticas corporativas
Seguridad operacional como motivación adicional: datos en la nube requieren anonimización para mitigar riesgos de robo o uso indebido
Recomendación de diseñar captura y almacenamiento considerando anonimización y controles de acceso
Privacidad, consentimiento y riesgos de extorsión (02:00:00)
Eliminación de datos identificables y ubicaciones GPS por seguridad operacional
Riesgo: divulgación de nombres o ubicaciones puede permitir amenazas o extorsiones
Consentimiento para uso de datos sensibles (biometría, GPS)
Necesidad de formatos y revisiones legales para autorización de uso; ejemplos: registro y consentimiento en solicitud de préstamos o manejo de datos de empleados
Ejemplos prácticos y legales: centrales de riesgo (Infocorp) y límites del uso de datos
Importancia de revisar cláusulas firmadas por usuarios y procedimientos legales para reclamos o eliminación de registros


Seguridad integral, cumplimiento en la nube y verificación de datos (02:06:56)
Herramientas de protección y cumplimiento en la nube (02:06:56)
Servicios de detección y protección de datos sensibles en nubes públicas
Google Cloud DLP identifica y protege datos como placas y nombres
AWS Macie automatiza alertas sobre datos personales
Comparativa regulatoria: Europa (GDPR) con regulación estricta y Estados Unidos con normativa más flexible
Consecuencia práctica: elección de región/nube influye en requisitos de cumplimiento y flexibilidad contractual
Encriptación como medida clásica de protección
Uso de librerías para encriptado y prácticas de cifrado en tránsito y reposo
Integridad de datos y verificación (02:08:20)
Concepto: asegurar que los datos recibidos son correctos y generados por la fuente esperada
Detección de anomalías: rutas extrañas, tiempos no esperados, datos falsos para auditoría y trazabilidad
Herramientas: hashing, control de accesos y logs de actividad
SHA-256 explicado como algoritmo criptográfico estándar para firmar y verificar registros
Práctica: enviar dato junto a su hash y comparar al recibir para detectar manipulaciones
Implementación didáctica con Pandas: generación de firmas hash por lectura de sensor
Flujo: crear hash por fila, almacenar firma, al volver a recibir generar nuevo hash y comparar para validar integridad


Práctica: creación de hash y demostración en Colab (02:10:41)
Ejercicio práctico con Pandas y librerías de hash (02:10:41)
Uso de Pandas para crear DataFrame simulado de sensores (IDs, temperaturas, timestamps)
Definición de función para calcular hash por fila y almacenar firma en columna
Depuración en vivo: corrección de errores y uso de IA (Gemini) para arreglar código rápidamente
Ventaja pedagógica: IA ayuda a depurar y explicar errores línea por línea
Aplicaciones del hashing en procesos sensibles (02:15:41)
Validación de datos para evitar inserción de lecturas falsas en IoT y procesos de microcréditos
Uso recomendado: cada dato enviado tiene su firma; al recibir se verifica y se detectan alteraciones
Amplitud de uso: desde validación de sensores hasta encriptación de contraseñas y trazabilidad para auditorías
Beneficio: detección temprana de datos manipulados y mejora de seguridad operacional


Orange / Data Mining práctico y ejercicios (02:18:49)
Instalación y recomendaciones (02:18:49)
Sugerencia de usar versión portable si la instalación stand-alone demora o presenta problemas
Portable: descargar zip y ejecutar sin instalar para evitar retrasos en máquinas personales
Profesor mostrará la aplicación y dejará el ejercicio para la siguiente clase si la instalación consume tiempo
Provisión de datos en CSV o SQL para practicar en la siguiente sesión
Flujo de trabajo visual en Orange (02:29:10)
Importar CSV, visualizar tabla y etapa de transformación sin código
Selección de columnas, filtros, condiciones (is between), concatenaciones y dominios
Visualización: scatter, barras, proyecciones y modelos simples como regresión logística
Posibilidad de integrar scripts Python para operaciones personalizadas
Uso pedagógico: ideal para aprender conceptos y preparar datos antes de escalar a código o producción