
EDU MIN
CLASE 17: OPTIMIZACIÓN EN LOS COSTOS DE OPERACIONES MINERAS - 1RA PARTE
Introducción y contexto general sobre la geometalurgia y su integración operativa (00:00:07)
Planeamiento minero ligado al modelamiento geometalúrgico y mezcla de bloques (00:20:54)
Análisis Exploratorio de Datos (EDA) aplicado a geometalurgia y definición de UGMs (00:28:25)
Manejo de datos escasos: proxies, regresiones y escalamiento a planta (00:37:44)
Modelos de regresión para predecir parámetros metalúrgicos y uso práctico con Orange Data Mining (00:45:41)
Validación, limitaciones y recomendaciones operativas para geometalurgia aplicada (00:59:30)
Revisión y manipulación de widgets y base de datos en Orange (01:00:03)
Conceptos clave de modelado predictivo y particionado de datos (01:03:50)
Recursos, software y cierre de la sesión educativa (02:11:08)
Importancia del test de consumo de ácido y su integración en el modelo (02:09:17)
Interpretación del clustering aplicado a variables múltiples y objetivo geometalúrgico (02:07:11)
Proceso iterativo del algoritmo k-means y ajuste de centroides (02:03:21)
Demostración práctica de clustering y generación de clusters (02:00:03)
Conceptos generales de minería de datos y recomendaciones de aprendizaje continuo (01:42:12)
Preparación de datos, limpieza y avance hacia clustering para consumo de ácido (01:38:22)
Selección de predictores, correlaciones y prácticas de exportación de resultados (01:27:55)
Construcción, evaluación y visualización del modelo de regresión lineal (01:17:14)

Introducción y contexto general sobre la geometalurgia y su integración operativa (00:00:07)

- Importancia del soporte geoestadístico y elección metodológica para extrapolar resultados espaciales (00:16:05)
  - Es fundamental seleccionar la metodología adecuada para extrapolar resultados de puntos espaciales dentro de la unidad geometalúrgica del yacimiento.
  - La extrapolación debe permitir generar bloques geometalúrgicos coherentes para la planificación y operación minera.
  - El proceso está en desarrollo y requiere revisión académica y ajustes en sílabos y formación profesional continua.
- Realidad operativa: la operación no espera a los modelos geometalúrgicos (00:18:20)
  - Las operaciones mineras continúan independientemente de la madurez del modelo geometalúrgico; muchas operan con o sin modelos.
  - Algunas operaciones utilizan modelos paralelos o modelos de referencia que se validan y aplican progresivamente.
  - La mayoría de la gran minería en Perú ya ha implementado metodologías de geometalurgia, aunque con variaciones entre organizaciones.
- Necesidad de actualización académica y competencias interdisciplinares (00:17:02)
  - Instituciones educativas deben replantear y reformular sílabos para incorporar mejor la geometalurgia.
  - La formación exige integración de geólogos, mineros, metalurgistas y otros especialistas que trabajen en equipo.
  - Los profesionales deben desarrollar competencias transversales en geometalurgia para operar y optimizar un yacimiento.

Planeamiento minero ligado al modelamiento geometalúrgico y mezcla de bloques (00:20:54)

- Conexión entre caracterización, modelamiento y planeamiento de minado (00:21:46)
  - La cadena: caracterización de yacimiento, modelamiento de recursos, modelamiento geometalúrgico y planeamiento minero deben estar integrados.
  - El planeamiento minero debe considerar cómo emplear los bloques del modelo geometalúrgico para optimizar el tajo o labores subterráneas.
  - La integración permite determinar la estrategia de extracción y la combinación (blending) de bloques para obtener mineral de calidad homogénea.
- Problemas prácticos en la operación: límites de cono y variabilidad del frente (00:22:18)
  - En la práctica se presentan sorpresas al minar frentes que están representados por bloques contiguos con distinta naturaleza, afectando la ley enviada a planta.
  - El manejo del cono envolvente y los límites de frentes requiere criterios expertos del geólogo y del minero para evitar mandos de material estéril a planta.
  - El control de envolventes y secuencias de minado influye directamente en la ley promedio y en la productividad del proceso.
- Blending y recomendaciones del modelo geometalúrgico para desarrollar el tajo (00:24:26)
  - El modelo geometalúrgico debe indicar combinaciones de bloques que optimicen la mezcla para procesamiento.
  - A partir de esa recomendación se diseña el desarrollo del tajo y las labores subterráneas, considerando mezclas y secuencia de extracción.
  - Estas operaciones unitarias requieren soporte especializado y coordinación multidisciplinar para ser eficientes y coherentes.

Análisis Exploratorio de Datos (EDA) aplicado a geometalurgia y definición de UGMs (00:28:25)

- Propósito del EDA y objetivo final de definir UGMs en modelamiento geometalúrgico (00:28:29)
  - El EDA resume las características principales de una base de datos mediante tablas y gráficos para formular hipótesis y explorar datos.
  - En geometalurgia el objetivo principal del EDA es definir Unidades Geometalúrgicas (UGMs) que controlen espacialmente el comportamiento metalúrgico.
  - Con la estimación se desarrolla un modelo de bloques basado en la respuesta metalúrgica estimada.
- Tipos de gráficas y tablas usados en EDA para geometalurgia (00:33:03)
  - Boxplots para resumir distribución de parámetros metalúrgicos, por ejemplo leyes de concentrado o parámetros de recuperación.
  - Gráficos probabilísticos (distribución acumulada en escala logarítmica) para comparar distribuciones de distintos dominios y UGMs.
  - Tablas de estadística descriptiva con media, mediana, desviación, cuantiles y otros indicadores que apoyan la definición de UGMs.
- Uso de EDA para agrupar dominios y formar UGMs basadas en parámetros metalúrgicos (00:34:07)
  - A partir de diferencias claras en las distribuciones (p. ej. unidad rica en pirita con baja ley de concentrado) se separan dominios para UGMs independientes.
  - El análisis de distribuciones permite agrupar dominios geológicos y convertirlos en UGMs con valores característicos de respuesta metalúrgica.
  - Las UGMs integran parámetros como ley de concentrado, dureza, velocidad de sedimentación o consumo ácido para caracterizar comportamiento metalúrgico.

EDU MIN

Manejo de datos escasos: proxies, regresiones y escalamiento a planta (00:37:44)

- Problema de bajo número de datos y resolución temporal para planes de corto y mediano plazo (00:38:34)
  - A menudo la frecuencia de muestreo es baja (por ejemplo una muestra cada varias semanas), insuficiente para planes semanales o de corto plazo.
  - El escaso número de muestras limita la resolución espacial y temporal del modelo geometalúrgico para planificación operativa.
  - Es necesario complementar datos con técnicas que aumenten la densidad de información para control de corto plazo.
- Uso de proxies y regresiones para incrementar la cantidad de datos disponibles (00:39:23)
  - Los proxies permiten obtener indirectamente el parámetro de interés (por ejemplo Work Index) mediante correlaciones con variables más abundantes.
  - Aunque los proxies son menos precisos que tests directos, permiten generar miles de datos estimados para mejorar la resolución de planes de producción.
  - Ejemplos de uso incluyen ecuaciones de regresión que relacionan mineralogía, químicas u otros parámetros operacionales con índices metalúrgicos.
- Escalamiento de ensayos de pequeña escala a resultados homologables a planta (00:30:56)
  - Ensayos de microcolumnas o columnas de diferente altura permiten determinar factores de escalamiento entre pruebas pequeñas y respuesta a escala más industrial.
  - El escalamiento define factores (por ejemplo 0,96) para ajustar recuperaciones o extracciones estimadas a una escala cercana a planta.
  - Si existe planta operativa, los datos permiten llevar a cabo reconciliaciones y validar funciones de escalamiento entre ensayo y planta.

Modelos de regresión para predecir parámetros metalúrgicos y uso práctico con Orange Data Mining (00:45:41)

- Introducción a regresión lineal simple y múltiple para predecir variables metalúrgicas (00:45:52)
  - La regresión lineal simple modela una variable dependiente en función de un predictor mediante pendiente e intercepto.
  - La regresión múltiple usa varias variables predictoras para estimar una respuesta dependiente, aplicable a predicción de Work Index o recuperación.
  - Variables predictoras posibles incluyen mineralogía, leyes químicas y parámetros operacionales; la variable objetivo puede ser Work Index u otro parámetro metalúrgico.
- Ejemplo práctico: predicción del Work Index usando leyes químicas como predictores (00:58:45)
  - Objetivo del ejercicio: generar una regresión lineal múltiple para predecir Work Index basándose en contenidos de hierro, magnesio y sílice.
  - El Work Index se define como la variable target; las leyes químicas se definen como features (predictores) en el modelo.
  - Se establece el rol y tipo de variables (numérico, categórico, metadato) antes de aplicar el modelo para asegurar correcta configuración.
- Software Orange Data Mining: funcionalidades y flujo de trabajo para el ejercicio práctico (00:49:24)
  - Orange Data Mining es software libre orientado a visualización de datos, Machine Learning y Data Mining, con widgets y posibilidad de integrar Python.
  - El entorno ofrece widgets para importar, transformar, preprocesar y visualizar datos, así como algoritmos supervisados y no supervisados.
  - En el ejemplo se utiliza el widget File para cargar la base de datos, se asignan tipos y roles a variables, y luego se aplica el modelo de regresión múltiple para predecir Work Index.

Validación, limitaciones y recomendaciones operativas para geometalurgia aplicada (00:59:30)

- Consideraciones sobre validación, actualización de datos y recarga de bases en workflows (00:59:30)
  - Es importante mantener actualizada la base de datos; el software permite recargar (reload) para actualizar análisis tras cambios en los datos.
  - Definir metadatos y roles facilita comparar y visualizar información en los gráficos y asegurar consistencia en el análisis.
  - La práctica indica que combinar datos operacionales, ensayos y proxies mejora la validez del modelo para distintos horizontes de planificación.
- Limitaciones de métodos y balance entre geostatística y modelos basados en proxies (00:40:42)
  - En algunas escuelas (por ejemplo mencionadas en Chile) la práctica predominante es estimar directamente mediante geoestadística aun con espaciamientos grandes entre muestras.
  - En otros enfoques se prefieren modelos de regresión que permiten aumentar la cantidad de datos disponibles mediante proxies y modelos estadísticos.
  - La decisión metodológica depende del propósito: modelos de largo plazo prefieren geoestadística con muestras directas; corto plazo puede requerir proxies y regresiones complementarias.
- Recomendaciones prácticas para integración geometalúrgica en operación minera (00:24:51)
  - Formar equipos interdisciplinarios que incluyan geólogos, mineros, metalurgistas y otros expertos para diseñar metodologías eficientes.
  - Implementar UGMs bien definidas y respaldadas por EDA que permitan control espacial del comportamiento metalúrgico.
  - Emplear proxies y escalamiento cuando la disponibilidad de datos directos sea limitada, y validar mediante reconciliaciones con planta cuando sea posible.

Revisión y manipulación de widgets y base de datos en Orange (01:00:03)

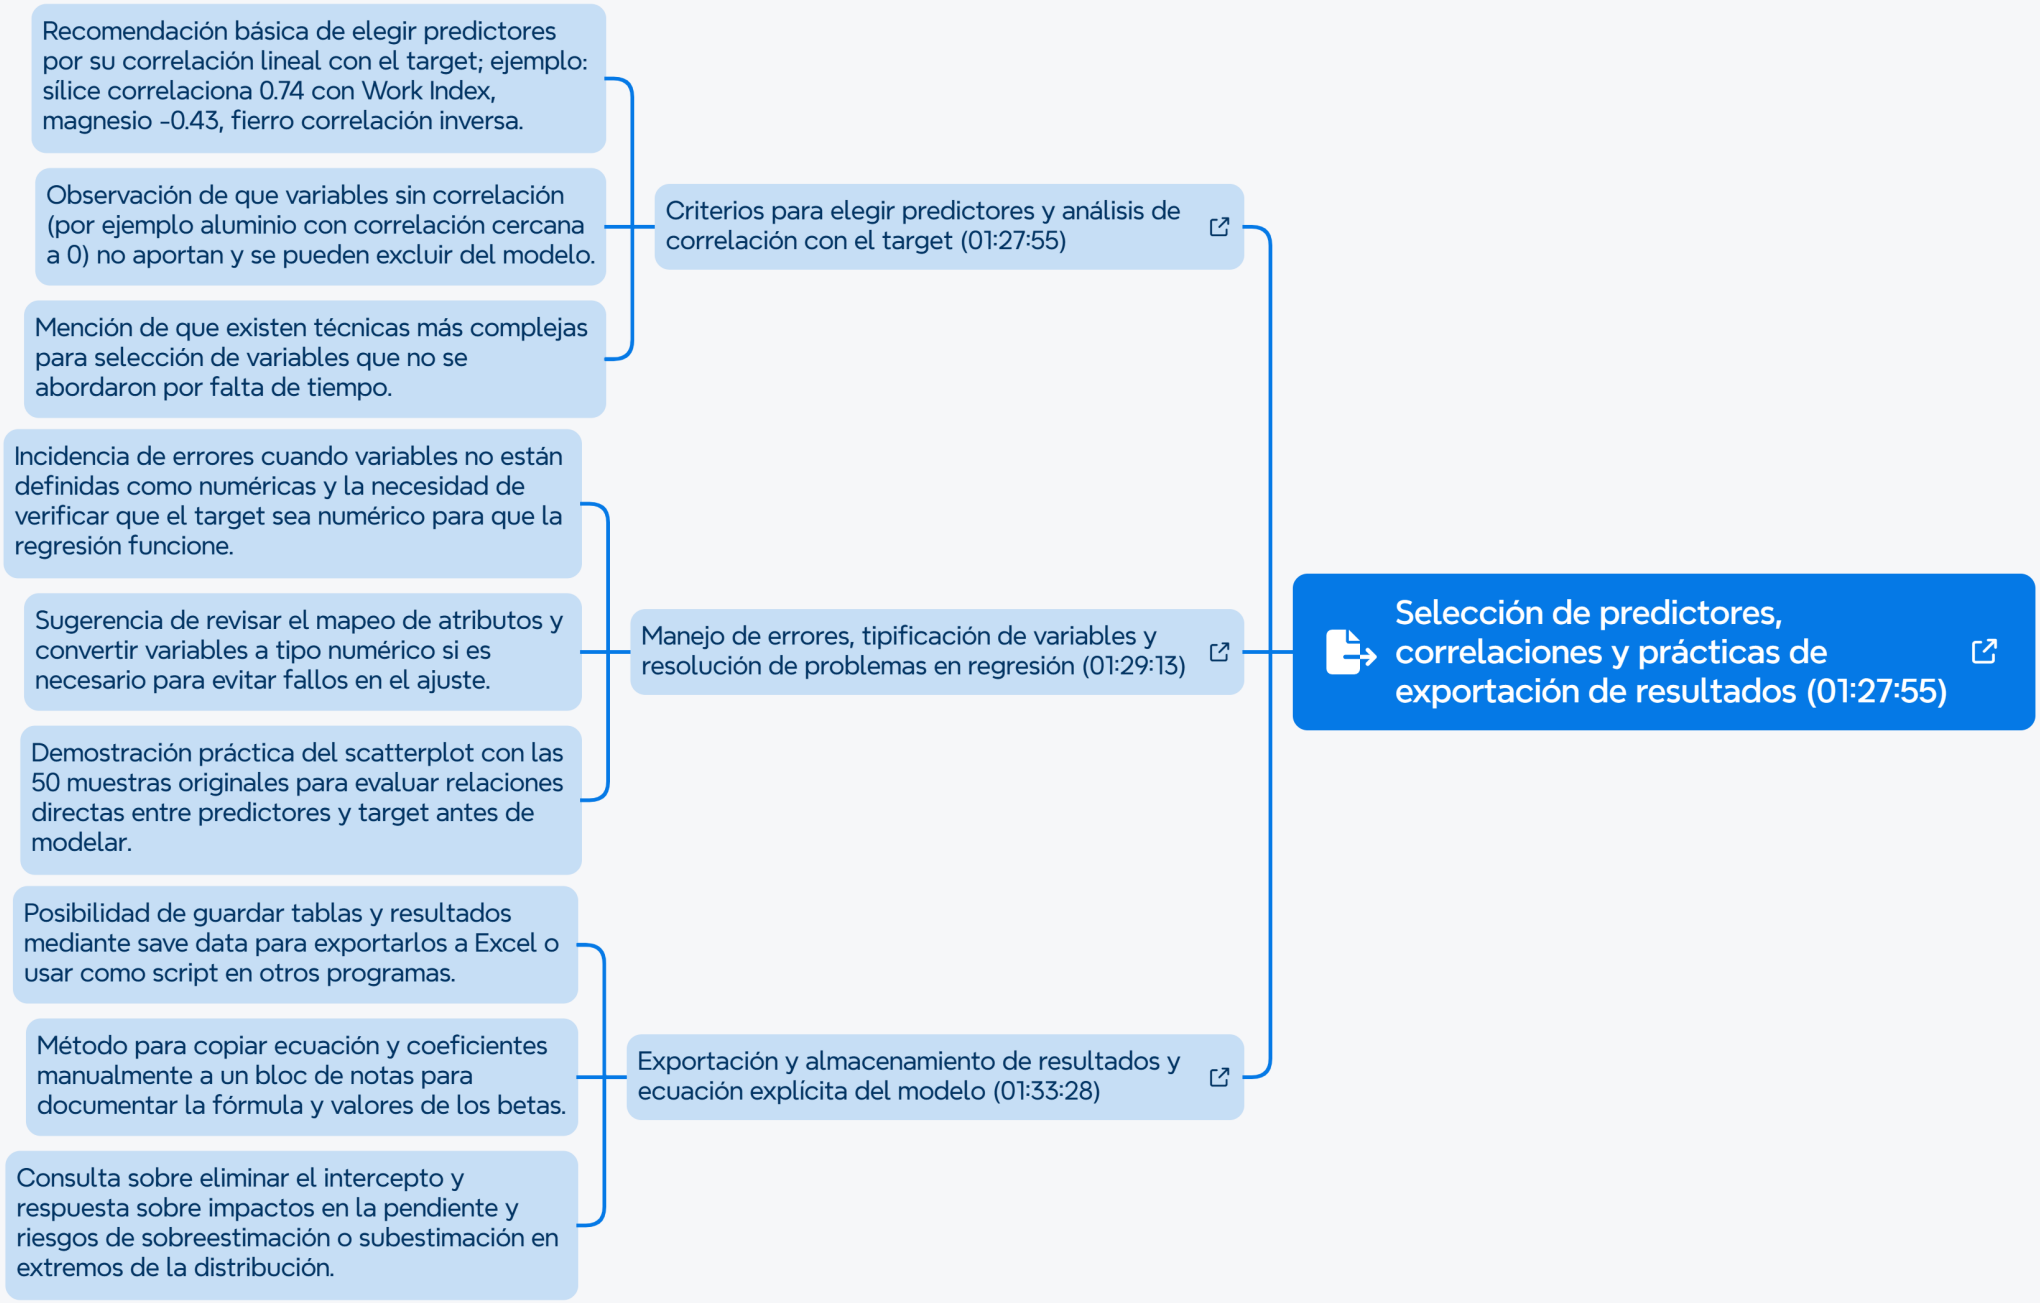
- Introducción a la interacción con widgets en la interfaz de Orange (01:00:07)
  - Explicación de cómo arrastrar y soltar widgets desde la paleta hasta el lienzo usando el botón izquierdo del ratón para visualizar opciones.
  - Alternativa de arrastrar widgets desde la parte superior y comprobar que al juntarlos se conectan automáticamente para formar flujos de trabajo.
  - Sugerencia de cambiar el zoom con control + rueda del ratón para ver widgets pequeños y facilitar la interacción en pantalla.
- Visualización y revisión de la tabla de datos cargada (01:01:44)
  - Doble clic en el widget Data Table para desplegar la base de datos y verificar que contiene 50 muestras y columnas de predictores y target.
  - Descripción del target (work index) y de los predictores (ley de fierro, ley de magnesio, ley de sílice) y mención de que los datos son reales de un depósito ortomagmático de Brasil.
  - Aclaración de que la columna target aparece como metadato y no se utilizará para la regresión en ese momento.
- Uso del Data Sample para dividir los datos en entrenamiento y test (01:05:51)
  - Inserción del widget Data Sample para dividir la base de datos en conjunto de entrenamiento y test, usando doble clic para configurarlo.
  - Explicación de seleccionar todos los datos como entrada y de eliminar conexiones innecesarias para reorganizar el flujo.
  - Justificación del muestreo: reservar por ejemplo el 20% para testeo y usar 80% para entrenamiento, mostrando que con 50 muestras quedan 40 para entrenar y 10 para testear.

Conceptos clave de modelado predictivo y particionado de datos (01:03:50)

- Necesidad de datos frescos para evaluar modelos predictivos y evitar sobreajuste (01:03:50)
  - Definición de por qué el modelo debe probarse con datos que no haya visto antes, evitando que memorice los puntos y dé resultados engañosamente perfectos.
  - Ejemplo de cómo una regresión polinomial puede pasar por todos los puntos de entrenamiento sin garantizar predicción correcta en datos nuevos.
  - Conclusión de que siempre hay que dividir los datos en sets de entrenamiento y test para medir la predictibilidad real.
- Opciones y métodos de muestreo y su impacto en la validación (01:12:10)
  - Mención de variantes como muestro estratificado, validación cruzada (cross-validation) y bootstrap, y cuándo son apropiadas según el tamaño de la muestra.
  - Observación de que la división 80-20 es una regla práctica común pero no obligatoria, pudiendo usarse 75-25 o 90-10 según disponibilidad de datos.
  - Nota sobre la importancia de conservar mayor parte de la muestra para entrenar el modelo cuando los datos son limitados, especialmente en geometalurgia.
- Configuración práctica del Data Sampler y obtención de subconjuntos (01:13:11)
  - Indicaciones para marcar opciones en Data Sample, elegir réplica y/o estratificación según se requiera, y ajustar el porcentaje de muestra al 80%.
  - Creación de dos tablas resultantes para visualizar training (remaining) con 40 muestras y test con 10 muestras tras el muestreo.
  - Aclaración de que la partición se realiza al azar pero puede ser determinística y replicable; recordar que existen métodos no aleatorios si se desea.

Construcción, evaluación y visualización del modelo de regresión lineal (01:17:14)

- Creación del modelo de regresión lineal y visualización de coeficientes (01:17:14)
  - Inserción del widget Linear Regression para ajustar un modelo lineal sencillo sin regularización adicional por defecto.
  - Doble clic en Regression para ver coeficientes: intercepto (beta0) y betas asociados a las leyes (fierro, magnesio, sílice).
  - Ejemplo explícito de la ecuación: Work Index = -3.9 + (-0.6)Fe + 0.3Mg + 0.3*Si (valores aproximados mostrados en la sesión).
- Predicción sobre el conjunto de test y comparación con valores reales (01:21:12)
  - Conexión del modelo con un widget de predicciones para aplicar la regresión a las 10 muestras test que el modelo no vio durante el entrenamiento.
  - Visualización de la predicción en un scatterplot comparando Work Index predicho (eje X) contra Work Index real (eje Y) para las muestras test.
  - Ejemplo de un punto donde la regresión predijo 17.2 y el valor real era 15.4, ilustrando discrepancias punto a punto.
- Interpretación de métricas gráficas y ajustes posibles del modelo (01:23:39)
  - Posibilidades de personalizar el scatterplot: tamaño y opacidad de símbolos, mostrar o ocultar leyenda y líneas de regresión.
  - Clarificación de que R cuadrado (R^2) es la medida del grado de explicación entre variables y puede observarse en el gráfico; afirmación de que el modelo en el ejercicio mostró buen ajuste.
  - Debate sobre ajustar el modelo usando las 10 muestras restantes para comparar o generar otra regresión, y advertencia sobre el peligro de usar todos los datos para entrenar sin testeo por sobreajuste.


Selección de predictores, correlaciones y prácticas de exportación de resultados (01:27:55)
Criterios para elegir predictores y análisis de correlación con el target (01:27:55)
Recomendación básica de elegir predictores por su correlación lineal con el target; ejemplo: sílice correlaciona 0.74 con Work Index, magnesio -0.43, fierro correlación inversa.
Observación de que variables sin correlación (por ejemplo aluminio con correlación cercana a 0) no aportan y se pueden excluir del modelo.
Mención de que existen técnicas más complejas para selección de variables que no se abordaron por falta de tiempo.
Manejo de errores, tipificación de variables y resolución de problemas en regresión (01:29:13)
Incidencia de errores cuando variables no están definidas como numéricas y la necesidad de verificar que el target sea numérico para que la regresión funcione.
Sugerencia de revisar el mapeo de atributos y convertir variables a tipo numérico si es necesario para evitar fallos en el ajuste.
Demostración práctica del scatterplot con las 50 muestras originales para evaluar relaciones directas entre predictores y target antes de modelar.
Exportación y almacenamiento de resultados y ecuación explícita del modelo (01:33:28)
Posibilidad de guardar tablas y resultados mediante save data para exportarlos a Excel o usar como script en otros programas.
Método para copiar ecuación y coeficientes manualmente a un bloc de notas para documentar la fórmula y valores de los betas.
Consulta sobre eliminar el intercepto y respuesta sobre impactos en la pendiente y riesgos de sobreestimación o subestimación en extremos de la distribución.

Preparación de datos, limpieza y avance hacia clustering para consumo de ácido (01:38:22)

- Importancia de la limpieza de datos y tratamiento de valores faltantes o códigos especiales (01:52:29)
  - Detección de valores codificados como -99 que indican ausencia de medición y la necesidad de excluirlos o tratarlos antes de promediar.
  - Advertencia sobre reemplazar -99 por cero sin criterio, ya que el cero es un valor válido pero distinto de un dato faltante.
  - Énfasis en que la preparación de datos suele consumir más tiempo que el análisis mismo y es clave para resultados válidos.
- Descripción del ensayo de consumo de ácido y relevancia económica en plantas de lixiviación (01:55:08)
  - Descripción del ensayo isopH de botellas: 1 kg de muestra, granulometría aproximada (10 mallas), 2 litros de agua, pH 1,5 mantenido por 72 horas, 20 rpm de agitación y medición de cobre libre y consumo de ácido.
  - Explicación de la importancia económica del consumo de ácido, representando alrededor del 10% del costo operativo en una planta de lixiviación y con precio del ácido cerca de 100 USD por tonelada.
  - Conexión entre la medición y la necesidad de modelar el consumo para optimizar costos y procesos.
- Introducción al clustering para generar UGMs preliminares de consumo de ácido (01:57:01)
  - Objetivo del ejercicio: usar clustering para crear grupos de comportamiento similar en consumo de ácido y obtener Unidades Geometalúrgicas (UGMs) preliminares.
  - Definición de clustering: agrupar muestras para que las del mismo grupo sean lo más semejantes posible y difieran de las de otros grupos.
  - Descripción de insumos disponibles: coordenadas de muestras, análisis químico, mineralogía y consumo de ácido, y planificación de realizar la práctica después del almuerzo.

Conceptos generales de minería de datos y recomendaciones de aprendizaje continuo (01:42:12)

- Definición y pilares de la minería de datos aplicada a minería (01:43:45)
  - Definición de data mining como campo de informática y estadística para extraer información útil desde grandes bases de datos y transformarla para uso posterior.
  - Tres pilares: estadística (colección y análisis), machine learning (algoritmos automáticos) y bases de datos (organización y almacenamiento de datos).
  - Aplicación práctica en minería: mejorar capacidad de planta, aumentar recuperaciones y transformar datos de sondajes, mineralogía y análisis químicos en modelos útiles.
- Flujo de trabajo en data mining y necesidad de actualización constante de modelos (01:45:22)
  - Pasos: entender problema de negocio, preparar datos, construir modelos, evaluar con conjunto de test y producir un producto usable por otras áreas, como modelos de bloque.
  - Observación de que todos los modelos caducan debido a nuevos datos y condiciones cambiantes, por lo que requieren actualización periódica.
  - Ejemplos de aplicaciones cotidianas de data mining: motores de búsqueda, recomendaciones de Amazon o YouTube y detección de fraudes, mostrando su presencia actual en múltiples industrias.
- Recursos de aprendizaje y sugerencias para formación práctica en data science (01:49:54)
  - Recomendación de Wikipedia y YouTube para materiales introductorios y prácticos, y mención de cursos MOOC en plataformas como Udemy y Coursera para aprendizaje estructurado.
  - Comentario sobre la rápida evolución del campo y que muchos empleadores valoran habilidades prácticas por encima de títulos formales en programación y machine learning.
  - Invitación a involucrarse en data science por su aplicabilidad inmediata y ventajas para el análisis de grandes volúmenes de datos en minería.

Demostración práctica de clustering y generación de clusters (02:00:03)

- Descripción de la muestra y conexión de puntos generados por el instructor (02:00:13)
  - El instructor explica que ha conectado visualmente las muestras que él mismo fabricó para ilustrar un conjunto de datos sintético observable en pantalla.
  - Presenta los puntos dispersos en dos dimensiones para facilitar la comprensión inicial del agrupamiento.
  - Indica que se utilizarán esas mismas muestras para generar clusters y observar el comportamiento del algoritmo.
- Definición intuitiva de "cluster" y creación de tres grupos (02:00:48)
  - Explica qué significa cluster de forma simple: "tres bolsitas" donde se agrupan las muestras según similitud.
  - Señala que se pedirá al algoritmo que genere exactamente tres clusters predefinidos por la instrucción.
  - Menciona que también puede solicitarse otro número de clusters, por ejemplo 2, y que 1 no tiene sentido práctico para la demostración.
- Limitación humana versus capacidad del algoritmo para dimensiones altas (02:02:08)
  - Pregunta retóricamente cómo harían los asistentes para agrupar datos si en vez de dos variables tuvieran diez dimensiones, señalando la imposibilidad humana.
  - Explica que el algoritmo calcula distancias en todas las dimensiones y busca los mejores grupos automáticamente.
  - Señala que esta capacidad de iterar en múltiples dimensiones es la principal ventaja del algoritmo frente al juicio humano manual.

Proceso iterativo del algoritmo k-means y ajuste de centroides (02:03:21)

- Ejecución inicial y asignación aleatoria de centroides (02:03:21)
  - El orador muestra que el algoritmo comienza con posicionamientos aleatorios de centroides, lo que puede producir agrupaciones insatisfactorias inicialmente.
  - Comenta ejemplos de asignaciones donde el algoritmo agrupa muestras que un humano no consideraría juntas.
  - Describe la observación de resultados feos o no coincidentes con la intuición humana al inicio de la ejecución.
- Recomputación de centroides y reasignación iterativa de muestras (02:04:05)
  - Explica que el algoritmo reposiciona los centroides moviéndolos al centro (media) de las muestras asignadas a cada cluster.
  - Muestra cómo, tras varias iteraciones, el algoritmo recalcula las asignaciones basadas en distancias y actualiza centroides repetidamente.
  - Señala que ese proceso iterativo permite que el algoritmo converja hacia una solución que minimiza las distancias internas de cada cluster.
- Convergencia final y comparación con la agrupación humana (02:05:52)
  - Indica que, tras suficiente iteración, el algoritmo logra identificar grupos equivalentes a los que un humano habría señalado en el ejemplo bidimensional.
  - Describe que los centroides finales minimizan las distancias dentro de cada grupo y reflejan comportamientos homogéneos.
  - Enumera cómo se interpretan los clusters en términos de variables X e Y (ejemplos de bajo/alto en cada variable).

Interpretación del clustering aplicado a variables múltiples y objetivo geometalúrgico (02:07:11)

Uso de muchas dimensiones para agrupar variables y predictores (02:07:11)

- Se enfatiza que el ejemplo es sencillo en dos dimensiones, pero el objetivo real consiste en aplicar el mismo procedimiento con muchas variables.
- Señala que teóricamente se podrían usar hasta 12 dimensiones o más para generar clusters representativos.
- Indica que el algoritmo repetirá el mismo ajuste iterativo en espacios de alta dimensionalidad para encontrar nubes consistentes.

Relación entre clustering y la variable objetivo de consumo de ácido (02:08:18)

- Se plantea como objetivo entender la variable target del consumo de ácido mediante agrupamientos de predictores.
- Explica que se analizará cómo se agrupan los datos de consumo de ácido y su relación con química y mineralogía.
- Señala que los clusters ayudarán a explicar variaciones en consumo de ácido a partir de múltiples predictores incluidos en el análisis.

Variables disponibles y potencial de uso en el análisis multidimensional (02:08:48)

- Enumera que existen 12 variables disponibles (incluyendo coordenadas) que, en teoría, pueden emplearse para generar el clustering.
- Explica que este conjunto multidimensional permitirá caracterizar comportamientos de consumo de ácido según combinaciones de variables.
- Menciona que el análisis multivariable servirá para definir unidades geometalúrgicas preliminares basadas en los clusters obtenidos.

Importancia del test de consumo de ácido y su integración en el modelo (02:09:17)

- Confirmación de comprensión e importancia operativa del test (02:09:17)
  - Se confirma con los asistentes que el test de consumo de ácido está entendido y se subraya su importancia.
  - Explica que disponer de este dato es fundamental para operar los módulos de proceso correctamente.
  - Señala que sin conocer el consumo de ácido no es posible ajustar dosificaciones ni optimizar procesos.
- Consecuencias operativas y riesgos de desconocer el consumo de ácido (02:09:42)
  - Detalla que la falta de conocimiento del consumo de ácido puede reducir la dosificación y afectar la recuperación metalúrgica.
  - Menciona posibles problemas aguas abajo, como desbalances en el sistema y afectación de etapas como solvente o electro-winning.
  - Indica que no disponer de este dato puede generar problemas operativos significativos en la planta.
- Incorporación del test en el modelo geometalúrgico y toma de decisiones (02:10:27)
  - Señala que el test debe modelarse dentro del modelo geometalúrgico para permitir decisiones informadas.
  - Indica que el primer objetivo será generar grupos de predictores que expliquen el consumo de ácido y permitan definir UGM preliminares.
  - Explica que estos resultados formarán parte de un análisis multivariable para suportar decisiones de procesamiento.

Recursos, software y cierre de la sesión educativa (02:11:08)

- Recomendación de software libre y recursos para aprendizaje (02:11:08)
  - Se presenta la existencia de software gratuito (Orange) como herramienta amigable para análisis de datos exploratorios y clustering.
  - Sugiere descargar el software y seguir instructivos o tutoriales en YouTube para familiarizarse con las herramientas.
  - Indica que el software permite manipular datos, interpretar gráficas y generar proxies útiles para geometalurgia.
- Utilidad del tratamiento de datos en geometalurgia y ejemplos de correlaciones relevantes (02:12:38)
  - Explica que la geometalurgia depende cada vez más del tratamiento e interpretación de la data de caracterización del yacimiento.
  - Ofrece ejemplos de correlaciones entre presencia de minerales (óxido de magnesio, mármol, hierro, cobre) y efectos en recuperación o flotación.
  - Señala que el tratamiento de datos corroborará hipótesis generadas por pruebas químicas y de laboratorio.
- Conclusión de la sesión, próximos temas y logística de seguimiento (02:16:21)
  - Se anuncia el cierre de la sesión y que la continuidad abarcará economía y plan de minado en la clase siguiente.
  - El moderador indica que compartirá el enlace del software y enviará información por el grupo de WhatsApp para socializar recursos.
  - Finaliza recordando el formulario de asistencia y los canales de contacto para dudas, y confirma la próxima clase a la misma hora.