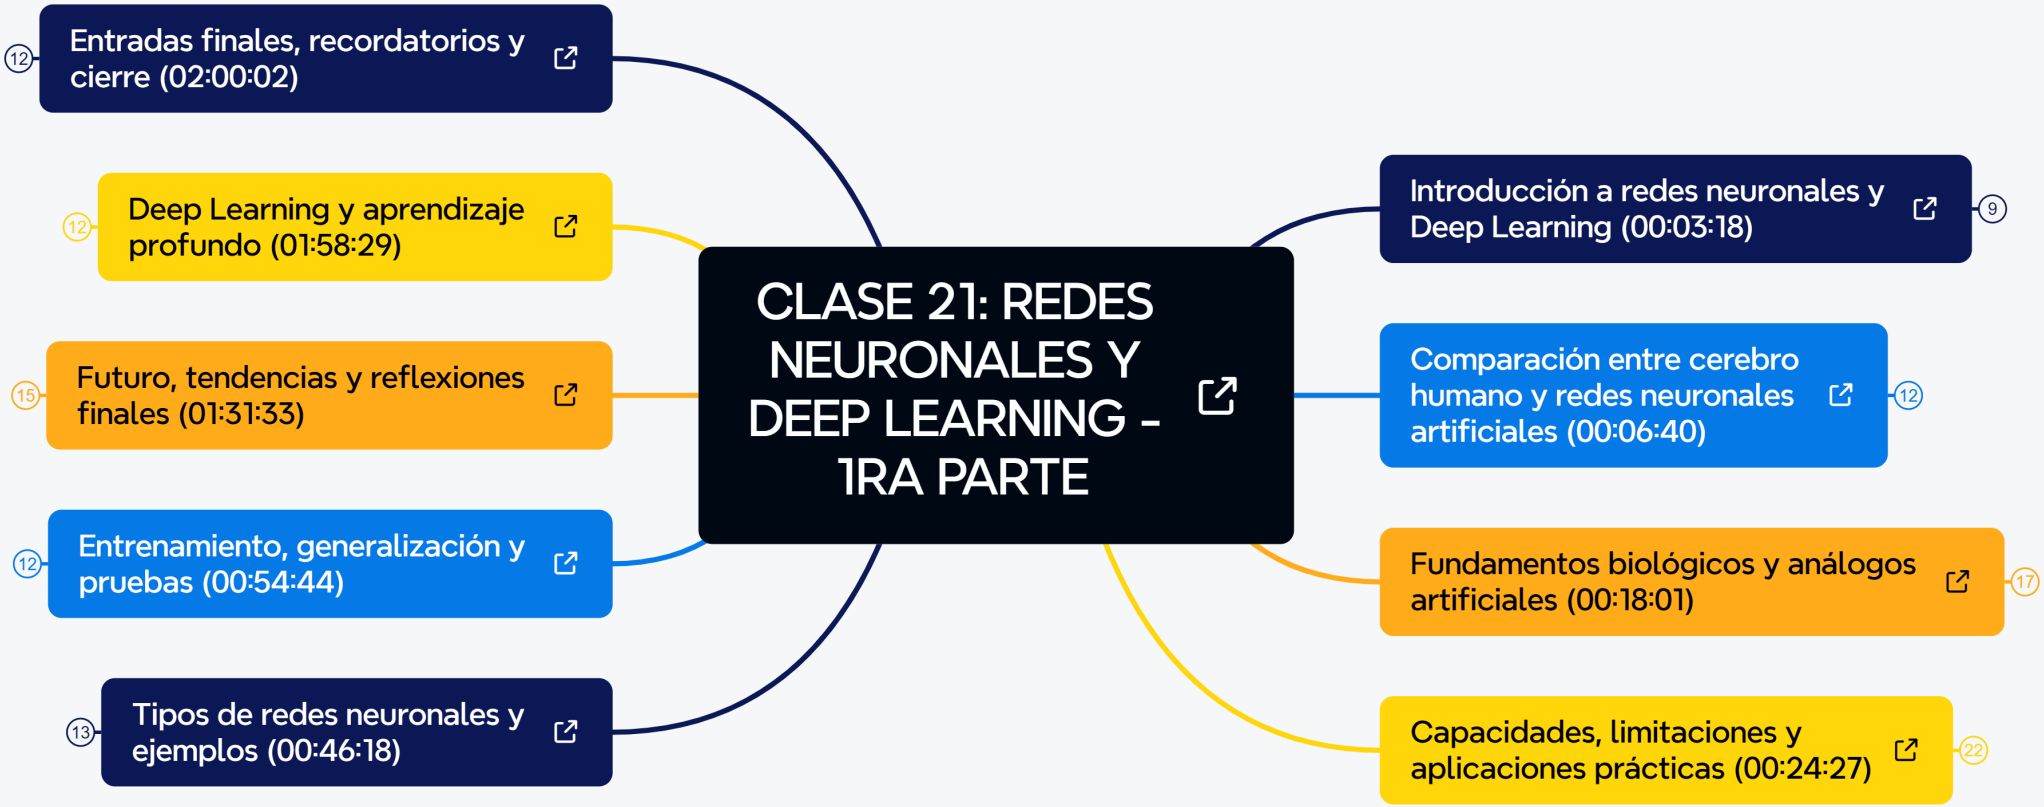
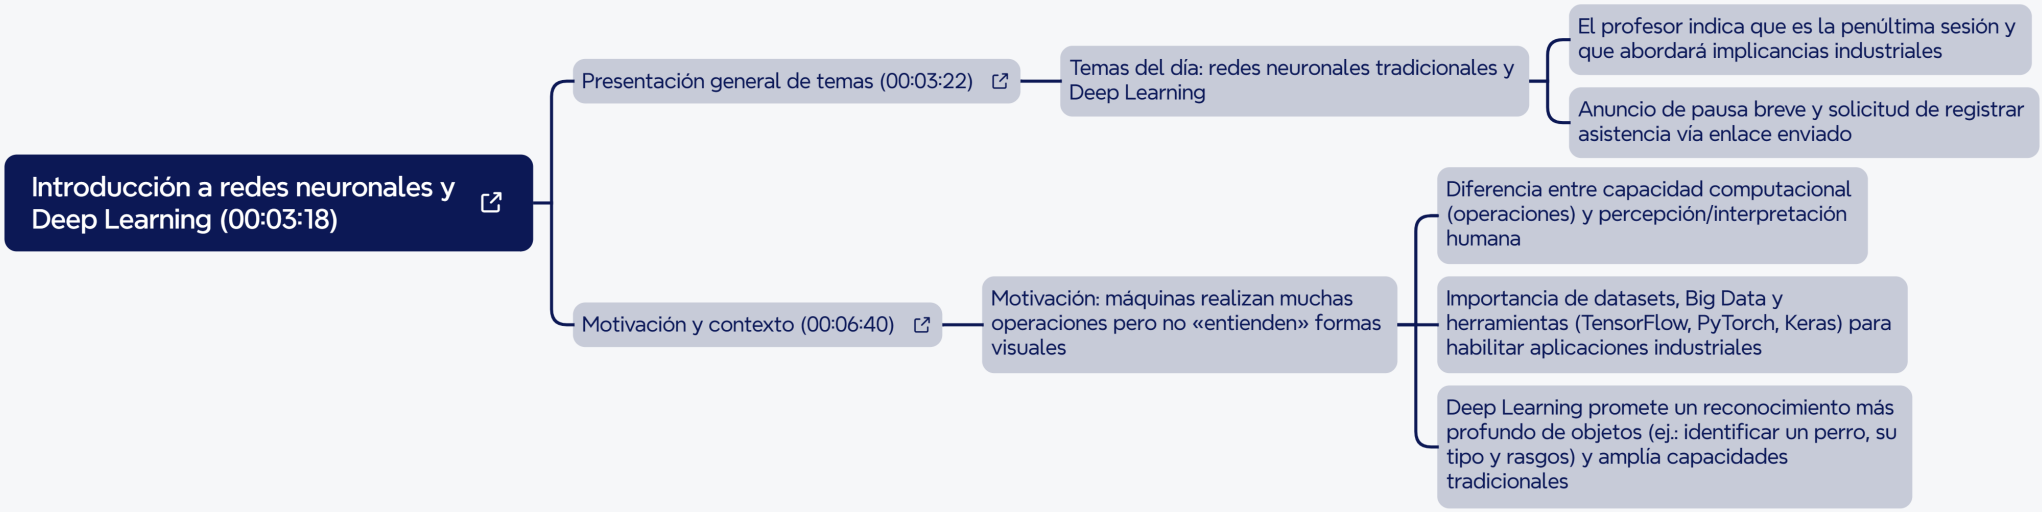
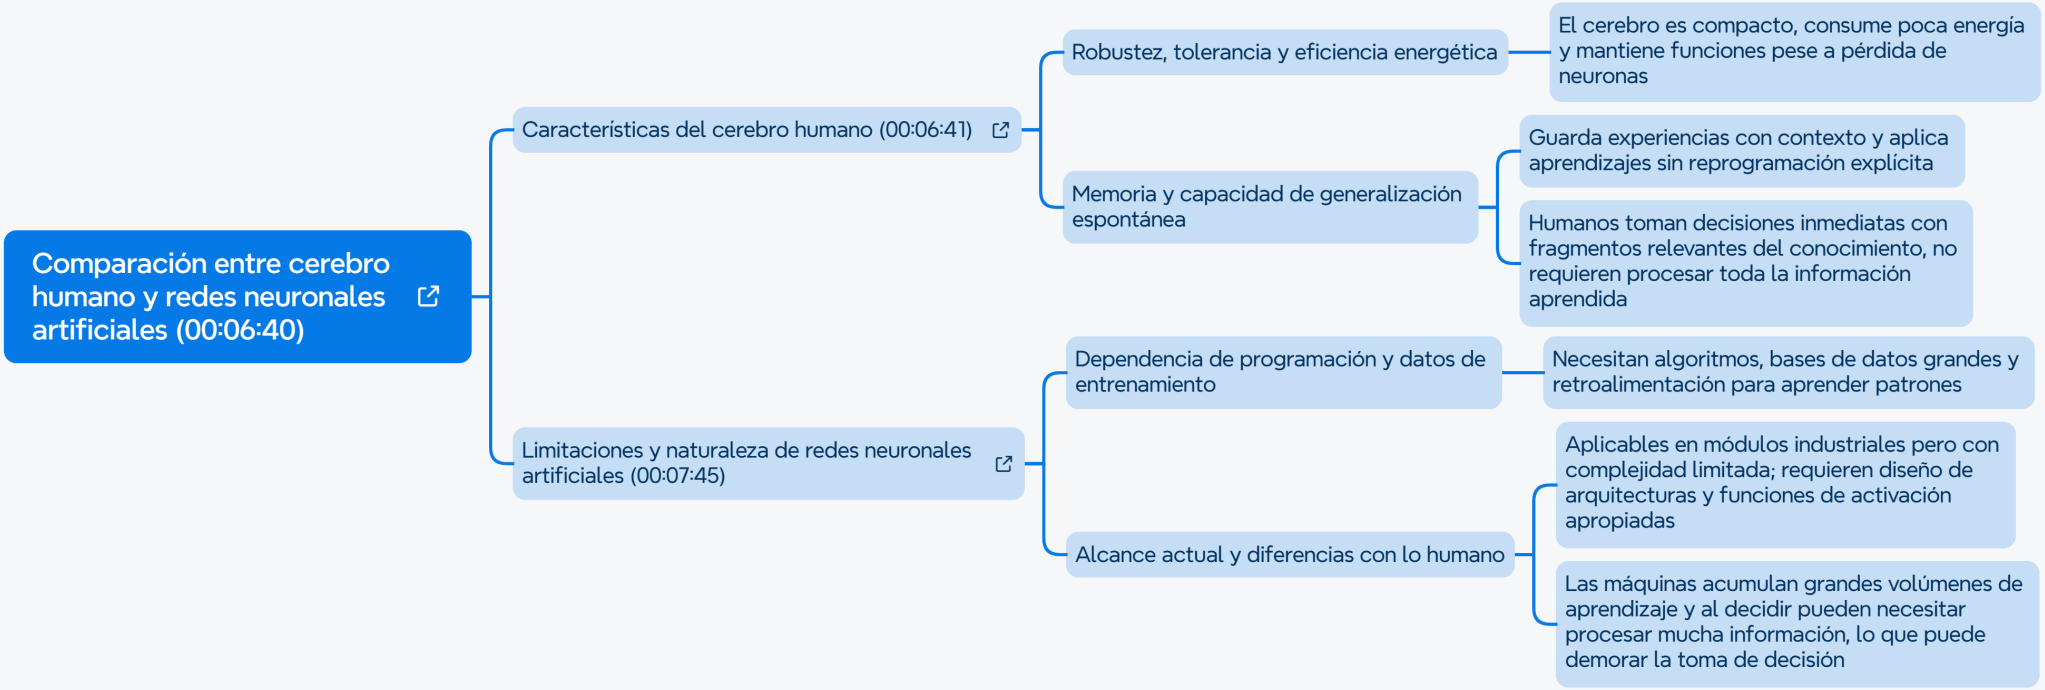
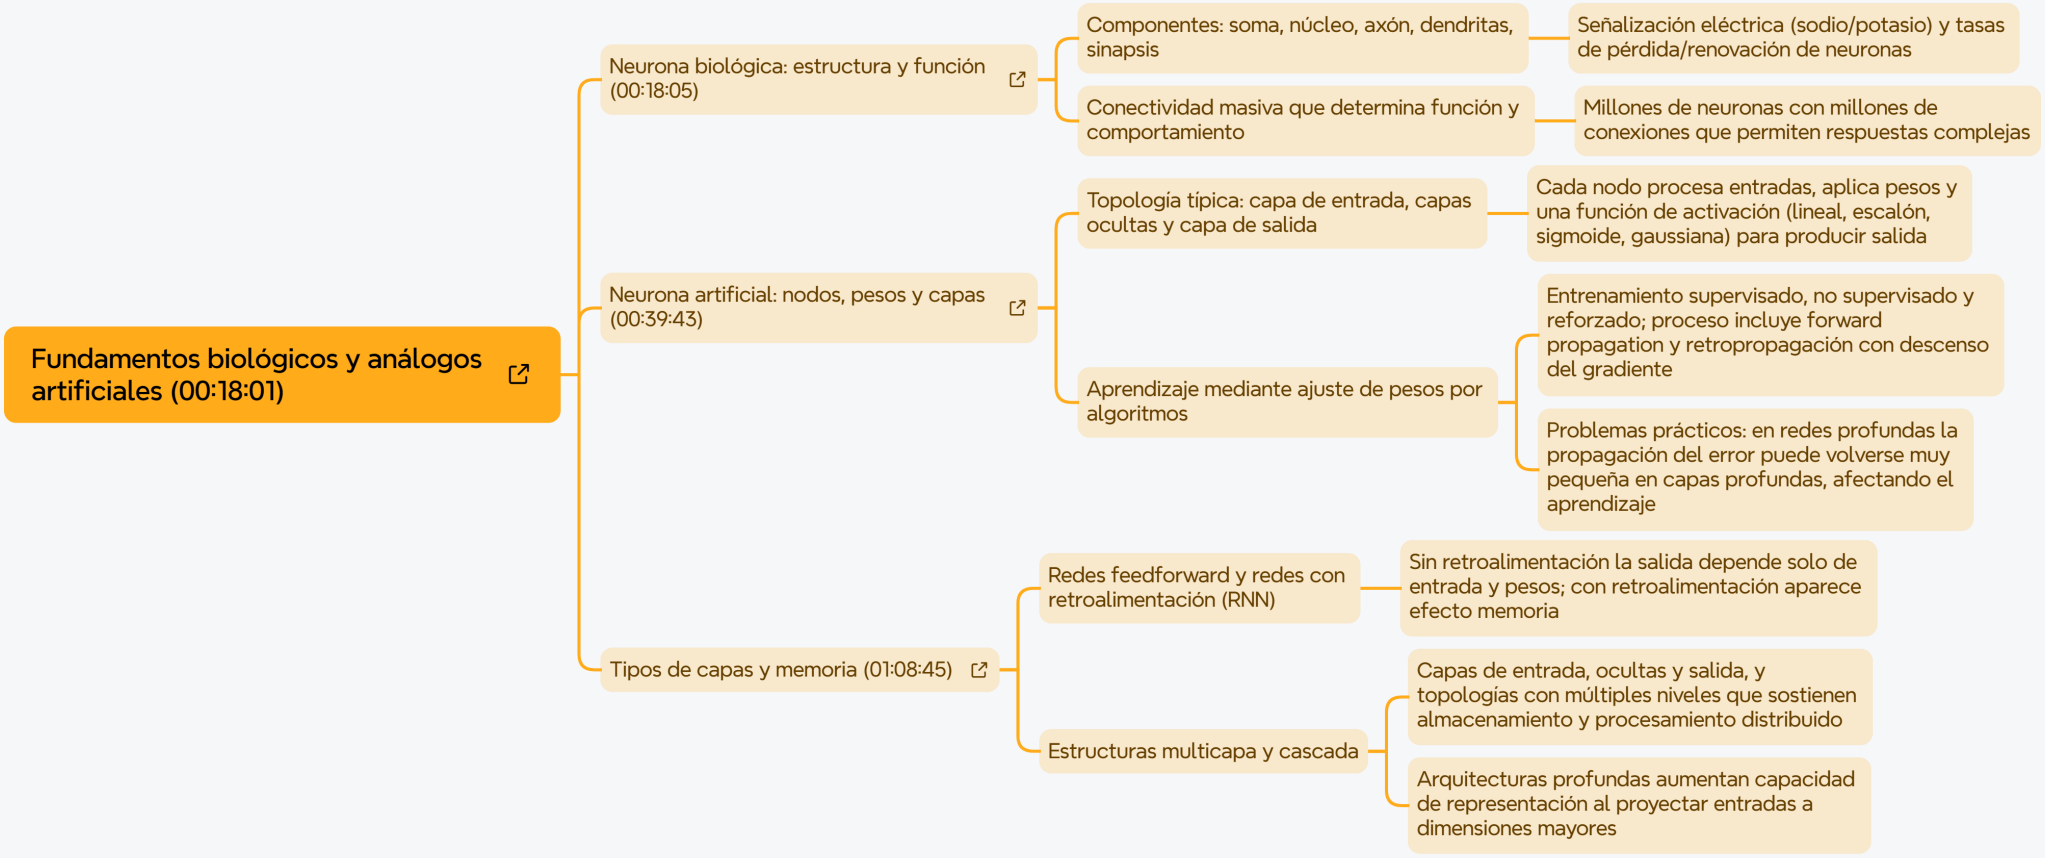
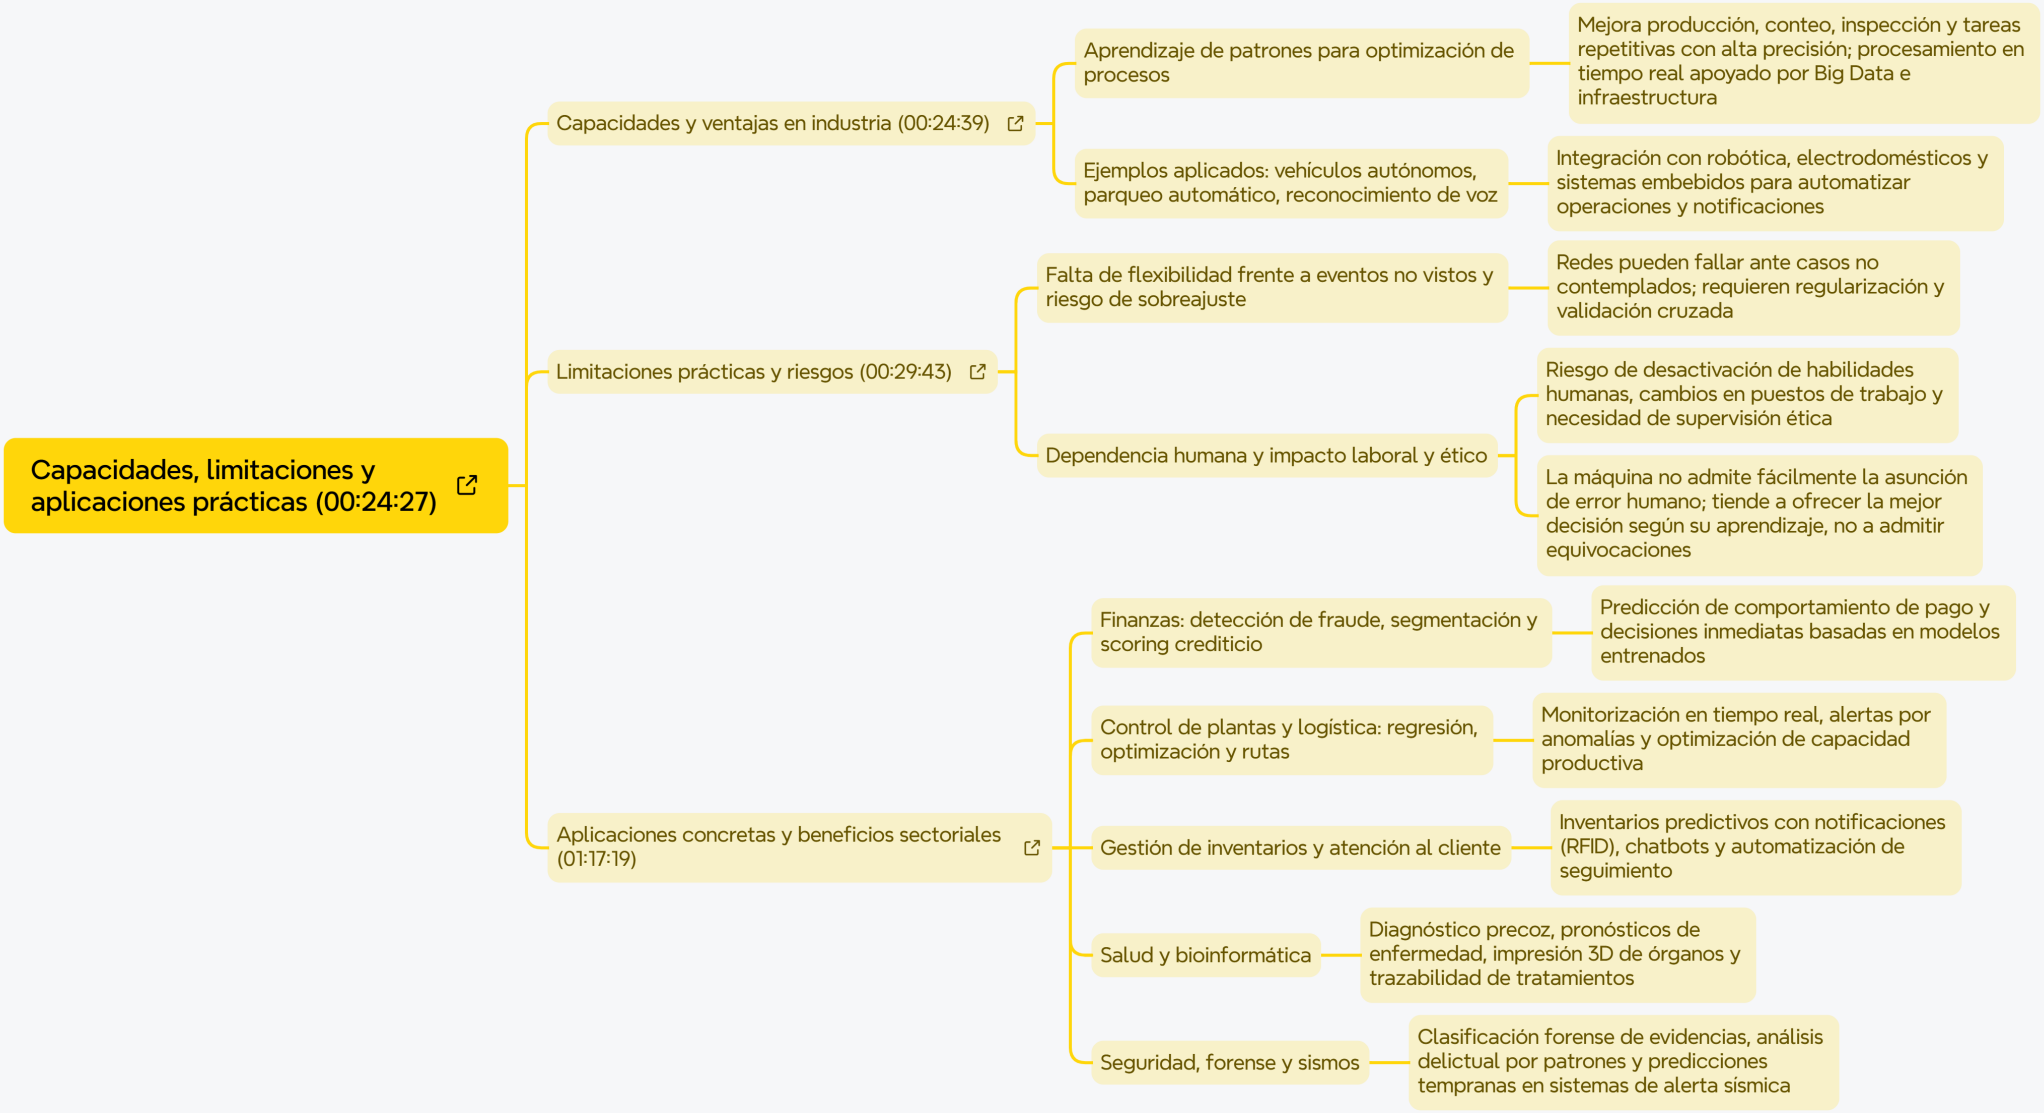
EDU MIN

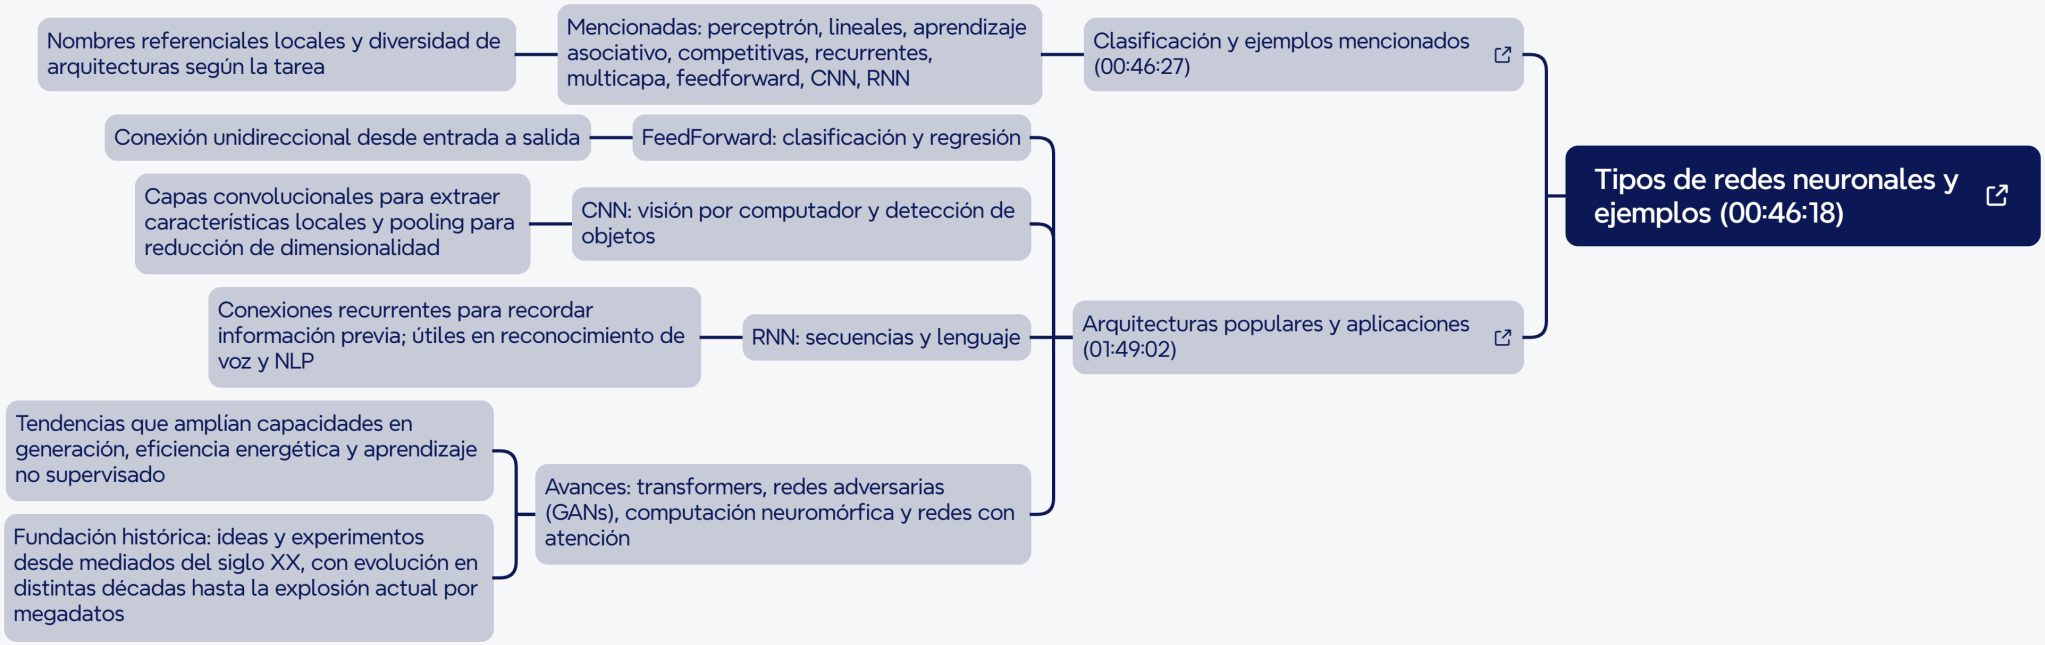

CLASE 21: REDES NEURONALES Y DEEP LEARNING - 1RA PARTE
Introducción a redes neuronales y Deep Learning (00:03:18)
9
Comparación entre cerebro humano y redes neuronales artificiales (00:06:40)
12
Fundamentos biológicos y análogos artificiales (00:18:01)
17
Capacidades, limitaciones y aplicaciones prácticas (00:24:27)
22
Entradas finales, recordatorios y cierre (02:00:02)
12
Deep Learning y aprendizaje profundo (01:58:29)
12
Futuro, tendencias y reflexiones finales (01:31:33)
15
Entrenamiento, generalización y pruebas (00:54:44)
12
Tipos de redes neuronales y ejemplos (00:46:18)
13

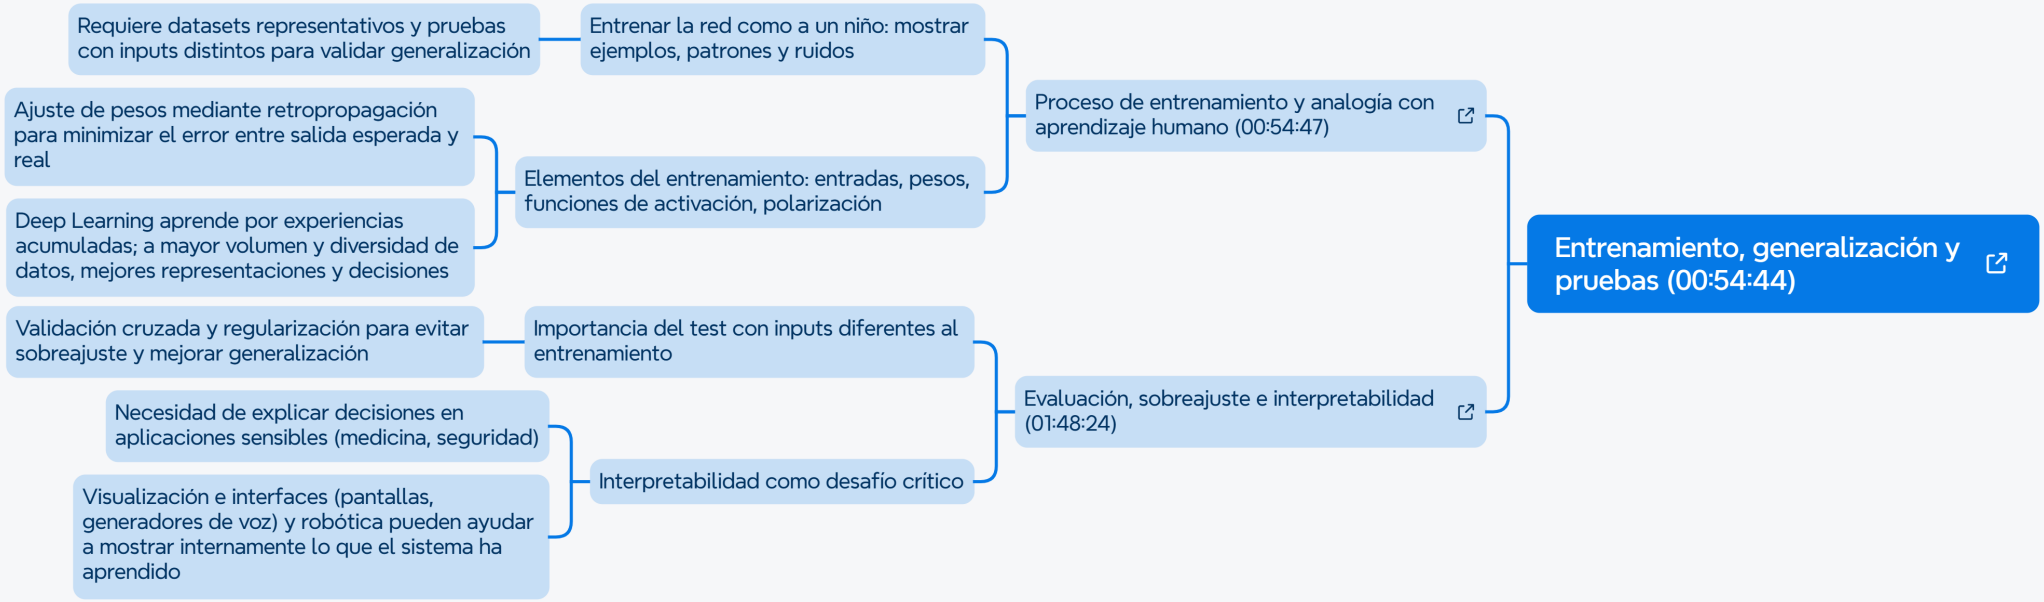

Introducción a redes neuronales y Deep Learning (00:03:18)
Presentación general de temas (00:03:22)
Temas del día: redes neuronales tradicionales y Deep Learning
El profesor indica que es la penúltima sesión y que abordará implicancias industriales
Anuncio de pausa breve y solicitud de registrar asistencia vía enlace enviado
Motivación y contexto (00:06:40)
Motivación: máquinas realizan muchas operaciones pero no «entienden» formas visuales
Diferencia entre capacidad computacional (operaciones) y percepción/interpretación humana
Importancia de datasets, Big Data y herramientas (TensorFlow, PyTorch, Keras) para habilitar aplicaciones industriales
Deep Learning promete un reconocimiento más profundo de objetos (ej.: identificar un perro, su tipo y rasgos) y amplía capacidades tradicionales

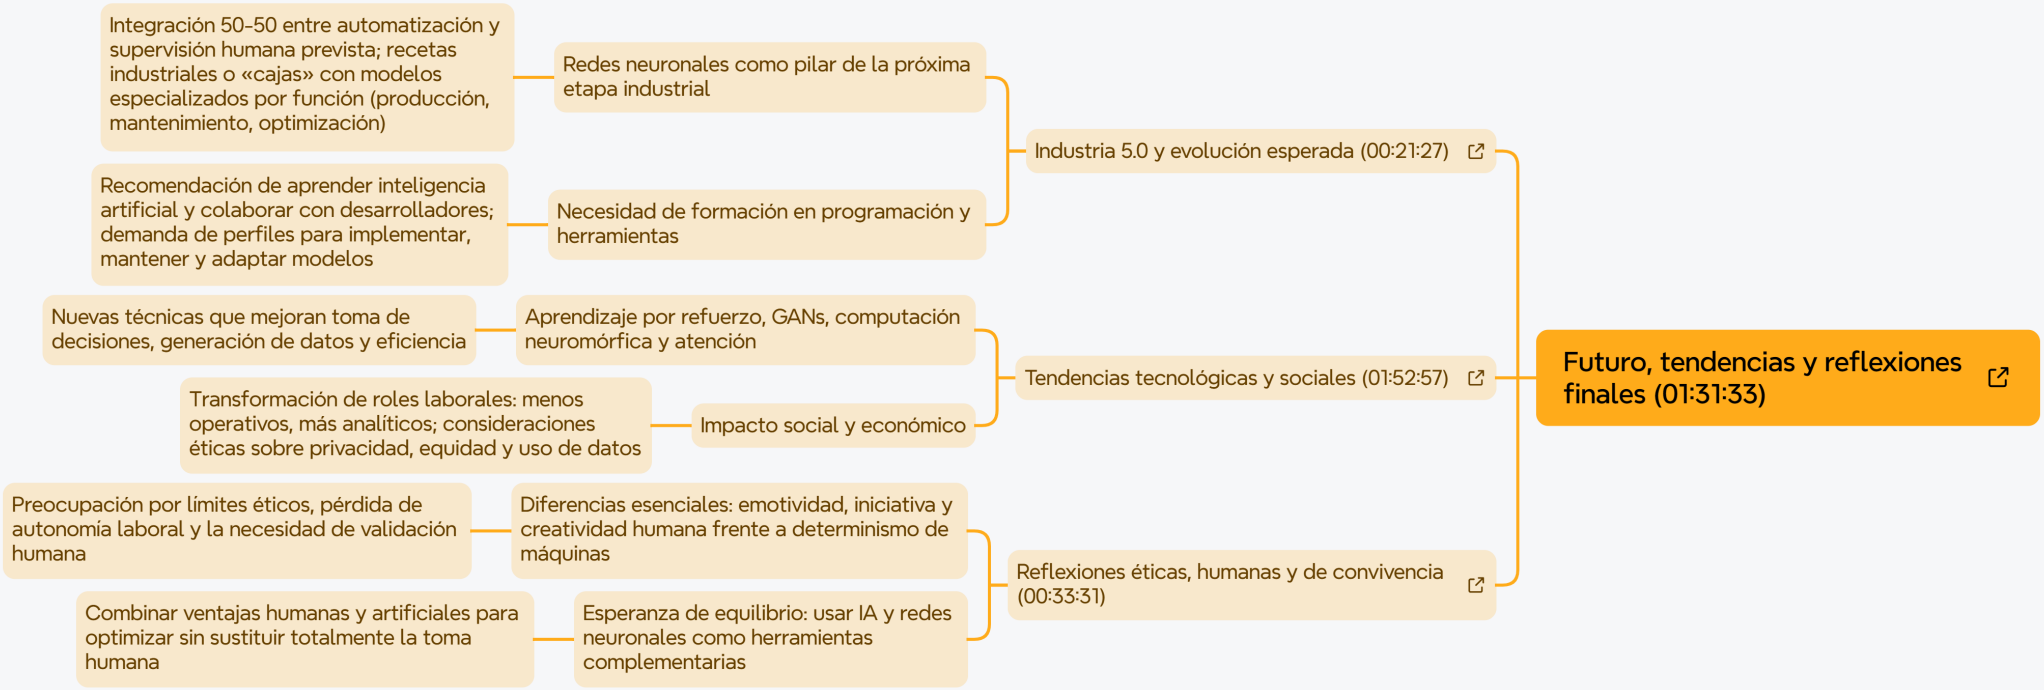

Comparación entre cerebro humano y redes neuronales artificiales (00:06:40)
Características del cerebro humano (00:06:41)
Robustez, tolerancia y eficiencia energética
El cerebro es compacto, consume poca energía y mantiene funciones pese a pérdida de neuronas
Memoria y capacidad de generalización espontánea
Guarda experiencias con contexto y aplica aprendizajes sin reprogramación explícita
Humanos toman decisiones inmediatas con fragmentos relevantes del conocimiento, no requieren procesar toda la información aprendida
Limitaciones y naturaleza de redes neuronales artificiales (00:07:45)
Dependencia de programación y datos de entrenamiento
Necesitan algoritmos, bases de datos grandes y retroalimentación para aprender patrones
Alcance actual y diferencias con lo humano
Aplicables en módulos industriales pero con complejidad limitada; requieren diseño de arquitecturas y funciones de activación apropiadas
Las máquinas acumulan grandes volúmenes de aprendizaje y al decidir pueden necesitar procesar mucha información, lo que puede demorar la toma de decisión

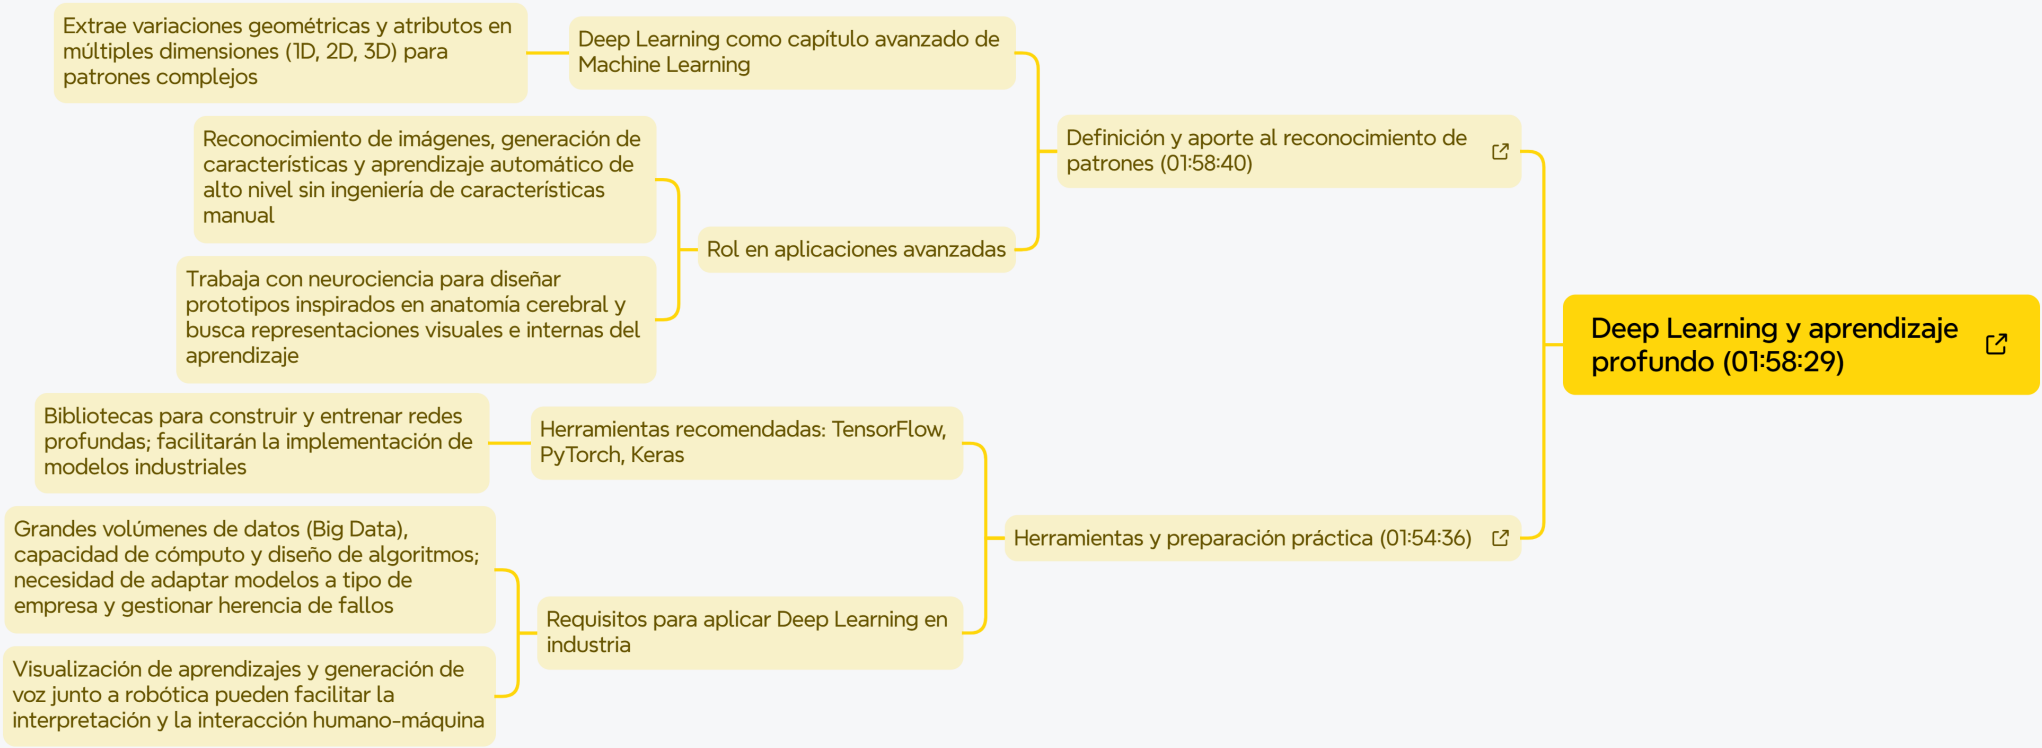

Fundamentos biológicos y análogos artificiales (00:18:01)
Neurona biológica: estructura y función (00:18:05)
Componentes: soma, núcleo, axón, dendritas, sinapsis
Señalización eléctrica (sodio/potasio) y tasas de pérdida/renovación de neuronas
Conectividad masiva que determina función y comportamiento
Millones de neuronas con millones de conexiones que permiten respuestas complejas
Neurona artificial: nodos, pesos y capas (00:39:43)
Topología típica: capa de entrada, capas ocultas y capa de salida
Cada nodo procesa entradas, aplica pesos y una función de activación (lineal, escalón, sigmoide, gaussiana) para producir salida
Aprendizaje mediante ajuste de pesos por algoritmos
Entrenamiento supervisado, no supervisado y reforzado; proceso incluye forward propagation y retropropagación con descenso del gradiente
Problemas prácticos: en redes profundas la propagación del error puede volverse muy pequeña en capas profundas, afectando el aprendizaje
Tipos de capas y memoria (01:08:45)
Redes feedforward y redes con retroalimentación (RNN)
Sin retroalimentación la salida depende solo de entrada y pesos; con retroalimentación aparece efecto memoria
Estructuras multicapa y cascada
Capas de entrada, ocultas y salida, y topologías con múltiples niveles que sostienen almacenamiento y procesamiento distribuido
Arquitecturas profundas aumentan capacidad de representación al proyectar entradas a dimensiones mayores

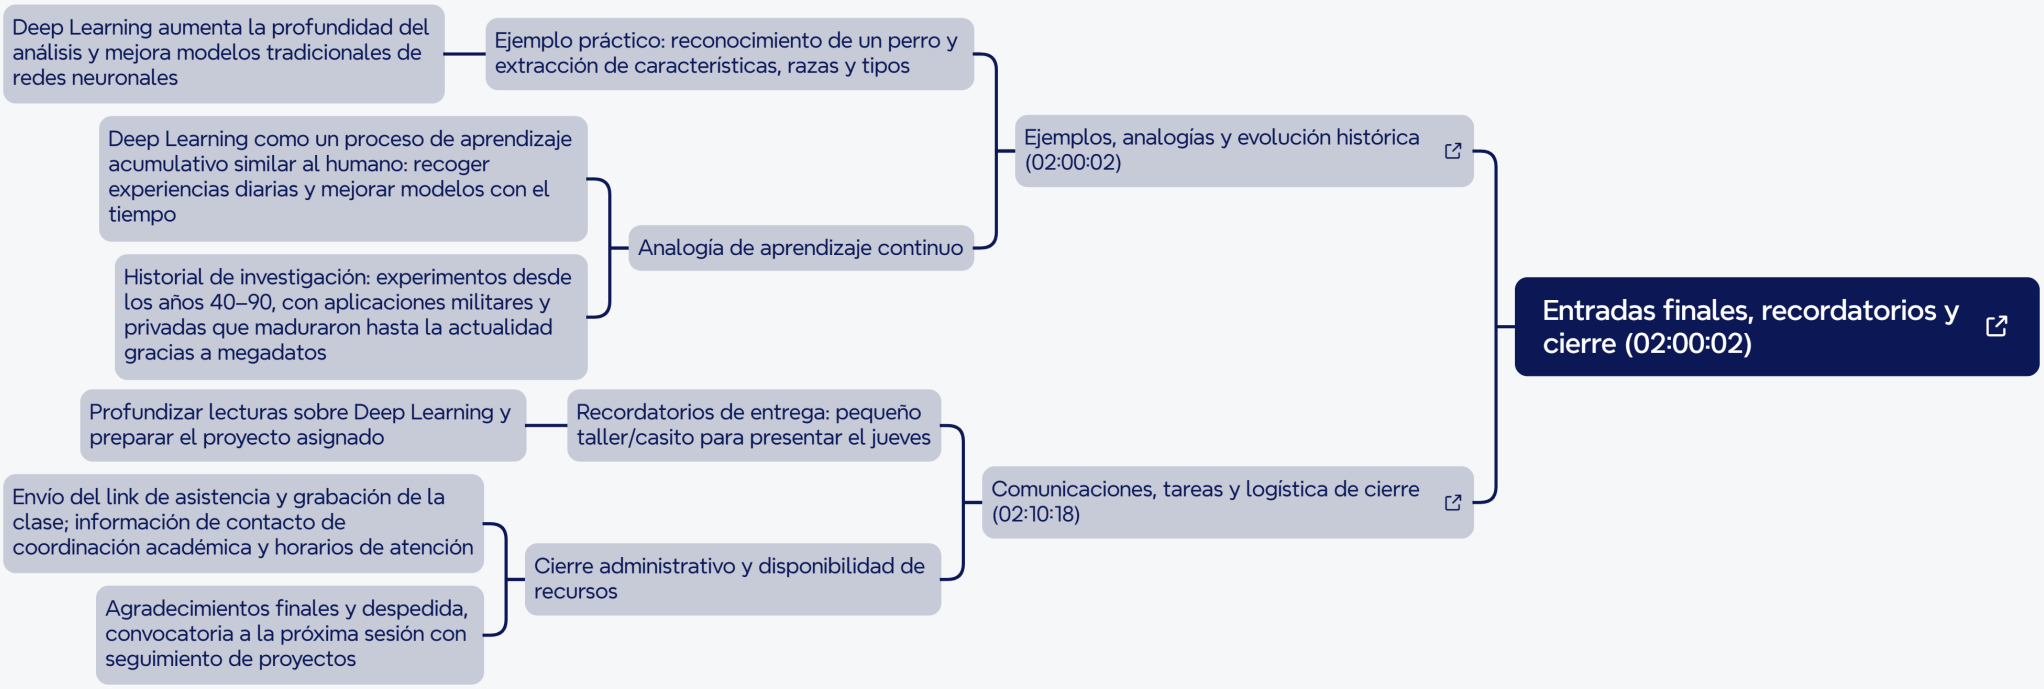

Capacidades, limitaciones y aplicaciones prácticas (00:24:27)
Capacidades y ventajas en industria (00:24:39)
Aprendizaje de patrones para optimización de procesos
Mejora producción, conteo, inspección y tareas repetitivas con alta precisión; procesamiento en tiempo real apoyado por Big Data e infraestructura
Ejemplos aplicados: vehículos autónomos, parqueo automático, reconocimiento de voz
Integración con robótica, electrodomésticos y sistemas embebidos para automatizar operaciones y notificaciones
Limitaciones prácticas y riesgos (00:29:43)
Falta de flexibilidad frente a eventos no vistos y riesgo de sobreajuste
Redes pueden fallar ante casos no contemplados; requieren regularización y validación cruzada
Dependencia humana y impacto laboral y ético
Riesgo de desactivación de habilidades humanas, cambios en puestos de trabajo y necesidad de supervisión ética
La máquina no admite fácilmente la asunción de error humano; tiende a ofrecer la mejor decisión según su aprendizaje, no a admitir equivocaciones
Aplicaciones concretas y beneficios sectoriales (01:17:19)
Finanzas: detección de fraude, segmentación y scoring crediticio
Predicción de comportamiento de pago y decisiones inmediatas basadas en modelos entrenados
Control de plantas y logística: regresión, optimización y rutas
Monitorización en tiempo real, alertas por anomalías y optimización de capacidad productiva
Gestión de inventarios y atención al cliente
Inventarios predictivos con notificaciones (RFID), chatbots y automatización de seguimiento
Salud y bioinformática
Diagnóstico precoz, pronósticos de enfermedad, impresión 3D de órganos y trazabilidad de tratamientos
Seguridad, forense y sismos
Clasificación forense de evidencias, análisis delictual por patrones y predicciones tempranas en sistemas de alerta sísmica


Tipos de redes neuronales y ejemplos (00:46:18)
Clasificación y ejemplos mencionados (00:46:27)
Mencionadas: perceptrón, lineales, aprendizaje asociativo, competitivas, recurrentes, multicapa, feedforward, CNN, RNN
Nombres referenciales locales y diversidad de arquitecturas según la tarea
Arquitecturas populares y aplicaciones (01:49:02)
FeedForward: clasificación y regresión
Conexión unidireccional desde entrada a salida
CNN: visión por computador y detección de objetos
Capas convolucionales para extraer características locales y pooling para reducción de dimensionalidad
RNN: secuencias y lenguaje
Conexiones recurrentes para recordar información previa; útiles en reconocimiento de voz y NLP
Avances: transformers, redes adversarias (GANs), computación neuromórfica y redes con atención
Tendencias que amplían capacidades en generación, eficiencia energética y aprendizaje no supervisado
Fundación histórica: ideas y experimentos desde mediados del siglo XX, con evolución en distintas décadas hasta la explosión actual por megadatos


Entrenamiento, generalización y pruebas (00:54:44)
Proceso de entrenamiento y analogía con aprendizaje humano (00:54:47)
Entrenar la red como a un niño: mostrar ejemplos, patrones y ruidos
Requiere datasets representativos y pruebas con inputs distintos para validar generalización
Elementos del entrenamiento: entradas, pesos, funciones de activación, polarización
Ajuste de pesos mediante retropropagación para minimizar el error entre salida esperada y real
Deep Learning aprende por experiencias acumuladas; a mayor volumen y diversidad de datos, mejores representaciones y decisiones
Evaluación, sobreajuste e interpretabilidad (01:48:24)
Importancia del test con inputs diferentes al entrenamiento
Validación cruzada y regularización para evitar sobreajuste y mejorar generalización
Interpretabilidad como desafío crítico
Necesidad de explicar decisiones en aplicaciones sensibles (medicina, seguridad)
Visualización e interfaces (pantallas, generadores de voz) y robótica pueden ayudar a mostrar internamente lo que el sistema ha aprendido


Futuro, tendencias y reflexiones finales (01:31:33)
Industria 5.0 y evolución esperada (00:21:27)
Redes neuronales como pilar de la próxima etapa industrial
Integración 50-50 entre automatización y supervisión humana prevista; recetas industriales o «cajas» con modelos especializados por función (producción, mantenimiento, optimización)
Necesidad de formación en programación y herramientas
Recomendación de aprender inteligencia artificial y colaborar con desarrolladores; demanda de perfiles para implementar, mantener y adaptar modelos
Tendencias tecnológicas y sociales (01:52:57)
Aprendizaje por refuerzo, GANs, computación neuromórfica y atención
Nuevas técnicas que mejoran toma de decisiones, generación de datos y eficiencia
Impacto social y económico
Transformación de roles laborales: menos operativos, más analíticos; consideraciones éticas sobre privacidad, equidad y uso de datos
Reflexiones éticas, humanas y de convivencia (00:33:31)
Diferencias esenciales: emotividad, iniciativa y creatividad humana frente a determinismo de máquinas
Preocupación por límites éticos, pérdida de autonomía laboral y la necesidad de validación humana
Esperanza de equilibrio: usar IA y redes neuronales como herramientas complementarias
Combinar ventajas humanas y artificiales para optimizar sin sustituir totalmente la toma humana


Deep Learning y aprendizaje profundo (01:58:29)
Definición y aporte al reconocimiento de patrones (01:58:40)
Deep Learning como capítulo avanzado de Machine Learning
Extrae variaciones geométricas y atributos en múltiples dimensiones (1D, 2D, 3D) para patrones complejos
Rol en aplicaciones avanzadas
Reconocimiento de imágenes, generación de características y aprendizaje automático de alto nivel sin ingeniería de características manual
Trabaja con neurociencia para diseñar prototipos inspirados en anatomía cerebral y busca representaciones visuales e internas del aprendizaje
Herramientas y preparación práctica (01:54:36)
Herramientas recomendadas: TensorFlow, PyTorch, Keras
Bibliotecas para construir y entrenar redes profundas; facilitarán la implementación de modelos industriales
Requisitos para aplicar Deep Learning en industria
Grandes volúmenes de datos (Big Data), capacidad de cómputo y diseño de algoritmos; necesidad de adaptar modelos a tipo de empresa y gestionar herencia de fallos
Visualización de aprendizajes y generación de voz junto a robótica pueden facilitar la interpretación y la interacción humano-máquina


Entradas finales, recordatorios y cierre (02:00:02)
Ejemplos, analogías y evolución histórica (02:00:02)
Ejemplo práctico: reconocimiento de un perro y extracción de características, razas y tipos
Deep Learning aumenta la profundidad del análisis y mejora modelos tradicionales de redes neuronales
Analogía de aprendizaje continuo
Deep Learning como un proceso de aprendizaje acumulativo similar al humano: recoger experiencias diarias y mejorar modelos con el tiempo
Historial de investigación: experimentos desde los años 40–90, con aplicaciones militares y privadas que maduraron hasta la actualidad gracias a megadatos
Comunicaciones, tareas y logística de cierre (02:10:18)
Recordatorios de entrega: pequeño taller/casito para presentar el jueves
Profundizar lecturas sobre Deep Learning y preparar el proyecto asignado
Cierre administrativo y disponibilidad de recursos
Envío del link de asistencia y grabación de la clase; información de contacto de coordinación académica y horarios de atención
Agradecimientos finales y despedida, convocatoria a la próxima sesión con seguimiento de proyectos