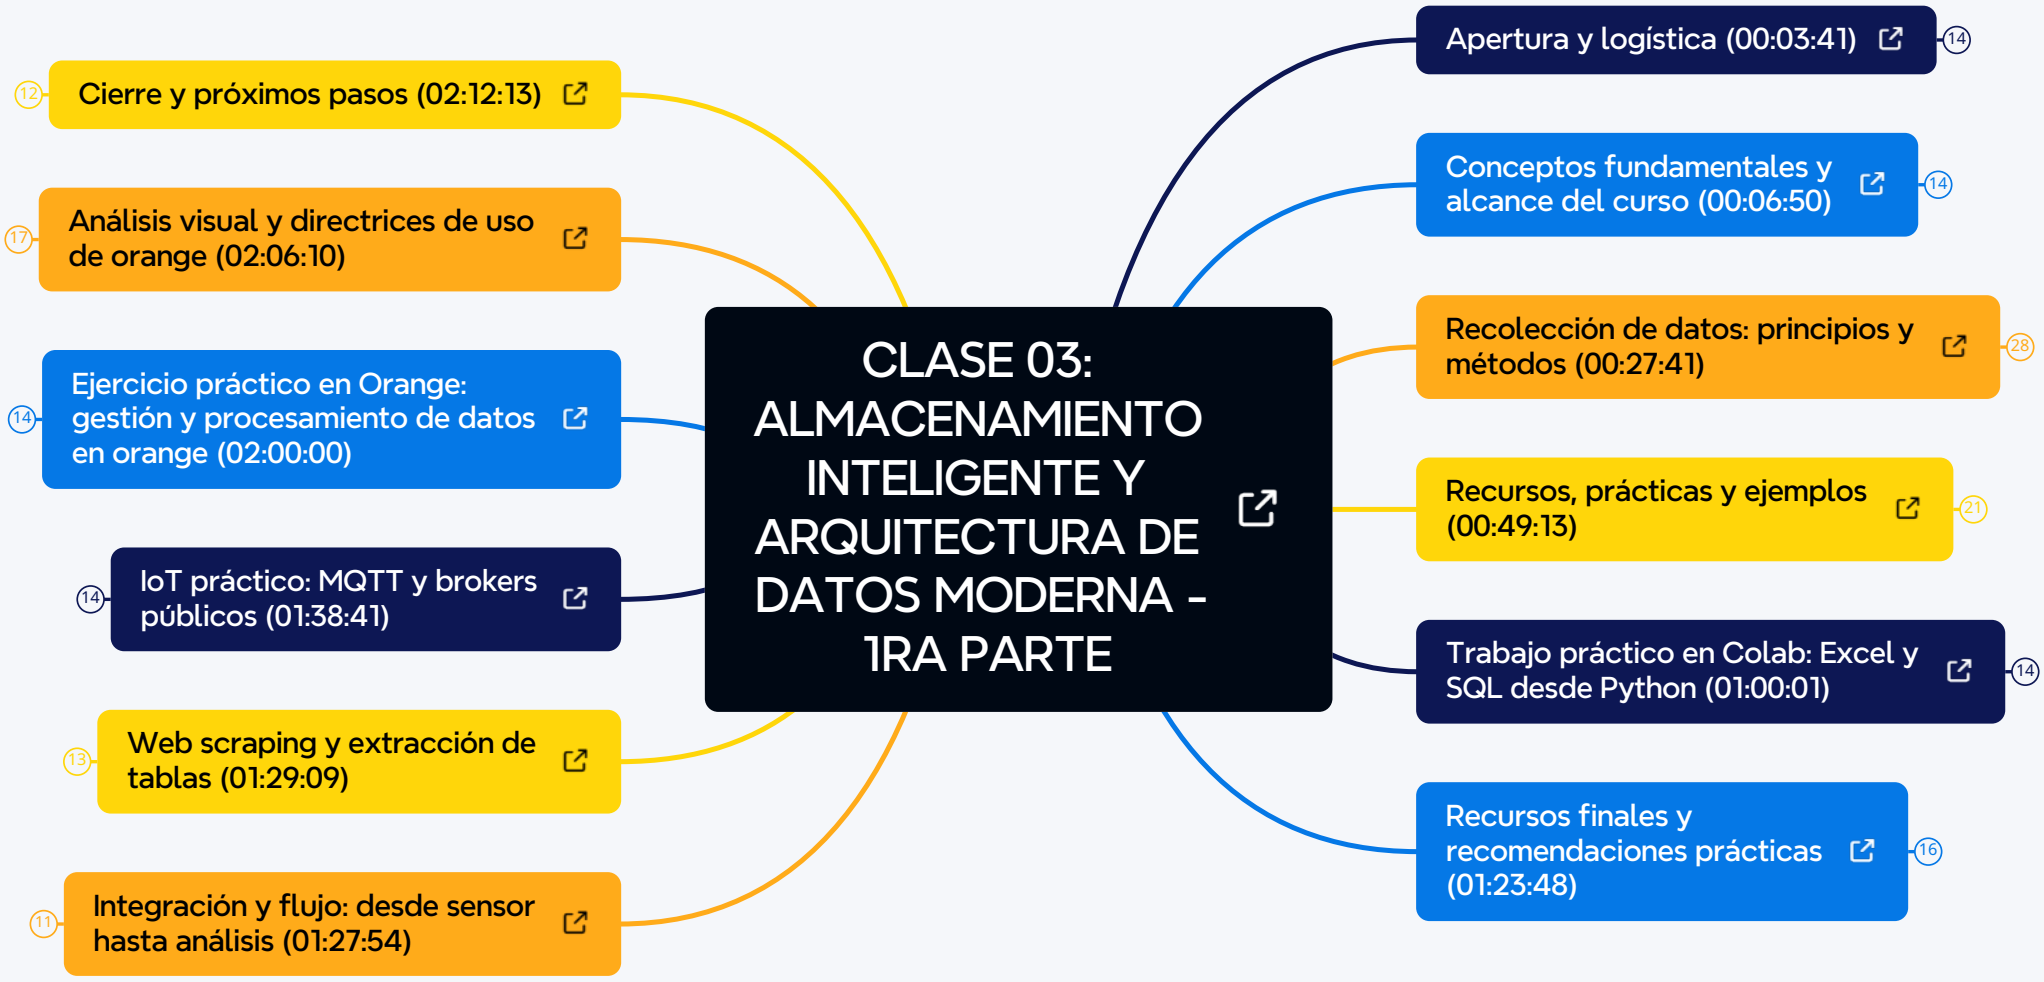
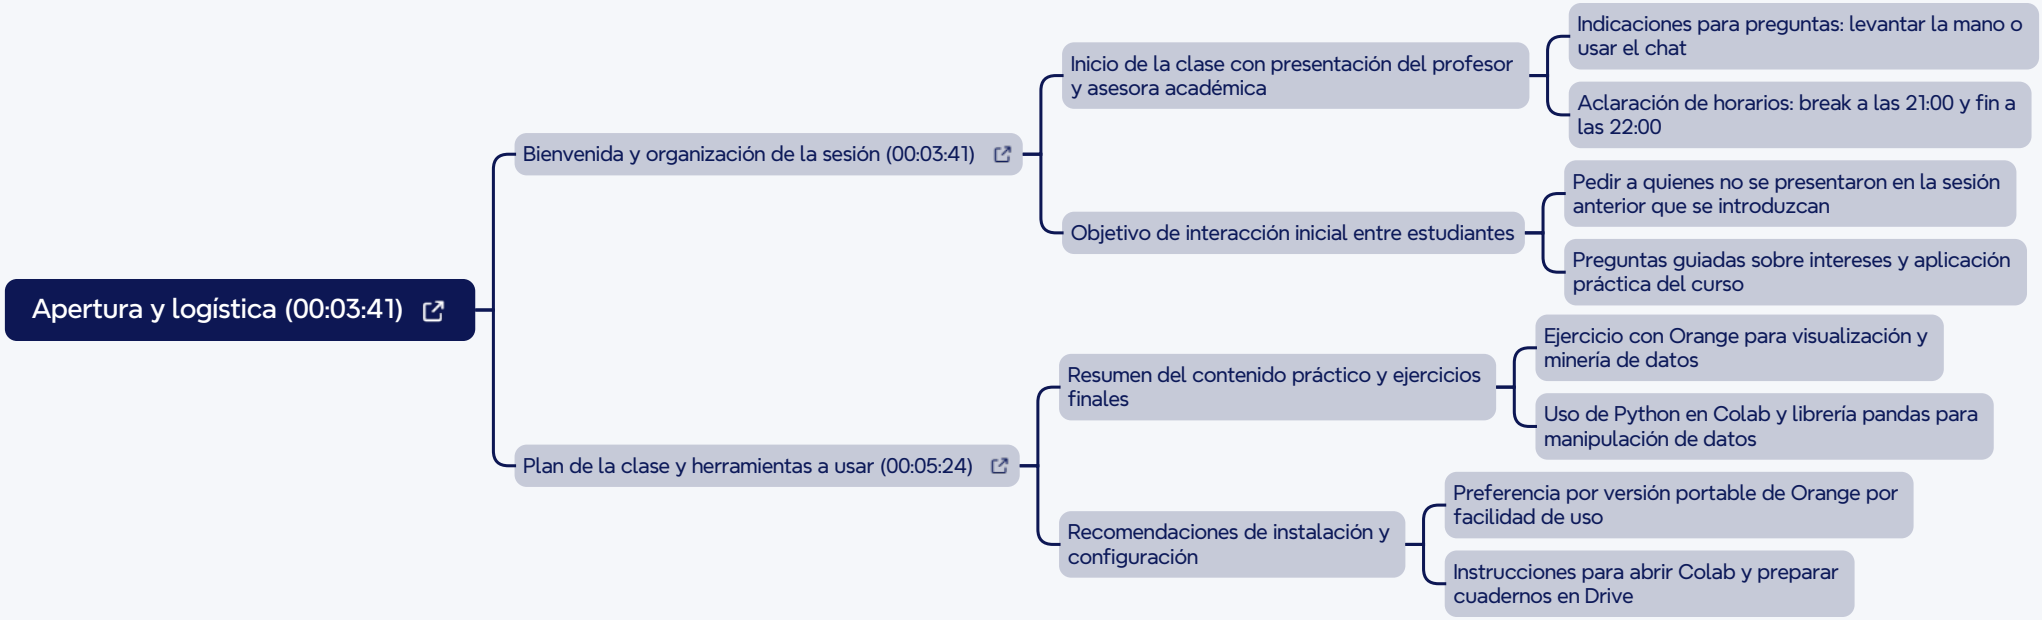
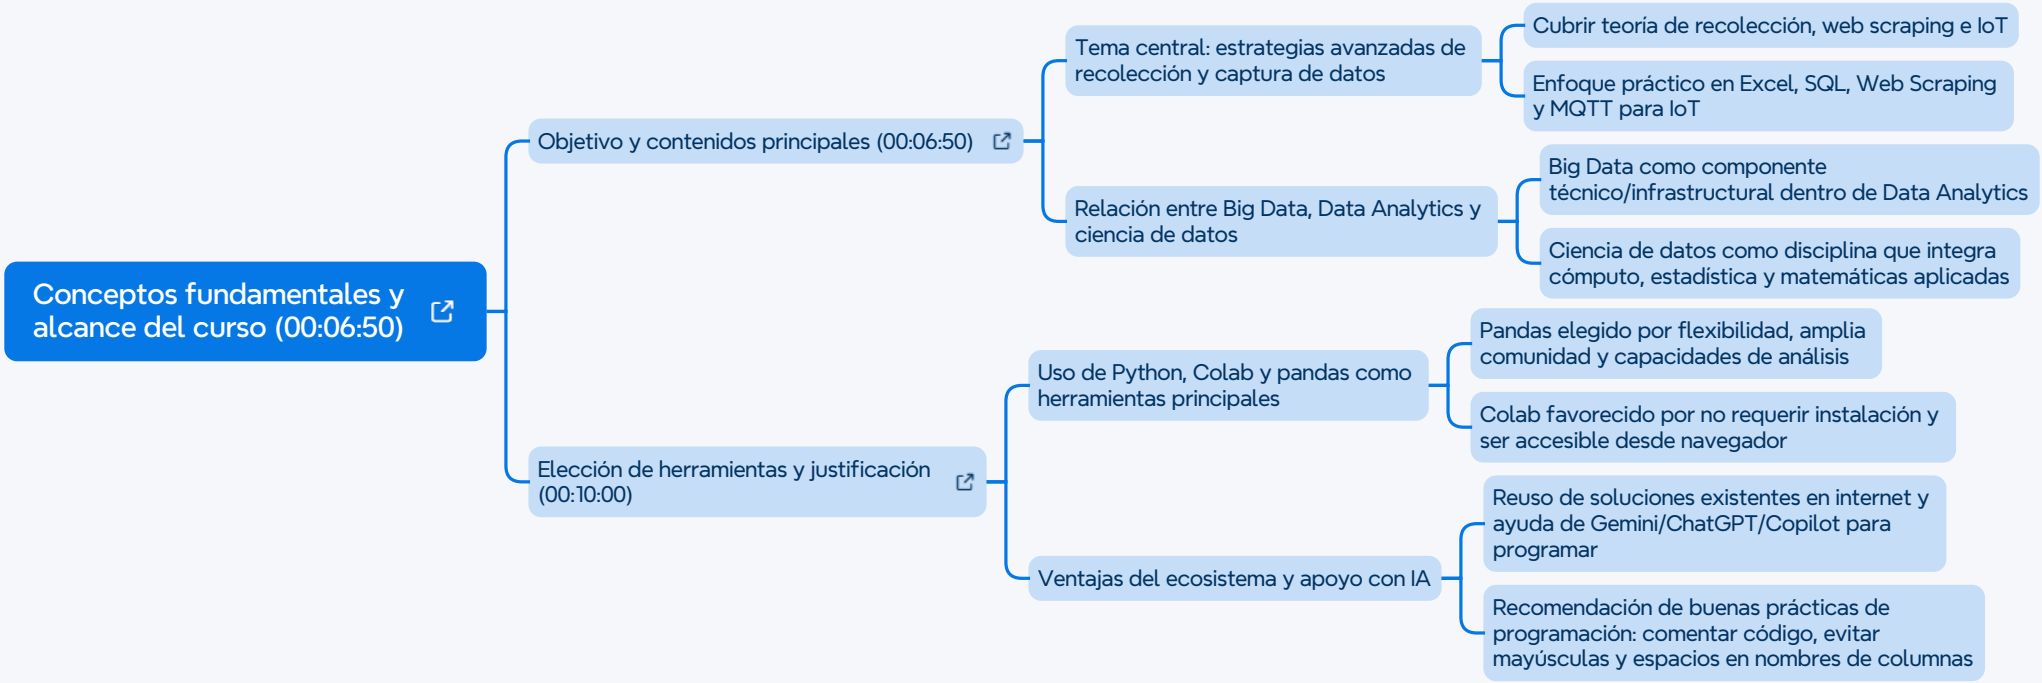
EDU MIN

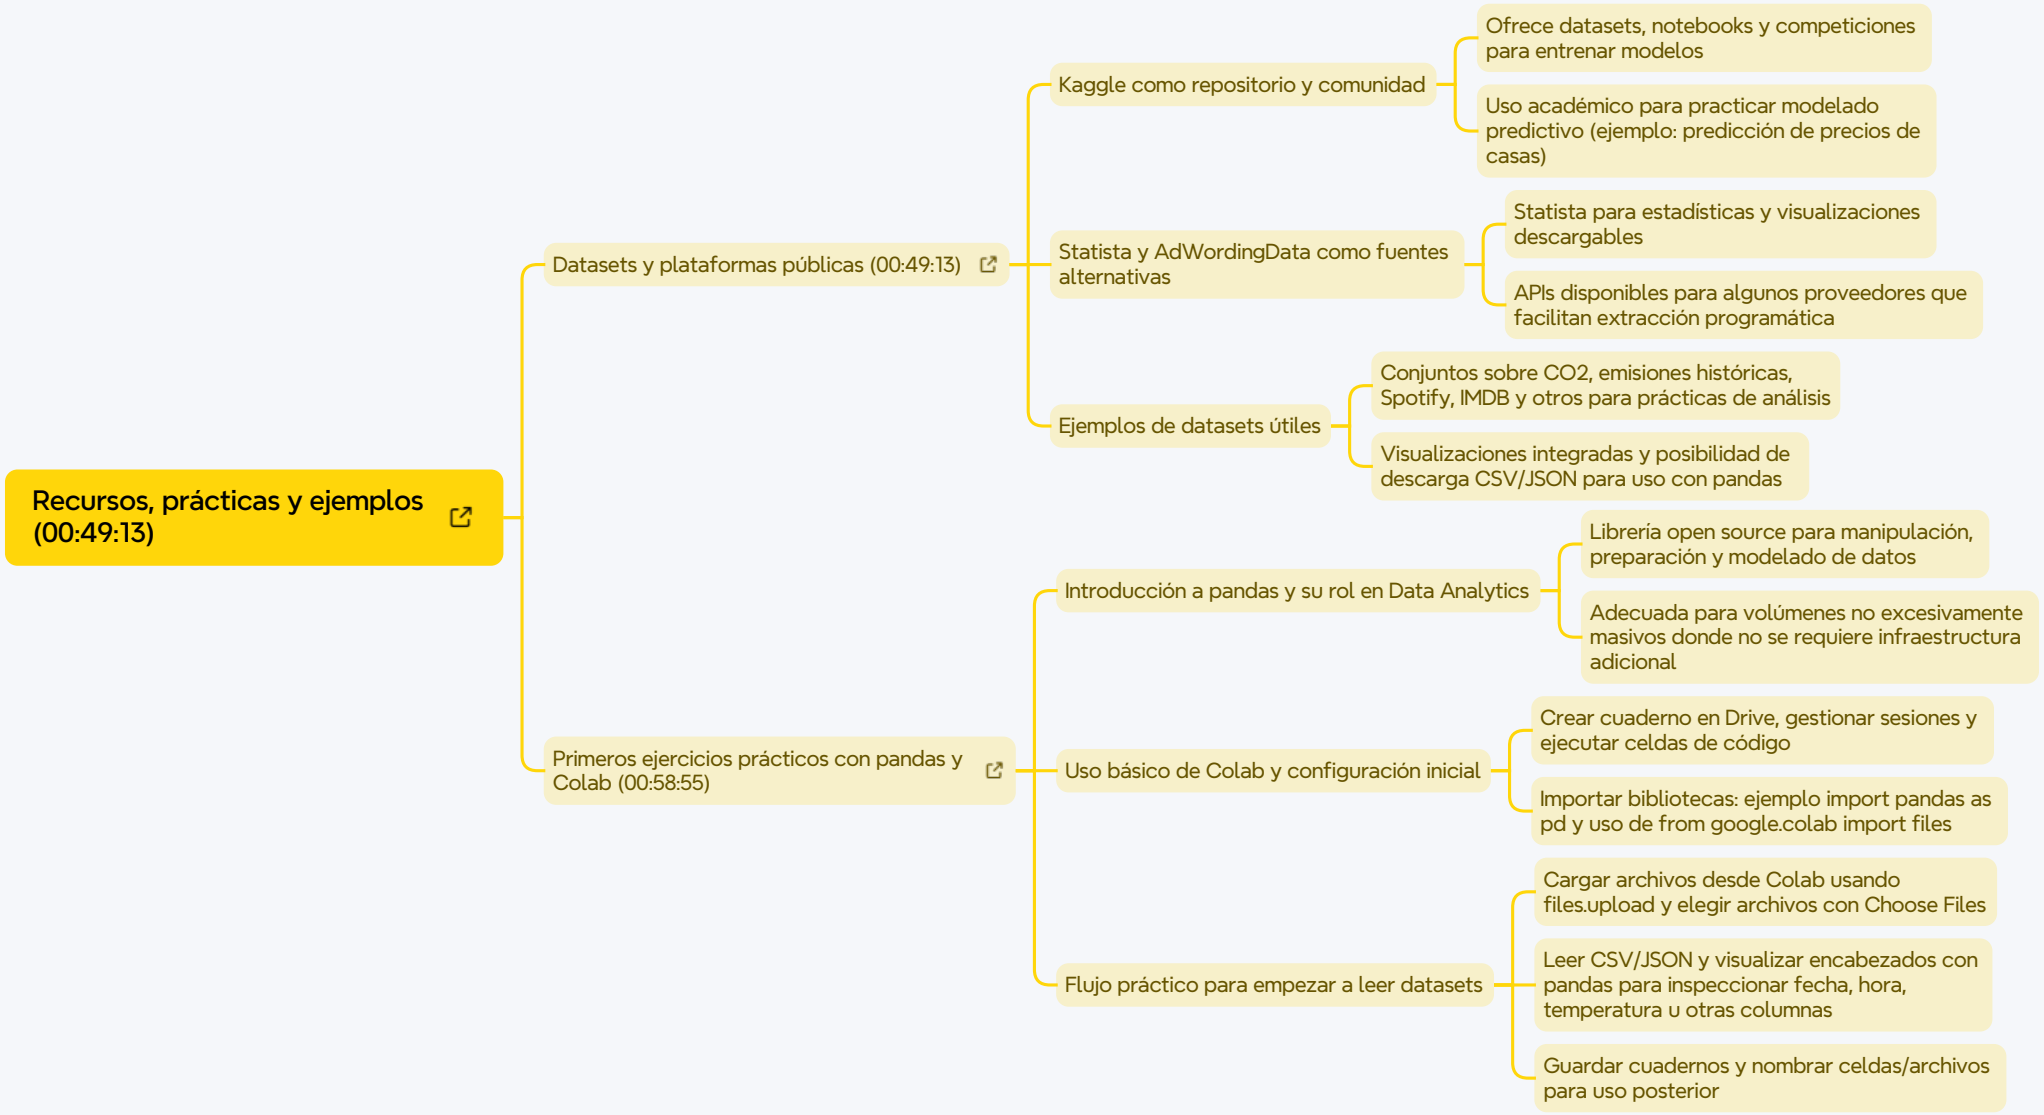

CLASE 03: ALMACENAMIENTO INTELIGENTE Y ARQUITECTURA DE DATOS MODERNA - 1RA PARTE
Apertura y logística (00:03:41) 14
Conceptos fundamentales y alcance del curso (00:06:50) 14
Recolección de datos: principios y métodos (00:27:41) 28
Recursos, prácticas y ejemplos (00:49:13) 21
Trabajo práctico en Colab: Excel y SQL desde Python (01:00:01) 14
Recursos finales y recomendaciones prácticas (01:23:48) 16
Cierre y próximos pasos (02:12:13) 12
Análisis visual y directrices de uso de orange (02:06:10) 17
Ejercicio práctico en Orange: gestión y procesamiento de datos en orange (02:00:00) 14
IoT práctico: MQTT y brokers públicos (01:38:41) 14
Web scraping y extracción de tablas (01:29:09) 13
Integración y flujo: desde sensor hasta análisis (01:27:54) 11

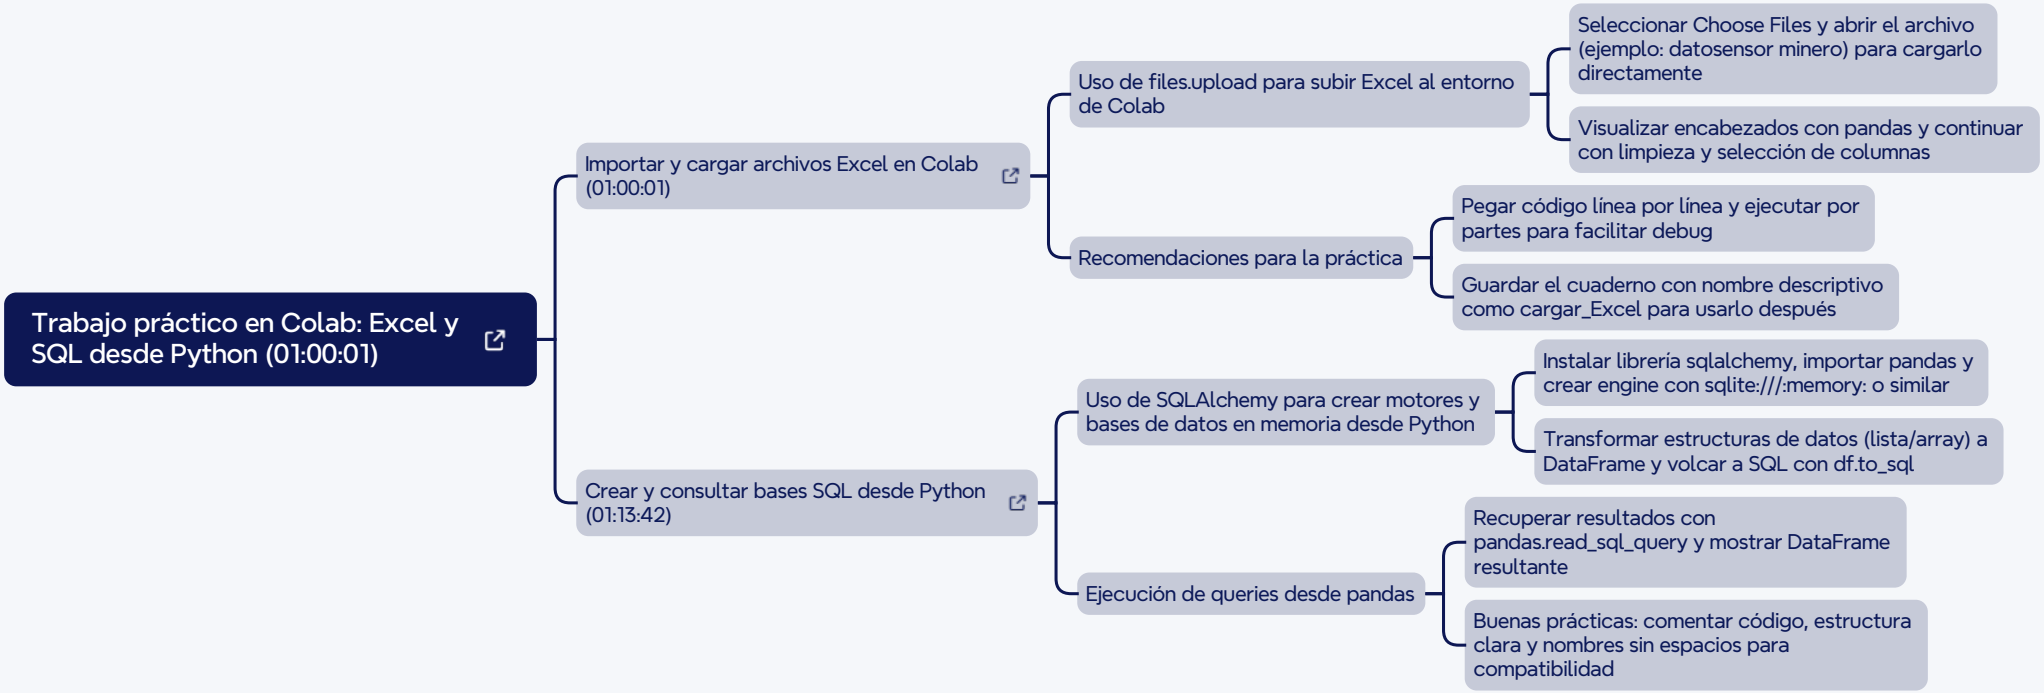

Apertura y logística (00:03:41)
Bienvenida y organización de la sesión (00:03:41)
Inicio de la clase con presentación del profesor y asesora académica
Indicaciones para preguntas: levantar la mano o usar el chat
Aclaración de horarios: break a las 21:00 y fin a las 22:00
Objetivo de interacción inicial entre estudiantes
Pedir a quienes no se presentaron en la sesión anterior que se introduzcan
Preguntas guiadas sobre intereses y aplicación práctica del curso
Plan de la clase y herramientas a usar (00:05:24)
Resumen del contenido práctico y ejercicios finales
Ejercicio con Orange para visualización y minería de datos
Uso de Python en Colab y librería pandas para manipulación de datos
Recomendaciones de instalación y configuración
Preferencia por versión portable de Orange por facilidad de uso
Instrucciones para abrir Colab y preparar cuadernos en Drive

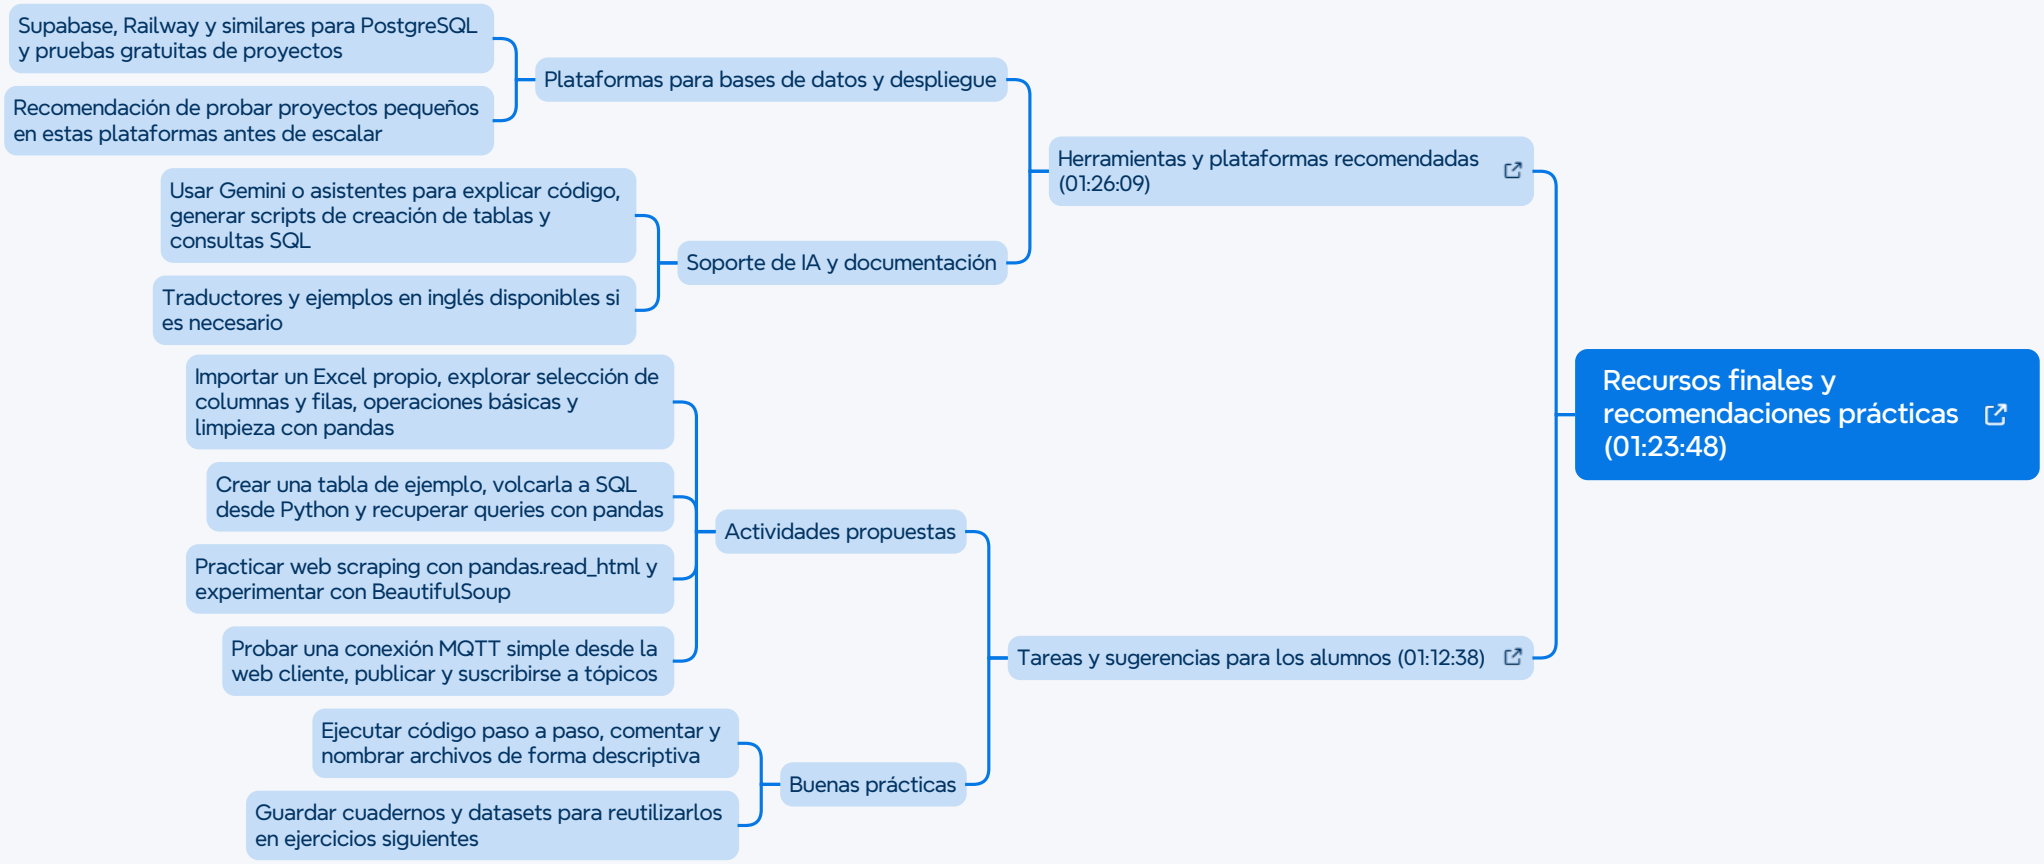

Conceptos fundamentales y alcance del curso (00:06:50)
Objetivo y contenidos principales (00:06:50)
Tema central: estrategias avanzadas de recolección y captura de datos
Cubrir teoría de recolección, web scraping e IoT
Enfoque práctico en Excel, SQL, Web Scraping y MQTT para IoT
Relación entre Big Data, Data Analytics y ciencia de datos
Big Data como componente técnico/infrastructural dentro de Data Analytics
Ciencia de datos como disciplina que integra cómputo, estadística y matemáticas aplicadas
Elección de herramientas y justificación (00:10:00)
Uso de Python, Colab y pandas como herramientas principales
Pandas elegido por flexibilidad, amplia comunidad y capacidades de análisis
Colab favorecido por no requerir instalación y ser accesible desde navegador
Ventajas del ecosistema y apoyo con IA
Reuso de soluciones existentes en internet y ayuda de Gemini/ChatGPT/Copilot para programar
Recomendación de buenas prácticas de programación: comentar código, evitar mayúsculas y espacios en nombres de columnas

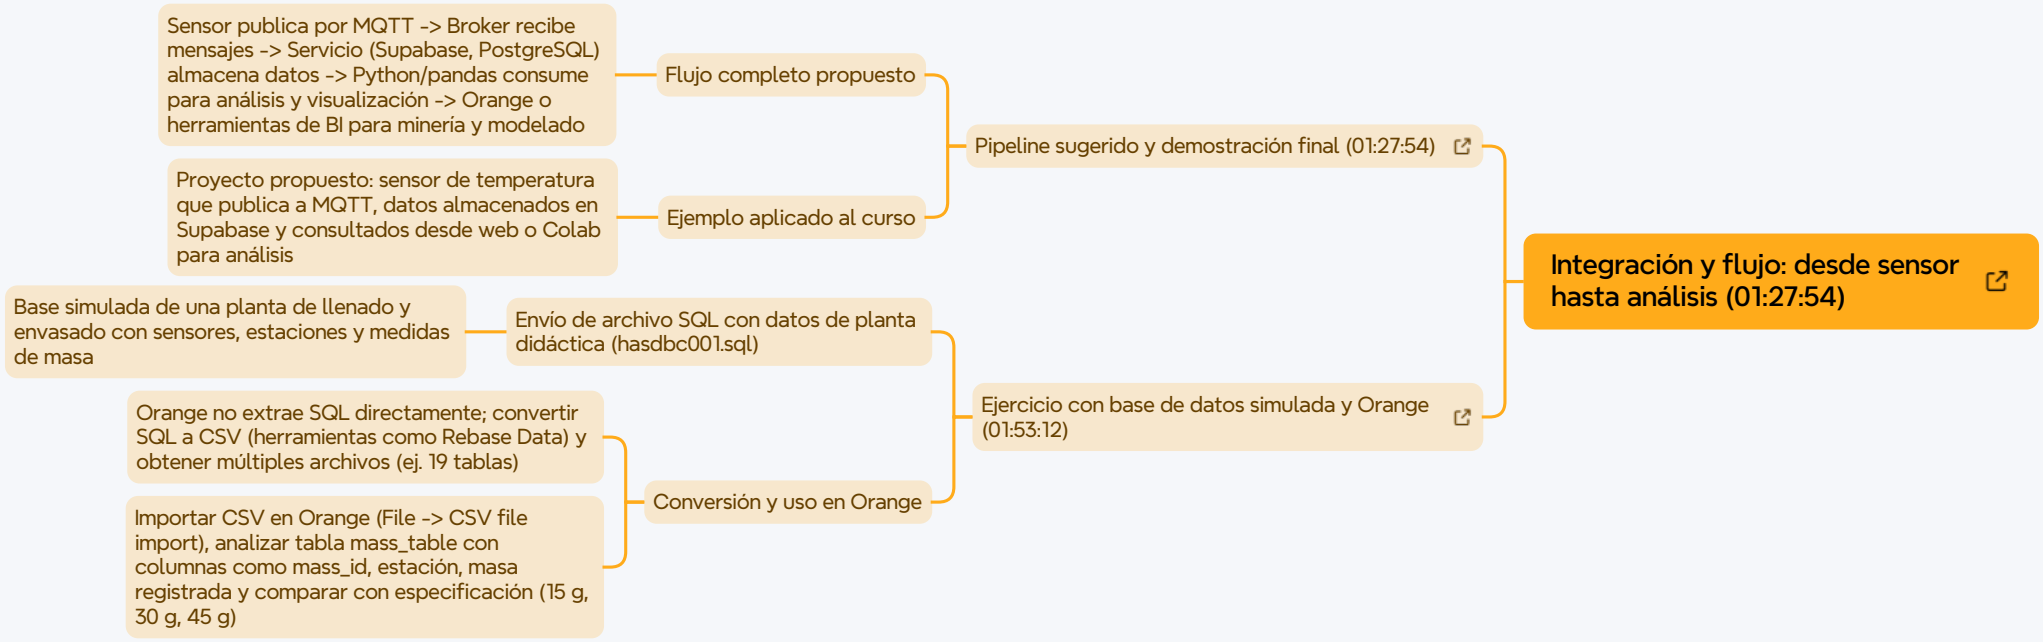
Recolección de datos: principios y métodos (00:27:41)

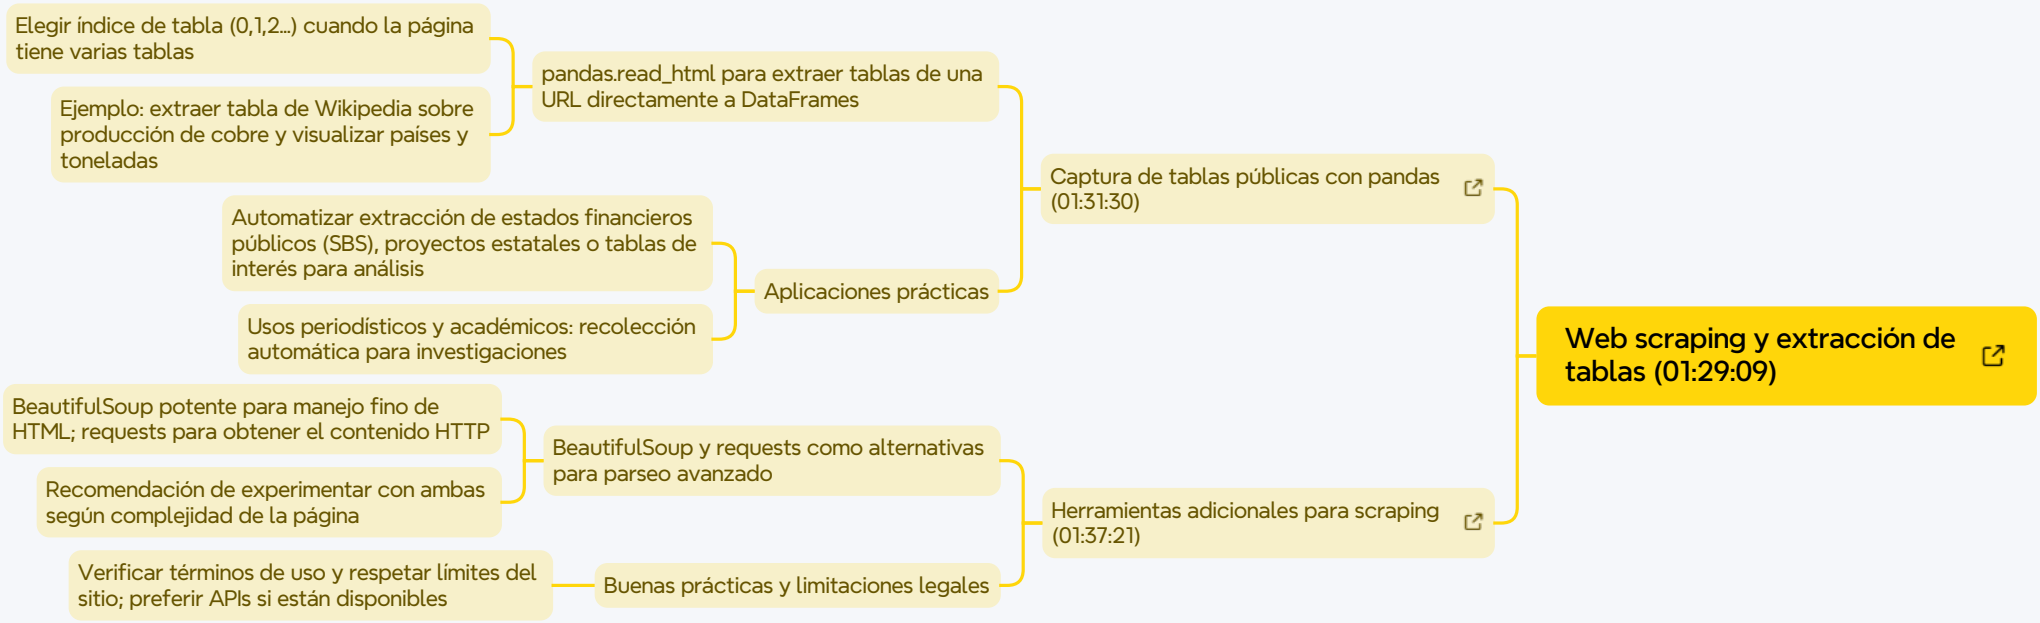
- Principios de la disciplina de datos (00:27:41)
  - Principio de calidad: datos fiables para conclusiones acertadas
    - Importancia de filtrar y limpiar datos corruptos
    - Técnicas para rellenar huecos evitando corrupción de la información
  - Principio de inercia: los datos adquieren valor al activarse
    - No recopilar datos sin propósito para la toma de decisiones
  - Principio de contexto: significado según origen y uso
    - Conocer si los datos son comerciales, técnicos, de mantenimiento u operativos
- Métodos y fuentes de recolección (00:38:21)
  - Recolección manual y tradicional
    - Encuestas y bases de datos tradicionales como punto de partida histórico
  - APIs y acceso programático a aplicaciones
    - APIs como protocolo que facilita extracción automatizada de datos
    - Dependencia de que el proveedor ofrezca las APIs y documentación
  - OPC y herramientas industriales
    - OPC como protocolo cliente-servidor usado en PLCs y software industrial
    - Ejemplo: uso de KepServer para integrar tópicos y centralizar datos desde PLCs
    - Posibilidad de crear servidores OPC con Python o usar clientes en Excel
  - IoT y sensores
    - IoT: envío automático de datos de sensores a bases de datos conectadas a Internet
    - Aplicaciones industriales: PLCs en red, ERP/SAP y supervisión remota
    - Riesgos de seguridad al exponer dispositivos industriales a Internet
  - Logs y registro de uso
    - Recolección de logs de aplicaciones, apps y sitios web para análisis
    - Requiere acceso a registros y mayor programación para extracción automatizada
  - MQTT para sensores IoT
    - Protocolo ligero recomendado para comunicación M2M en entornos IoT
    - Modelo publicador-suscriptor, brokers públicos y limitaciones de cuentas gratuitas

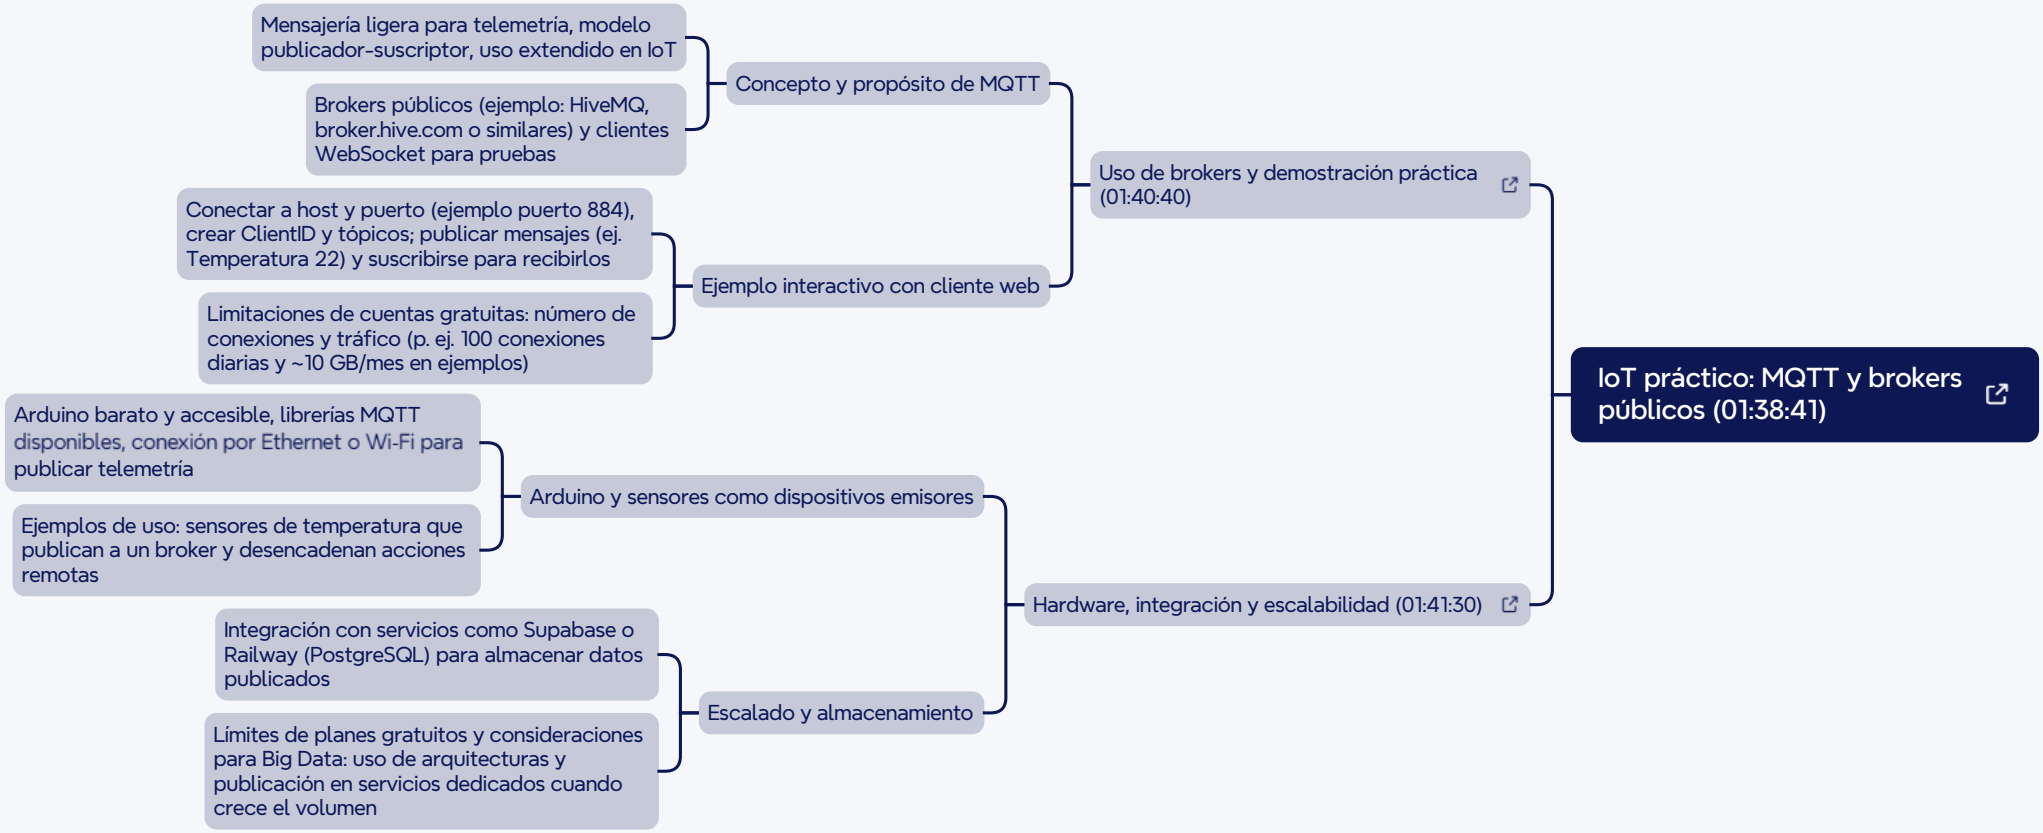

Recursos, prácticas y ejemplos (00:49:13)
Datasets y plataformas públicas (00:49:13)
Kaggle como repositorio y comunidad
Ofrece datasets, notebooks y competiciones para entrenar modelos
Uso académico para practicar modelado predictivo (ejemplo: predicción de precios de casas)
Statista y AdWordingData como fuentes alternativas
Statista para estadísticas y visualizaciones descargables
APIs disponibles para algunos proveedores que facilitan extracción programática
Ejemplos de datasets útiles
Conjuntos sobre CO2, emisiones históricas, Spotify, IMDB y otros para prácticas de análisis
Visualizaciones integradas y posibilidad de descarga CSV/JSON para uso con pandas
Primeros ejercicios prácticos con pandas y Colab (00:58:55)
Introducción a pandas y su rol en Data Analytics
Librería open source para manipulación, preparación y modelado de datos
Adecuada para volúmenes no excesivamente masivos donde no se requiere infraestructura adicional
Uso básico de Colab y configuración inicial
Crear cuaderno en Drive, gestionar sesiones y ejecutar celdas de código
Importar bibliotecas: ejemplo import pandas as pd y uso de from google.colab import files
Flujo práctico para empezar a leer datasets
Cargar archivos desde Colab usando files.upload y elegir archivos con Choose Files
Leer CSV/JSON y visualizar encabezados con pandas para inspeccionar fecha, hora, temperatura u otras columnas
Guardar cuadernos y nombrar celdas/archivos para uso posterior

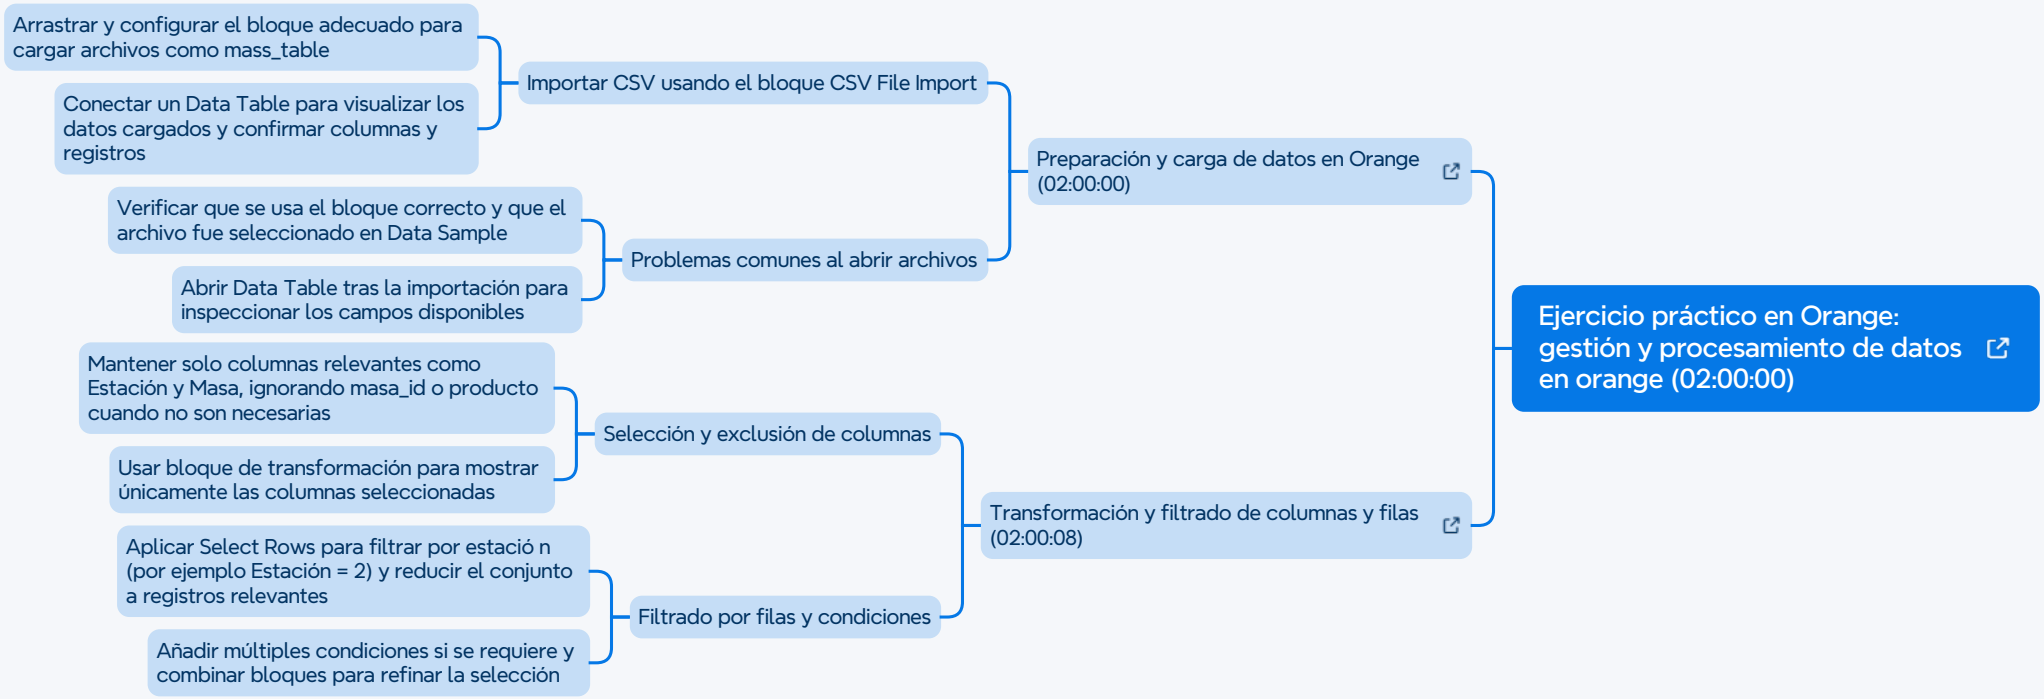

Trabajo práctico en Colab: Excel y SQL desde Python (01:00:01)
Importar y cargar archivos Excel en Colab (01:00:01)
Uso de files.upload para subir Excel al entorno de Colab
Seleccionar Choose Files y abrir el archivo (ejemplo: datosensor minero) para cargarlo directamente
Visualizar encabezados con pandas y continuar con limpieza y selección de columnas
Recomendaciones para la práctica
Pegar código línea por línea y ejecutar por partes para facilitar debug
Guardar el cuaderno con nombre descriptivo como cargar_Excel para usarlo después
Crear y consultar bases SQL desde Python (01:13:42)
Uso de SQLAlchemy para crear motores y bases de datos en memoria desde Python
Instalar librería sqlalchemy, importar pandas y crear engine con sqlite:///:memory: o similar
Transformar estructuras de datos (lista/array) a DataFrame y volcar a SQL con df.to_sql
Ejecución de queries desde pandas
Recuperar resultados con pandas.read_sql_query y mostrar DataFrame resultante
Buenas prácticas: comentar código, estructura clara y nombres sin espacios para compatibilidad

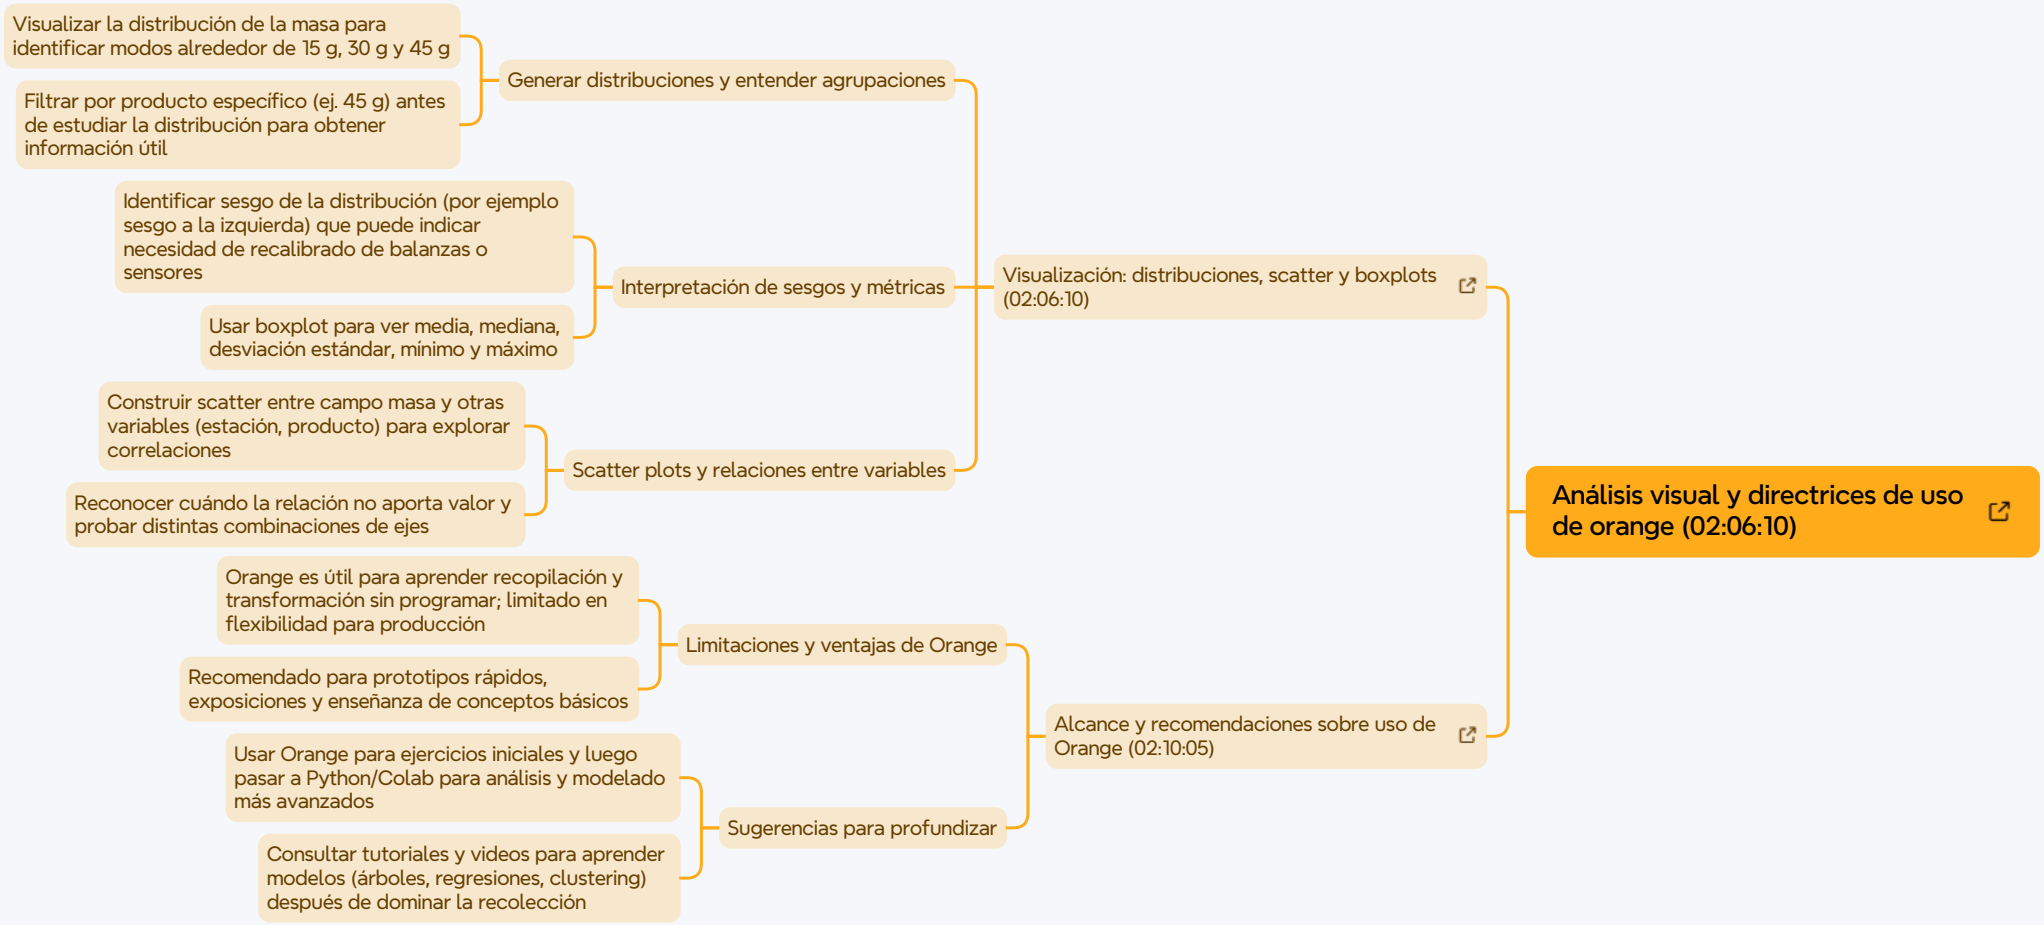

Recursos finales y recomendaciones prácticas (01:23:48)
Herramientas y plataformas recomendadas (01:26:09)
Plataformas para bases de datos y despliegue
Supabase, Railway y similares para PostgreSQL y pruebas gratuitas de proyectos
Recomendación de probar proyectos pequeños en estas plataformas antes de escalar
Soporte de IA y documentación
Usar Gemini o asistentes para explicar código, generar scripts de creación de tablas y consultas SQL
Traductores y ejemplos en inglés disponibles si es necesario
Tareas y sugerencias para los alumnos (01:12:38)
Actividades propuestas
Importar un Excel propio, explorar selección de columnas y filas, operaciones básicas y limpieza con pandas
Crear una tabla de ejemplo, volcarla a SQL desde Python y recuperar queries con pandas
Practicar web scraping con pandas.read_html y experimentar con BeautifulSoup
Probar una conexión MQTT simple desde la web cliente, publicar y suscribirse a tópicos
Buenas prácticas
Ejecutar código paso a paso, comentar y nombrar archivos de forma descriptiva
Guardar cuadernos y datasets para reutilizarlos en ejercicios siguientes

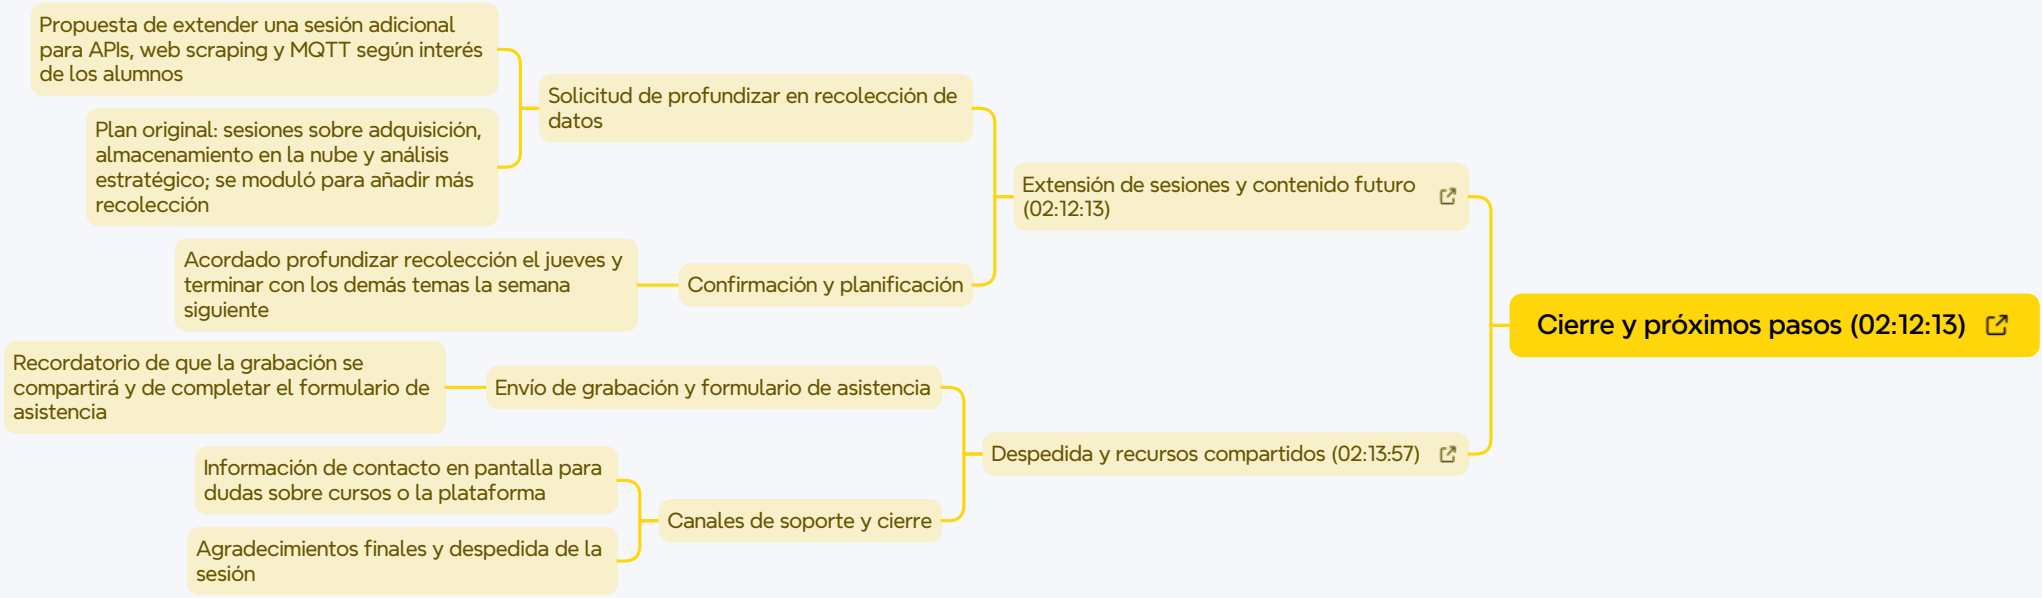

Integración y flujo: desde sensor hasta análisis (01:27:54)
Pipeline sugerido y demostración final (01:27:54)
Flujo completo propuesto
Sensor publica por MQTT -> Broker recibe mensajes -> Servicio (Supabase, PostgreSQL) almacena datos -> Python/pandas consume para análisis y visualización -> Orange o herramientas de BI para minería y modelado
Ejemplo aplicado al curso
Proyecto propuesto: sensor de temperatura que publica a MQTT, datos almacenados en Supabase y consultados desde web o Colab para análisis
Ejercicio con base de datos simulada y Orange (01:53:12)
Envío de archivo SQL con datos de planta didáctica (hasdbc001.sql)
Base simulada de una planta de llenado y envasado con sensores, estaciones y medidas de masa
Conversión y uso en Orange
Orange no extrae SQL directamente; convertir SQL a CSV (herramientas como Rebase Data) y obtener múltiples archivos (ej. 19 tablas)
Importar CSV en Orange (File -> CSV file import), analizar tabla mass_table con columnas como mass_id, estación, masa registrada y comparar con especificación (15 g, 30 g, 45 g)


Web scraping y extracción de tablas (01:29:09)
Captura de tablas públicas con pandas (01:31:30)
pandas.read_html para extraer tablas de una URL directamente a DataFrames
Elegir índice de tabla (0,1,2...) cuando la página tiene varias tablas
Ejemplo: extraer tabla de Wikipedia sobre producción de cobre y visualizar países y toneladas
Aplicaciones prácticas
Automatizar extracción de estados financieros públicos (SBS), proyectos estatales o tablas de interés para análisis
Usos periodísticos y académicos: recolección automática para investigaciones
Herramientas adicionales para scraping (01:37:21)
BeautifulSoup y requests como alternativas para parseo avanzado
BeautifulSoup potente para manejo fino de HTML; requests para obtener el contenido HTTP
Recomendación de experimentar con ambas según complejidad de la página
Buenas prácticas y limitaciones legales
Verificar términos de uso y respetar límites del sitio; preferir APIs si están disponibles


IoT práctico: MQTT y brokers públicos (01:38:41)
Uso de brokers y demostración práctica (01:40:40)
Concepto y propósito de MQTT
Mensajería ligera para telemetría, modelo publicador-suscriptor, uso extendido en IoT
Brokers públicos (ejemplo: HiveMQ, broker.hive.com o similares) y clientes WebSocket para pruebas
Ejemplo interactivo con cliente web
Conectar a host y puerto (ejemplo puerto 884), crear ClientID y tópicos; publicar mensajes (ej. Temperatura 22) y suscribirse para recibirlos
Limitaciones de cuentas gratuitas: número de conexiones y tráfico (p. ej. 100 conexiones diarias y ~10 GB/mes en ejemplos)
Hardware, integración y escalabilidad (01:41:30)
Arduino y sensores como dispositivos emisores
Arduino barato y accesible, librerías MQTT disponibles, conexión por Ethernet o Wi-Fi para publicar telemetría
Ejemplos de uso: sensores de temperatura que publican a un broker y desencadenan acciones remotas
Escalado y almacenamiento
Integración con servicios como Supabase o Railway (PostgreSQL) para almacenar datos publicados
Límites de planes gratuitos y consideraciones para Big Data: uso de arquitecturas y publicación en servicios dedicados cuando crece el volumen


Ejercicio práctico en Orange: gestión y procesamiento de datos en orange (02:00:00)
Preparación y carga de datos en Orange (02:00:00)
Importar CSV usando el bloque CSV File Import
Arrastrar y configurar el bloque adecuado para cargar archivos como mass_table
Conectar un Data Table para visualizar los datos cargados y confirmar columnas y registros
Problemas comunes al abrir archivos
Verificar que se usa el bloque correcto y que el archivo fue seleccionado en Data Sample
Abrir Data Table tras la importación para inspeccionar los campos disponibles
Transformación y filtrado de columnas y filas (02:00:08)
Selección y exclusión de columnas
Mantener solo columnas relevantes como Estación y Masa, ignorando masa_id o producto cuando no son necesarias
Usar bloque de transformación para mostrar únicamente las columnas seleccionadas
Filtrado por filas y condiciones
Aplicar Select Rows para filtrar por estació n (por ejemplo Estación = 2) y reducir el conjunto a registros relevantes
Añadir múltiples condiciones si se requiere y combinar bloques para refinar la selección


Análisis visual y directrices de uso de orange (02:06:10)
Visualización: distribuciones, scatter y boxplots (02:06:10)
Generar distribuciones y entender agrupaciones
Visualizar la distribución de la masa para identificar modos alrededor de 15 g, 30 g y 45 g
Filtrar por producto específico (ej. 45 g) antes de estudiar la distribución para obtener información útil
Interpretación de sesgos y métricas
Identificar sesgo de la distribución (por ejemplo sesgo a la izquierda) que puede indicar necesidad de recalibrado de balanzas o sensores
Usar boxplot para ver media, mediana, desviación estándar, mínimo y máximo
Scatter plots y relaciones entre variables
Construir scatter entre campo masa y otras variables (estación, producto) para explorar correlaciones
Reconocer cuándo la relación no aporta valor y probar distintas combinaciones de ejes
Alcance y recomendaciones sobre uso de Orange (02:10:05)
Limitaciones y ventajas de Orange
Orange es útil para aprender recopilación y transformación sin programar; limitado en flexibilidad para producción
Recomendado para prototipos rápidos, exposiciones y enseñanza de conceptos básicos
Sugerencias para profundizar
Usar Orange para ejercicios iniciales y luego pasar a Python/Colab para análisis y modelado más avanzados
Consultar tutoriales y videos para aprender modelos (árboles, regresiones, clustering) después de dominar la recolección


Cierre y próximos pasos (02:12:13)
Extensión de sesiones y contenido futuro (02:12:13)
Solicitud de profundizar en recolección de datos
Propuesta de extender una sesión adicional para APIs, web scraping y MQTT según interés de los alumnos
Plan original: sesiones sobre adquisición, almacenamiento en la nube y análisis estratégico; se moduló para añadir más recolección
Confirmación y planificación
Acordado profundizar recolección el jueves y terminar con los demás temas la semana siguiente
Despedida y recursos compartidos (02:13:57)
Envío de grabación y formulario de asistencia
Recordatorio de que la grabación se compartirá y de completar el formulario de asistencia
Canales de soporte y cierre
Información de contacto en pantalla para dudas sobre cursos o la plataforma
Agradecimientos finales y despedida de la sesión