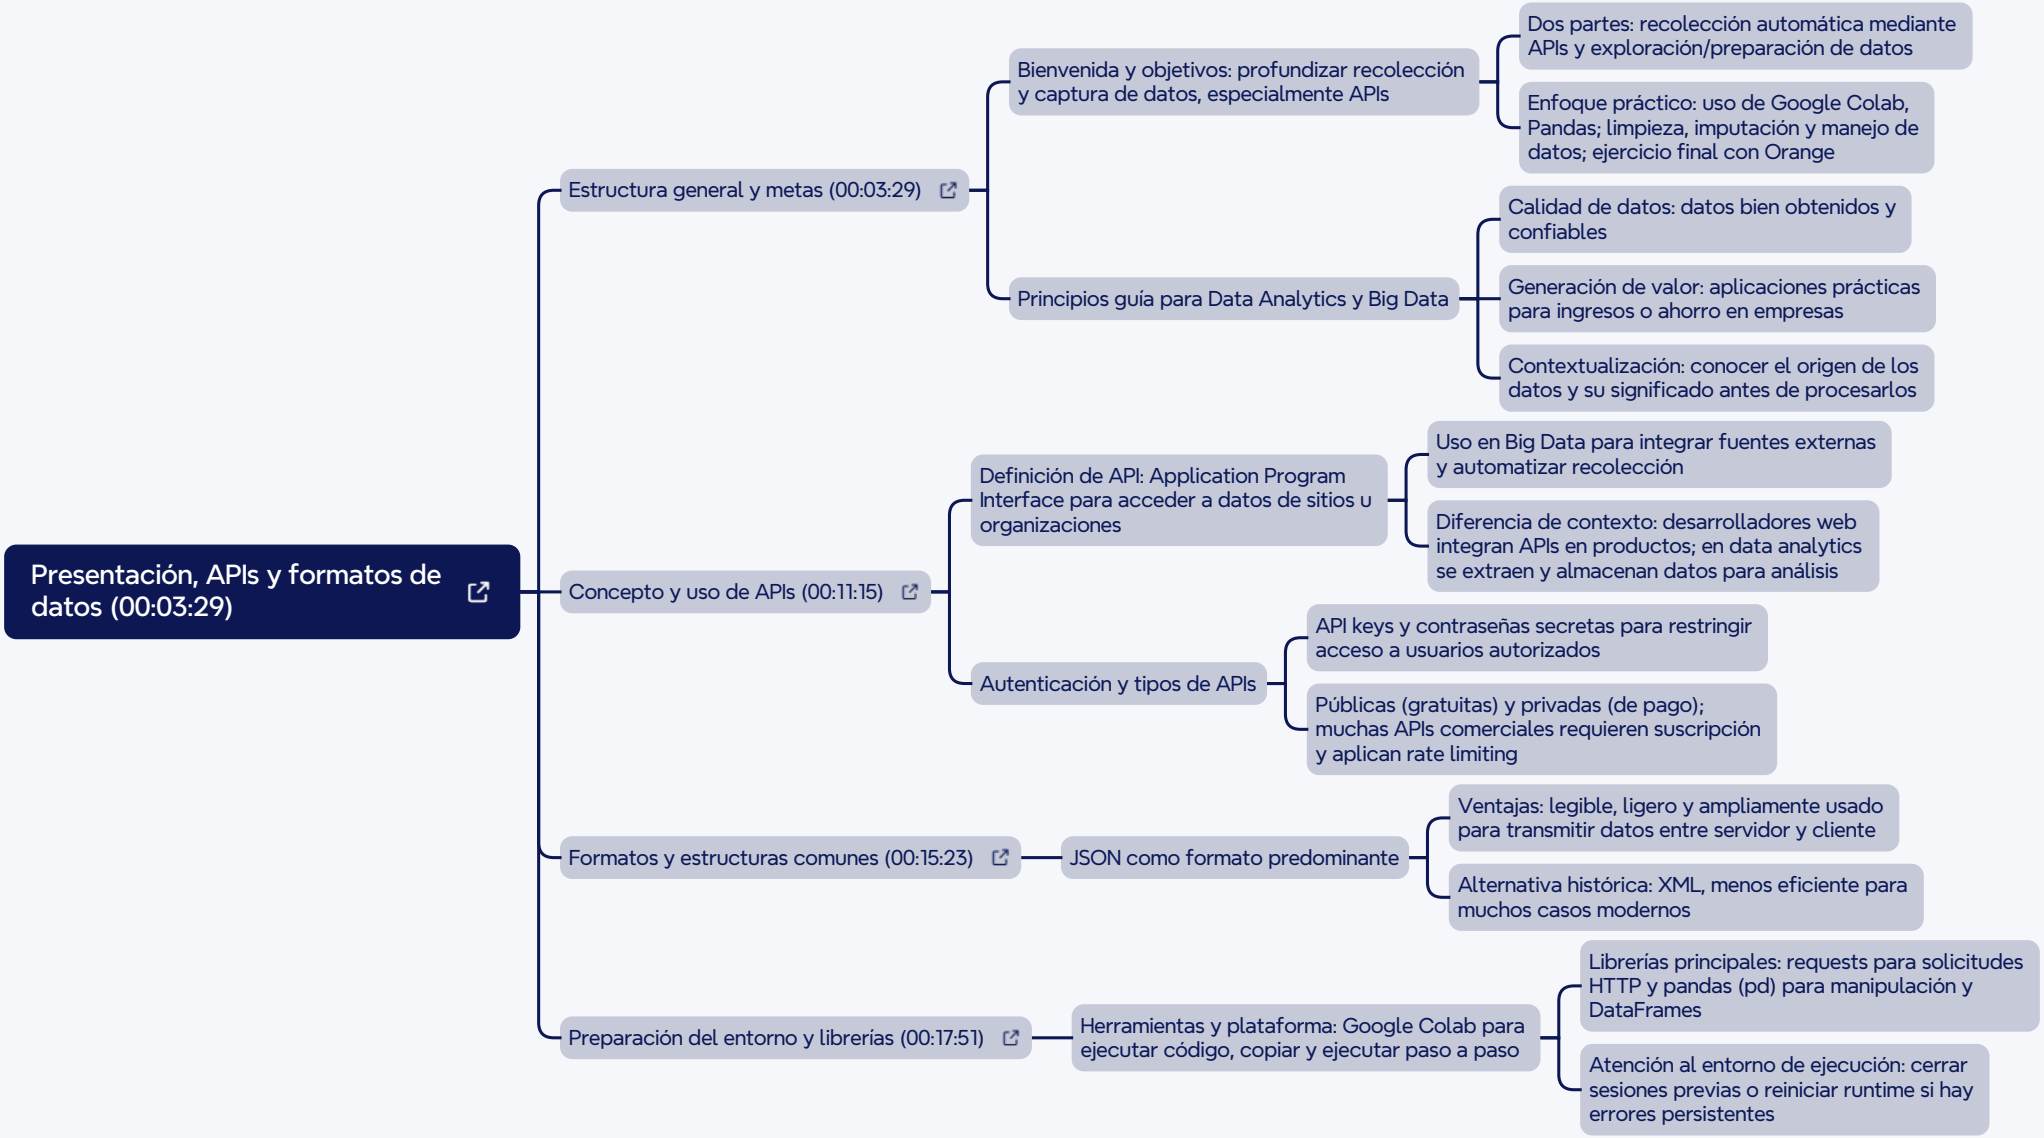
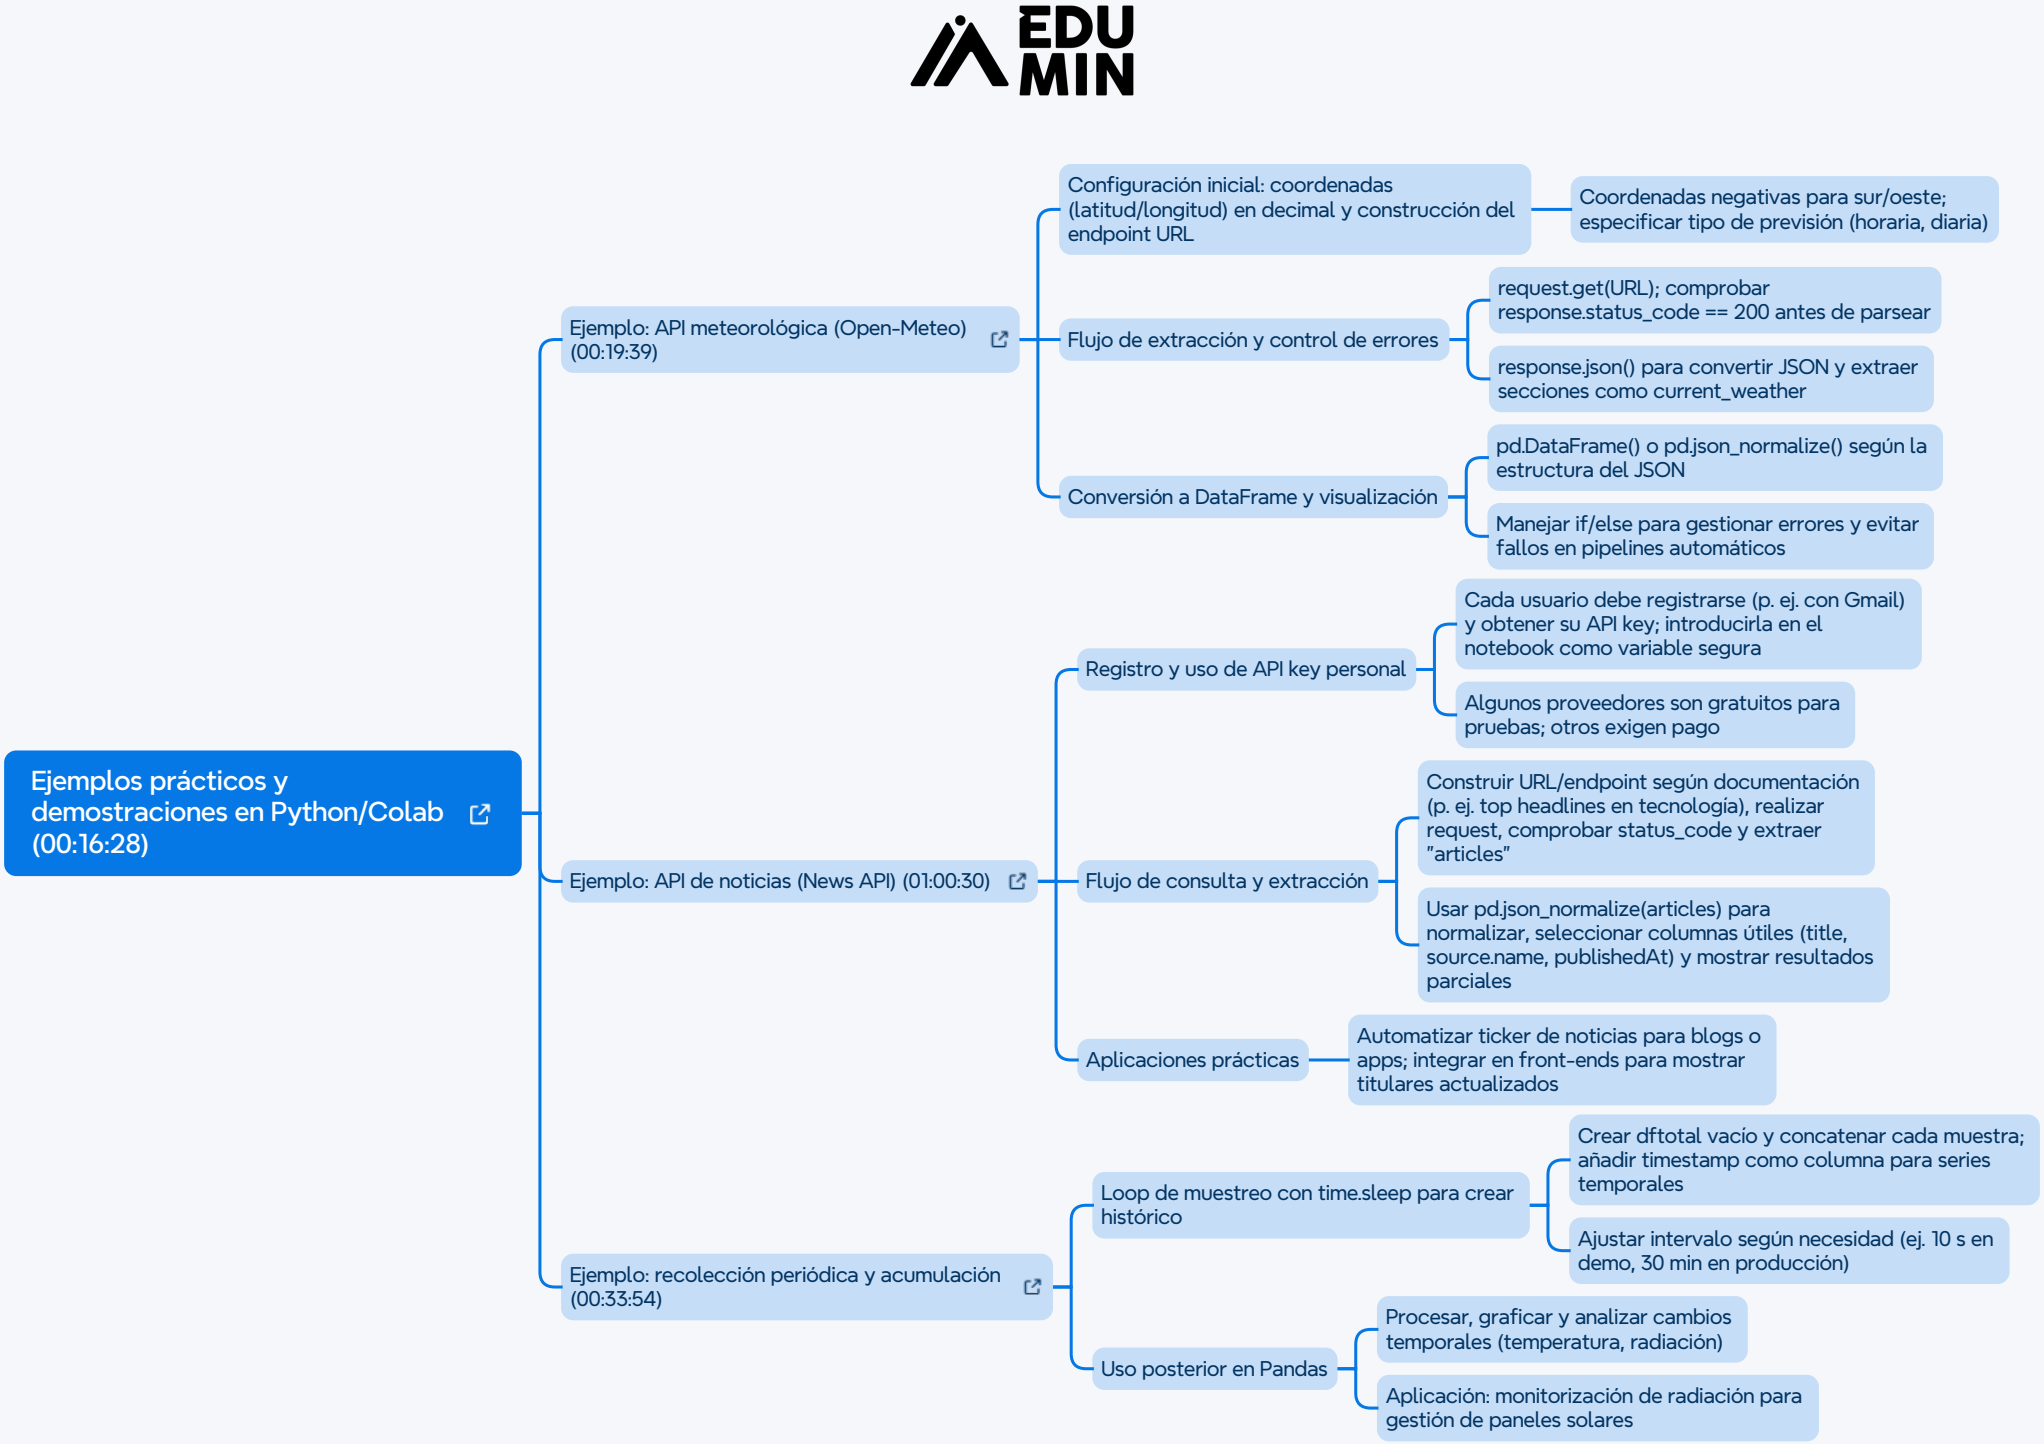
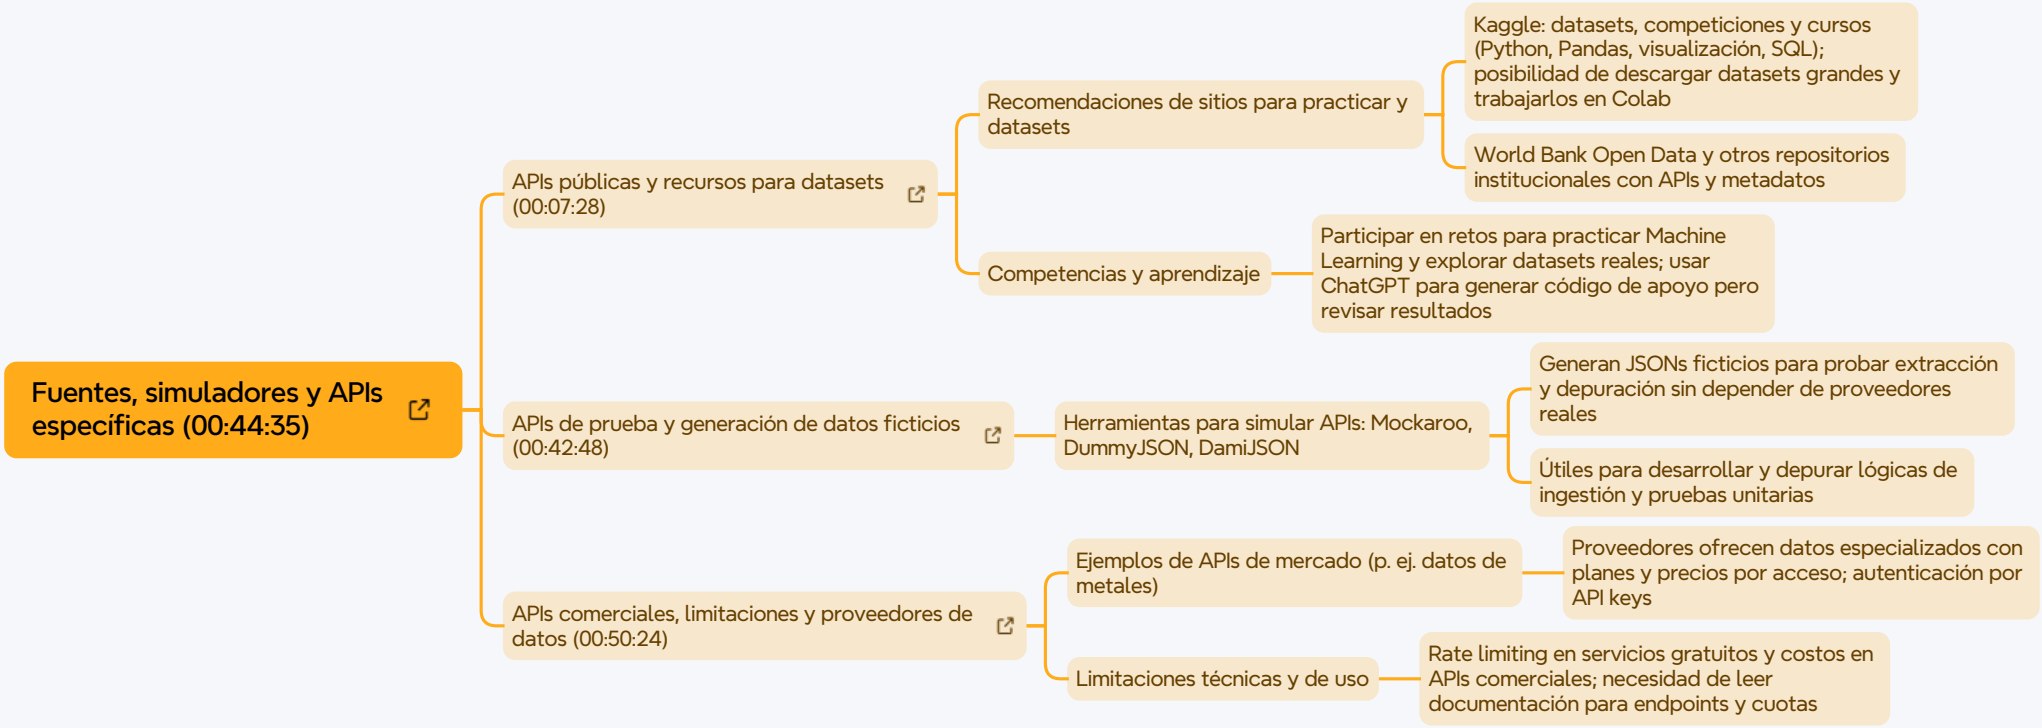
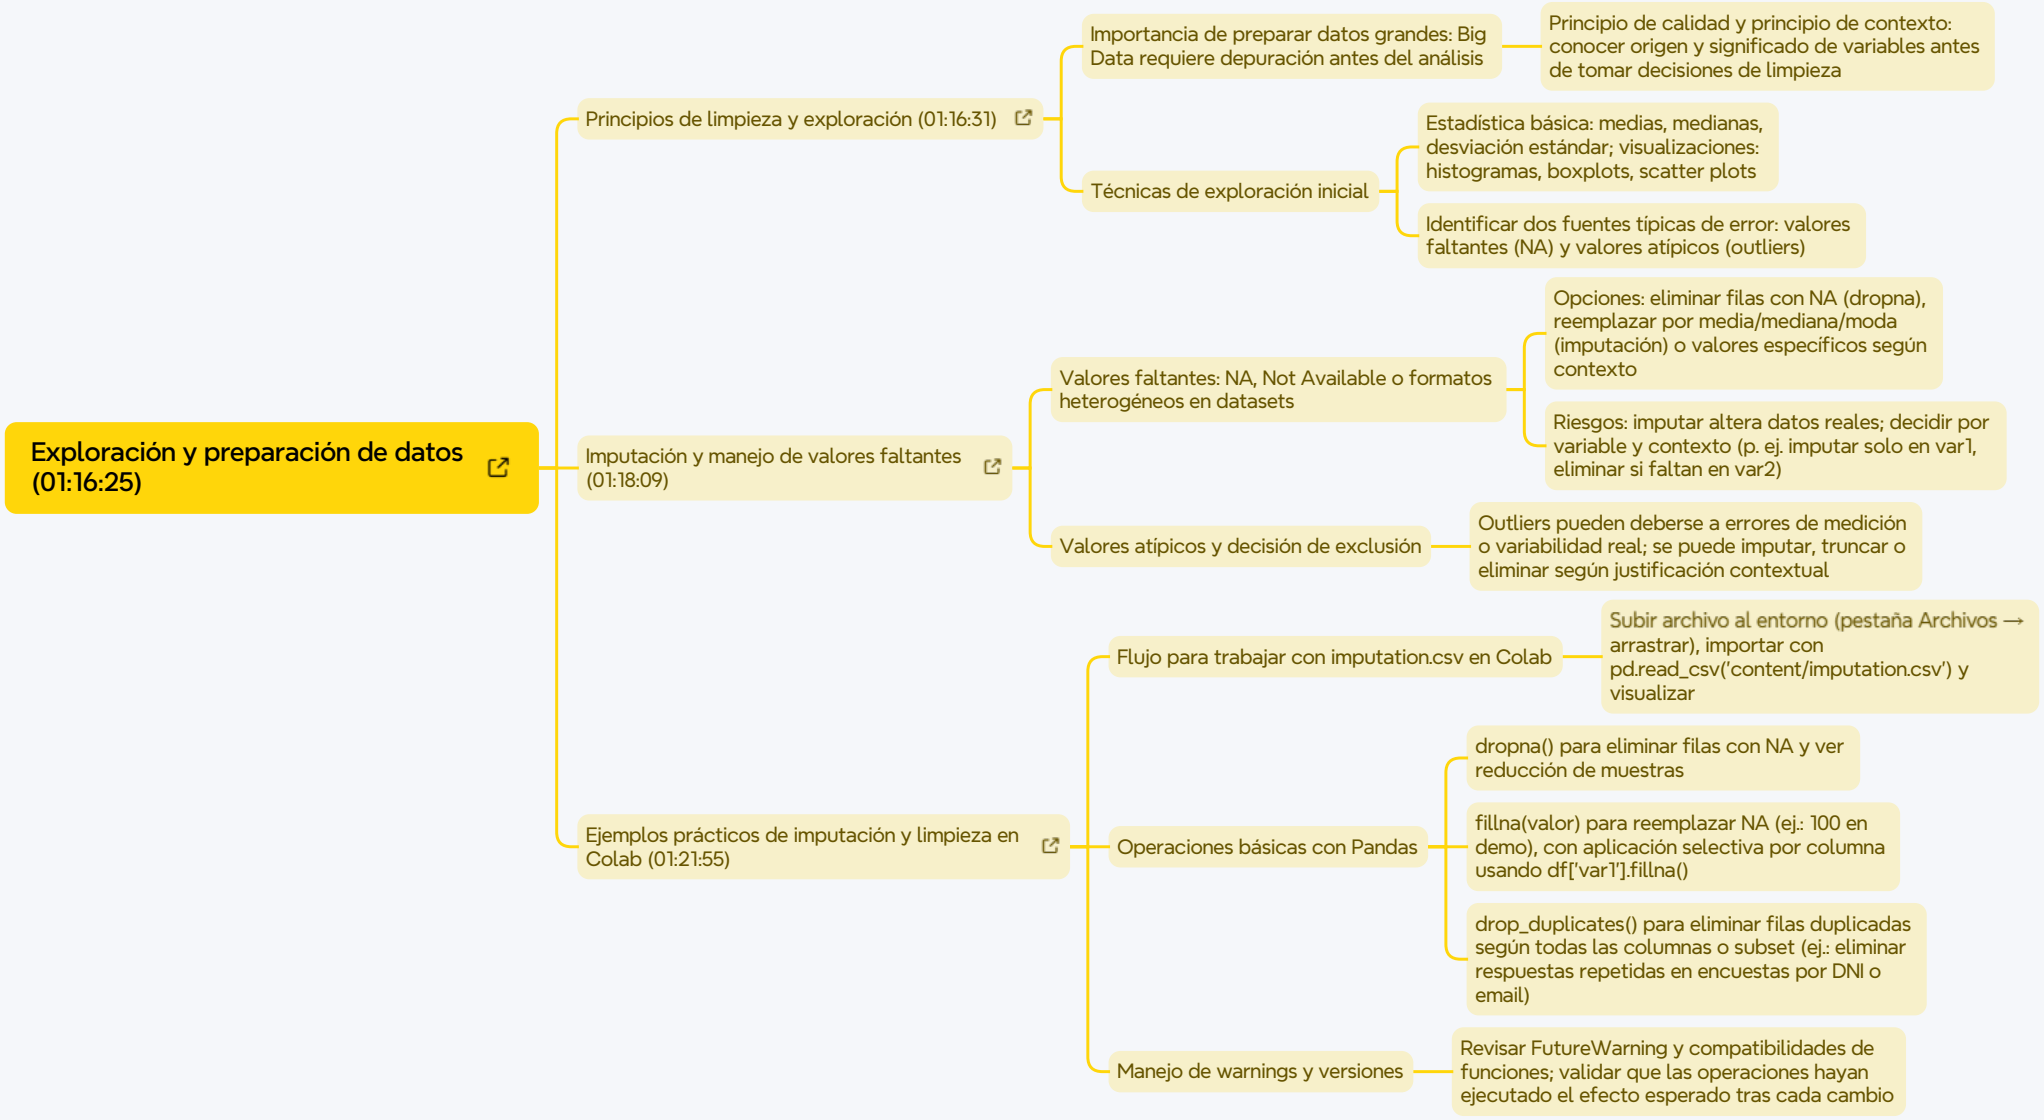
EDU MIN


CLASE 04: ALMACENAMIENTO INTELIGENTE Y ARQUITECTURA DE DATOS MODERNA - 2DA PARTE
Cierre, tareas sugeridas y próximos pasos (02:29:12)
Buenas prácticas y consideraciones finales (02:26:24)
Caso práctico con Orange: importación, filtrado e imputación (02:08:39)
Recursos locales, GIS y bancos de datos nacionales (02:00:05)
Otras fuentes y herramientas de apoyo (01:57:30)
Presentación, APIs y formatos de datos (00:03:29)
Ejemplos prácticos y demostraciones en Python/Colab (00:16:28)
Fuentes, simuladores y APIs específicas (00:44:35)
Exploración y preparación de datos (01:16:25)
Trabajo con datasets grandes: Kaggle y ejemplo práctico (01:35:55)


Presentación, APIs y formatos de datos (00:03:29)
Estructura general y metas (00:03:29)
Bienvenida y objetivos: profundizar recolección y captura de datos, especialmente APIs
Dos partes: recolección automática mediante APIs y exploración/preparación de datos
Enfoque práctico: uso de Google Colab, Pandas; limpieza, imputación y manejo de datos; ejercicio final con Orange
Principios guía para Data Analytics y Big Data
Calidad de datos: datos bien obtenidos y confiables
Generación de valor: aplicaciones prácticas para ingresos o ahorro en empresas
Contextualización: conocer el origen de los datos y su significado antes de procesarlos
Concepto y uso de APIs (00:11:15)
Definición de API: Application Program Interface para acceder a datos de sitios u organizaciones
Uso en Big Data para integrar fuentes externas y automatizar recolección
Diferencia de contexto: desarrolladores web integran APIs en productos; en data analytics se extraen y almacenan datos para análisis
Autenticación y tipos de APIs
API keys y contraseñas secretas para restringir acceso a usuarios autorizados
Públicas (gratuitas) y privadas (de pago); muchas APIs comerciales requieren suscripción y aplican rate limiting
Formatos y estructuras comunes (00:15:23)
JSON como formato predominante
Ventajas: legible, ligero y ampliamente usado para transmitir datos entre servidor y cliente
Alternativa histórica: XML, menos eficiente para muchos casos modernos
Preparación del entorno y librerías (00:17:51)
Herramientas y plataforma: Google Colab para ejecutar código, copiar y ejecutar paso a paso
Librerías principales: requests para solicitudes HTTP y pandas (pd) para manipulación y DataFrames
Atención al entorno de ejecución: cerrar sesiones previas o reiniciar runtime si hay errores persistentes

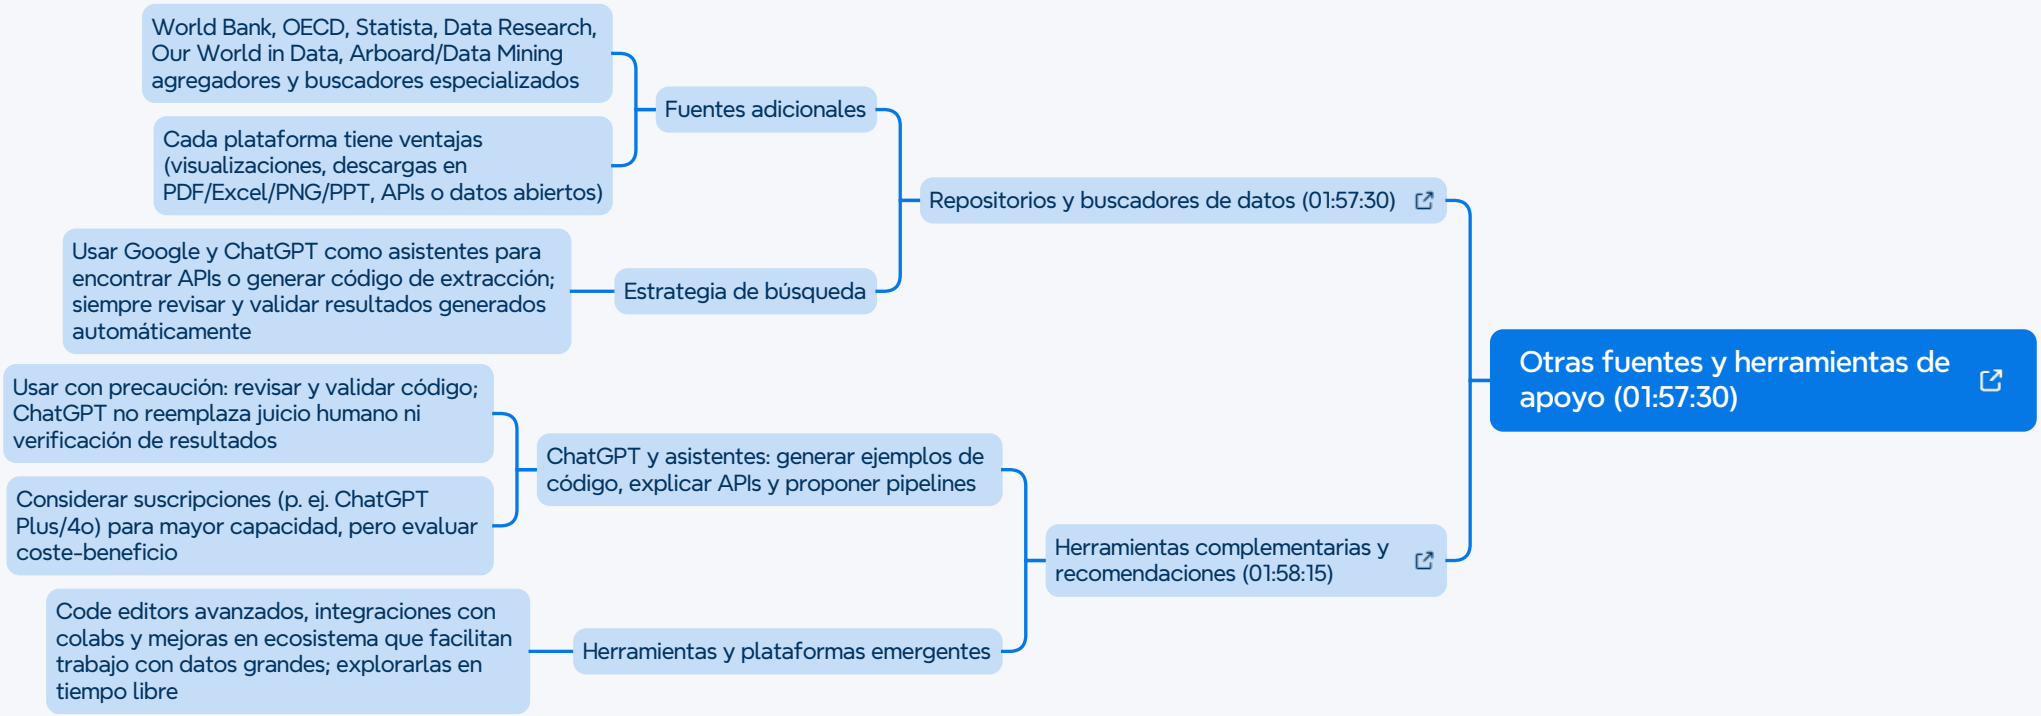

Ejemplos prácticos y demostraciones en Python/Colab (00:16:28)
Ejemplo: API meteorológica (Open-Meteo) (00:19:39)
Configuración inicial: coordenadas (latitud/longitud) en decimal y construcción del endpoint URL
Coordenadas negativas para sur/oeste; especificar tipo de previsión (horaria, diaria)
Flujo de extracción y control de errores
request.get(URL); comprobar response.status_code == 200 antes de parsear
response.json() para convertir JSON y extraer secciones como current_weather
Conversión a DataFrame y visualización
pd.DataFrame() o pd.json_normalize() según la estructura del JSON
Manejar if/else para gestionar errores y evitar fallos en pipelines automáticos
Ejemplo: API de noticias (News API) (01:00:30)
Registro y uso de API key personal
Cada usuario debe registrarse (p. ej. con Gmail) y obtener su API key; introducirla en el notebook como variable segura
Algunos proveedores son gratuitos para pruebas; otros exigen pago
Flujo de consulta y extracción
Construir URL/endpoint según documentación (p. ej. top headlines en tecnología), realizar request, comprobar status_code y extraer "articles"
Usar pd.json_normalize(articles) para normalizar, seleccionar columnas útiles (title, source.name, publishedAt) y mostrar resultados parciales
Aplicaciones prácticas
Automatizar ticker de noticias para blogs o apps; integrar en front-ends para mostrar titulares actualizados
Ejemplo: recolección periódica y acumulación (00:33:54)
Loop de muestreo con time.sleep para crear histórico
Crear dftotal vacío y concatenar cada muestra; añadir timestamp como columna para series temporales
Ajustar intervalo según necesidad (ej. 10 s en demo, 30 min en producción)
Uso posterior en Pandas
Procesar, graficar y analizar cambios temporales (temperatura, radiación)
Aplicación: monitorización de radiación para gestión de paneles solares


Fuentes, simuladores y APIs específicas (00:44:35)
APIs públicas y recursos para datasets (00:07:28)
Recomendaciones de sitios para practicar y datasets
Kaggle: datasets, competiciones y cursos (Python, Pandas, visualización, SQL); posibilidad de descargar datasets grandes y trabajarlos en Colab
World Bank Open Data y otros repositorios institucionales con APIs y metadatos
Competencias y aprendizaje
Participar en retos para practicar Machine Learning y explorar datasets reales; usar ChatGPT para generar código de apoyo pero revisar resultados
APIs de prueba y generación de datos ficticios (00:42:48)
Herramientas para simular APIs: Mockaroo, DummyJSON, DamiJSON
Generan JSONs ficticios para probar extracción y depuración sin depender de proveedores reales
Útiles para desarrollar y depurar lógicas de ingestión y pruebas unitarias
APIs comerciales, limitaciones y proveedores de datos (00:50:24)
Ejemplos de APIs de mercado (p. ej. datos de metales)
Proveedores ofrecen datos especializados con planes y precios por acceso; autenticación por API keys
Limitaciones técnicas y de uso
Rate limiting en servicios gratuitos y costos en APIs comerciales; necesidad de leer documentación para endpoints y cuotas


Exploración y preparación de datos (01:16:25)
Principios de limpieza y exploración (01:16:31)
Importancia de preparar datos grandes: Big Data requiere depuración antes del análisis
Principio de calidad y principio de contexto: conocer origen y significado de variables antes de tomar decisiones de limpieza
Técnicas de exploración inicial
Estadística básica: medias, medianas, desviación estándar; visualizaciones: histogramas, boxplots, scatter plots
Identificar dos fuentes típicas de error: valores faltantes (NA) y valores atípicos (outliers)
Imputación y manejo de valores faltantes (01:18:09)
Valores faltantes: NA, Not Available o formatos heterogéneos en datasets
Opciones: eliminar filas con NA (dropna), reemplazar por media/mediana/moda (imputación) o valores específicos según contexto
Riesgos: imputar altera datos reales; decidir por variable y contexto (p. ej. imputar solo en var1, eliminar si faltan en var2)
Valores atípicos y decisión de exclusión
Outliers pueden deberse a errores de medición o variabilidad real; se puede imputar, truncar o eliminar según justificación contextual
Ejemplos prácticos de imputación y limpieza en Colab (01:21:55)
Flujo para trabajar con imputation.csv en Colab
Subir archivo al entorno (pestaña Archivos → arrastrar), importar con pd.read_csv('content/imputation.csv') y visualizar
Operaciones básicas con Pandas
dropna() para eliminar filas con NA y ver reducción de muestras
fillna(valor) para reemplazar NA (ej.: 100 en demo), con aplicación selectiva por columna usando df['var1'].fillna()
drop_duplicates() para eliminar filas duplicadas según todas las columnas o subset (ej.: eliminar respuestas repetidas en encuestas por DNI o email)
Manejo de warnings y versiones
Revisar FutureWarning y compatibilidades de funciones; validar que las operaciones hayan ejecutado el efecto esperado tras cada cambio

Trabajo con datasets grandes: Kaggle y ejemplo práctico (01:35:55)

- Descarga e importación de datasets (01:35:55)
  - Uso de Kaggle para obtener datasets grandes
    - Descargar dataset como ZIP desde la página (botón Download dataset), suscribirse si es necesario y subir el CSV al entorno de Colab
    - Ejemplo: cpsdata.csv (~15 MB) con encuestas de demografía y empleo en Estados Unidos (2013)
  - Carga en Pandas y primeras inspecciones
    - pd.read_csv() a DataFrame; usar df.shape, len(df) y df.describe() para resumen de filas, columnas y estadísticas
    - Evitar imprimir todo el DataFrame grande: usar head(), tail() y resúmenes
- Exploración del dataset CPS (01:43:00)
  - Contenido y columnas relevantes
    - Variables: región, estado, código metropolitano, edad, estado civil, sexo, educación, raza, etnicidad (hispanic), país de nacimiento, ciudadanía, estatus de empleo e industria
    - Notas: industria disponible solo si el entrevistado está empleado; por ello habrá vacíos en empleo/desempleo
  - Filtrado y conteo por industria
    - Eliminar NA en columna industria para análisis de sectores (dropna subset sobre industria)
    - Calcular LEN del subset filtrado y counts por industria para identificar sectores más comunes (servicios educacionales y de salud, comercio, manufactura, construcción, finanzas, transporte, agricultura, etc.)
- Planteamiento de hipótesis y análisis orientado (01:54:31)
  - Definir hipótesis antes de analizar (p. ej. qué industrias emplean más a hispanos)
    - Pasos: obtener población general por industria, filtrar por hispanidad y comparar proporciones para detectar sobrerrepresentación
    - Interpretación: distinguir entre preferencia y necesidad; contextualizar con demografía y factores socioeconómicos
  - Uso del Big Data para validar intuiciones
    - Evitar conclusiones por observación anecdótica; respaldar decisiones con datos y métricas (nulo sin verba: datos que soporten afirmaciones)

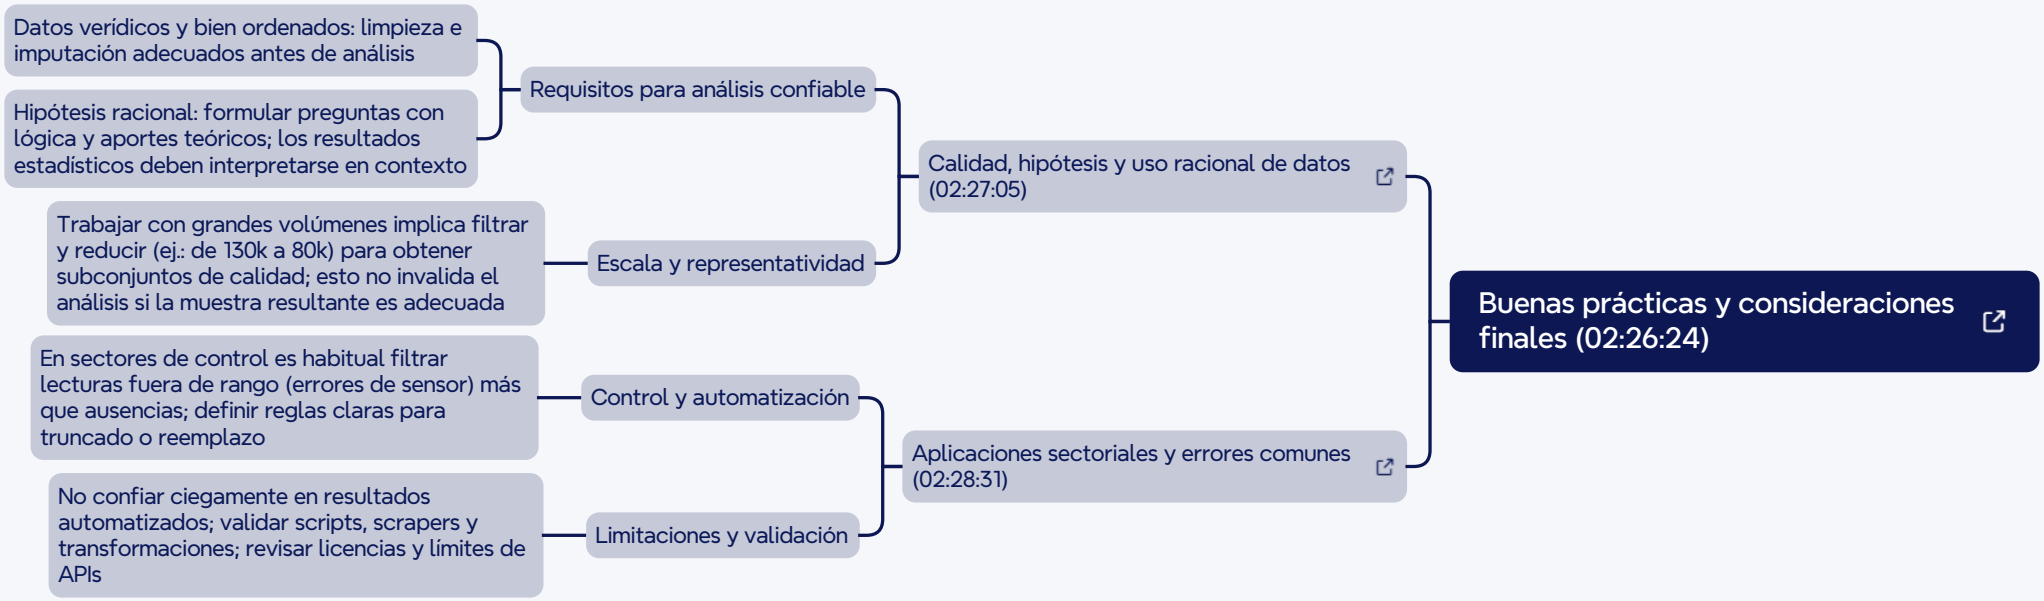

Otras fuentes y herramientas de apoyo (01:57:30)
Repositorios y buscadores de datos (01:57:30)
Fuentes adicionales
World Bank, OECD, Statista, Data Research, Our World in Data, Arboard/Data Mining agregadores y buscadores especializados
Cada plataforma tiene ventajas (visualizaciones, descargas en PDF/Excel/PNG/PPT, APIs o datos abiertos)
Estrategia de búsqueda
Usar Google y ChatGPT como asistentes para encontrar APIs o generar código de extracción; siempre revisar y validar resultados generados automáticamente
Herramientas complementarias y recomendaciones (01:58:15)
ChatGPT y asistentes: generar ejemplos de código, explicar APIs y proponer pipelines
Usar con precaución: revisar y validar código; ChatGPT no reemplaza juicio humano ni verificación de resultados
Considerar suscripciones (p. ej. ChatGPT Plus/4o) para mayor capacidad, pero evaluar coste-beneficio
Herramientas y plataformas emergentes
Code editors avanzados, integraciones con colabs y mejoras en ecosistema que facilitan trabajo con datos grandes; explorarlas en tiempo libre

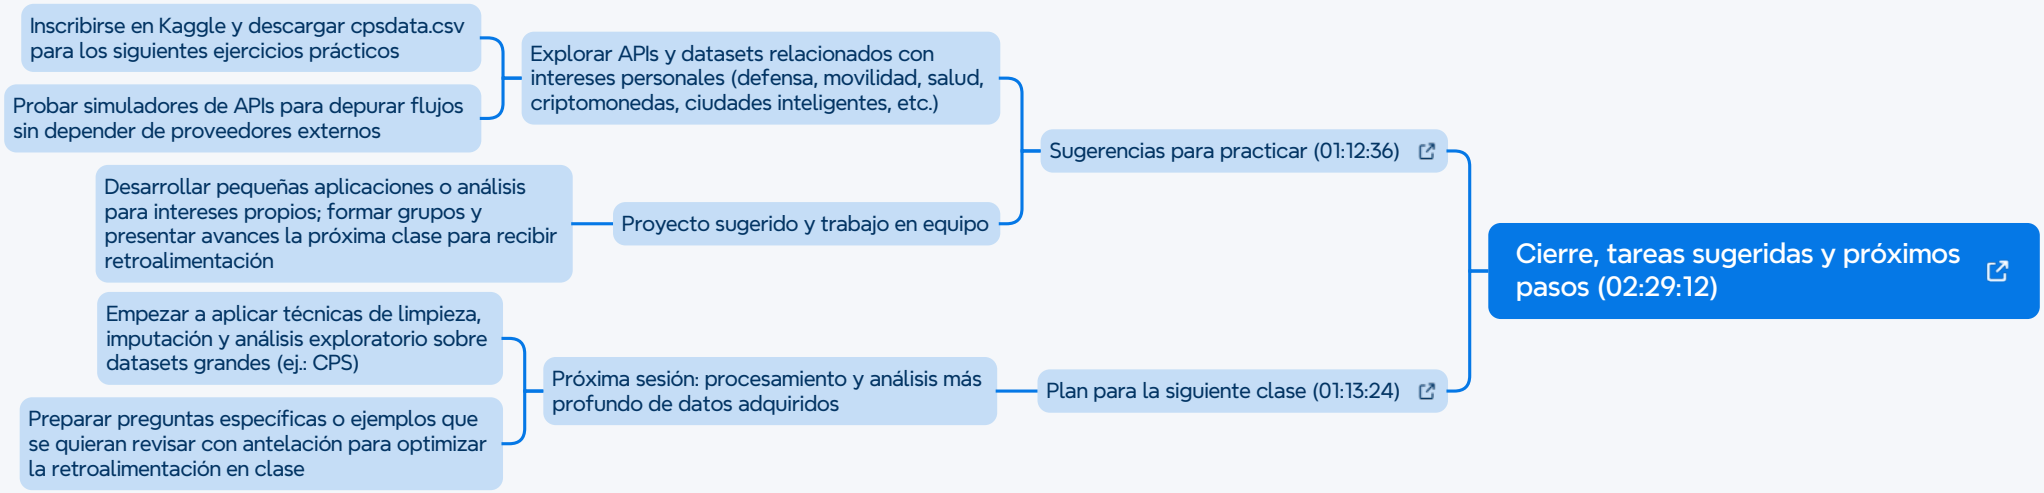
Recursos locales, GIS y bancos de datos nacionales (02:00:05)

- Bases de datos especializados y académico-industrias (02:00:05)
  - Repositorios académicos y profesionales
    - IEEE dataport: colecciones como imágenes de rayos X de pecho útiles para entrenar modelos de visión por computador; posible acceso restringido o pago
    - GitHub y repositorios públicos con scrapers o APIs para datos específicos (ej.: códigos de viaje, microdatos)
  - Uso y limitaciones de fuentes académicas
    - Muchos recursos son valiosos para IA y entrenamiento de modelos, pero revisar licencias y costos de acceso
- Datos gubernamentales y GIS (02:01:59)
  - Portales estatales y sistemas GIS
    - INEI y Visor Geo Perú: datos de centros poblados, encuestas sobre pobreza, infraestructura, programas sociales y proyectos de inversión pública
    - Mapas sectoriales (Minem, sistemas eléctricos) con información geoespacial que puede requerir web scraping avanzado o interacción con APIs específicas
  - Dificultad de extracción y herramientas necesarias
    - Web scraping de GIS suele requerir conocimientos de JavaScript, manejo de APIs geoespaciales y/o uso de herramientas de automatización; puede ayudar la IA para generar scripts
    - Algunos visores permiten exportar datos, otros requieren extracción personalizada
- Sectores con datos abiertos relevantes (02:03:43)
  - Energía y sistema interconectado (ESEIN/COES)
    - Datos en tiempo real o casi real sobre generación por centrales, líneas de transmisión, estado de la red, mix renovable vs térmico
    - Aplicaciones: monitoreo de generación, análisis de integración de renovables, evaluación de proyectos de interconexión
  - Bancos de inversión y proyectos públicos
    - Portales con información sobre proyectos de inversión pública y consultas avanzadas útiles para análisis de impacto y planificación

Caso práctico con Orange: importación, filtrado e imputación (02:08:39)

- Apertura e importación del CPS en Orange (02:13:32)
  - Carga del CSV en Orange
    - Importar cpsdata.csv mediante File → Import → CSV; Orange muestra la tabla con todos los registros (ej.: 131.302 instancias, 32k+ registros por segmento)
    - Ver la tabla con Data Table para inspección inicial sin cargar todo en código
  - Selección de columnas relevantes
    - Seleccionar columnas industry e hispanic para el análisis comparativo y arrastrarlas a Features en Orange
- Filtrado de la población objetivo y manejo de NA (02:18:31)
  - Filtrar hispanos y remover no hispanos
    - Usar Select Rows con condición hispanic == 1 para quedarse solo con individuos hispanos
    - Comprobar salida en Data Table para asegurar que solo queden instancias con hispanic = 1
  - Manejar registros sin información de industria
    - Filtrar o usar Select Rows con condición "is one of" para conservar solo categorías de industria válidas
    - Alternativa: usar Impute → remover instancias con valores desconocidos para eliminar filas con industria ausente
    - Verificación de conteos después del filtrado (ej.: 8.177 instancias tras eliminar missing en industria)
- Visualización y comparación de distribuciones (02:23:25)
  - Distribución por industria de hispanos
    - Usar widget Distribution en Orange para ver proporciones por industria entre hispanos: educación, ocio y recreo, comercio, gestión y profesionales, construcción, manufactura, etc.
    - Observación preliminar: educación y comercio aparecen con representación notable; manufactura y otros sectores pueden ser menores
  - Comparación con población general
    - Repetir el proceso para la población general (sin filtrar hispanic) y comparar proporciones por industria
    - Interpretación requiere estadísticas y contextualización demográfica para evitar conclusiones sesgadas


Buenas prácticas y consideraciones finales (02:26:24)
Calidad, hipótesis y uso racional de datos (02:27:05)
Requisitos para análisis confiable
Datos verídicos y bien ordenados: limpieza e imputación adecuados antes de análisis
Hipótesis racional: formular preguntas con lógica y aportes teóricos; los resultados estadísticos deben interpretarse en contexto
Escala y representatividad
Trabajar con grandes volúmenes implica filtrar y reducir (ej.: de 130k a 80k) para obtener subconjuntos de calidad; esto no invalida el análisis si la muestra resultante es adecuada
Aplicaciones sectoriales y errores comunes (02:28:31)
Control y automatización
En sectores de control es habitual filtrar lecturas fuera de rango (errores de sensor) más que ausencias; definir reglas claras para truncado o reemplazo
Limitaciones y validación
No confiar ciegamente en resultados automatizados; validar scripts, scrapers y transformaciones; revisar licencias y límites de APIs


Cierre, tareas sugeridas y próximos pasos (02:29:12)
Sugerencias para practicar (01:12:36)
Explorar APIs y datasets relacionados con intereses personales (defensa, movilidad, salud, criptomonedas, ciudades inteligentes, etc.)
Inscribirse en Kaggle y descargar cpsdata.csv para los siguientes ejercicios prácticos
Probar simuladores de APIs para depurar flujos sin depender de proveedores externos
Proyecto sugerido y trabajo en equipo
Desarrollar pequeñas aplicaciones o análisis para intereses propios; formar grupos y presentar avances la próxima clase para recibir retroalimentación
Plan para la siguiente clase (01:13:24)
Próxima sesión: procesamiento y análisis más profundo de datos adquiridos
Empezar a aplicar técnicas de limpieza, imputación y análisis exploratorio sobre datasets grandes (ej.: CPS)
Preparar preguntas específicas o ejemplos que se quieran revisar con antelación para optimizar la retroalimentación en clase