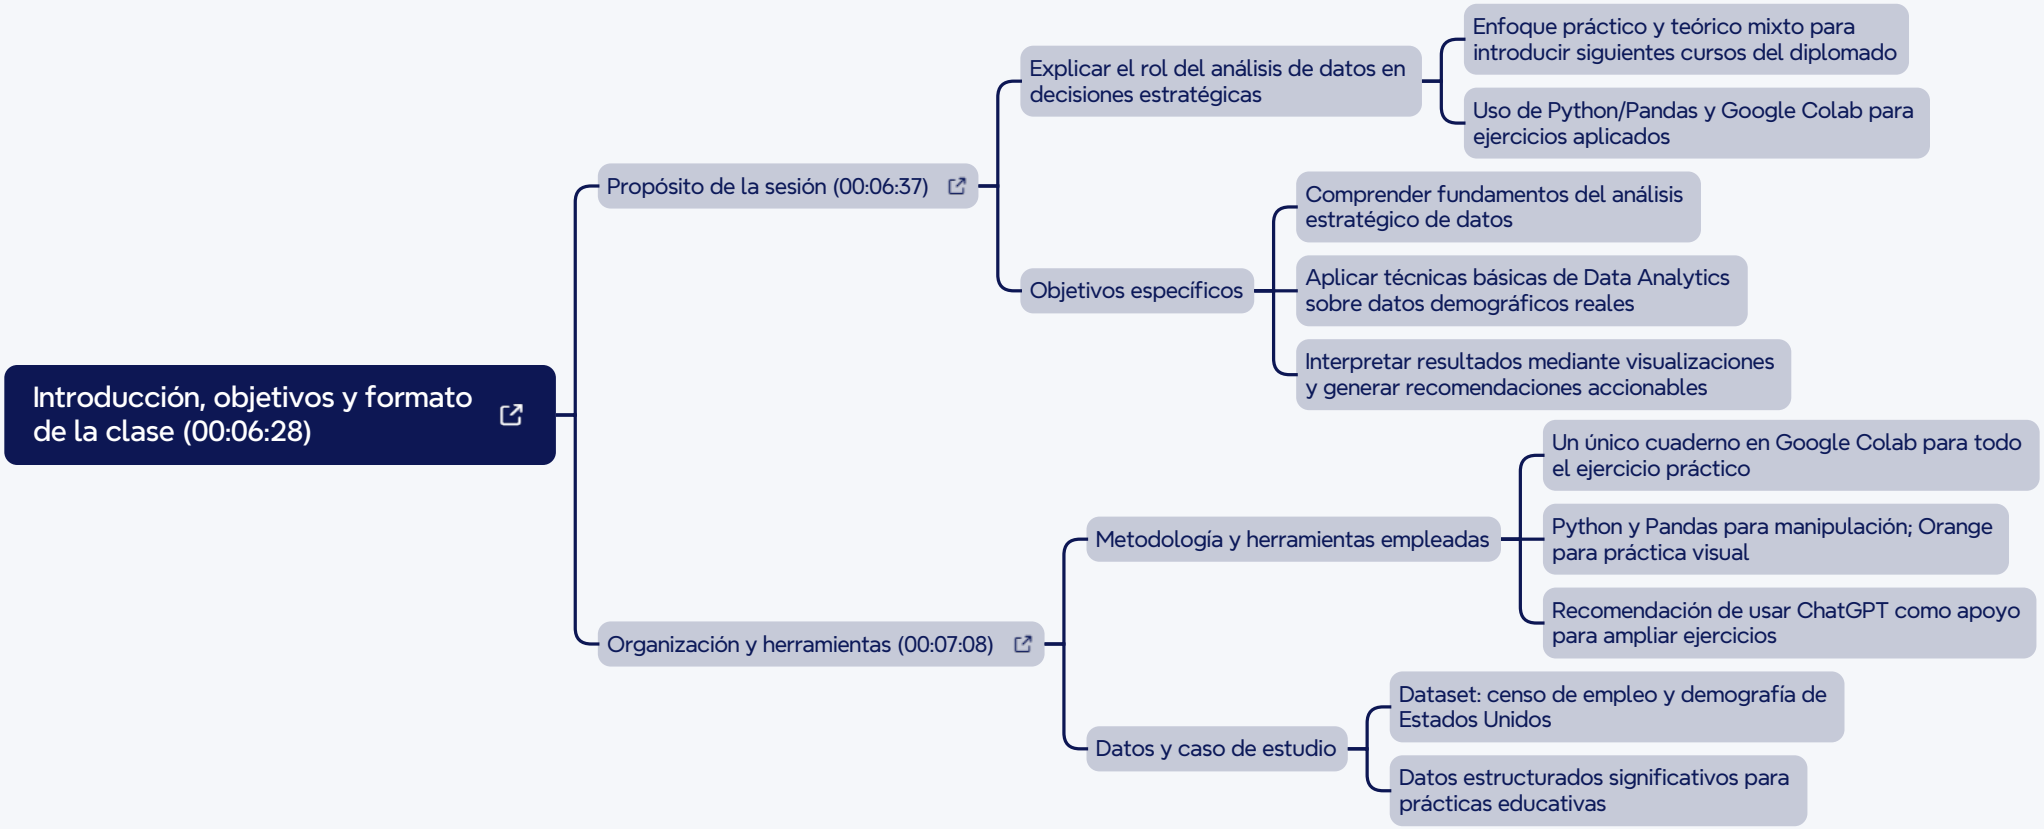
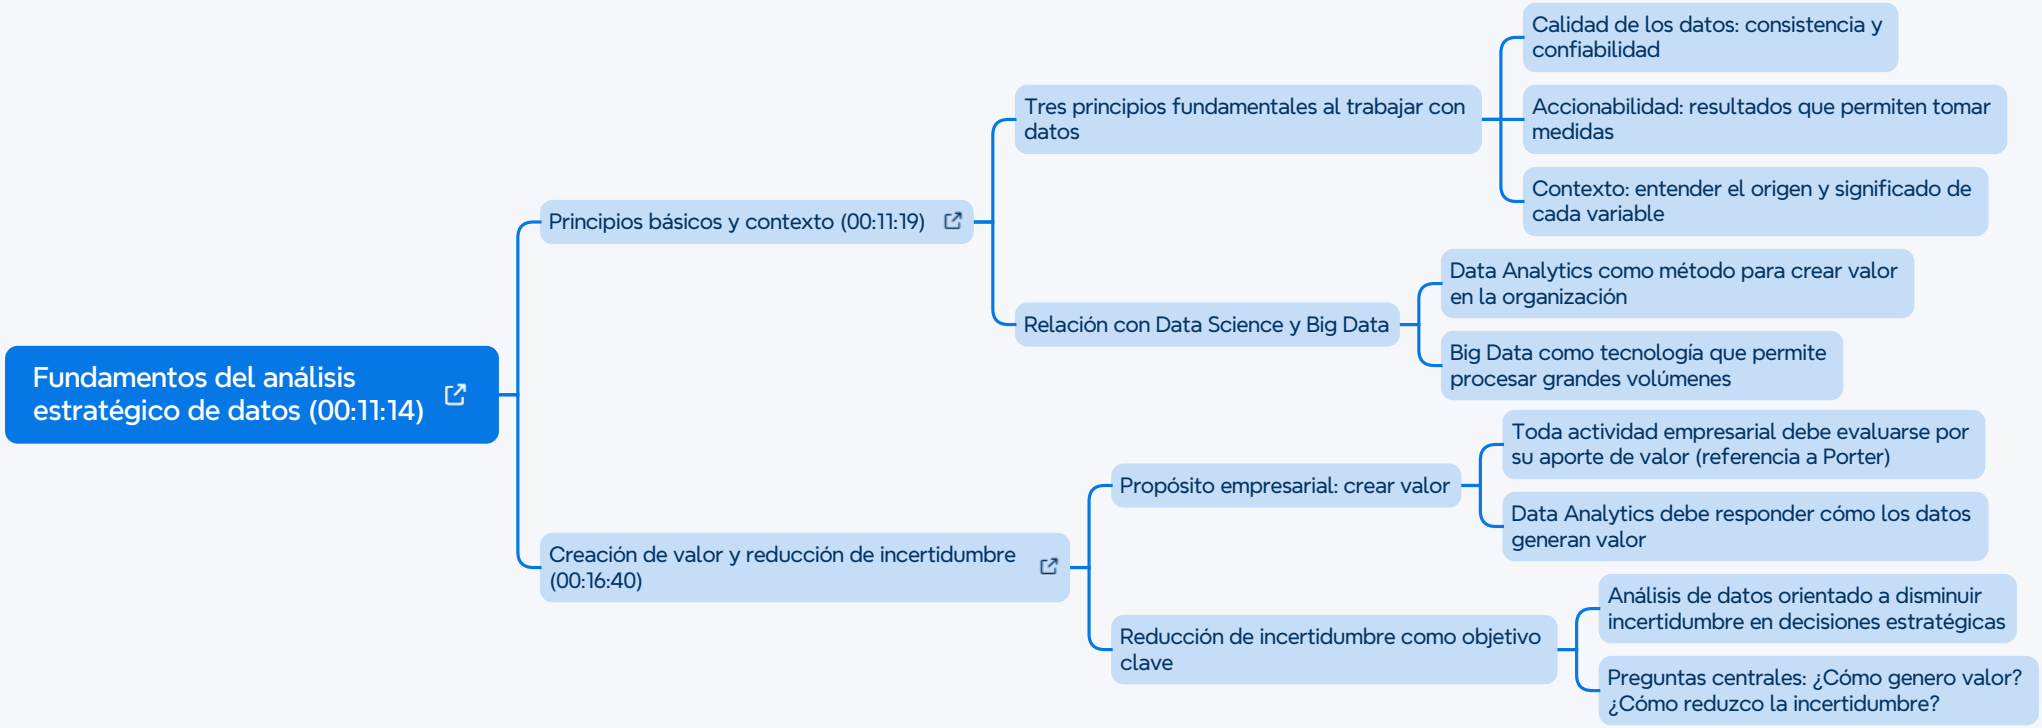
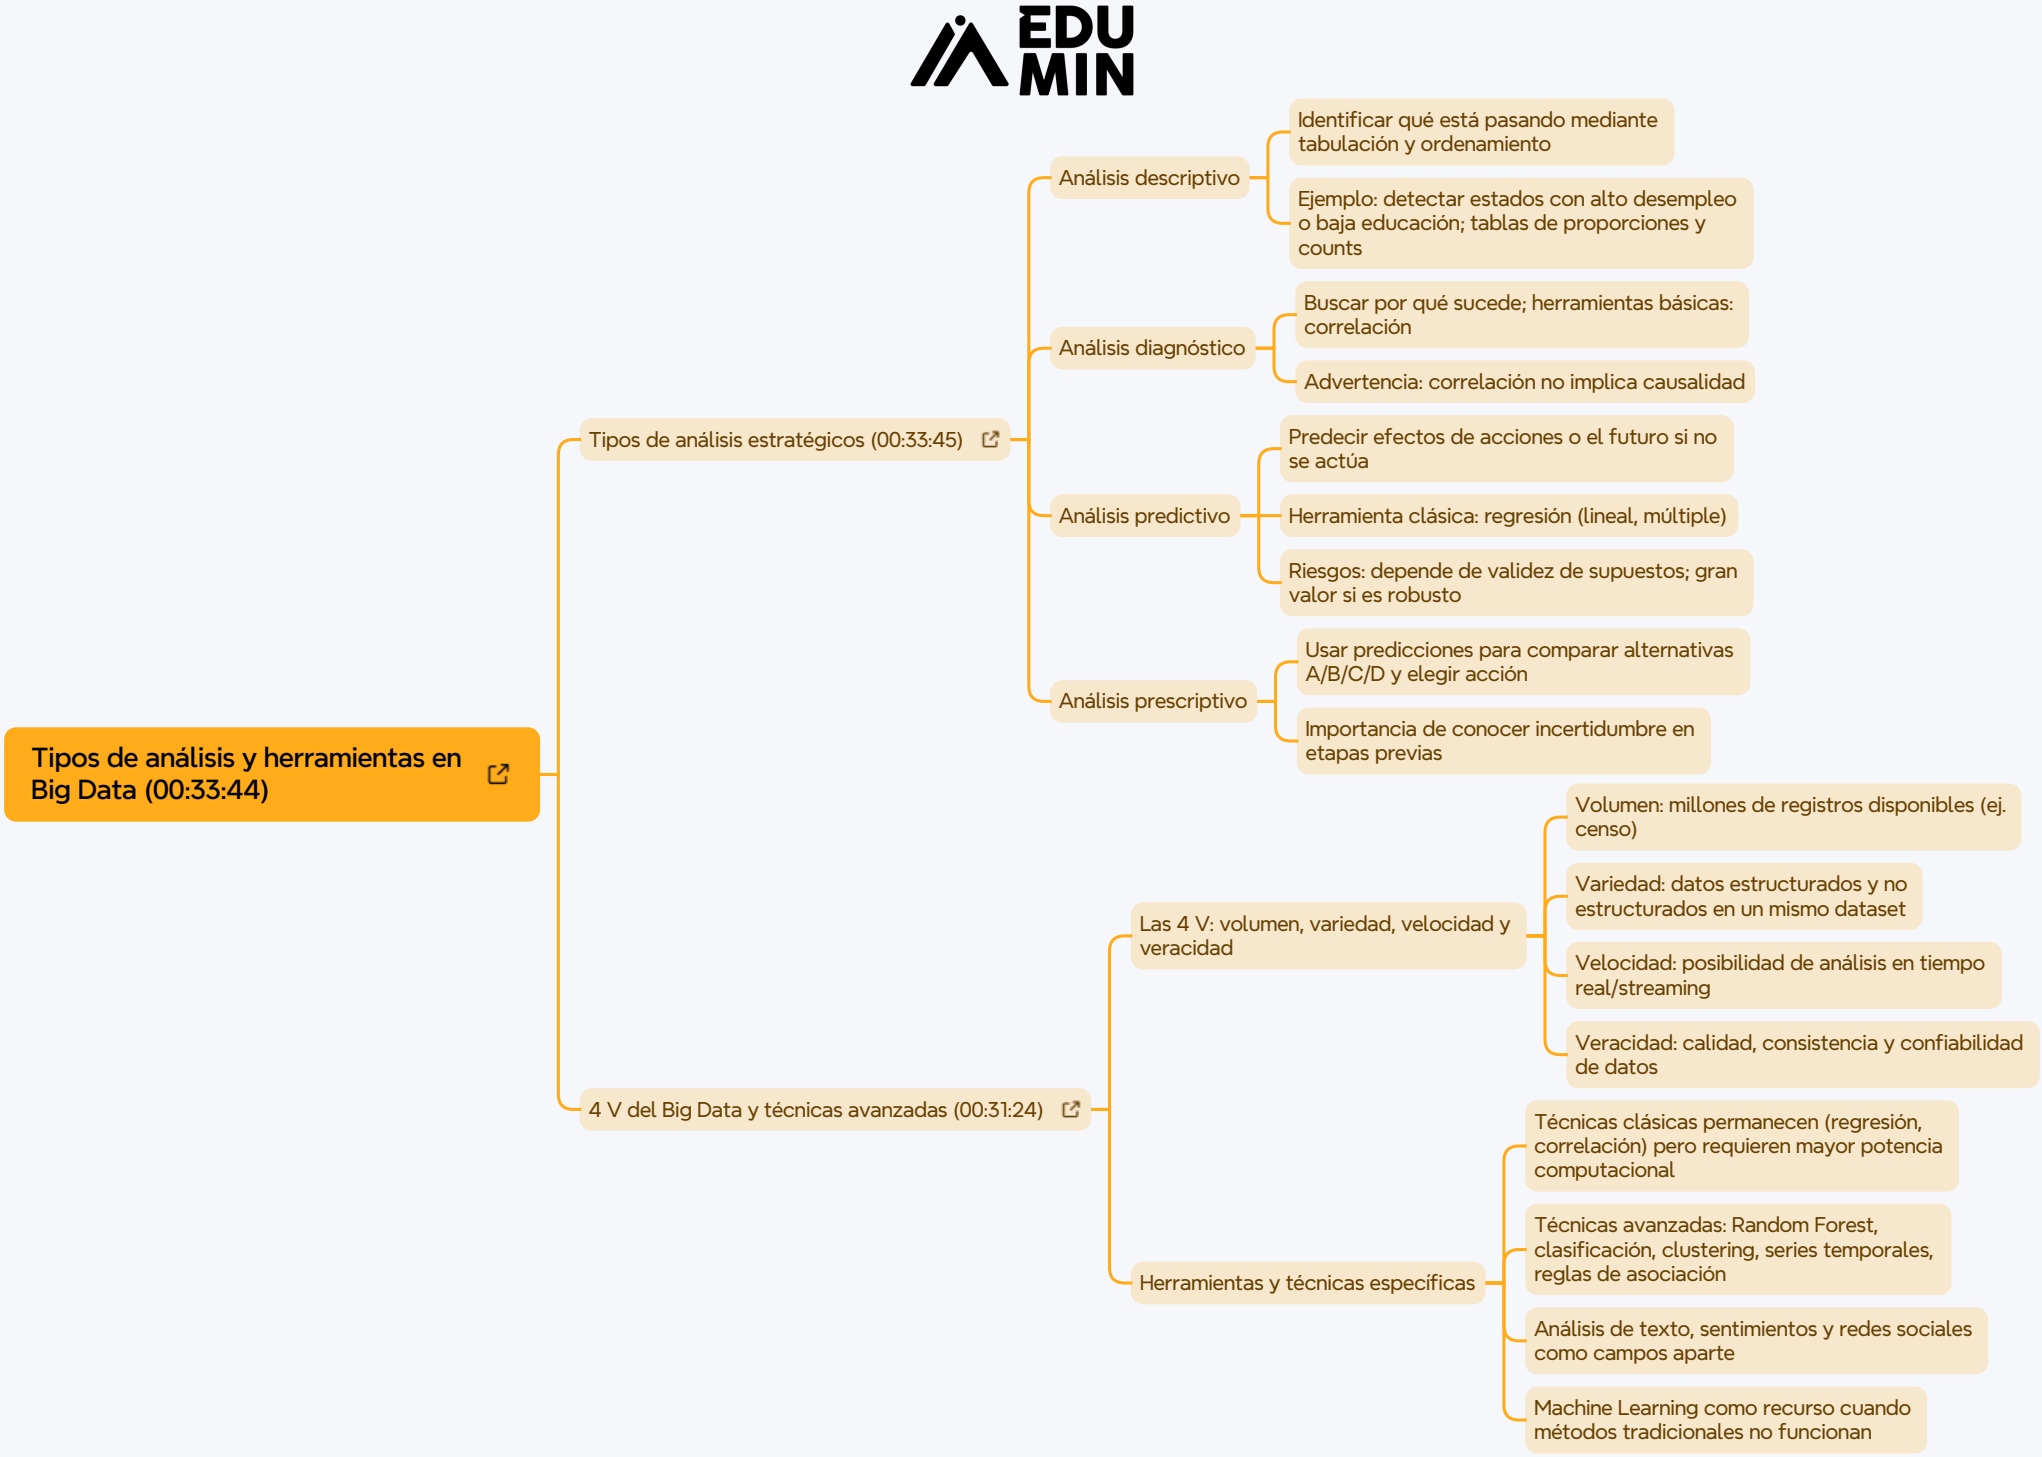
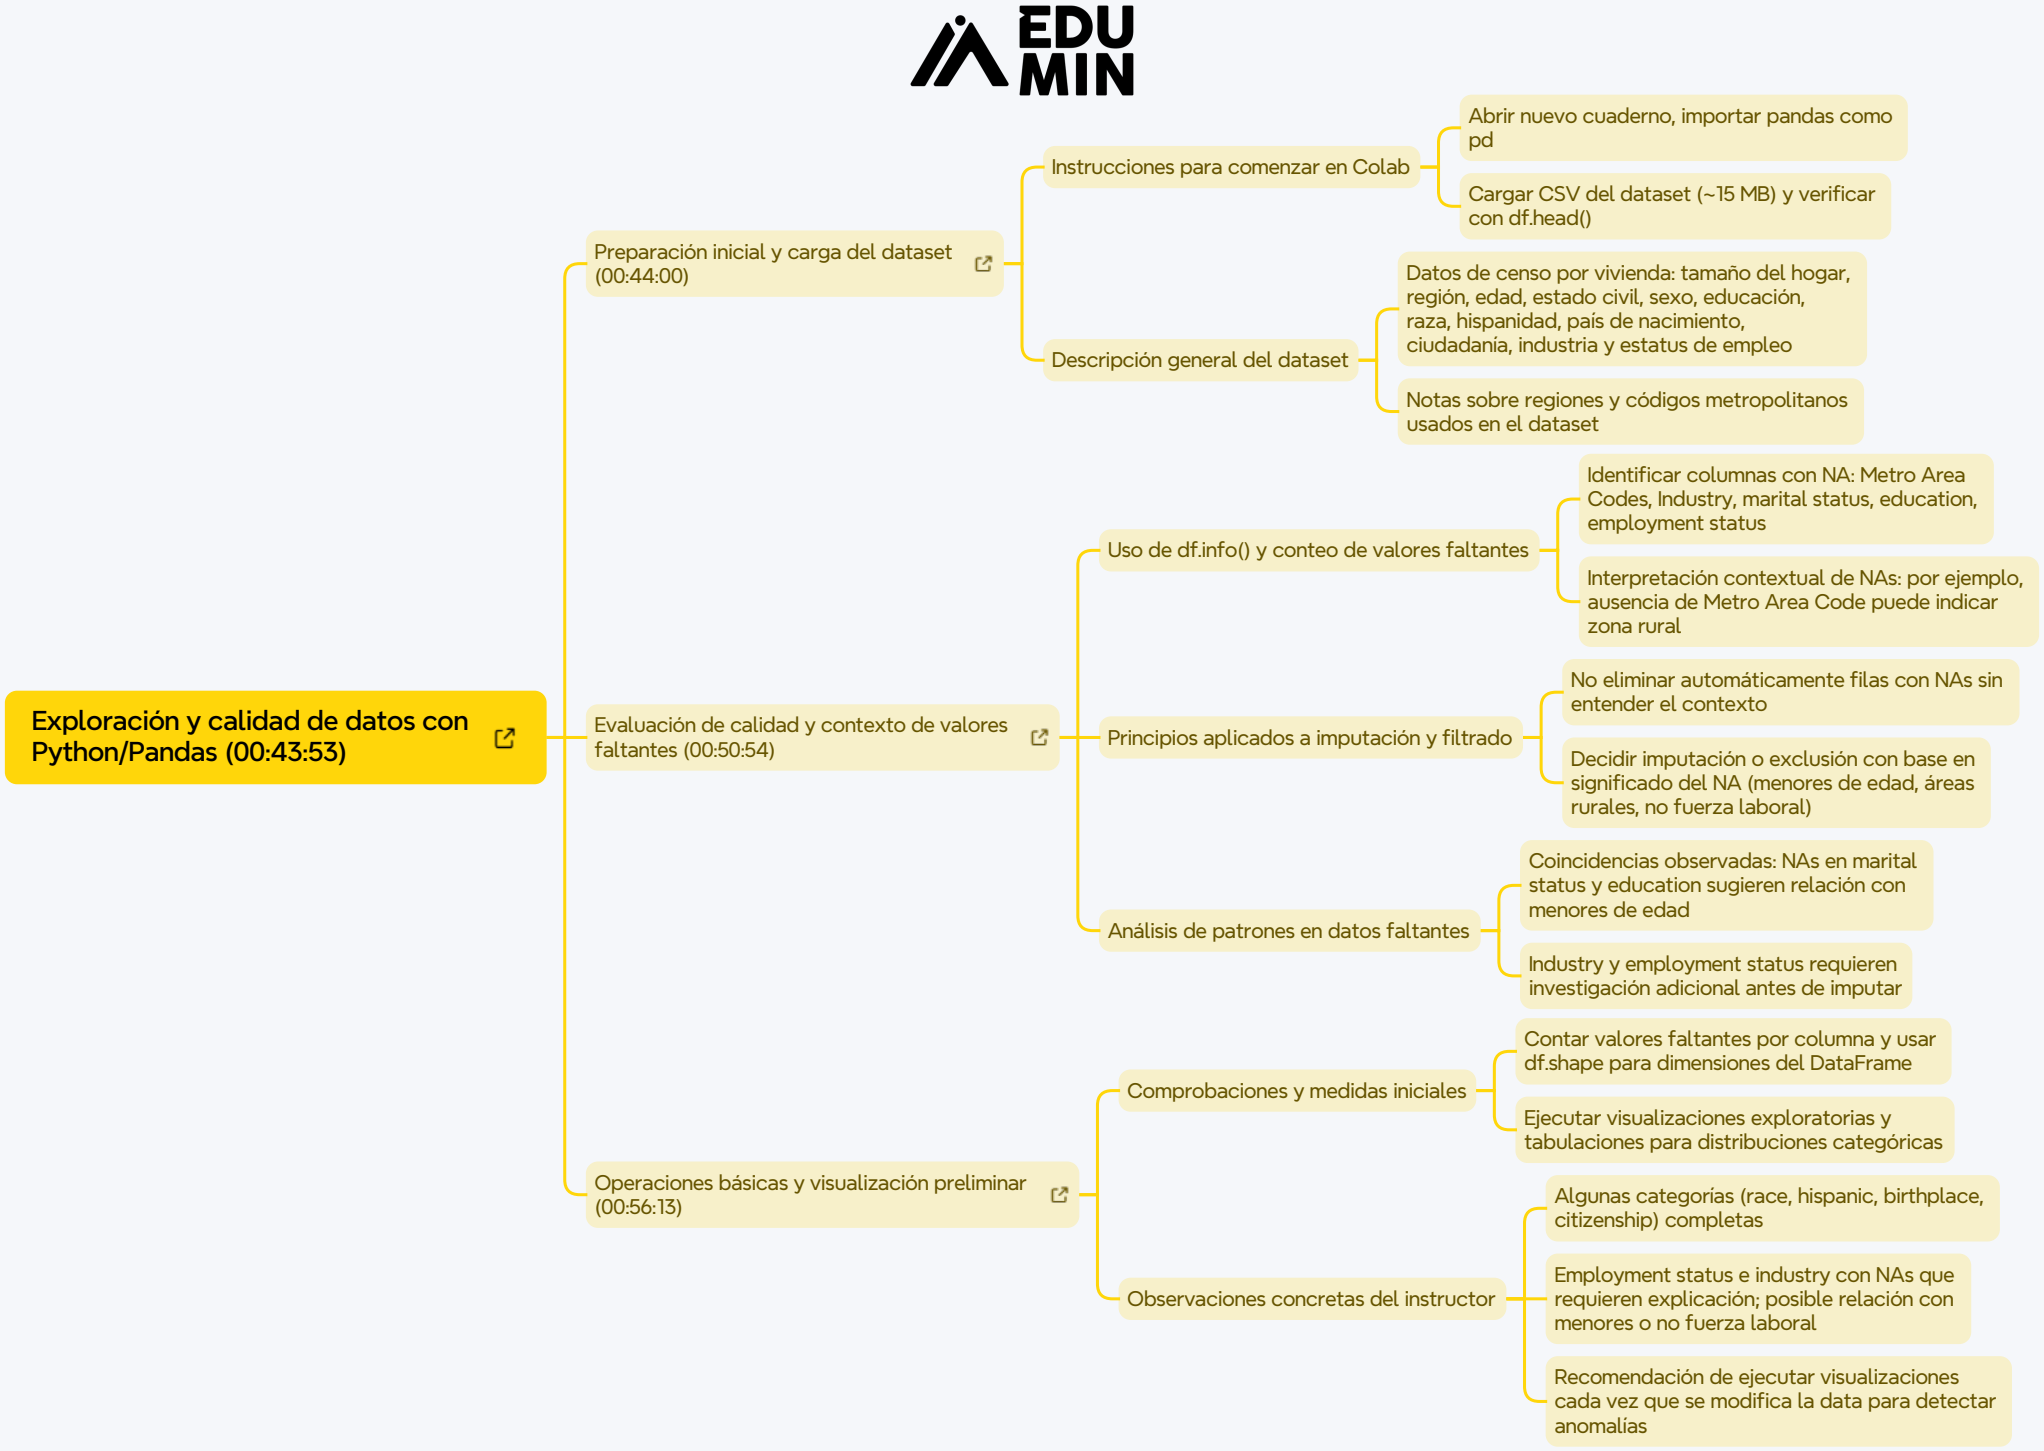
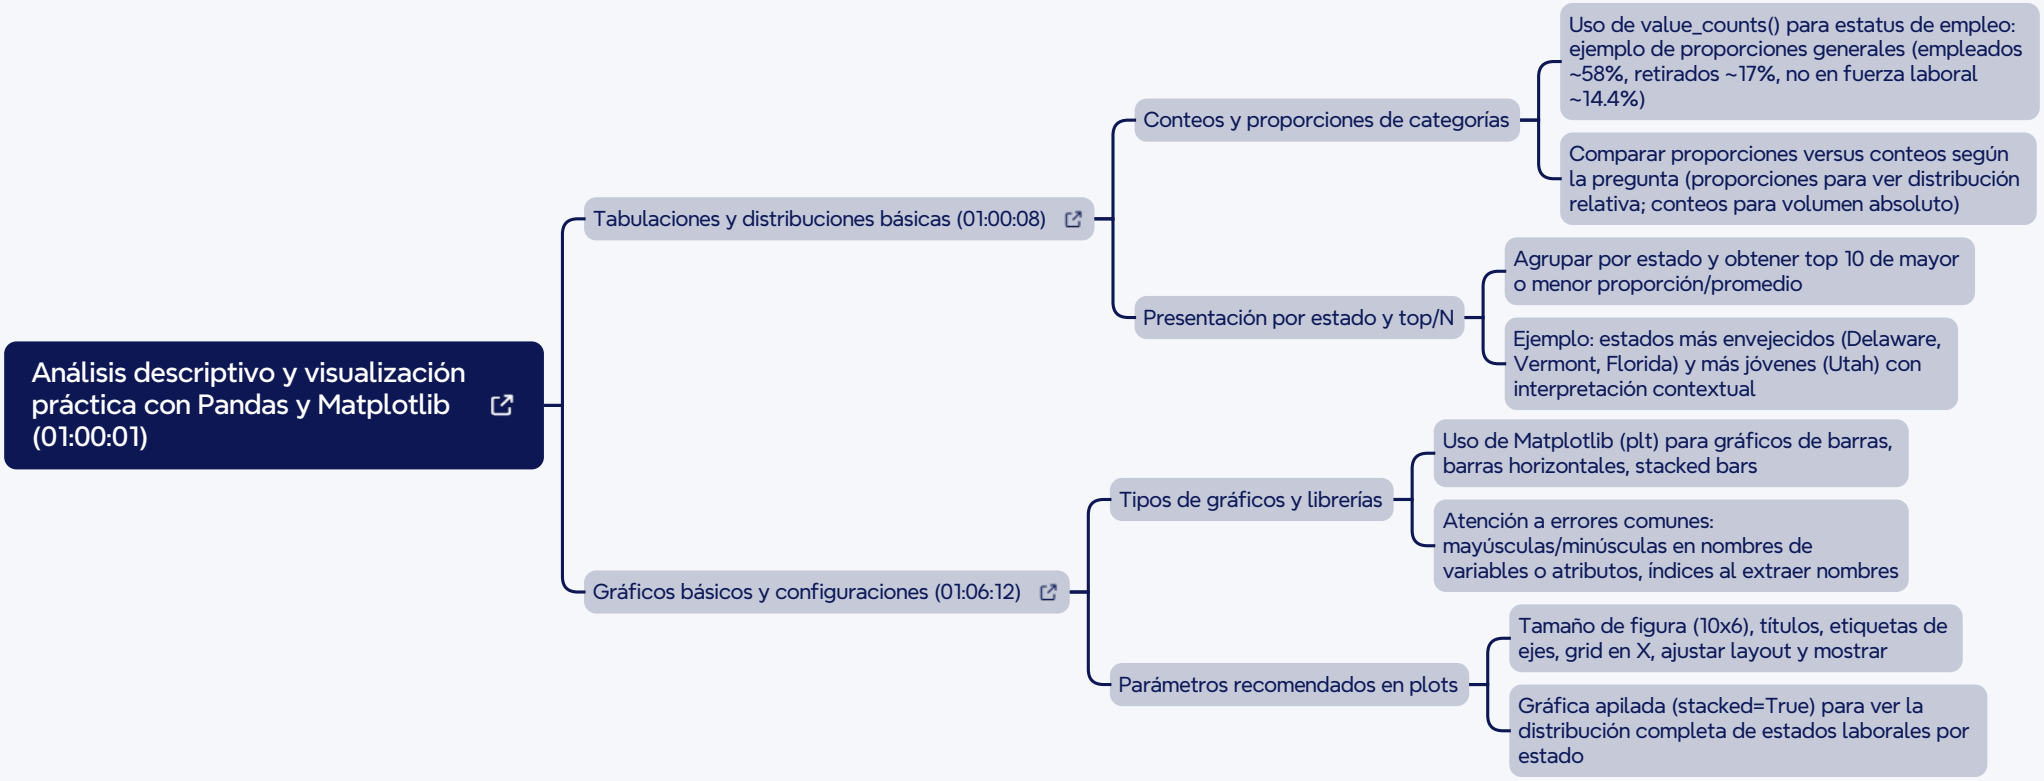

EDU MIN
CLASE 06: ANÁLISIS DE DATOS PARA LA TOMA DE DECISIONES ESTRATÉGICAS - 2DA PARTE
Introducción, objetivos y formato de la clase (00:06:28)
Fundamentos del análisis estratégico de datos (00:11:14)
Tipos de análisis y herramientas en Big Data (00:33:44)
Exploración y calidad de datos con Python/Pandas (00:43:53)
Análisis descriptivo y visualización práctica con Pandas y Matplotlib (01:00:01)
Cruces, mapeo de variables y análisis comparativo (01:13:47)
Exploración adicional: industria, ciudadanía y raza/etnicidad (01:26:46)
Cierre de la clase y logística final (02:14:44)
Procesos, tecnologías y recomendaciones finales (02:20:02)
Recolección automática, almacenamiento y tecnologías para producción (02:19:59)
Uso de Metro Area Code y decisiones comerciales basadas en ruralidad (02:04:21)
Aplicaciones prácticas: investigar valores faltantes y validar supuestos (01:56:45)
Proceso ordenado de análisis para la toma de decisiones (01:54:56)
De patrones a hallazgos y recomendaciones estratégicas (01:43:44)

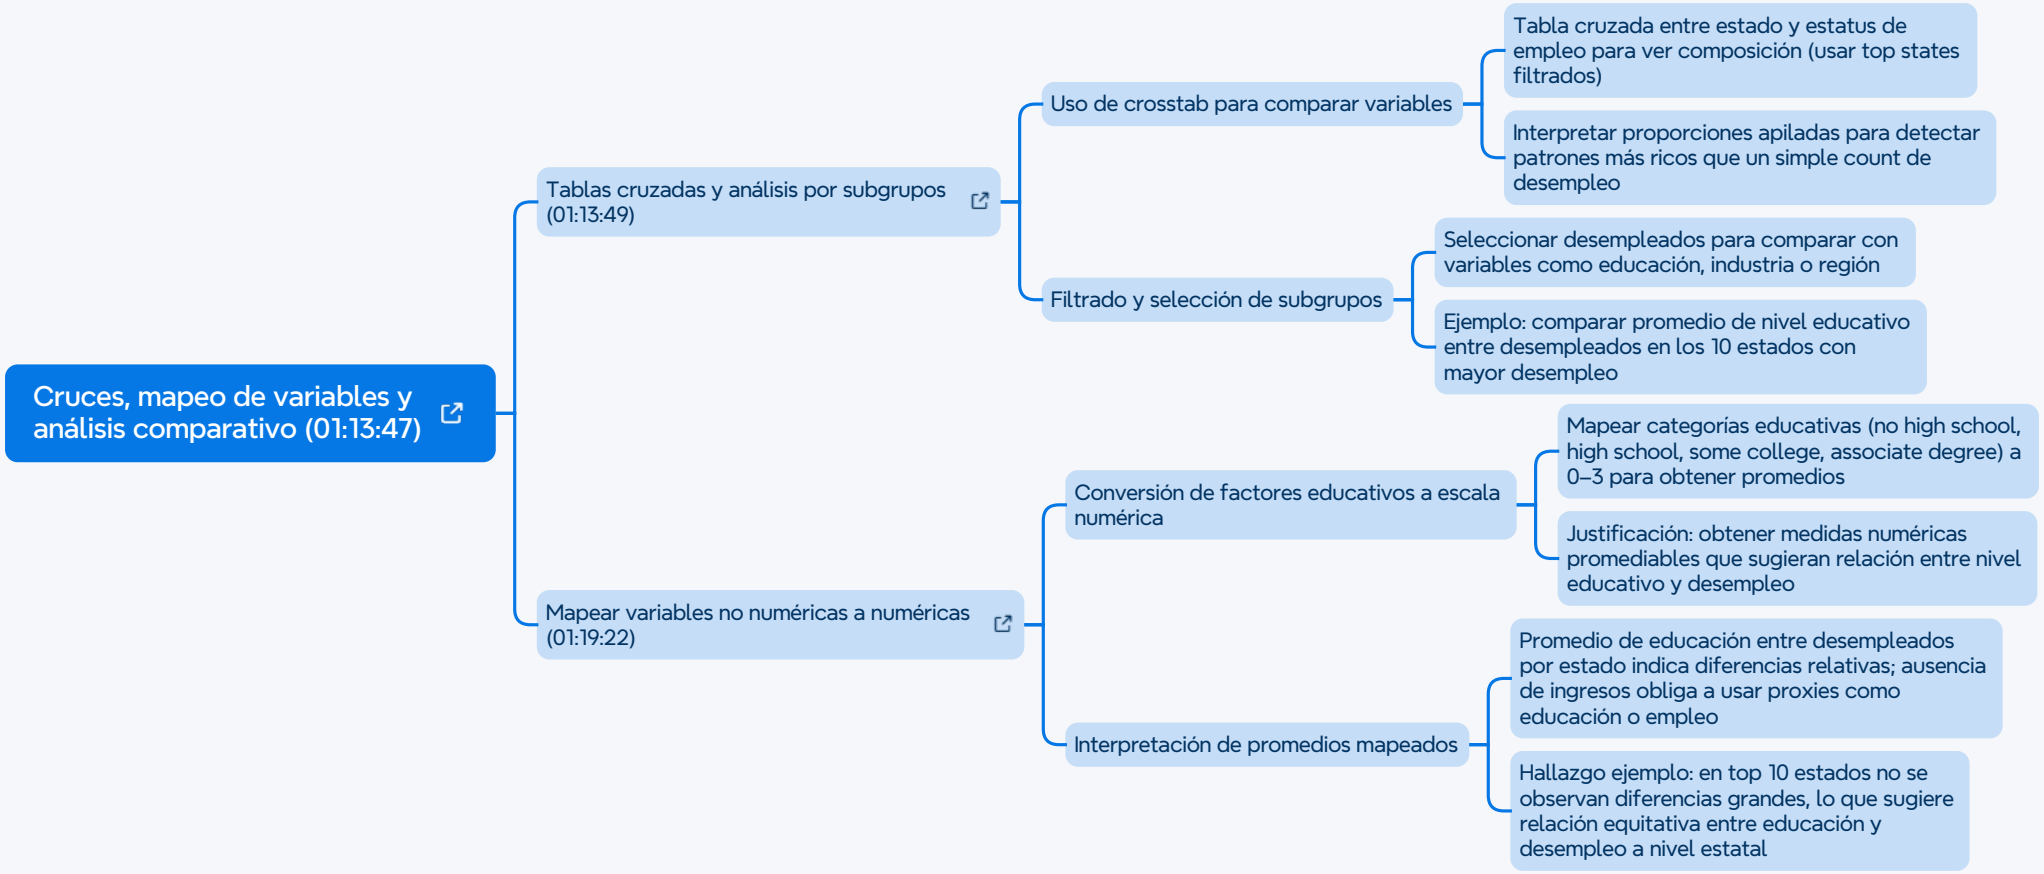

Introducción, objetivos y formato de la clase (00:06:28)
Propósito de la sesión (00:06:37)
Explicar el rol del análisis de datos en decisiones estratégicas
Enfoque práctico y teórico mixto para introducir siguientes cursos del diplomado
Uso de Python/Pandas y Google Colab para ejercicios aplicados
Objetivos específicos
Comprender fundamentos del análisis estratégico de datos
Aplicar técnicas básicas de Data Analytics sobre datos demográficos reales
Interpretar resultados mediante visualizaciones y generar recomendaciones accionables
Organización y herramientas (00:07:08)
Metodología y herramientas empleadas
Un único cuaderno en Google Colab para todo el ejercicio práctico
Python y Pandas para manipulación; Orange para práctica visual
Recomendación de usar ChatGPT como apoyo para ampliar ejercicios
Datos y caso de estudio
Dataset: censo de empleo y demografía de Estados Unidos
Datos estructurados significativos para prácticas educativas

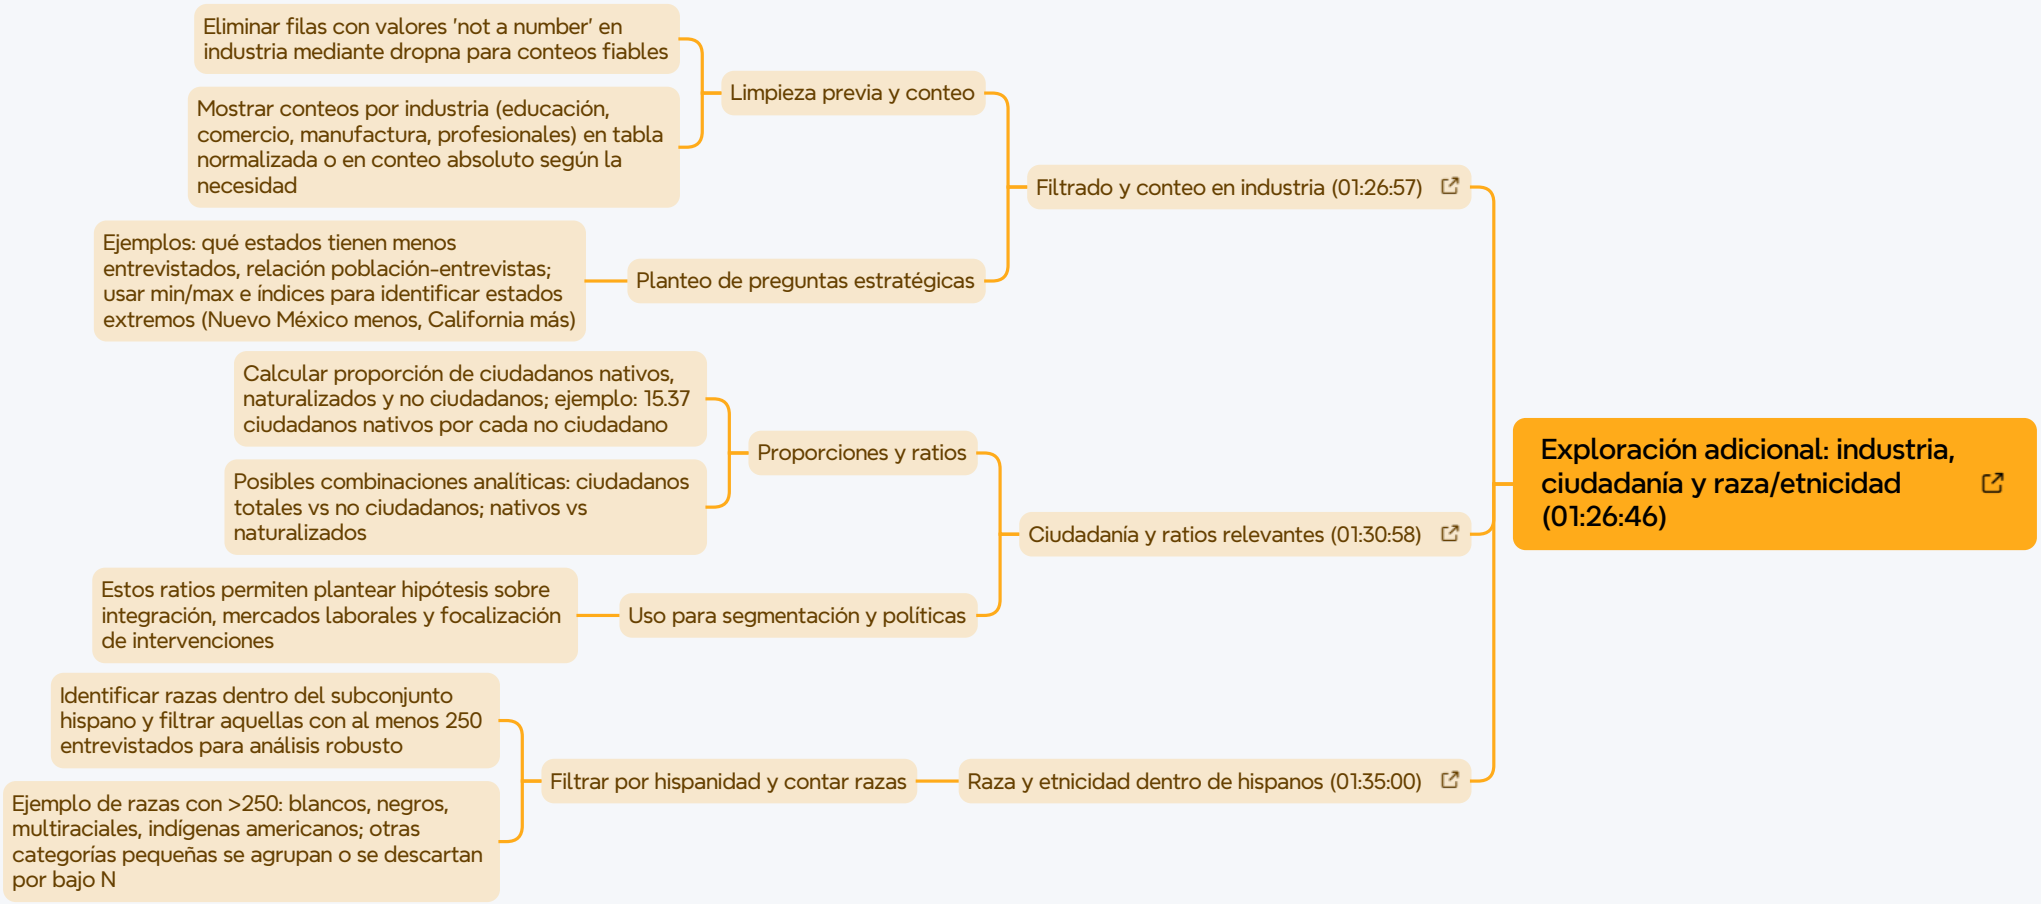

Fundamentos del análisis estratégico de datos (00:11:14)
Principios básicos y contexto (00:11:19)
Tres principios fundamentales al trabajar con datos
Calidad de los datos: consistencia y confiabilidad
Accionabilidad: resultados que permiten tomar medidas
Contexto: entender el origen y significado de cada variable
Relación con Data Science y Big Data
Data Analytics como método para crear valor en la organización
Big Data como tecnología que permite procesar grandes volúmenes
Creación de valor y reducción de incertidumbre (00:16:40)
Propósito empresarial: crear valor
Toda actividad empresarial debe evaluarse por su aporte de valor (referencia a Porter)
Data Analytics debe responder cómo los datos generan valor
Reducción de incertidumbre como objetivo clave
Análisis de datos orientado a disminuir incertidumbre en decisiones estratégicas
Preguntas centrales: ¿Cómo genero valor? ¿Cómo reduzco la incertidumbre?

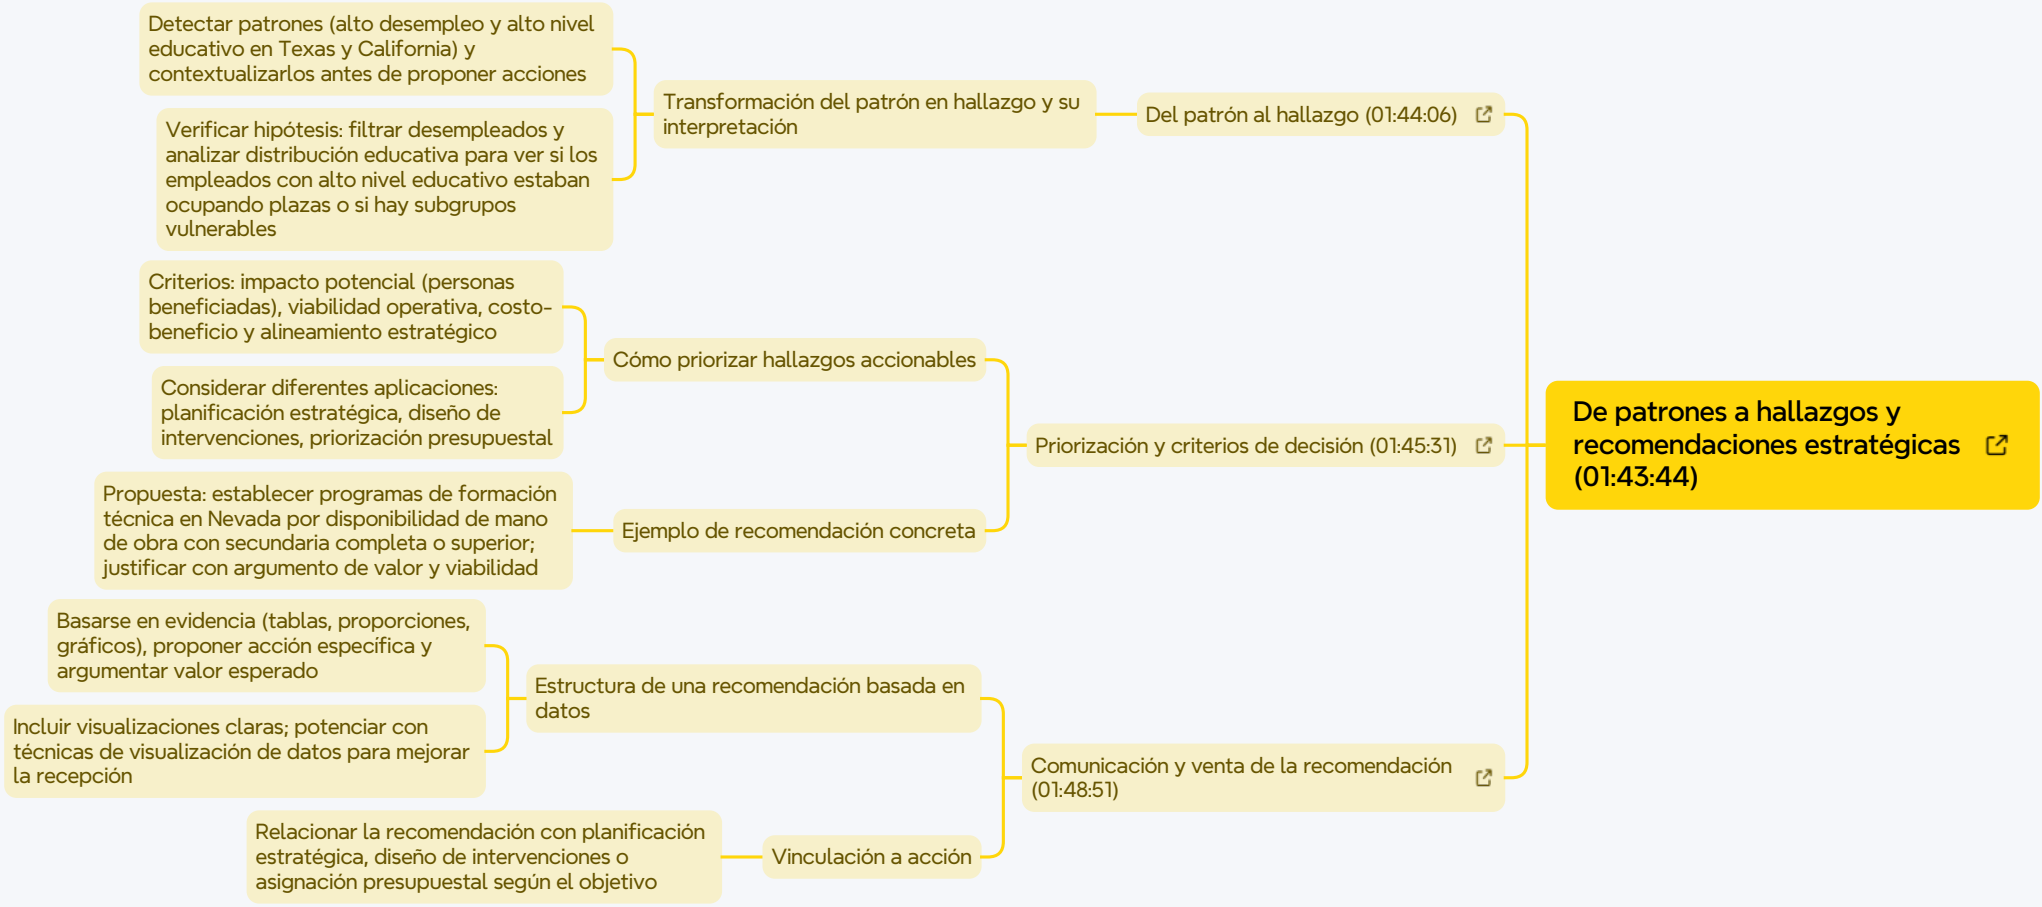

Tipos de análisis y herramientas en Big Data (00:33:44)
Tipos de análisis estratégicos (00:33:45)
Análisis descriptivo
Identificar qué está pasando mediante tabulación y ordenamiento
Ejemplo: detectar estados con alto desempleo o baja educación; tablas de proporciones y counts
Análisis diagnóstico
Buscar por qué sucede; herramientas básicas: correlación
Advertencia: correlación no implica causalidad
Análisis predictivo
Predecir efectos de acciones o el futuro si no se actúa
Herramienta clásica: regresión (lineal, múltiple)
Riesgos: depende de validez de supuestos; gran valor si es robusto
Análisis prescriptivo
Usar predicciones para comparar alternativas A/B/C/D y elegir acción
Importancia de conocer incertidumbre en etapas previas
4 V del Big Data y técnicas avanzadas (00:31:24)
Las 4 V: volumen, variedad, velocidad y veracidad
Volumen: millones de registros disponibles (ej. censo)
Variedad: datos estructurados y no estructurados en un mismo dataset
Velocidad: posibilidad de análisis en tiempo real/streaming
Veracidad: calidad, consistencia y confiabilidad de datos
Herramientas y técnicas específicas
Técnicas clásicas permanecen (regresión, correlación) pero requieren mayor potencia computacional
Técnicas avanzadas: Random Forest, clasificación, clustering, series temporales, reglas de asociación
Análisis de texto, sentimientos y redes sociales como campos aparte
Machine Learning como recurso cuando métodos tradicionales no funcionan

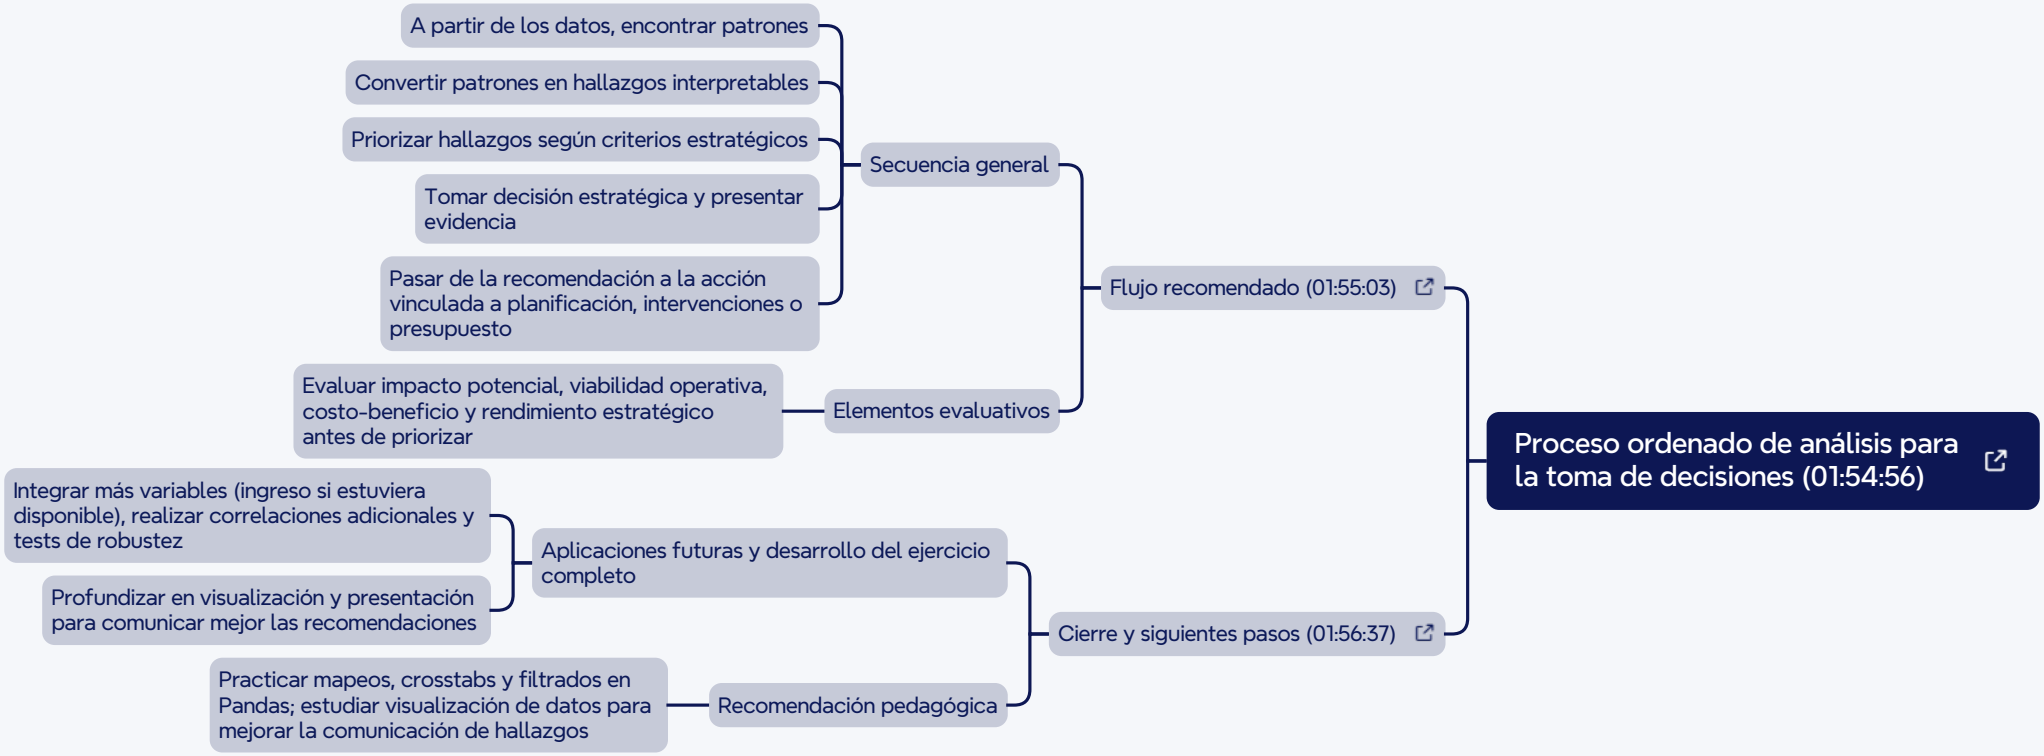

Exploración y calidad de datos con Python/Pandas (00:43:53)
Preparación inicial y carga del dataset (00:44:00)
Instrucciones para comenzar en Colab
Abrir nuevo cuaderno, importar pandas como pd
Cargar CSV del dataset (~15 MB) y verificar con df.head()
Descripción general del dataset
Datos de censo por vivienda: tamaño del hogar, región, edad, estado civil, sexo, educación, raza, hispanidad, país de nacimiento, ciudadanía, industria y estatus de empleo
Notas sobre regiones y códigos metropolitanos usados en el dataset
Evaluación de calidad y contexto de valores faltantes (00:50:54)
Uso de df.info() y conteo de valores faltantes
Identificar columnas con NA: Metro Area Codes, Industry, marital status, education, employment status
Interpretación contextual de NAs: por ejemplo, ausencia de Metro Area Code puede indicar zona rural
Principios aplicados a imputación y filtrado
No eliminar automáticamente filas con NAs sin entender el contexto
Decidir imputación o exclusión con base en significado del NA (menores de edad, áreas rurales, no fuerza laboral)
Análisis de patrones en datos faltantes
Coincidencias observadas: NAs en marital status y education sugieren relación con menores de edad
Industry y employment status requieren investigación adicional antes de imputar
Operaciones básicas y visualización preliminar (00:56:13)
Comprobaciones y medidas iniciales
Contar valores faltantes por columna y usar df.shape para dimensiones del DataFrame
Ejecutar visualizaciones exploratorias y tabulaciones para distribuciones categóricas
Observaciones concretas del instructor
Algunas categorías (race, hispanic, birthplace, citizenship) completas
Employment status e industry con NAs que requieren explicación; posible relación con menores o no fuerza laboral
Recomendación de ejecutar visualizaciones cada vez que se modifica la data para detectar anomalías

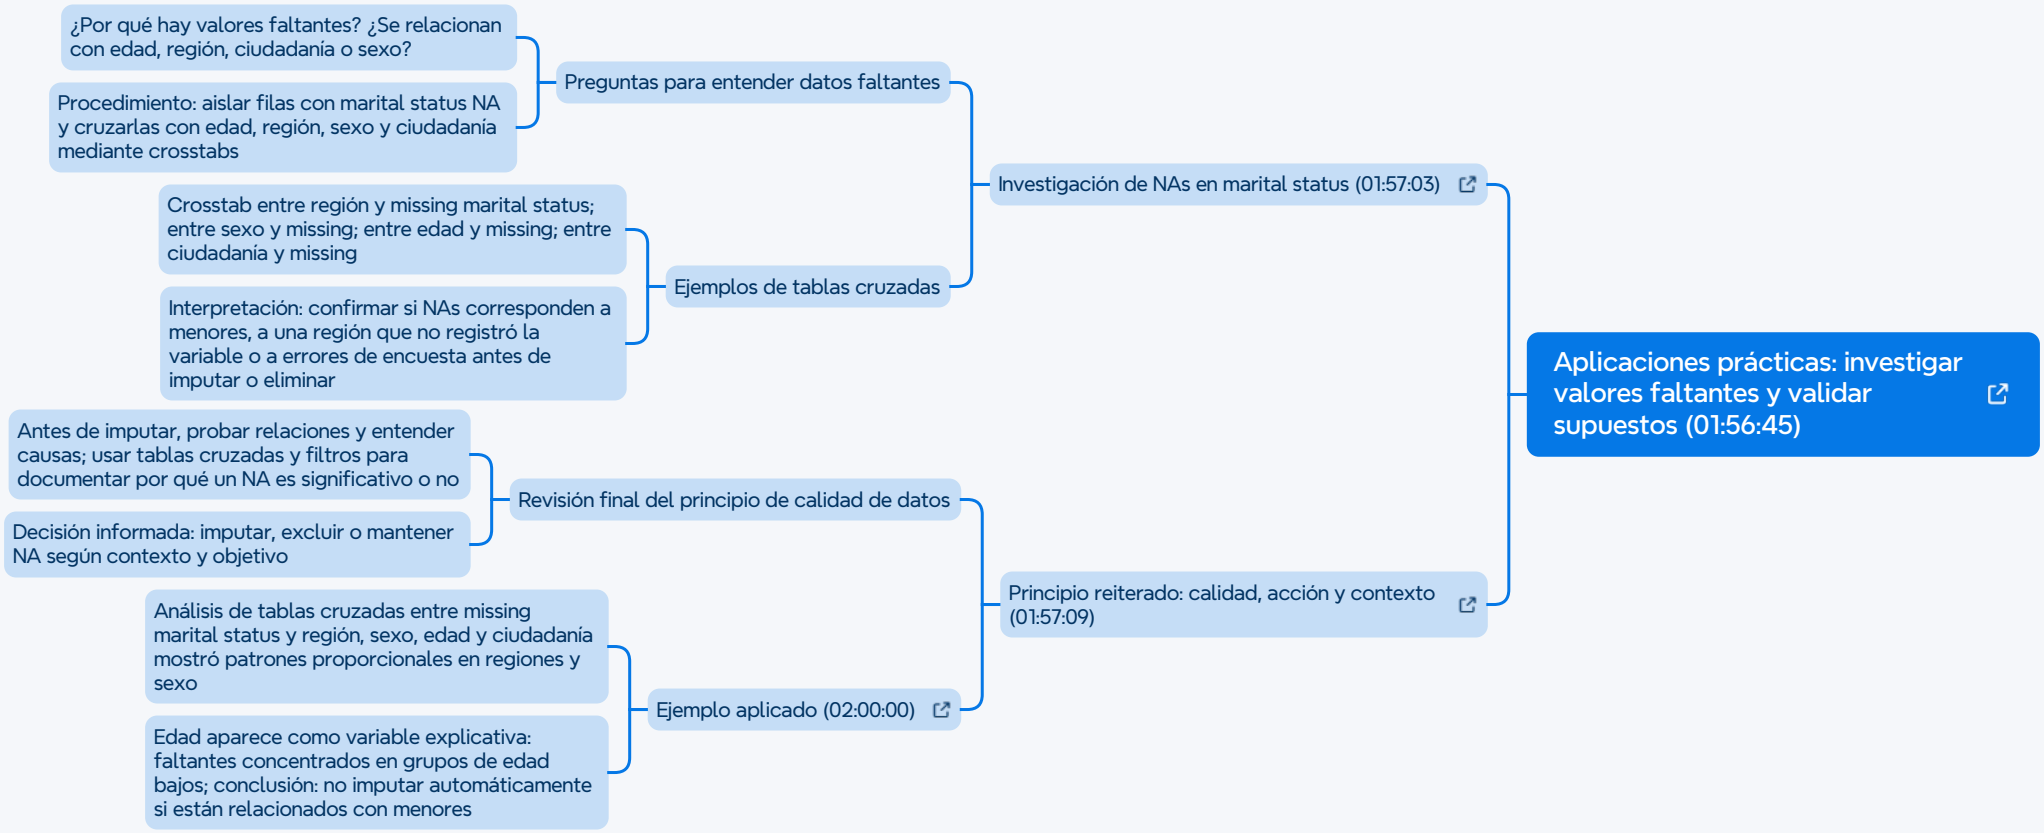

Análisis descriptivo y visualización práctica con Pandas y Matplotlib (01:00:01)
Tabulaciones y distribuciones básicas (01:00:08)
Conteos y proporciones de categorías
Uso de value_counts() para estatus de empleo: ejemplo de proporciones generales (empleados ~58%, retirados ~17%, no en fuerza laboral ~14.4%)
Comparar proporciones versus conteos según la pregunta (proporciones para ver distribución relativa; conteos para volumen absoluto)
Presentación por estado y top/N
Agrupar por estado y obtener top 10 de mayor o menor proporción/promedio
Ejemplo: estados más envejecidos (Delaware, Vermont, Florida) y más jóvenes (Utah) con interpretación contextual
Gráficos básicos y configuraciones (01:06:12)
Tipos de gráficos y librerías
Uso de Matplotlib (plt) para gráficos de barras, barras horizontales, stacked bars
Atención a errores comunes: mayúsculas/minúsculas en nombres de variables o atributos, índices al extraer nombres
Parámetros recomendados en plots
Tamaño de figura (10x6), títulos, etiquetas de ejes, grid en X, ajustar layout y mostrar
Gráfica apilada (stacked=True) para ver la distribución completa de estados laborales por estado

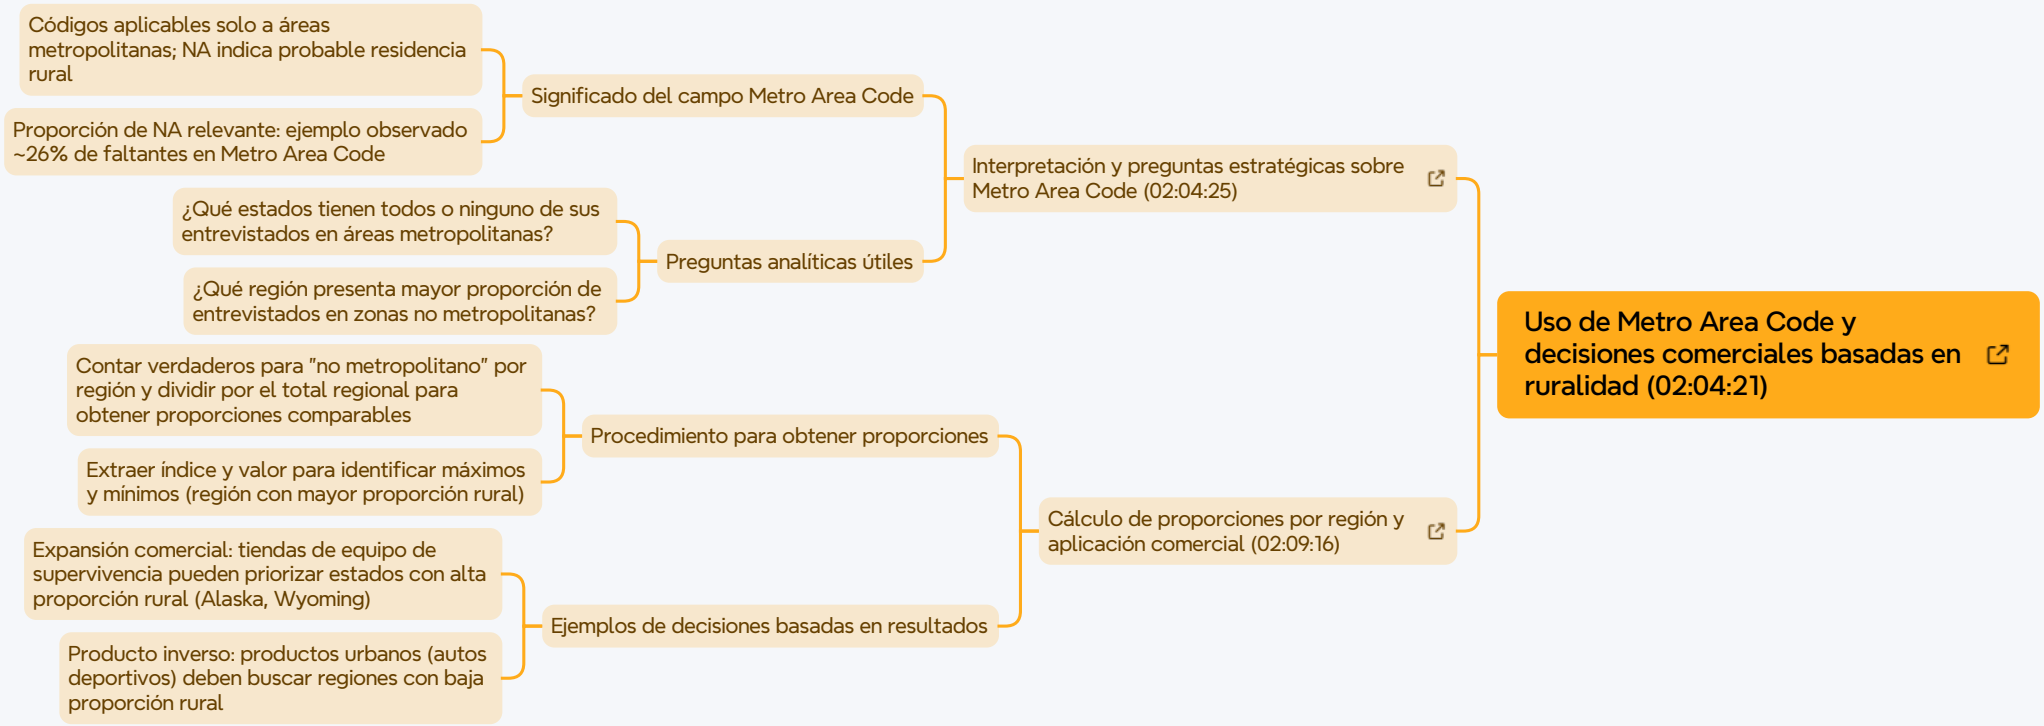

Cruces, mapeo de variables y análisis comparativo (01:13:47)
Tablas cruzadas y análisis por subgrupos (01:13:49)
Uso de crosstab para comparar variables
Tabla cruzada entre estado y estatus de empleo para ver composición (usar top states filtrados)
Interpretar proporciones apiladas para detectar patrones más ricos que un simple count de desempleo
Filtrado y selección de subgrupos
Seleccionar desempleados para comparar con variables como educación, industria o región
Ejemplo: comparar promedio de nivel educativo entre desempleados en los 10 estados con mayor desempleo
Mapear variables no numéricas a numéricas (01:19:22)
Conversión de factores educativos a escala numérica
Mapear categorías educativas (no high school, high school, some college, associate degree) a 0–3 para obtener promedios
Justificación: obtener medidas numéricas promediables que sugieran relación entre nivel educativo y desempleo
Interpretación de promedios mapeados
Promedio de educación entre desempleados por estado indica diferencias relativas; ausencia de ingresos obliga a usar proxies como educación o empleo
Hallazgo ejemplo: en top 10 estados no se observan diferencias grandes, lo que sugiere relación equitativa entre educación y desempleo a nivel estatal

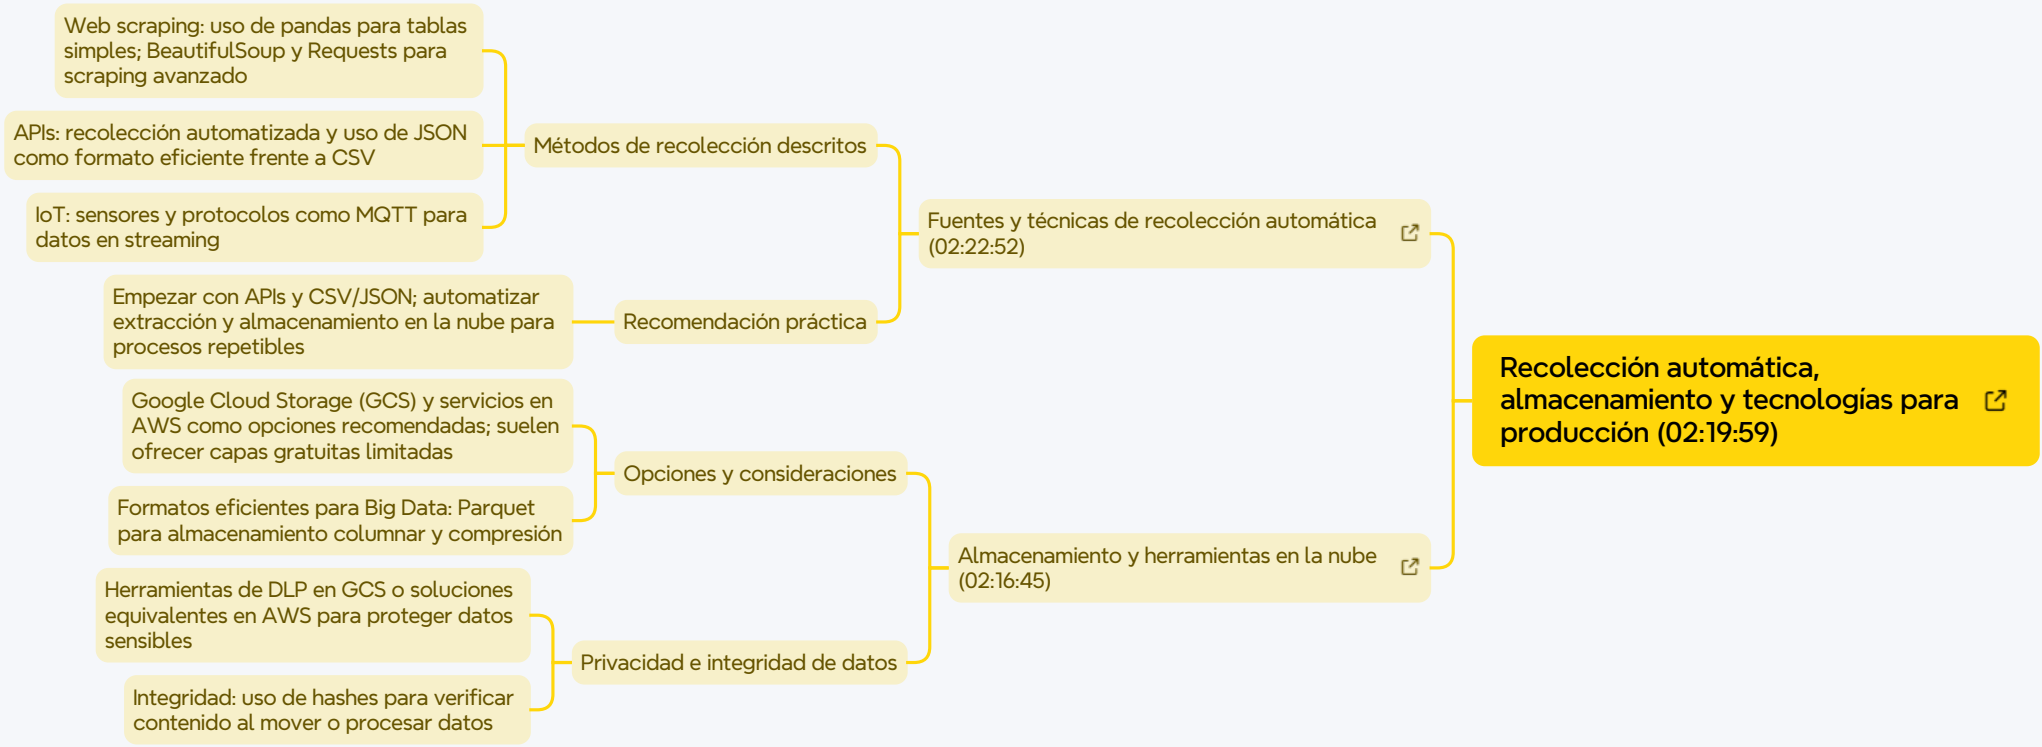

Exploración adicional: industria, ciudadanía y raza/etnicidad (01:26:46)
Filtrado y conteo en industria (01:26:57)
Limpieza previa y conteo
Eliminar filas con valores 'not a number' en industria mediante dropna para conteos fiables
Mostrar conteos por industria (educación, comercio, manufactura, profesionales) en tabla normalizada o en conteo absoluto según la necesidad
Planteo de preguntas estratégicas
Ejemplos: qué estados tienen menos entrevistados, relación población-entrevistas; usar min/max e índices para identificar estados extremos (Nuevo México menos, California más)
Ciudadanía y ratios relevantes (01:30:58)
Proporciones y ratios
Calcular proporción de ciudadanos nativos, naturalizados y no ciudadanos; ejemplo: 15.37 ciudadanos nativos por cada no ciudadano
Posibles combinaciones analíticas: ciudadanos totales vs no ciudadanos; nativos vs naturalizados
Uso para segmentación y políticas
Estos ratios permiten plantear hipótesis sobre integración, mercados laborales y focalización de intervenciones
Raza y etnicidad dentro de hispanos (01:35:00)
Filtrar por hispanidad y contar razas
Identificar razas dentro del subconjunto hispano y filtrar aquellas con al menos 250 entrevistados para análisis robusto
Ejemplo de razas con >250: blancos, negros, multiraciales, indígenas americanos; otras categorías pequeñas se agrupan o se descartan por bajo N

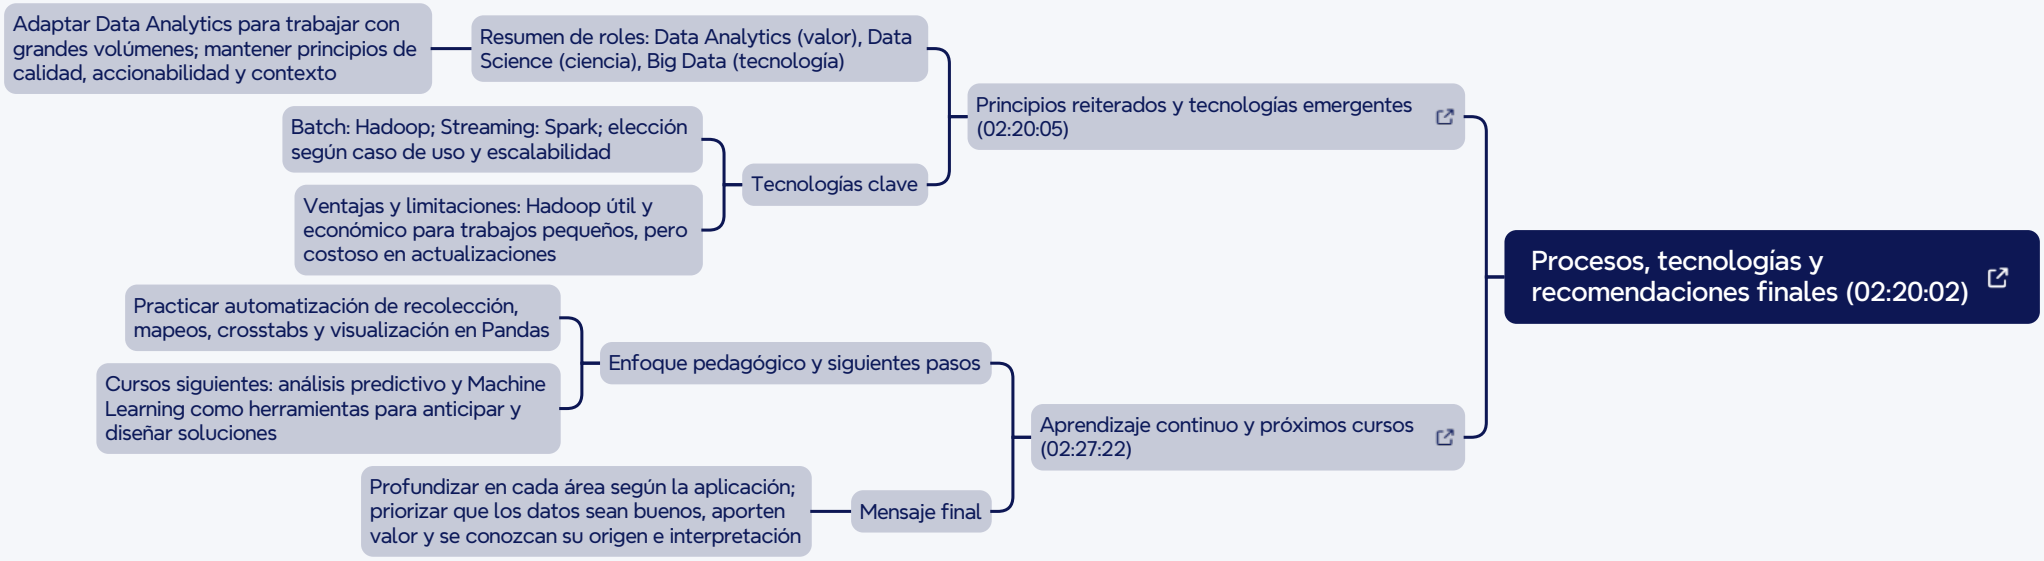

De patrones a hallazgos y recomendaciones estratégicas (01:43:44)
Del patrón al hallazgo (01:44:06)
Transformación del patrón en hallazgo y su interpretación
Detectar patrones (alto desempleo y alto nivel educativo en Texas y California) y contextualizarlos antes de proponer acciones
Verificar hipótesis: filtrar desempleados y analizar distribución educativa para ver si los empleados con alto nivel educativo estaban ocupando plazas o si hay subgrupos vulnerables
Priorización y criterios de decisión (01:45:31)
Cómo priorizar hallazgos accionables
Criterios: impacto potencial (personas beneficiadas), viabilidad operativa, costo-beneficio y alineamiento estratégico
Considerar diferentes aplicaciones: planificación estratégica, diseño de intervenciones, priorización presupuestal
Ejemplo de recomendación concreta
Propuesta: establecer programas de formación técnica en Nevada por disponibilidad de mano de obra con secundaria completa o superior; justificar con argumento de valor y viabilidad
Comunicación y venta de la recomendación (01:48:51)
Estructura de una recomendación basada en datos
Basarse en evidencia (tablas, proporciones, gráficos), proponer acción específica y argumentar valor esperado
Incluir visualizaciones claras; potenciar con técnicas de visualización de datos para mejorar la recepción
Vinculación a acción
Relacionar la recomendación con planificación estratégica, diseño de intervenciones o asignación presupuestal según el objetivo

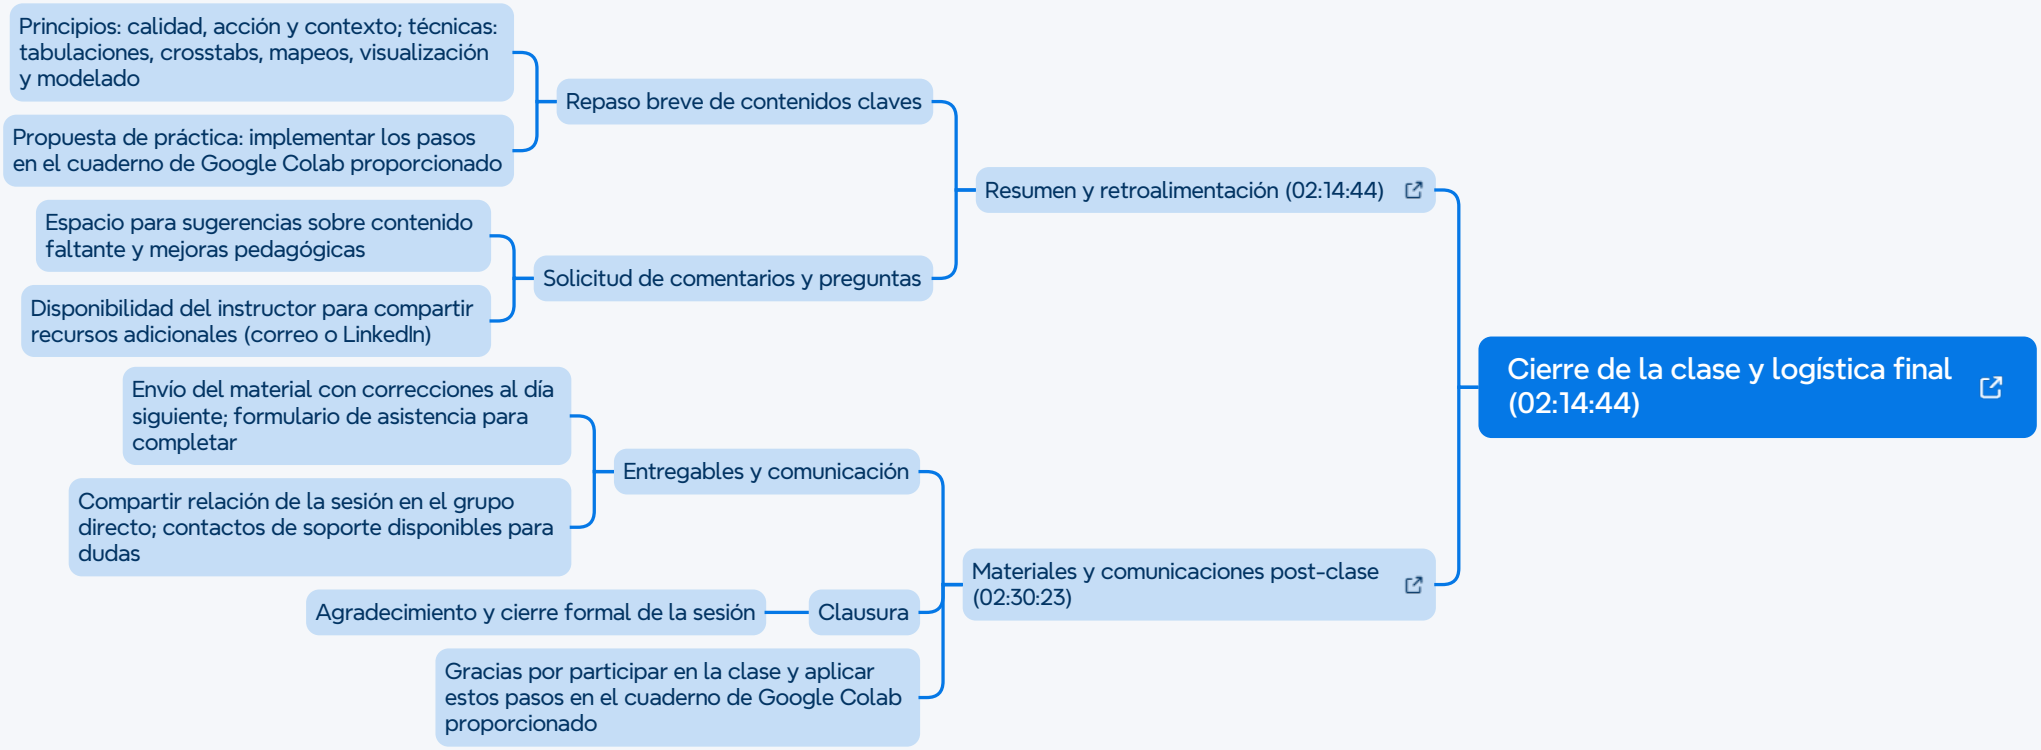

Proceso ordenado de análisis para la toma de decisiones (01:54:56)
Flujo recomendado (01:55:03)
Secuencia general
A partir de los datos, encontrar patrones
Convertir patrones en hallazgos interpretables
Priorizar hallazgos según criterios estratégicos
Tomar decisión estratégica y presentar evidencia
Pasar de la recomendación a la acción vinculada a planificación, intervenciones o presupuesto
Elementos evaluativos
Evaluar impacto potencial, viabilidad operativa, costo-beneficio y rendimiento estratégico antes de priorizar
Cierre y siguientes pasos (01:56:37)
Aplicaciones futuras y desarrollo del ejercicio completo
Integrar más variables (ingreso si estuviera disponible), realizar correlaciones adicionales y tests de robustez
Profundizar en visualización y presentación para comunicar mejor las recomendaciones
Recomendación pedagógica
Practicar mapeos, crosstabs y filtrados en Pandas; estudiar visualización de datos para mejorar la comunicación de hallazgos


Aplicaciones prácticas: investigar valores faltantes y validar supuestos (01:56:45)
Investigación de NAs en marital status (01:57:03)
Preguntas para entender datos faltantes
¿Por qué hay valores faltantes? ¿Se relacionan con edad, región, ciudadanía o sexo?
Procedimiento: aislar filas con marital status NA y cruzarlas con edad, región, sexo y ciudadanía mediante crosstabs
Ejemplos de tablas cruzadas
Crosstab entre región y missing marital status; entre sexo y missing; entre edad y missing; entre ciudadanía y missing
Interpretación: confirmar si NAs corresponden a menores, a una región que no registró la variable o a errores de encuesta antes de imputar o eliminar
Principio reiterado: calidad, acción y contexto (01:57:09)
Revisión final del principio de calidad de datos
Antes de imputar, probar relaciones y entender causas; usar tablas cruzadas y filtros para documentar por qué un NA es significativo o no
Decisión informada: imputar, excluir o mantener NA según contexto y objetivo
Ejemplo aplicado (02:00:00)
Análisis de tablas cruzadas entre missing marital status y región, sexo, edad y ciudadanía mostró patrones proporcionales en regiones y sexo
Edad aparece como variable explicativa: faltantes concentrados en grupos de edad bajos; conclusión: no imputar automáticamente si están relacionados con menores


Uso de Metro Area Code y decisiones comerciales basadas en ruralidad (02:04:21)
Interpretación y preguntas estratégicas sobre Metro Area Code (02:04:25)
Significado del campo Metro Area Code
Códigos aplicables solo a áreas metropolitanas; NA indica probable residencia rural
Proporción de NA relevante: ejemplo observado ~26% de faltantes en Metro Area Code
Preguntas analíticas útiles
¿Qué estados tienen todos o ninguno de sus entrevistados en áreas metropolitanas?
¿Qué región presenta mayor proporción de entrevistados en zonas no metropolitanas?
Cálculo de proporciones por región y aplicación comercial (02:09:16)
Procedimiento para obtener proporciones
Contar verdaderos para "no metropolitano" por región y dividir por el total regional para obtener proporciones comparables
Extraer índice y valor para identificar máximos y mínimos (región con mayor proporción rural)
Ejemplos de decisiones basadas en resultados
Expansión comercial: tiendas de equipo de supervivencia pueden priorizar estados con alta proporción rural (Alaska, Wyoming)
Producto inverso: productos urbanos (autos deportivos) deben buscar regiones con baja proporción rural


Recolección automática, almacenamiento y tecnologías para producción (02:19:59)
Fuentes y técnicas de recolección automática (02:22:52)
Métodos de recolección descritos
Web scraping: uso de pandas para tablas simples; BeautifulSoup y Requests para scraping avanzado
APIs: recolección automatizada y uso de JSON como formato eficiente frente a CSV
IoT: sensores y protocolos como MQTT para datos en streaming
Recomendación práctica
Empezar con APIs y CSV/JSON; automatizar extracción y almacenamiento en la nube para procesos repetibles
Almacenamiento y herramientas en la nube (02:16:45)
Opciones y consideraciones
Google Cloud Storage (GCS) y servicios en AWS como opciones recomendadas; suelen ofrecer capas gratuitas limitadas
Formatos eficientes para Big Data: Parquet para almacenamiento columnar y compresión
Privacidad e integridad de datos
Herramientas de DLP en GCS o soluciones equivalentes en AWS para proteger datos sensibles
Integridad: uso de hashes para verificar contenido al mover o procesar datos


Procesos, tecnologías y recomendaciones finales (02:20:02)
Principios reiterados y tecnologías emergentes (02:20:05)
Resumen de roles: Data Analytics (valor), Data Science (ciencia), Big Data (tecnología)
Adaptar Data Analytics para trabajar con grandes volúmenes; mantener principios de calidad, accionabilidad y contexto
Tecnologías clave
Batch: Hadoop; Streaming: Spark; elección según caso de uso y escalabilidad
Ventajas y limitaciones: Hadoop útil y económico para trabajos pequeños, pero costoso en actualizaciones
Aprendizaje continuo y próximos cursos (02:27:22)
Enfoque pedagógico y siguientes pasos
Practicar automatización de recolección, mapeos, crosstabs y visualización en Pandas
Cursos siguientes: análisis predictivo y Machine Learning como herramientas para anticipar y diseñar soluciones
Mensaje final
Profundizar en cada área según la aplicación; priorizar que los datos sean buenos, aporten valor y se conozcan su origen e interpretación


Cierre de la clase y logística final (02:14:44)
Resumen y retroalimentación (02:14:44)
Repaso breve de contenidos claves
Principios: calidad, acción y contexto; técnicas: tabulaciones, crosstabs, mapeos, visualización y modelado
Propuesta de práctica: implementar los pasos en el cuaderno de Google Colab proporcionado
Solicitud de comentarios y preguntas
Espacio para sugerencias sobre contenido faltante y mejoras pedagógicas
Disponibilidad del instructor para compartir recursos adicionales (correo o LinkedIn)
Materiales y comunicaciones post-clase (02:30:23)
Entregables y comunicación
Envío del material con correcciones al día siguiente; formulario de asistencia para completar
Compartir relación de la sesión en el grupo directo; contactos de soporte disponibles para dudas
Clausura
Agradecimiento y cierre formal de la sesión
Gracias por participar en la clase y aplicar estos pasos en el cuaderno de Google Colab proporcionado