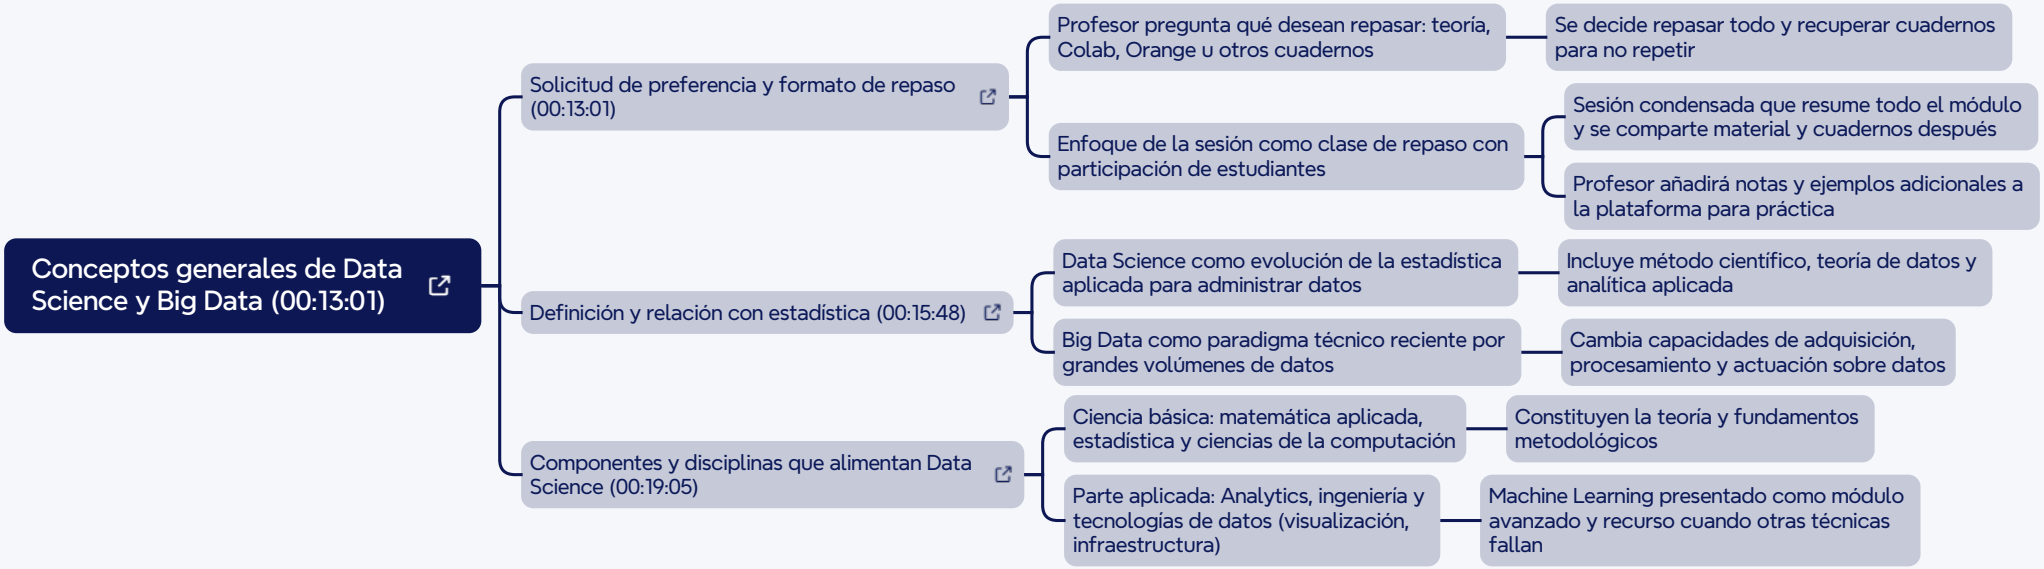
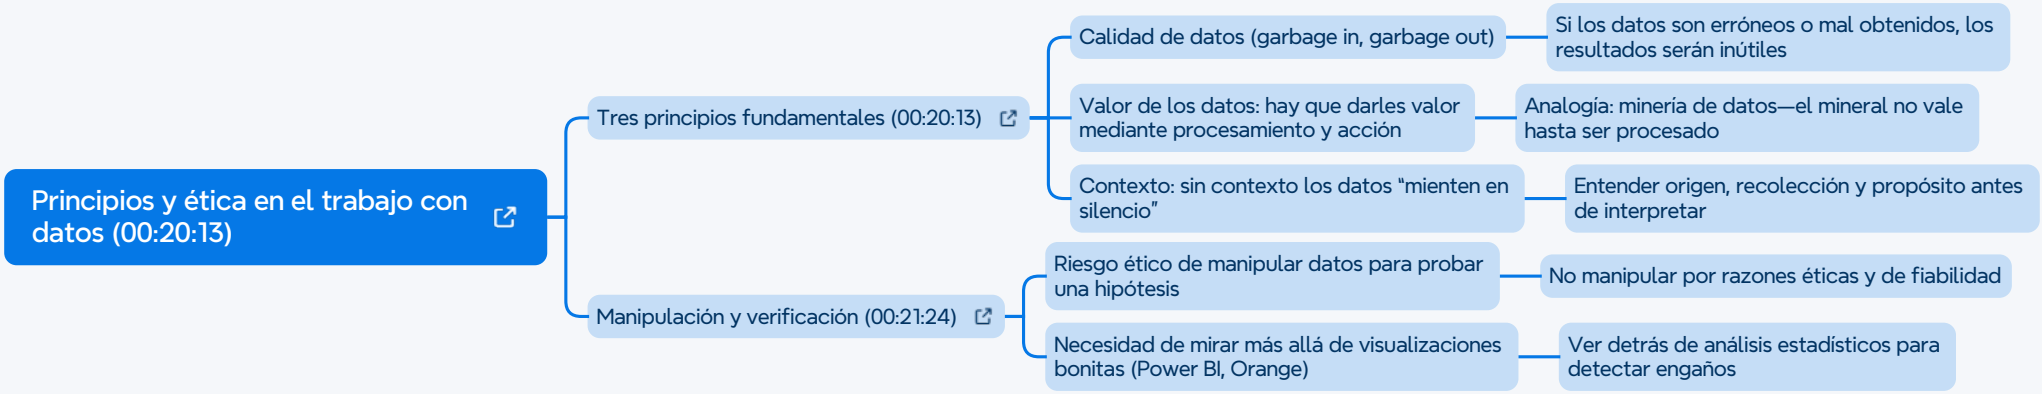
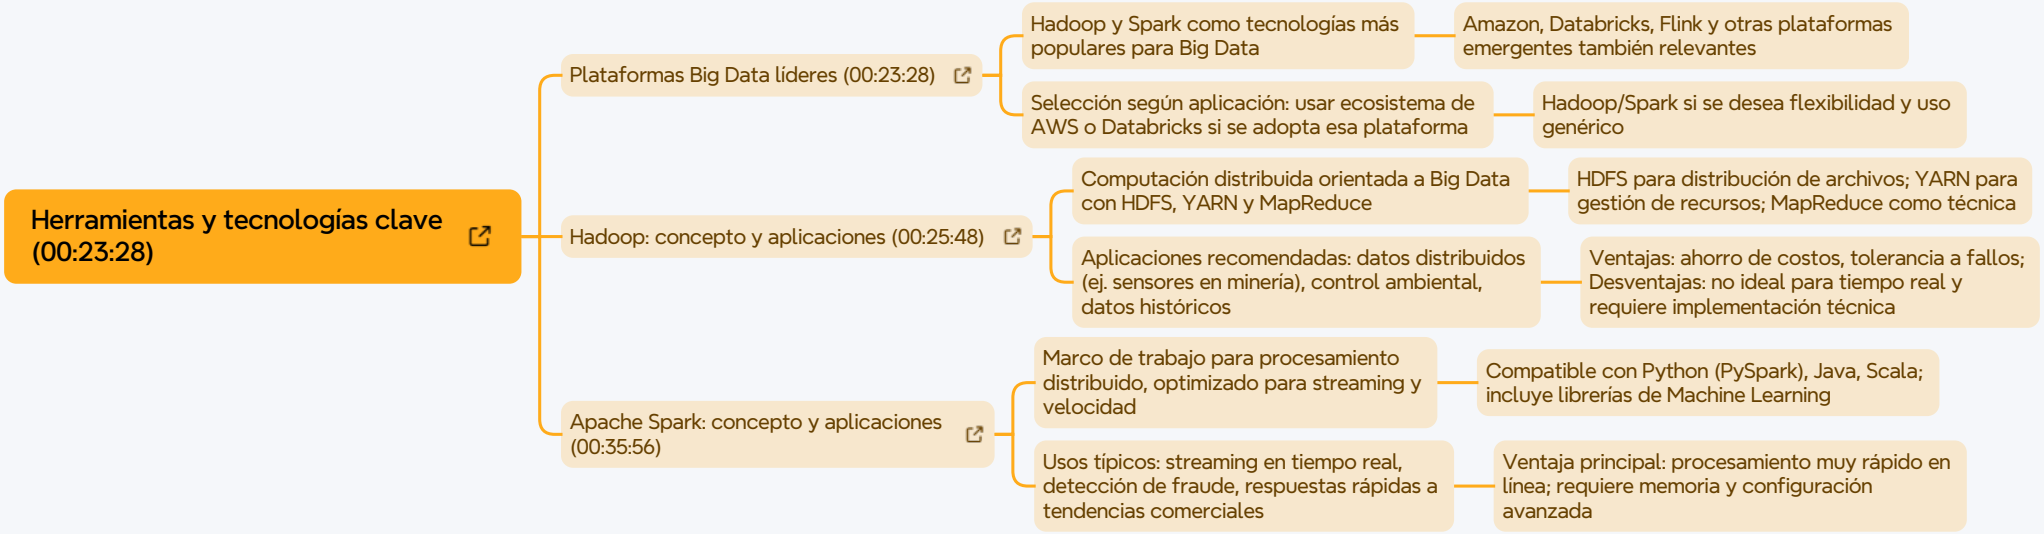
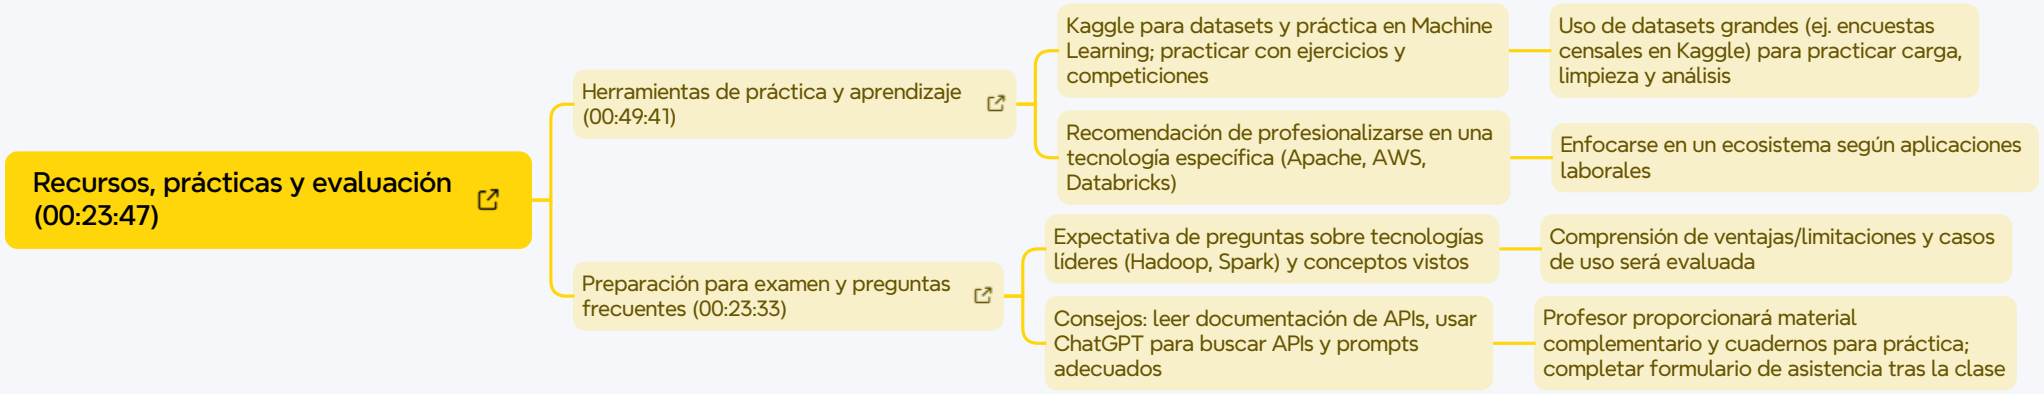
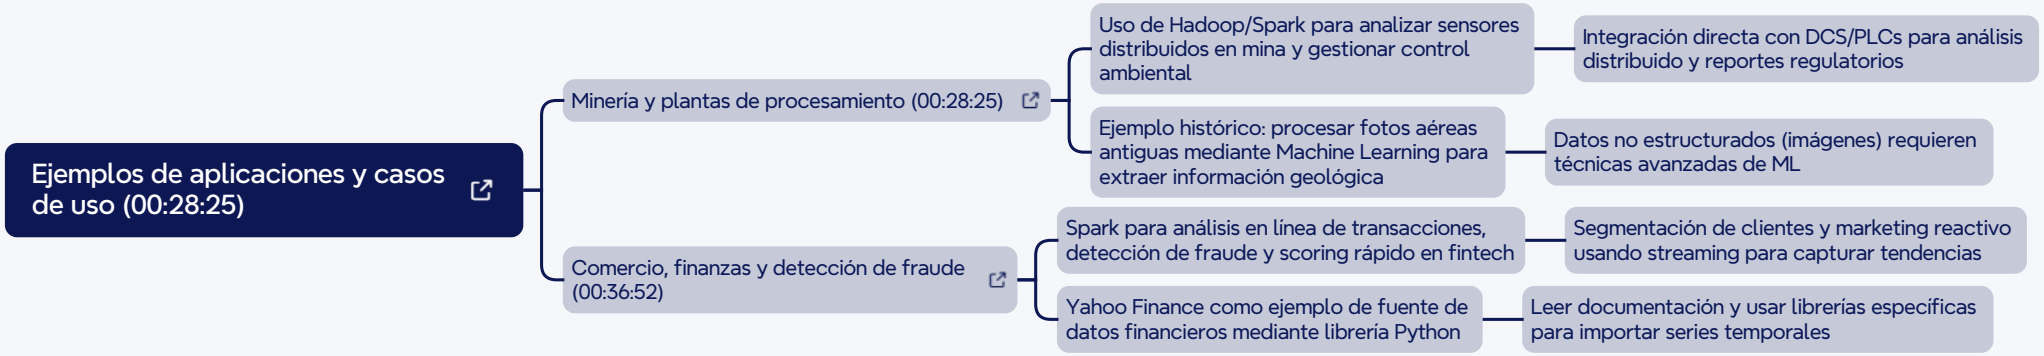

CLASE 07: APLICACIÓN PRÁCTICA Y ZONA DE PREGUNTAS - 1RA PARTE
De hallazgos a decisiones y recomendaciones estratégicas (01:19:18)
15
Actividades prácticas y ejercicios finales (01:18:29)
10
Métodos comunes en Machine Learning y casos avanzados (01:17:11)
10
Análisis predictivo y prescriptivo (01:15:44)
10
Gestión del ciclo de datos y arquitecturas (01:04:31)
11
Exploración, limpieza e imputación de datos (01:03:48)
10
Recolección de datos y fuentes (00:45:21)
15
Conceptos generales de Data Science y Big Data (00:13:01)
16
Principios y ética en el trabajo con datos (00:20:13)
12
Herramientas y tecnologías clave (00:23:28)
15
Recursos, prácticas y evaluación (00:23:47)
10
Ejemplos de aplicaciones y casos de uso (00:28:25)
10
Python, librerías y práctica en Colab (00:33:34)
13
Privacidad, seguridad y normativas (00:42:46)
8

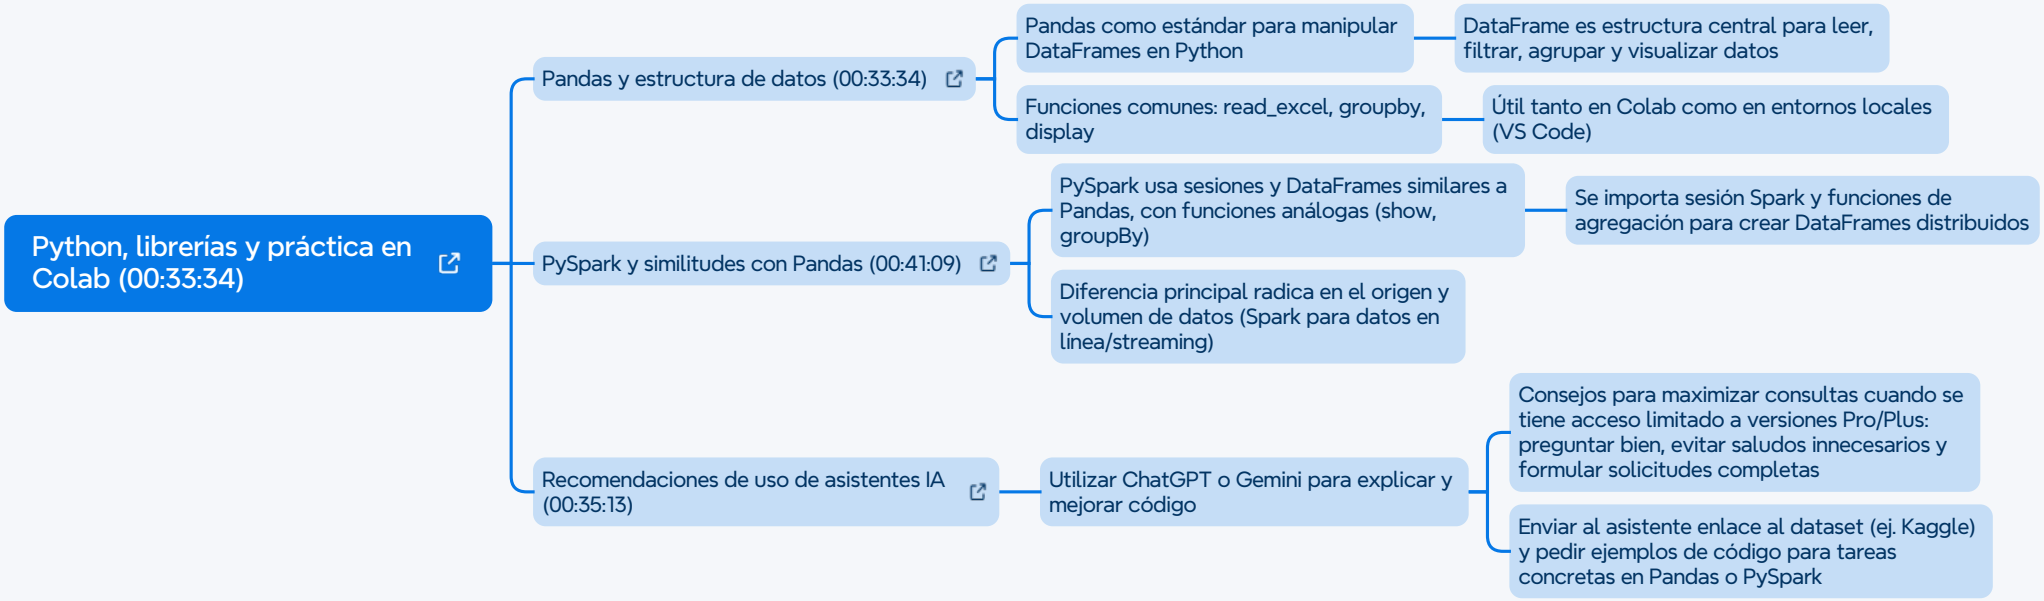

Conceptos generales de Data Science y Big Data (00:13:01)
Solicitud de preferencia y formato de repaso (00:13:01)
Profesor pregunta qué desean repasar: teoría, Colab, Orange u otros cuadernos
Se decide repasar todo y recuperar cuadernos para no repetir
Enfoque de la sesión como clase de repaso con participación de estudiantes
Sesión condensada que resume todo el módulo y se comparte material y cuadernos después
Profesor añadirá notas y ejemplos adicionales a la plataforma para práctica
Definición y relación con estadística (00:15:48)
Data Science como evolución de la estadística aplicada para administrar datos
Incluye método científico, teoría de datos y analítica aplicada
Big Data como paradigma técnico reciente por grandes volúmenes de datos
Cambia capacidades de adquisición, procesamiento y actuación sobre datos
Componentes y disciplinas que alimentan Data Science (00:19:05)
Ciencia básica: matemática aplicada, estadística y ciencias de la computación
Constituyen la teoría y fundamentos metodológicos
Parte aplicada: Analytics, ingeniería y tecnologías de datos (visualización, infraestructura)
Machine Learning presentado como módulo avanzado y recurso cuando otras técnicas fallan

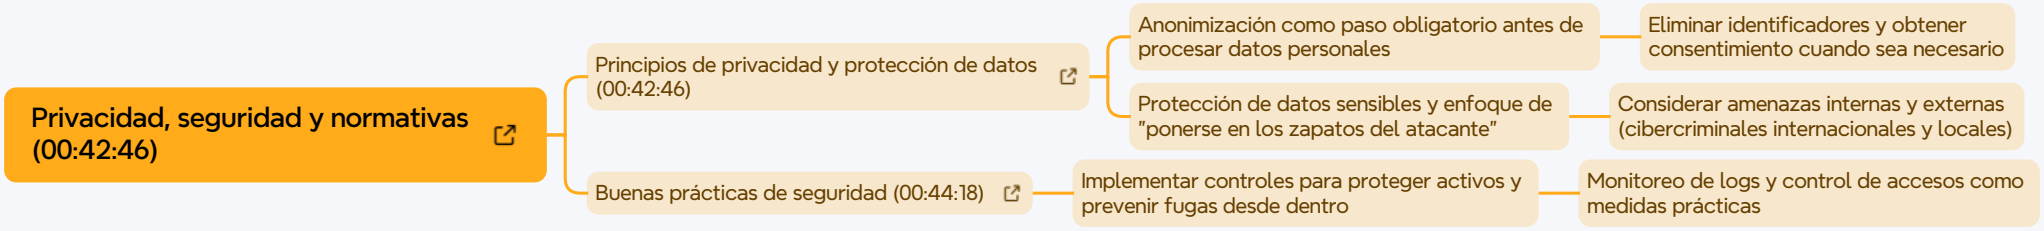

Principios y ética en el trabajo con datos (00:20:13)
Tres principios fundamentales (00:20:13)
Calidad de datos (garbage in, garbage out)
Si los datos son erróneos o mal obtenidos, los resultados serán inútiles
Valor de los datos: hay que darles valor mediante procesamiento y acción
Analogía: minería de datos—el mineral no vale hasta ser procesado
Contexto: sin contexto los datos "mienten en silencio"
Entender origen, recolección y propósito antes de interpretar
Manipulación y verificación (00:21:24)
Riesgo ético de manipular datos para probar una hipótesis
No manipular por razones éticas y de fiabilidad
Necesidad de mirar más allá de visualizaciones bonitas (Power BI, Orange)
Ver detrás de análisis estadísticos para detectar engaños

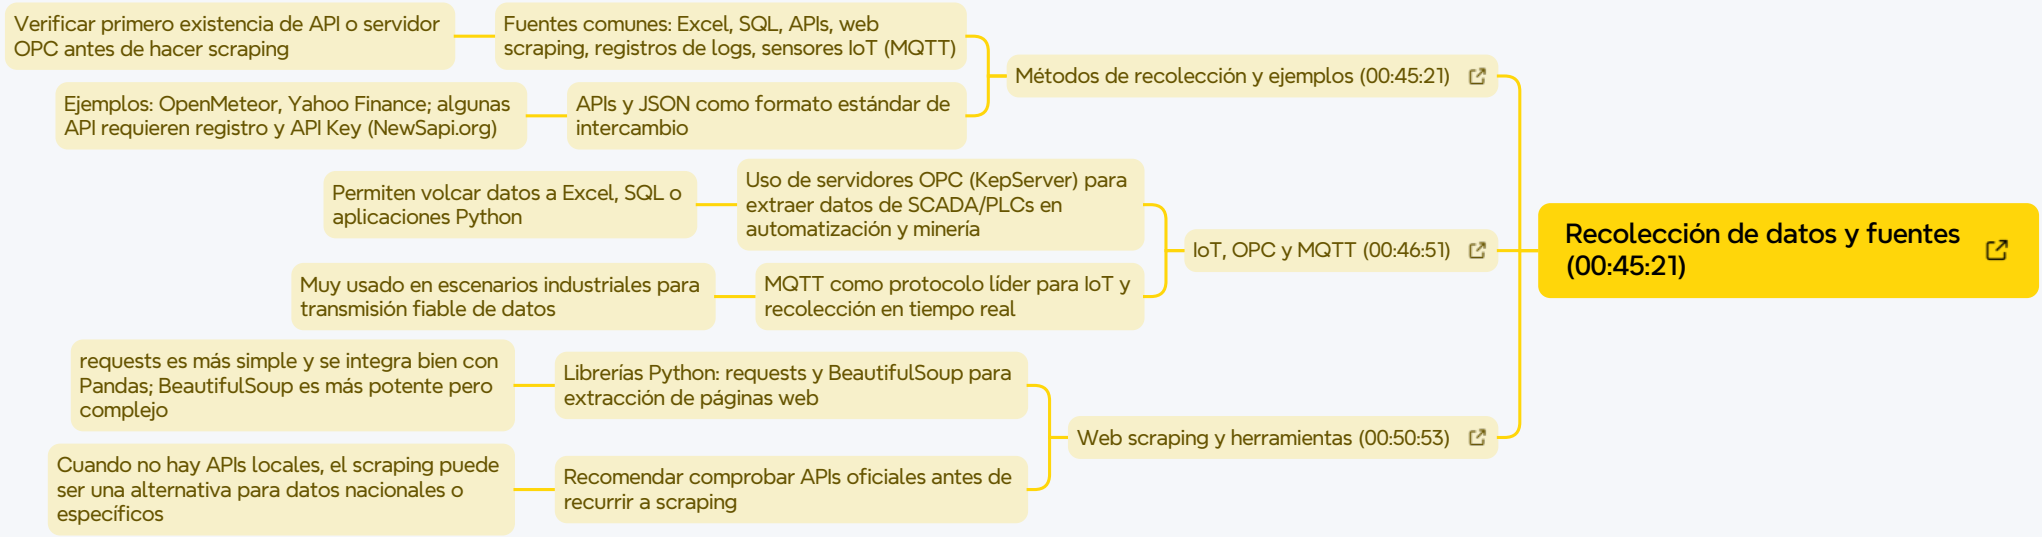

Herramientas y tecnologías clave (00:23:28)
Plataformas Big Data líderes (00:23:28)
Hadoop y Spark como tecnologías más populares para Big Data
Amazon, Databricks, Flink y otras plataformas emergentes también relevantes
Selección según aplicación: usar ecosistema de AWS o Databricks si se adopta esa plataforma
Hadoop/Spark si se desea flexibilidad y uso genérico
Hadoop: concepto y aplicaciones (00:25:48)
Computación distribuida orientada a Big Data con HDFS, YARN y MapReduce
HDFS para distribución de archivos; YARN para gestión de recursos; MapReduce como técnica
Aplicaciones recomendadas: datos distribuidos (ej. sensores en minería), control ambiental, datos históricos
Ventajas: ahorro de costos, tolerancia a fallos; Desventajas: no ideal para tiempo real y requiere implementación técnica
Apache Spark: concepto y aplicaciones (00:35:56)
Marco de trabajo para procesamiento distribuido, optimizado para streaming y velocidad
Compatible con Python (PySpark), Java, Scala; incluye librerías de Machine Learning
Usos típicos: streaming en tiempo real, detección de fraude, respuestas rápidas a tendencias comerciales
Ventaja principal: procesamiento muy rápido en línea; requiere memoria y configuración avanzada

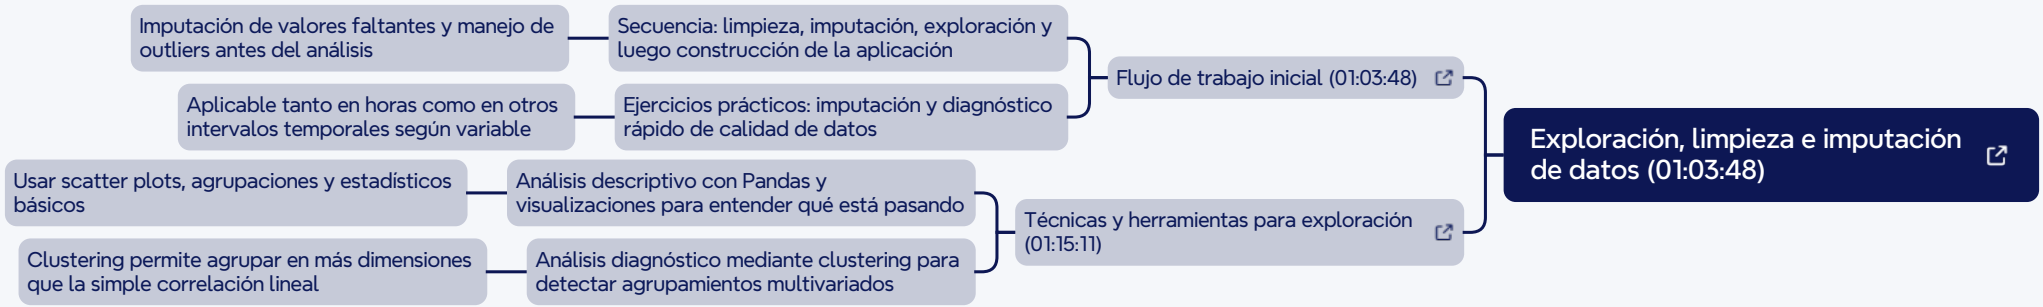

Recursos, prácticas y evaluación (00:23:47)
Herramientas de práctica y aprendizaje (00:49:41)
Kaggle para datasets y práctica en Machine Learning; practicar con ejercicios y competiciones
Uso de datasets grandes (ej. encuestas censales en Kaggle) para practicar carga, limpieza y análisis
Recomendación de profesionalizarse en una tecnología específica (Apache, AWS, Databricks)
Enfocarse en un ecosistema según aplicaciones laborales
Preparación para examen y preguntas frecuentes (00:23:33)
Expectativa de preguntas sobre tecnologías líderes (Hadoop, Spark) y conceptos vistos
Comprensión de ventajas/limitaciones y casos de uso será evaluada
Consejos: leer documentación de APIs, usar ChatGPT para buscar APIs y prompts adecuados
Profesor proporcionará material complementario y cuadernos para práctica; completar formulario de asistencia tras la clase

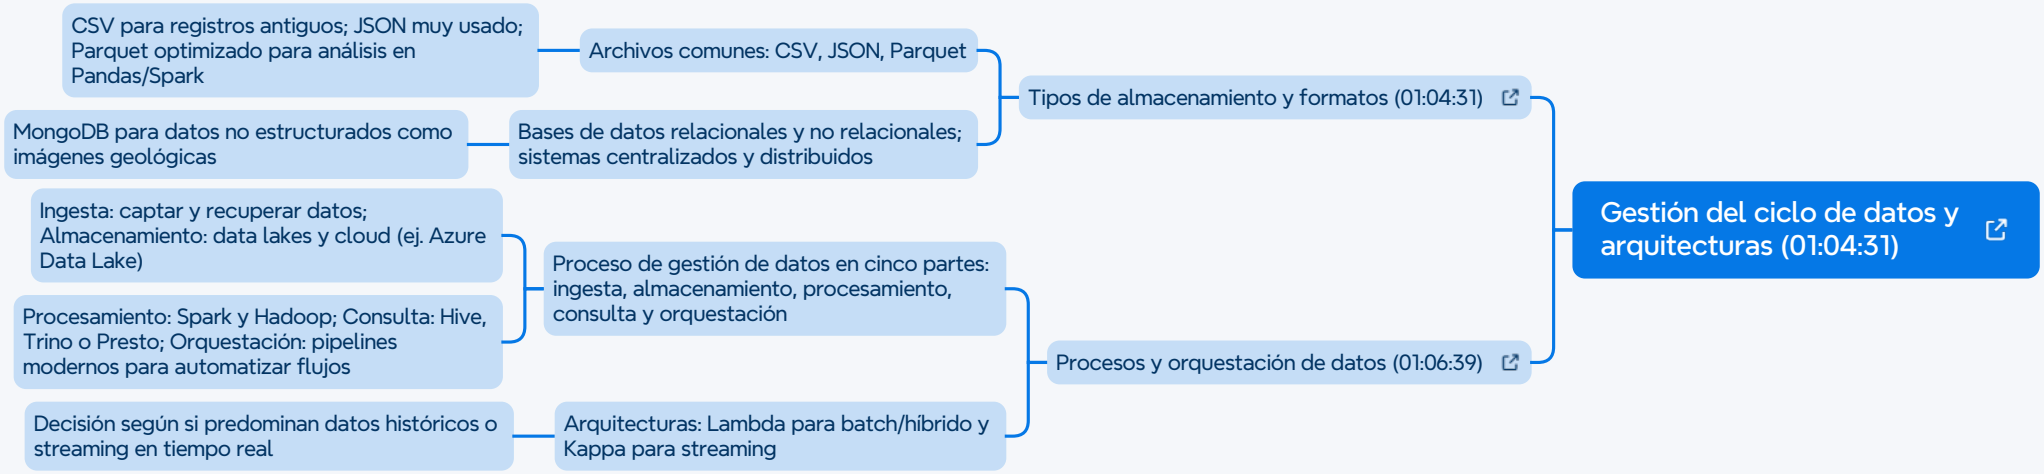

Ejemplos de aplicaciones y casos de uso (00:28:25)
Minería y plantas de procesamiento (00:28:25)
Uso de Hadoop/Spark para analizar sensores distribuidos en mina y gestionar control ambiental
Integración directa con DCS/PLCs para análisis distribuido y reportes regulatorios
Ejemplo histórico: procesar fotos aéreas antiguas mediante Machine Learning para extraer información geológica
Datos no estructurados (imágenes) requieren técnicas avanzadas de ML
Comercio, finanzas y detección de fraude (00:36:52)
Spark para análisis en línea de transacciones, detección de fraude y scoring rápido en fintech
Segmentación de clientes y marketing reactivo usando streaming para capturar tendencias
Yahoo Finance como ejemplo de fuente de datos financieros mediante librería Python
Leer documentación y usar librerías específicas para importar series temporales

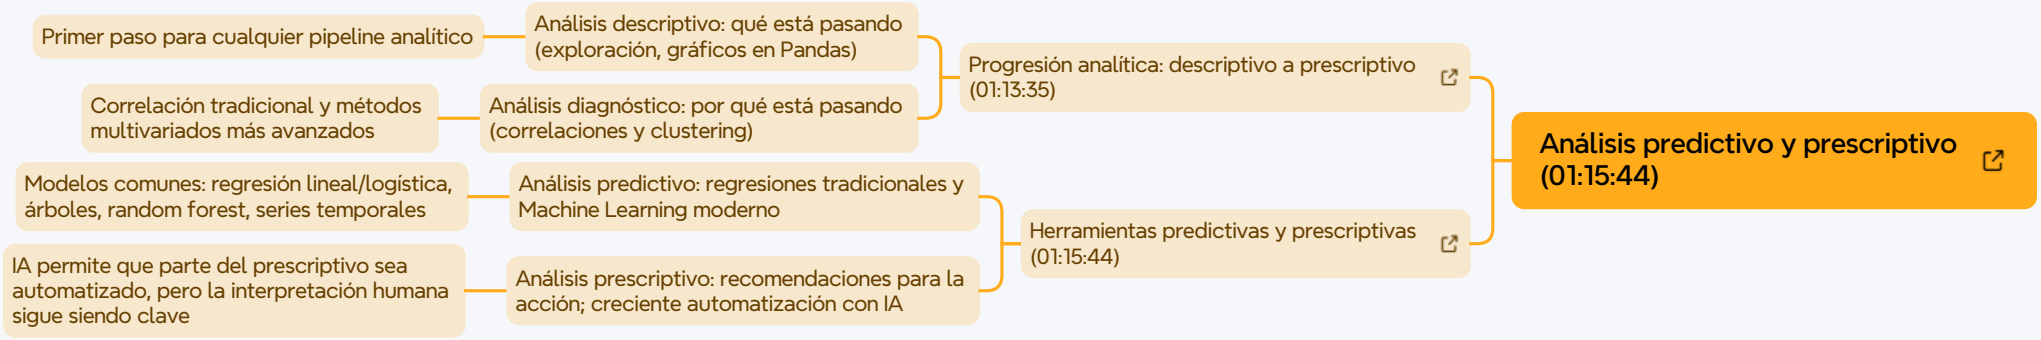

Python, librerías y práctica en Colab (00:33:34)
Pandas y estructura de datos (00:33:34)
Pandas como estándar para manipular DataFrames en Python
DataFrame es estructura central para leer, filtrar, agrupar y visualizar datos
Funciones comunes: read_excel, groupby, display
Útil tanto en Colab como en entornos locales (VS Code)
PySpark y similitudes con Pandas (00:41:09)
PySpark usa sesiones y DataFrames similares a Pandas, con funciones análogas (show, groupBy)
Se importa sesión Spark y funciones de agregación para crear DataFrames distribuidos
Diferencia principal radica en el origen y volumen de datos (Spark para datos en línea/streaming)
Recomendaciones de uso de asistentes IA (00:35:13)
Utilizar ChatGPT o Gemini para explicar y mejorar código
Consejos para maximizar consultas cuando se tiene acceso limitado a versiones Pro/Plus: preguntar bien, evitar saludos innecesarios y formular solicitudes completas
Enviar al asistente enlace al dataset (ej. Kaggle) y pedir ejemplos de código para tareas concretas en Pandas o PySpark

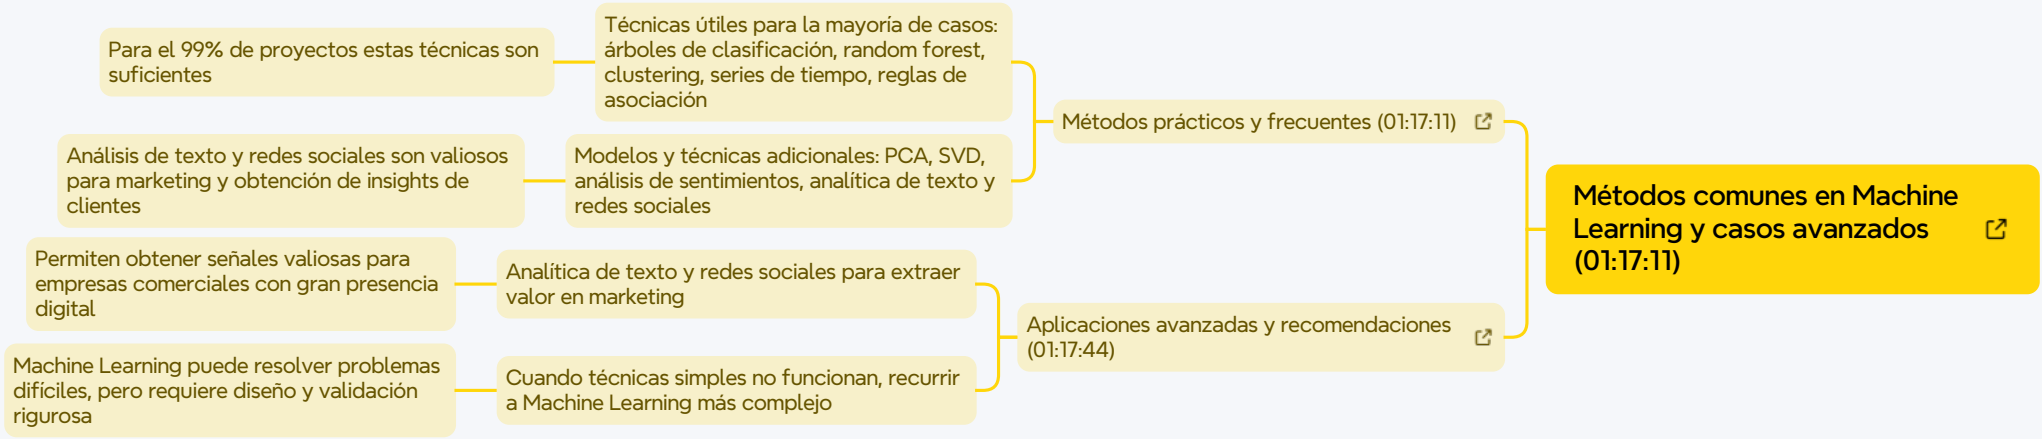

Privacidad, seguridad y normativas (00:42:46)
Principios de privacidad y protección de datos (00:42:46)
Anonimización como paso obligatorio antes de procesar datos personales
Eliminar identificadores y obtener consentimiento cuando sea necesario
Protección de datos sensibles y enfoque de "ponerse en los zapatos del atacante"
Considerar amenazas internas y externas (cibercriminales internacionales y locales)
Buenas prácticas de seguridad (00:44:18)
Implementar controles para proteger activos y prevenir fugas desde dentro
Monitoreo de logs y control de accesos como medidas prácticas

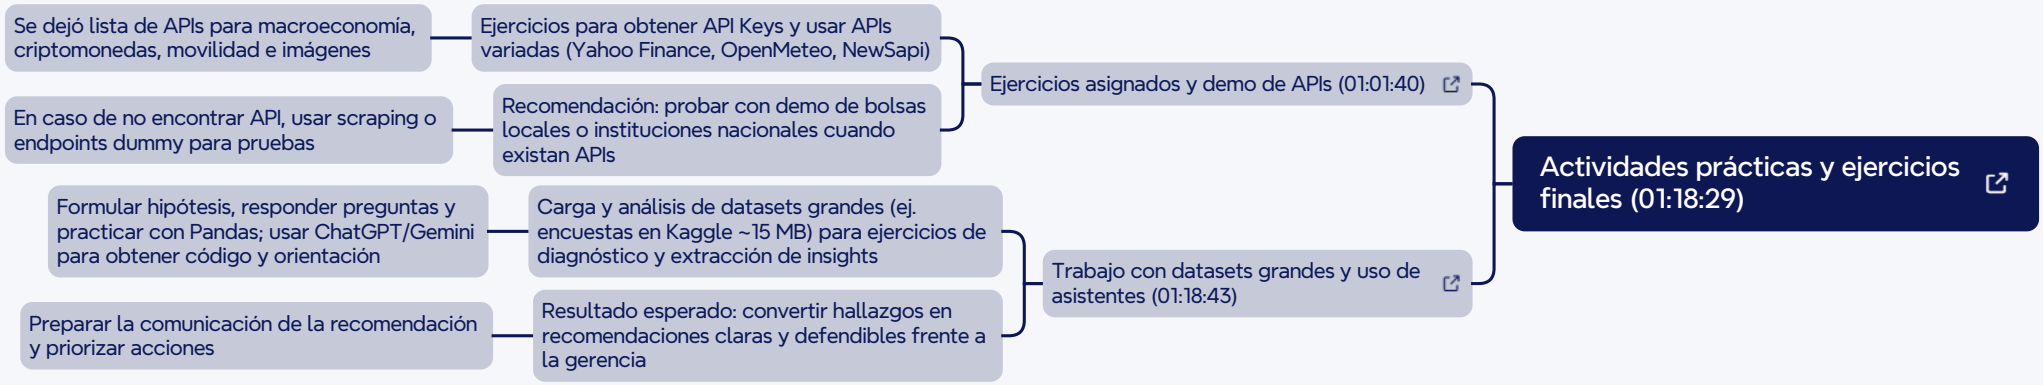

Recolección de datos y fuentes (00:45:21)
Métodos de recolección y ejemplos (00:45:21)
Fuentes comunes: Excel, SQL, APIs, web scraping, registros de logs, sensores IoT (MQTT)
Verificar primero existencia de API o servidor OPC antes de hacer scraping
APIs y JSON como formato estándar de intercambio
Ejemplos: OpenMeteor, Yahoo Finance; algunas API requieren registro y API Key (NewSapi.org)
IoT, OPC y MQTT (00:46:51)
Uso de servidores OPC (KepServer) para extraer datos de SCADA/PLCs en automatización y minería
Permiten volcar datos a Excel, SQL o aplicaciones Python
MQTT como protocolo líder para IoT y recolección en tiempo real
Muy usado en escenarios industriales para transmisión fiable de datos
Web scraping y herramientas (00:50:53)
Librerías Python: requests y BeautifulSoup para extracción de páginas web
requests es más simple y se integra bien con Pandas; BeautifulSoup es más potente pero complejo
Recomendar comprobar APIs oficiales antes de recurrir a scraping
Cuando no hay APIs locales, el scraping puede ser una alternativa para datos nacionales o específicos

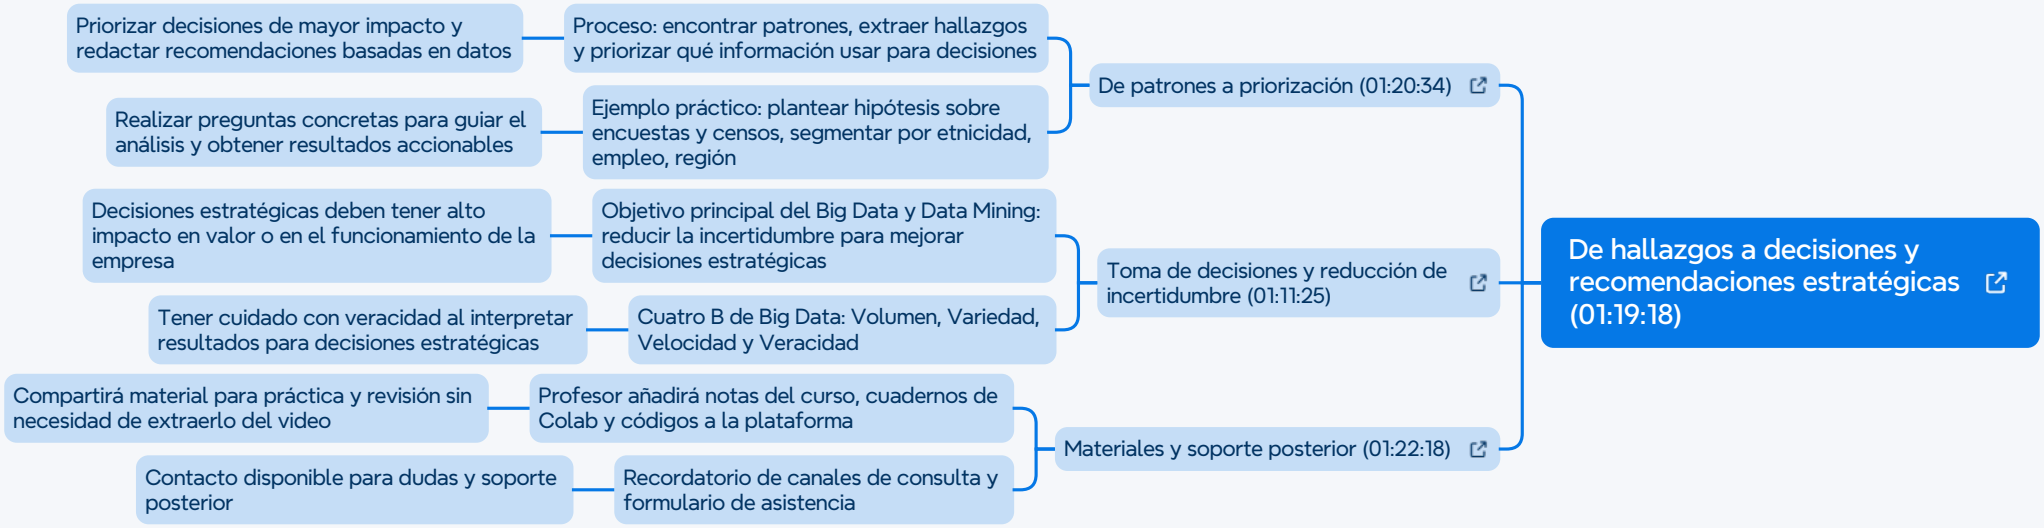

Exploración, limpieza e imputación de datos (01:03:48)
Flujo de trabajo inicial (01:03:48)
Secuencia: limpieza, imputación, exploración y luego construcción de la aplicación
Imputación de valores faltantes y manejo de outliers antes del análisis
Ejercicios prácticos: imputación y diagnóstico rápido de calidad de datos
Aplicable tanto en horas como en otros intervalos temporales según variable
Técnicas y herramientas para exploración (01:15:11)
Análisis descriptivo con Pandas y visualizaciones para entender qué está pasando
Usar scatter plots, agrupaciones y estadísticos básicos
Análisis diagnóstico mediante clustering para detectar agrupamientos multivariados
Clustering permite agrupar en más dimensiones que la simple correlación lineal


Gestión del ciclo de datos y arquitecturas (01:04:31)
Tipos de almacenamiento y formatos (01:04:31)
Archivos comunes: CSV, JSON, Parquet
CSV para registros antiguos; JSON muy usado; Parquet optimizado para análisis en Pandas/Spark
Bases de datos relacionales y no relacionales; sistemas centralizados y distribuidos
MongoDB para datos no estructurados como imágenes geológicas
Procesos y orquestación de datos (01:06:39)
Proceso de gestión de datos en cinco partes: ingesta, almacenamiento, procesamiento, consulta y orquestación
Ingesta: captar y recuperar datos; Almacenamiento: data lakes y cloud (ej. Azure Data Lake)
Procesamiento: Spark y Hadoop; Consulta: Hive, Trino o Presto; Orquestación: pipelines modernos para automatizar flujos
Arquitecturas: Lambda para batch/híbrido y Kappa para streaming
Decisión según si predominan datos históricos o streaming en tiempo real


Análisis predictivo y prescriptivo (01:15:44)
Progresión analítica: descriptivo a prescriptivo (01:13:35)
Análisis descriptivo: qué está pasando (exploración, gráficos en Pandas)
Primer paso para cualquier pipeline analítico
Análisis diagnóstico: por qué está pasando (correlaciones y clustering)
Correlación tradicional y métodos multivariados más avanzados
Herramientas predictivas y prescriptivas (01:15:44)
Análisis predictivo: regresiones tradicionales y Machine Learning moderno
Modelos comunes: regresión lineal/logística, árboles, random forest, series temporales
Análisis prescriptivo: recomendaciones para la acción; creciente automatización con IA
IA permite que parte del prescriptivo sea automatizado, pero la interpretación humana sigue siendo clave


Métodos comunes en Machine Learning y casos avanzados (01:17:11)
Métodos prácticos y frecuentes (01:17:11)
Técnicas útiles para la mayoría de casos: árboles de clasificación, random forest, clustering, series de tiempo, reglas de asociación
Para el 99% de proyectos estas técnicas son suficientes
Modelos y técnicas adicionales: PCA, SVD, análisis de sentimientos, analítica de texto y redes sociales
Análisis de texto y redes sociales son valiosos para marketing y obtención de insights de clientes
Aplicaciones avanzadas y recomendaciones (01:17:44)
Analítica de texto y redes sociales para extraer valor en marketing
Permiten obtener señales valiosas para empresas comerciales con gran presencia digital
Cuando técnicas simples no funcionan, recurrir a Machine Learning más complejo
Machine Learning puede resolver problemas difíciles, pero requiere diseño y validación rigurosa


Actividades prácticas y ejercicios finales (01:18:29)
Ejercicios asignados y demo de APIs (01:01:40)
Ejercicios para obtener API Keys y usar APIs variadas (Yahoo Finance, OpenMeteo, NewSapi)
Se dejó lista de APIs para macroeconomía, criptomonedas, movilidad e imágenes
Recomendación: probar con demo de bolsas locales o instituciones nacionales cuando existan APIs
En caso de no encontrar API, usar scraping o endpoints dummy para pruebas
Trabajo con datasets grandes y uso de asistentes (01:18:43)
Carga y análisis de datasets grandes (ej. encuestas en Kaggle ~15 MB) para ejercicios de diagnóstico y extracción de insights
Formular hipótesis, responder preguntas y practicar con Pandas; usar ChatGPT/Gemini para obtener código y orientación
Resultado esperado: convertir hallazgos en recomendaciones claras y defendibles frente a la gerencia
Preparar la comunicación de la recomendación y priorizar acciones


De hallazgos a decisiones y recomendaciones estratégicas (01:19:18)
De patrones a priorización (01:20:34)
Proceso: encontrar patrones, extraer hallazgos y priorizar qué información usar para decisiones
Priorizar decisiones de mayor impacto y redactar recomendaciones basadas en datos
Ejemplo práctico: plantear hipótesis sobre encuestas y censos, segmentar por etnicidad, empleo, región
Realizar preguntas concretas para guiar el análisis y obtener resultados accionables
Toma de decisiones y reducción de incertidumbre (01:11:25)
Objetivo principal del Big Data y Data Mining: reducir la incertidumbre para mejorar decisiones estratégicas
Decisiones estratégicas deben tener alto impacto en valor o en el funcionamiento de la empresa
Cuatro B de Big Data: Volumen, Variedad, Velocidad y Veracidad
Tener cuidado con veracidad al interpretar resultados para decisiones estratégicas
Materiales y soporte posterior (01:22:18)
Profesor añadirá notas del curso, cuadernos de Colab y códigos a la plataforma
Compartirá material para práctica y revisión sin necesidad de extraerlo del video
Recordatorio de canales de consulta y formulario de asistencia
Contacto disponible para dudas y soporte posterior