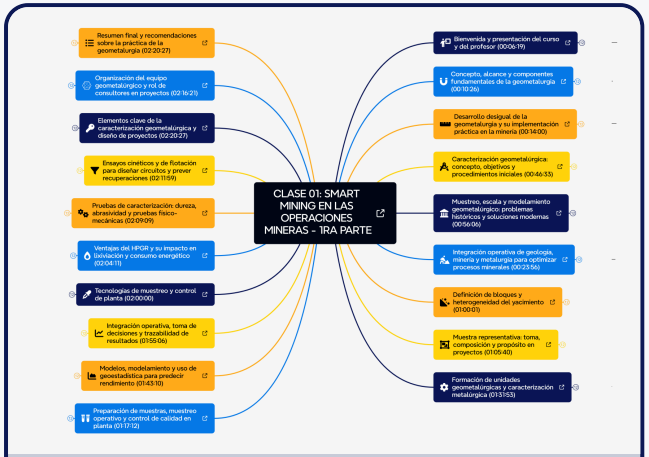
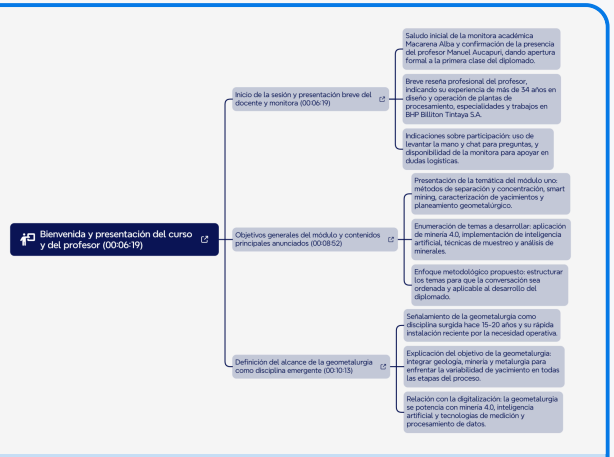
¡APRENDE A USAR TU MAPA MENTAL EN 04 PASOS!

01. Encuentra el tema central



En la **primera página** verás el nombre de la clase y los temas más importantes. Es el punto de partida ideal antes de comenzar.

02. Profundiza en los temas



En las **páginas siguientes**, cada tema se divide en conceptos clave fáciles de seguir. Explora el mapa para entender mejor la información.

03. Ve directo a la explicación



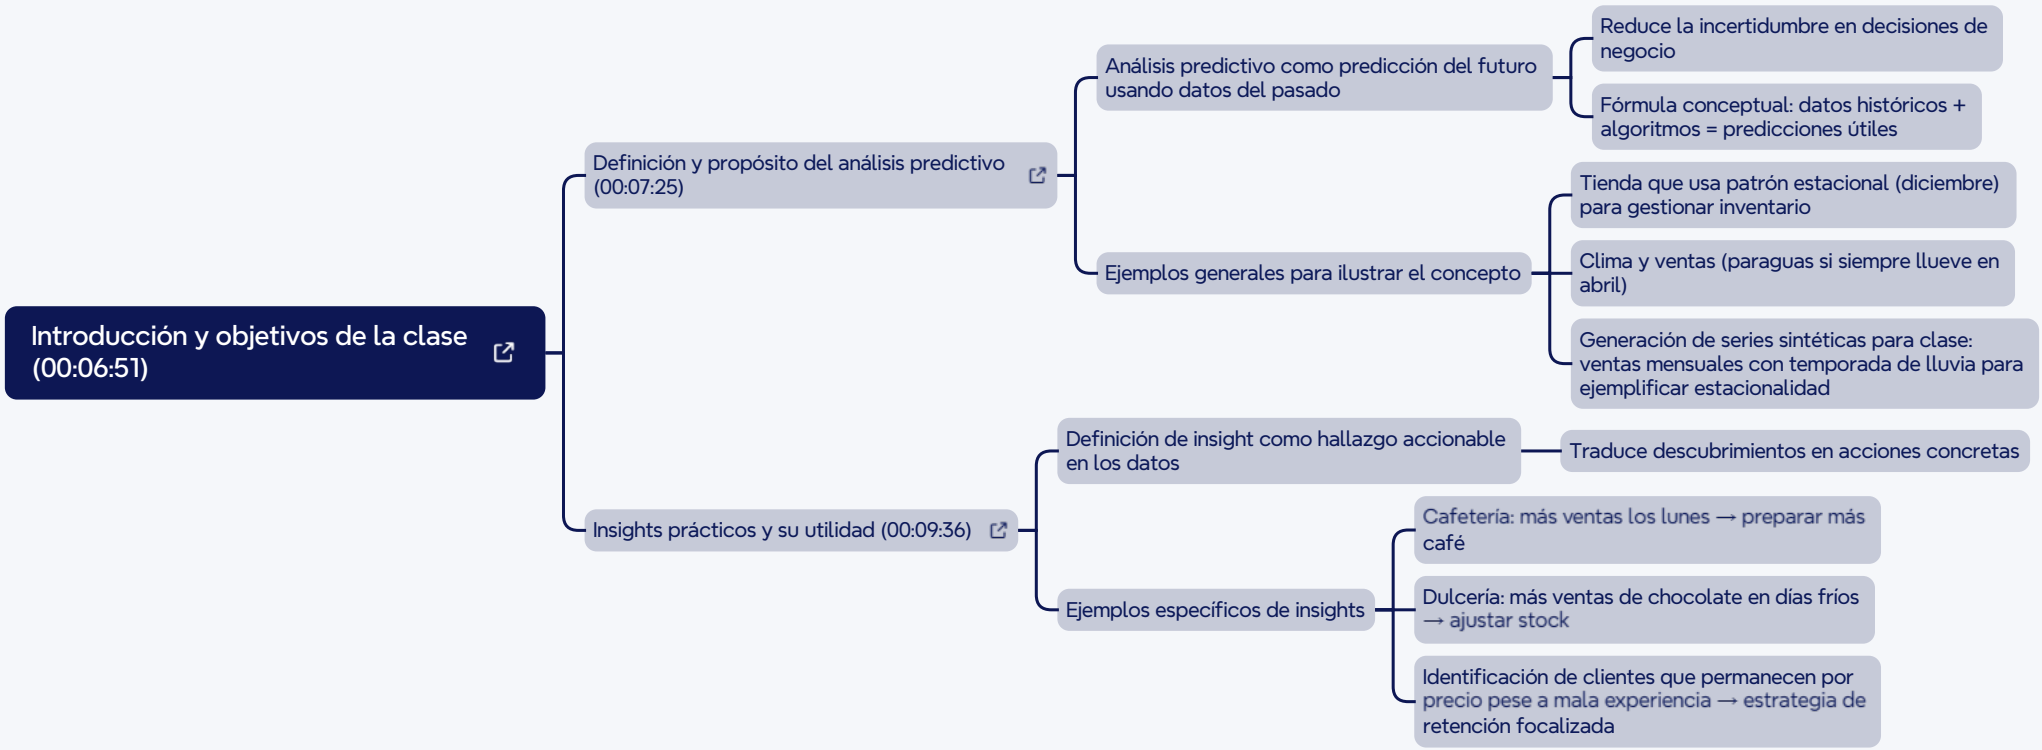
Selecciona este ícono ↗ para ir al **momento exacto** de la clase donde se explica ese punto. Ahorra tiempo gracias a esta función.

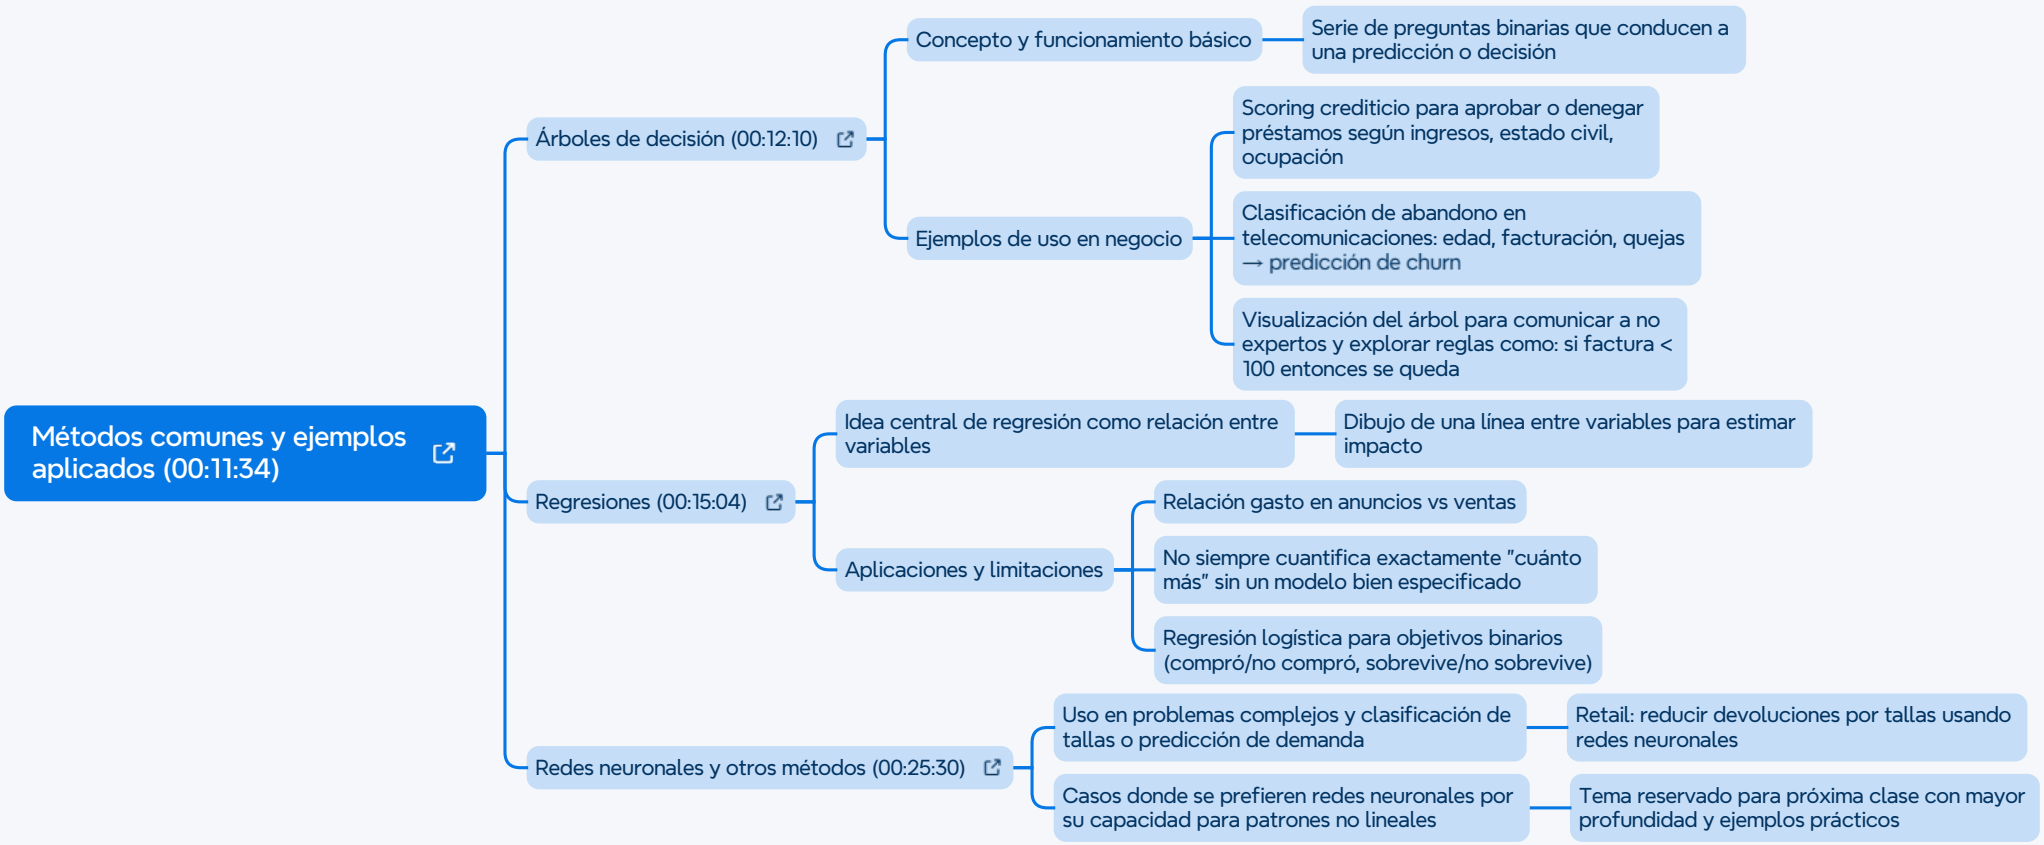
04. Amplía y descarga el mapa

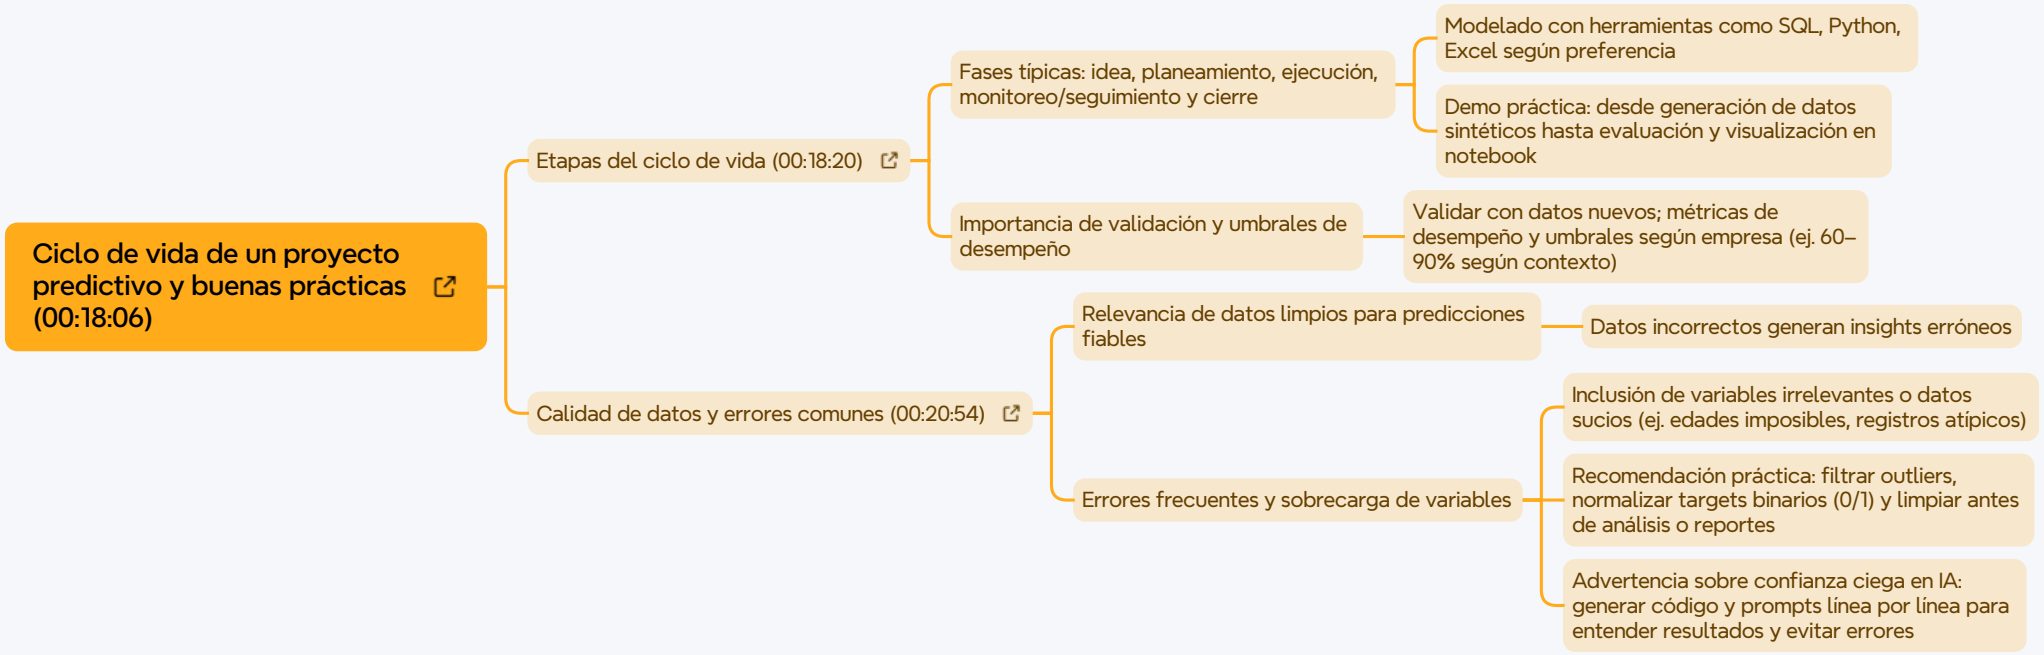
Utiliza el botón de la esquina superior derecha para **agrandar el mapa** y visualizarlo con mayor comodidad. También puedes descargarlo para revisar el contenido en cualquier momento.

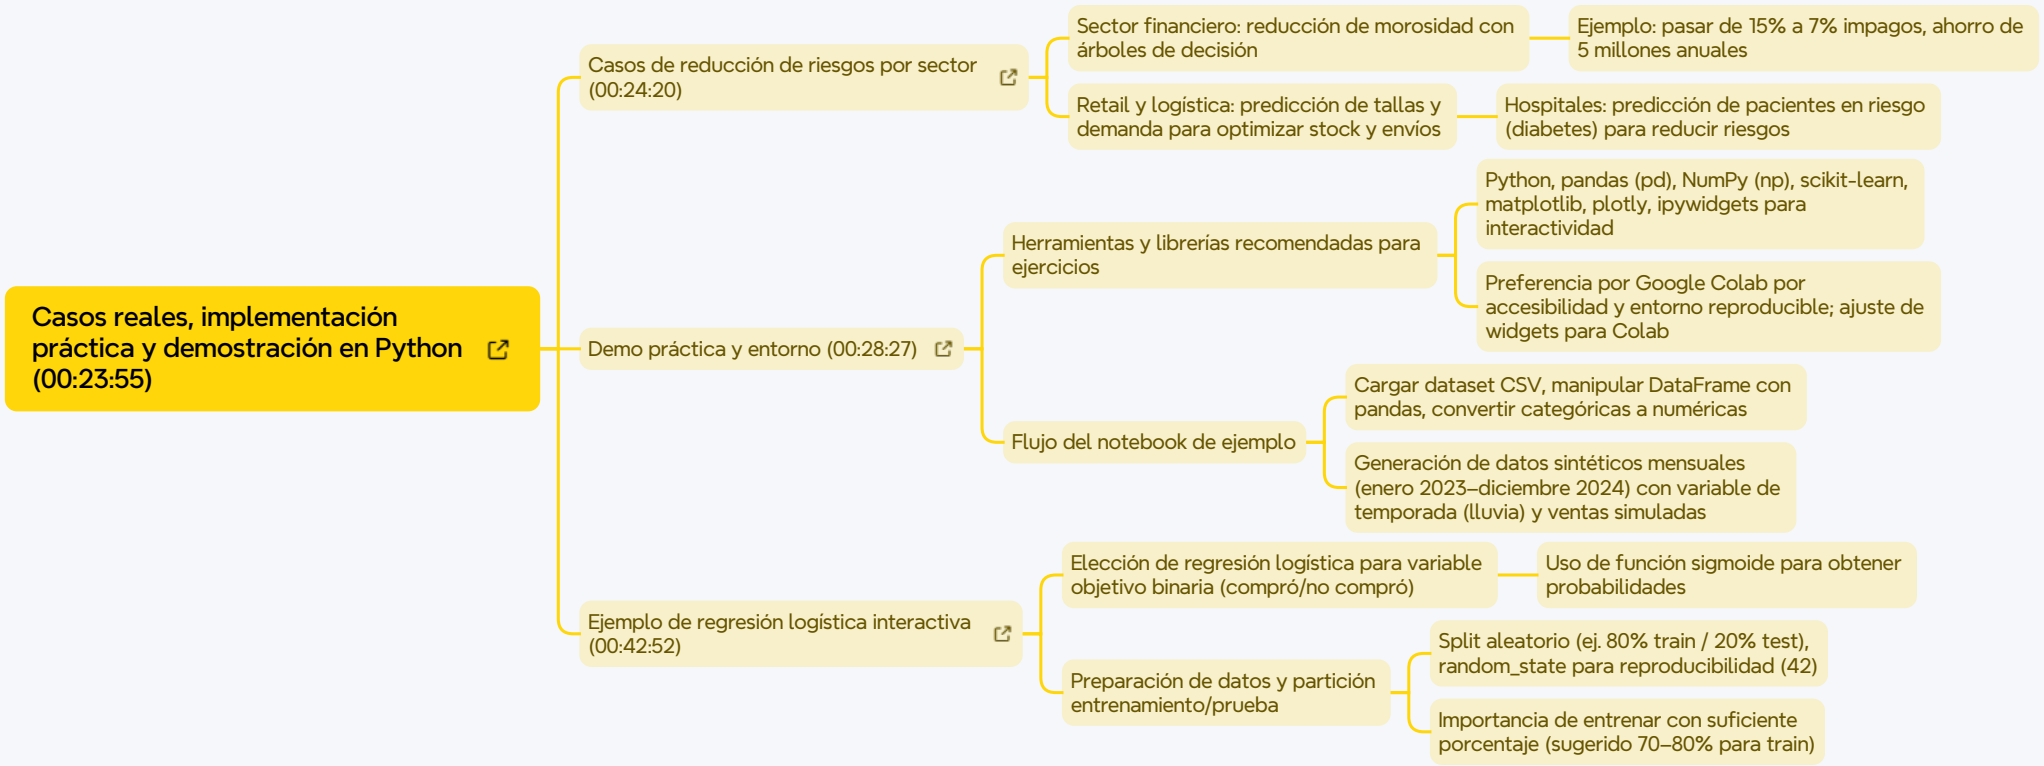
EDU MIN

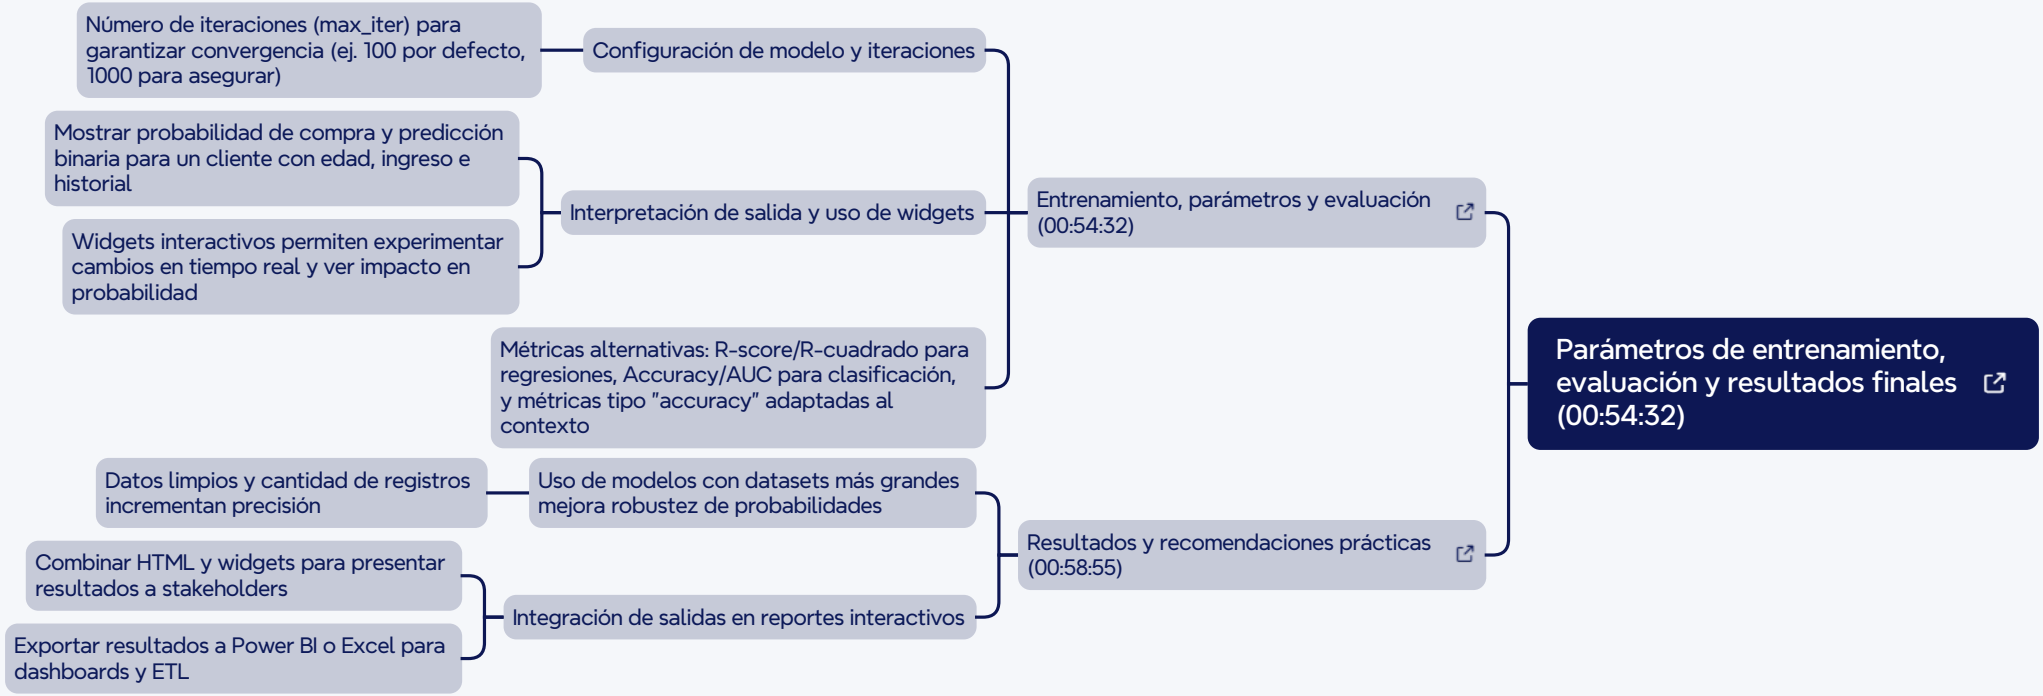

CLASE 09: DOMINANDO EL ANÁLISIS PREDICTIVO PARA DECISIONES INTELIGENTES - 1RA PARTE
Introducción y objetivos de la clase (00:06:51)
15
Métodos comunes y ejemplos aplicados (00:11:34)
19
Ciclo de vida de un proyecto predictivo y buenas prácticas (00:18:06)
13
Casos reales, implementación práctica y demostración en Python (00:23:55)
18
Cierre, tareas y siguientes pasos (01:47:06)
8
Recursos, aprendizaje y recomendaciones profesionales (01:36:22)
9
Ejemplos prácticos adicionales: churn y retail (01:19:19)
9
Ejemplos adicionales y herramientas didácticas (01:00:00)
15
Parámetros de entrenamiento, evaluación y resultados finales (00:54:32)
13


Introducción y objetivos de la clase (00:06:51)
Definición y propósito del análisis predictivo (00:07:25)
Análisis predictivo como predicción del futuro usando datos del pasado
Reduce la incertidumbre en decisiones de negocio
Fórmula conceptual: datos históricos + algoritmos = predicciones útiles
Ejemplos generales para ilustrar el concepto
Tienda que usa patrón estacional (diciembre) para gestionar inventario
Clima y ventas (paraguas si siempre llueve en abril)
Generación de series sintéticas para clase: ventas mensuales con temporada de lluvia para ejemplificar estacionalidad
Insights prácticos y su utilidad (00:09:36)
Definición de insight como hallazgo accionable en los datos
Traduce descubrimientos en acciones concretas
Ejemplos específicos de insights
Cafetería: más ventas los lunes → preparar más café
Dulcería: más ventas de chocolate en días fríos → ajustar stock
Identificación de clientes que permanecen por precio pese a mala experiencia → estrategia de retención focalizada

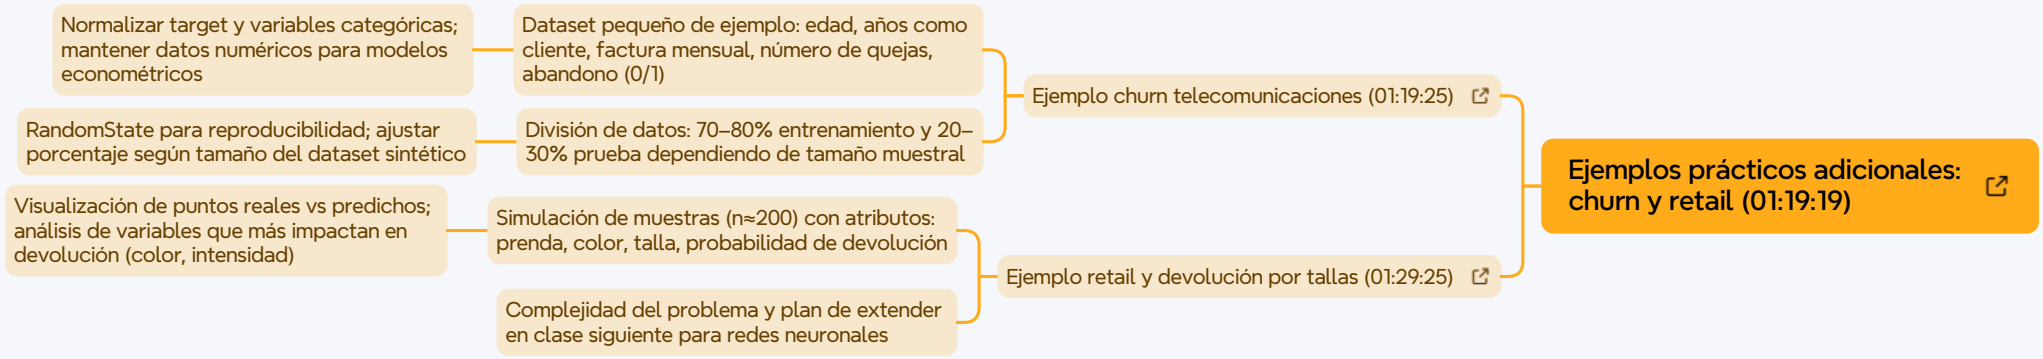

Métodos comunes y ejemplos aplicados (00:11:34)
Árboles de decisión (00:12:10)
Concepto y funcionamiento básico
Serie de preguntas binarias que conducen a una predicción o decisión
Ejemplos de uso en negocio
Scoring crediticio para aprobar o denegar préstamos según ingresos, estado civil, ocupación
Clasificación de abandono en telecomunicaciones: edad, facturación, quejas → predicción de churn
Visualización del árbol para comunicar a no expertos y explorar reglas como: si factura < 100 entonces se queda
Regresiones (00:15:04)
Idea central de regresión como relación entre variables
Dibujo de una línea entre variables para estimar impacto
Aplicaciones y limitaciones
Relación gasto en anuncios vs ventas
No siempre cuantifica exactamente "cuánto más" sin un modelo bien especificado
Regresión logística para objetivos binarios (compró/no compró, sobrevive/no sobrevive)
Redes neuronales y otros métodos (00:25:30)
Uso en problemas complejos y clasificación de tallas o predicción de demanda
Retail: reducir devoluciones por tallas usando redes neuronales
Casos donde se prefieren redes neuronales por su capacidad para patrones no lineales
Tema reservado para próxima clase con mayor profundidad y ejemplos prácticos

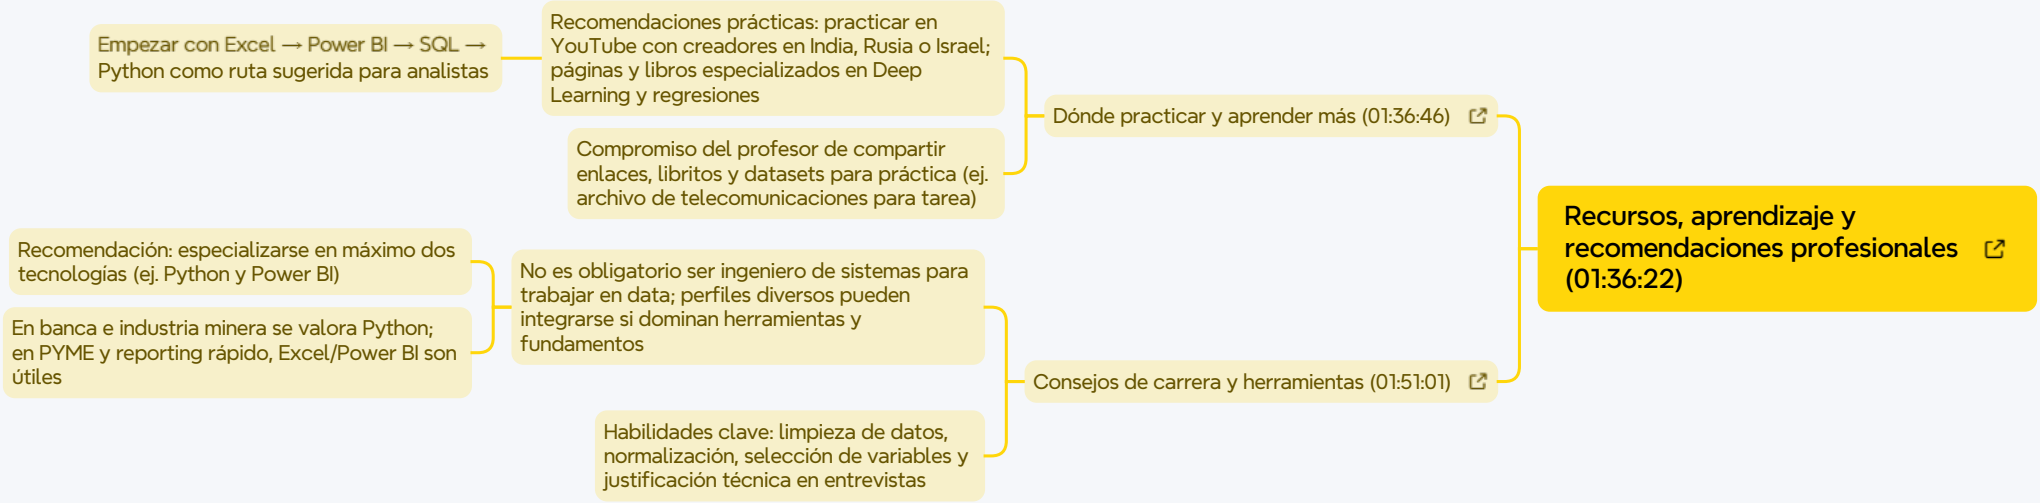

Ciclo de vida de un proyecto predictivo y buenas prácticas (00:18:06)
Etapas del ciclo de vida (00:18:20)
Fases típicas: idea, planeamiento, ejecución, monitoreo/seguimiento y cierre
Modelado con herramientas como SQL, Python, Excel según preferencia
Demo práctica: desde generación de datos sintéticos hasta evaluación y visualización en notebook
Importancia de validación y umbrales de desempeño
Validar con datos nuevos; métricas de desempeño y umbrales según empresa (ej. 60–90% según contexto)
Calidad de datos y errores comunes (00:20:54)
Relevancia de datos limpios para predicciones fiables
Datos incorrectos generan insights erróneos
Errores frecuentes y sobrecarga de variables
Inclusión de variables irrelevantes o datos sucios (ej. edades imposibles, registros atípicos)
Recomendación práctica: filtrar outliers, normalizar targets binarios (0/1) y limpiar antes de análisis o reportes
Advertencia sobre confianza ciega en IA: generar código y prompts línea por línea para entender resultados y evitar errores

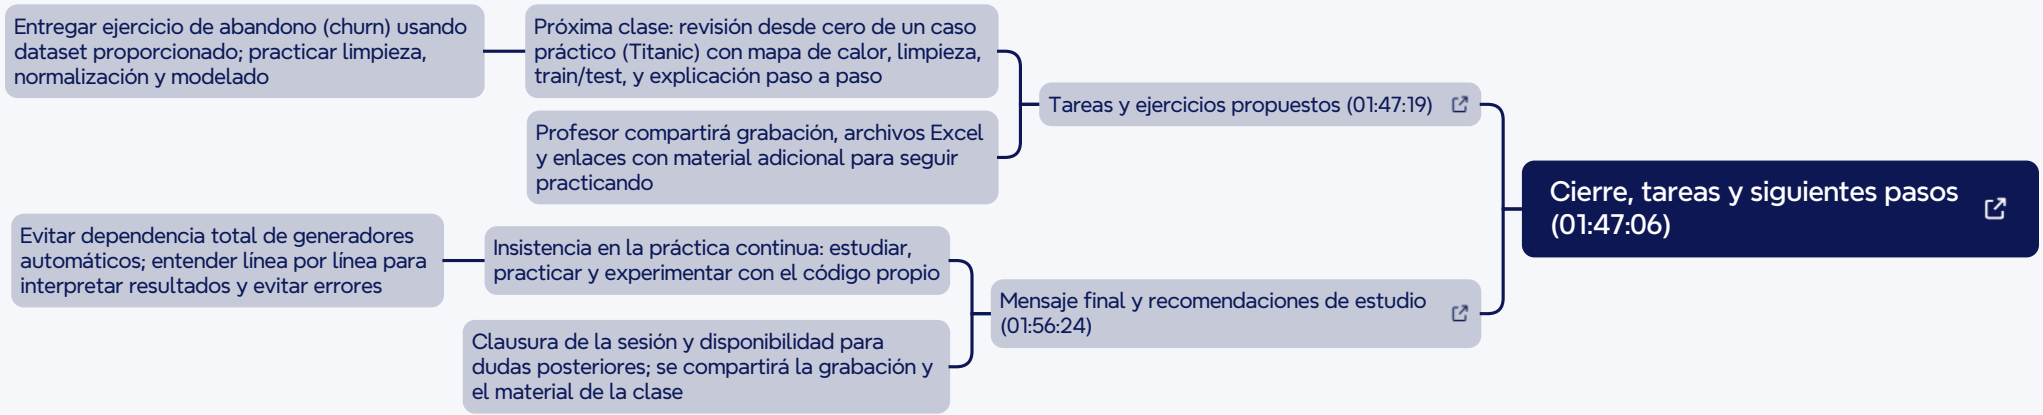

Casos reales, implementación práctica y demostración en Python (00:23:55)
Casos de reducción de riesgos por sector (00:24:20)
Sector financiero: reducción de morosidad con árboles de decisión
Ejemplo: pasar de 15% a 7% impagos, ahorro de 5 millones anuales
Retail y logística: predicción de tallas y demanda para optimizar stock y envíos
Hospitales: predicción de pacientes en riesgo (diabetes) para reducir riesgos
Demo práctica y entorno (00:28:27)
Herramientas y librerías recomendadas para ejercicios
Python, pandas (pd), NumPy (np), scikit-learn, matplotlib, plotly, ipywidgets para interactividad
Preferencia por Google Colab por accesibilidad y entorno reproducible; ajuste de widgets para Colab
Flujo del notebook de ejemplo
Cargar dataset CSV, manipular DataFrame con pandas, convertir categóricas a numéricas
Generación de datos sintéticos mensuales (enero 2023–diciembre 2024) con variable de temporada (lluvia) y ventas simuladas
Ejemplo de regresión logística interactiva (00:42:52)
Elección de regresión logística para variable objetivo binaria (compró/no compró)
Uso de función sigmoide para obtener probabilidades
Preparación de datos y partición entrenamiento/prueba
Split aleatorio (ej. 80% train / 20% test), random_state para reproducibilidad (42)
Importancia de entrenar con suficiente porcentaje (sugerido 70–80% para train)


Parámetros de entrenamiento, evaluación y resultados finales (00:54:32)
Entrenamiento, parámetros y evaluación (00:54:32)
Configuración de modelo y iteraciones
Número de iteraciones (max_iter) para garantizar convergencia (ej. 100 por defecto, 1000 para asegurar)
Interpretación de salida y uso de widgets
Mostrar probabilidad de compra y predicción binaria para un cliente con edad, ingreso e historial
Widgets interactivos permiten experimentar cambios en tiempo real y ver impacto en probabilidad
Métricas alternativas: R-score/R-cuadrado para regresiones, Accuracy/AUC para clasificación, y métricas tipo "accuracy" adaptadas al contexto
Resultados y recomendaciones prácticas (00:58:55)
Uso de modelos con datasets más grandes mejora robustez de probabilidades
Datos limpios y cantidad de registros incrementan precisión
Integración de salidas en reportes interactivos
Combinar HTML y widgets para presentar resultados a stakeholders
Exportar resultados a Power BI o Excel para dashboards y ETL


Ejemplos adicionales y herramientas didácticas (01:00:00)
Generación de datasets sintéticos y lógica de negocio (01:02:00)
Creación de series temporales mensuales con estacionalidad para demostrar efectos de temporada
Extraer mes de fecha, crear variable binaria temporada (ej. diciembre–febrero = 1) y usar distribuciones normales para simular ventas
En temporada lluvia: media 1200, sd 100; fuera de temporada: media 800, sd 80 (valores de ejemplo)
Redondeo de ventas y conversión de categorías a enteros para modelado
Manipulación de data con lambda y funciones vectorizadas para facilitar generación y reproducibilidad
Uso de RandomForest y manejo de outliers (01:08:35)
RandomForest como método no lineal que combina muchos árboles para mejorar precisión y reducir sobreajuste
Robustez frente a outliers y no linealidades; selección aleatoria de subconjuntos de datos y variables
Interpretación práctica de reglas y trade-offs
Ejemplo: cliente con muchas quejas pero baja factura puede permanecer por motivos económicos; modificar facturación en el árbol cambia la predicción
Visualización y widgets para exploración (01:15:00)
Widgets (sliders, selectores) para ajustar hiperparámetros como profundidad máxima del árbol y ver efecto en reglas
Profundidad baja = reglas simples; profundidad alta = reglas complejas que combinan edad, quejas y factura
Librerías para dibujar árboles y la documentación asociada (plot_tree/plotly) para explicar resultados a audiencias no técnicas


Ejemplos prácticos adicionales: churn y retail (01:19:19)
Ejemplo churn telecomunicaciones (01:19:25)
Dataset pequeño de ejemplo: edad, años como cliente, factura mensual, número de quejas, abandono (0/1)
Normalizar target y variables categóricas; mantener datos numéricos para modelos econométricos
División de datos: 70–80% entrenamiento y 20–30% prueba dependiendo de tamaño muestral
RandomState para reproducibilidad; ajustar porcentaje según tamaño del dataset sintético
Ejemplo retail y devolución por tallas (01:29:25)
Simulación de muestras (n≈200) con atributos: prenda, color, talla, probabilidad de devolución
Visualización de puntos reales vs predichos; análisis de variables que más impactan en devolución (color, intensidad)
Complejidad del problema y plan de extender en clase siguiente para redes neuronales


Recursos, aprendizaje y recomendaciones profesionales (01:36:22)
Dónde practicar y aprender más (01:36:46)
Recomendaciones prácticas: practicar en YouTube con creadores en India, Rusia o Israel; páginas y libros especializados en Deep Learning y regresiones
Empezar con Excel → Power BI → SQL → Python como ruta sugerida para analistas
Compromiso del profesor de compartir enlaces, libritos y datasets para práctica (ej. archivo de telecomunicaciones para tarea)
Consejos de carrera y herramientas (01:51:01)
No es obligatorio ser ingeniero de sistemas para trabajar en data; perfiles diversos pueden integrarse si dominan herramientas y fundamentos
Recomendación: especializarse en máximo dos tecnologías (ej. Python y Power BI)
En banca e industria minera se valora Python; en PYME y reporting rápido, Excel/Power BI son útiles
Habilidades clave: limpieza de datos, normalización, selección de variables y justificación técnica en entrevistas


Cierre, tareas y siguientes pasos (01:47:06)
Tareas y ejercicios propuestos (01:47:19)
Próxima clase: revisión desde cero de un caso práctico (Titanic) con mapa de calor, limpieza, train/test, y explicación paso a paso
Entregar ejercicio de abandono (churn) usando dataset proporcionado; practicar limpieza, normalización y modelado
Profesor compartirá grabación, archivos Excel y enlaces con material adicional para seguir practicando
Mensaje final y recomendaciones de estudio (01:56:24)
Insistencia en la práctica continua: estudiar, practicar y experimentar con el código propio
Evitar dependencia total de generadores automáticos; entender línea por línea para interpretar resultados y evitar errores
Clausura de la sesión y disponibilidad para dudas posteriores; se compartirá la grabación y el material de la clase