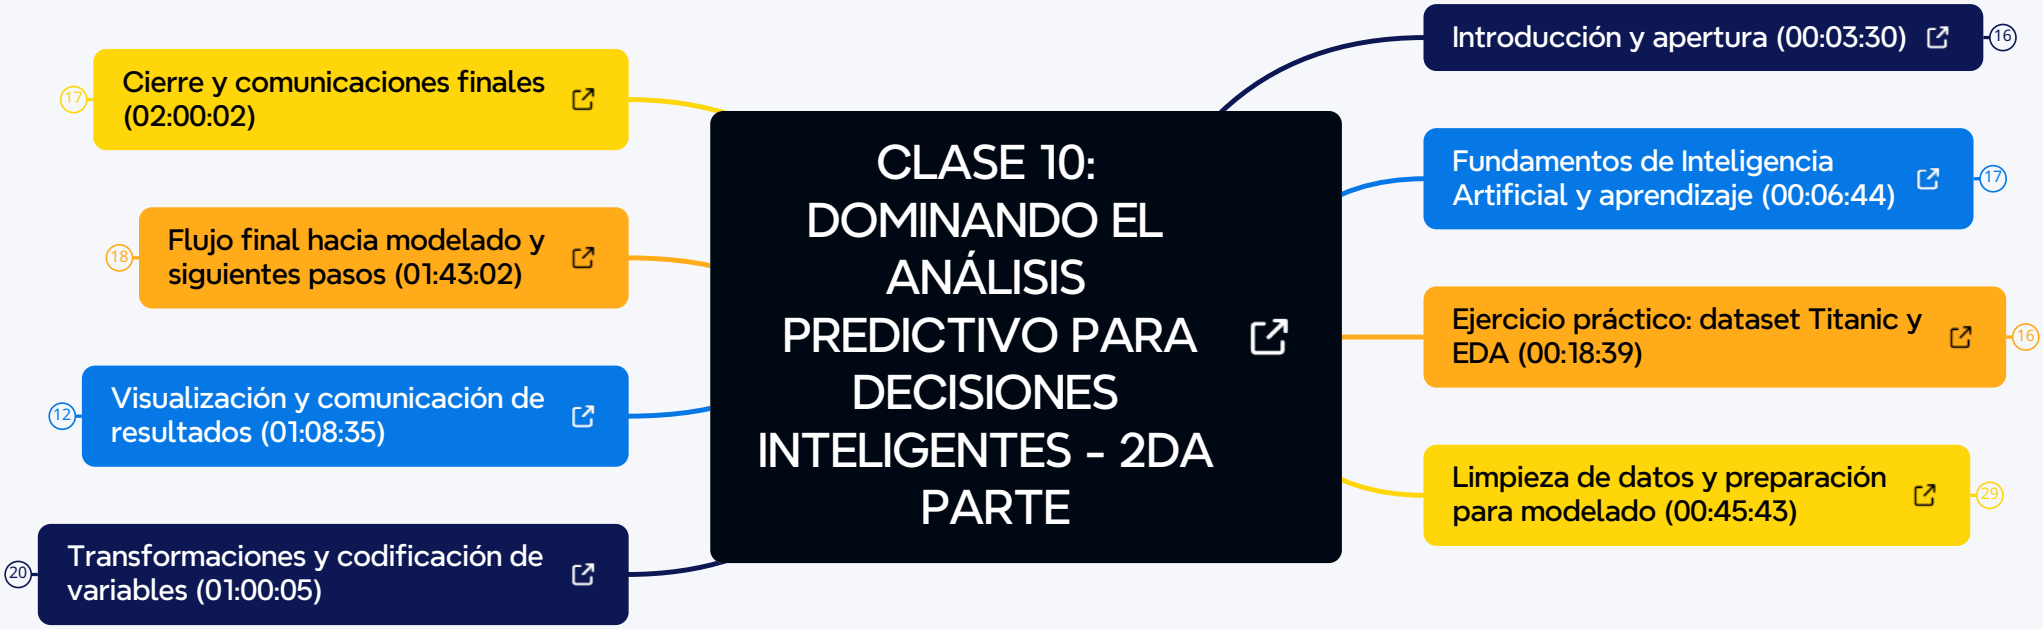
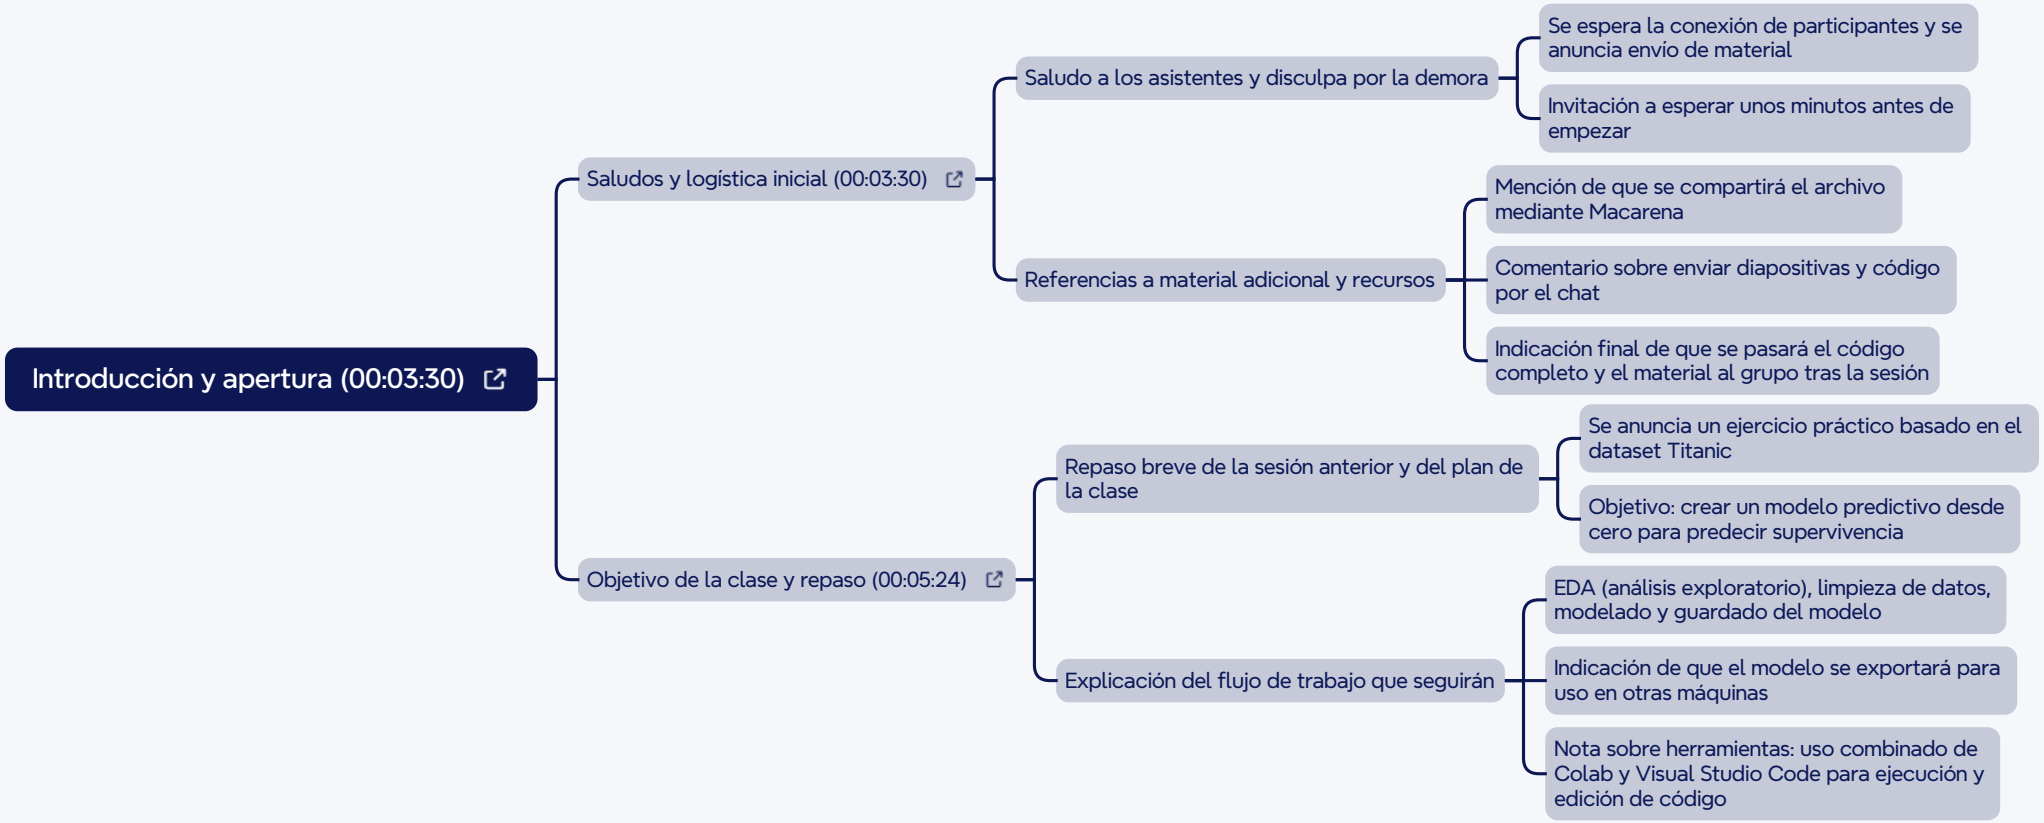
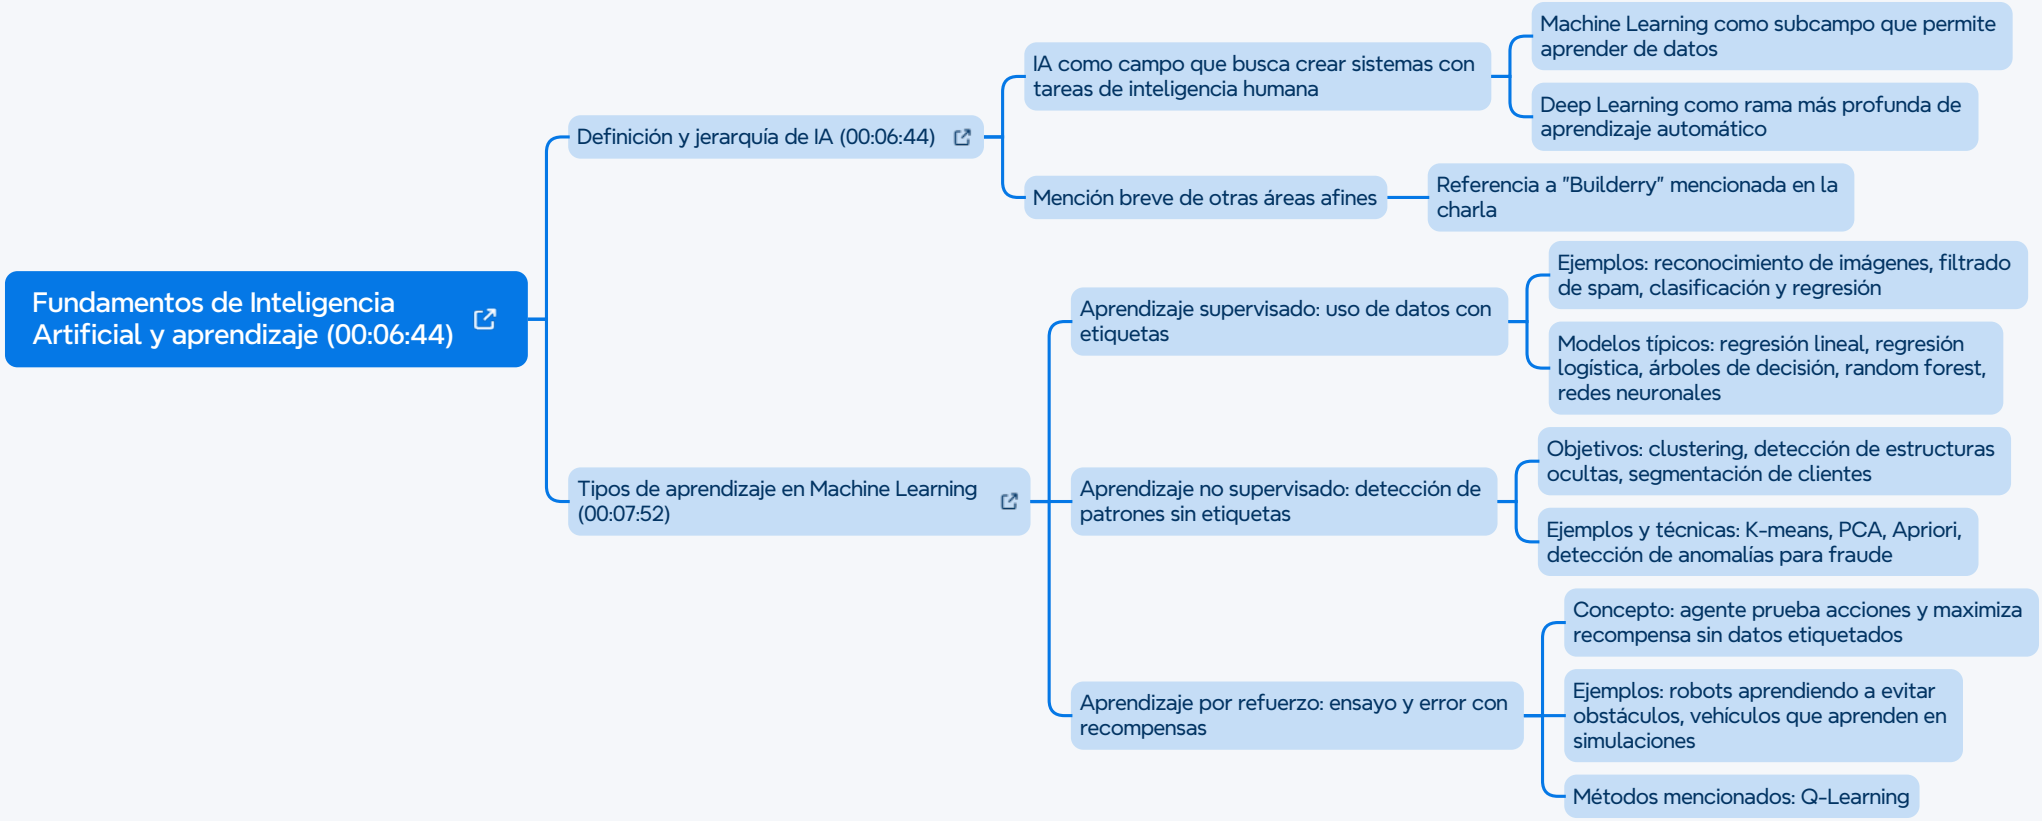
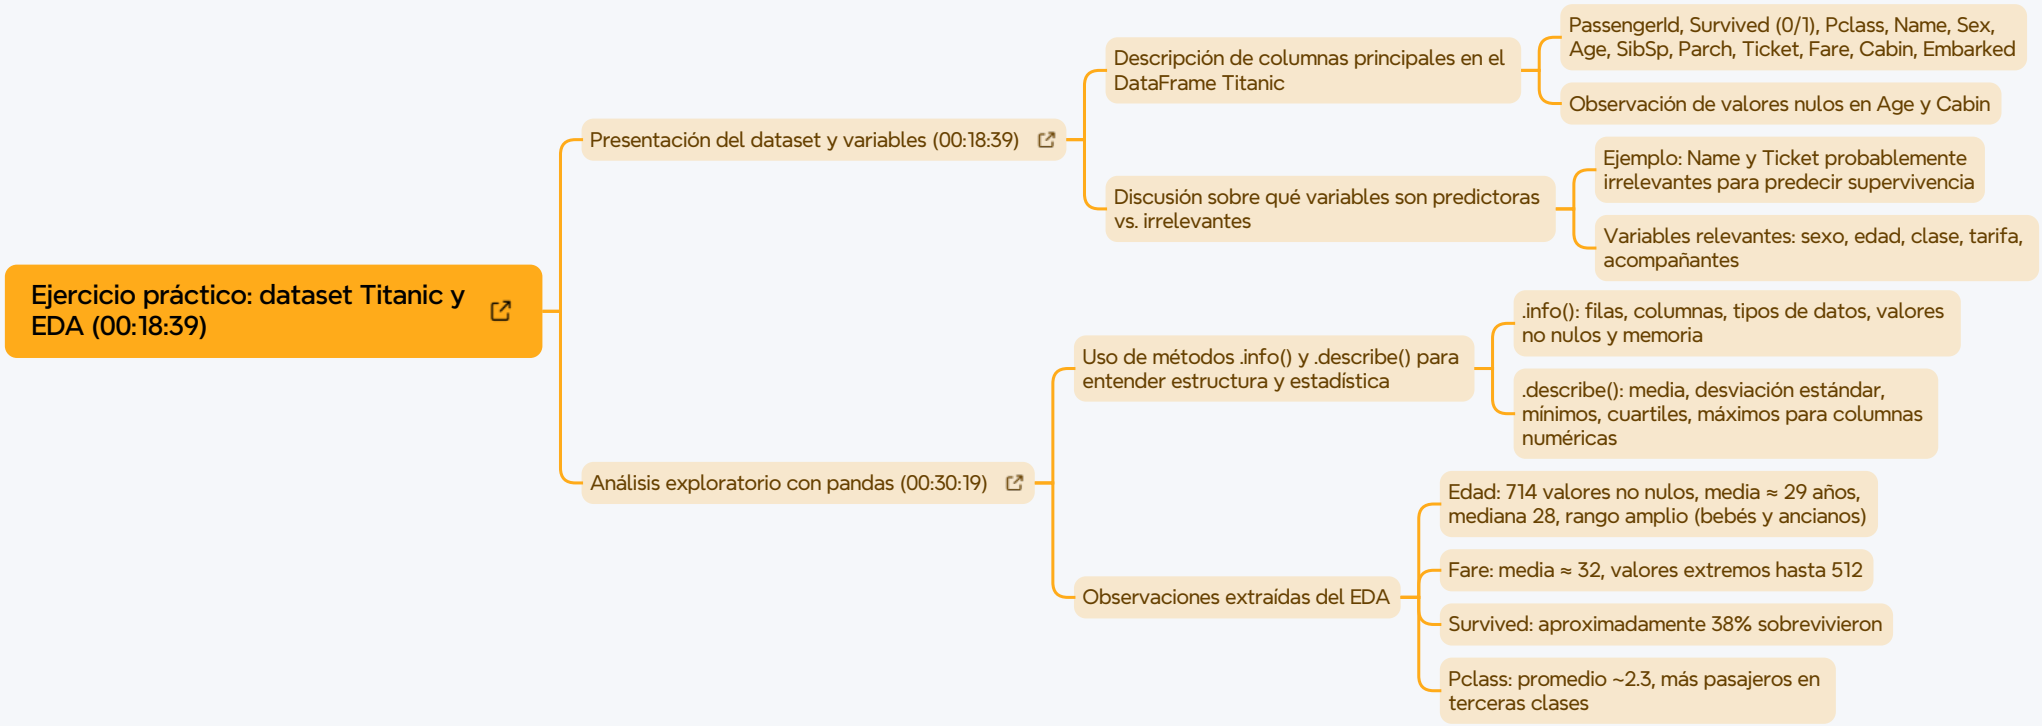
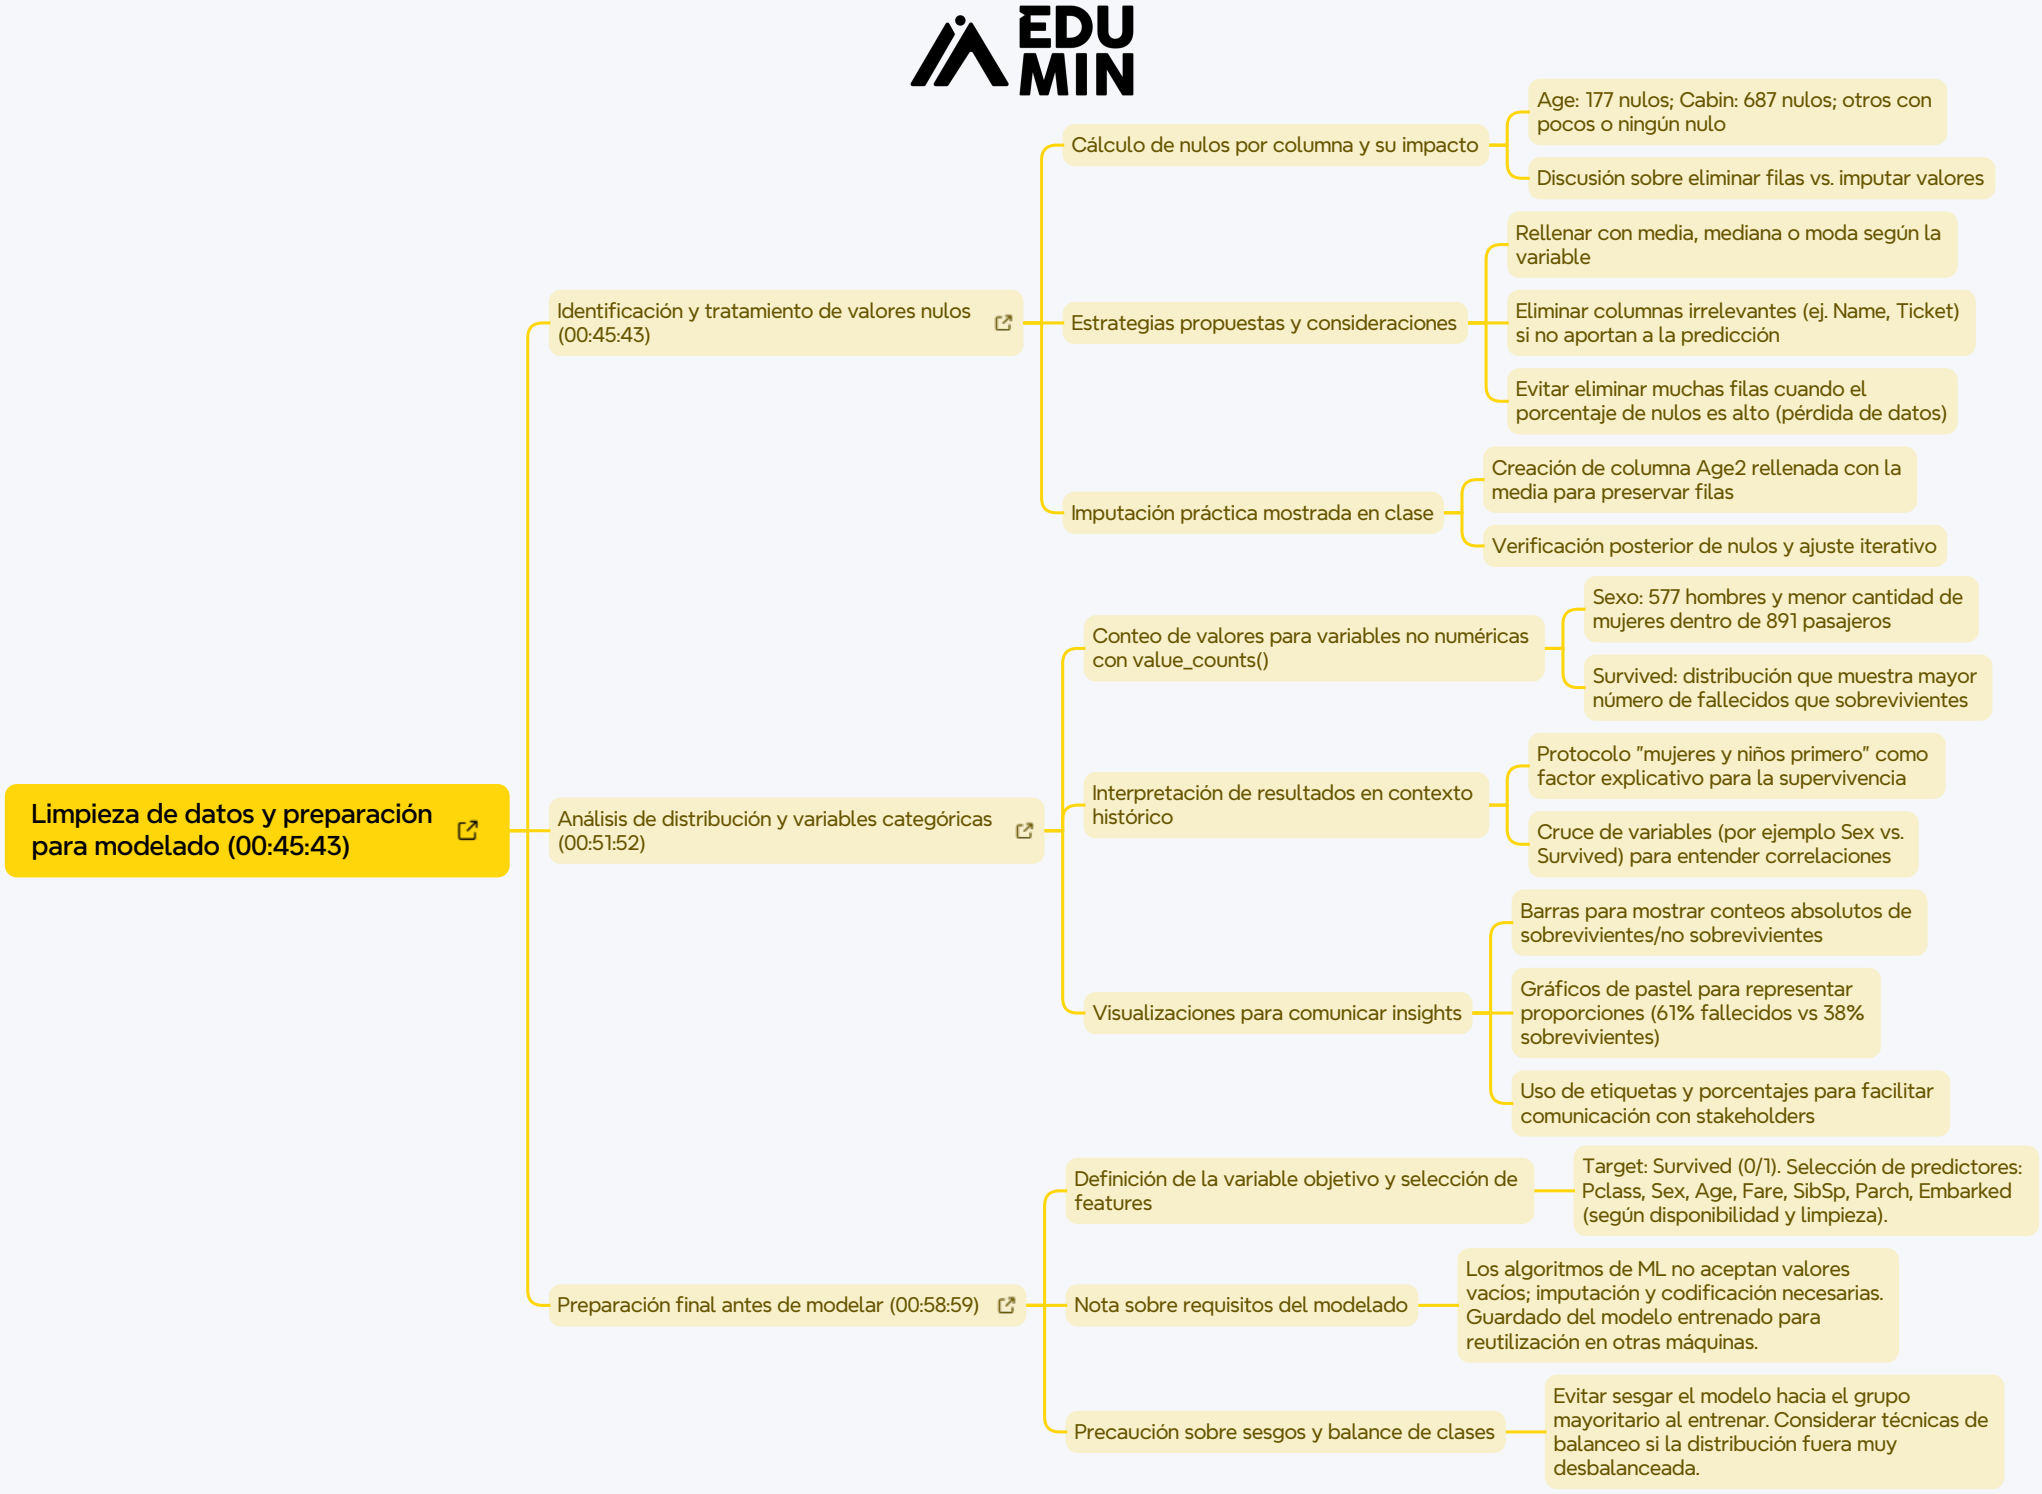
EDU MIN

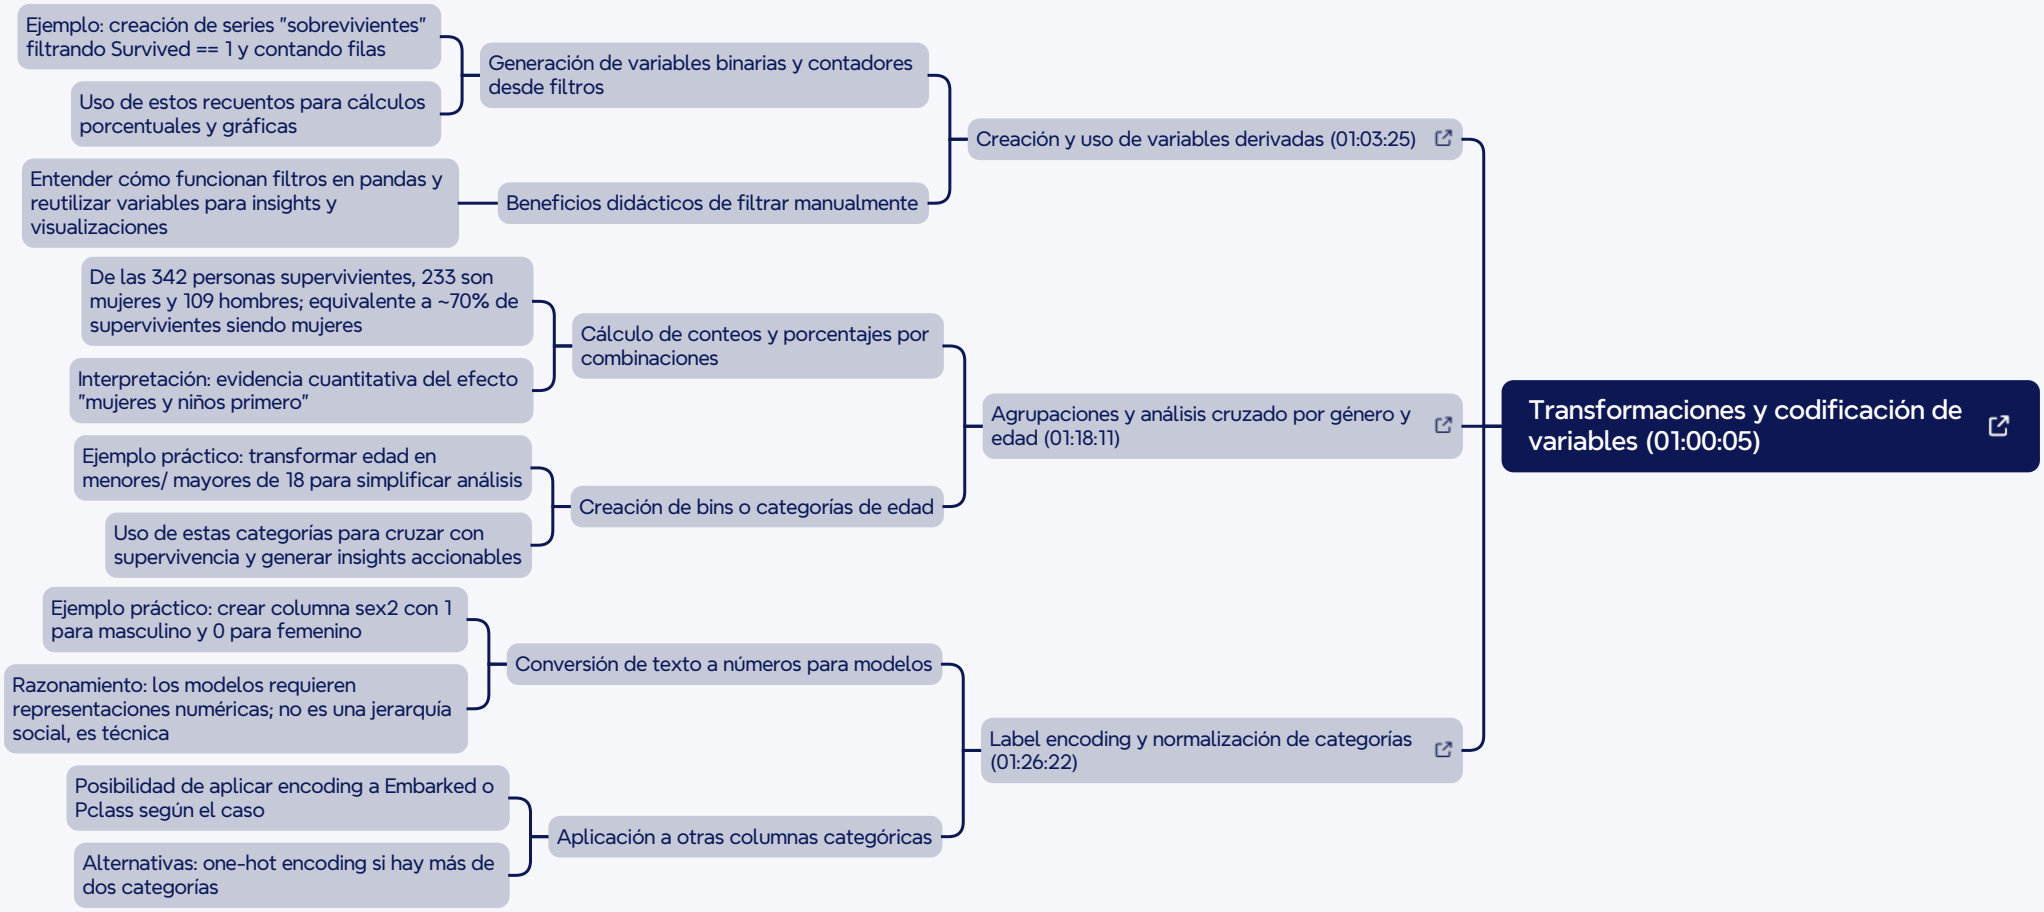

CLASE 10: DOMINANDO EL ANÁLISIS PREDICTIVO PARA DECISIONES INTELIGENTES - 2DA PARTE
Introducción y apertura (00:03:30)
16
Fundamentos de Inteligencia Artificial y aprendizaje (00:06:44)
17
Ejercicio práctico: dataset Titanic y EDA (00:18:39)
16
Limpieza de datos y preparación para modelado (00:45:43)
29
Cierre y comunicaciones finales (02:00:02)
17
Flujo final hacia modelado y siguientes pasos (01:43:02)
18
Visualización y comunicación de resultados (01:08:35)
12
Transformaciones y codificación de variables (01:00:05)
20

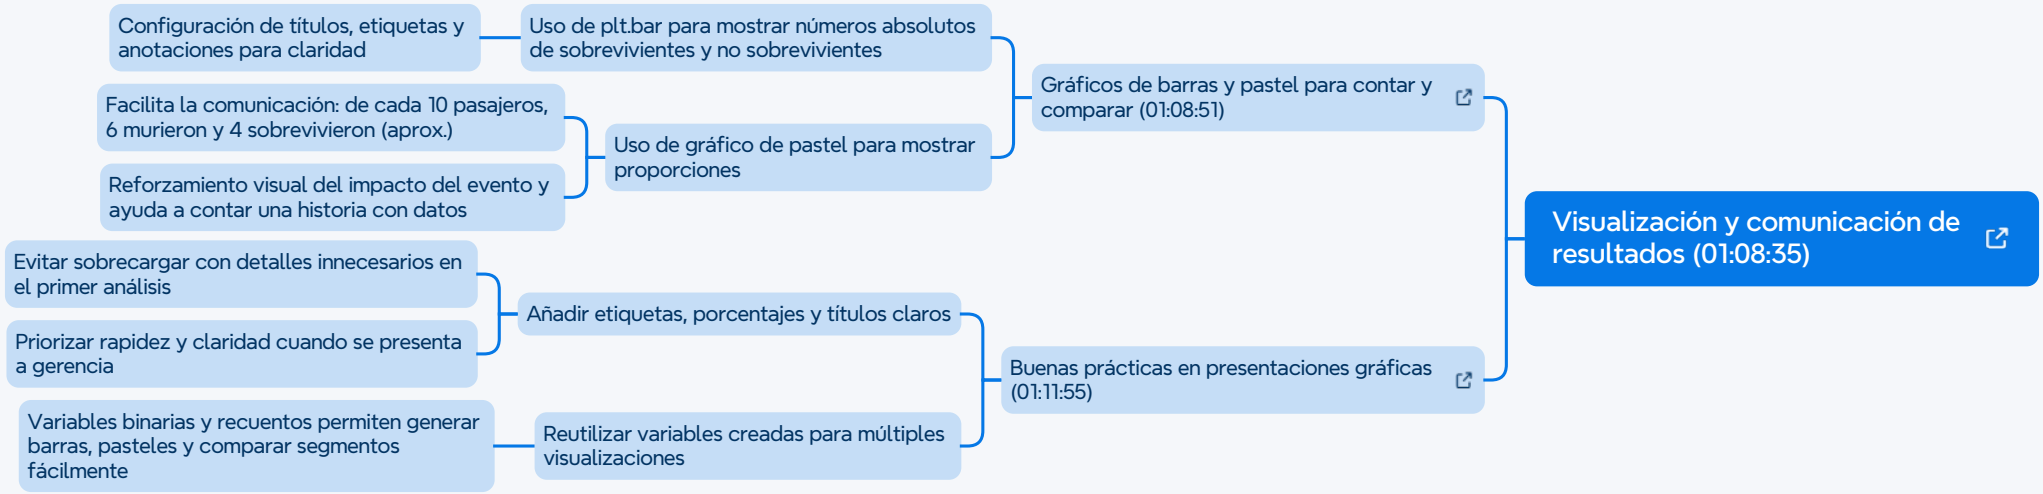

Introducción y apertura (00:03:30)
Saludos y logística inicial (00:03:30)
Saludo a los asistentes y disculpa por la demora
Se espera la conexión de participantes y se anuncia envío de material
Invitación a esperar unos minutos antes de empezar
Referencias a material adicional y recursos
Mención de que se compartirá el archivo mediante Macarena
Comentario sobre enviar diapositivas y código por el chat
Indicación final de que se pasará el código completo y el material al grupo tras la sesión
Objetivo de la clase y repaso (00:05:24)
Repaso breve de la sesión anterior y del plan de la clase
Se anuncia un ejercicio práctico basado en el dataset Titanic
Objetivo: crear un modelo predictivo desde cero para predecir supervivencia
Explicación del flujo de trabajo que seguirán
EDA (análisis exploratorio), limpieza de datos, modelado y guardado del modelo
Indicación de que el modelo se exportará para uso en otras máquinas
Nota sobre herramientas: uso combinado de Colab y Visual Studio Code para ejecución y edición de código

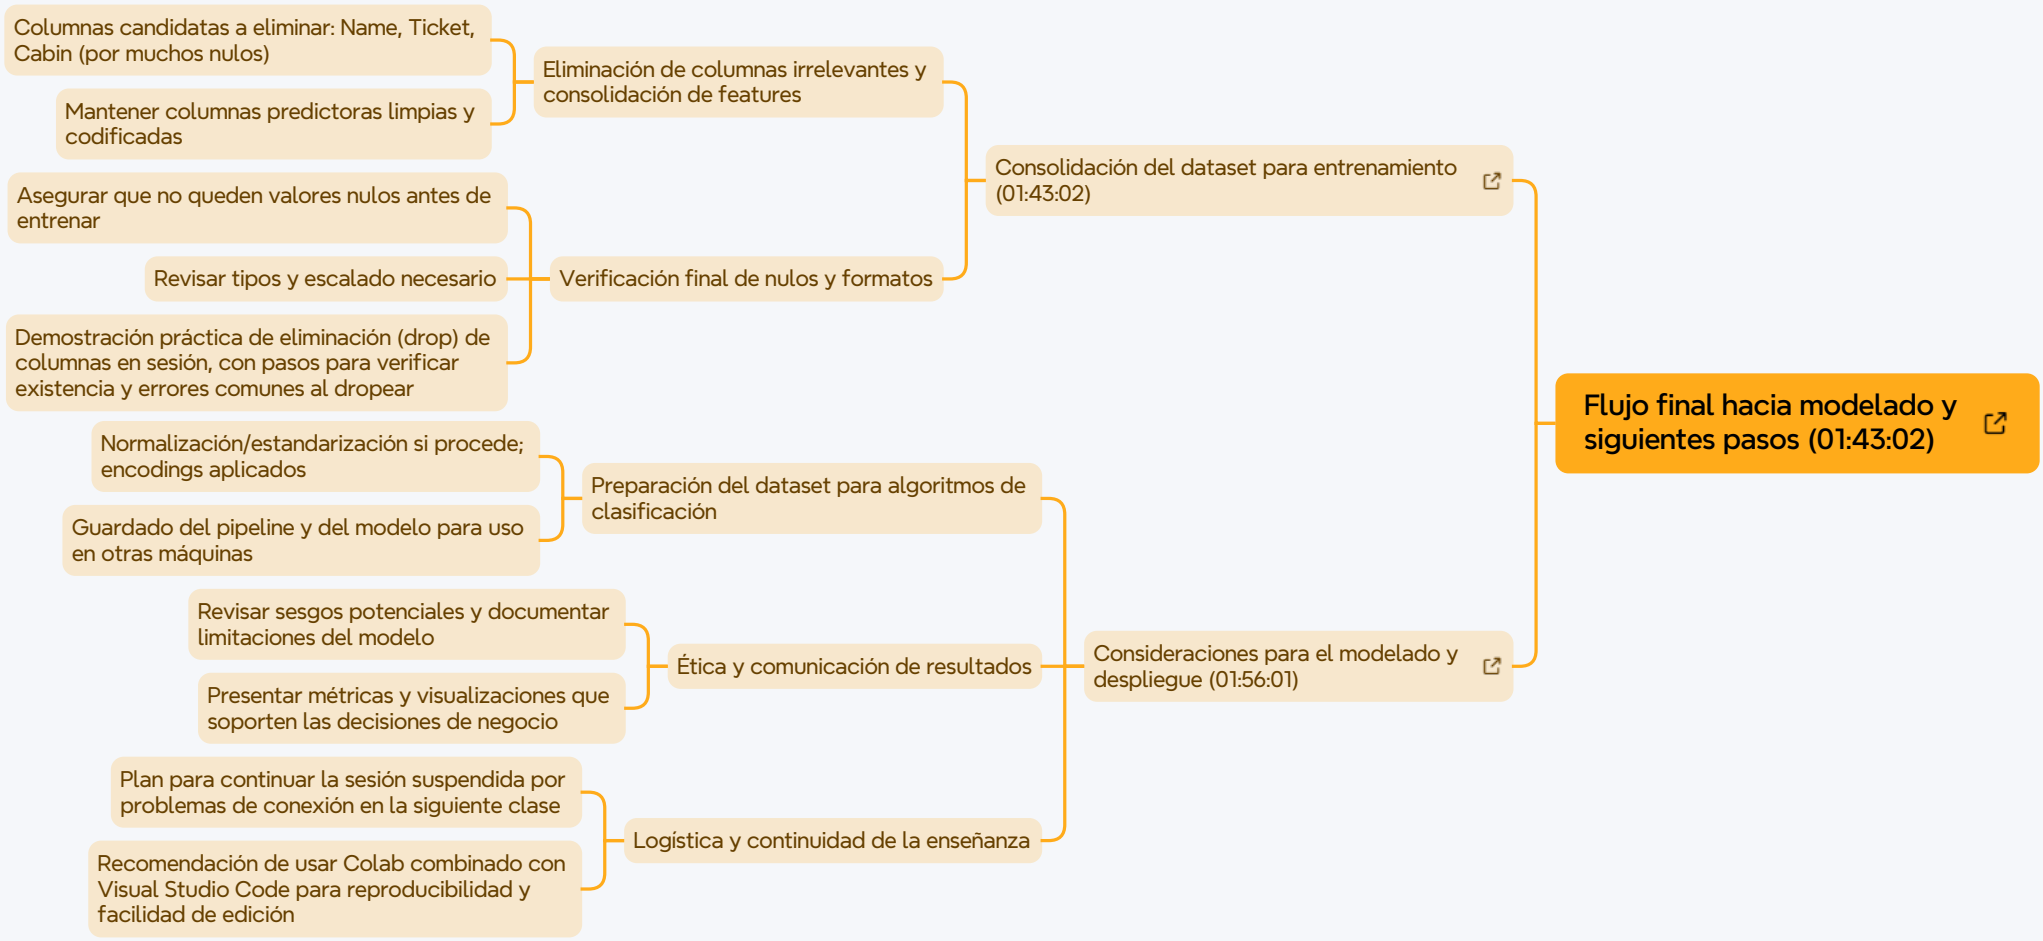

Fundamentos de Inteligencia Artificial y aprendizaje (00:06:44)
Definición y jerarquía de IA (00:06:44)
IA como campo que busca crear sistemas con tareas de inteligencia humana
Machine Learning como subcampo que permite aprender de datos
Deep Learning como rama más profunda de aprendizaje automático
Mención breve de otras áreas afines
Referencia a "Builderry" mencionada en la charla
Tipos de aprendizaje en Machine Learning (00:07:52)
Aprendizaje supervisado: uso de datos con etiquetas
Ejemplos: reconocimiento de imágenes, filtrado de spam, clasificación y regresión
Modelos típicos: regresión lineal, regresión logística, árboles de decisión, random forest, redes neuronales
Aprendizaje no supervisado: detección de patrones sin etiquetas
Objetivos: clustering, detección de estructuras ocultas, segmentación de clientes
Ejemplos y técnicas: K-means, PCA, Apriori, detección de anomalías para fraude
Aprendizaje por refuerzo: ensayo y error con recompensas
Concepto: agente prueba acciones y maximiza recompensa sin datos etiquetados
Ejemplos: robots aprendiendo a evitar obstáculos, vehículos que aprenden en simulaciones
Métodos mencionados: Q-Learning

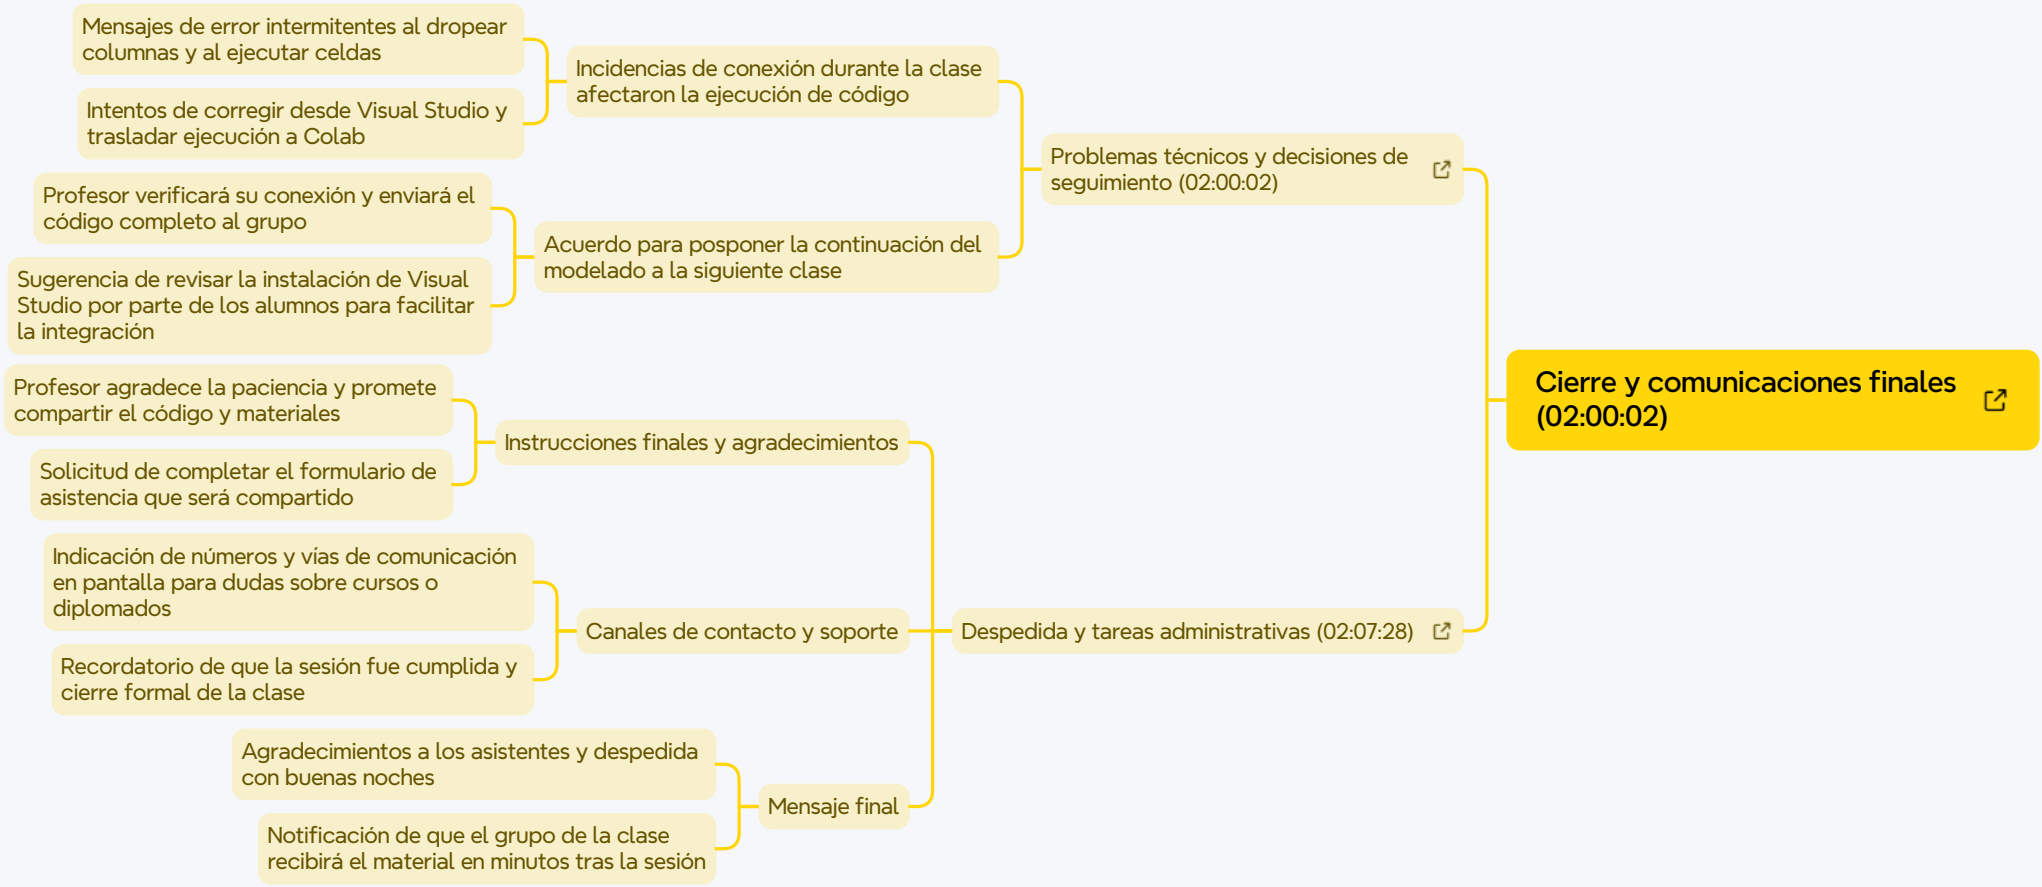

Ejercicio práctico: dataset Titanic y EDA (00:18:39)
Presentación del dataset y variables (00:18:39)
Descripción de columnas principales en el DataFrame Titanic
PassengerId, Survived (0/1), Pclass, Name, Sex, Age, SibSp, Parch, Ticket, Fare, Cabin, Embarked
Observación de valores nulos en Age y Cabin
Discusión sobre qué variables son predictoras vs. irrelevantes
Ejemplo: Name y Ticket probablemente irrelevantes para predecir supervivencia
Variables relevantes: sexo, edad, clase, tarifa, acompañantes
Análisis exploratorio con pandas (00:30:19)
Uso de métodos .info() y .describe() para entender estructura y estadística
.info(): filas, columnas, tipos de datos, valores no nulos y memoria
.describe(): media, desviación estándar, mínimos, cuartiles, máximos para columnas numéricas
Observaciones extraídas del EDA
Edad: 714 valores no nulos, media ≈ 29 años, mediana 28, rango amplio (bebés y ancianos)
Fare: media ≈ 32, valores extremos hasta 512
Survived: aproximadamente 38% sobrevivieron
Pclass: promedio ~2.3, más pasajeros en terceras clases


Limpieza de datos y preparación para modelado (00:45:43)
Identificación y tratamiento de valores nulos (00:45:43)
Cálculo de nulos por columna y su impacto
Age: 177 nulos; Cabin: 687 nulos; otros con pocos o ningún nulo
Discusión sobre eliminar filas vs. imputar valores
Estrategias propuestas y consideraciones
Rellenar con media, mediana o moda según la variable
Eliminar columnas irrelevantes (ej. Name, Ticket) si no aportan a la predicción
Evitar eliminar muchas filas cuando el porcentaje de nulos es alto (pérdida de datos)
Imputación práctica mostrada en clase
Creación de columna Age2 rellenada con la media para preservar filas
Verificación posterior de nulos y ajuste iterativo
Análisis de distribución y variables categóricas (00:51:52)
Conteo de valores para variables no numéricas con value_counts()
Sexo: 577 hombres y menor cantidad de mujeres dentro de 891 pasajeros
Survived: distribución que muestra mayor número de fallecidos que sobrevivientes
Interpretación de resultados en contexto histórico
Protocolo "mujeres y niños primero" como factor explicativo para la supervivencia
Cruce de variables (por ejemplo Sex vs. Survived) para entender correlaciones
Visualizaciones para comunicar insights
Barras para mostrar conteos absolutos de sobrevivientes/no sobrevivientes
Gráficos de pastel para representar proporciones (61% fallecidos vs 38% sobrevivientes)
Uso de etiquetas y porcentajes para facilitar comunicación con stakeholders
Preparación final antes de modelar (00:58:59)
Definición de la variable objetivo y selección de features
Target: Survived (0/1). Selección de predictores: Pclass, Sex, Age, Fare, SibSp, Parch, Embarked (según disponibilidad y limpieza).
Nota sobre requisitos del modelado
Los algoritmos de ML no aceptan valores vacíos; imputación y codificación necesarias. Guardado del modelo entrenado para reutilización en otras máquinas.
Precaución sobre sesgos y balance de clases
Evitar sesgar el modelo hacia el grupo mayoritario al entrenar. Considerar técnicas de balanceo si la distribución fuera muy desbalanceada.


Transformaciones y codificación de variables (01:00:05)
Creación y uso de variables derivadas (01:03:25)
Generación de variables binarias y contadores desde filtros
Ejemplo: creación de series "sobrevivientes" filtrando Survived == 1 y contando filas
Uso de estos recuentos para cálculos porcentuales y gráficas
Beneficios didácticos de filtrar manualmente
Entender cómo funcionan filtros en pandas y reutilizar variables para insights y visualizaciones
Agrupaciones y análisis cruzado por género y edad (01:18:11)
Cálculo de conteos y porcentajes por combinaciones
De las 342 personas supervivientes, 233 son mujeres y 109 hombres; equivalente a ~70% de supervivientes siendo mujeres
Interpretación: evidencia cuantitativa del efecto "mujeres y niños primero"
Creación de bins o categorías de edad
Ejemplo práctico: transformar edad en menores/ mayores de 18 para simplificar análisis
Uso de estas categorías para cruzar con supervivencia y generar insights accionables
Label encoding y normalización de categorías (01:26:22)
Conversión de texto a números para modelos
Ejemplo práctico: crear columna sex2 con 1 para masculino y 0 para femenino
Razonamiento: los modelos requieren representaciones numéricas; no es una jerarquía social, es técnica
Aplicación a otras columnas categóricas
Posibilidad de aplicar encoding a Embarked o Pclass según el caso
Alternativas: one-hot encoding si hay más de dos categorías


Visualización y comunicación de resultados (01:08:35)
Gráficos de barras y pastel para contar y comparar (01:08:51)
Uso de plt.bar para mostrar números absolutos de sobrevivientes y no sobrevivientes
Configuración de títulos, etiquetas y anotaciones para claridad
Uso de gráfico de pastel para mostrar proporciones
Facilita la comunicación: de cada 10 pasajeros, 6 murieron y 4 sobrevivieron (aprox.)
Reforzamiento visual del impacto del evento y ayuda a contar una historia con datos
Buenas prácticas en presentaciones gráficas (01:11:55)
Añadir etiquetas, porcentajes y títulos claros
Evitar sobrecargar con detalles innecesarios en el primer análisis
Priorizar rapidez y claridad cuando se presenta a gerencia
Reutilizar variables creadas para múltiples visualizaciones
Variables binarias y recuentos permiten generar barras, pasteles y comparar segmentos fácilmente


Flujo final hacia modelado y siguientes pasos (01:43:02)
Consolidación del dataset para entrenamiento (01:43:02)
Eliminación de columnas irrelevantes y consolidación de features
Columnas candidatas a eliminar: Name, Ticket, Cabin (por muchos nulos)
Mantener columnas predictoras limpias y codificadas
Verificación final de nulos y formatos
Asegurar que no queden valores nulos antes de entrenar
Revisar tipos y escalado necesario
Demostración práctica de eliminación (drop) de columnas en sesión, con pasos para verificar existencia y errores comunes al dropear
Consideraciones para el modelado y despliegue (01:56:01)
Preparación del dataset para algoritmos de clasificación
Normalización/estandarización si procede; encodings aplicados
Guardado del pipeline y del modelo para uso en otras máquinas
Ética y comunicación de resultados
Revisar sesgos potenciales y documentar limitaciones del modelo
Presentar métricas y visualizaciones que soporten las decisiones de negocio
Logística y continuidad de la enseñanza
Plan para continuar la sesión suspendida por problemas de conexión en la siguiente clase
Recomendación de usar Colab combinado con Visual Studio Code para reproducibilidad y facilidad de edición


Cierre y comunicaciones finales (02:00:02)
Problemas técnicos y decisiones de seguimiento (02:00:02)
Incidencias de conexión durante la clase afectaron la ejecución de código
Mensajes de error intermitentes al dropear columnas y al ejecutar celdas
Intentos de corregir desde Visual Studio y trasladar ejecución a Colab
Acuerdo para posponer la continuación del modelado a la siguiente clase
Profesor verificará su conexión y enviará el código completo al grupo
Sugerencia de revisar la instalación de Visual Studio por parte de los alumnos para facilitar la integración
Despedida y tareas administrativas (02:07:28)
Instrucciones finales y agradecimientos
Profesor agradece la paciencia y promete compartir el código y materiales
Solicitud de completar el formulario de asistencia que será compartido
Canales de contacto y soporte
Indicación de números y vías de comunicación en pantalla para dudas sobre cursos o diplomados
Recordatorio de que la sesión fue cumplida y cierre formal de la clase
Mensaje final
Agradecimientos a los asistentes y despedida con buenas noches
Notificación de que el grupo de la clase recibirá el material en minutos tras la sesión