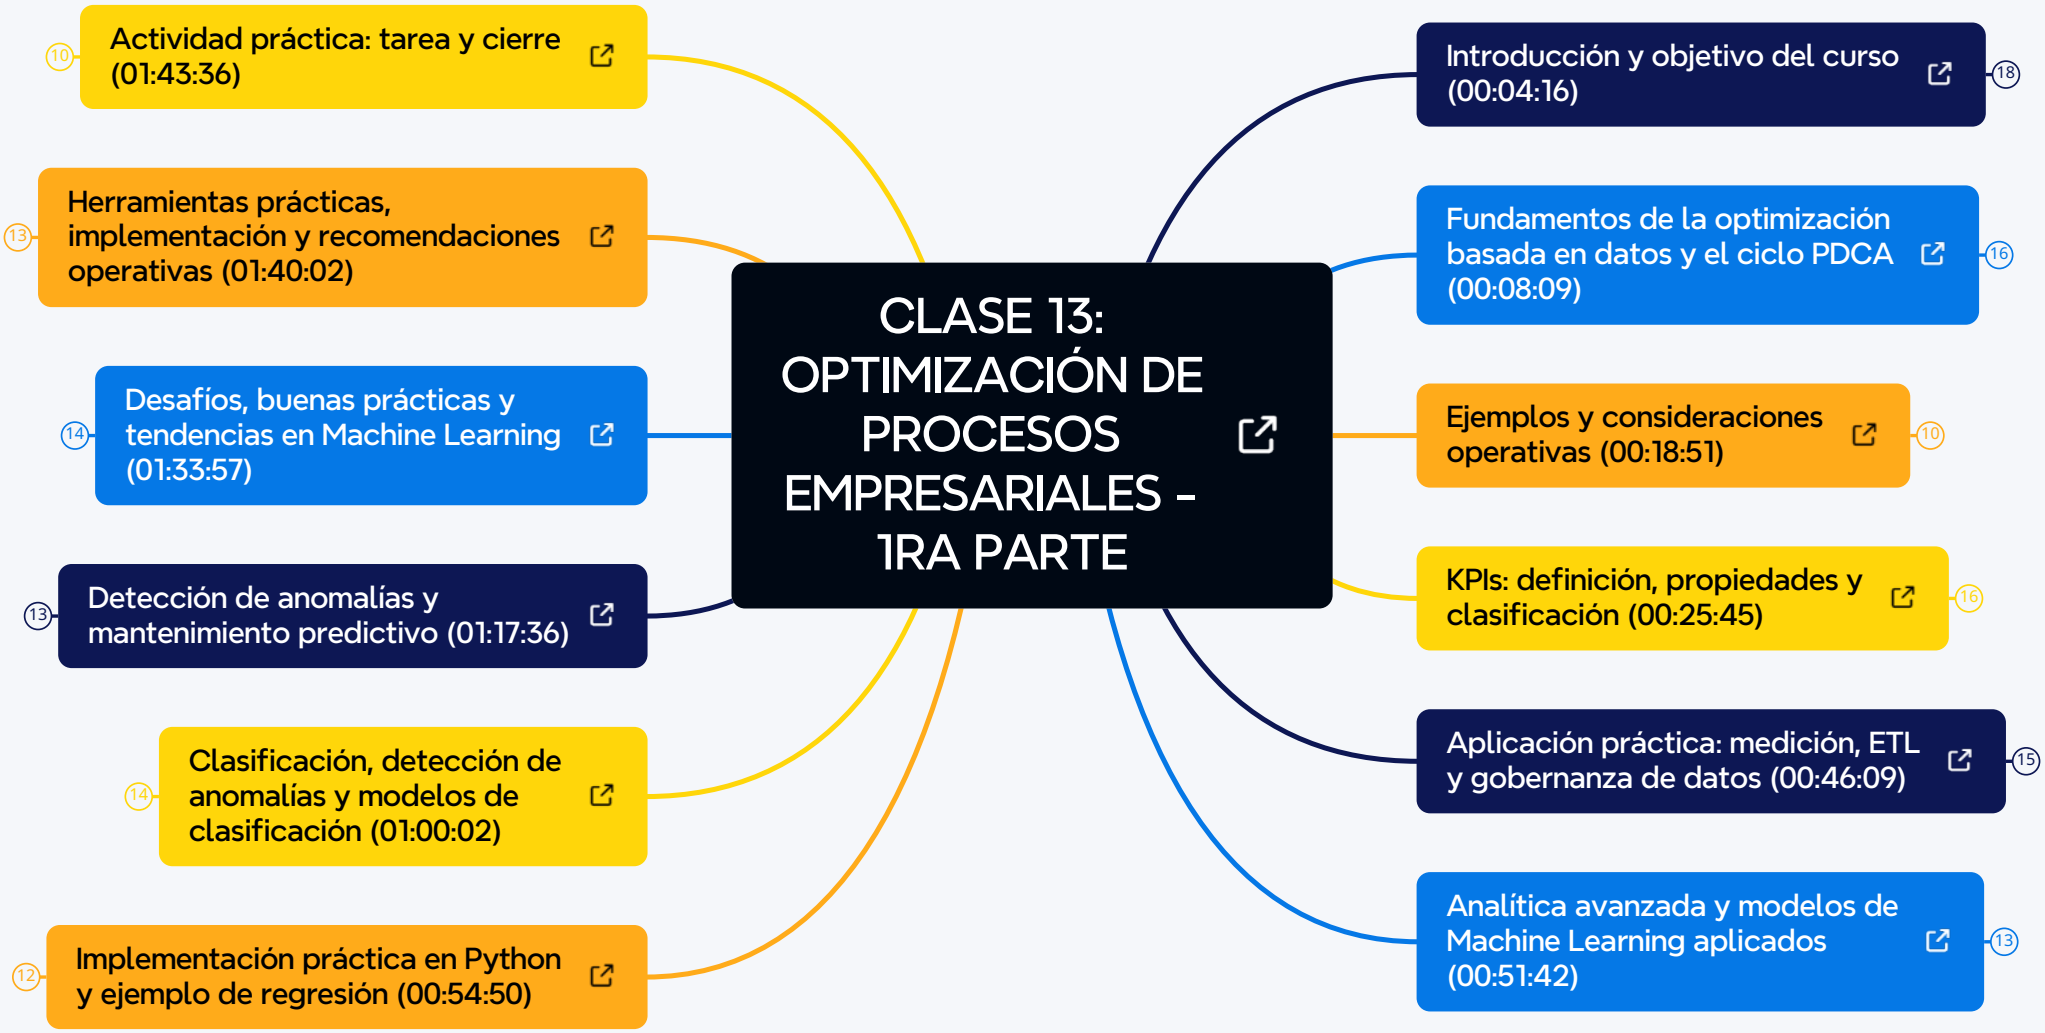
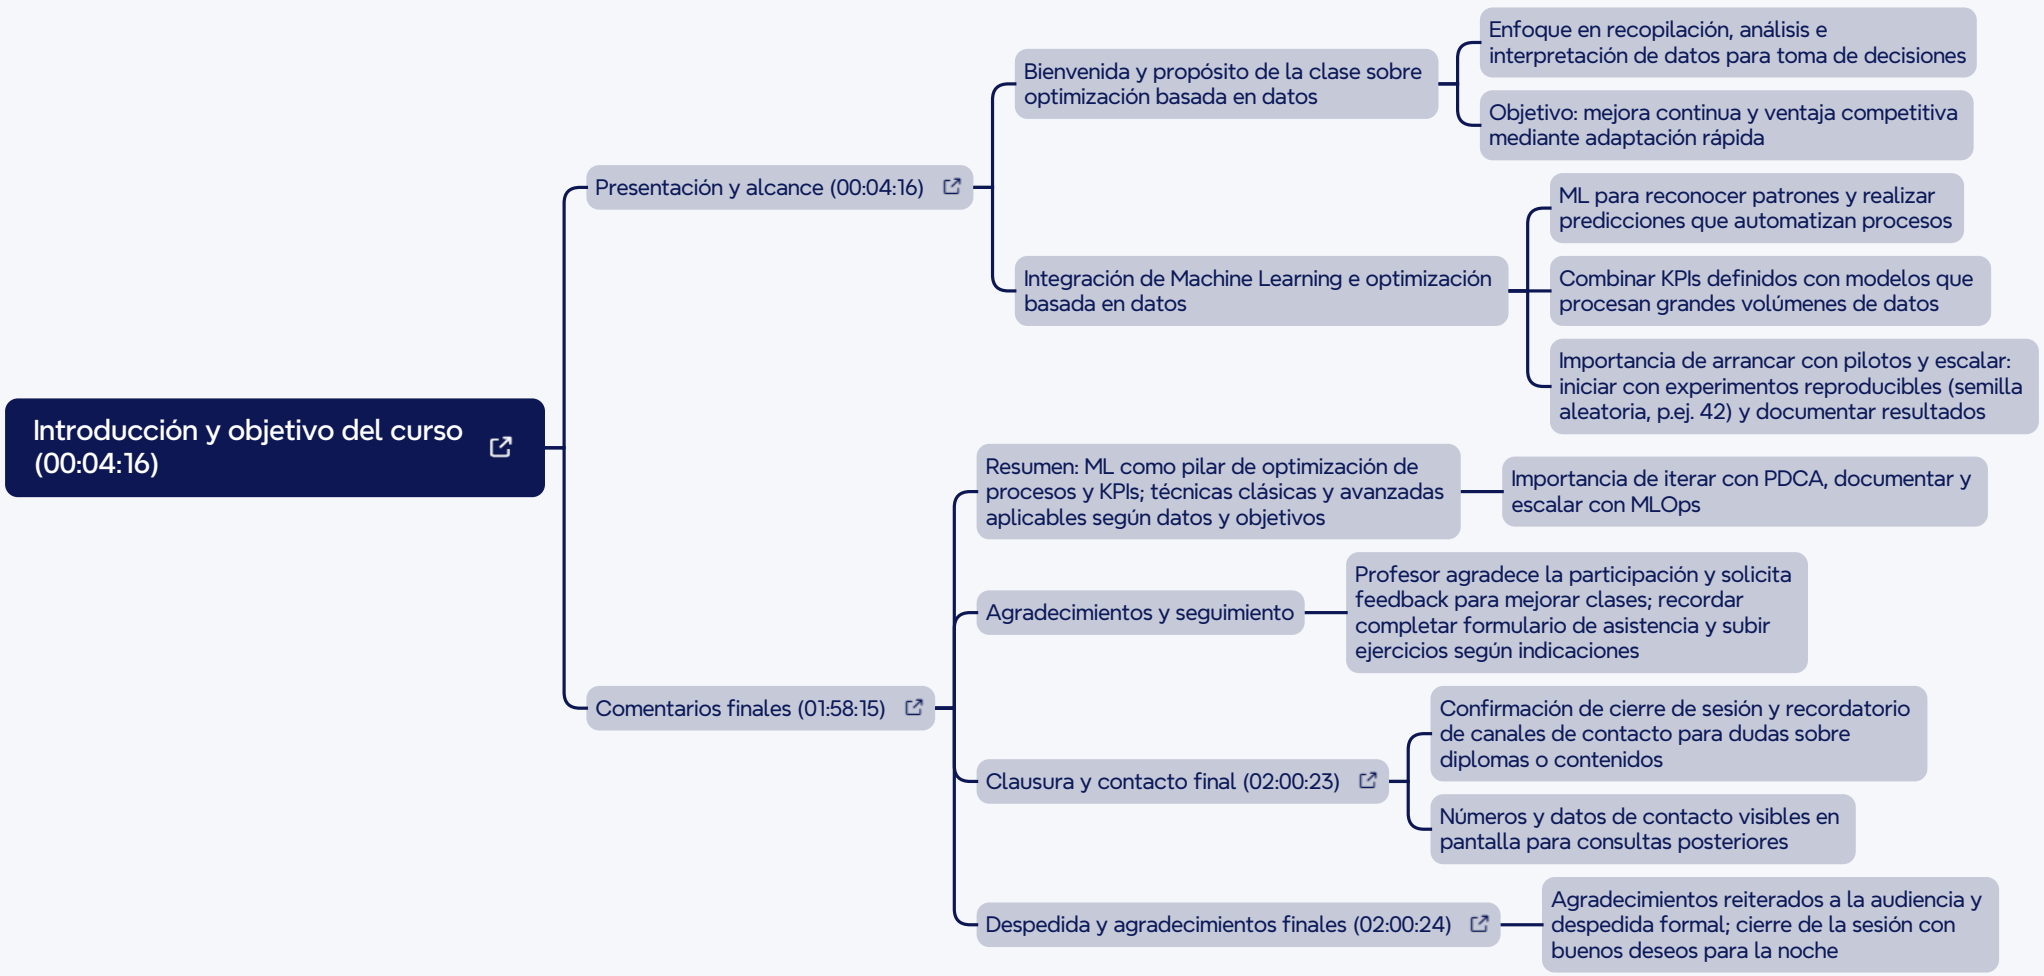
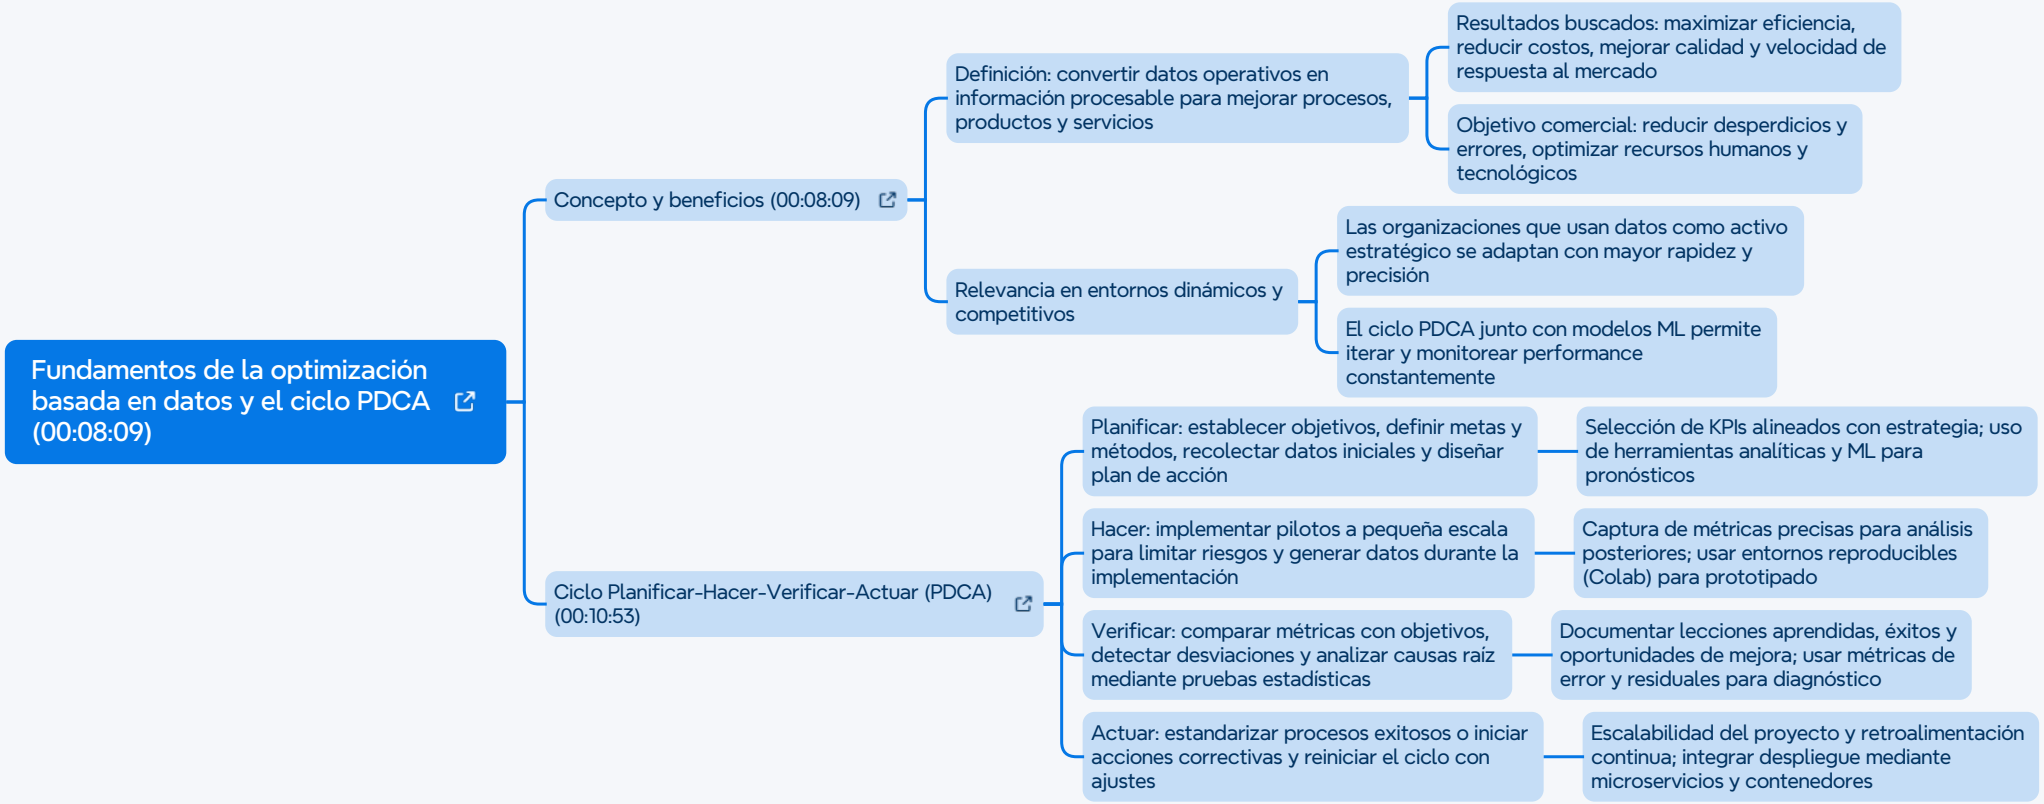
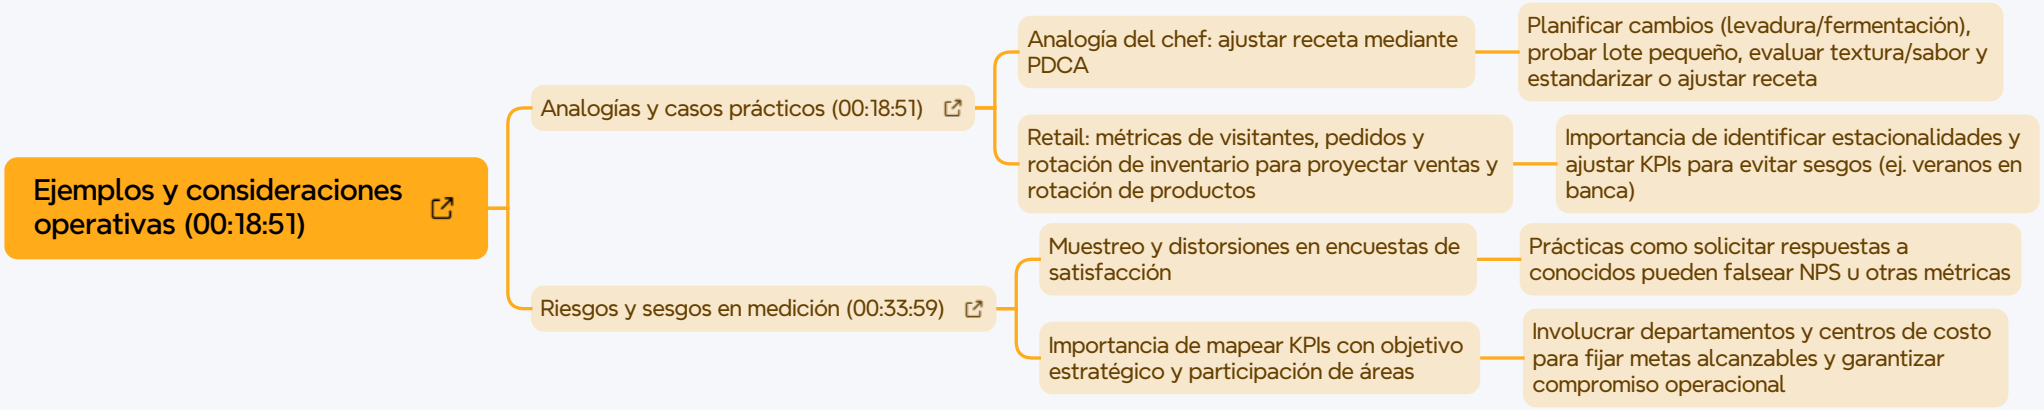
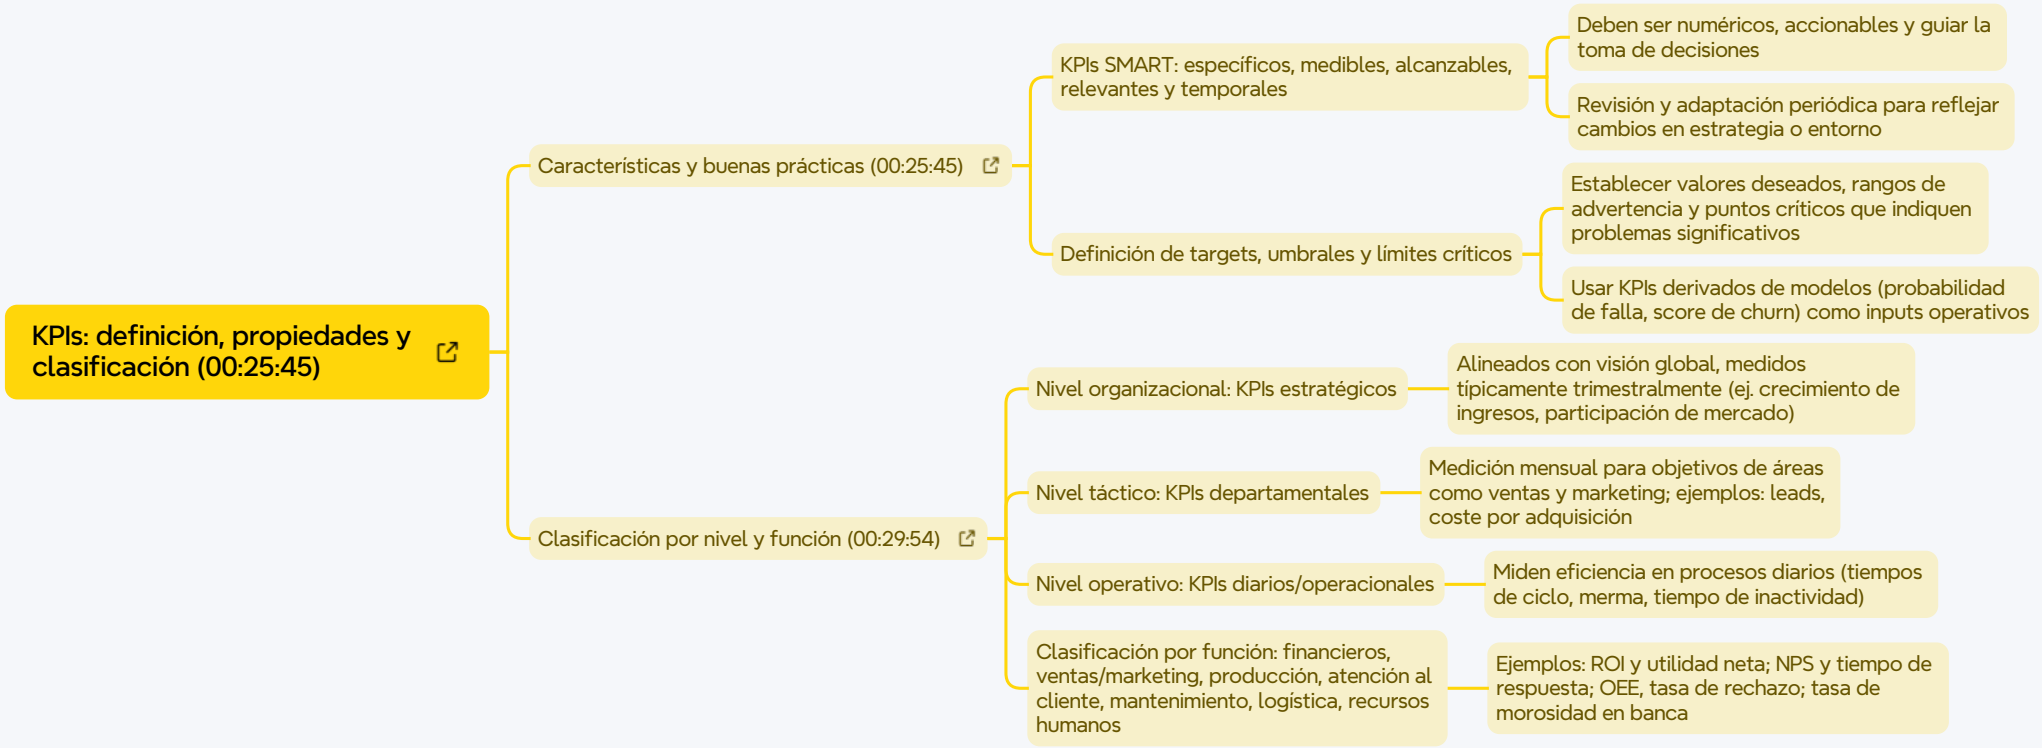
EDU MIN

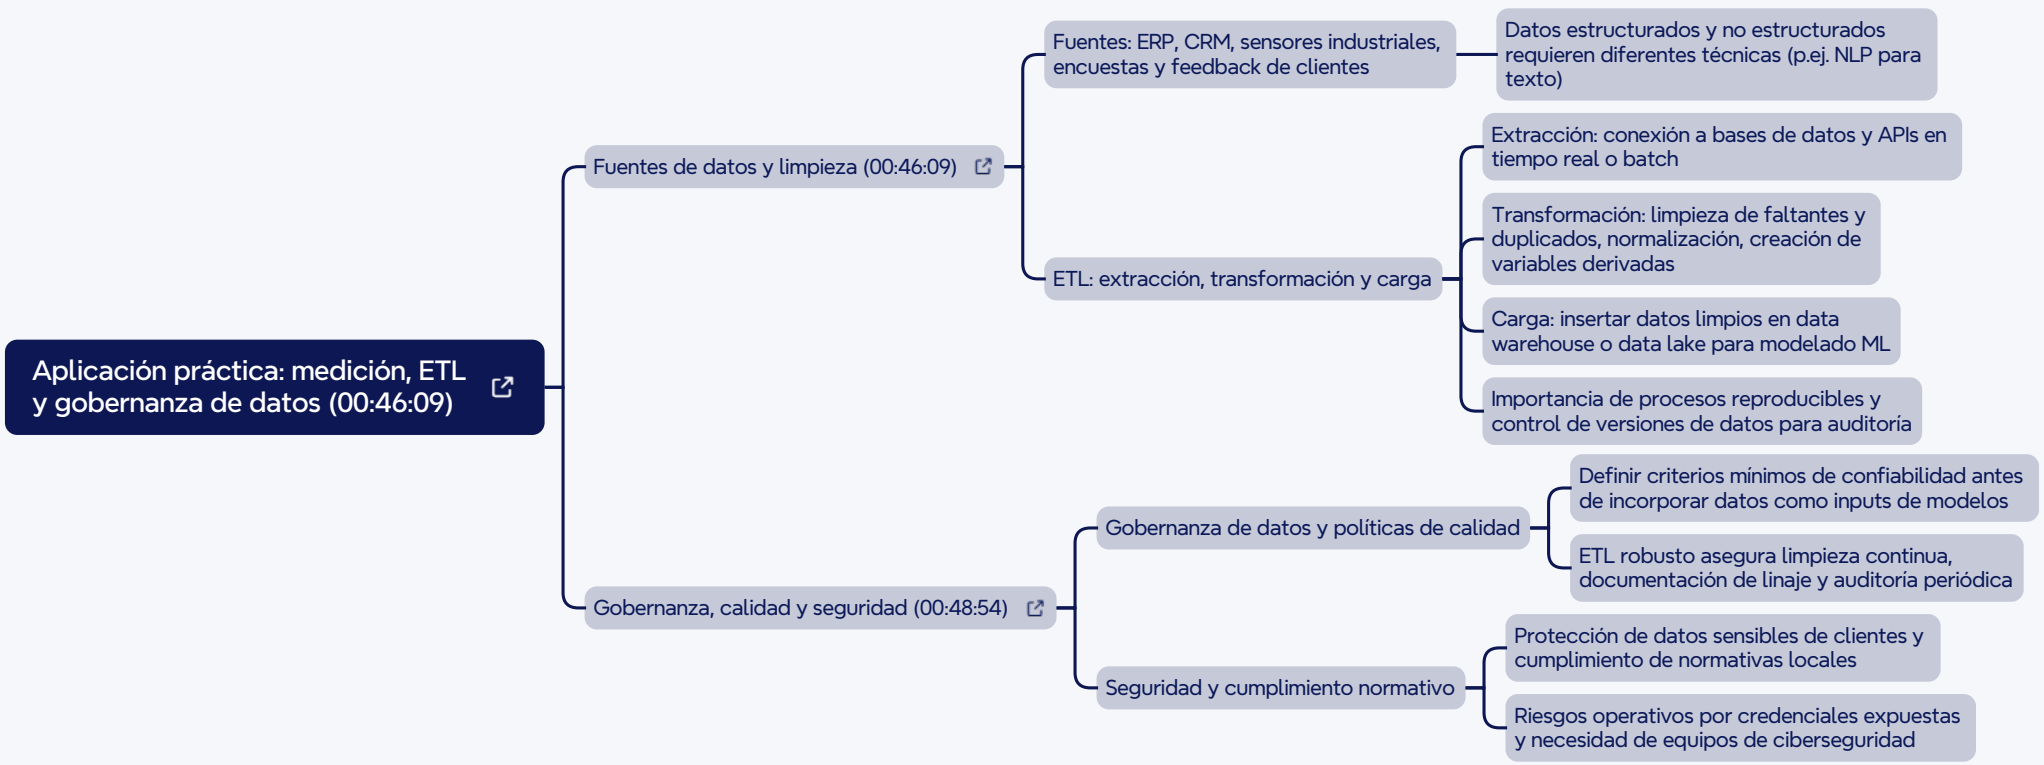

CLASE 13: OPTIMIZACIÓN DE PROCESOS EMPRESARIALES - 1RA PARTE
Introducción y objetivo del curso (00:04:16)
Fundamentos de la optimización basada en datos y el ciclo PDCA (00:08:09)
Ejemplos y consideraciones operativas (00:18:51)
KPIs: definición, propiedades y clasificación (00:25:45)
Aplicación práctica: medición, ETL y gobernanza de datos (00:46:09)
Analítica avanzada y modelos de Machine Learning aplicados (00:51:42)
Actividad práctica: tarea y cierre (01:43:36)
Herramientas prácticas, implementación y recomendaciones operativas (01:40:02)
Desafíos, buenas prácticas y tendencias en Machine Learning (01:33:57)
Detección de anomalías y mantenimiento predictivo (01:17:36)
Clasificación, detección de anomalías y modelos de clasificación (01:00:02)
Implementación práctica en Python y ejemplo de regresión (00:54:50)

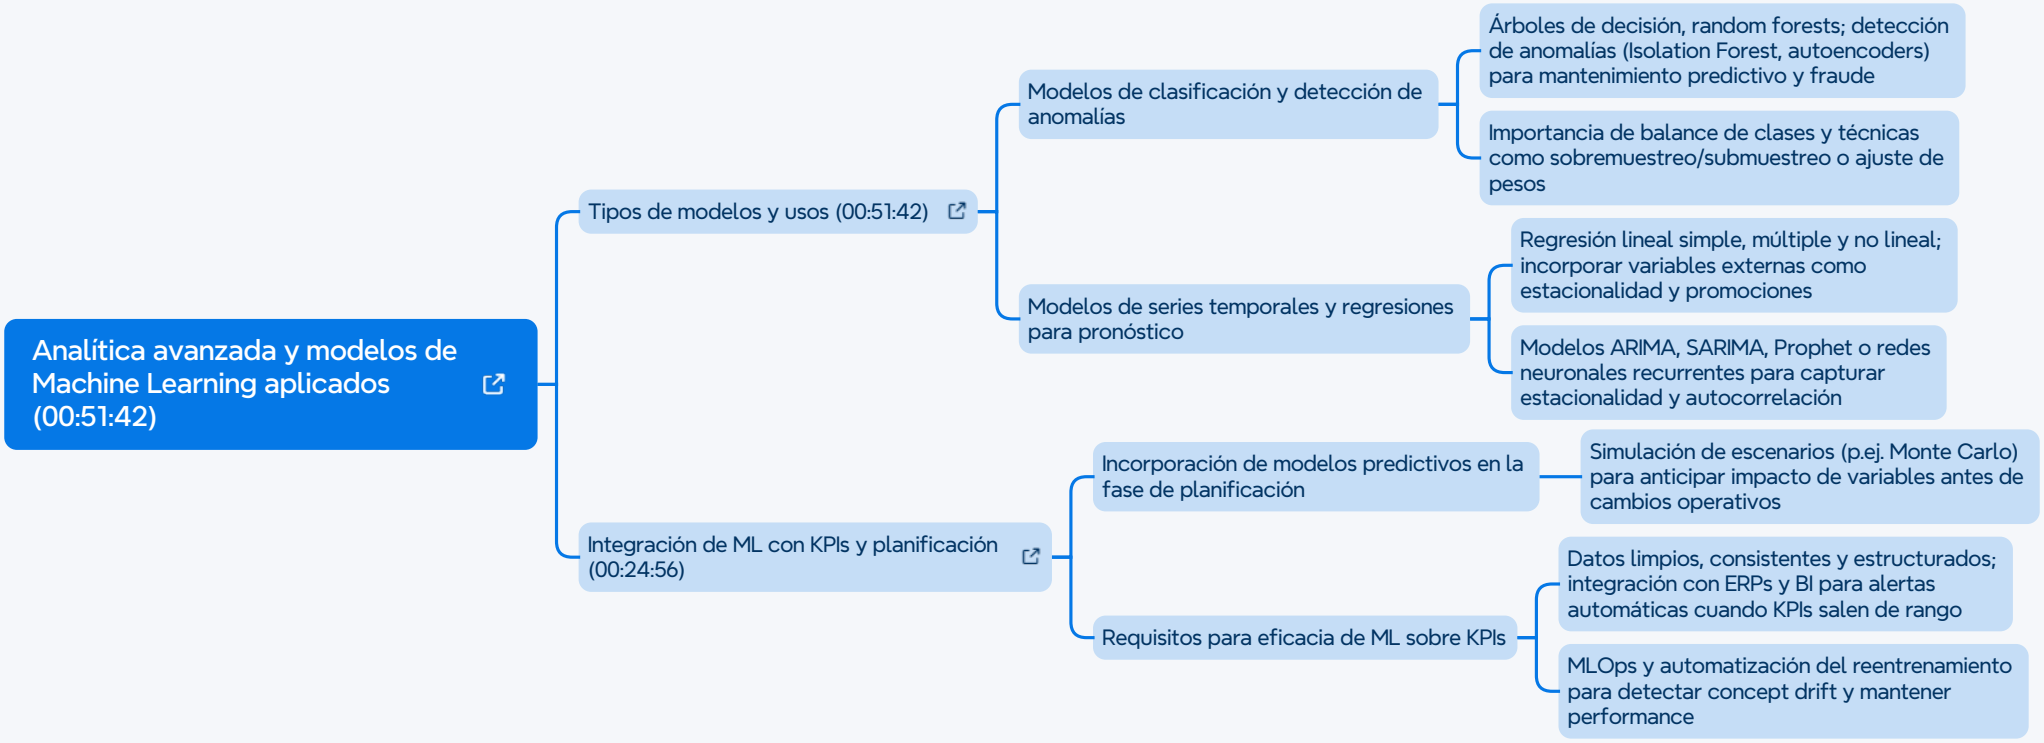

Introducción y objetivo del curso (00:04:16)
Presentación y alcance (00:04:16)
Bienvenida y propósito de la clase sobre optimización basada en datos
Enfoque en recopilación, análisis e interpretación de datos para toma de decisiones
Objetivo: mejora continua y ventaja competitiva mediante adaptación rápida
Integración de Machine Learning e optimización basada en datos
ML para reconocer patrones y realizar predicciones que automatizan procesos
Combinar KPIs definidos con modelos que procesan grandes volúmenes de datos
Importancia de arrancar con pilotos y escalar: iniciar con experimentos reproducibles (semilla aleatoria, p.ej. 42) y documentar resultados
Comentarios finales (01:58:15)
Resumen: ML como pilar de optimización de procesos y KPIs; técnicas clásicas y avanzadas aplicables según datos y objetivos
Importancia de iterar con PDCA, documentar y escalar con MLOps
Agradecimientos y seguimiento
Profesor agradece la participación y solicita feedback para mejorar clases; recordar completar formulario de asistencia y subir ejercicios según indicaciones
Clausura y contacto final (02:00:23)
Confirmación de cierre de sesión y recordatorio de canales de contacto para dudas sobre diplomas o contenidos
Números y datos de contacto visibles en pantalla para consultas posteriores
Despedida y agradecimientos finales (02:00:24)
Agradecimientos reiterados a la audiencia y despedida formal; cierre de la sesión con buenos deseos para la noche

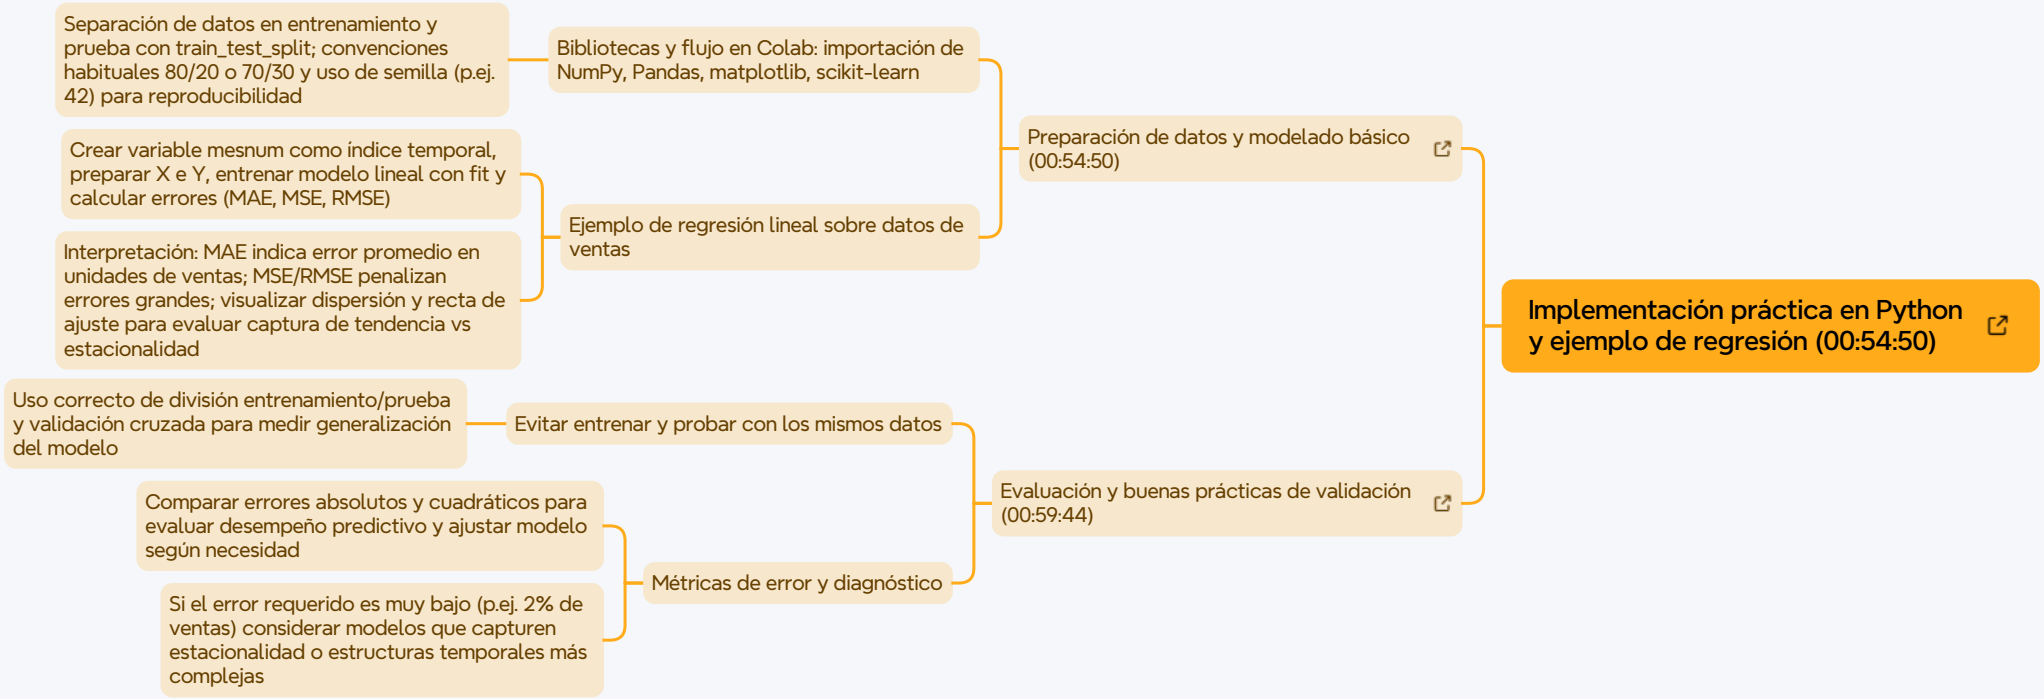

Fundamentos de la optimización basada en datos y el ciclo PDCA (00:08:09)
Concepto y beneficios (00:08:09)
Definición: convertir datos operativos en información procesable para mejorar procesos, productos y servicios
Resultados buscados: maximizar eficiencia, reducir costos, mejorar calidad y velocidad de respuesta al mercado
Objetivo comercial: reducir desperdicios y errores, optimizar recursos humanos y tecnológicos
Relevancia en entornos dinámicos y competitivos
Las organizaciones que usan datos como activo estratégico se adaptan con mayor rapidez y precisión
El ciclo PDCA junto con modelos ML permite iterar y monitorear performance constantemente
Ciclo Planificar-Hacer-Verificar-Actuar (PDCA) (00:10:53)
Planificar: establecer objetivos, definir metas y métodos, recolectar datos iniciales y diseñar plan de acción
Selección de KPIs alineados con estrategia; uso de herramientas analíticas y ML para pronósticos
Hacer: implementar pilotos a pequeña escala para limitar riesgos y generar datos durante la implementación
Captura de métricas precisas para análisis posteriores; usar entornos reproducibles (Colab) para prototipado
Verificar: comparar métricas con objetivos, detectar desviaciones y analizar causas raíz mediante pruebas estadísticas
Documentar lecciones aprendidas, éxitos y oportunidades de mejora; usar métricas de error y residuales para diagnóstico
Actuar: estandarizar procesos exitosos o iniciar acciones correctivas y reiniciar el ciclo con ajustes
Escalabilidad del proyecto y retroalimentación continua; integrar despliegue mediante microservicios y contenedores

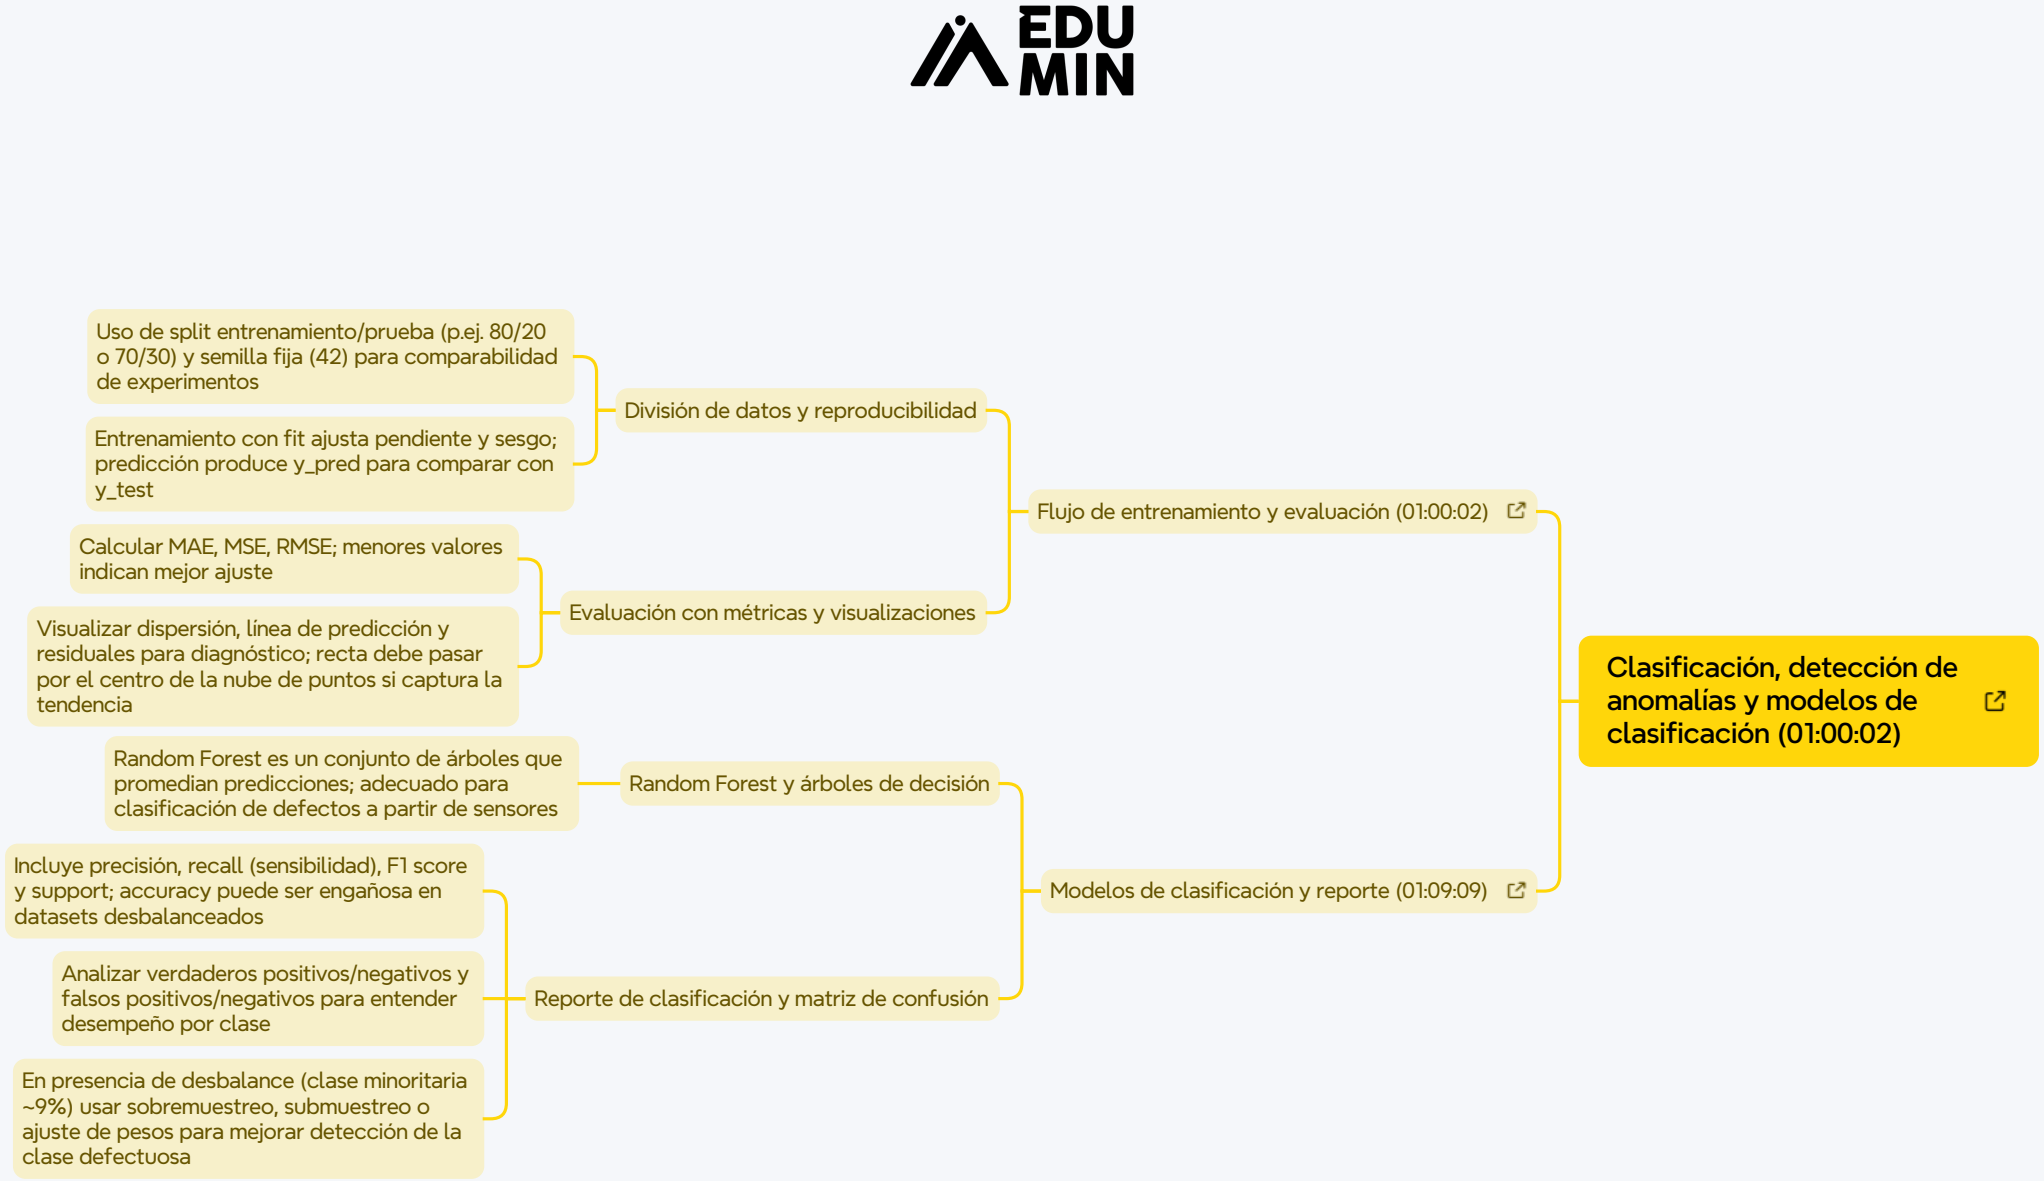

Ejemplos y consideraciones operativas (00:18:51)
Analogías y casos prácticos (00:18:51)
Analogía del chef: ajustar receta mediante PDCA
Planificar cambios (levadura/fermentación), probar lote pequeño, evaluar textura/sabor y estandarizar o ajustar receta
Retail: métricas de visitantes, pedidos y rotación de inventario para proyectar ventas y rotación de productos
Importancia de identificar estacionalidades y ajustar KPIs para evitar sesgos (ej. veranos en banca)
Riesgos y sesgos en medición (00:33:59)
Muestreo y distorsiones en encuestas de satisfacción
Prácticas como solicitar respuestas a conocidos pueden falsear NPS u otras métricas
Importancia de mapear KPIs con objetivo estratégico y participación de áreas
Involucrar departamentos y centros de costo para fijar metas alcanzables y garantizar compromiso operacional

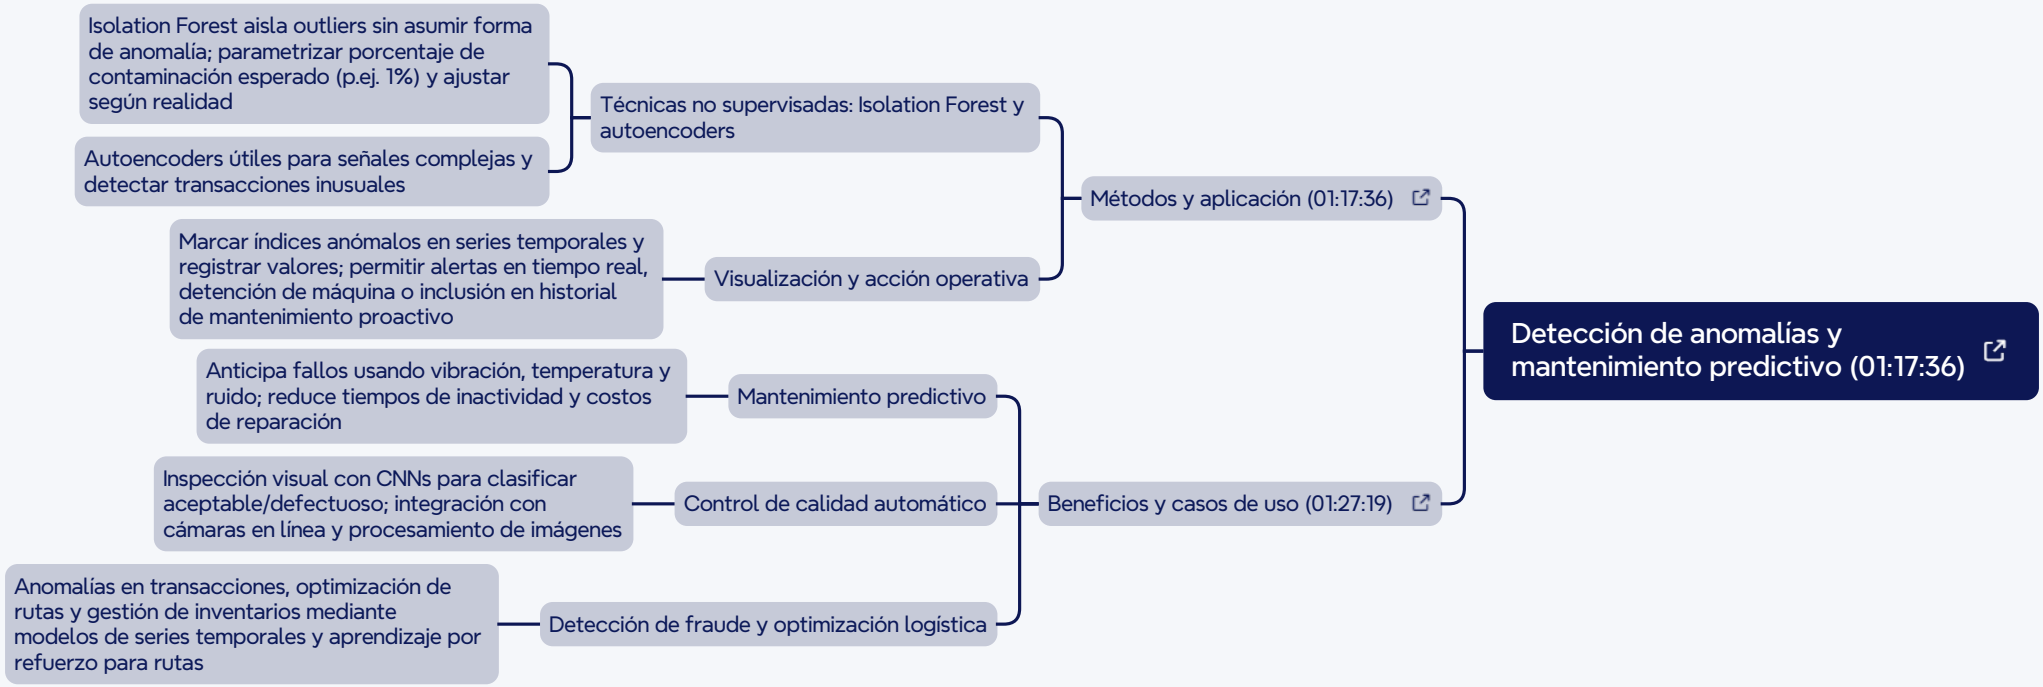

KPIs: definición, propiedades y clasificación (00:25:45)
Características y buenas prácticas (00:25:45)
KPIs SMART: específicos, medibles, alcanzables, relevantes y temporales
Deben ser numéricos, accionables y guiar la toma de decisiones
Revisión y adaptación periódica para reflejar cambios en estrategia o entorno
Definición de targets, umbrales y límites críticos
Establecer valores deseados, rangos de advertencia y puntos críticos que indiquen problemas significativos
Usar KPIs derivados de modelos (probabilidad de falla, score de churn) como inputs operativos
Clasificación por nivel y función (00:29:54)
Nivel organizacional: KPIs estratégicos
Alineados con visión global, medidos típicamente trimestralmente (ej. crecimiento de ingresos, participación de mercado)
Nivel táctico: KPIs departamentales
Medición mensual para objetivos de áreas como ventas y marketing; ejemplos: leads, coste por adquisición
Nivel operativo: KPIs diarios/operacionales
Miden eficiencia en procesos diarios (tiempos de ciclo, merma, tiempo de inactividad)
Clasificación por función: financieros, ventas/marketing, producción, atención al cliente, mantenimiento, logística, recursos humanos
Ejemplos: ROI y utilidad neta; NPS y tiempo de respuesta; OEE, tasa de rechazo; tasa de morosidad en banca

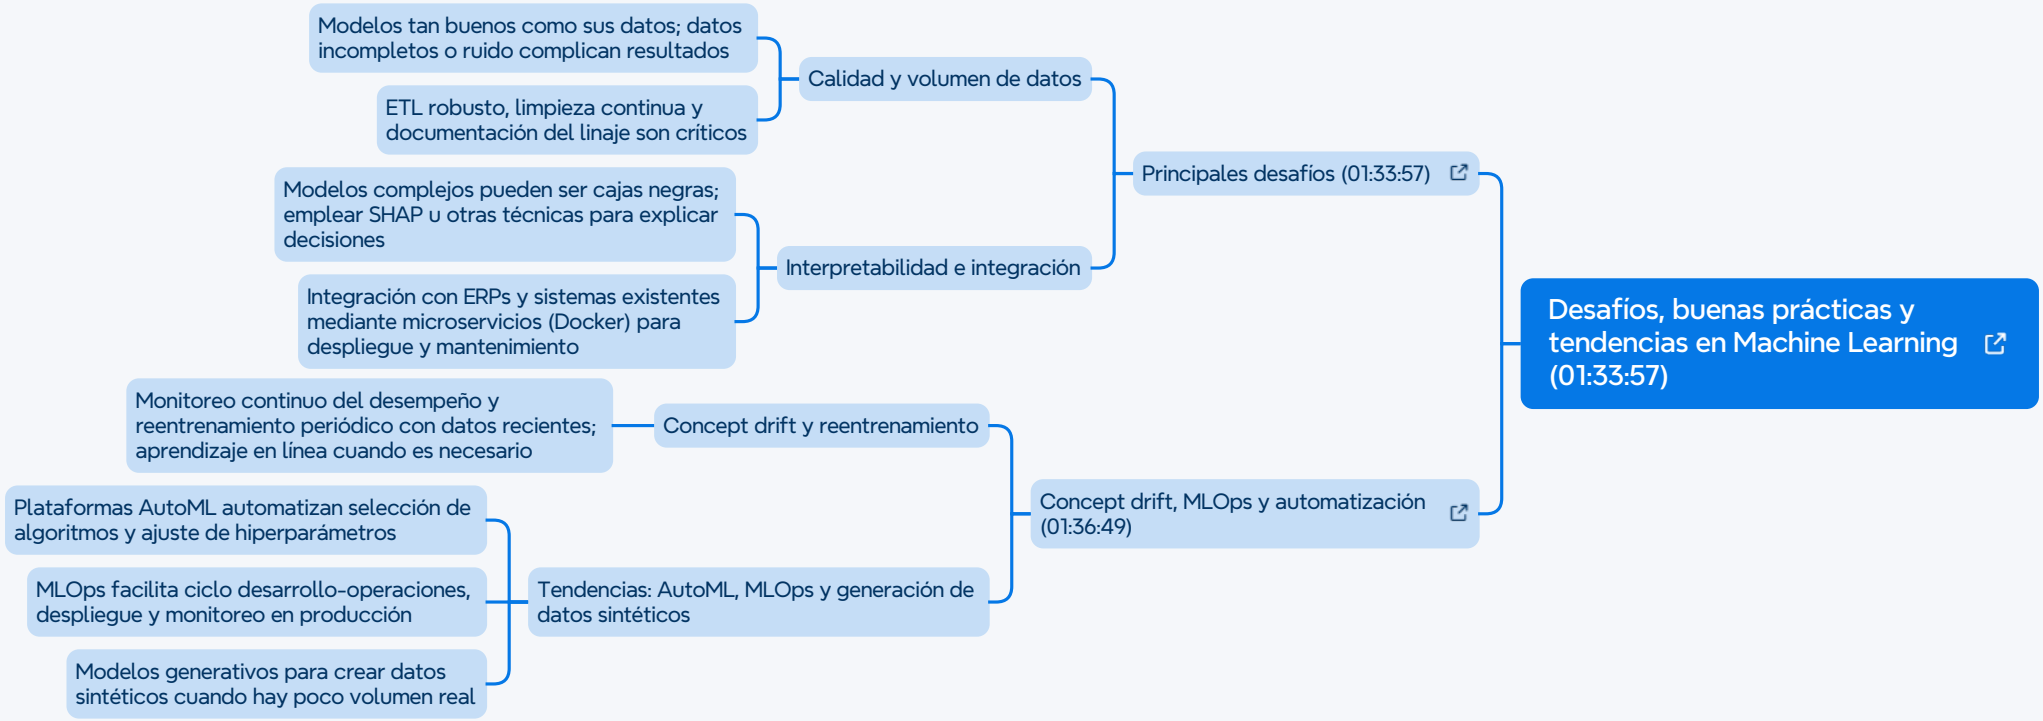

Aplicación práctica: medición, ETL y gobernanza de datos (00:46:09)
Fuentes de datos y limpieza (00:46:09)
Fuentes: ERP, CRM, sensores industriales, encuestas y feedback de clientes
Datos estructurados y no estructurados requieren diferentes técnicas (p.ej. NLP para texto)
ETL: extracción, transformación y carga
Extracción: conexión a bases de datos y APIs en tiempo real o batch
Transformación: limpieza de faltantes y duplicados, normalización, creación de variables derivadas
Carga: insertar datos limpios en data warehouse o data lake para modelado ML
Importancia de procesos reproducibles y control de versiones de datos para auditoría
Gobernanza, calidad y seguridad (00:48:54)
Gobernanza de datos y políticas de calidad
Definir criterios mínimos de confiabilidad antes de incorporar datos como inputs de modelos
ETL robusto asegura limpieza continua, documentación de linaje y auditoría periódica
Seguridad y cumplimiento normativo
Protección de datos sensibles de clientes y cumplimiento de normativas locales
Riesgos operativos por credenciales expuestas y necesidad de equipos de ciberseguridad

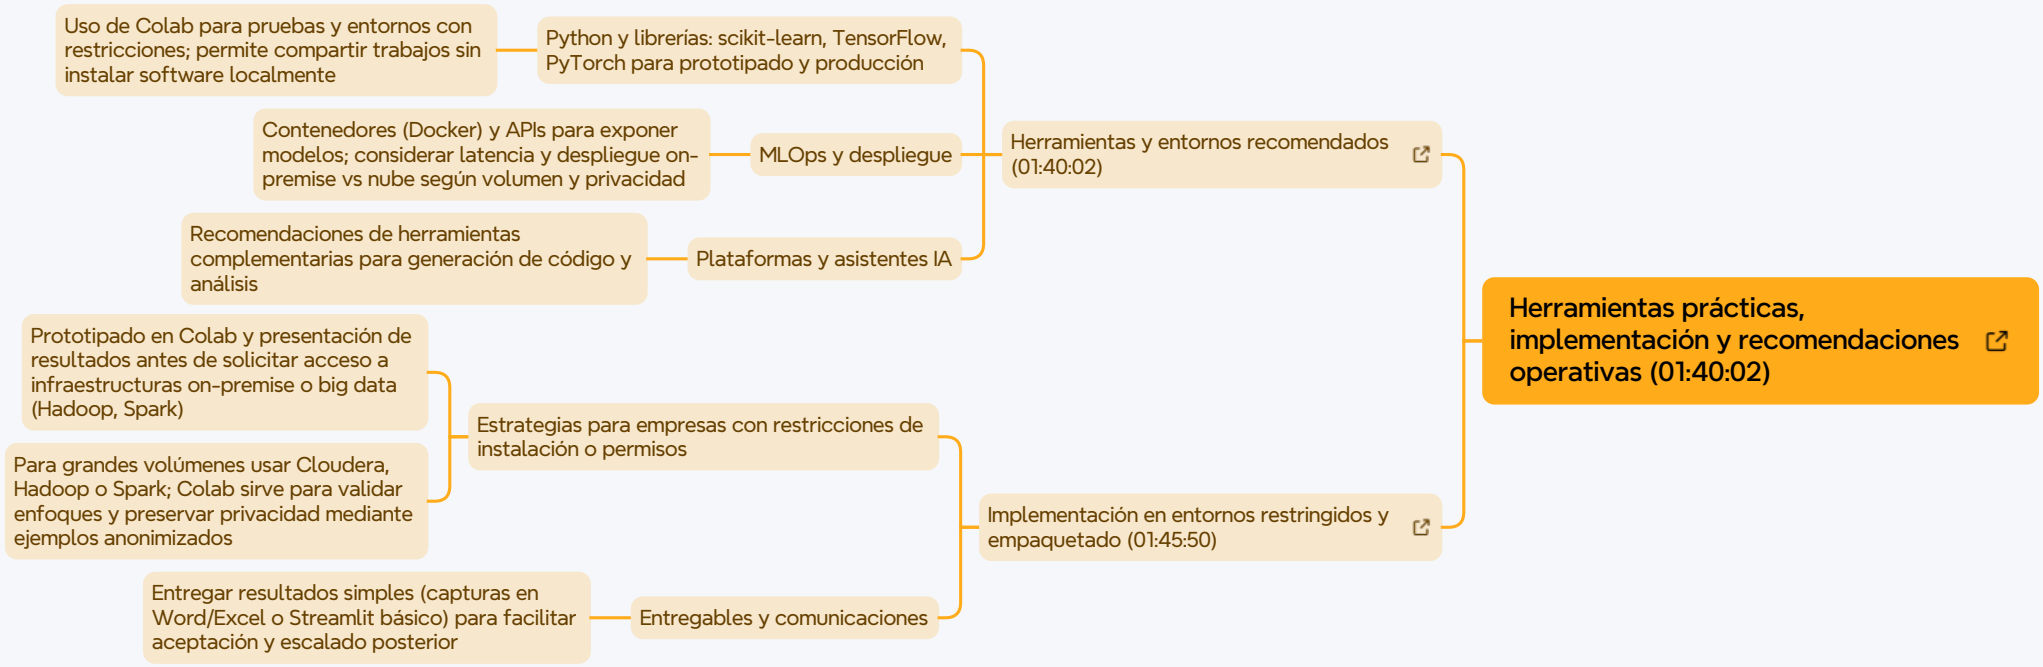

Analítica avanzada y modelos de Machine Learning aplicados (00:51:42)
Tipos de modelos y usos (00:51:42)
Modelos de clasificación y detección de anomalías
Árboles de decisión, random forests; detección de anomalías (Isolation Forest, autoencoders) para mantenimiento predictivo y fraude
Importancia de balance de clases y técnicas como sobremuestreo/submuestreo o ajuste de pesos
Modelos de series temporales y regresiones para pronóstico
Regresión lineal simple, múltiple y no lineal; incorporar variables externas como estacionalidad y promociones
Modelos ARIMA, SARIMA, Prophet o redes neuronales recurrentes para capturar estacionalidad y autocorrelación
Integración de ML con KPIs y planificación (00:24:56)
Incorporación de modelos predictivos en la fase de planificación
Simulación de escenarios (p.ej. Monte Carlo) para anticipar impacto de variables antes de cambios operativos
Requisitos para eficacia de ML sobre KPIs
Datos limpios, consistentes y estructurados; integración con ERPs y BI para alertas automáticas cuando KPIs salen de rango
MLOps y automatización del reentrenamiento para detectar concept drift y mantener performance

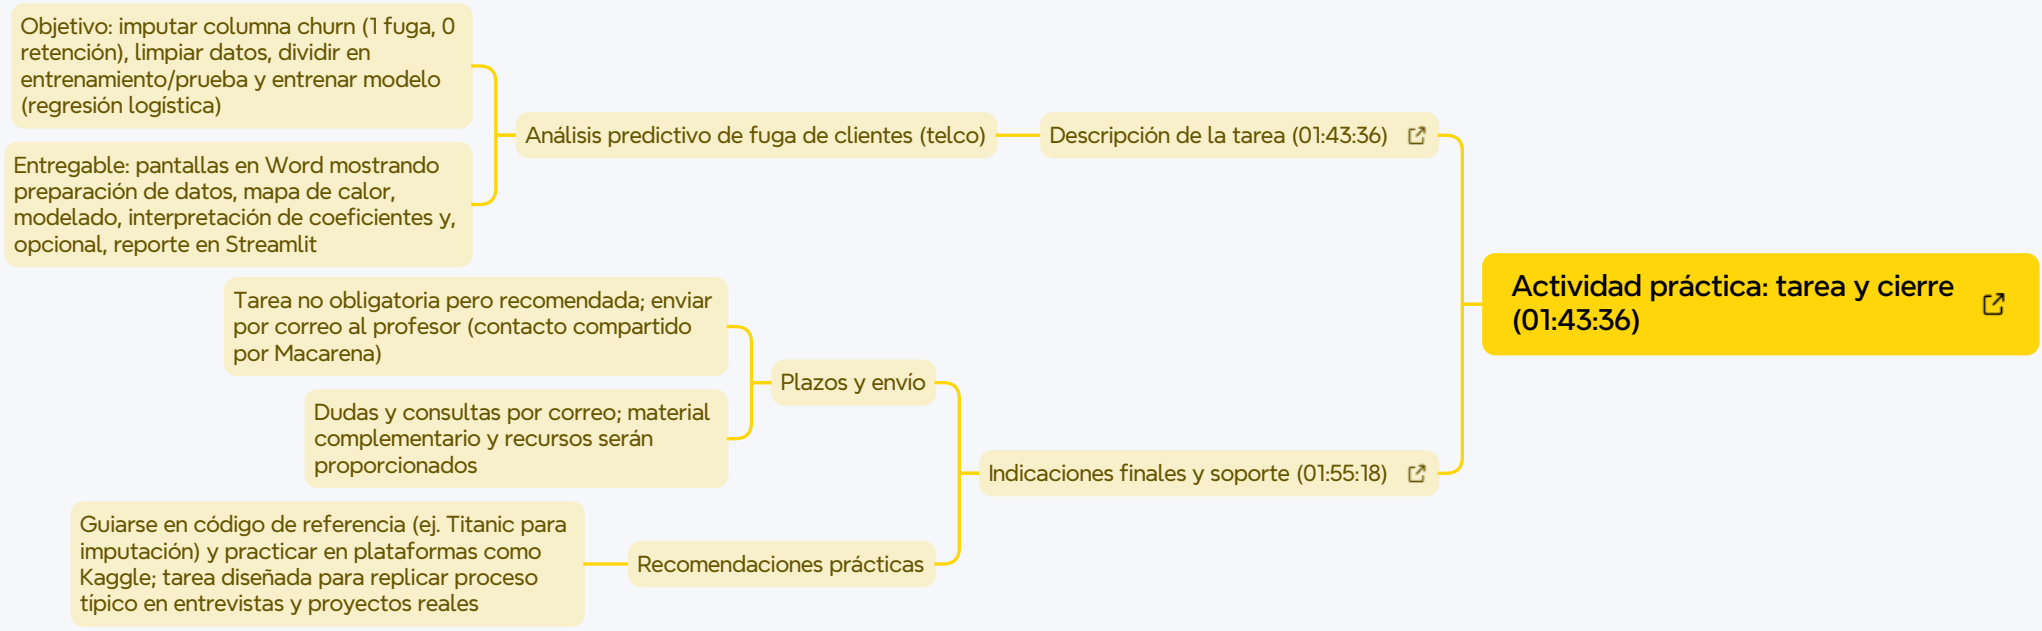

Implementación práctica en Python y ejemplo de regresión (00:54:50)
Preparación de datos y modelado básico (00:54:50)
Bibliotecas y flujo en Colab: importación de NumPy, Pandas, matplotlib, scikit-learn
Separación de datos en entrenamiento y prueba con train_test_split; convenciones habituales 80/20 o 70/30 y uso de semilla (p.ej. 42) para reproducibilidad
Ejemplo de regresión lineal sobre datos de ventas
Crear variable mesnum como índice temporal, preparar X e Y, entrenar modelo lineal con fit y calcular errores (MAE, MSE, RMSE)
Interpretación: MAE indica error promedio en unidades de ventas; MSE/RMSE penalizan errores grandes; visualizar dispersión y recta de ajuste para evaluar captura de tendencia vs estacionalidad
Evaluación y buenas prácticas de validación (00:59:44)
Evitar entrenar y probar con los mismos datos
Uso correcto de división entrenamiento/prueba y validación cruzada para medir generalización del modelo
Métricas de error y diagnóstico
Comparar errores absolutos y cuadráticos para evaluar desempeño predictivo y ajustar modelo según necesidad
Si el error requerido es muy bajo (p.ej. 2% de ventas) considerar modelos que capturen estacionalidad o estructuras temporales más complejas


Clasificación, detección de anomalías y modelos de clasificación (01:00:02)
Flujo de entrenamiento y evaluación (01:00:02)
División de datos y reproducibilidad
Uso de split entrenamiento/prueba (p.ej. 80/20 o 70/30) y semilla fija (42) para comparabilidad de experimentos
Entrenamiento con fit ajusta pendiente y sesgo; predicción produce y_pred para comparar con y_test
Evaluación con métricas y visualizaciones
Calcular MAE, MSE, RMSE; menores valores indican mejor ajuste
Visualizar dispersión, línea de predicción y residuales para diagnóstico; recta debe pasar por el centro de la nube de puntos si captura la tendencia
Modelos de clasificación y reporte (01:09:09)
Random Forest y árboles de decisión
Random Forest es un conjunto de árboles que promedian predicciones; adecuado para clasificación de defectos a partir de sensores
Reporte de clasificación y matriz de confusión
Incluye precisión, recall (sensibilidad), F1 score y support; accuracy puede ser engañosa en datasets desbalanceados
Analizar verdaderos positivos/negativos y falsos positivos/negativos para entender desempeño por clase
En presencia de desbalance (clase minoritaria ~9%) usar sobremuestreo, submuestreo o ajuste de pesos para mejorar detección de la clase defectuosa


Detección de anomalías y mantenimiento predictivo (01:17:36)
Métodos y aplicación (01:17:36)
Técnicas no supervisadas: Isolation Forest y autoencoders
Isolation Forest aisla outliers sin asumir forma de anomalía; parametrizar porcentaje de contaminación esperado (p.ej. 1%) y ajustar según realidad
Autoencoders útiles para señales complejas y detectar transacciones inusuales
Visualización y acción operativa
Marcar índices anómalos en series temporales y registrar valores; permitir alertas en tiempo real, detención de máquina o inclusión en historial de mantenimiento proactivo
Beneficios y casos de uso (01:27:19)
Mantenimiento predictivo
Anticipa fallos usando vibración, temperatura y ruido; reduce tiempos de inactividad y costos de reparación
Control de calidad automático
Inspección visual con CNNs para clasificar aceptable/defectuoso; integración con cámaras en línea y procesamiento de imágenes
Detección de fraude y optimización logística
Anomalías en transacciones, optimización de rutas y gestión de inventarios mediante modelos de series temporales y aprendizaje por refuerzo para rutas


Desafíos, buenas prácticas y tendencias en Machine Learning (01:33:57)
Principales desafíos (01:33:57)
Calidad y volumen de datos
Modelos tan buenos como sus datos; datos incompletos o ruido complican resultados
ETL robusto, limpieza continua y documentación del linaje son críticos
Interpretabilidad e integración
Modelos complejos pueden ser cajas negras; emplear SHAP u otras técnicas para explicar decisiones
Integración con ERPs y sistemas existentes mediante microservicios (Docker) para despliegue y mantenimiento
Concept drift, MLOps y automatización (01:36:49)
Concept drift y reentrenamiento
Monitoreo continuo del desempeño y reentrenamiento periódico con datos recientes; aprendizaje en línea cuando es necesario
Tendencias: AutoML, MLOps y generación de datos sintéticos
Plataformas AutoML automatizan selección de algoritmos y ajuste de hiperparámetros
MLOps facilita ciclo desarrollo-operaciones, despliegue y monitoreo en producción
Modelos generativos para crear datos sintéticos cuando hay poco volumen real


Herramientas prácticas, implementación y recomendaciones operativas (01:40:02)
Herramientas y entornos recomendados (01:40:02)
Python y librerías: scikit-learn, TensorFlow, PyTorch para prototipado y producción
Uso de Colab para pruebas y entornos con restricciones; permite compartir trabajos sin instalar software localmente
MLOps y despliegue
Contenedores (Docker) y APIs para exponer modelos; considerar latencia y despliegue on-premise vs nube según volumen y privacidad
Plataformas y asistentes IA
Recomendaciones de herramientas complementarias para generación de código y análisis
Implementación en entornos restringidos y empaquetado (01:45:50)
Estrategias para empresas con restricciones de instalación o permisos
Prototipado en Colab y presentación de resultados antes de solicitar acceso a infraestructuras on-premise o big data (Hadoop, Spark)
Para grandes volúmenes usar Cloudera, Hadoop o Spark; Colab sirve para validar enfoques y preservar privacidad mediante ejemplos anonimizados
Entregables y comunicaciones
Entregar resultados simples (capturas en Word/Excel o Streamlit básico) para facilitar aceptación y escalado posterior


Actividad práctica: tarea y cierre (01:43:36)
Descripción de la tarea (01:43:36)
Análisis predictivo de fuga de clientes (telco)
Objetivo: imputar columna churn (1 fuga, 0 retención), limpiar datos, dividir en entrenamiento/prueba y entrenar modelo (regresión logística)
Entregable: pantallas en Word mostrando preparación de datos, mapa de calor, modelado, interpretación de coeficientes y, opcional, reporte en Streamlit
Indicaciones finales y soporte (01:55:18)
Plazos y envío
Tarea no obligatoria pero recomendada; enviar por correo al profesor (contacto compartido por Macarena)
Dudas y consultas por correo; material complementario y recursos serán proporcionados
Recomendaciones prácticas
Guiarse en código de referencia (ej. Titanic para imputación) y practicar en plataformas como Kaggle; tarea diseñada para replicar proceso típico en entrevistas y proyectos reales