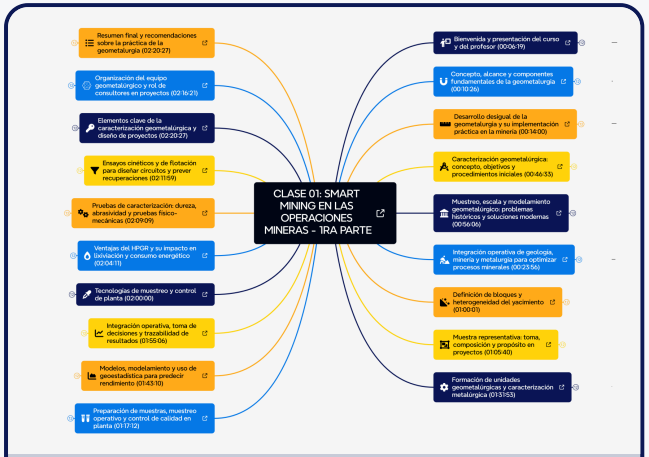
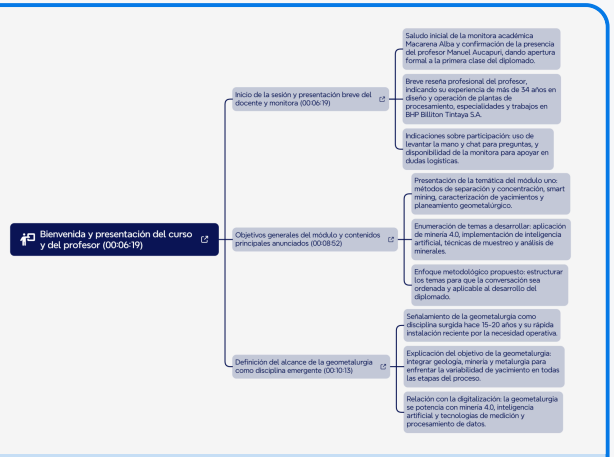
¡APRENDE A USAR TU MAPA MENTAL EN 04 PASOS!

01. Encuentra el tema central



En la **primera página** verás el nombre de la clase y los temas más importantes. Es el punto de partida ideal antes de comenzar.

02. Profundiza en los temas



En las **páginas siguientes**, cada tema se divide en conceptos clave fáciles de seguir. Explora el mapa para entender mejor la información.

03. Ve directo a la explicación



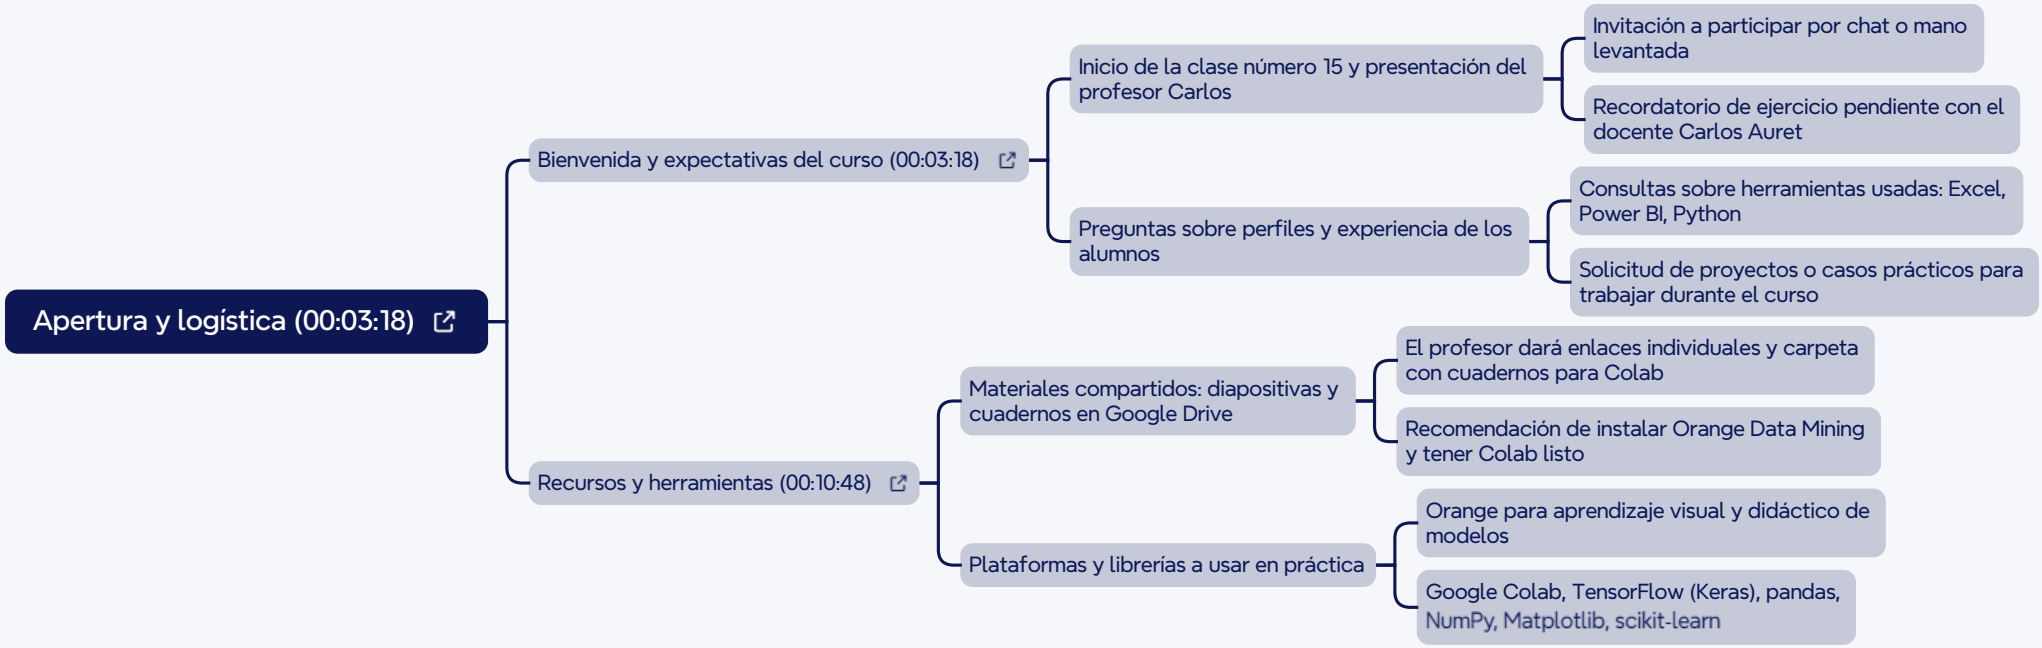
Selecciona este ícono ↗ para ir al **momento exacto** de la clase donde se explica ese punto. Ahorra tiempo gracias a esta función.

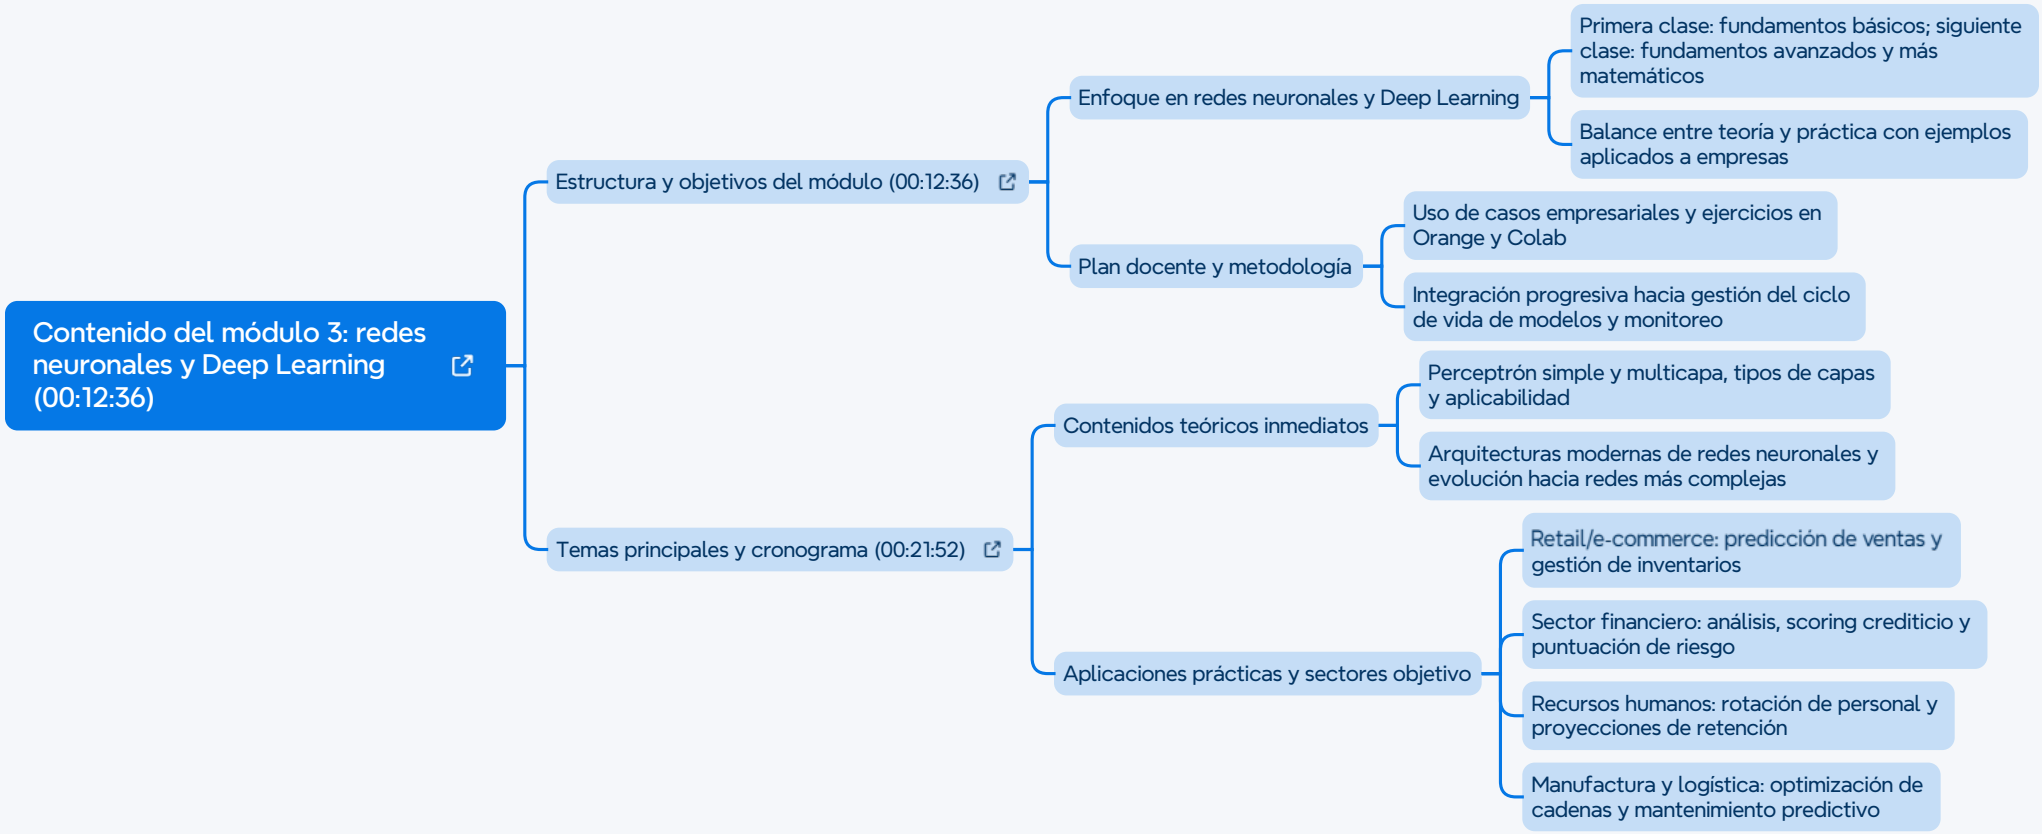
04. Amplía y descarga el mapa

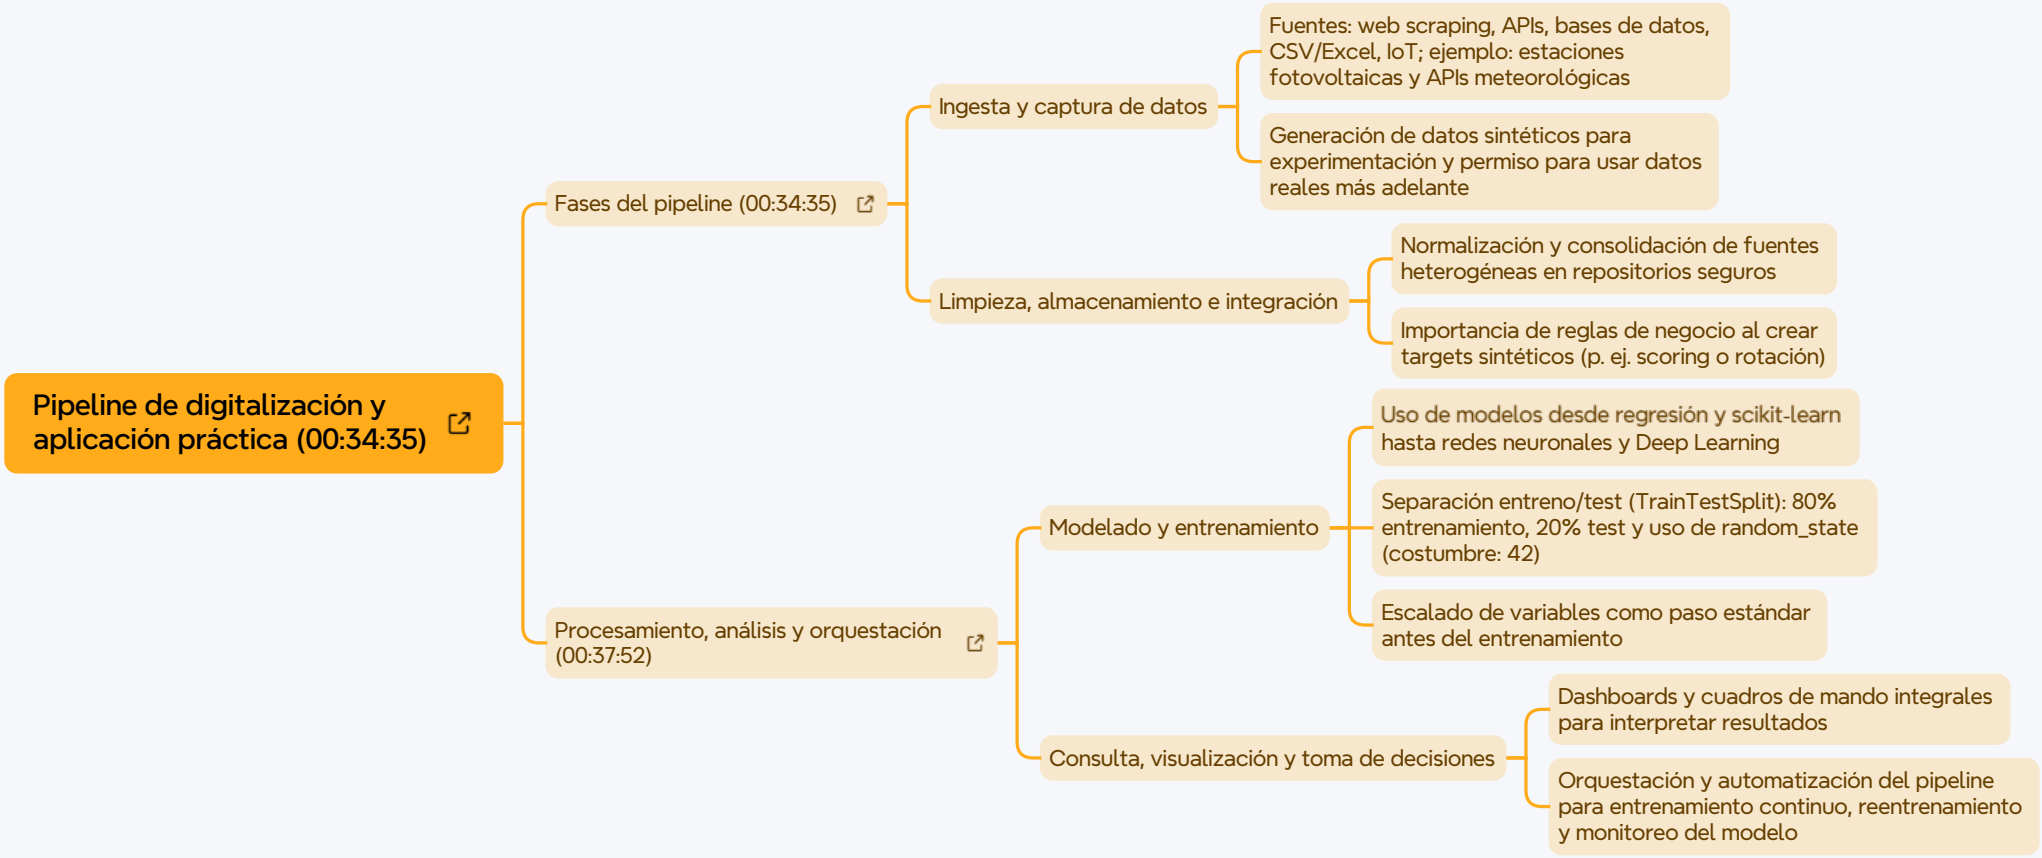
Utiliza el botón de la esquina superior derecha para **agrandar el mapa** y visualizarlo con mayor comodidad. También puedes descargarlo para revisar el contenido en cualquier momento.

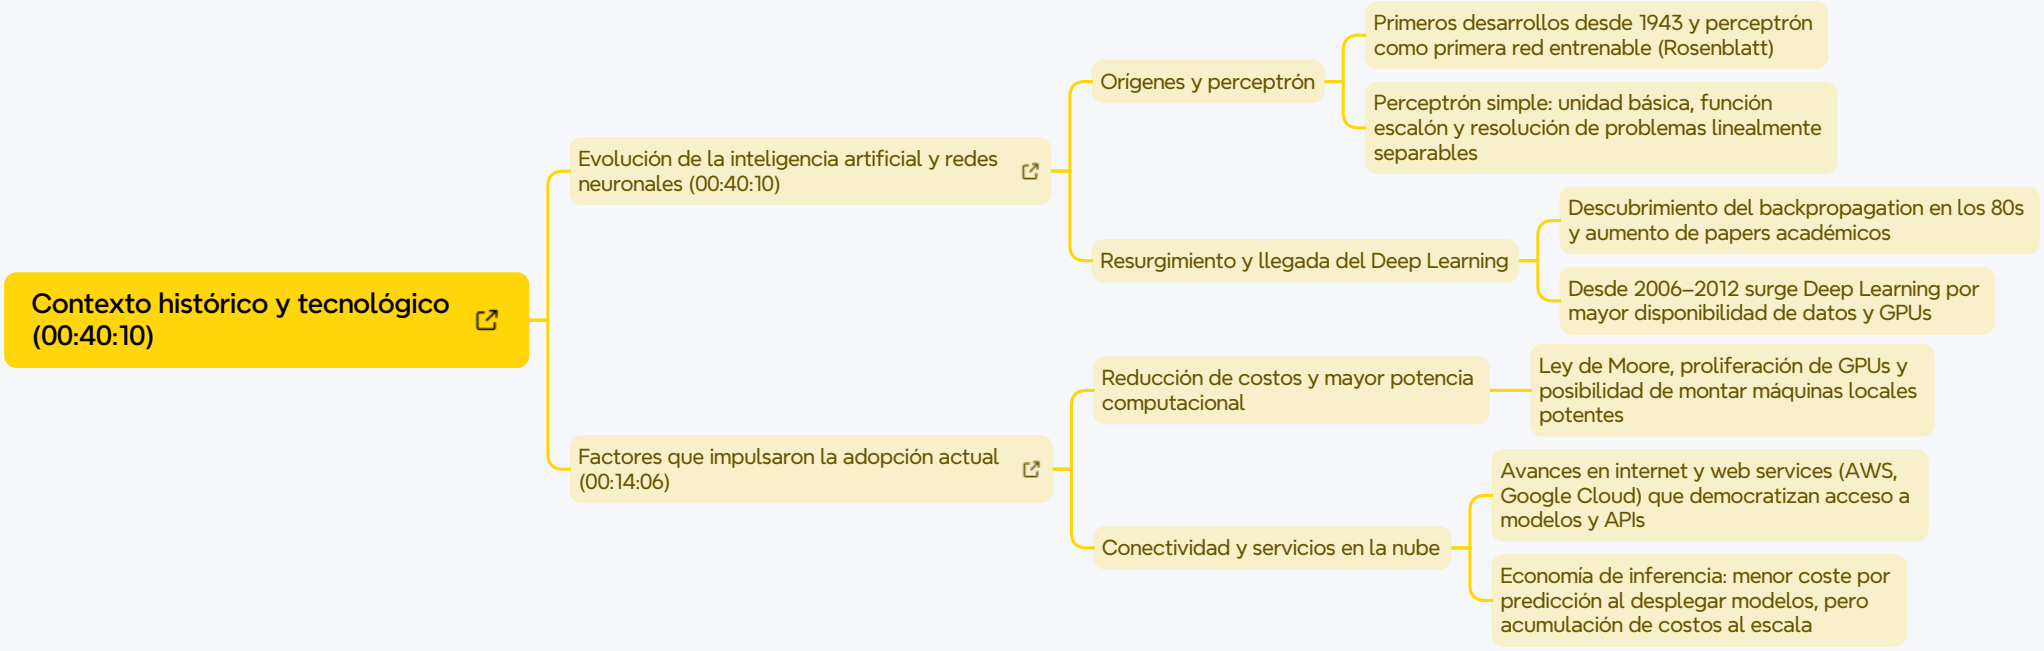
EDU MIN

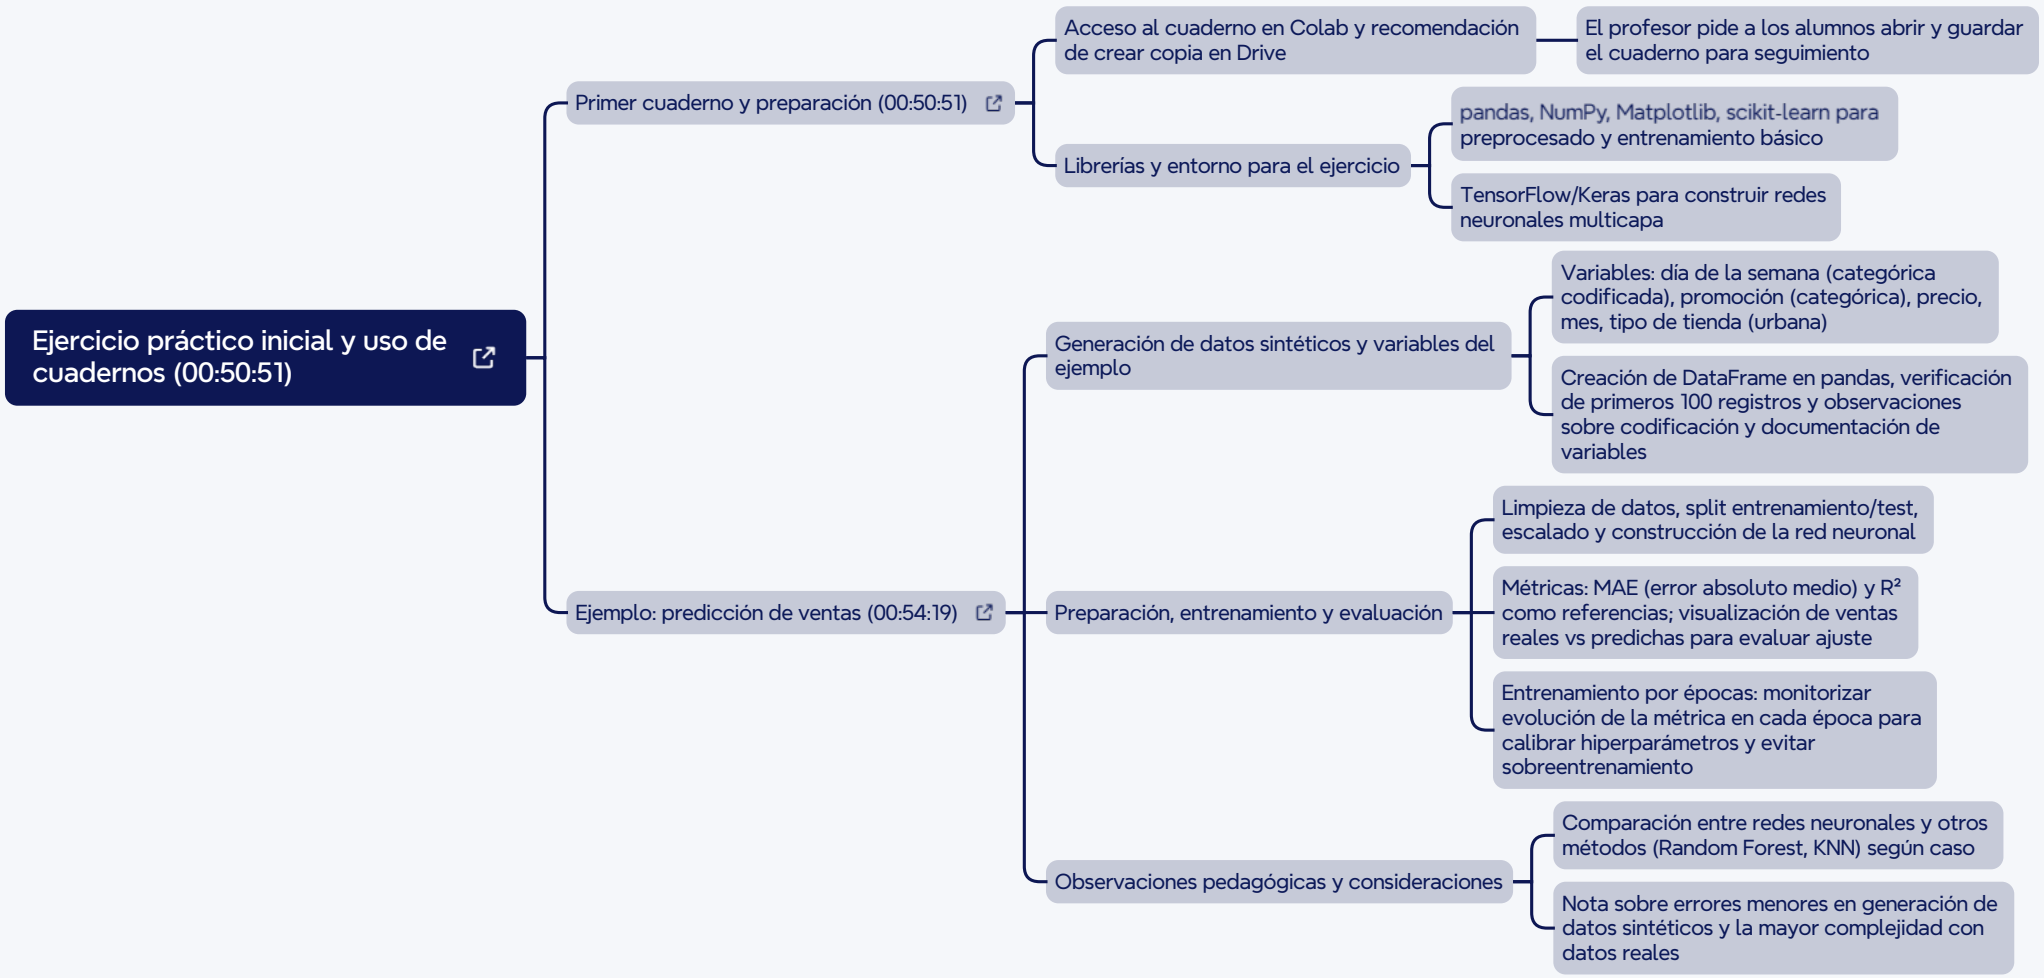

CLASE 15: FUNDAMENTOS AVANZADOS DE REDES NEURONALES - 1RA PARTE
Apertura y logística (00:03:18)
Contenido del módulo 3: redes neuronales y Deep Learning (00:12:36)
Pipeline de digitalización y aplicación práctica (00:34:35)
Contexto histórico y tecnológico (00:40:10)
Ejercicio práctico inicial y uso de cuadernos (00:50:51)
Desarrollo de ejemplos adicionales y prácticas (01:00:06)
Aplicaciones clásicas, limitaciones y nuevas tendencias (01:28:24)
Herramientas prácticas, datasets y ejecución en Colab (02:20:52)
Métodos y algoritmos para clasificación y agrupamiento (02:12:02)
Mantenimiento predictivo y modelos en producción (02:00:03)
Práctica, despliegue y criterios operativos (01:54:45)
Tipos de capas y arquitecturas (01:41:21)
Ejemplos aplicados: scoring crediticio y rotación de personal (01:37:33)

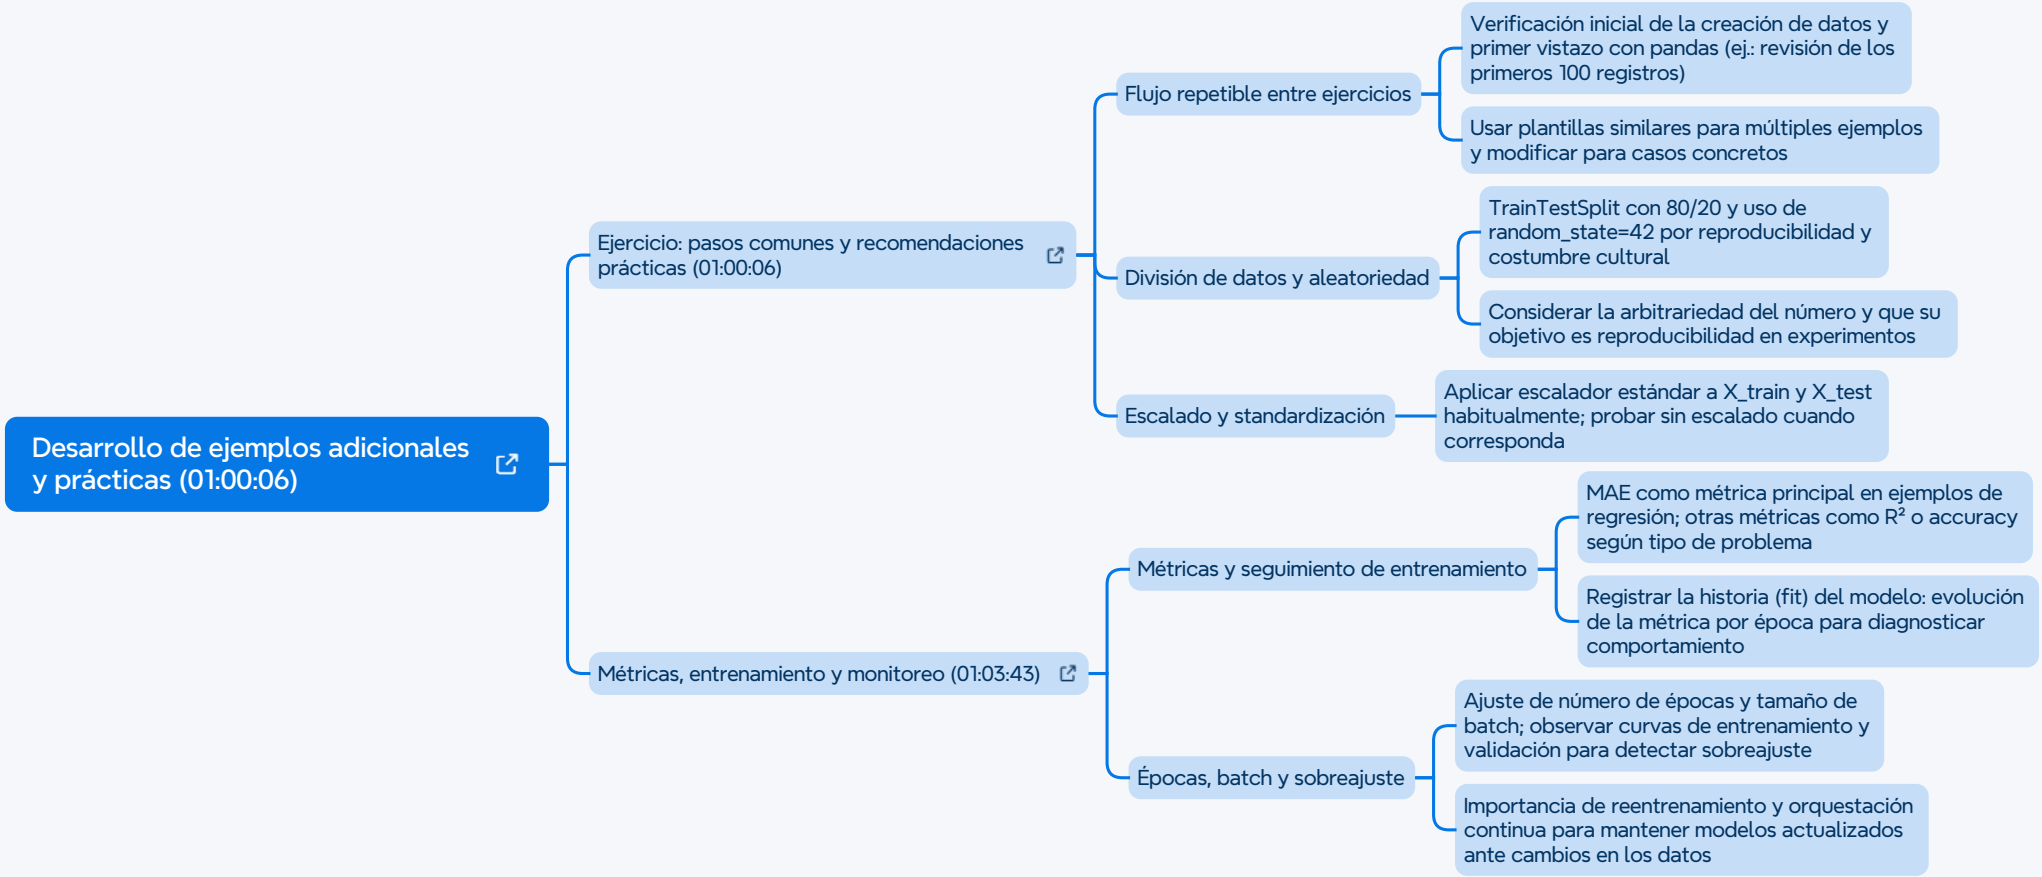

Apertura y logística (00:03:18)
Bienvenida y expectativas del curso (00:03:18)
Inicio de la clase número 15 y presentación del profesor Carlos
Invitación a participar por chat o mano levantada
Recordatorio de ejercicio pendiente con el docente Carlos Auret
Preguntas sobre perfiles y experiencia de los alumnos
Consultas sobre herramientas usadas: Excel, Power BI, Python
Solicitud de proyectos o casos prácticos para trabajar durante el curso
Recursos y herramientas (00:10:48)
Materiales compartidos: diapositivas y cuadernos en Google Drive
El profesor dará enlaces individuales y carpeta con cuadernos para Colab
Recomendación de instalar Orange Data Mining y tener Colab listo
Plataformas y librerías a usar en práctica
Orange para aprendizaje visual y didáctico de modelos
Google Colab, TensorFlow (Keras), pandas, NumPy, Matplotlib, scikit-learn

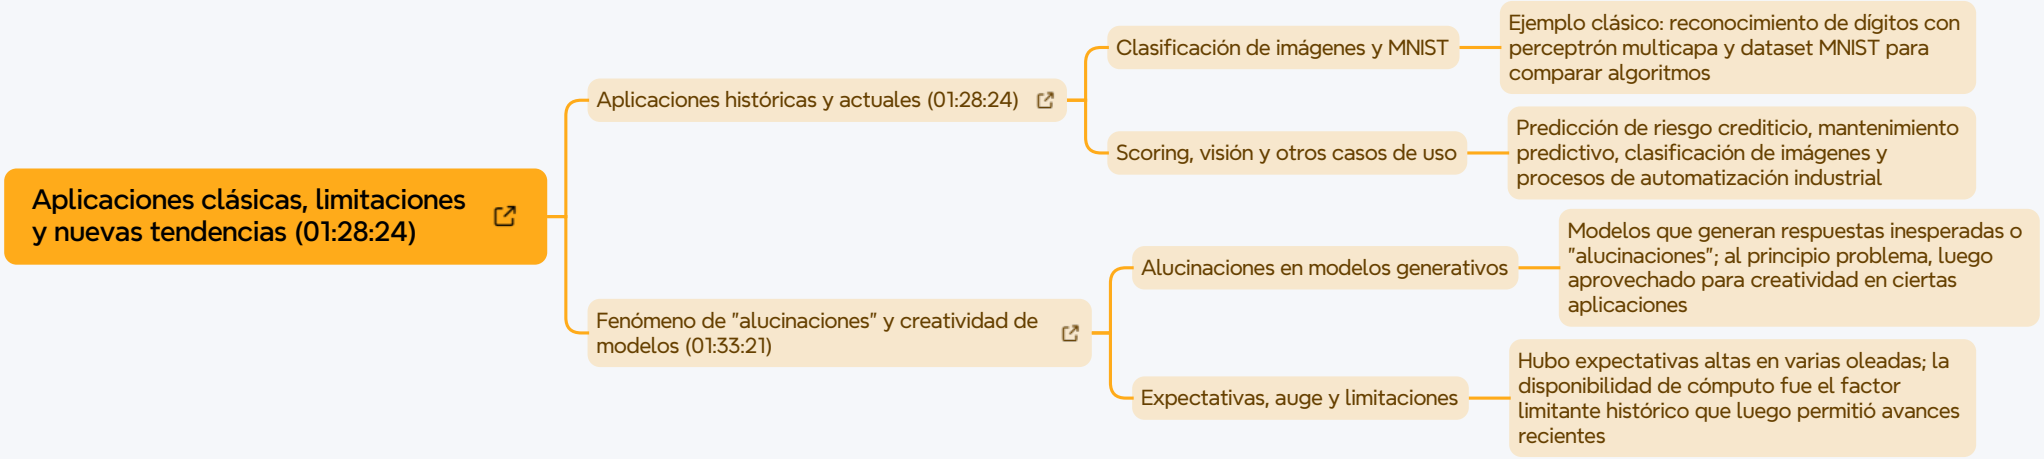

Contenido del módulo 3: redes neuronales y Deep Learning (00:12:36)
Estructura y objetivos del módulo (00:12:36)
Enfoque en redes neuronales y Deep Learning
Primera clase: fundamentos básicos; siguiente clase: fundamentos avanzados y más matemáticos
Balance entre teoría y práctica con ejemplos aplicados a empresas
Plan docente y metodología
Uso de casos empresariales y ejercicios en Orange y Colab
Integración progresiva hacia gestión del ciclo de vida de modelos y monitoreo
Temas principales y cronograma (00:21:52)
Contenidos teóricos inmediatos
Perceptrón simple y multicapa, tipos de capas y aplicabilidad
Arquitecturas modernas de redes neuronales y evolución hacia redes más complejas
Aplicaciones prácticas y sectores objetivo
Retail/e-commerce: predicción de ventas y gestión de inventarios
Sector financiero: análisis, scoring crediticio y puntuación de riesgo
Recursos humanos: rotación de personal y proyecciones de retención
Manufactura y logística: optimización de cadenas y mantenimiento predictivo

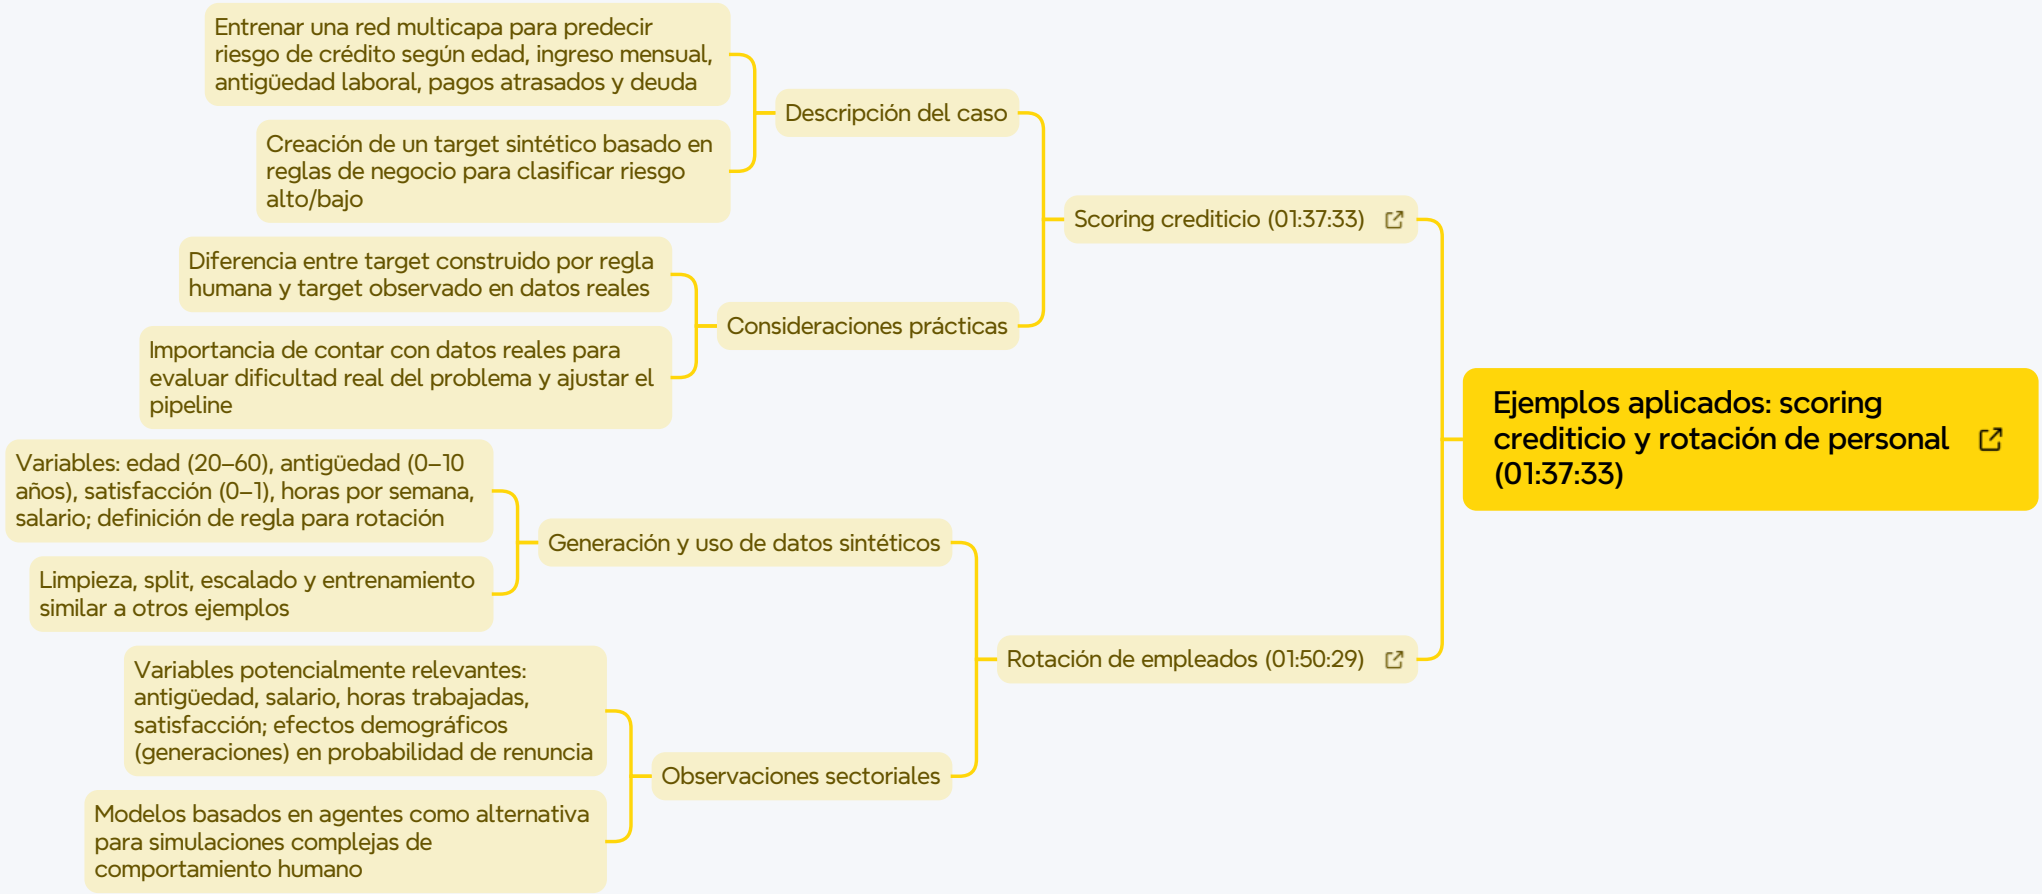

Pipeline de digitalización y aplicación práctica (00:34:35)
Fases del pipeline (00:34:35)
Ingesta y captura de datos
Fuentes: web scraping, APIs, bases de datos, CSV/Excel, IoT; ejemplo: estaciones fotovoltaicas y APIs meteorológicas
Generación de datos sintéticos para experimentación y permiso para usar datos reales más adelante
Limpieza, almacenamiento e integración
Normalización y consolidación de fuentes heterogéneas en repositorios seguros
Importancia de reglas de negocio al crear targets sintéticos (p. ej. scoring o rotación)
Procesamiento, análisis y orquestación (00:37:52)
Modelado y entrenamiento
Uso de modelos desde regresión y scikit-learn hasta redes neuronales y Deep Learning
Separación entreno/test (TrainTestSplit): 80% entrenamiento, 20% test y uso de random_state (costumbre: 42)
Escalado de variables como paso estándar antes del entrenamiento
Consulta, visualización y toma de decisiones
Dashboards y cuadros de mando integrales para interpretar resultados
Orquestación y automatización del pipeline para entrenamiento continuo, reentrenamiento y monitoreo del modelo

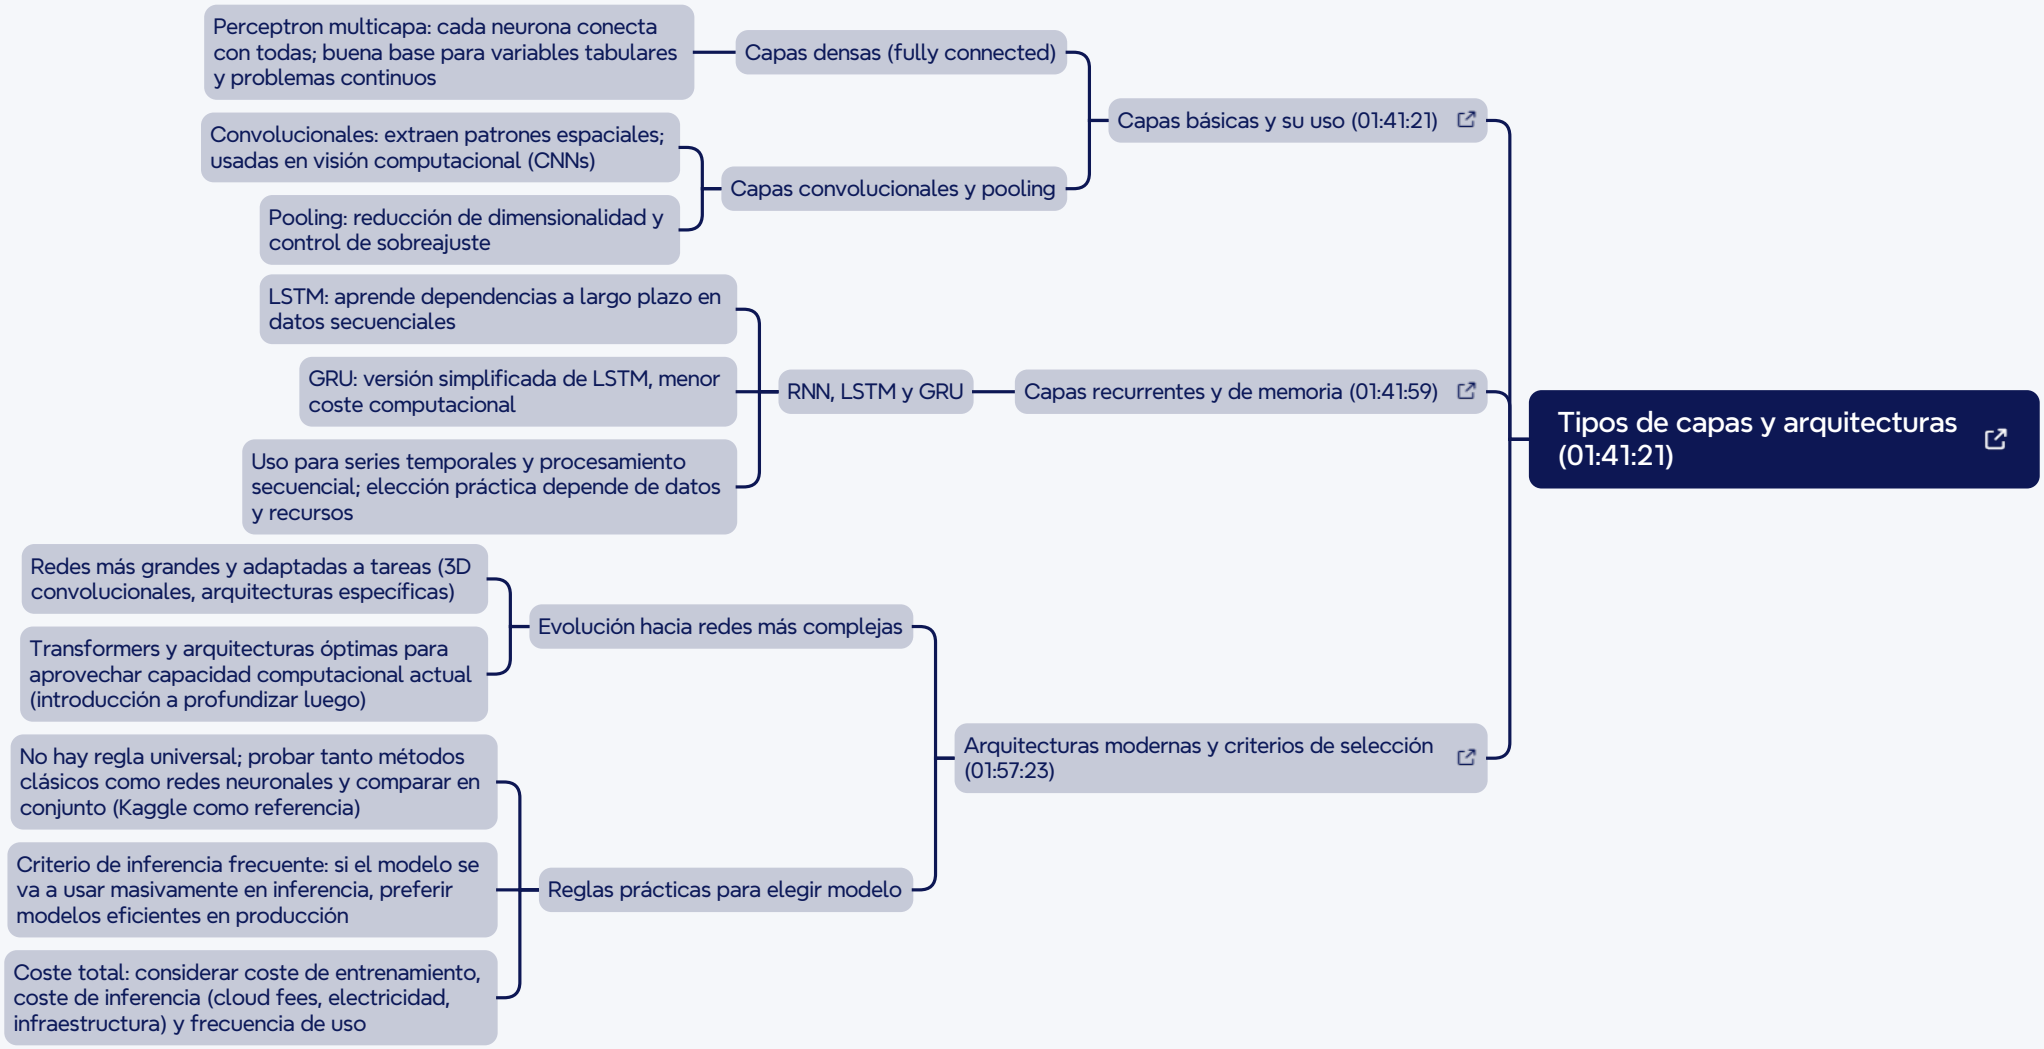

Contexto histórico y tecnológico (00:40:10)
Evolución de la inteligencia artificial y redes neuronales (00:40:10)
Orígenes y perceptrón
Primeros desarrollos desde 1943 y perceptrón como primera red entrenable (Rosenblatt)
Perceptrón simple: unidad básica, función escalón y resolución de problemas linealmente separables
Resurgimiento y llegada del Deep Learning
Descubrimiento del backpropagation en los 80s y aumento de papers académicos
Desde 2006–2012 surge Deep Learning por mayor disponibilidad de datos y GPUs
Factores que impulsaron la adopción actual (00:14:06)
Reducción de costos y mayor potencia computacional
Ley de Moore, proliferación de GPUs y posibilidad de montar máquinas locales potentes
Conectividad y servicios en la nube
Avances en internet y web services (AWS, Google Cloud) que democratizan acceso a modelos y APIs
Economía de inferencia: menor coste por predicción al desplegar modelos, pero acumulación de costos al escala

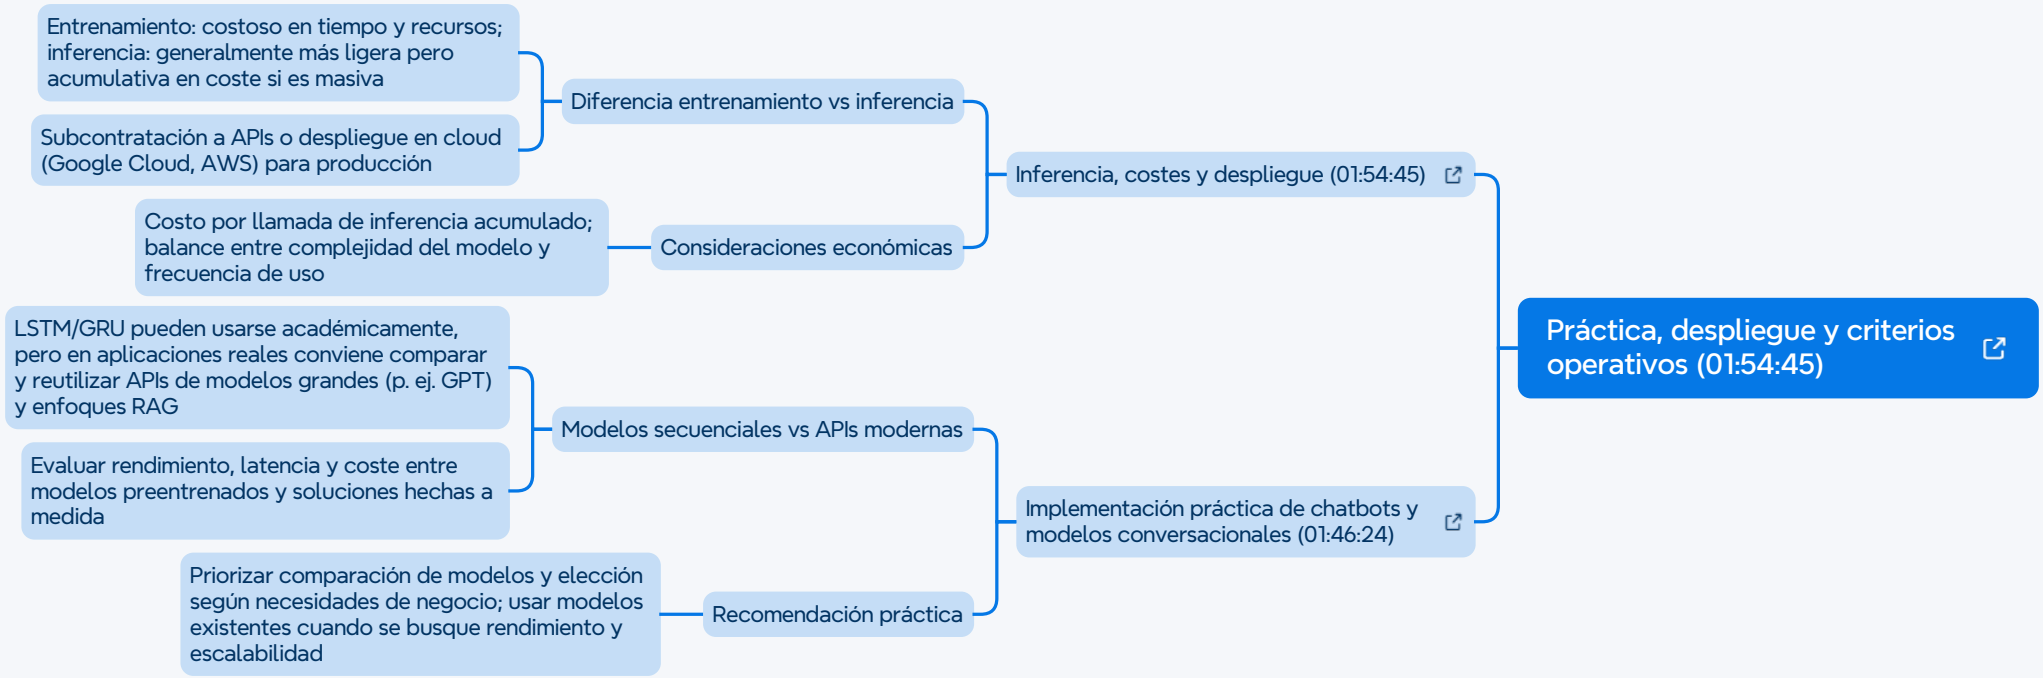

Ejercicio práctico inicial y uso de cuadernos (00:50:51)
Primer cuaderno y preparación (00:50:51)
Acceso al cuaderno en Colab y recomendación de crear copia en Drive
El profesor pide a los alumnos abrir y guardar el cuaderno para seguimiento
Librerías y entorno para el ejercicio
pandas, NumPy, Matplotlib, scikit-learn para preprocesado y entrenamiento básico
TensorFlow/Keras para construir redes neuronales multicapa
Ejemplo: predicción de ventas (00:54:19)
Generación de datos sintéticos y variables del ejemplo
Variables: día de la semana (categórica codificada), promoción (categórica), precio, mes, tipo de tienda (urbana)
Creación de DataFrame en pandas, verificación de primeros 100 registros y observaciones sobre codificación y documentación de variables
Preparación, entrenamiento y evaluación
Limpieza de datos, split entrenamiento/test, escalado y construcción de la red neuronal
Métricas: MAE (error absoluto medio) y R² como referencias; visualización de ventas reales vs predichas para evaluar ajuste
Entrenamiento por épocas: monitorizar evolución de la métrica en cada época para calibrar hiperparámetros y evitar sobreentrenamiento
Observaciones pedagógicas y consideraciones
Comparación entre redes neuronales y otros métodos (Random Forest, KNN) según caso
Nota sobre errores menores en generación de datos sintéticos y la mayor complejidad con datos reales

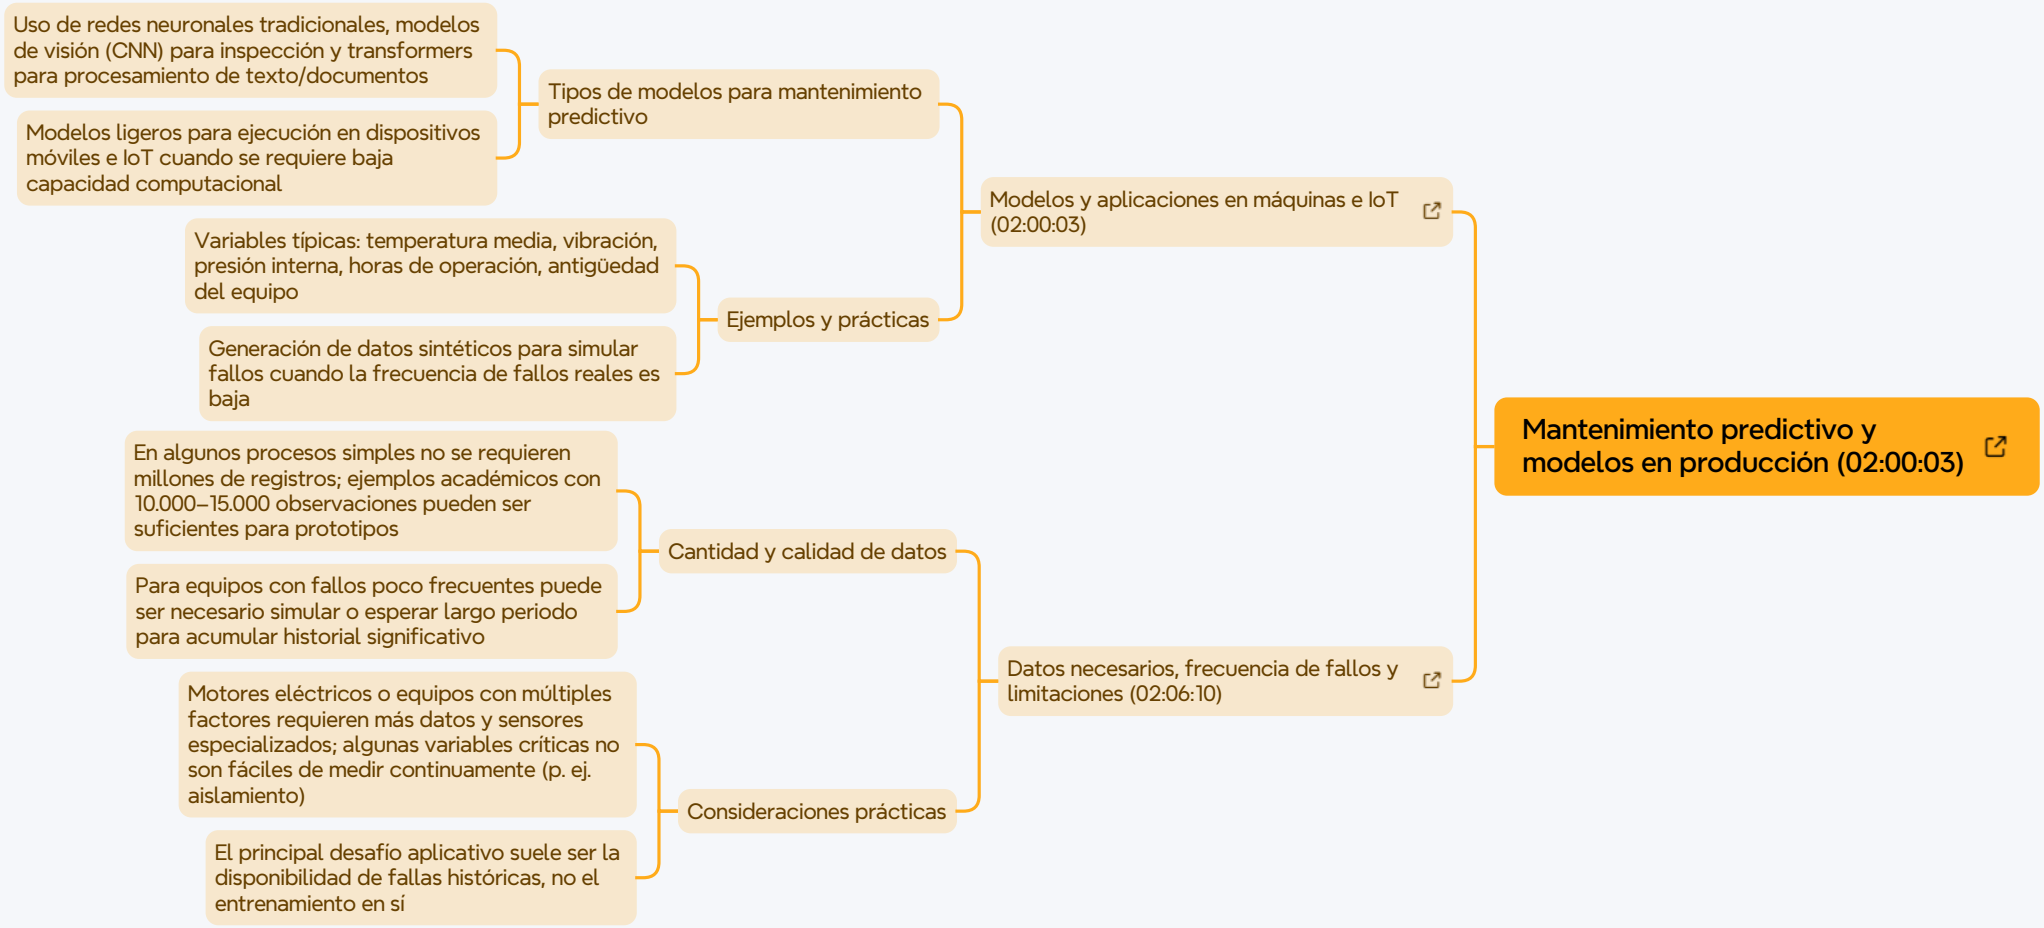

Desarrollo de ejemplos adicionales y prácticas (01:00:06)
Ejercicio: pasos comunes y recomendaciones prácticas (01:00:06)
Flujo repetible entre ejercicios
Verificación inicial de la creación de datos y primer vistazo con pandas (ej.: revisión de los primeros 100 registros)
Usar plantillas similares para múltiples ejemplos y modificar para casos concretos
División de datos y aleatoriedad
TrainTestSplit con 80/20 y uso de random_state=42 por reproducibilidad y costumbre cultural
Considerar la arbitrariedad del número y que su objetivo es reproducibilidad en experimentos
Escalado y standardización
Aplicar escalador estándar a X_train y X_test habitualmente; probar sin escalado cuando corresponda
Métricas, entrenamiento y monitoreo (01:03:43)
Métricas y seguimiento de entrenamiento
MAE como métrica principal en ejemplos de regresión; otras métricas como R² o accuracy según tipo de problema
Registrar la historia (fit) del modelo: evolución de la métrica por época para diagnosticar comportamiento
Épocas, batch y sobreajuste
Ajuste de número de épocas y tamaño de batch; observar curvas de entrenamiento y validación para detectar sobreajuste
Importancia de reentrenamiento y orquestación continua para mantener modelos actualizados ante cambios en los datos

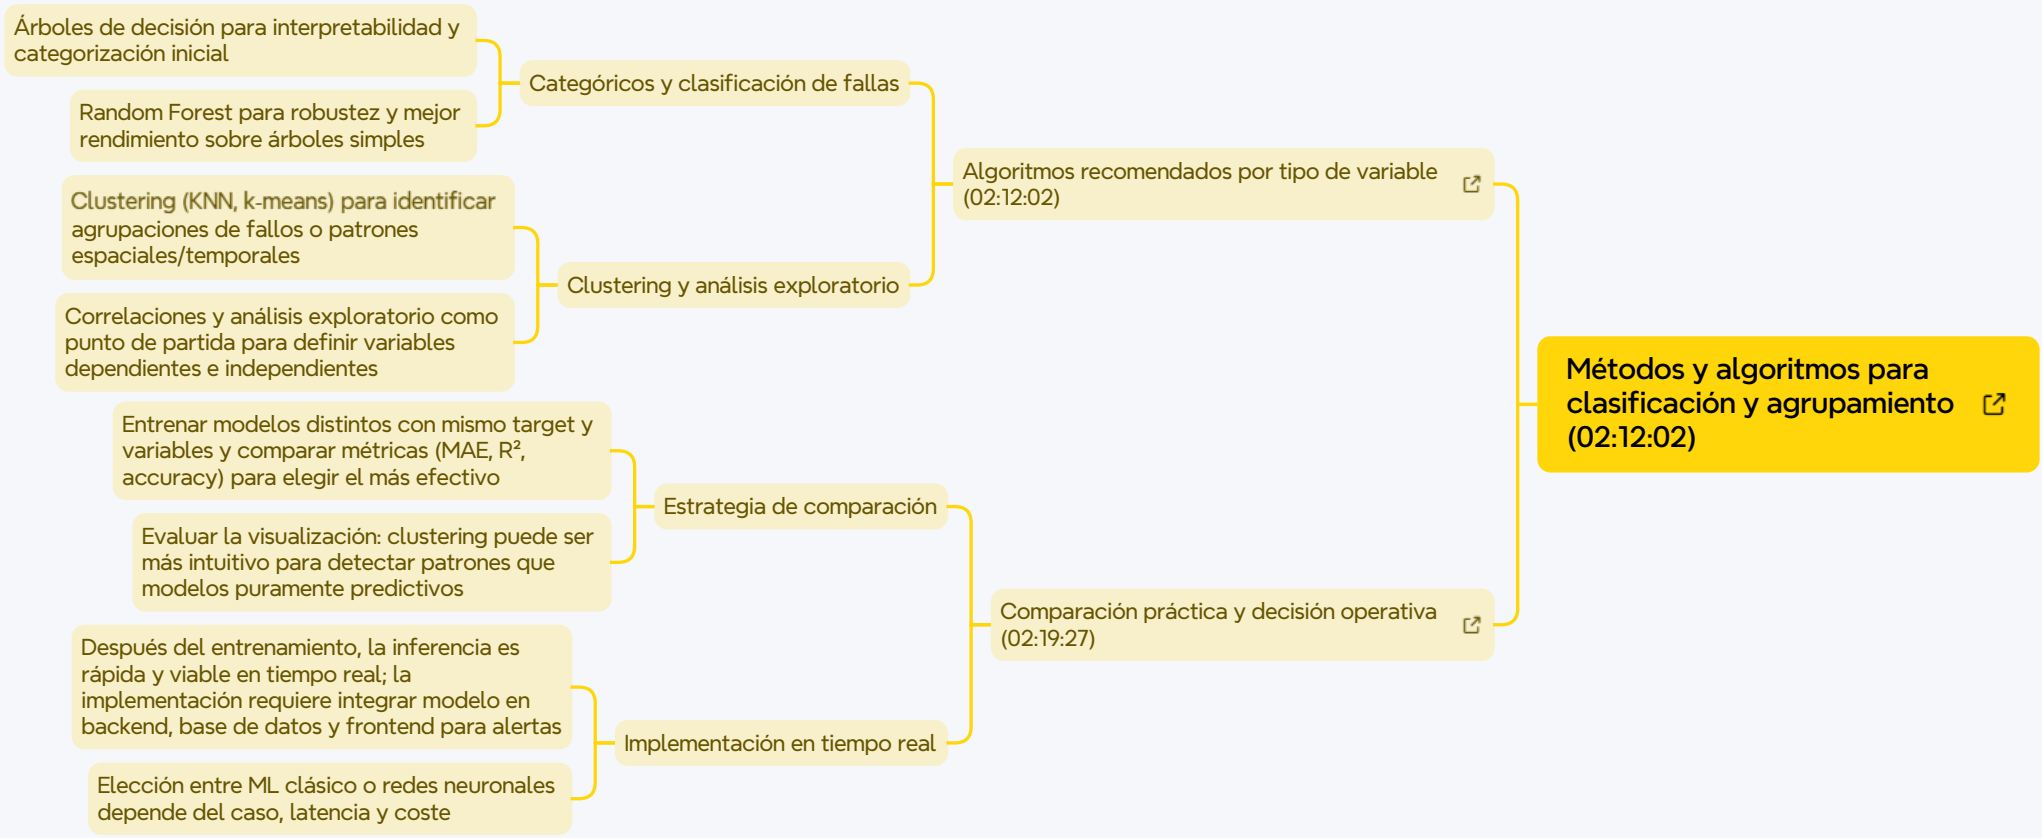

Aplicaciones clásicas, limitaciones y nuevas tendencias (01:28:24)
Aplicaciones históricas y actuales (01:28:24)
Clasificación de imágenes y MNIST
Ejemplo clásico: reconocimiento de dígitos con perceptrón multicapa y dataset MNIST para comparar algoritmos
Scoring, visión y otros casos de uso
Predicción de riesgo crediticio, mantenimiento predictivo, clasificación de imágenes y procesos de automatización industrial
Fenómeno de "alucinaciones" y creatividad de modelos (01:33:21)
Alucinaciones en modelos generativos
Modelos que generan respuestas inesperadas o "alucinaciones"; al principio problema, luego aprovechado para creatividad en ciertas aplicaciones
Expectativas, auge y limitaciones
Hubo expectativas altas en varias oleadas; la disponibilidad de cómputo fue el factor limitante histórico que luego permitió avances recientes

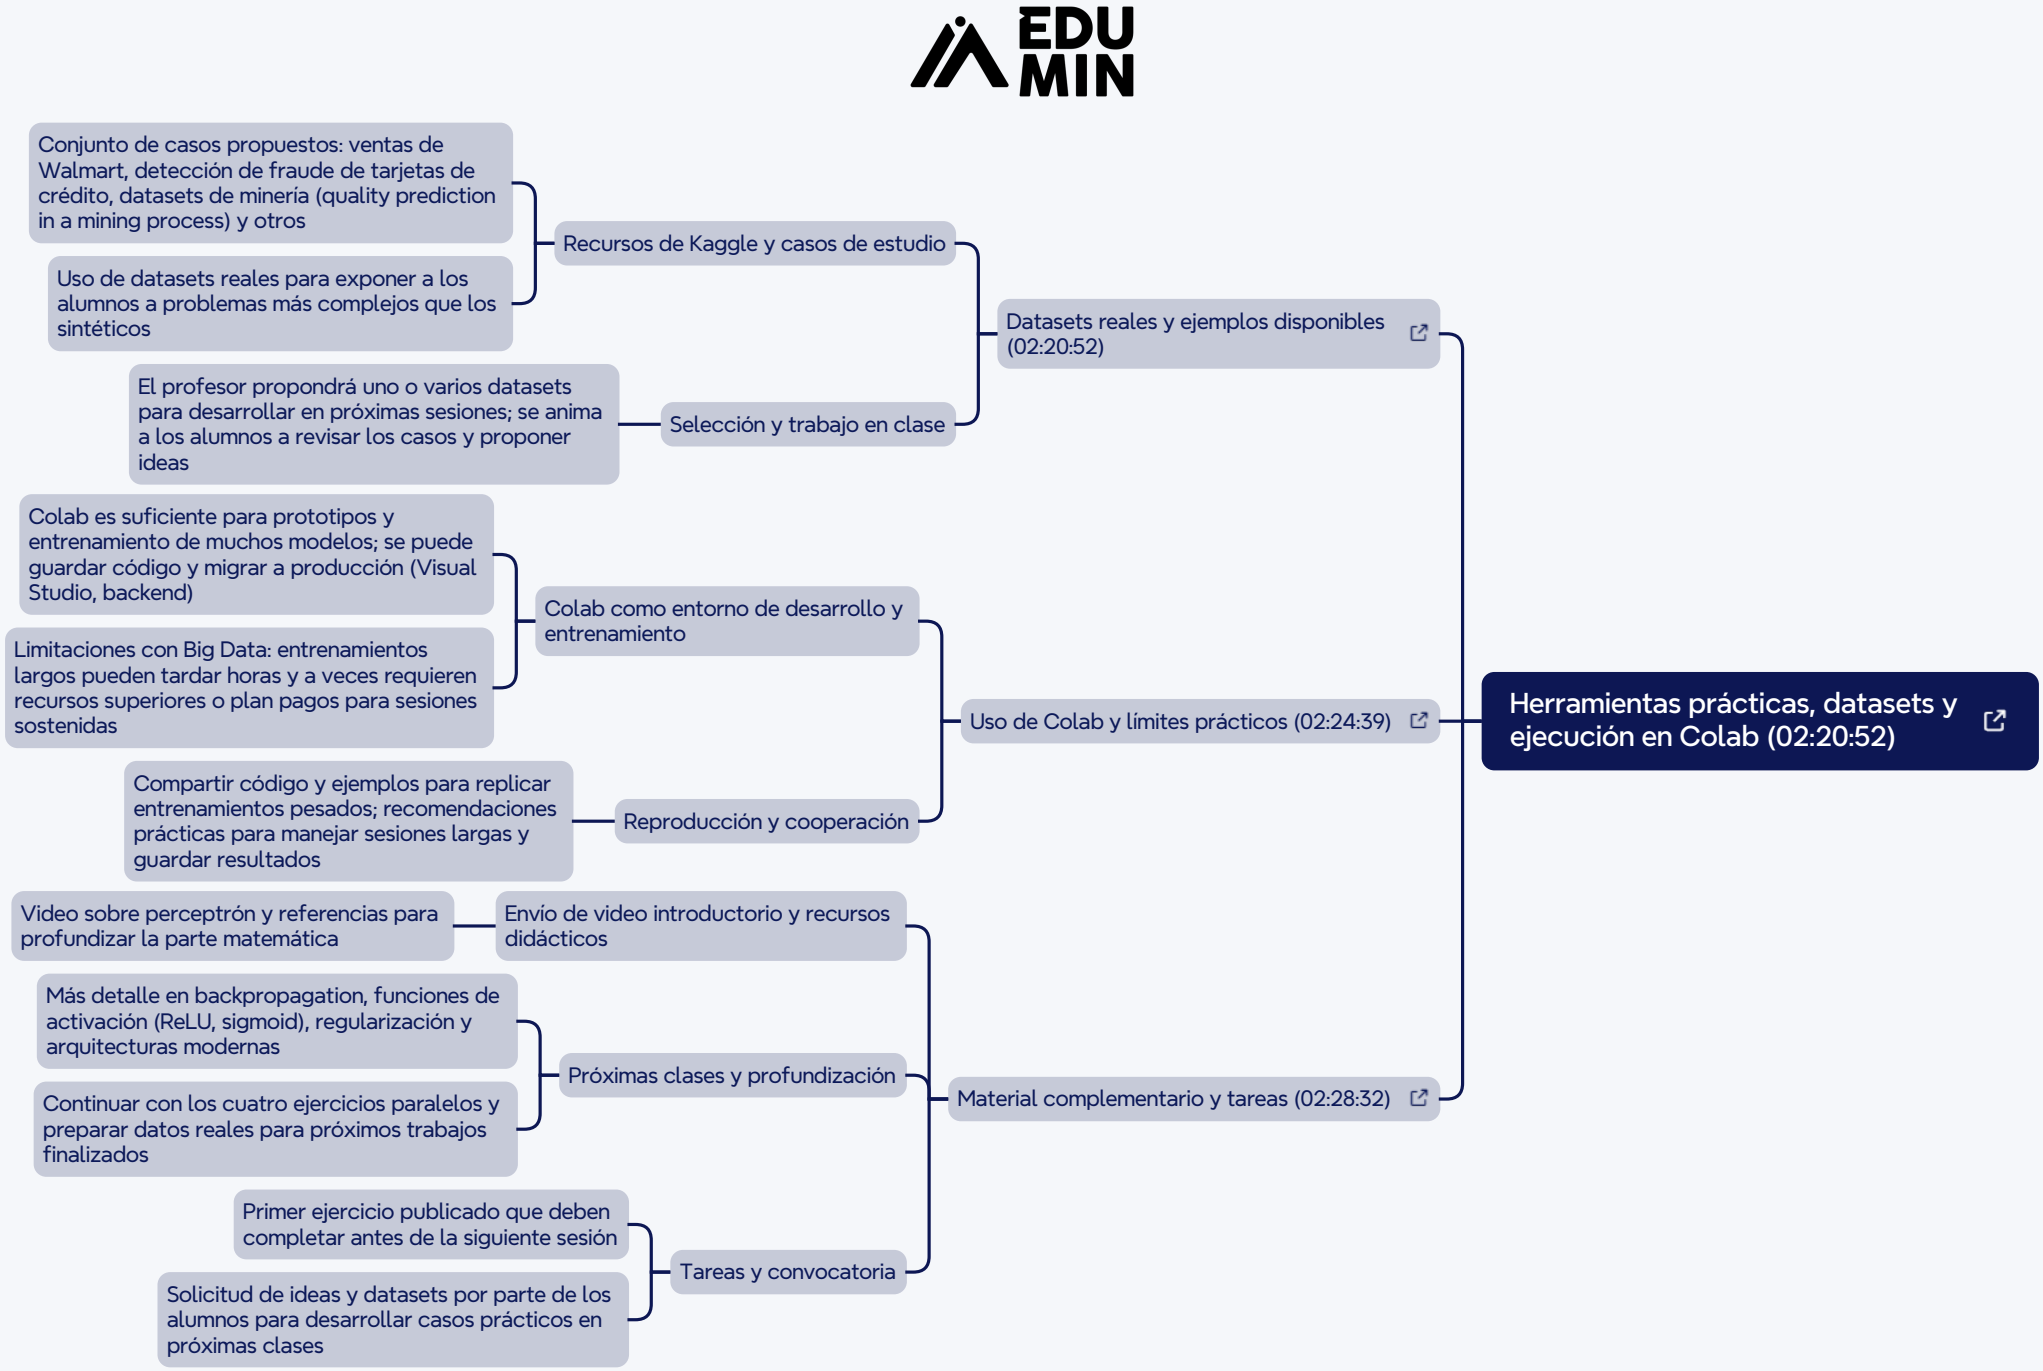

Ejemplos aplicados: scoring crediticio y rotación de personal (01:37:33)
Scoring crediticio (01:37:33)
Descripción del caso
Entrenar una red multicapa para predecir riesgo de crédito según edad, ingreso mensual, antigüedad laboral, pagos atrasados y deuda
Creación de un target sintético basado en reglas de negocio para clasificar riesgo alto/bajo
Consideraciones prácticas
Diferencia entre target construido por regla humana y target observado en datos reales
Importancia de contar con datos reales para evaluar dificultad real del problema y ajustar el pipeline
Rotación de empleados (01:50:29)
Generación y uso de datos sintéticos
Variables: edad (20–60), antigüedad (0–10 años), satisfacción (0–1), horas por semana, salario; definición de regla para rotación
Limpieza, split, escalado y entrenamiento similar a otros ejemplos
Observaciones sectoriales
Variables potencialmente relevantes: antigüedad, salario, horas trabajadas, satisfacción; efectos demográficos (generaciones) en probabilidad de renuncia
Modelos basados en agentes como alternativa para simulaciones complejas de comportamiento humano


Tipos de capas y arquitecturas (01:41:21)
Capas básicas y su uso (01:41:21)
Capas densas (fully connected)
Perceptron multicapa: cada neurona conecta con todas; buena base para variables tabulares y problemas continuos
Capas convolucionales y pooling
Convolucionales: extraen patrones espaciales; usadas en visión computacional (CNNs)
Pooling: reducción de dimensionalidad y control de sobreajuste
Capas recurrentes y de memoria (01:41:59)
RNN, LSTM y GRU
LSTM: aprende dependencias a largo plazo en datos secuenciales
GRU: versión simplificada de LSTM, menor coste computacional
Uso para series temporales y procesamiento secuencial; elección práctica depende de datos y recursos
Arquitecturas modernas y criterios de selección (01:57:23)
Evolución hacia redes más complejas
Redes más grandes y adaptadas a tareas (3D convolucionales, arquitecturas específicas)
Transformers y arquitecturas óptimas para aprovechar capacidad computacional actual (introducción a profundizar luego)
Reglas prácticas para elegir modelo
No hay regla universal; probar tanto métodos clásicos como redes neuronales y comparar en conjunto (Kaggle como referencia)
Criterio de inferencia frecuente: si el modelo se va a usar masivamente en inferencia, preferir modelos eficientes en producción
Coste total: considerar coste de entrenamiento, coste de inferencia (cloud fees, electricidad, infraestructura) y frecuencia de uso


Práctica, despliegue y criterios operativos (01:54:45)
Inferencia, costes y despliegue (01:54:45)
Diferencia entrenamiento vs inferencia
Entrenamiento: costoso en tiempo y recursos; inferencia: generalmente más ligera pero acumulativa en coste si es masiva
Subcontratación a APIs o despliegue en cloud (Google Cloud, AWS) para producción
Consideraciones económicas
Costo por llamada de inferencia acumulado; balance entre complejidad del modelo y frecuencia de uso
Implementación práctica de chatbots y modelos conversacionales (01:46:24)
Modelos secuenciales vs APIs modernas
LSTM/GRU pueden usarse académicamente, pero en aplicaciones reales conviene comparar y reutilizar APIs de modelos grandes (p. ej. GPT) y enfoques RAG
Evaluar rendimiento, latencia y coste entre modelos preentrenados y soluciones hechas a medida
Recomendación práctica
Priorizar comparación de modelos y elección según necesidades de negocio; usar modelos existentes cuando se busque rendimiento y escalabilidad


Mantenimiento predictivo y modelos en producción (02:00:03)
Modelos y aplicaciones en máquinas e IoT (02:00:03)
Tipos de modelos para mantenimiento predictivo
Uso de redes neuronales tradicionales, modelos de visión (CNN) para inspección y transformers para procesamiento de texto/documentos
Modelos ligeros para ejecución en dispositivos móviles e IoT cuando se requiere baja capacidad computacional
Ejemplos y prácticas
Variables típicas: temperatura media, vibración, presión interna, horas de operación, antigüedad del equipo
Generación de datos sintéticos para simular fallos cuando la frecuencia de fallos reales es baja
Datos necesarios, frecuencia de fallos y limitaciones (02:06:10)
Cantidad y calidad de datos
En algunos procesos simples no se requieren millones de registros; ejemplos académicos con 10.000–15.000 observaciones pueden ser suficientes para prototipos
Para equipos con fallos poco frecuentes puede ser necesario simular o esperar largo periodo para acumular historial significativo
Consideraciones prácticas
Motores eléctricos o equipos con múltiples factores requieren más datos y sensores especializados; algunas variables críticas no son fáciles de medir continuamente (p. ej. aislamiento)
El principal desafío aplicativo suele ser la disponibilidad de fallas históricas, no el entrenamiento en sí


Métodos y algoritmos para clasificación y agrupamiento (02:12:02)
Algoritmos recomendados por tipo de variable (02:12:02)
Categóricos y clasificación de fallas
Árboles de decisión para interpretabilidad y categorización inicial
Random Forest para robustez y mejor rendimiento sobre árboles simples
Clustering y análisis exploratorio
Clustering (KNN, k-means) para identificar agrupaciones de fallos o patrones espaciales/temporales
Correlaciones y análisis exploratorio como punto de partida para definir variables dependientes e independientes
Comparación práctica y decisión operativa (02:19:27)
Estrategia de comparación
Entrenar modelos distintos con mismo target y variables y comparar métricas (MAE, R², accuracy) para elegir el más efectivo
Evaluar la visualización: clustering puede ser más intuitivo para detectar patrones que modelos puramente predictivos
Implementación en tiempo real
Después del entrenamiento, la inferencia es rápida y viable en tiempo real; la implementación requiere integrar modelo en backend, base de datos y frontend para alertas
Elección entre ML clásico o redes neuronales depende del caso, latencia y coste


Herramientas prácticas, datasets y ejecución en Colab (02:20:52)
Datasets reales y ejemplos disponibles (02:20:52)
Recursos de Kaggle y casos de estudio
Conjunto de casos propuestos: ventas de Walmart, detección de fraude de tarjetas de crédito, datasets de minería (quality prediction in a mining process) y otros
Uso de datasets reales para exponer a los alumnos a problemas más complejos que los sintéticos
Selección y trabajo en clase
El profesor propondrá uno o varios datasets para desarrollar en próximas sesiones; se anima a los alumnos a revisar los casos y proponer ideas
Uso de Colab y límites prácticos (02:24:39)
Colab como entorno de desarrollo y entrenamiento
Colab es suficiente para prototipos y entrenamiento de muchos modelos; se puede guardar código y migrar a producción (Visual Studio, backend)
Limitaciones con Big Data: entrenamientos largos pueden tardar horas y a veces requieren recursos superiores o plan pagos para sesiones sostenidas
Reproducción y cooperación
Compartir código y ejemplos para replicar entrenamientos pesados; recomendaciones prácticas para manejar sesiones largas y guardar resultados
Material complementario y tareas (02:28:32)
Envío de video introductorio y recursos didácticos
Video sobre perceptrón y referencias para profundizar la parte matemática
Próximas clases y profundización
Más detalle en backpropagation, funciones de activación (ReLU, sigmoid), regularización y arquitecturas modernas
Continuar con los cuatro ejercicios paralelos y preparar datos reales para próximos trabajos finalizados
Tareas y convocatoria
Primer ejercicio publicado que deben completar antes de la siguiente sesión
Solicitud de ideas y datasets por parte de los alumnos para desarrollar casos prácticos en próximas clases