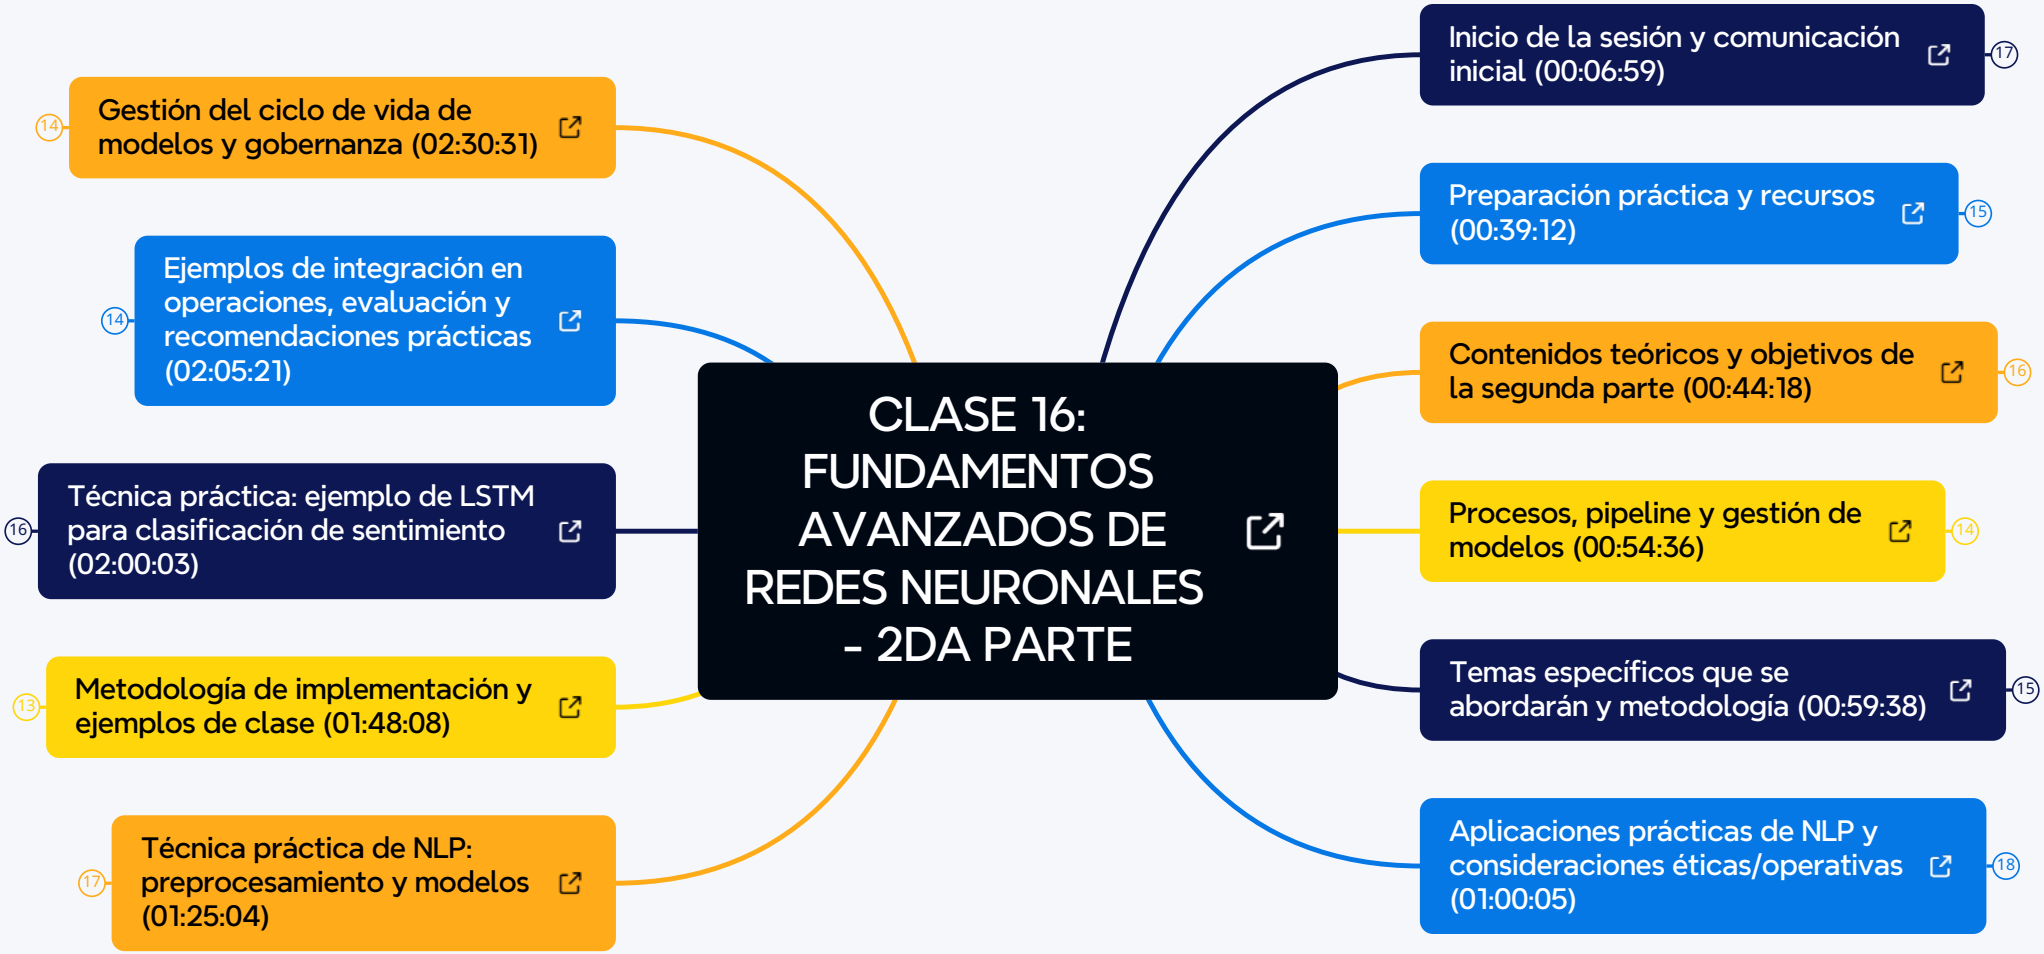
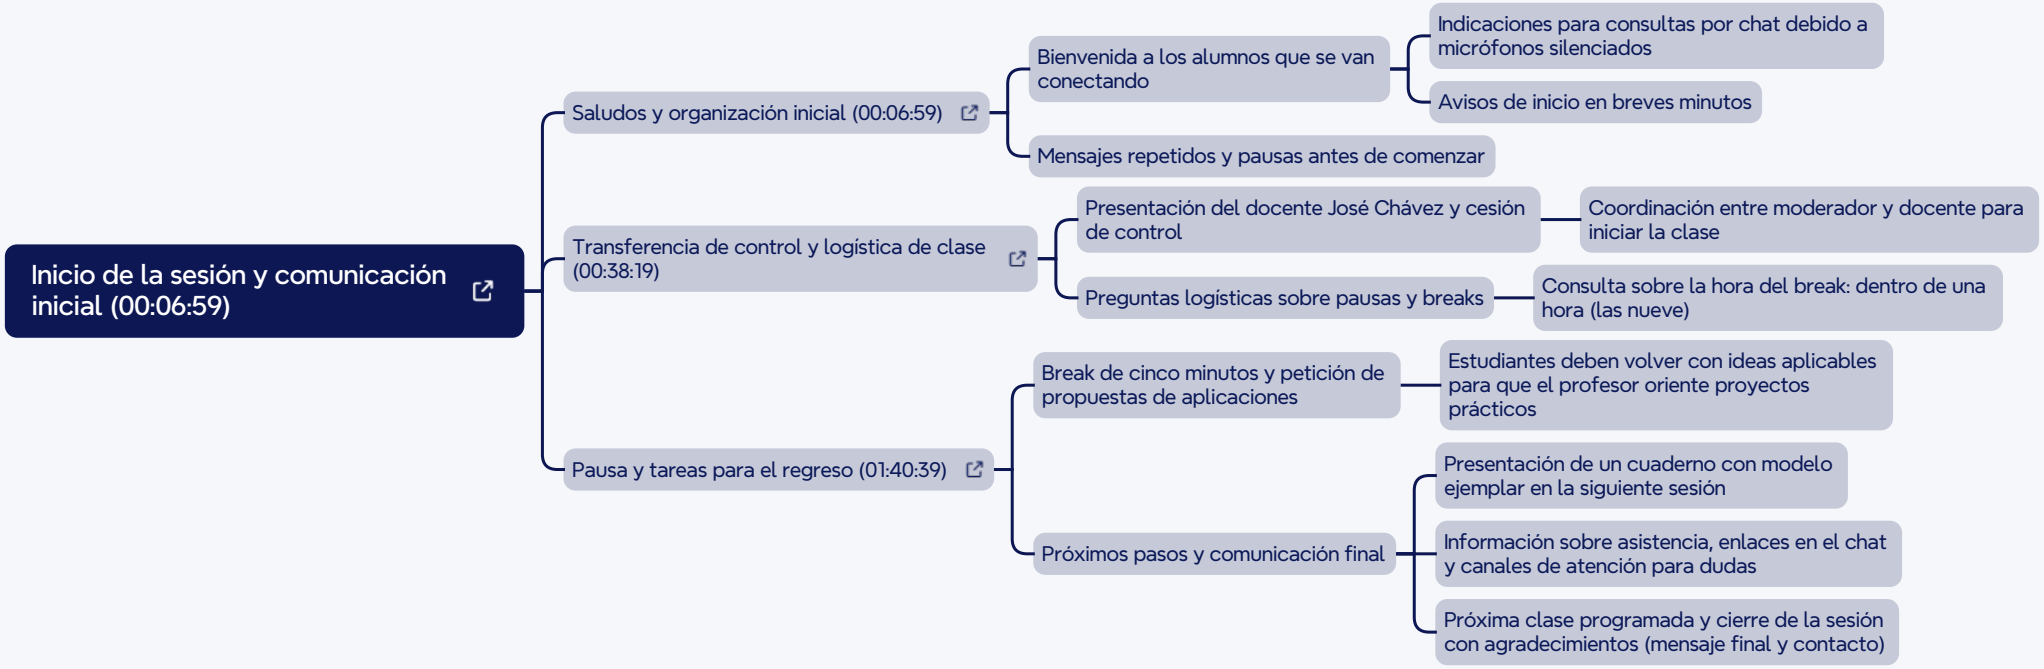
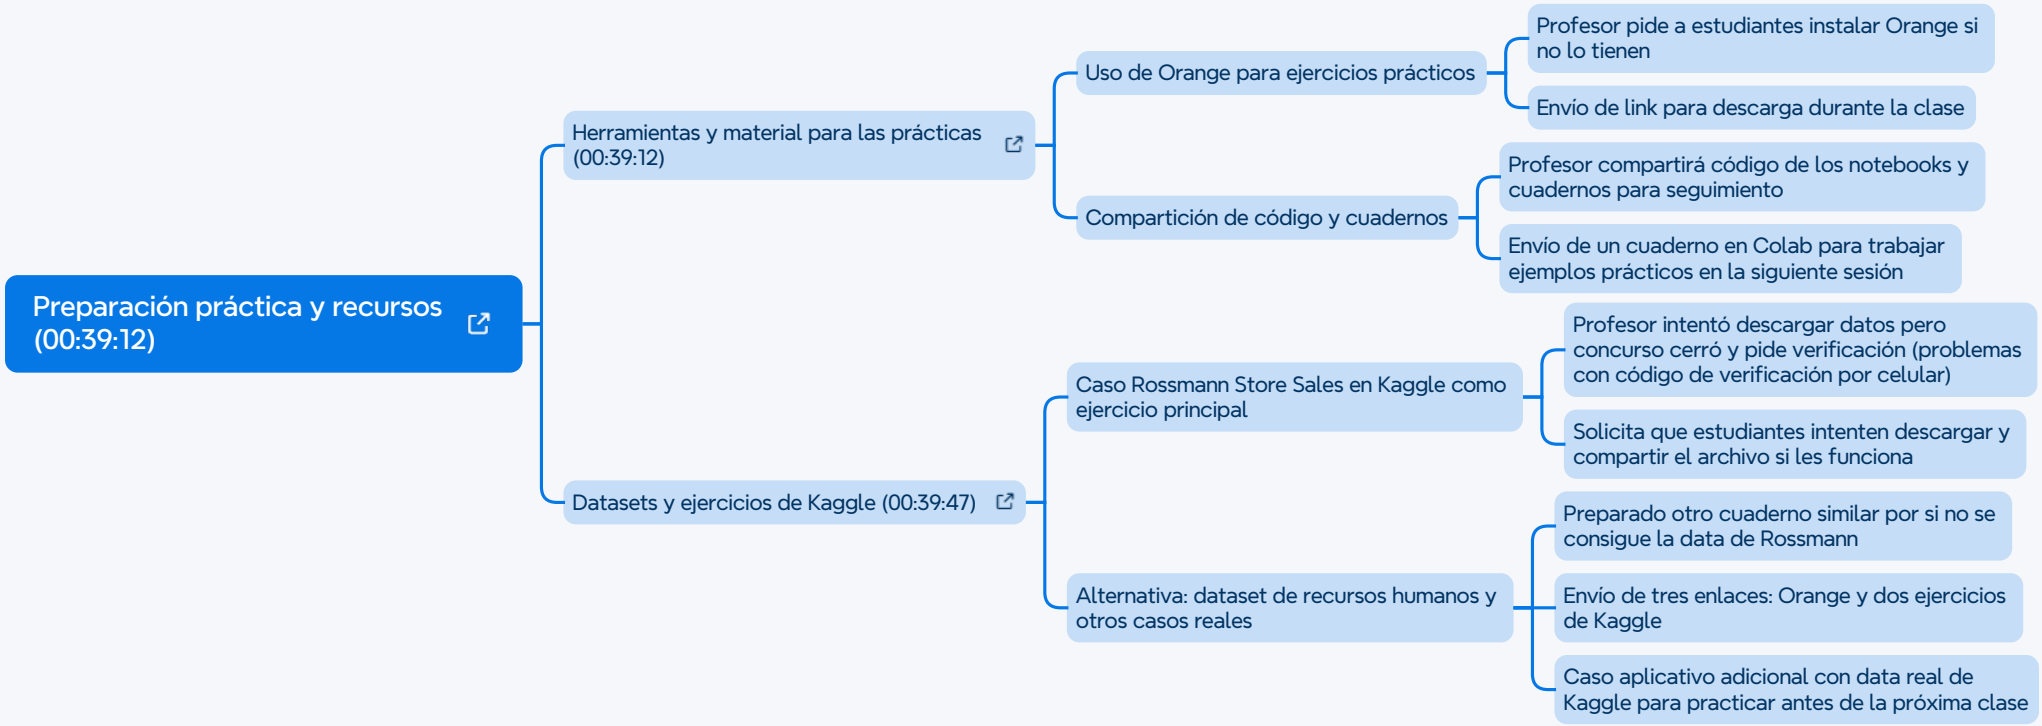
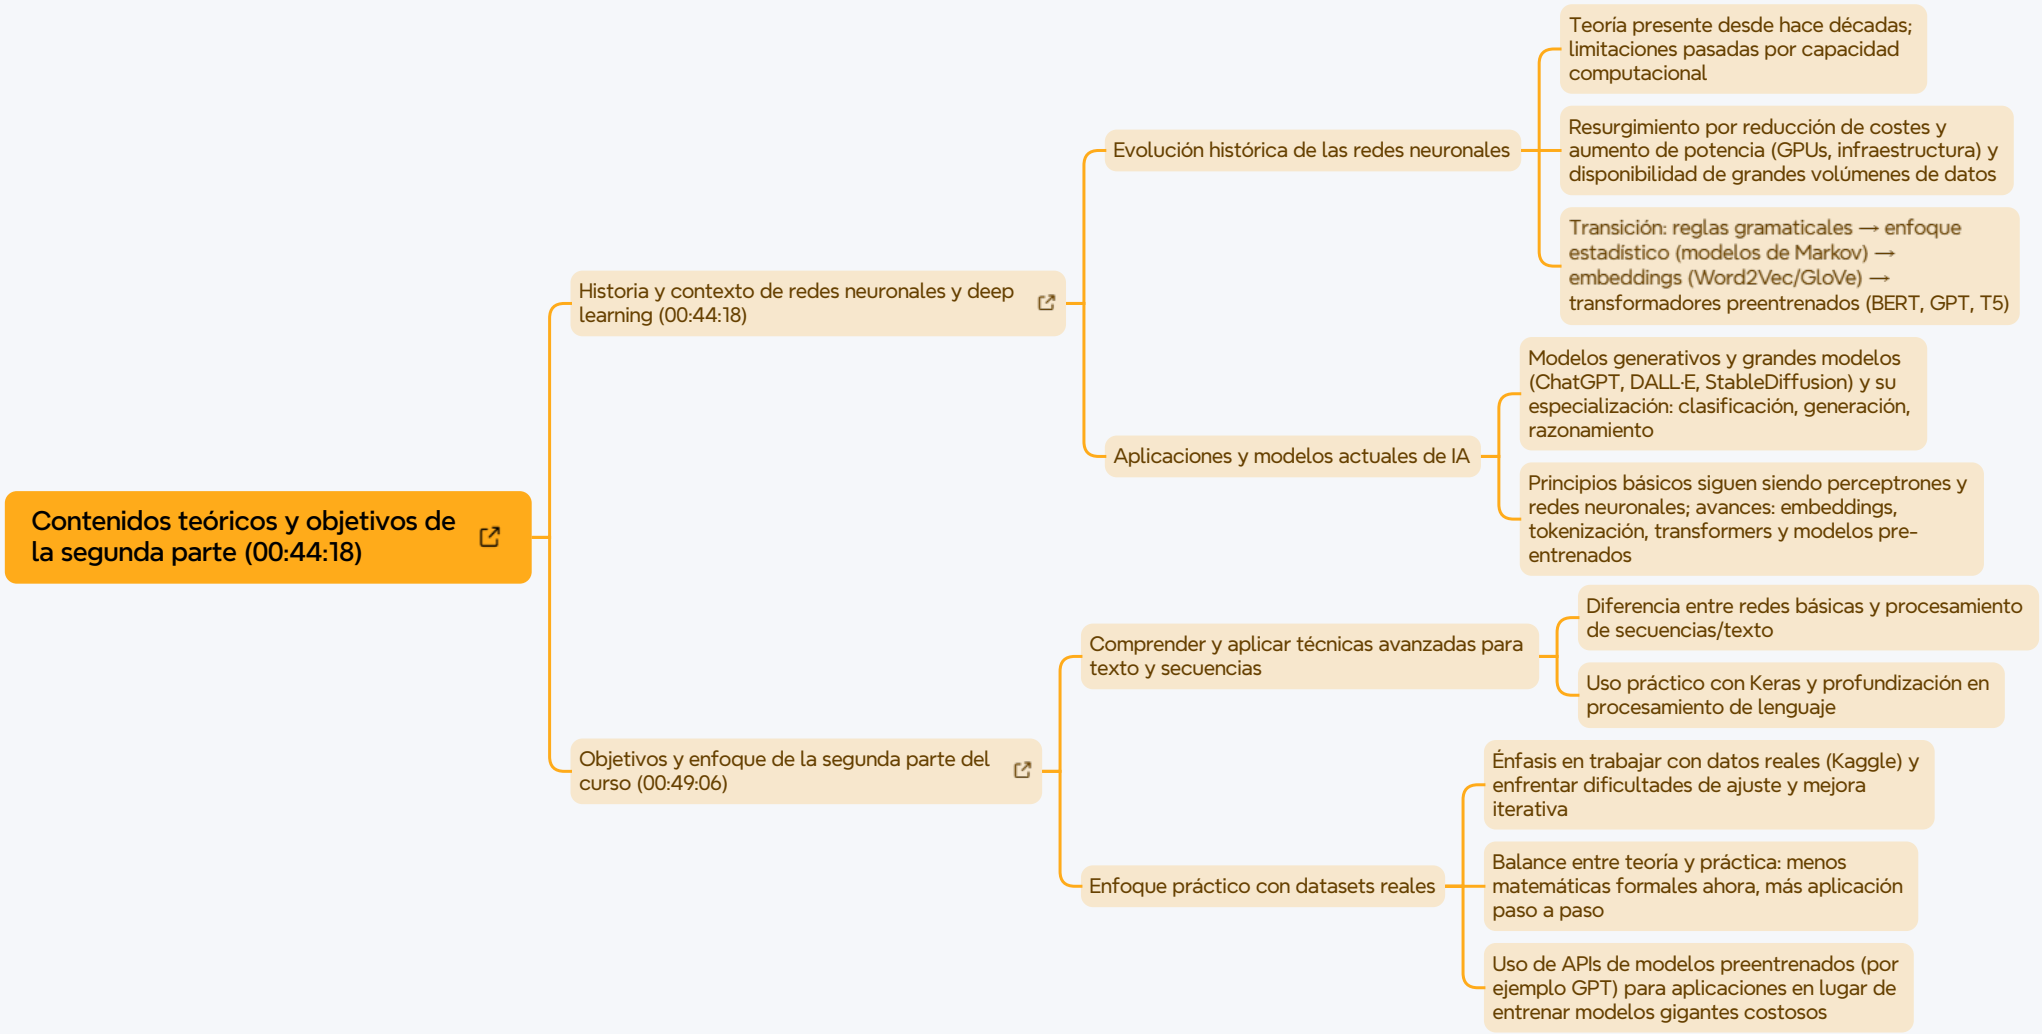
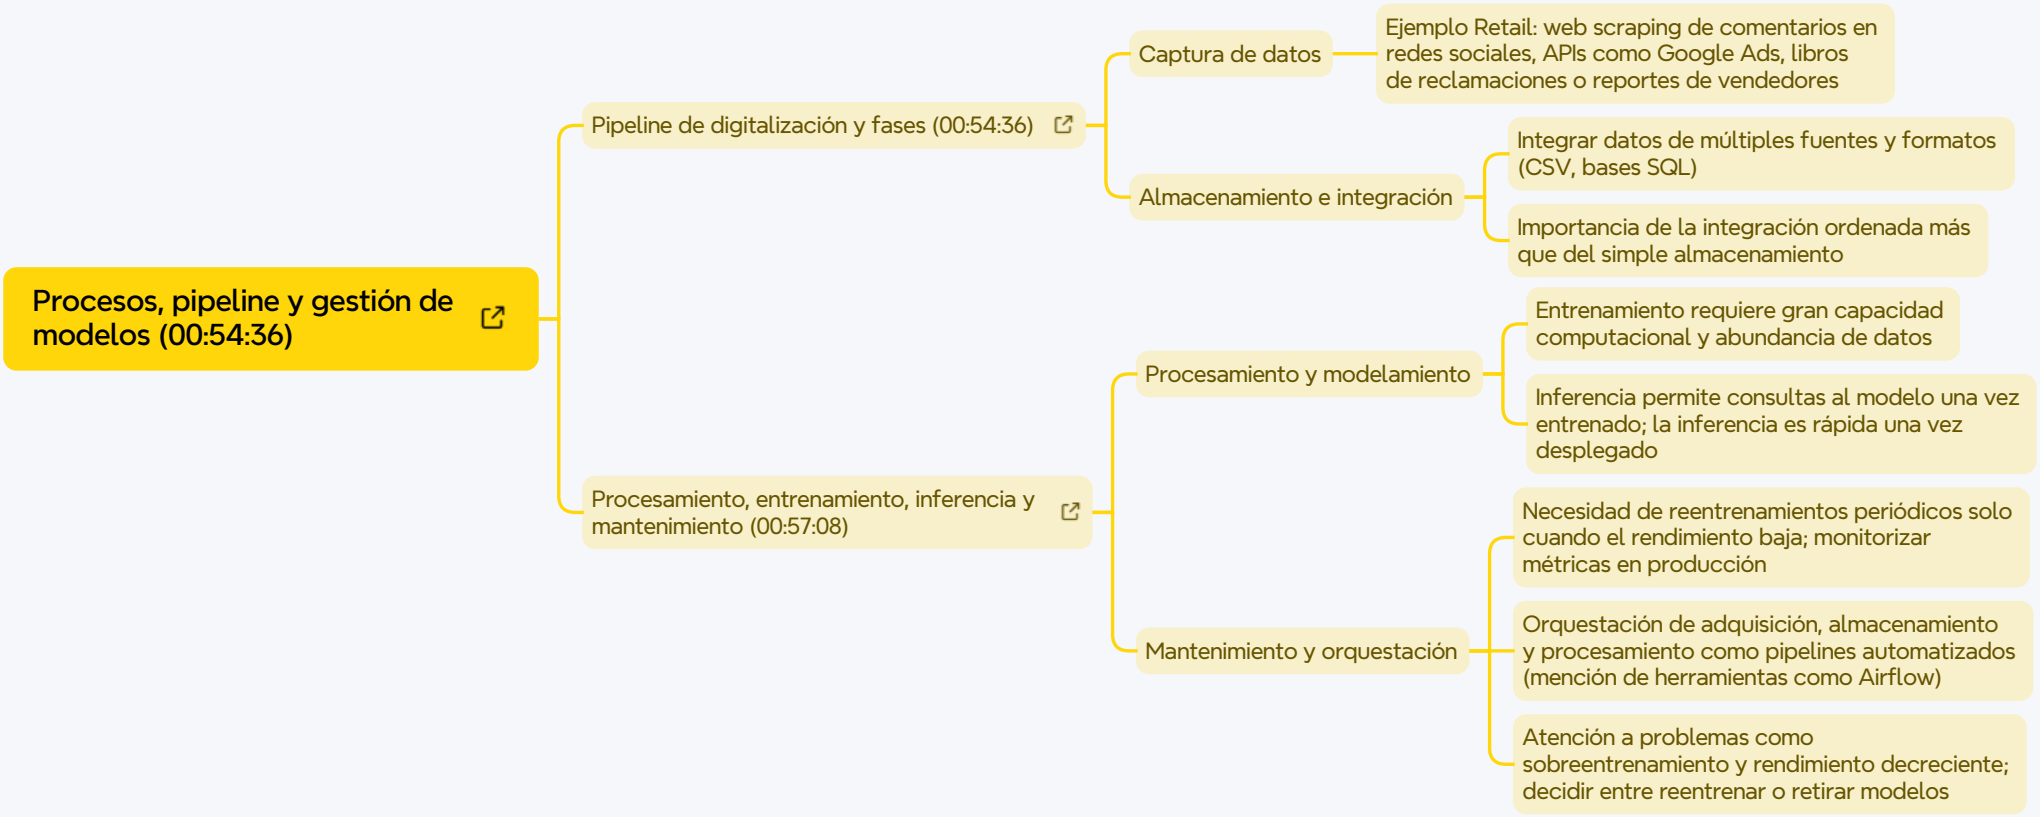
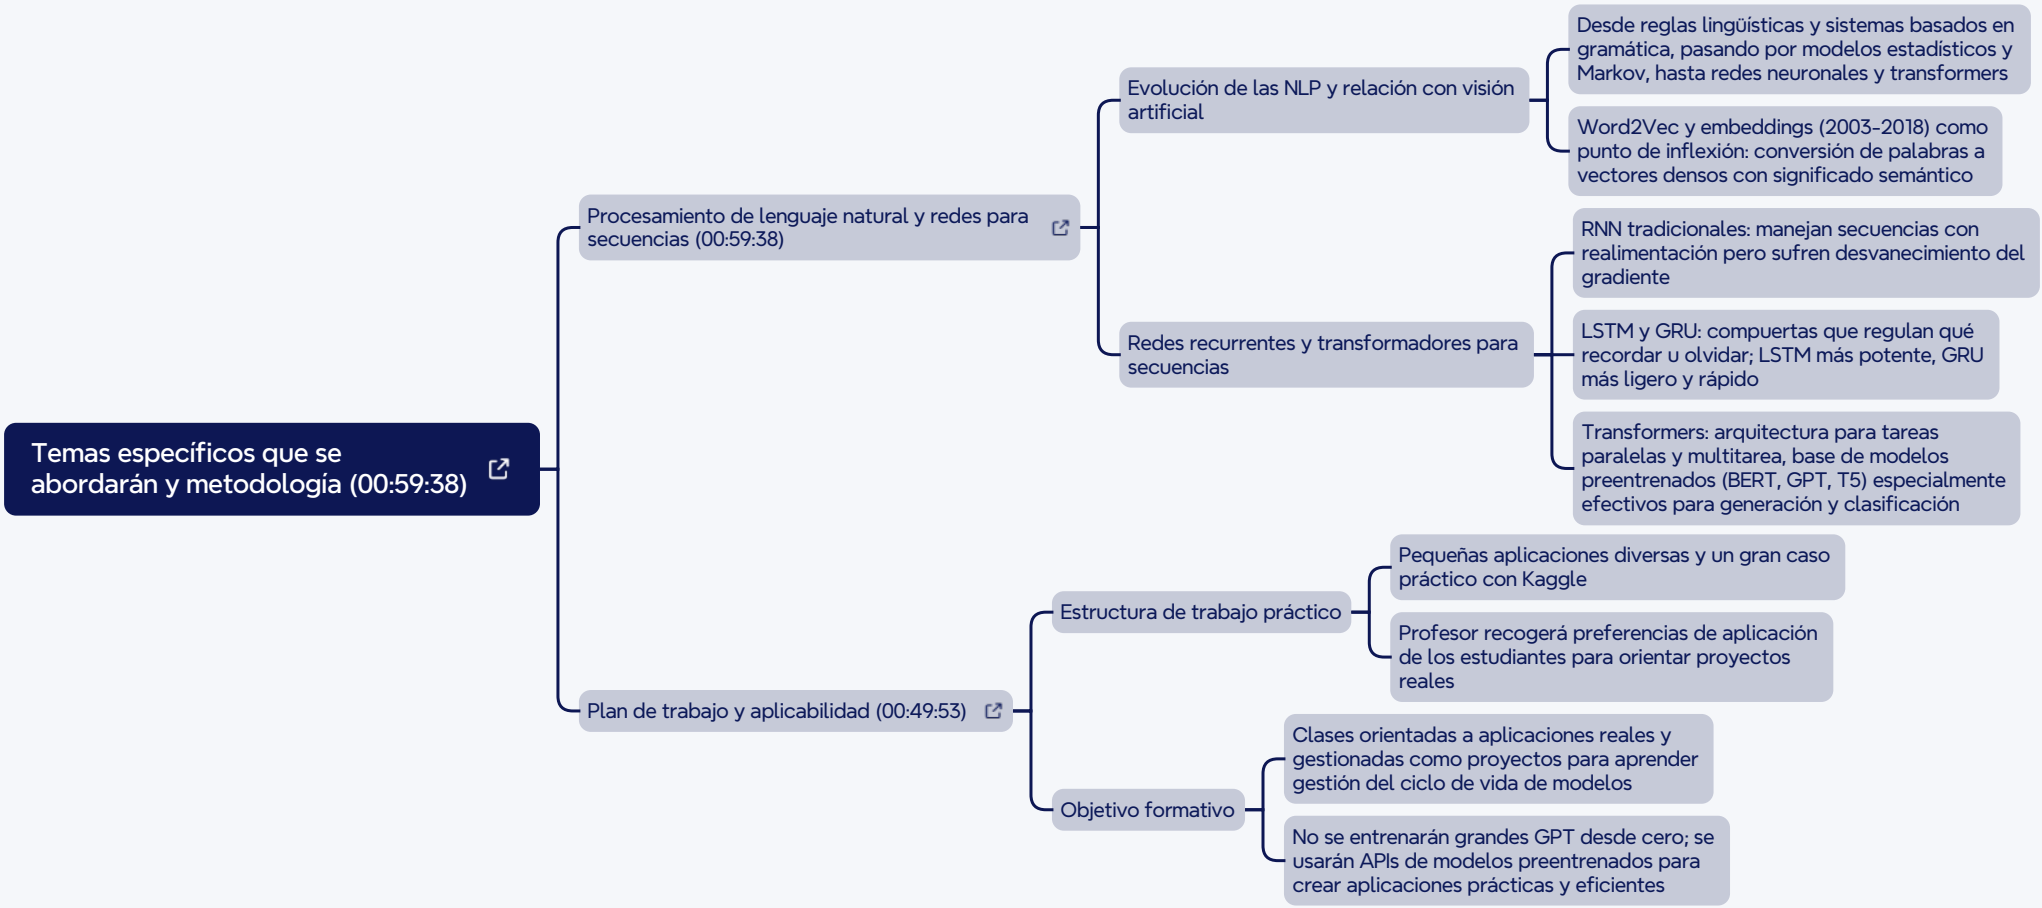

CLASE 16: FUNDAMENTOS AVANZADOS DE REDES NEURONALES - 2DA PARTE
Inicio de la sesión y comunicación inicial (00:06:59)
17
Preparación práctica y recursos (00:39:12)
15
Contenidos teóricos y objetivos de la segunda parte (00:44:18)
16
Procesos, pipeline y gestión de modelos (00:54:36)
14
Temas específicos que se abordarán y metodología (00:59:38)
15
Aplicaciones prácticas de NLP y consideraciones éticas/operativas (01:00:05)
18
Gestión del ciclo de vida de modelos y gobernanza (02:30:31)
14
Ejemplos de integración en operaciones, evaluación y recomendaciones prácticas (02:05:21)
14
Técnica práctica: ejemplo de LSTM para clasificación de sentimiento (02:00:03)
16
Metodología de implementación y ejemplos de clase (01:48:08)
13
Técnica práctica de NLP: preprocesamiento y modelos (01:25:04)
17

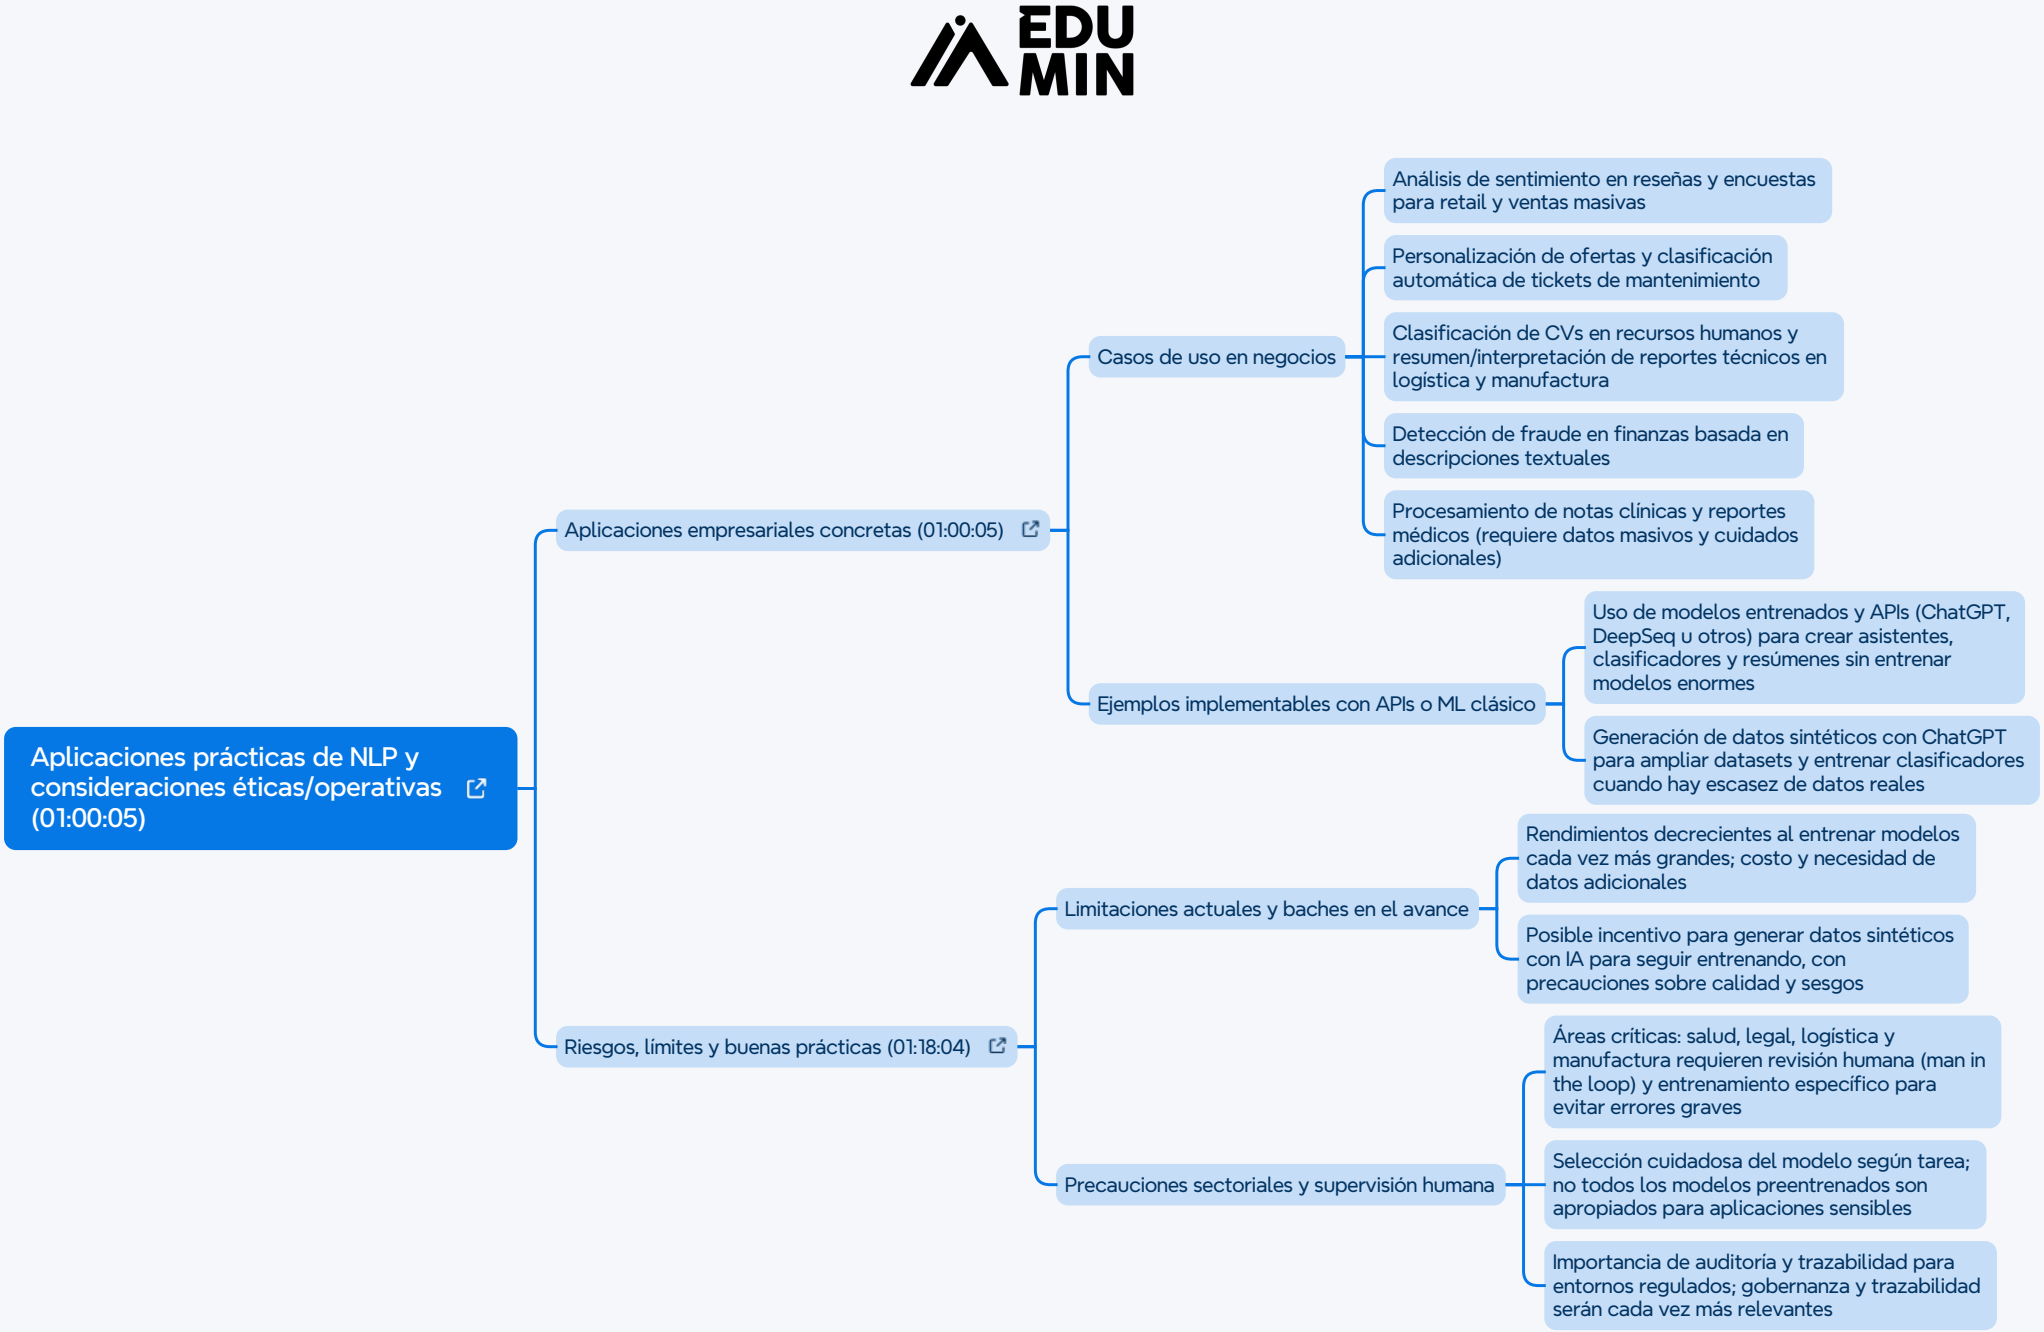

Inicio de la sesión y comunicación inicial (00:06:59)
Saludos y organización inicial (00:06:59)
Bienvenida a los alumnos que se van conectando
Indicaciones para consultas por chat debido a micrófonos silenciados
Avisos de inicio en breves minutos
Mensajes repetidos y pausas antes de comenzar
Transferencia de control y logística de clase (00:38:19)
Presentación del docente José Chávez y cesión de control
Coordinación entre moderador y docente para iniciar la clase
Preguntas logísticas sobre pausas y breaks
Consulta sobre la hora del break: dentro de una hora (las nueve)
Pausa y tareas para el regreso (01:40:39)
Break de cinco minutos y petición de propuestas de aplicaciones
Estudiantes deben volver con ideas aplicables para que el profesor oriente proyectos prácticos
Próximos pasos y comunicación final
Presentación de un cuaderno con modelo ejemplar en la siguiente sesión
Información sobre asistencia, enlaces en el chat y canales de atención para dudas
Próxima clase programada y cierre de la sesión con agradecimientos (mensaje final y contacto)


Preparación práctica y recursos (00:39:12)
Herramientas y material para las prácticas (00:39:12)
Uso de Orange para ejercicios prácticos
Profesor pide a estudiantes instalar Orange si no lo tienen
Envío de link para descarga durante la clase
Compartición de código y cuadernos
Profesor compartirá código de los notebooks y cuadernos para seguimiento
Envío de un cuaderno en Colab para trabajar ejemplos prácticos en la siguiente sesión
Datasets y ejercicios de Kaggle (00:39:47)
Caso Rossmann Store Sales en Kaggle como ejercicio principal
Profesor intentó descargar datos pero concurso cerró y pide verificación (problemas con código de verificación por celular)
Solicita que estudiantes intenten descargar y compartir el archivo si les funciona
Alternativa: dataset de recursos humanos y otros casos reales
Preparado otro cuaderno similar por si no se consigue la data de Rossmann
Envío de tres enlaces: Orange y dos ejercicios de Kaggle
Caso aplicativo adicional con data real de Kaggle para practicar antes de la próxima clase


Contenidos teóricos y objetivos de la segunda parte (00:44:18)
Historia y contexto de redes neuronales y deep learning (00:44:18)
Evolución histórica de las redes neuronales
Teoría presente desde hace décadas; limitaciones pasadas por capacidad computacional
Resurgimiento por reducción de costes y aumento de potencia (GPUs, infraestructura) y disponibilidad de grandes volúmenes de datos
Transición: reglas gramaticales → enfoque estadístico (modelos de Markov) → embeddings (Word2Vec/GloVe) → transformadores preentrenados (BERT, GPT, T5)
Aplicaciones y modelos actuales de IA
Modelos generativos y grandes modelos (ChatGPT, DALL·E, StableDiffusion) y su especialización: clasificación, generación, razonamiento
Principios básicos siguen siendo perceptrones y redes neuronales; avances: embeddings, tokenización, transformers y modelos pre-entrenados
Objetivos y enfoque de la segunda parte del curso (00:49:06)
Comprender y aplicar técnicas avanzadas para texto y secuencias
Diferencia entre redes básicas y procesamiento de secuencias/texto
Uso práctico con Keras y profundización en procesamiento de lenguaje
Enfoque práctico con datasets reales
Énfasis en trabajar con datos reales (Kaggle) y enfrentar dificultades de ajuste y mejora iterativa
Balance entre teoría y práctica: menos matemáticas formales ahora, más aplicación paso a paso
Uso de APIs de modelos preentrenados (por ejemplo GPT) para aplicaciones en lugar de entrenar modelos gigantes costosos

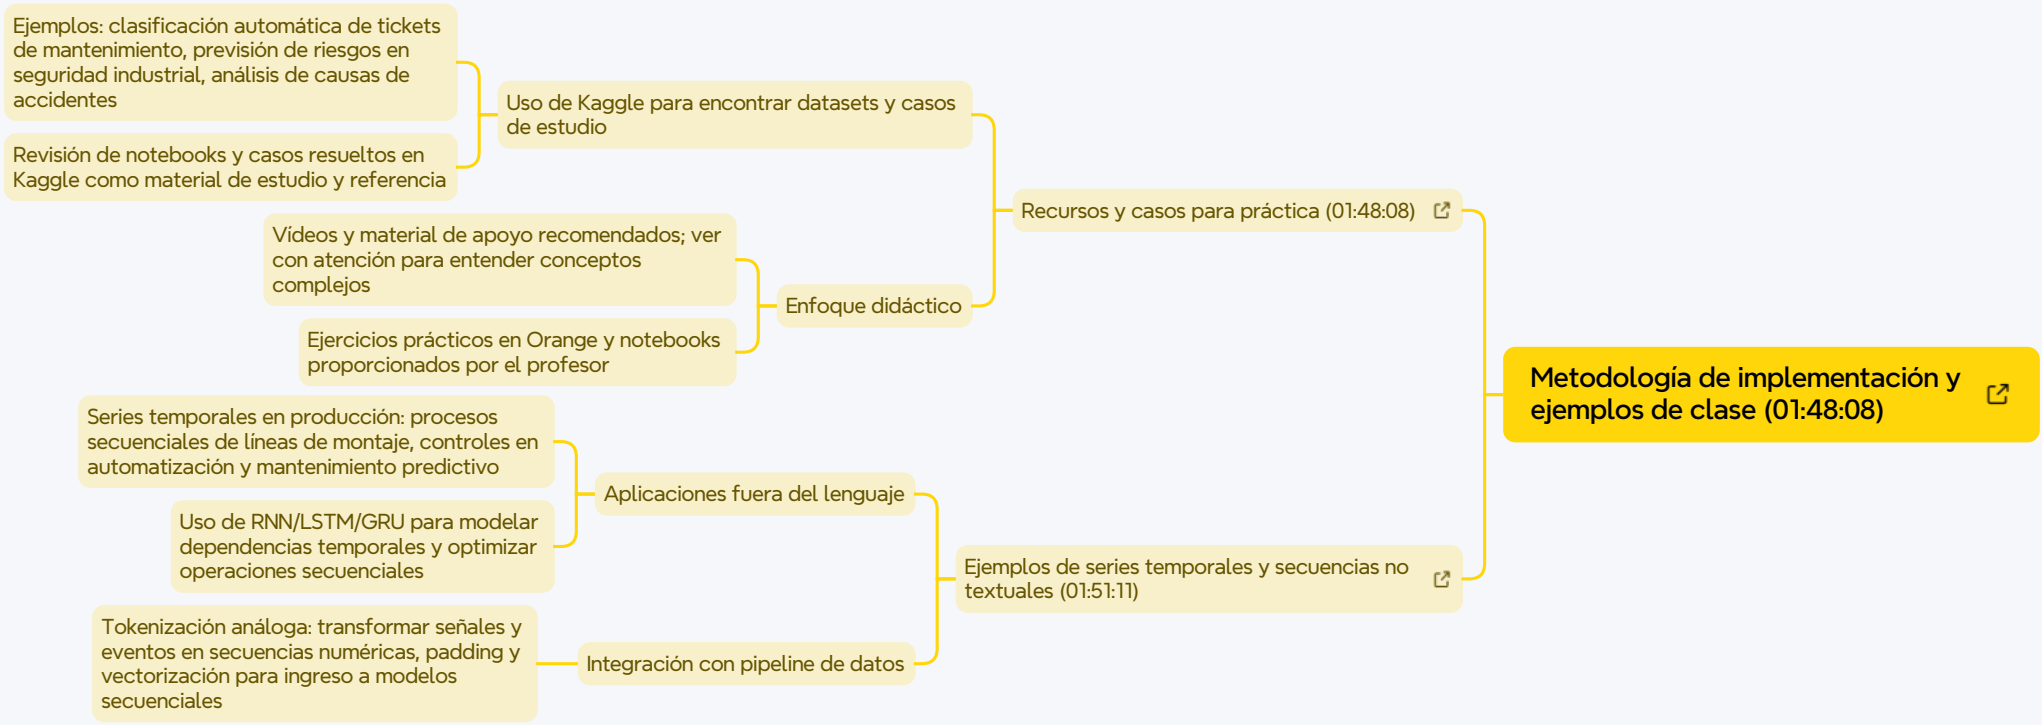

Procesos, pipeline y gestión de modelos (00:54:36)
Pipeline de digitalización y fases (00:54:36)
Captura de datos
Ejemplo Retail: web scraping de comentarios en redes sociales, APIs como Google Ads, libros de reclamaciones o reportes de vendedores
Almacenamiento e integración
Integrar datos de múltiples fuentes y formatos (CSV, bases SQL)
Importancia de la integración ordenada más que del simple almacenamiento
Procesamiento, entrenamiento, inferencia y mantenimiento (00:57:08)
Procesamiento y modelamiento
Entrenamiento requiere gran capacidad computacional y abundancia de datos
Inferencia permite consultas al modelo una vez entrenado; la inferencia es rápida una vez desplegado
Mantenimiento y orquestación
Necesidad de reentrenamientos periódicos solo cuando el rendimiento baja; monitorizar métricas en producción
Orquestación de adquisición, almacenamiento y procesamiento como pipelines automatizados (mención de herramientas como Airflow)
Atención a problemas como sobreentrenamiento y rendimiento decreciente; decidir entre reentrenar o retirar modelos

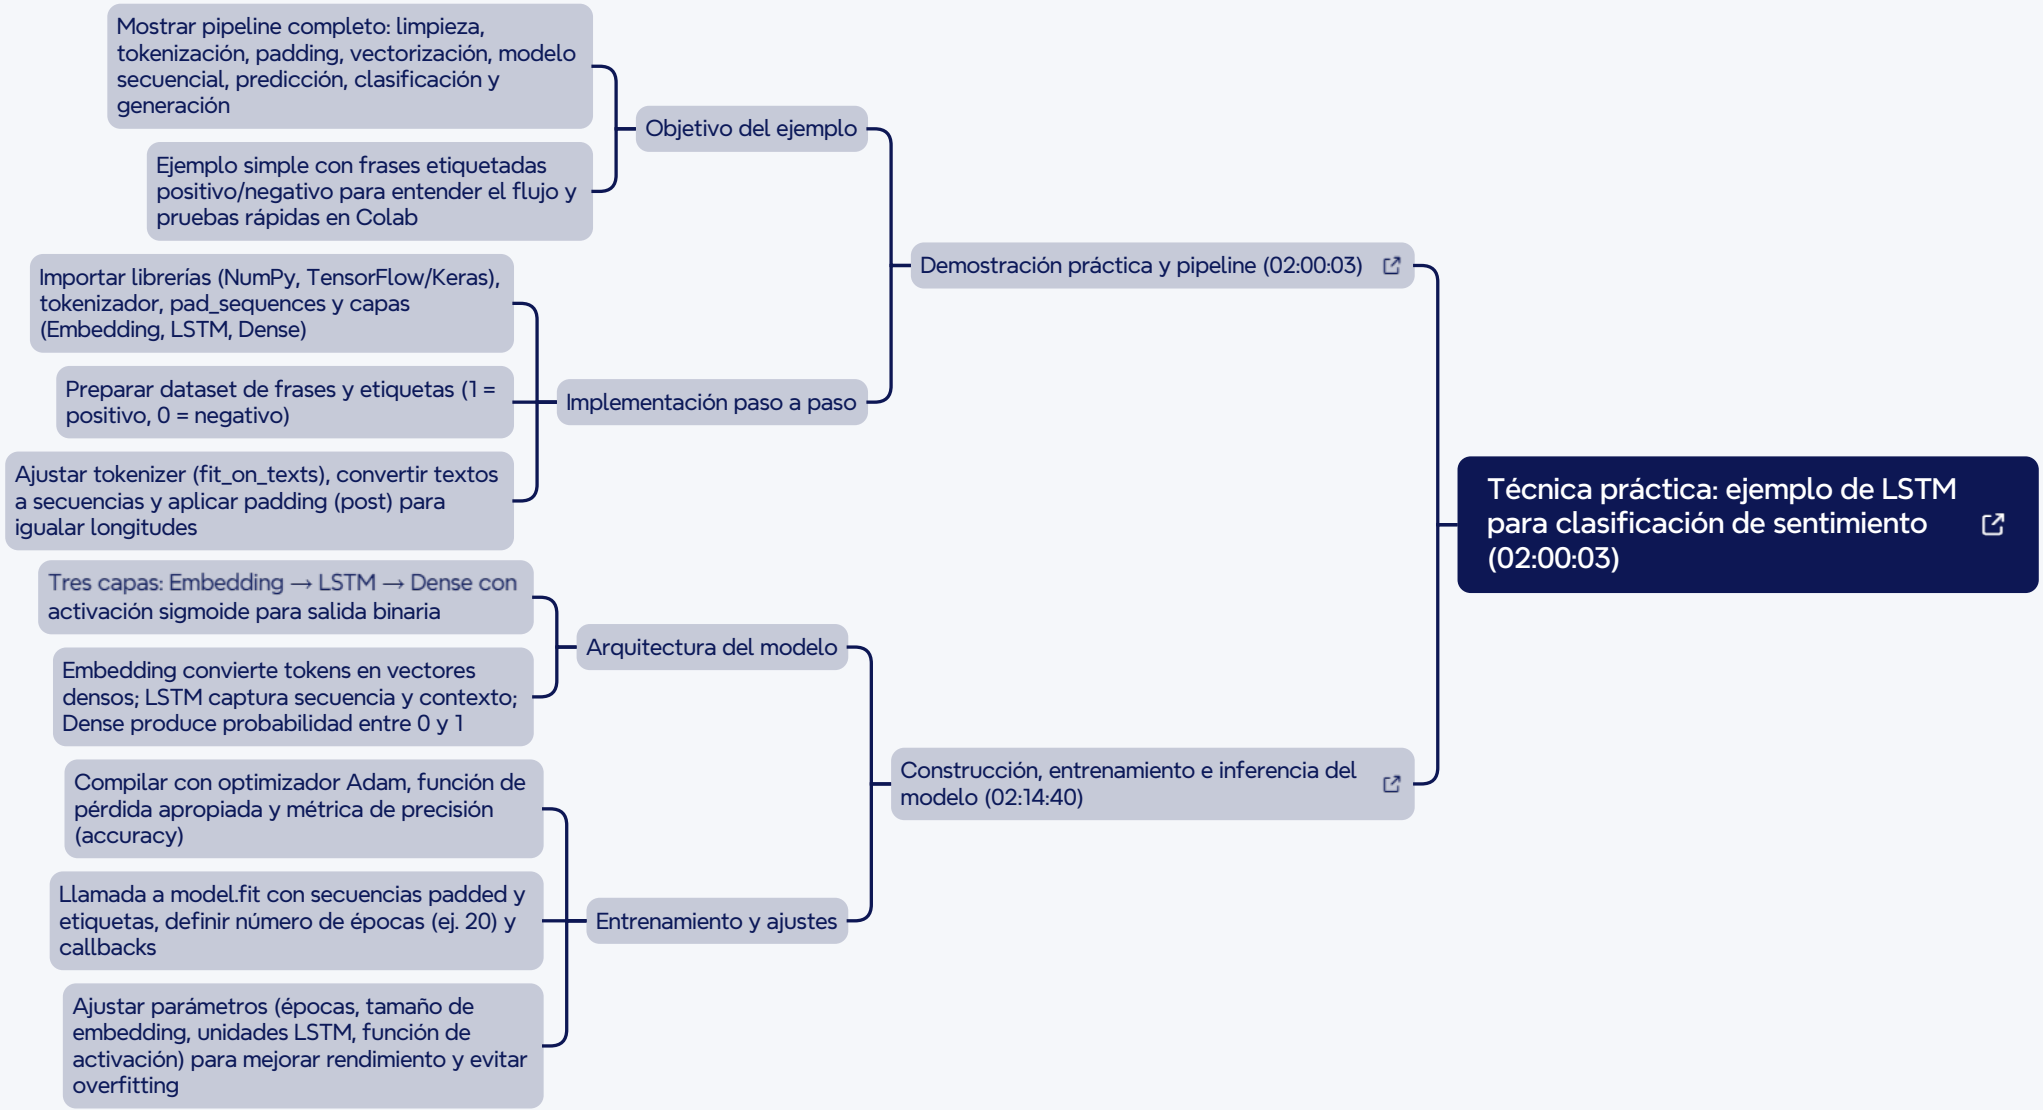

Temas específicos que se abordarán y metodología (00:59:38)
Procesamiento de lenguaje natural y redes para secuencias (00:59:38)
Evolución de las NLP y relación con visión artificial
Desde reglas lingüísticas y sistemas basados en gramática, pasando por modelos estadísticos y Markov, hasta redes neuronales y transformers
Word2Vec y embeddings (2003–2018) como punto de inflexión: conversión de palabras a vectores densos con significado semántico
Redes recurrentes y transformadores para secuencias
RNN tradicionales: manejan secuencias con realimentación pero sufren desvanecimiento del gradiente
LSTM y GRU: compuertas que regulan qué recordar u olvidar; LSTM más potente, GRU más ligero y rápido
Transformers: arquitectura para tareas paralelas y multitarea, base de modelos preentrenados (BERT, GPT, T5) especialmente efectivos para generación y clasificación
Plan de trabajo y aplicabilidad (00:49:53)
Estructura de trabajo práctico
Pequeñas aplicaciones diversas y un gran caso práctico con Kaggle
Profesor recogerá preferencias de aplicación de los estudiantes para orientar proyectos reales
Objetivo formativo
Clases orientadas a aplicaciones reales y gestionadas como proyectos para aprender gestión del ciclo de vida de modelos
No se entrenarán grandes GPT desde cero; se usarán APIs de modelos preentrenados para crear aplicaciones prácticas y eficientes

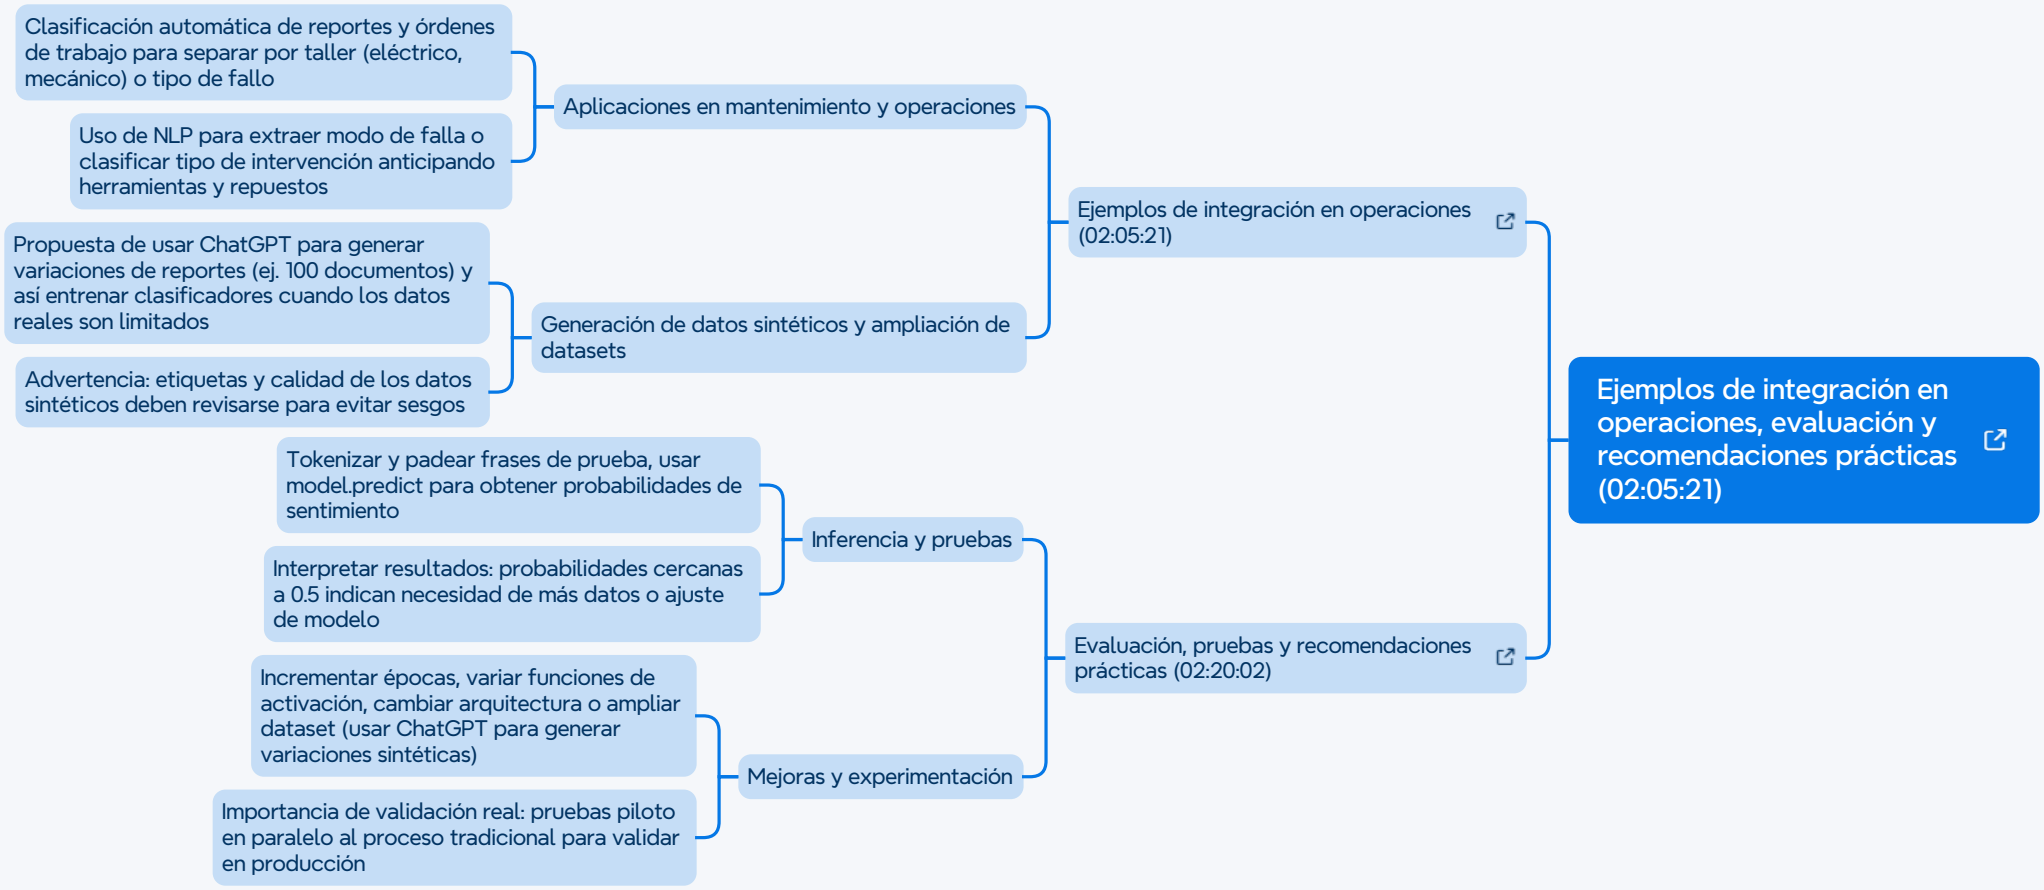

Aplicaciones prácticas de NLP y consideraciones éticas/operativas (01:00:05)
Aplicaciones empresariales concretas (01:00:05)
Casos de uso en negocios
Análisis de sentimiento en reseñas y encuestas para retail y ventas masivas
Personalización de ofertas y clasificación automática de tickets de mantenimiento
Clasificación de CVs en recursos humanos y resumen/interpretación de reportes técnicos en logística y manufactura
Detección de fraude en finanzas basada en descripciones textuales
Procesamiento de notas clínicas y reportes médicos (requiere datos masivos y cuidados adicionales)
Ejemplos implementables con APIs o ML clásico
Uso de modelos entrenados y APIs (ChatGPT, DeepSeq u otros) para crear asistentes, clasificadores y resúmenes sin entrenar modelos enormes
Generación de datos sintéticos con ChatGPT para ampliar datasets y entrenar clasificadores cuando hay escasez de datos reales
Riesgos, límites y buenas prácticas (01:18:04)
Limitaciones actuales y baches en el avance
Rendimientos decrecientes al entrenar modelos cada vez más grandes; costo y necesidad de datos adicionales
Posible incentivo para generar datos sintéticos con IA para seguir entrenando, con precauciones sobre calidad y sesgos
Precauciones sectoriales y supervisión humana
Áreas críticas: salud, legal, logística y manufactura requieren revisión humana (man in the loop) y entrenamiento específico para evitar errores graves
Selección cuidadosa del modelo según tarea; no todos los modelos preentrenados son apropiados para aplicaciones sensibles
Importancia de auditoría y trazabilidad para entornos regulados; gobernanza y trazabilidad serán cada vez más relevantes

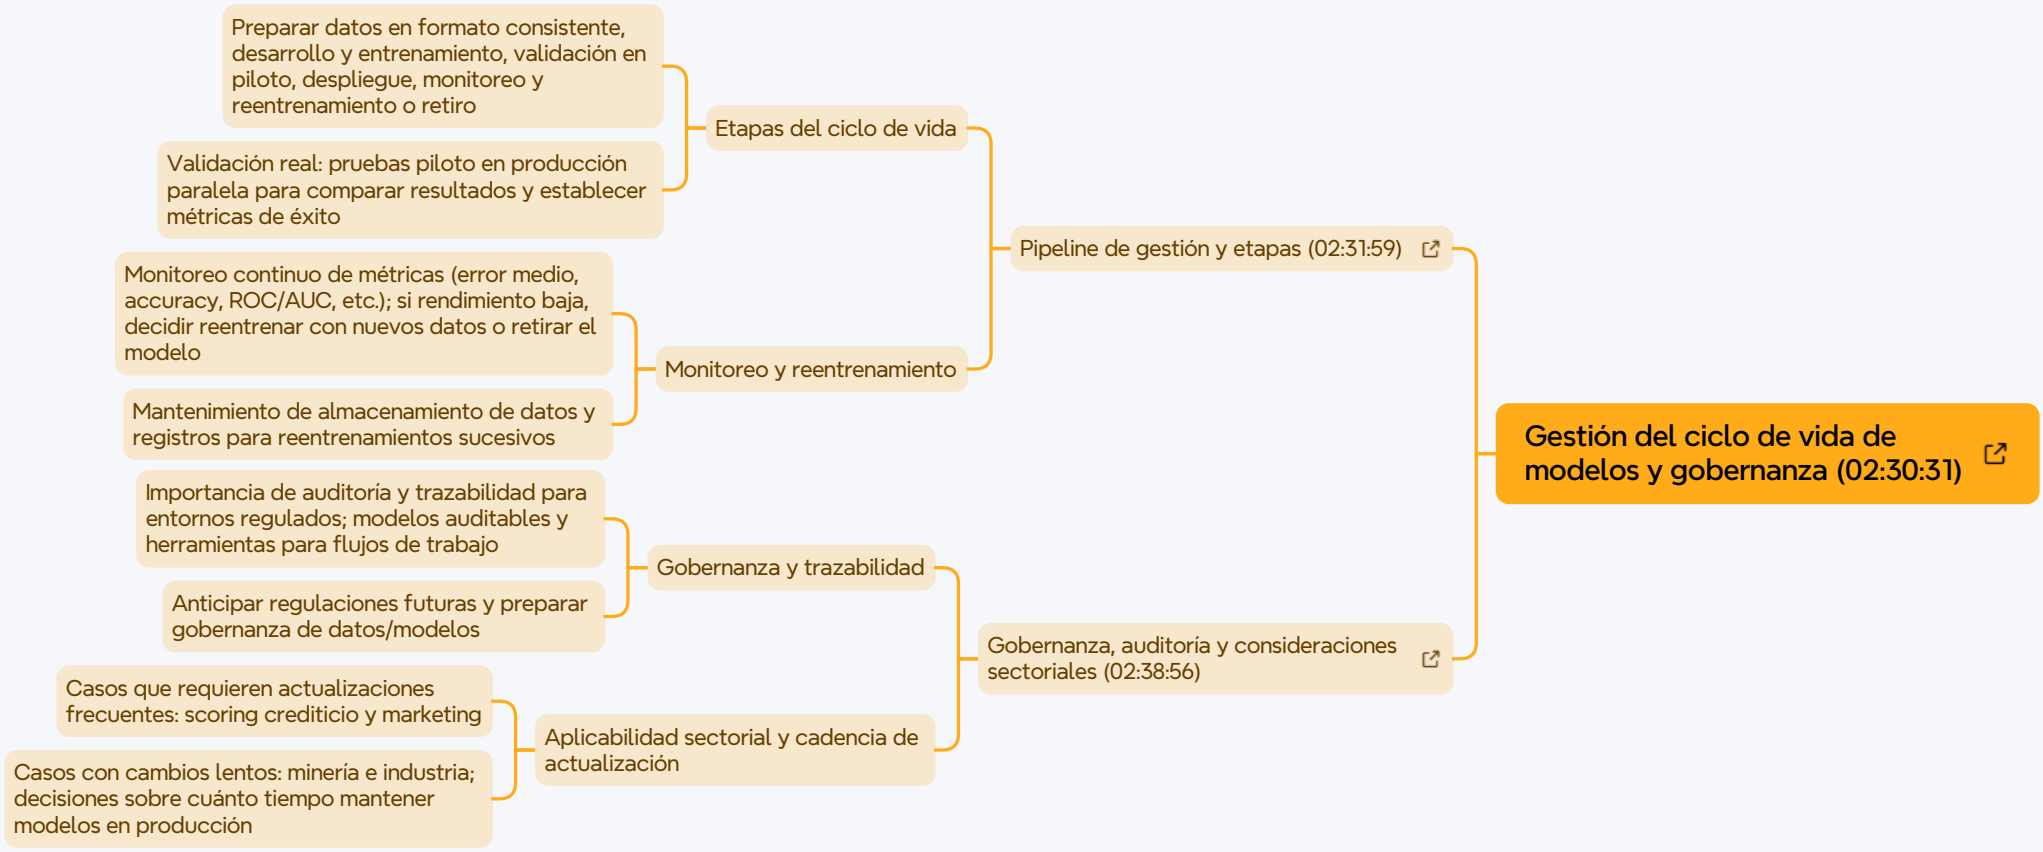
Técnica práctica de NLP: preprocesamiento y modelos (01:25:04)

- Procedimiento de texto y secuencias (01:25:04)
  - Pasos de procesamiento
    - Limpieza de texto: eliminación de símbolos, normalización (minúsculas) — trade-off entre agilidad y pérdida de contexto en idiomas ricos como el español
    - Tokenización: dividir texto en unidades (tokens) que pueden ser caracteres, palabras o subpalabras
    - Padding/truncado: igualar longitudes de secuencias para procesamiento en batch
    - Vectorización: embeddings (Word2Vec, GloVe, embeddings entrenables de NVIDIA) que convierten tokens a vectores densos
  - Tokens y coste computacional
    - Medición de procesamiento y coste por token; diferencia entre tokens en entrenamiento e inferencia
    - Diferencias de coste y capacidad entre modelos y optimizaciones según precio por token
- Modelos secuenciales y entrenamiento (01:36:34)
  - Tipos de modelos y aplicaciones
    - LSTM y GRU para secuencias largas y contexto; RNN clásicos para secuencias cortas
    - Transformers para procesamiento paralelo, multitarea y grandes prestaciones en clasificación y generación
  - Entrenamiento y backpropagation
    - Backpropagation como algoritmo fundamental para ajustar pesos y minimizar pérdida
    - Problemas técnicos: desvanecimiento del gradiente en RNN, soluciones con compuertas en LSTM/GRU y con arquitectura en transformers
    - Decisiones prácticas: elegir LSTM si hay capacidad de cómputo, GRU para implementaciones más ligeras y rápidas


Metodología de implementación y ejemplos de clase (01:48:08)
Recursos y casos para práctica (01:48:08)
Uso de Kaggle para encontrar datasets y casos de estudio
Ejemplos: clasificación automática de tickets de mantenimiento, previsión de riesgos en seguridad industrial, análisis de causas de accidentes
Revisión de notebooks y casos resueltos en Kaggle como material de estudio y referencia
Enfoque didáctico
Vídeos y material de apoyo recomendados; ver con atención para entender conceptos complejos
Ejercicios prácticos en Orange y notebooks proporcionados por el profesor
Ejemplos de series temporales y secuencias no textuales (01:51:11)
Aplicaciones fuera del lenguaje
Series temporales en producción: procesos secuenciales de líneas de montaje, controles en automatización y mantenimiento predictivo
Uso de RNN/LSTM/GRU para modelar dependencias temporales y optimizar operaciones secuenciales
Integración con pipeline de datos
Tokenización análoga: transformar señales y eventos en secuencias numéricas, padding y vectorización para ingreso a modelos secuenciales


Técnica práctica: ejemplo de LSTM para clasificación de sentimiento (02:00:03)
Demostración práctica y pipeline (02:00:03)
Objetivo del ejemplo
Mostrar pipeline completo: limpieza, tokenización, padding, vectorización, modelo secuencial, predicción, clasificación y generación
Ejemplo simple con frases etiquetadas positivo/negativo para entender el flujo y pruebas rápidas en Colab
Implementación paso a paso
Importar librerías (NumPy, TensorFlow/Keras), tokenizador, pad_sequences y capas (Embedding, LSTM, Dense)
Preparar dataset de frases y etiquetas (1 = positivo, 0 = negativo)
Ajustar tokenizer (fit_on_texts), convertir textos a secuencias y aplicar padding (post) para igualar longitudes
Construcción, entrenamiento e inferencia del modelo (02:14:40)
Arquitectura del modelo
Tres capas: Embedding → LSTM → Dense con activación sigmoide para salida binaria
Embedding convierte tokens en vectores densos; LSTM captura secuencia y contexto; Dense produce probabilidad entre 0 y 1
Entrenamiento y ajustes
Compilar con optimizador Adam, función de pérdida apropiada y métrica de precisión (accuracy)
Llamada a model.fit con secuencias padded y etiquetas, definir número de épocas (ej. 20) y callbacks
Ajustar parámetros (épocas, tamaño de embedding, unidades LSTM, función de activación) para mejorar rendimiento y evitar overfitting


Ejemplos de integración en operaciones, evaluación y recomendaciones prácticas (02:05:21)
Ejemplos de integración en operaciones (02:05:21)
Aplicaciones en mantenimiento y operaciones
Clasificación automática de reportes y órdenes de trabajo para separar por taller (eléctrico, mecánico) o tipo de fallo
Uso de NLP para extraer modo de falla o clasificar tipo de intervención anticipando herramientas y repuestos
Generación de datos sintéticos y ampliación de datasets
Propuesta de usar ChatGPT para generar variaciones de reportes (ej. 100 documentos) y así entrenar clasificadores cuando los datos reales son limitados
Advertencia: etiquetas y calidad de los datos sintéticos deben revisarse para evitar sesgos
Evaluación, pruebas y recomendaciones prácticas (02:20:02)
Inferencia y pruebas
Tokenizar y padear frases de prueba, usar model.predict para obtener probabilidades de sentimiento
Interpretar resultados: probabilidades cercanas a 0.5 indican necesidad de más datos o ajuste de modelo
Mejoras y experimentación
Incrementar épocas, variar funciones de activación, cambiar arquitectura o ampliar dataset (usar ChatGPT para generar variaciones sintéticas)
Importancia de validación real: pruebas piloto en paralelo al proceso tradicional para validar en producción


Gestión del ciclo de vida de modelos y gobernanza (02:30:31)
Pipeline de gestión y etapas (02:31:59)
Etapas del ciclo de vida
Preparar datos en formato consistente, desarrollo y entrenamiento, validación en piloto, despliegue, monitoreo y reentrenamiento o retiro
Validación real: pruebas piloto en producción paralela para comparar resultados y establecer métricas de éxito
Monitoreo y reentrenamiento
Monitoreo continuo de métricas (error medio, accuracy, ROC/AUC, etc.); si rendimiento baja, decidir reentrenar con nuevos datos o retirar el modelo
Mantenimiento de almacenamiento de datos y registros para reentrenamientos sucesivos
Gobernanza, auditoría y consideraciones sectoriales (02:38:56)
Gobernanza y trazabilidad
Importancia de auditoría y trazabilidad para entornos regulados; modelos auditables y herramientas para flujos de trabajo
Anticipar regulaciones futuras y preparar gobernanza de datos/modelos
Aplicabilidad sectorial y cadencia de actualización
Casos que requieren actualizaciones frecuentes: scoring crediticio y marketing
Casos con cambios lentos: minería e industria; decisiones sobre cuánto tiempo mantener modelos en producción