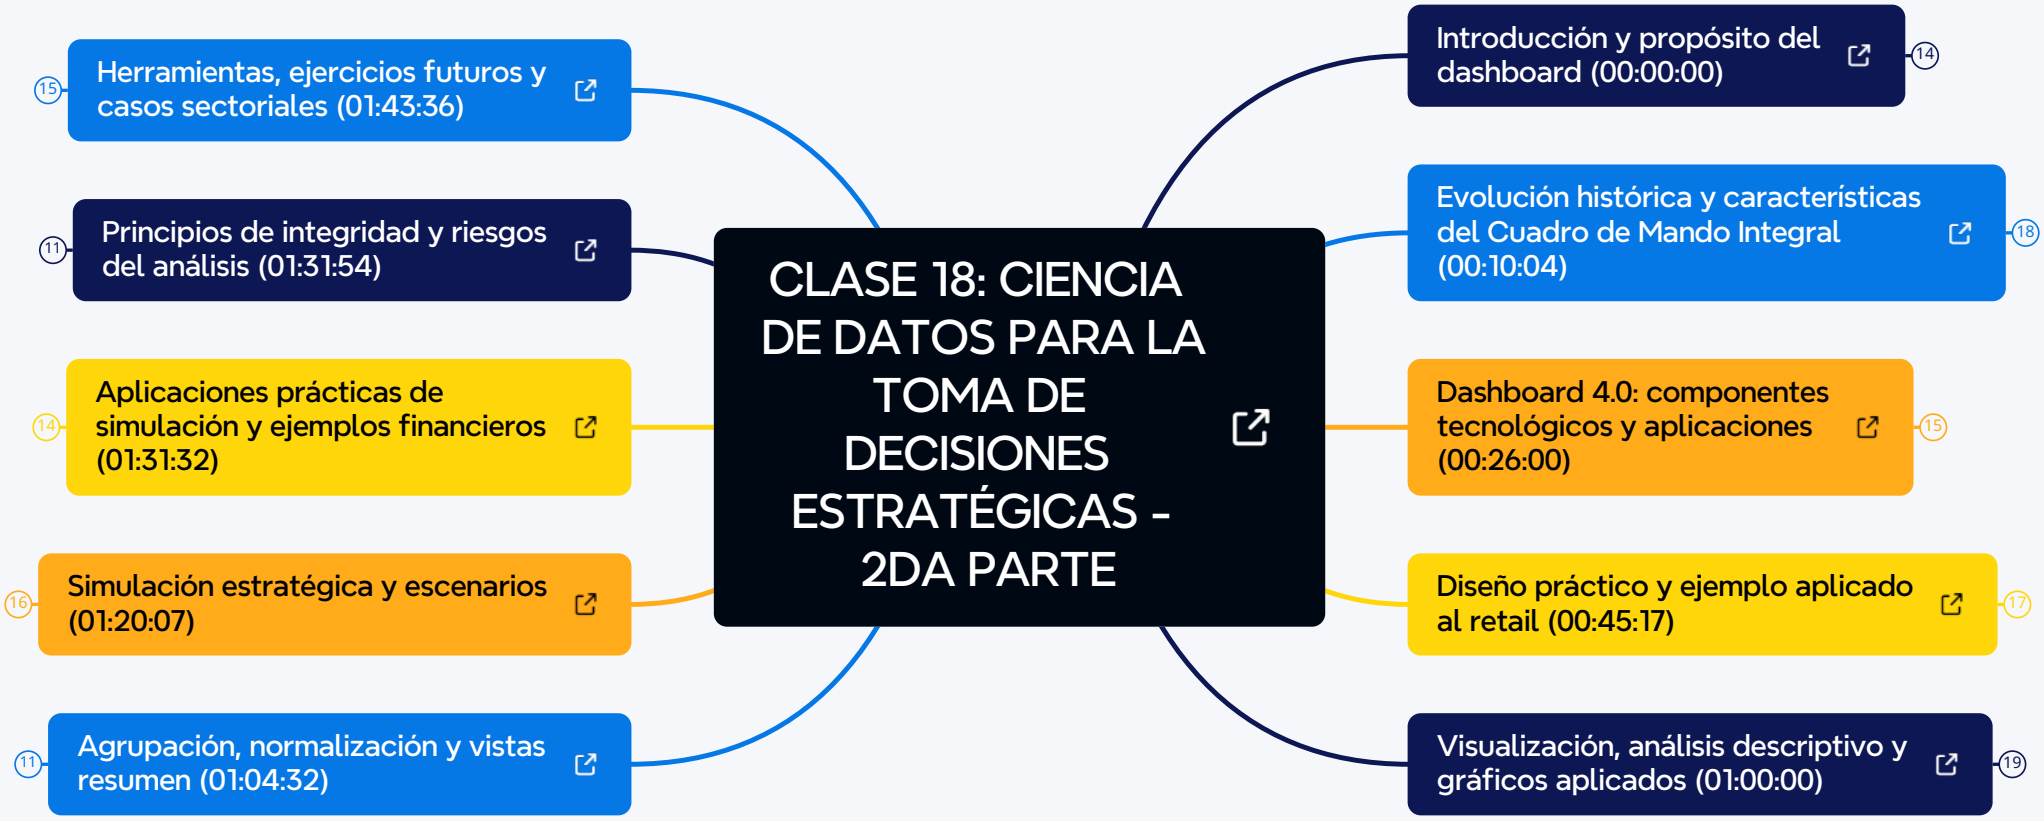
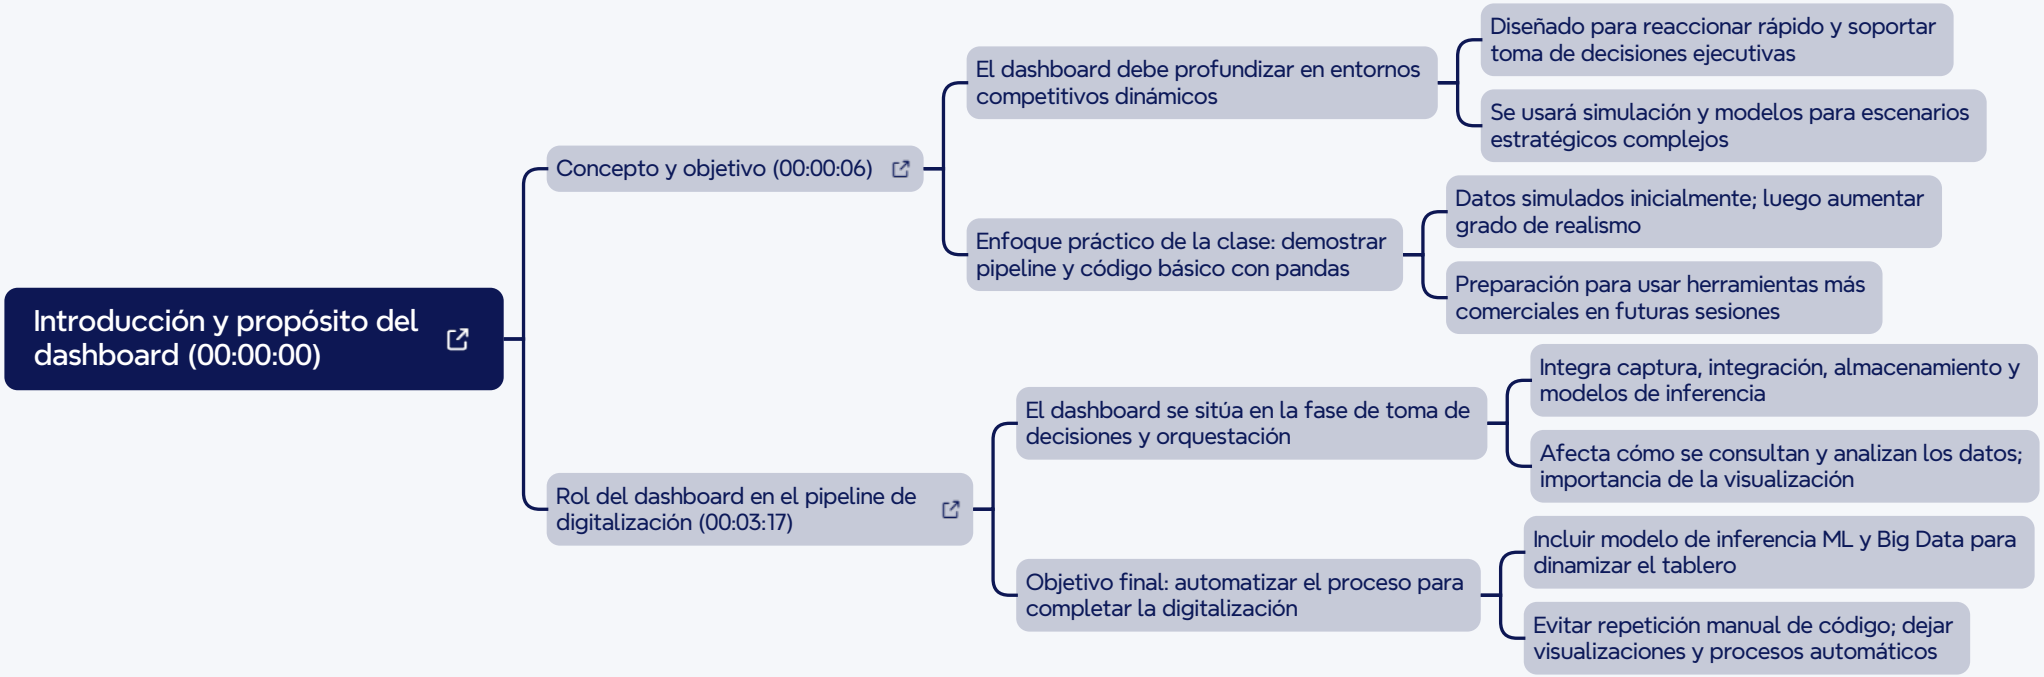
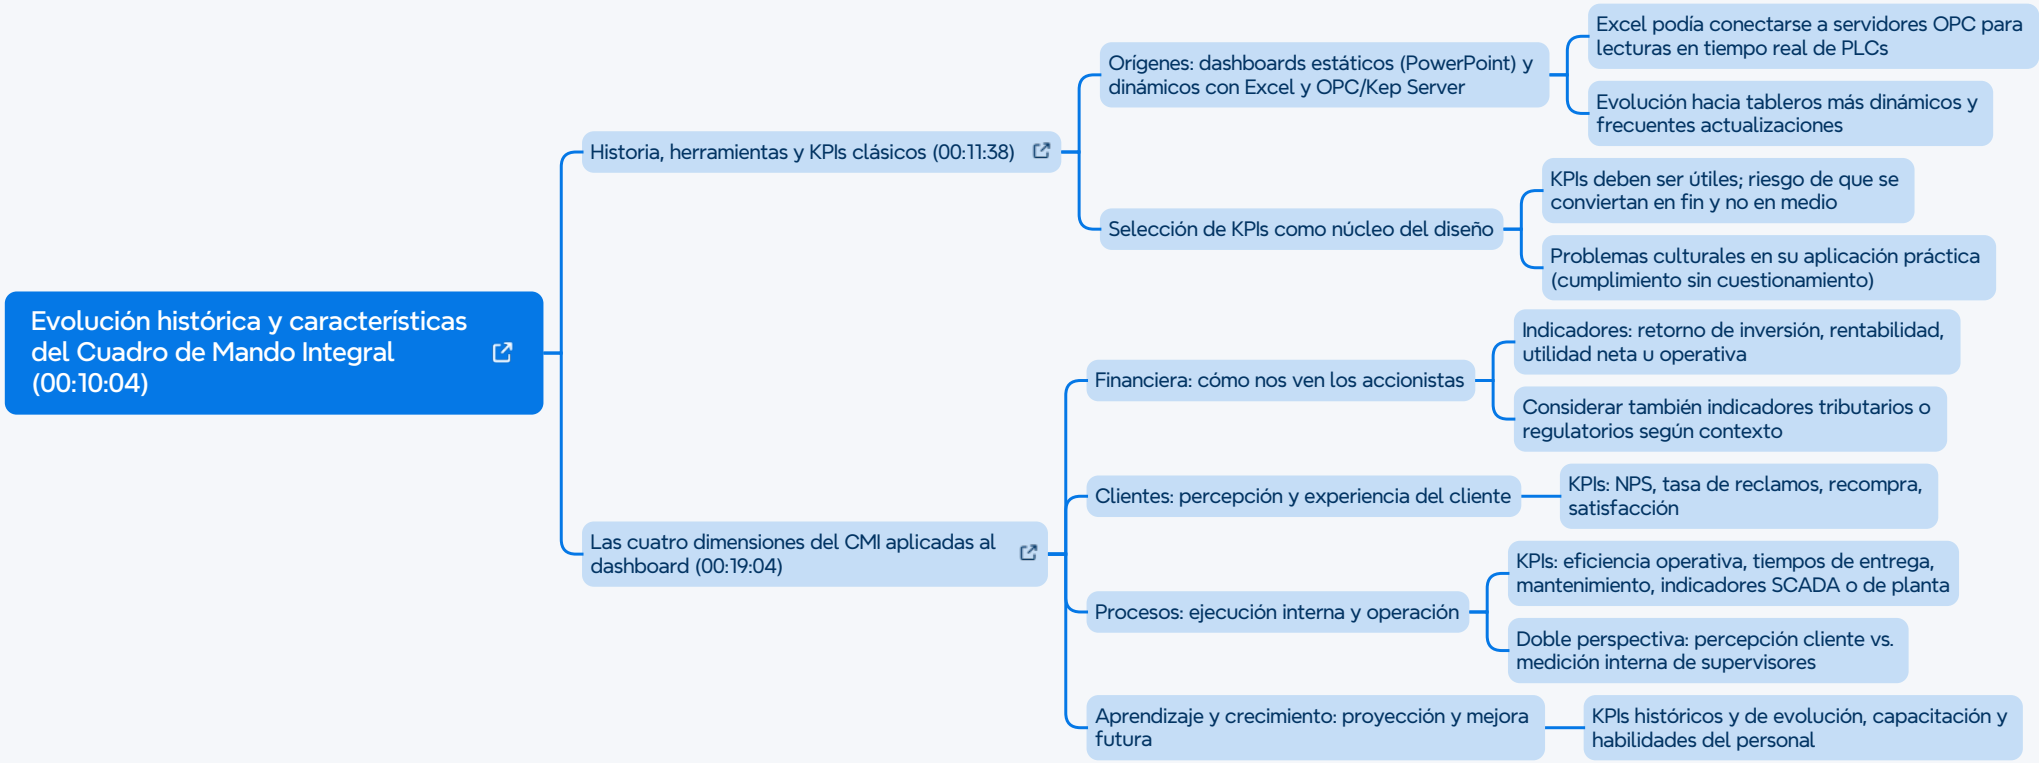
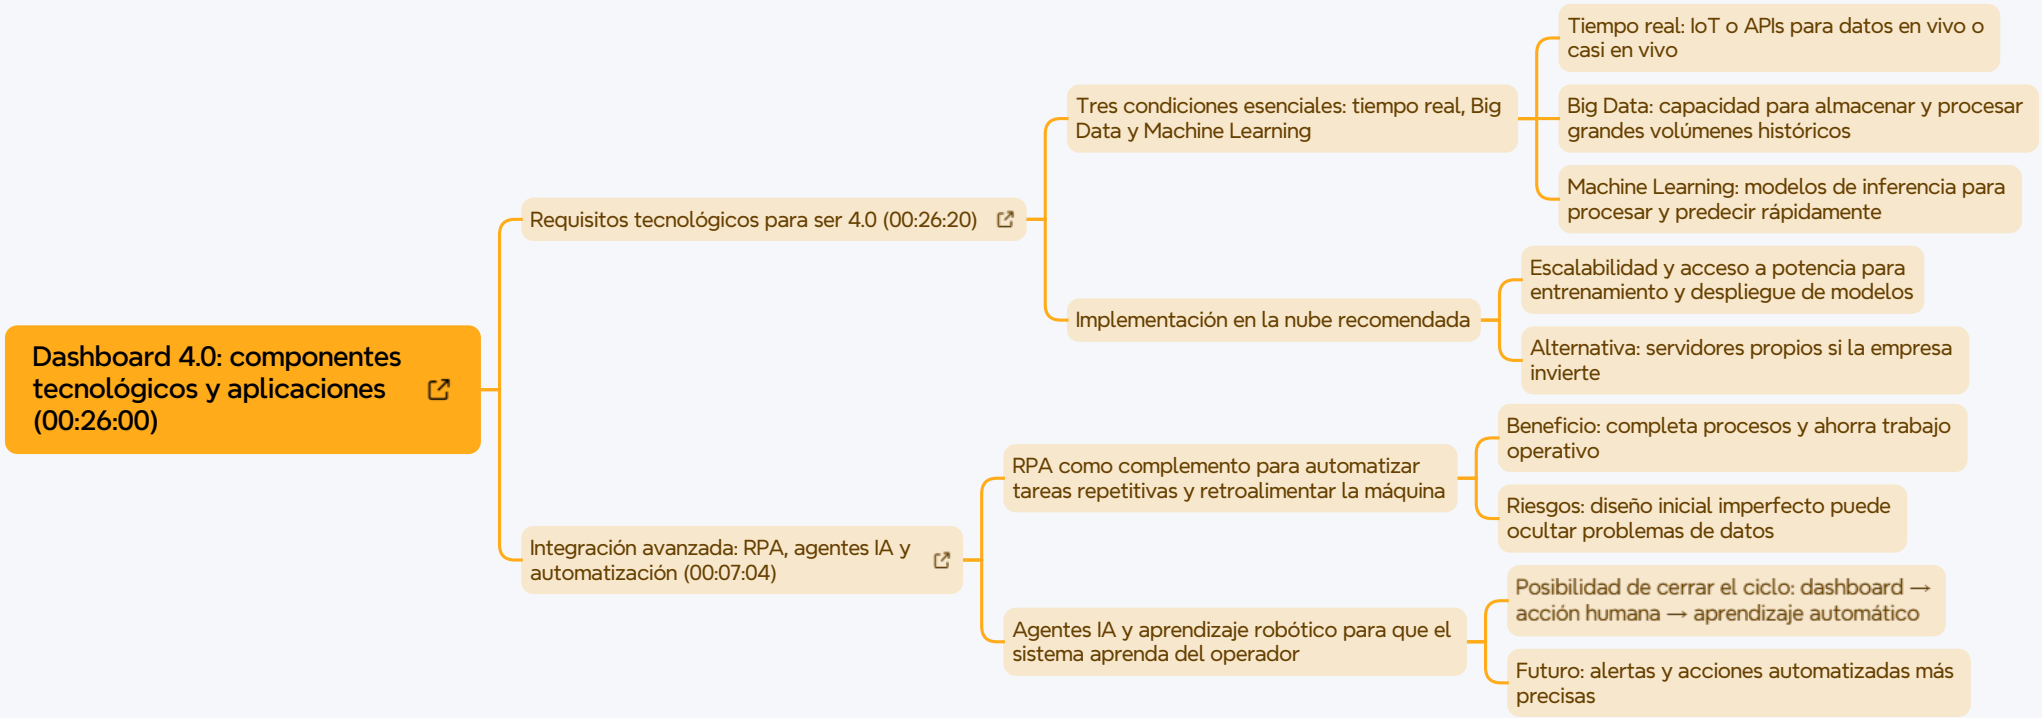
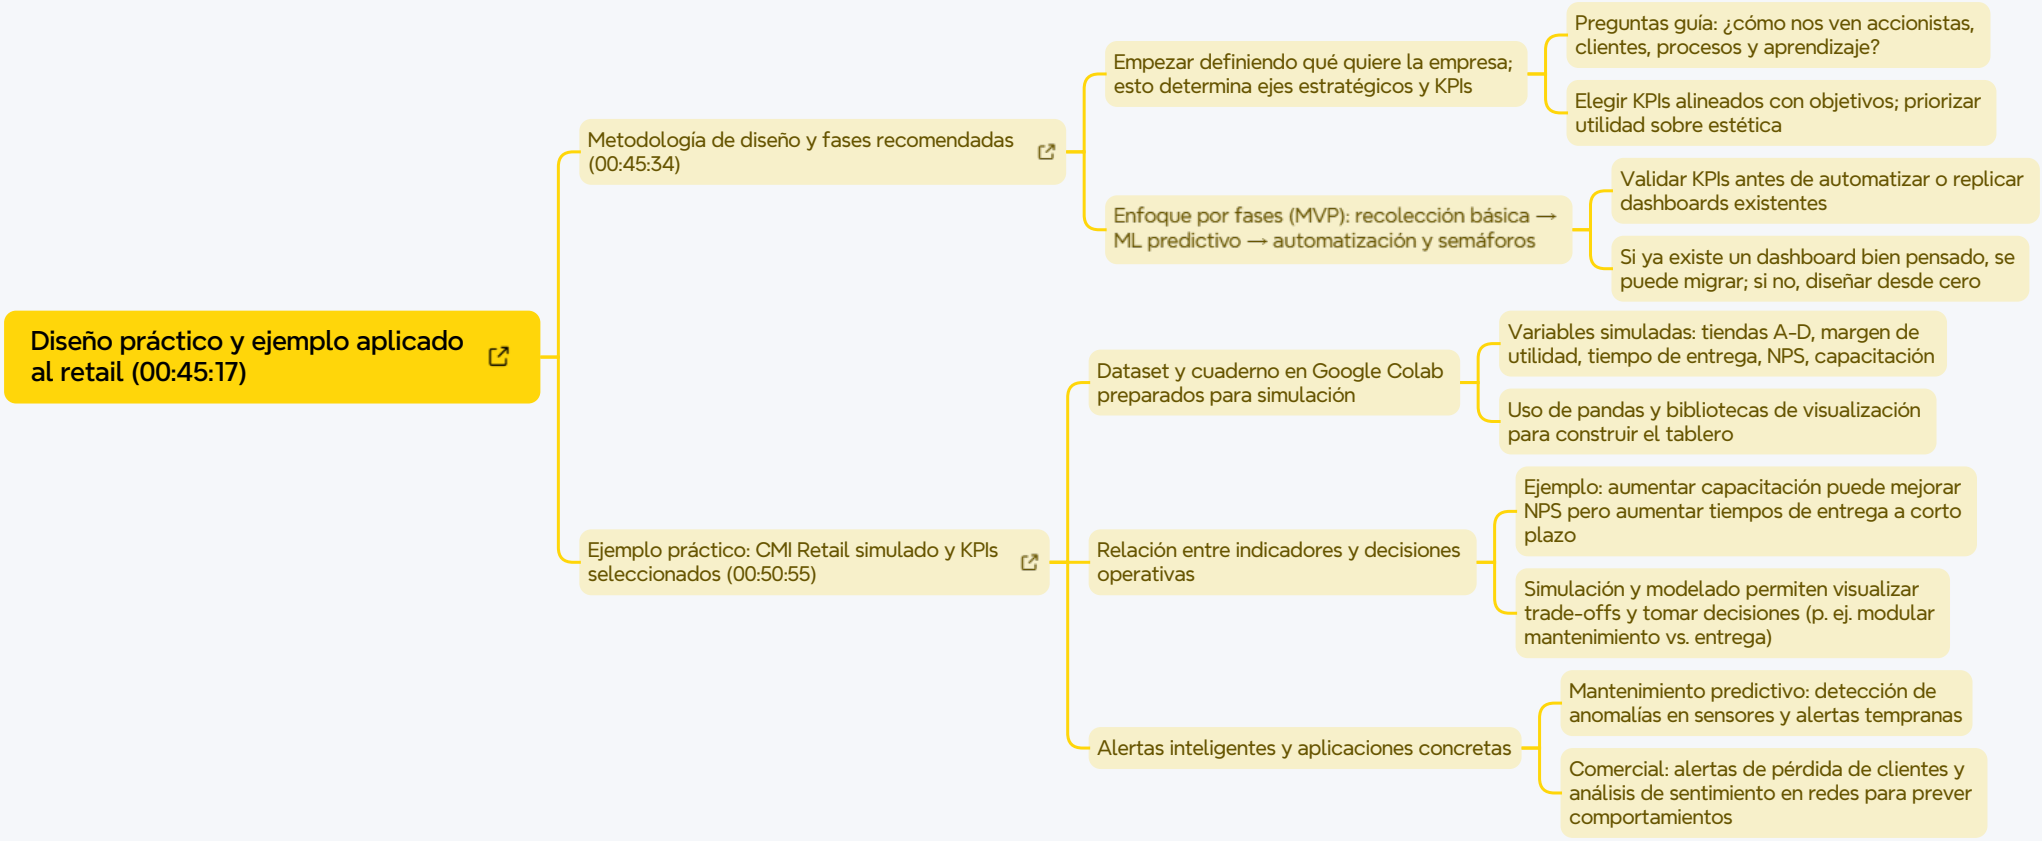
EDU MIN

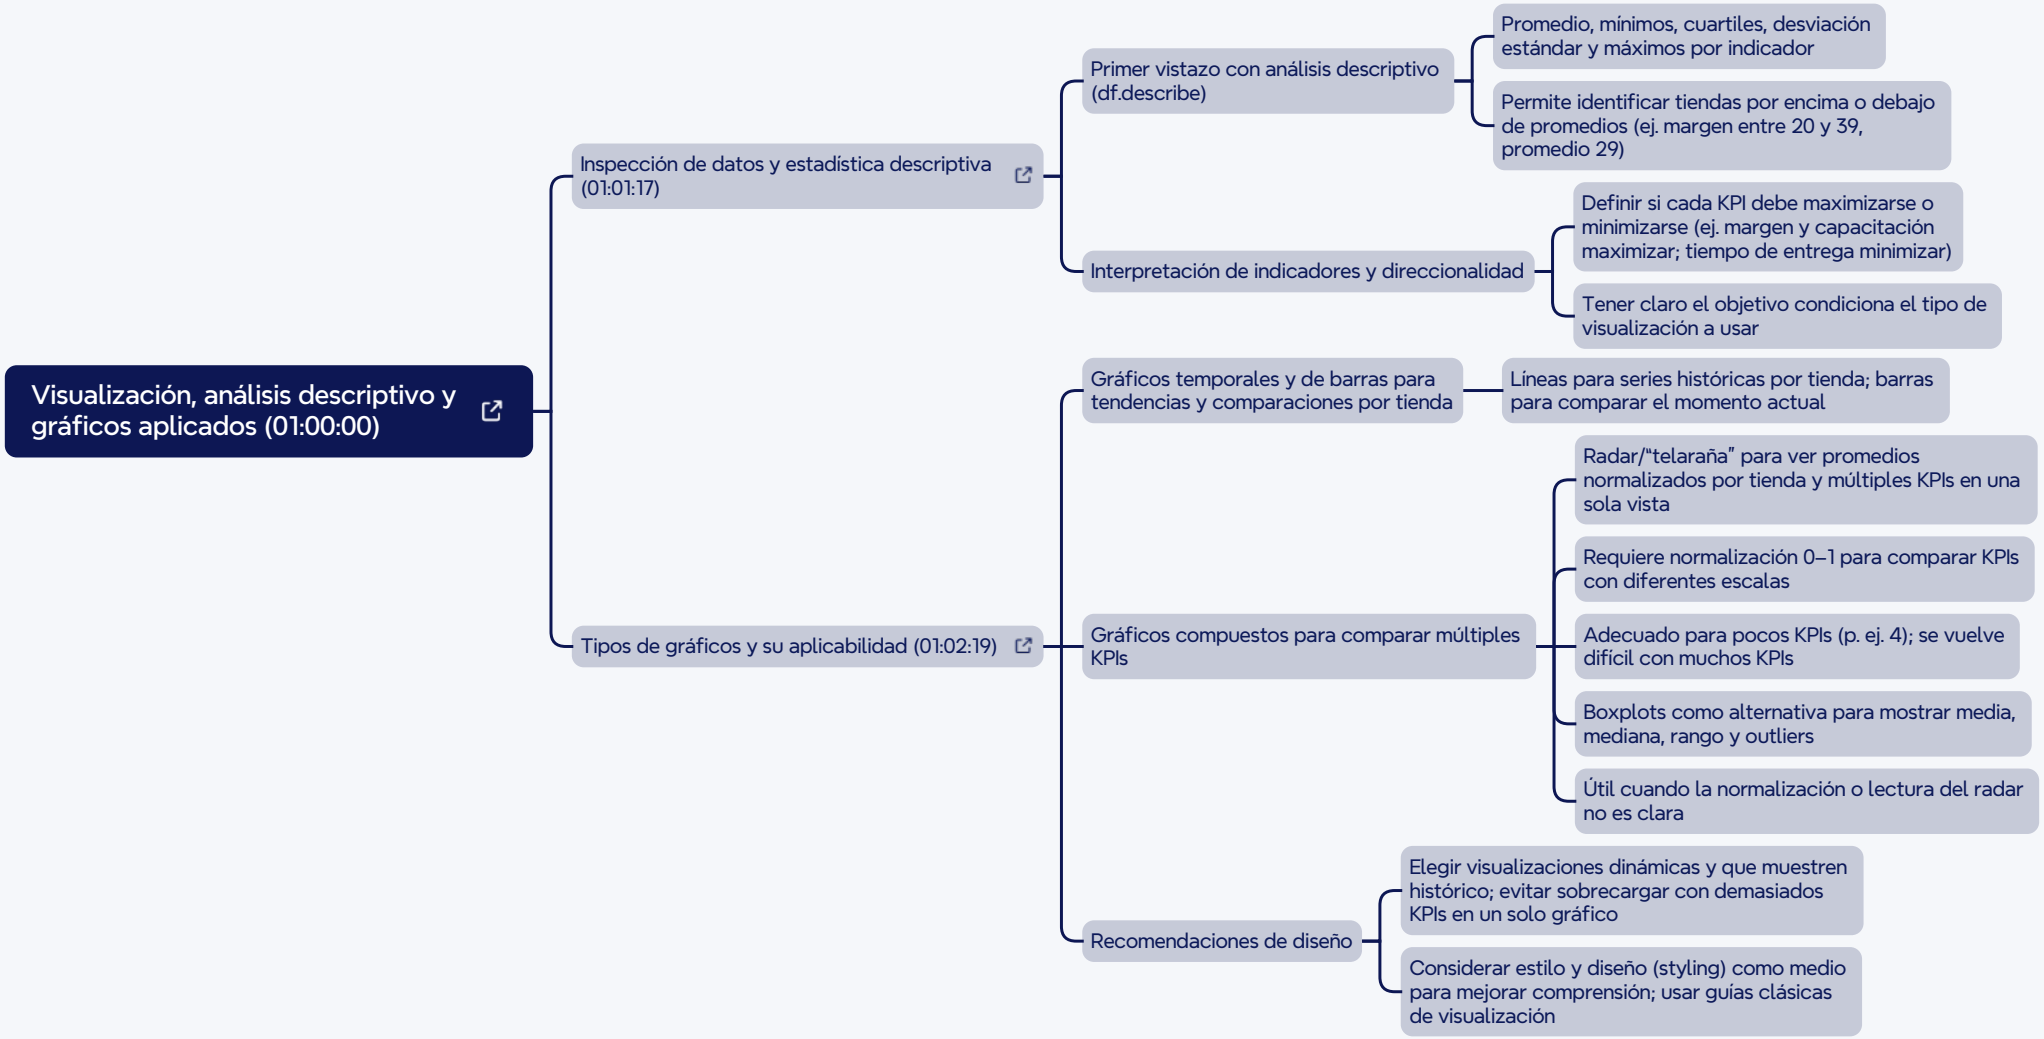

CLASE 18: CIENCIA DE DATOS PARA LA TOMA DE DECISIONES ESTRATÉGICAS - 2DA PARTE
Introducción y propósito del dashboard (00:00:00)
14
Evolución histórica y características del Cuadro de Mando Integral (00:10:04)
18
Dashboard 4.0: componentes tecnológicos y aplicaciones (00:26:00)
15
Diseño práctico y ejemplo aplicado al retail (00:45:17)
17
Visualización, análisis descriptivo y gráficos aplicados (01:00:00)
19
Herramientas, ejercicios futuros y casos sectoriales (01:43:36)
15
Principios de integridad y riesgos del análisis (01:31:54)
11
Aplicaciones prácticas de simulación y ejemplos financieros (01:31:32)
14
Simulación estratégica y escenarios (01:20:07)
16
Agrupación, normalización y vistas resumen (01:04:32)
11

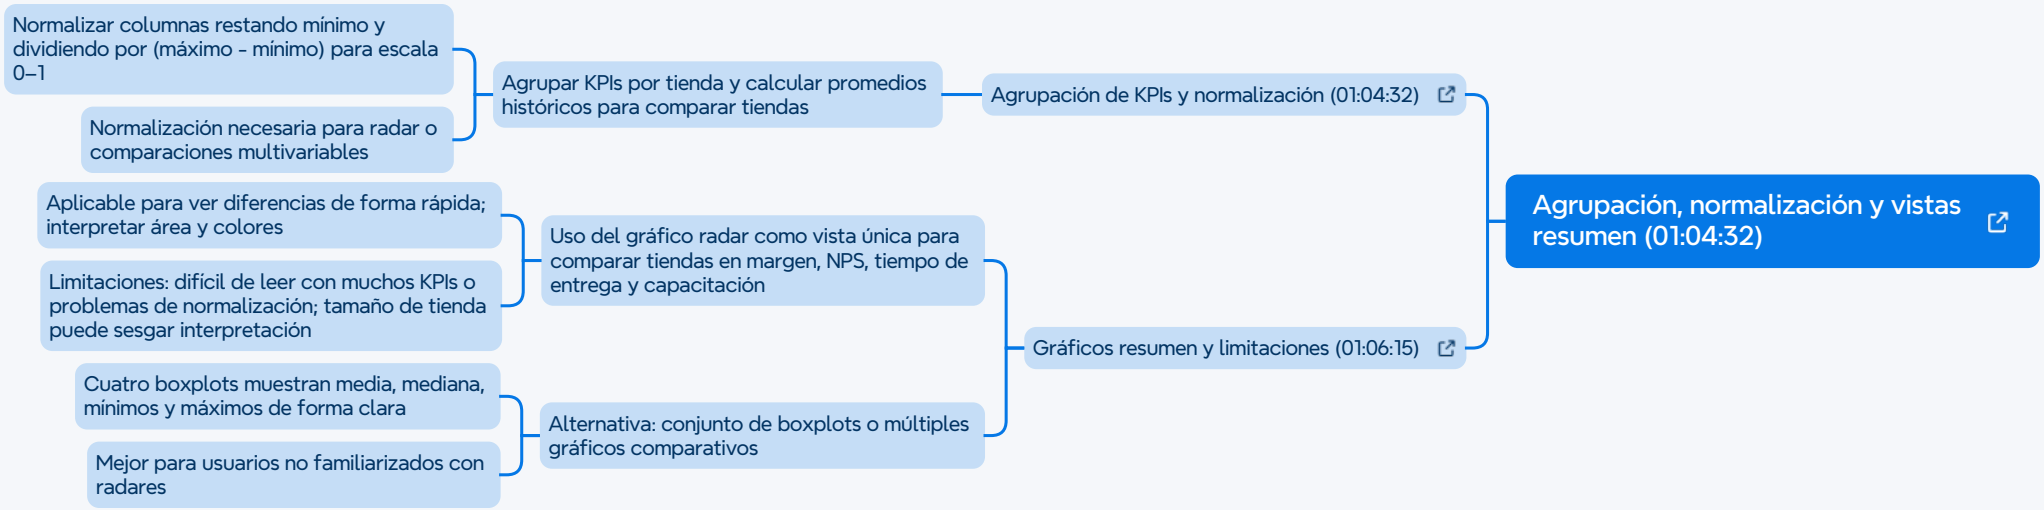

Introducción y propósito del dashboard (00:00:00)
Concepto y objetivo (00:00:06)
El dashboard debe profundizar en entornos competitivos dinámicos
Diseñado para reaccionar rápido y soportar toma de decisiones ejecutivas
Se usará simulación y modelos para escenarios estratégicos complejos
Enfoque práctico de la clase: demostrar pipeline y código básico con pandas
Datos simulados inicialmente; luego aumentar grado de realismo
Preparación para usar herramientas más comerciales en futuras sesiones
Rol del dashboard en el pipeline de digitalización (00:03:17)
El dashboard se sitúa en la fase de toma de decisiones y orquestación
Integra captura, integración, almacenamiento y modelos de inferencia
Afecta cómo se consultan y analizan los datos; importancia de la visualización
Objetivo final: automatizar el proceso para completar la digitalización
Incluir modelo de inferencia ML y Big Data para dinamizar el tablero
Evitar repetición manual de código; dejar visualizaciones y procesos automáticos


Evolución histórica y características del Cuadro de Mando Integral (00:10:04)
Historia, herramientas y KPIs clásicos (00:11:38)
Orígenes: dashboards estáticos (PowerPoint) y dinámicos con Excel y OPC/Kep Server
Excel podía conectarse a servidores OPC para lecturas en tiempo real de PLCs
Evolución hacia tableros más dinámicos y frecuentes actualizaciones
Selección de KPIs como núcleo del diseño
KPIs deben ser útiles; riesgo de que se conviertan en fin y no en medio
Problemas culturales en su aplicación práctica (cumplimiento sin cuestionamiento)
Las cuatro dimensiones del CMI aplicadas al dashboard (00:19:04)
Financiera: cómo nos ven los accionistas
Indicadores: retorno de inversión, rentabilidad, utilidad neta u operativa
Considerar también indicadores tributarios o regulatorios según contexto
Clientes: percepción y experiencia del cliente
KPIs: NPS, tasa de reclamos, recompra, satisfacción
Procesos: ejecución interna y operación
KPIs: eficiencia operativa, tiempos de entrega, mantenimiento, indicadores SCADA o de planta
Doble perspectiva: percepción cliente vs. medición interna de supervisores
Aprendizaje y crecimiento: proyección y mejora futura
KPIs históricos y de evolución, capacitación y habilidades del personal

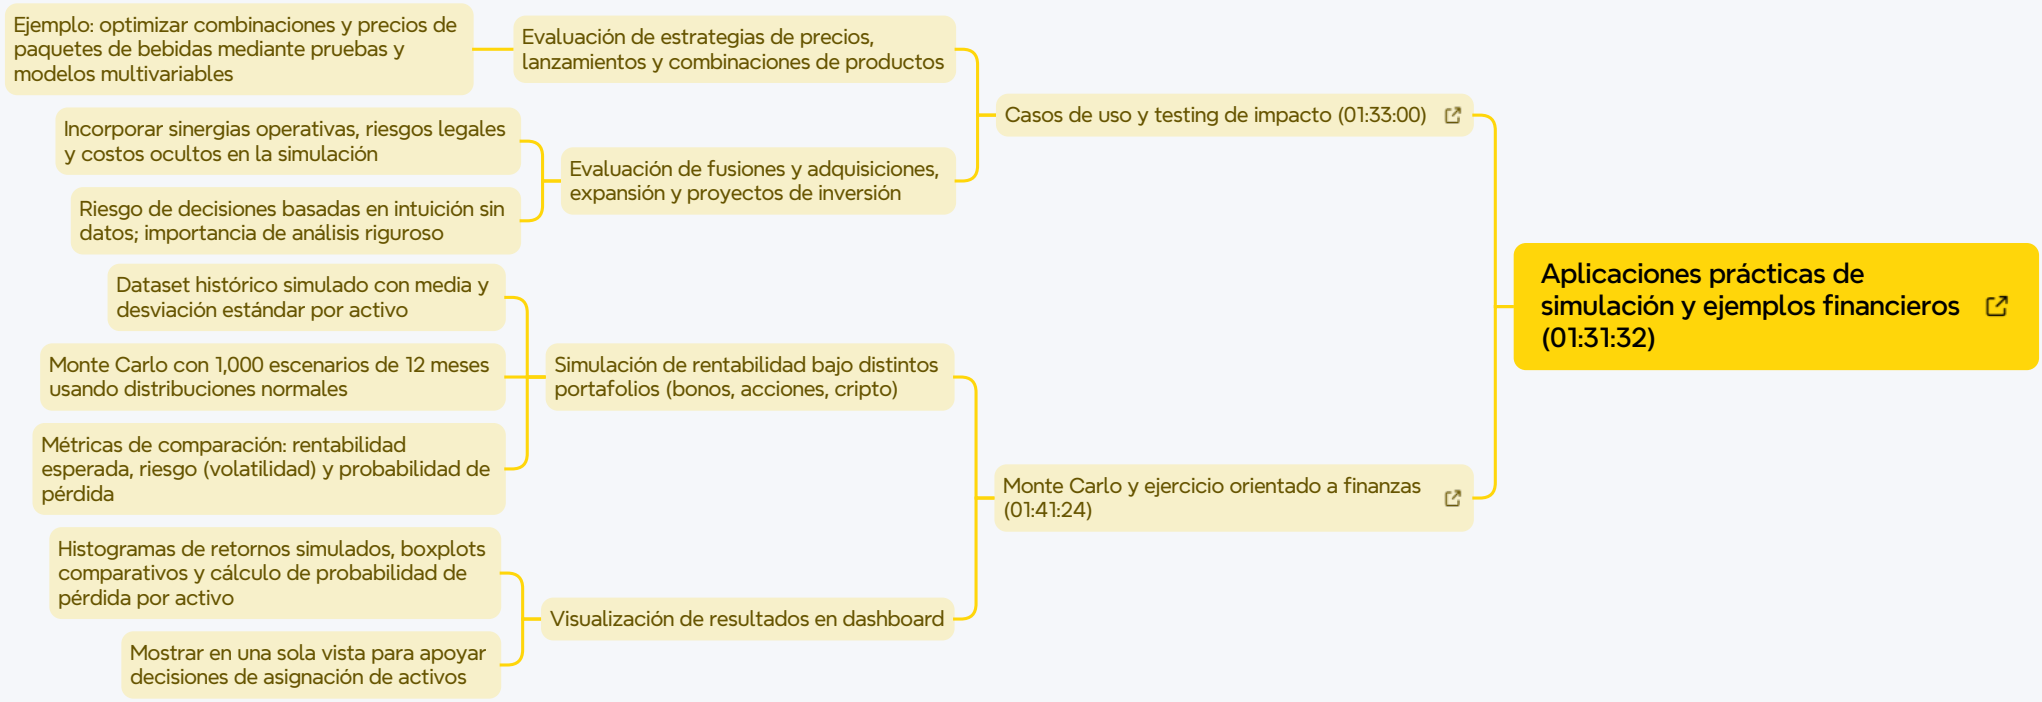

Dashboard 4.0: componentes tecnológicos y aplicaciones (00:26:00)
Requisitos tecnológicos para ser 4.0 (00:26:20)
Tres condiciones esenciales: tiempo real, Big Data y Machine Learning
Tiempo real: IoT o APIs para datos en vivo o casi en vivo
Big Data: capacidad para almacenar y procesar grandes volúmenes históricos
Machine Learning: modelos de inferencia para procesar y predecir rápidamente
Implementación en la nube recomendada
Escalabilidad y acceso a potencia para entrenamiento y despliegue de modelos
Alternativa: servidores propios si la empresa invierte
Integración avanzada: RPA, agentes IA y automatización (00:07:04)
RPA como complemento para automatizar tareas repetitivas y retroalimentar la máquina
Beneficio: completa procesos y ahorra trabajo operativo
Riesgos: diseño inicial imperfecto puede ocultar problemas de datos
Agentes IA y aprendizaje robótico para que el sistema aprenda del operador
Posibilidad de cerrar el ciclo: dashboard → acción humana → aprendizaje automático
Futuro: alertas y acciones automatizadas más precisas

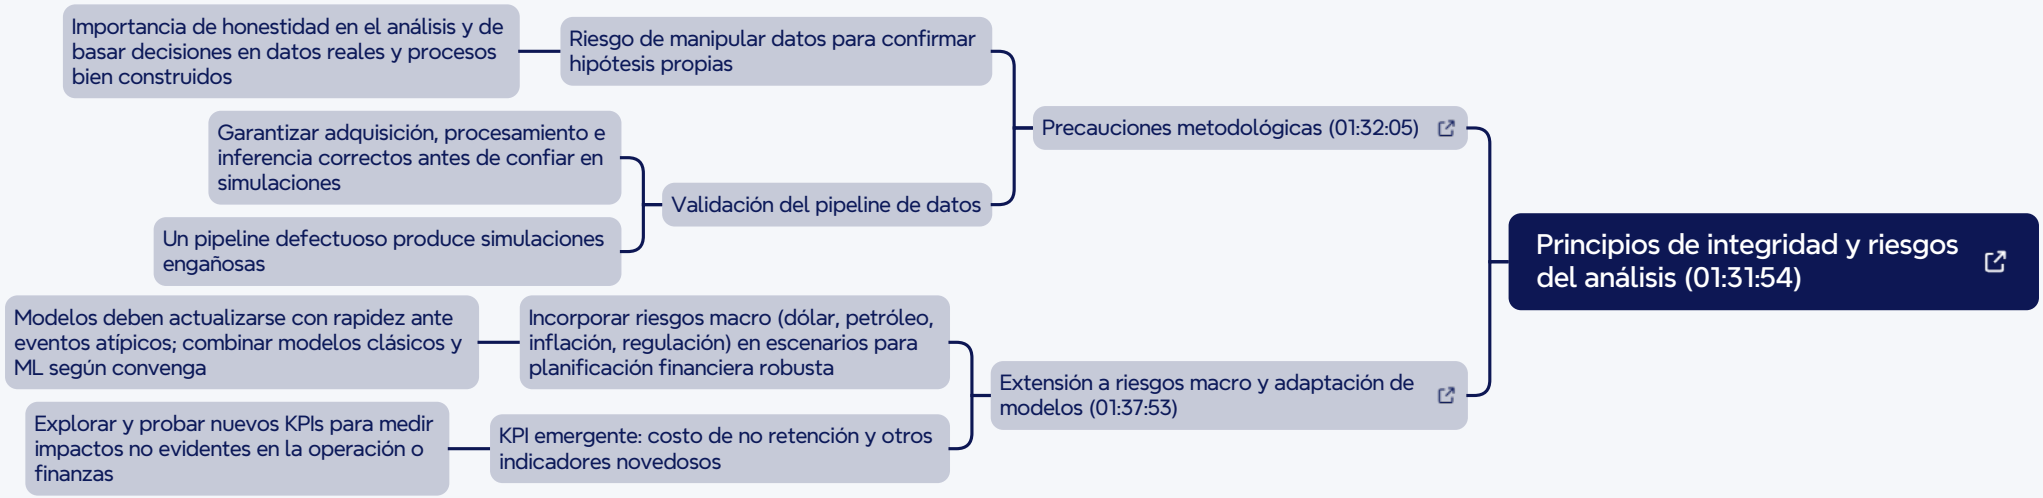

Diseño práctico y ejemplo aplicado al retail (00:45:17)
Metodología de diseño y fases recomendadas (00:45:34)
Empezar definiendo qué quiere la empresa; esto determina ejes estratégicos y KPIs
Preguntas guía: ¿cómo nos ven accionistas, clientes, procesos y aprendizaje?
Elegir KPIs alineados con objetivos; priorizar utilidad sobre estética
Enfoque por fases (MVP): recolección básica → ML predictivo → automatización y semáforos
Validar KPIs antes de automatizar o replicar dashboards existentes
Si ya existe un dashboard bien pensado, se puede migrar; si no, diseñar desde cero
Ejemplo práctico: CMI Retail simulado y KPIs seleccionados (00:50:55)
Dataset y cuaderno en Google Colab preparados para simulación
Variables simuladas: tiendas A-D, margen de utilidad, tiempo de entrega, NPS, capacitación
Uso de pandas y bibliotecas de visualización para construir el tablero
Relación entre indicadores y decisiones operativas
Ejemplo: aumentar capacitación puede mejorar NPS pero aumentar tiempos de entrega a corto plazo
Simulación y modelado permiten visualizar trade-offs y tomar decisiones (p. ej. modular mantenimiento vs. entrega)
Alertas inteligentes y aplicaciones concretas
Mantenimiento predictivo: detección de anomalías en sensores y alertas tempranas
Comercial: alertas de pérdida de clientes y análisis de sentimiento en redes para prever comportamientos


Visualización, análisis descriptivo y gráficos aplicados (01:00:00)
Inspección de datos y estadística descriptiva (01:01:17)
Primer vistazo con análisis descriptivo (df.describe)
Promedio, mínimos, cuartiles, desviación estándar y máximos por indicador
Permite identificar tiendas por encima o debajo de promedios (ej. margen entre 20 y 39, promedio 29)
Interpretación de indicadores y direccionalidad
Definir si cada KPI debe maximizarse o minimizarse (ej. margen y capacitación maximizar; tiempo de entrega minimizar)
Tener claro el objetivo condiciona el tipo de visualización a usar
Tipos de gráficos y su aplicabilidad (01:02:19)
Gráficos temporales y de barras para tendencias y comparaciones por tienda
Líneas para series históricas por tienda; barras para comparar el momento actual
Gráficos compuestos para comparar múltiples KPIs
Radar/"telaraña" para ver promedios normalizados por tienda y múltiples KPIs en una sola vista
Requiere normalización 0–1 para comparar KPIs con diferentes escalas
Adecuado para pocos KPIs (p. ej. 4); se vuelve difícil con muchos KPIs
Boxplots como alternativa para mostrar media, mediana, rango y outliers
Útil cuando la normalización o lectura del radar no es clara
Recomendaciones de diseño
Elegir visualizaciones dinámicas y que muestren histórico; evitar sobrecargar con demasiados KPIs en un solo gráfico
Considerar estilo y diseño (styling) como medio para mejorar comprensión; usar guías clásicas de visualización


Agrupación, normalización y vistas resumen (01:04:32)
Agrupación de KPIs y normalización (01:04:32)
Agrupar KPIs por tienda y calcular promedios históricos para comparar tiendas
Normalizar columnas restando mínimo y dividiendo por (máximo - mínimo) para escala 0–1
Normalización necesaria para radar o comparaciones multivariables
Gráficos resumen y limitaciones (01:06:15)
Uso del gráfico radar como vista única para comparar tiendas en margen, NPS, tiempo de entrega y capacitación
Aplicable para ver diferencias de forma rápida; interpretar área y colores
Limitaciones: difícil de leer con muchos KPIs o problemas de normalización; tamaño de tienda puede sesgar interpretación
Alternativa: conjunto de boxplots o múltiples gráficos comparativos
Cuatro boxplots muestran media, mediana, mínimos y máximos de forma clara
Mejor para usuarios no familiarizados con radares

- Simulación estratégica y escenarios (01:20:07)
  - Dashboard como simulador y máquina del tiempo (01:20:15)
    - El dashboard digital permite simular estrategias alternativas y comparar resultados prospectivos
      - Usarlo para proyectar hacia adelante o atrás, acelerar o ralentizar el tiempo, y comparar estrategias
      - Permite evaluar consecuencias de decisiones sin riesgo real (simuladores tipo aviación/carreras)
    - Requisitos para simulación estratégica
      - Decisiones viables y metas medibles integradas en KPIs del dashboard
      - Capacidad de crear y comparar escenarios manualmente o mediante código; guardar resultados para comparación
  - Modelos predictivos y análisis de sensibilidad (01:27:31)
    - Necesidad de incorporar un modelo predictivo en el dashboard
      - Puede ser desde regresión simple hasta ML/Deep Learning según complejidad y datos
    - Análisis de sensibilidad para evaluar escenarios (optimista, pesimista, realista)
      - Ambos componentes (modelo predictivo y análisis de sensibilidad) son esenciales
      - Monte Carlo y métodos clásicos siguen siendo útiles junto a ML
    - Selección de técnica según naturaleza del problema
      - Modelos determinísticos → algoritmos de optimización (genéticos, grid search)
      - Modelos estocásticos → Monte Carlo para evaluar distribuciones de resultados


Aplicaciones prácticas de simulación y ejemplos financieros (01:31:32)
Casos de uso y testing de impacto (01:33:00)
Evaluación de estrategias de precios, lanzamientos y combinaciones de productos
Ejemplo: optimizar combinaciones y precios de paquetes de bebidas mediante pruebas y modelos multivariables
Evaluación de fusiones y adquisiciones, expansión y proyectos de inversión
Incorporar sinergias operativas, riesgos legales y costos ocultos en la simulación
Riesgo de decisiones basadas en intuición sin datos; importancia de análisis riguroso
Monte Carlo y ejercicio orientado a finanzas (01:41:24)
Simulación de rentabilidad bajo distintos portafolios (bonos, acciones, cripto)
Dataset histórico simulado con media y desviación estándar por activo
Monte Carlo con 1,000 escenarios de 12 meses usando distribuciones normales
Métricas de comparación: rentabilidad esperada, riesgo (volatilidad) y probabilidad de pérdida
Visualización de resultados en dashboard
Histogramas de retornos simulados, boxplots comparativos y cálculo de probabilidad de pérdida por activo
Mostrar en una sola vista para apoyar decisiones de asignación de activos


Principios de integridad y riesgos del análisis (01:31:54)
Precauciones metodológicas (01:32:05)
Riesgo de manipular datos para confirmar hipótesis propias
Importancia de honestidad en el análisis y de basar decisiones en datos reales y procesos bien construidos
Validación del pipeline de datos
Garantizar adquisición, procesamiento e inferencia correctos antes de confiar en simulaciones
Un pipeline defectuoso produce simulaciones engañosas
Extensión a riesgos macro y adaptación de modelos (01:37:53)
Incorporar riesgos macro (dólar, petróleo, inflación, regulación) en escenarios para planificación financiera robusta
Modelos deben actualizarse con rapidez ante eventos atípicos; combinar modelos clásicos y ML según convenga
KPI emergente: costo de no retención y otros indicadores novedosos
Explorar y probar nuevos KPIs para medir impactos no evidentes en la operación o finanzas


Herramientas, ejercicios futuros y casos sectoriales (01:43:36)
Herramientas y estilo (01:46:17)
Uso de Python/Colab y ORANGE para casos prácticos
ORANGE como alternativa visual para mostrar flujo y modelos; Colab para código reproducible
Importancia del styling y guías clásicas de visualización
Presentación y diseño afectan la comprensión; recomienda lectura de textos clásicos de visualización
Casos sectoriales y próximos ejercicios (01:51:21)
Sectores a desarrollar en próximas clases: retail e-commerce, sector financiero, recursos humanos, manufactura y logística
Cada caso con especificidad práctica (ej. mantenimiento predictivo para manufactura/minas)
Ejercicio planeado: simulación de portafolios (finanzas) y caso principal más realista en Python/Colab
Casos adicionales: velocidad de abandono de clientes, rotura de stock, scoring crediticio, mantenimiento predictivo
Organización y seguimiento (01:54:00)
Envío de material, formularios de asistencia y grupo directo de aceleración de la sesión
Invitación a los alumnos para pensar en aplicación sectorial antes de la siguiente clase
Próxima sesión: mayor especificidad por sector y más tiempo para desarrollar ejercicios prácticos
Incorporación de feedback de alumnos y desarrollo de casos más realistas y completos