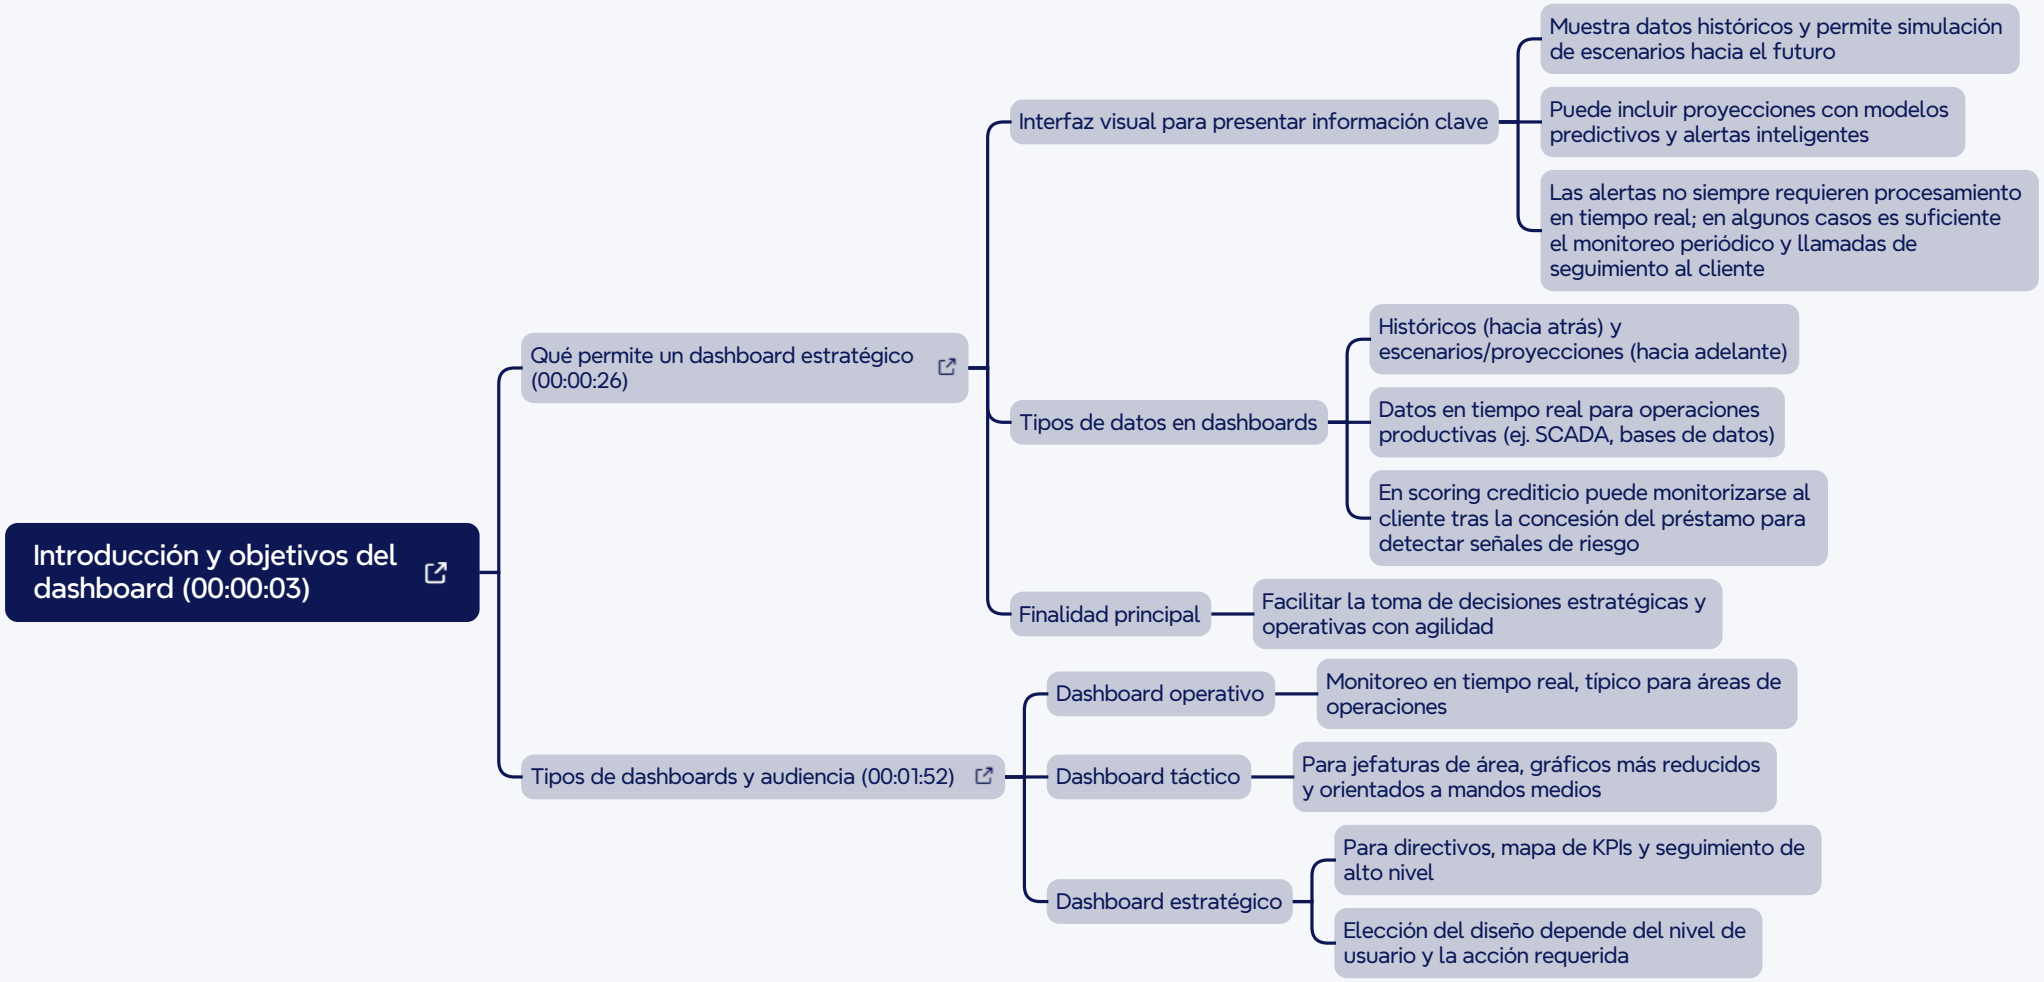
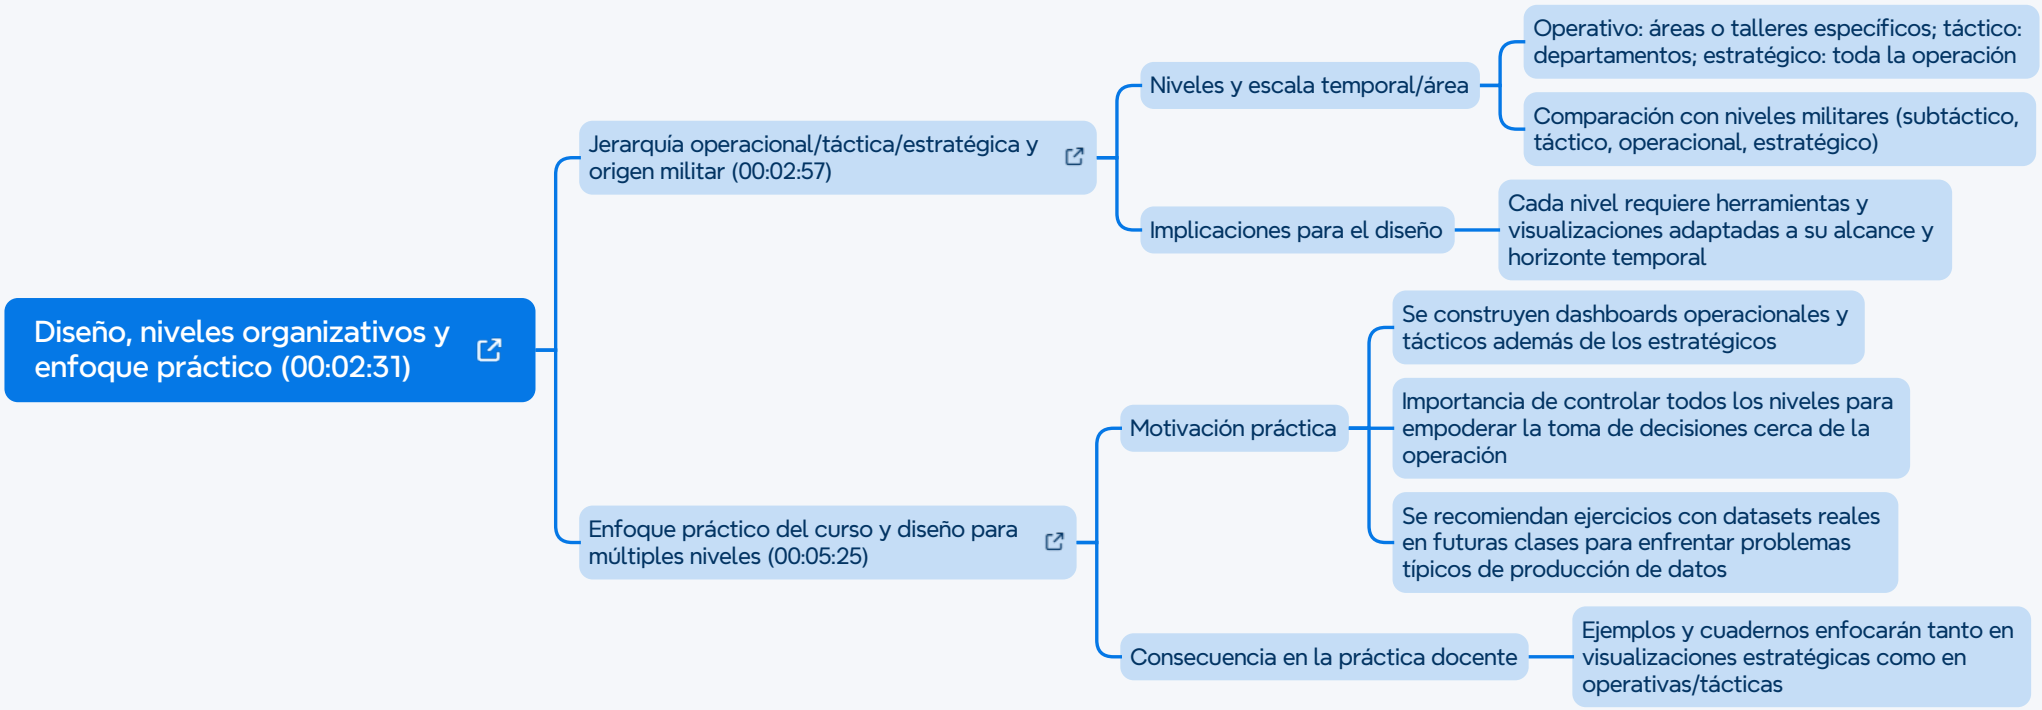
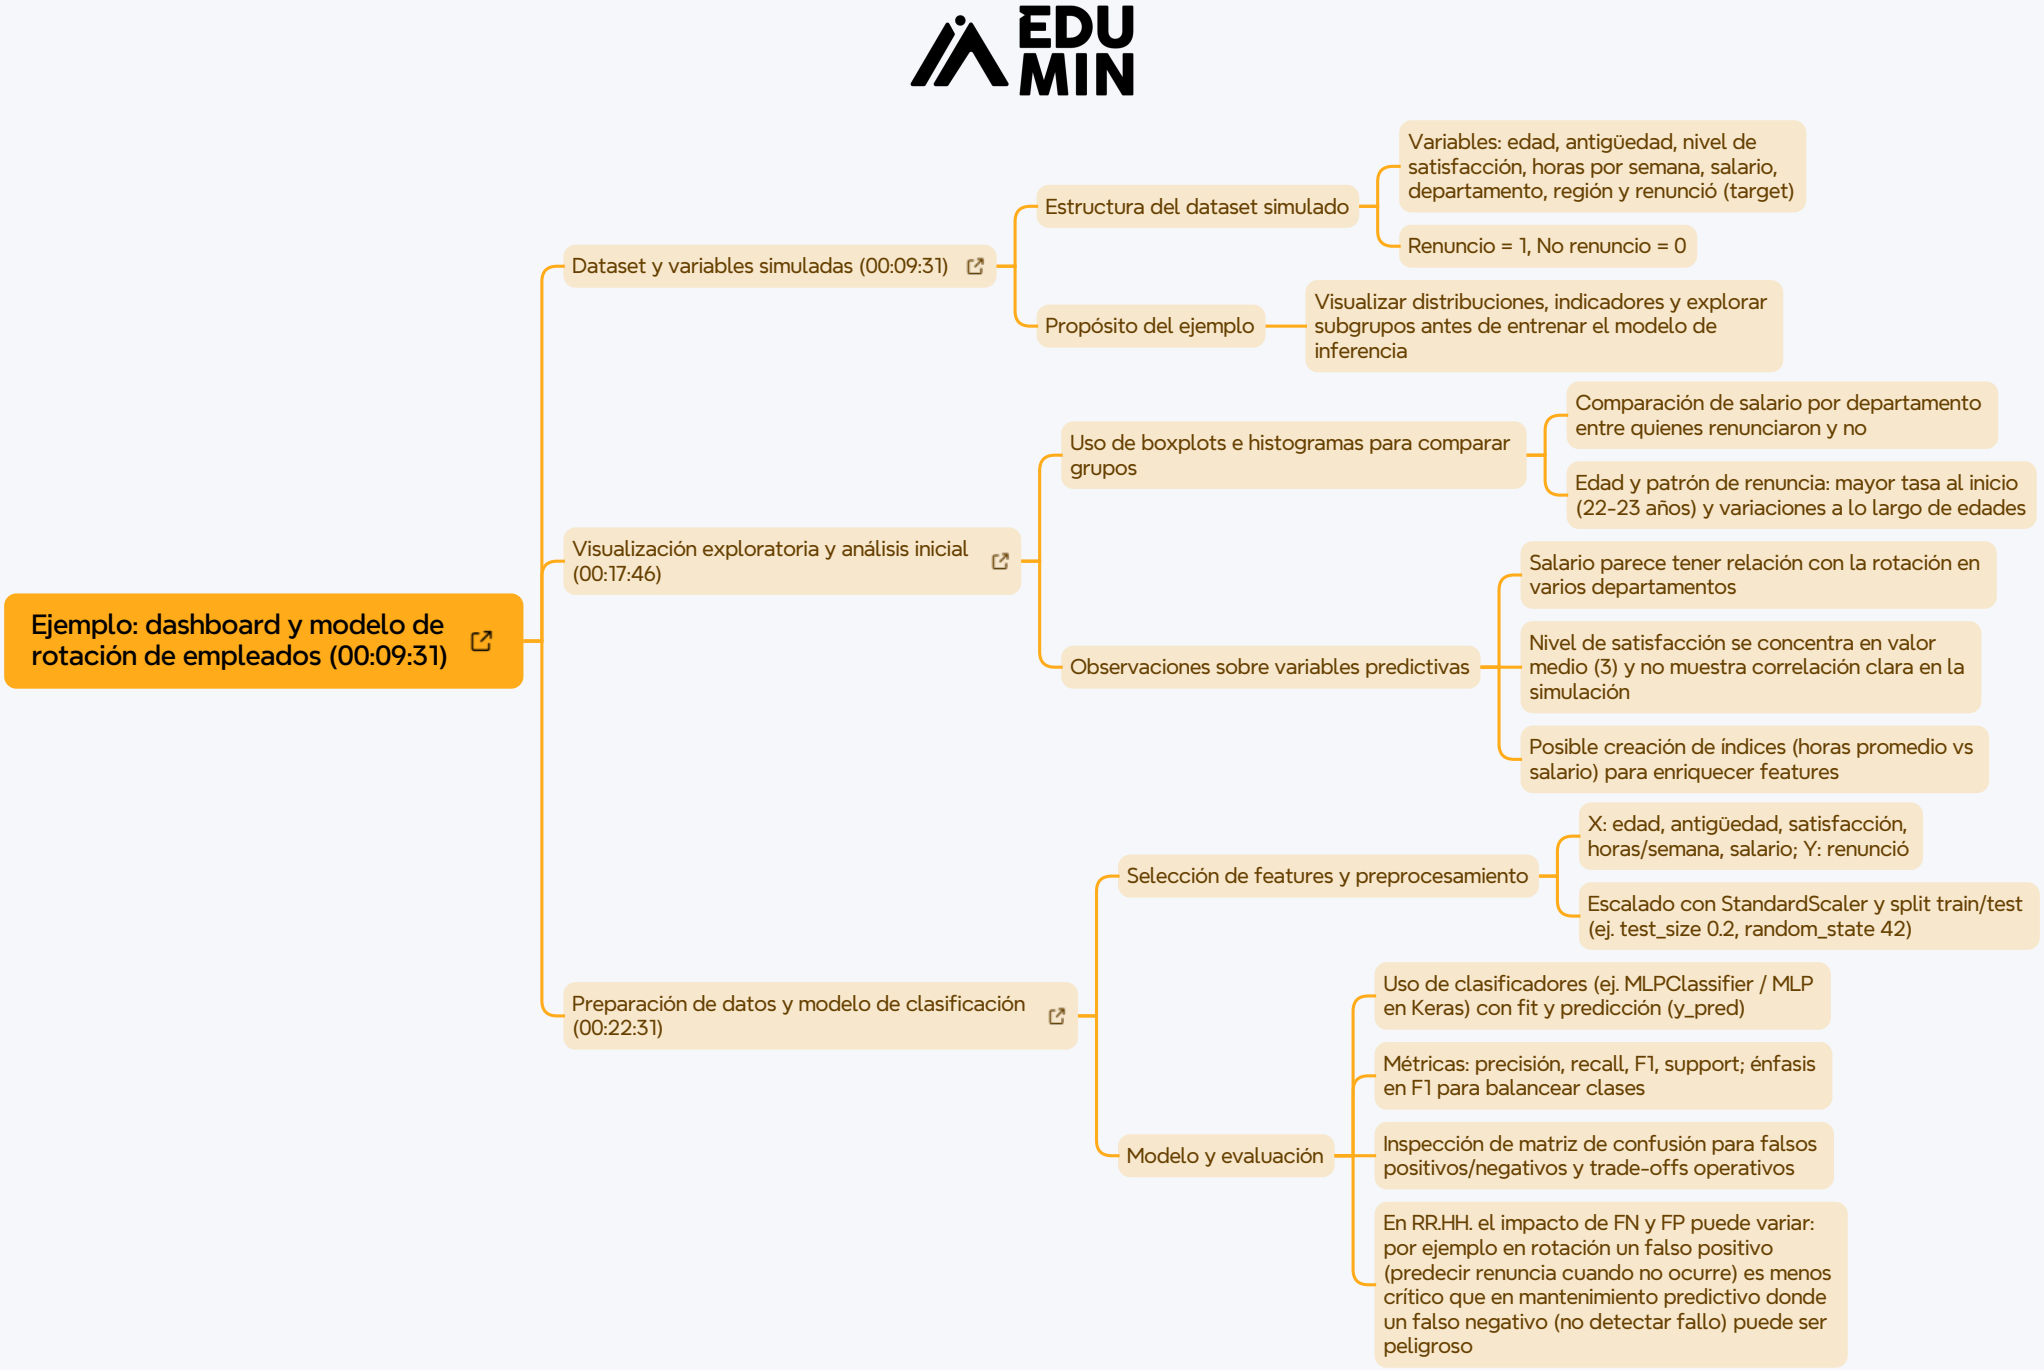
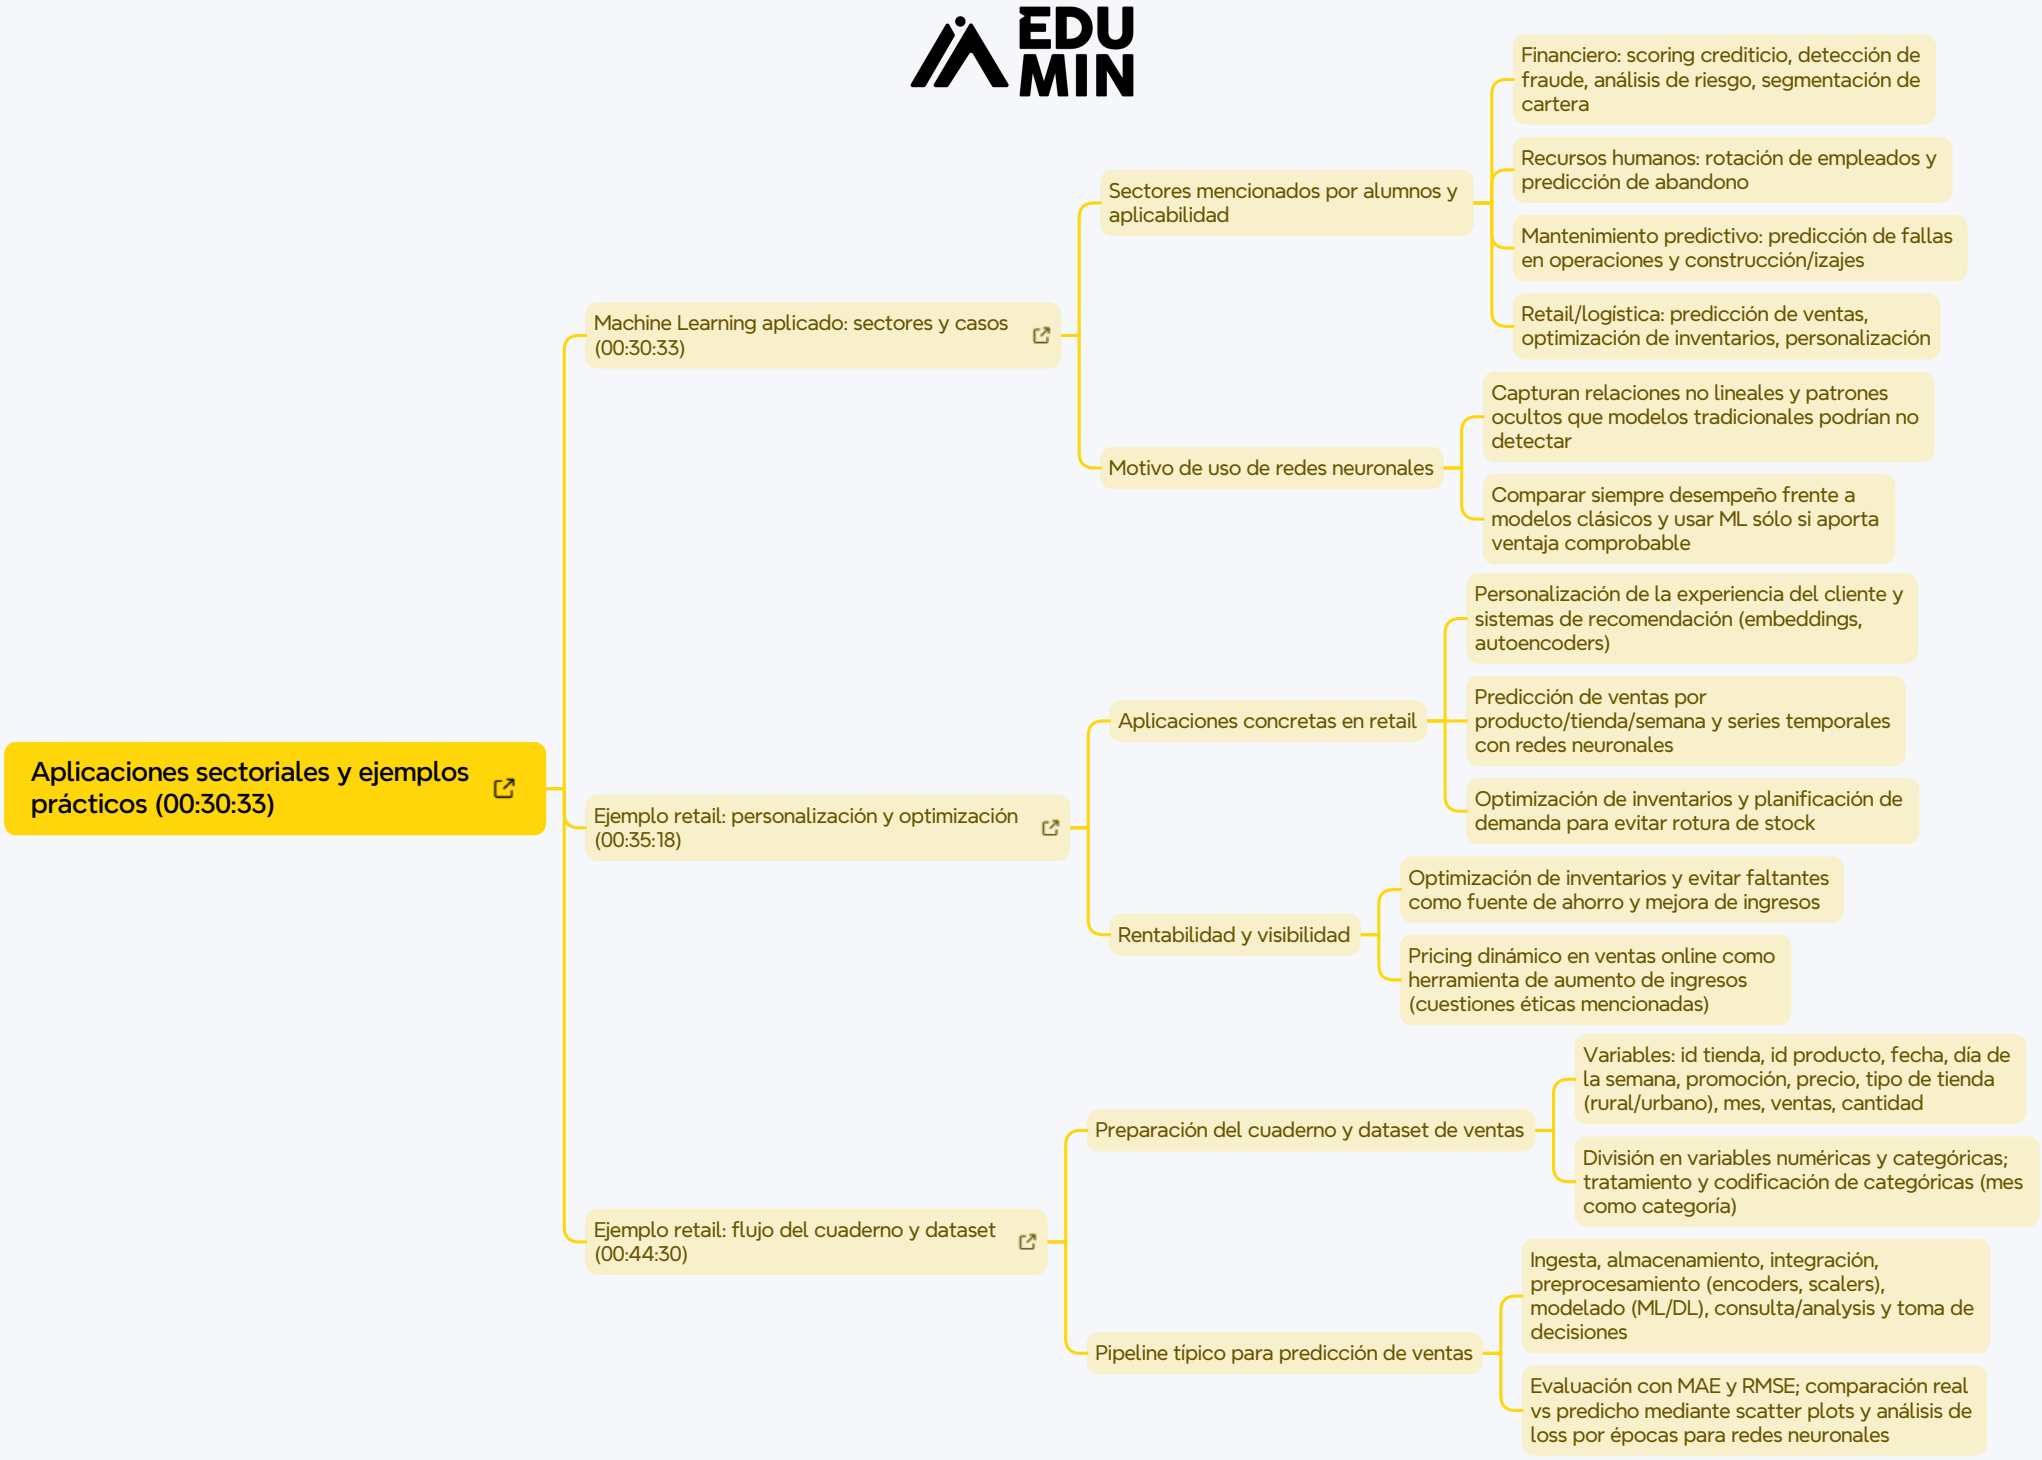
EDU MIN

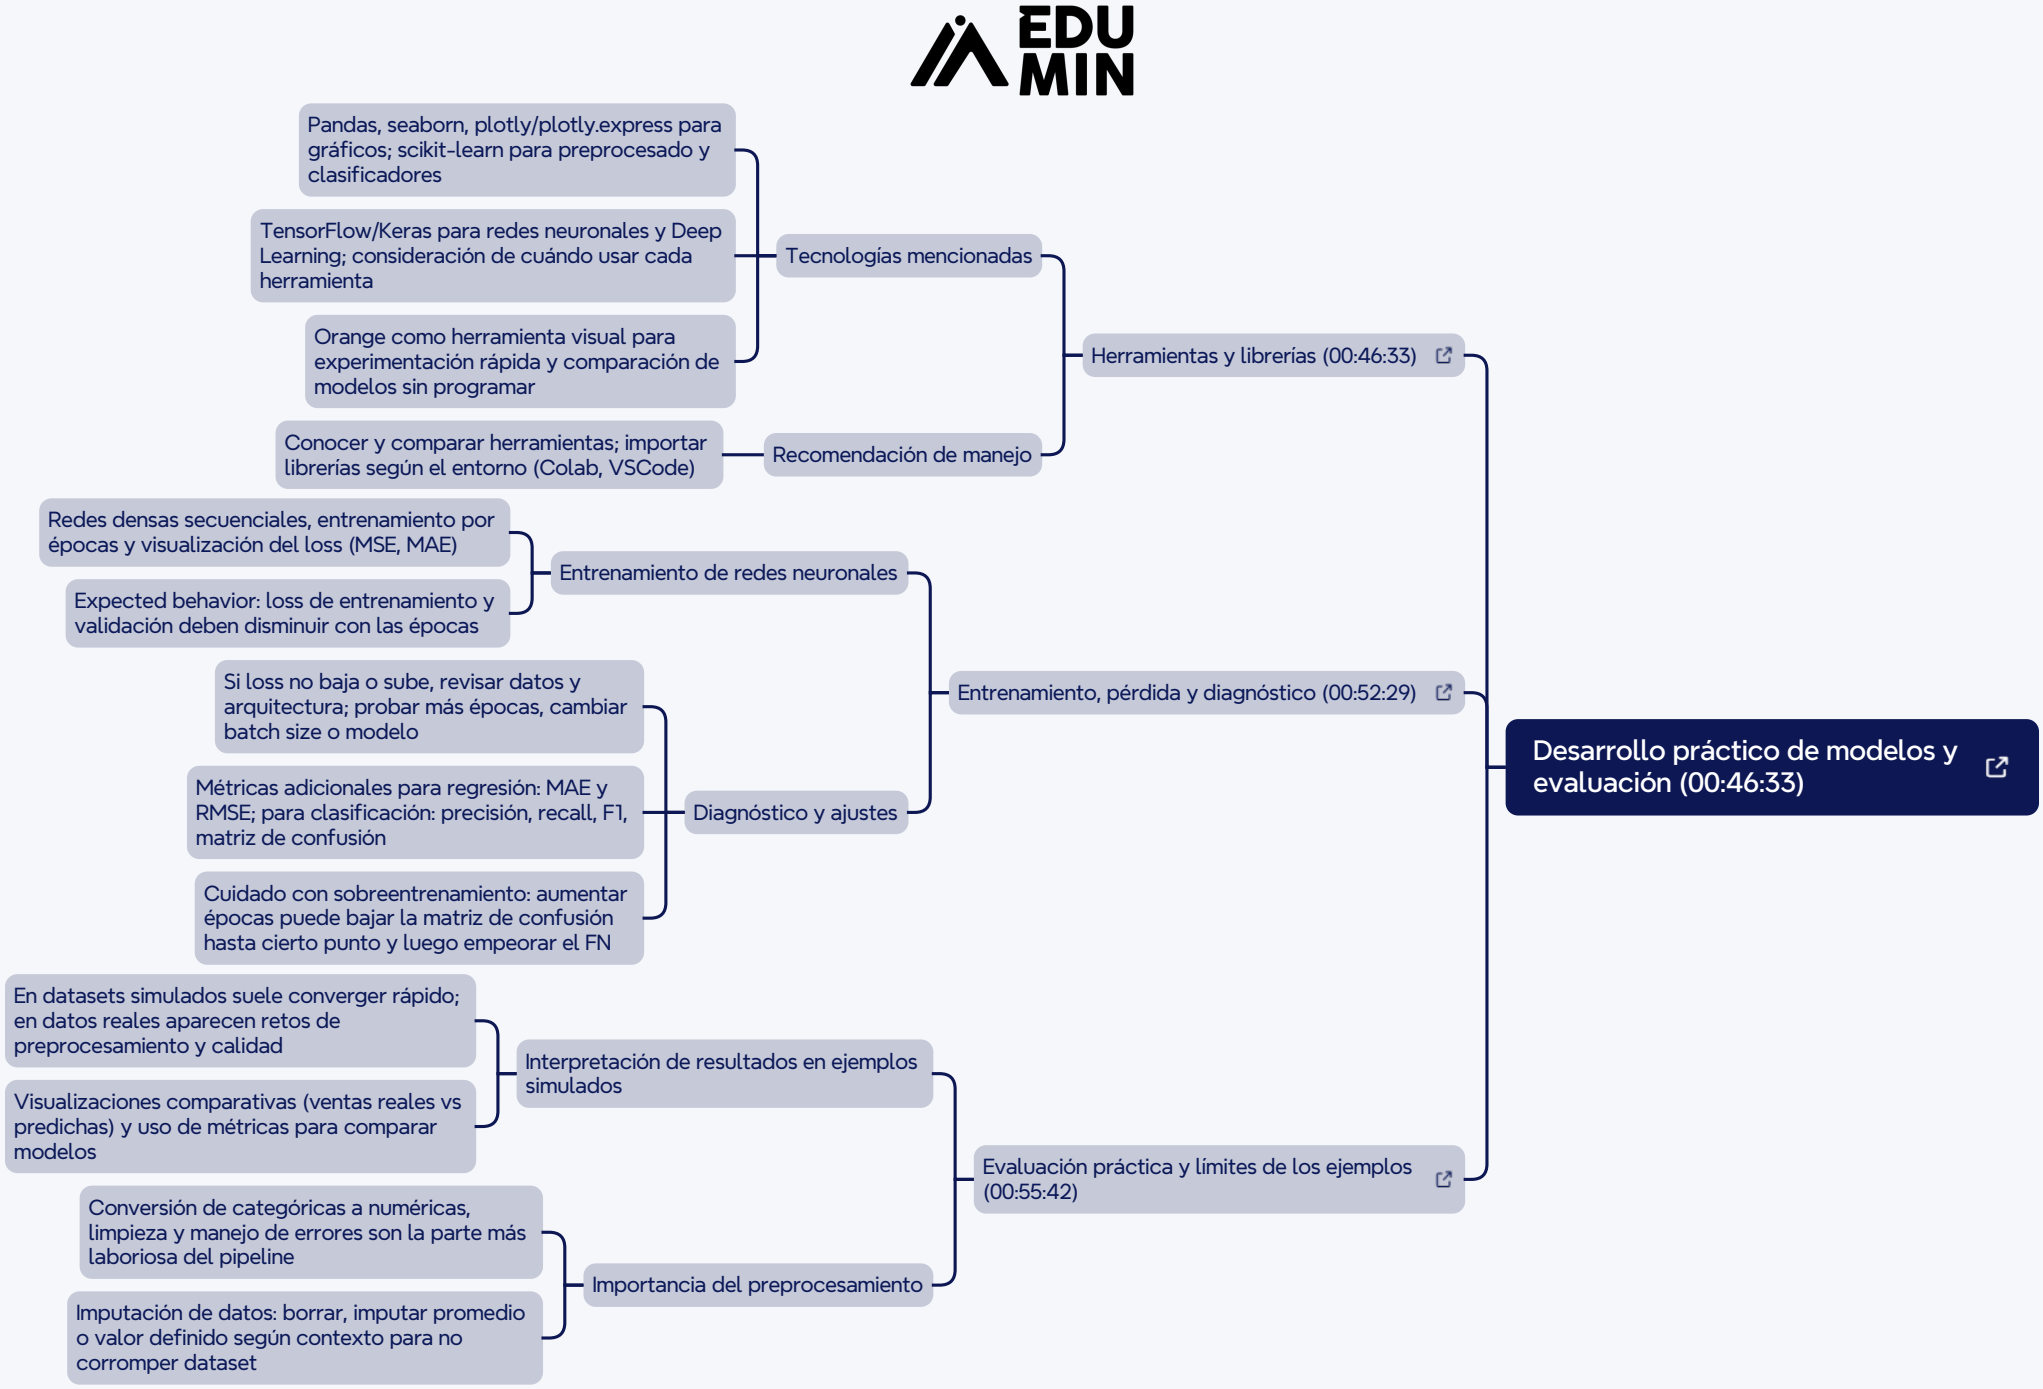

CLASE 19: MACHINE LEARNING APLICADO A SECTORES EMPRESARIALES CLAVE - 1RA PARTE
Introducción y objetivos del dashboard (00:00:03)
19
Diseño, niveles organizativos y enfoque práctico (00:02:31)
13
Ejemplo: dashboard y modelo de rotación de empleados (00:09:31)
23
Aplicaciones sectoriales y ejemplos prácticos (00:30:33)
24
Ejercicios prácticos con Orange y datasets reales (01:39:55)
21
Casos prácticos adicionales y herramientas visuales (01:00:07)
25
Desarrollo práctico de modelos y evaluación (00:46:33)
22

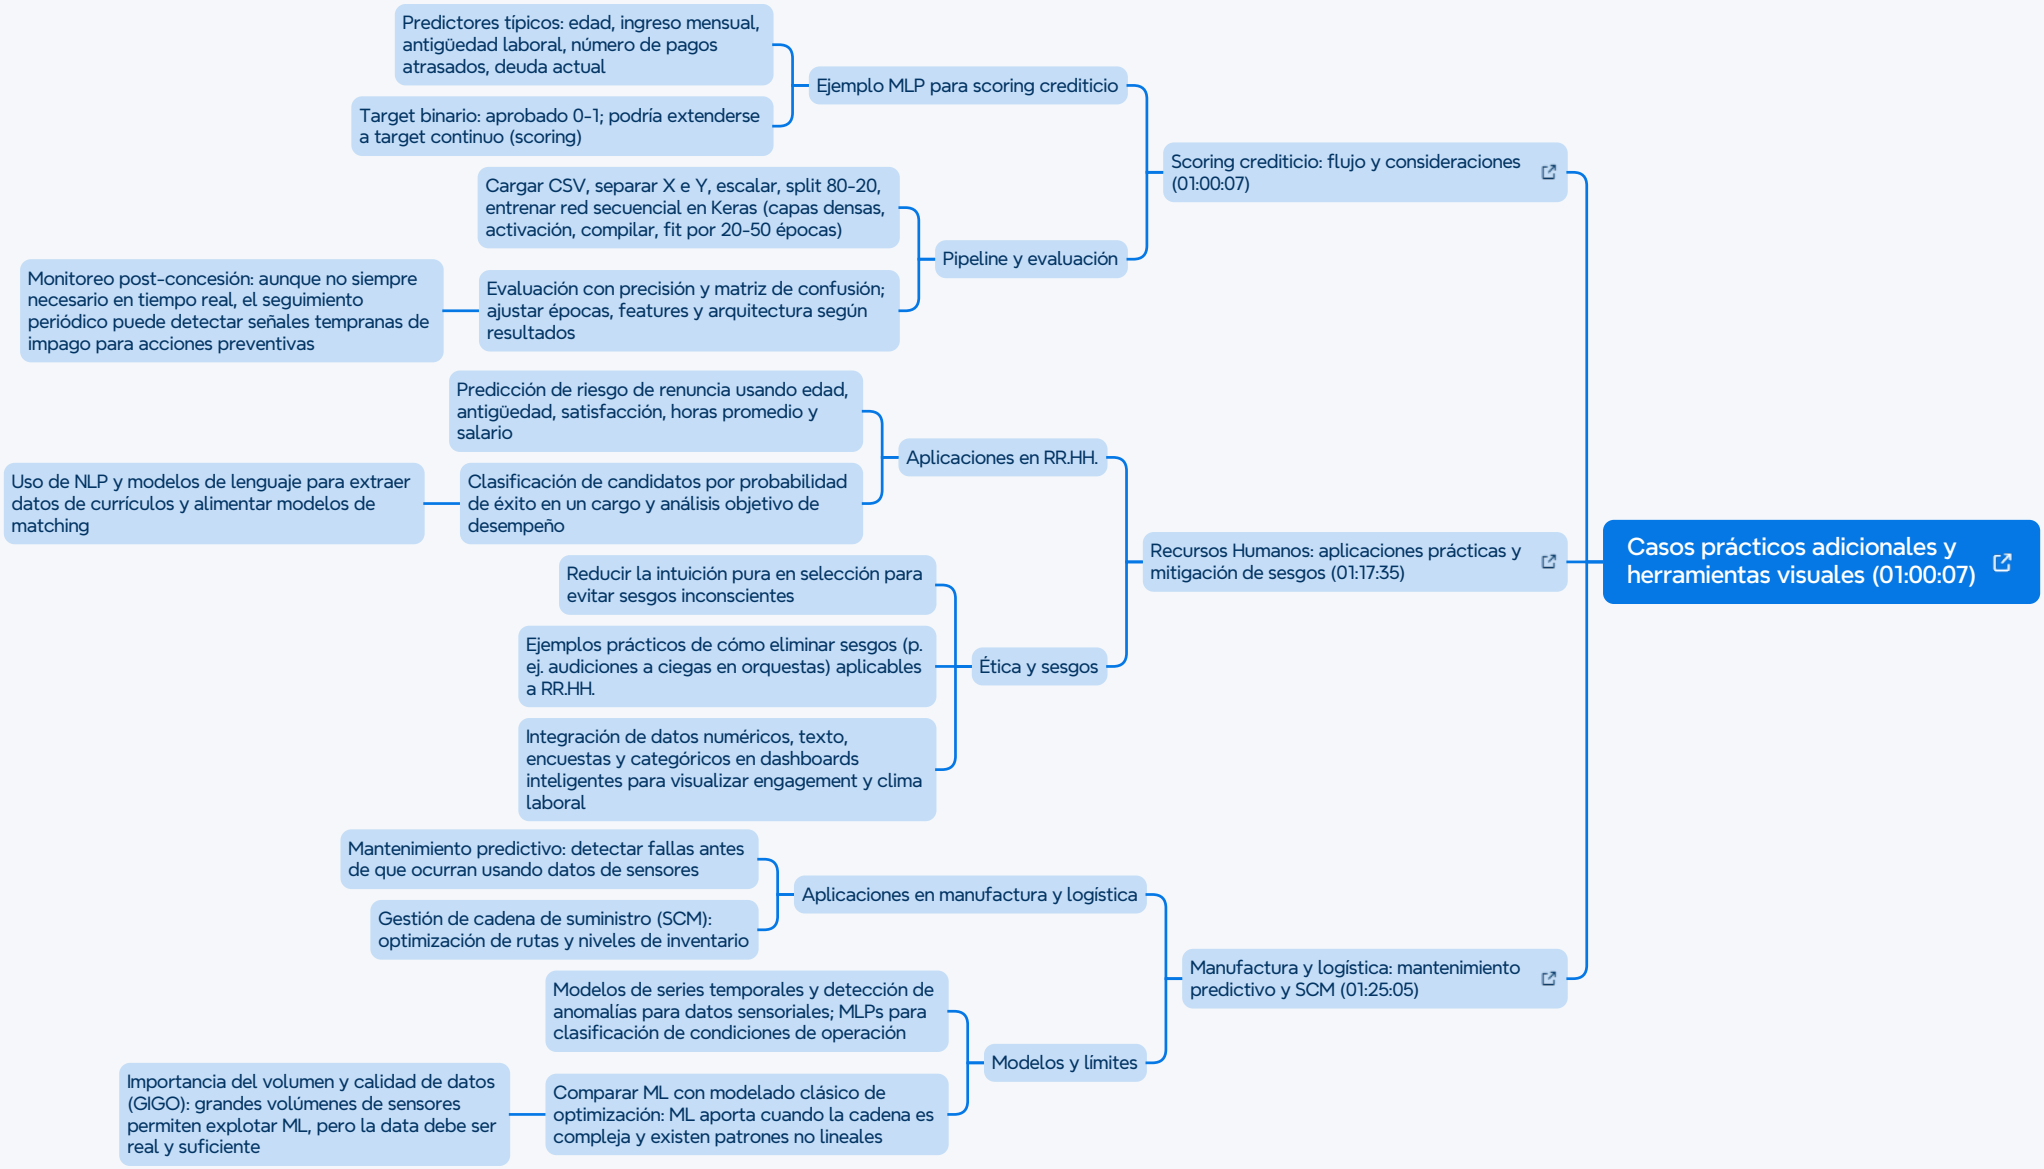

Introducción y objetivos del dashboard (00:00:03)
Qué permite un dashboard estratégico (00:00:26)
Interfaz visual para presentar información clave
Muestra datos históricos y permite simulación de escenarios hacia el futuro
Puede incluir proyecciones con modelos predictivos y alertas inteligentes
Las alertas no siempre requieren procesamiento en tiempo real; en algunos casos es suficiente el monitoreo periódico y llamadas de seguimiento al cliente
Tipos de datos en dashboards
Históricos (hacia atrás) y escenarios/proyecciones (hacia adelante)
Datos en tiempo real para operaciones productivas (ej. SCADA, bases de datos)
En scoring crediticio puede monitorizarse al cliente tras la concesión del préstamo para detectar señales de riesgo
Finalidad principal
Facilitar la toma de decisiones estratégicas y operativas con agilidad
Tipos de dashboards y audiencia (00:01:52)
Dashboard operativo
Monitoreo en tiempo real, típico para áreas de operaciones
Dashboard táctico
Para jefaturas de área, gráficos más reducidos y orientados a mandos medios
Dashboard estratégico
Para directivos, mapa de KPIs y seguimiento de alto nivel
Elección del diseño depende del nivel de usuario y la acción requerida


Diseño, niveles organizativos y enfoque práctico (00:02:31)
Jerarquía operacional/táctica/estratégica y origen militar (00:02:57)
Niveles y escala temporal/área
Operativo: áreas o talleres específicos; táctico: departamentos; estratégico: toda la operación
Comparación con niveles militares (subtáctico, táctico, operacional, estratégico)
Implicaciones para el diseño
Cada nivel requiere herramientas y visualizaciones adaptadas a su alcance y horizonte temporal
Enfoque práctico del curso y diseño para múltiples niveles (00:05:25)
Motivación práctica
Se construyen dashboards operacionales y tácticos además de los estratégicos
Importancia de controlar todos los niveles para empoderar la toma de decisiones cerca de la operación
Se recomiendan ejercicios con datasets reales en futuras clases para enfrentar problemas típicos de producción de datos
Consecuencia en la práctica docente
Ejemplos y cuadernos enfocarán tanto en visualizaciones estratégicas como en operativas/tácticas


Ejemplo: dashboard y modelo de rotación de empleados (00:09:31)
Dataset y variables simuladas (00:09:31)
Estructura del dataset simulado
Variables: edad, antigüedad, nivel de satisfacción, horas por semana, salario, departamento, región y renunció (target)
Renuncio = 1, No renuncio = 0
Propósito del ejemplo
Visualizar distribuciones, indicadores y explorar subgrupos antes de entrenar el modelo de inferencia
Visualización exploratoria y análisis inicial (00:17:46)
Uso de boxplots e histogramas para comparar grupos
Comparación de salario por departamento entre quienes renunciaron y no
Edad y patrón de renuncia: mayor tasa al inicio (22-23 años) y variaciones a lo largo de edades
Observaciones sobre variables predictivas
Salario parece tener relación con la rotación en varios departamentos
Nivel de satisfacción se concentra en valor medio (3) y no muestra correlación clara en la simulación
Posible creación de índices (horas promedio vs salario) para enriquecer features
Preparación de datos y modelo de clasificación (00:22:31)
Selección de features y preprocesamiento
X: edad, antigüedad, satisfacción, horas/semana, salario; Y: renunció
Escalado con StandardScaler y split train/test (ej. test_size 0.2, random_state 42)
Modelo y evaluación
Uso de clasificadores (ej. MLPClassifier / MLP en Keras) con fit y predicción (y_pred)
Métricas: precisión, recall, F1, support; énfasis en F1 para balancear clases
Inspección de matriz de confusión para falsos positivos/negativos y trade-offs operativos
En RR.HH. el impacto de FN y FP puede variar: por ejemplo en rotación un falso positivo (predecir renuncia cuando no ocurre) es menos crítico que en mantenimiento predictivo donde un falso negativo (no detectar fallo) puede ser peligroso


Aplicaciones sectoriales y ejemplos prácticos (00:30:33)
Machine Learning aplicado: sectores y casos (00:30:33)
Sectores mencionados por alumnos y aplicabilidad
Financiero: scoring crediticio, detección de fraude, análisis de riesgo, segmentación de cartera
Recursos humanos: rotación de empleados y predicción de abandono
Mantenimiento predictivo: predicción de fallas en operaciones y construcción/izajes
Retail/logística: predicción de ventas, optimización de inventarios, personalización
Motivo de uso de redes neuronales
Capturan relaciones no lineales y patrones ocultos que modelos tradicionales podrían no detectar
Comparar siempre desempeño frente a modelos clásicos y usar ML sólo si aporta ventaja comprobable
Ejemplo retail: personalización y optimización (00:35:18)
Aplicaciones concretas en retail
Personalización de la experiencia del cliente y sistemas de recomendación (embeddings, autoencoders)
Predicción de ventas por producto/tienda/semana y series temporales con redes neuronales
Optimización de inventarios y planificación de demanda para evitar rotura de stock
Rentabilidad y visibilidad
Optimización de inventarios y evitar faltantes como fuente de ahorro y mejora de ingresos
Pricing dinámico en ventas online como herramienta de aumento de ingresos (cuestiones éticas mencionadas)
Ejemplo retail: flujo del cuaderno y dataset (00:44:30)
Preparación del cuaderno y dataset de ventas
Variables: id tienda, id producto, fecha, día de la semana, promoción, precio, tipo de tienda (rural/urbano), mes, ventas, cantidad
División en variables numéricas y categóricas; tratamiento y codificación de categóricas (mes como categoría)
Pipeline típico para predicción de ventas
Ingesta, almacenamiento, integración, preprocesamiento (encoders, scalers), modelado (ML/DL), consulta/analysis y toma de decisiones
Evaluación con MAE y RMSE; comparación real vs predicho mediante scatter plots y análisis de loss por épocas para redes neuronales


Desarrollo práctico de modelos y evaluación (00:46:33)
Herramientas y librerías (00:46:33)
Tecnologías mencionadas
Pandas, seaborn, plotly/plotly.express para gráficos; scikit-learn para preprocesado y clasificadores
TensorFlow/Keras para redes neuronales y Deep Learning; consideración de cuándo usar cada herramienta
Orange como herramienta visual para experimentación rápida y comparación de modelos sin programar
Recomendación de manejo
Conocer y comparar herramientas; importar librerías según el entorno (Colab, VSCode)
Entrenamiento, pérdida y diagnóstico (00:52:29)
Entrenamiento de redes neuronales
Redes densas secuenciales, entrenamiento por épocas y visualización del loss (MSE, MAE)
Expected behavior: loss de entrenamiento y validación deben disminuir con las épocas
Diagnóstico y ajustes
Si loss no baja o sube, revisar datos y arquitectura; probar más épocas, cambiar batch size o modelo
Métricas adicionales para regresión: MAE y RMSE; para clasificación: precisión, recall, F1, matriz de confusión
Cuidado con sobreentrenamiento: aumentar épocas puede bajar la matriz de confusión hasta cierto punto y luego empeorar el FN
Evaluación práctica y límites de los ejemplos (00:55:42)
Interpretación de resultados en ejemplos simulados
En datasets simulados suele converger rápido; en datos reales aparecen retos de preprocesamiento y calidad
Visualizaciones comparativas (ventas reales vs predichas) y uso de métricas para comparar modelos
Importancia del preprocesamiento
Conversión de categóricas a numéricas, limpieza y manejo de errores son la parte más laboriosa del pipeline
Imputación de datos: borrar, imputar promedio o valor definido según contexto para no corromper dataset


Casos prácticos adicionales y herramientas visuales (01:00:07)
Scoring crediticio: flujo y consideraciones (01:00:07)
Ejemplo MLP para scoring crediticio
Predictores típicos: edad, ingreso mensual, antigüedad laboral, número de pagos atrasados, deuda actual
Target binario: aprobado 0-1; podría extenderse a target continuo (scoring)
Pipeline y evaluación
Cargar CSV, separar X e Y, escalar, split 80-20, entrenar red secuencial en Keras (capas densas, activación, compilar, fit por 20-50 épocas)
Evaluación con precisión y matriz de confusión; ajustar épocas, features y arquitectura según resultados
Monitoreo post-concesión: aunque no siempre necesario en tiempo real, el seguimiento periódico puede detectar señales tempranas de impago para acciones preventivas
Recursos Humanos: aplicaciones prácticas y mitigación de sesgos (01:17:35)
Aplicaciones en RR.HH.
Predicción de riesgo de renuncia usando edad, antigüedad, satisfacción, horas promedio y salario
Clasificación de candidatos por probabilidad de éxito en un cargo y análisis objetivo de desempeño
Uso de NLP y modelos de lenguaje para extraer datos de currículos y alimentar modelos de matching
Ética y sesgos
Reducir la intuición pura en selección para evitar sesgos inconscientes
Ejemplos prácticos de cómo eliminar sesgos (p. ej. audiciones a ciegas en orquestas) aplicables a RR.HH.
Integración de datos numéricos, texto, encuestas y categóricos en dashboards inteligentes para visualizar engagement y clima laboral
Manufactura y logística: mantenimiento predictivo y SCM (01:25:05)
Aplicaciones en manufactura y logística
Mantenimiento predictivo: detectar fallas antes de que ocurran usando datos de sensores
Gestión de cadena de suministro (SCM): optimización de rutas y niveles de inventario
Modelos y límites
Modelos de series temporales y detección de anomalías para datos sensoriales; MLPs para clasificación de condiciones de operación
Comparar ML con modelado clásico de optimización: ML aporta cuando la cadena es compleja y existen patrones no lineales
Importancia del volumen y calidad de datos (GIGO): grandes volúmenes de sensores permiten explotar ML, pero la data debe ser real y suficiente

Ejercicios prácticos con Orange y datasets reales (01:39:55)

- Uso de Orange para mantenimiento predictivo (01:39:55)
  - Flujo visual en Orange
    - Widgets ordenados por pipeline: importación de CSV, inspección (Data Table), imputación, selección de columnas, sampler (80-20), modelos y evaluación (Test & Score, matriz de confusión)
    - Permite probar múltiples modelos rápidamente (GLM, Random Forest, KNN) y comparar matrices de confusión y ROC
  - Ajustes rápidos y experimentación
    - Selección de features para probar impacto; cambiar parámetros de modelos (ej. número de árboles en Random Forest)
    - Atención al hecho de que datasets simulados pueden dar resultados optimistas; con datos reales aparecerán problemas de limpieza y ruido
- Caso práctico: mantenimiento predictivo con datos reales (01:54:25)
  - Dataset real sugerido para práctica
    - Datos típicos: identificador, tipo de máquina (categoría), temperatura del aire, temperatura del proceso, RPM, torque, desgaste de herramienta y target de fallo
    - Metadata útil y limpieza previa: convertir categorías a numéricas, imputar valores atípicos y revisar ranges razonables
  - Recomendación para alumnos
    - Buscar datasets relacionados con su sector en repositorios (link provisto en el chat) y traer preguntas sobre problemas encontrados en la siguiente clase
    - Practicar con el cuaderno provisto y el dataset real para experimentar exploración, limpieza, modelado y evaluación
- Siguientes pasos y recursos (01:57:15)
  - Recomendaciones
    - Trabajar con datasets reales en próximas clases para enfrentar problemas reales de limpieza, imputación y ajuste de modelos
    - Usar herramientas visuales como Orange para aprendizaje rápido y librerías (Pandas, scikit-learn, TensorFlow/Keras) para implementación reproducible
  - Comunicaciones y materiales
    - Grabación de la sesión y material compartido por el grupo de clase; completar programa de asistencia y contactarse por dudas
    - Practicar buscando datasets afines al propio sector y preparar consultas para la siguiente clase