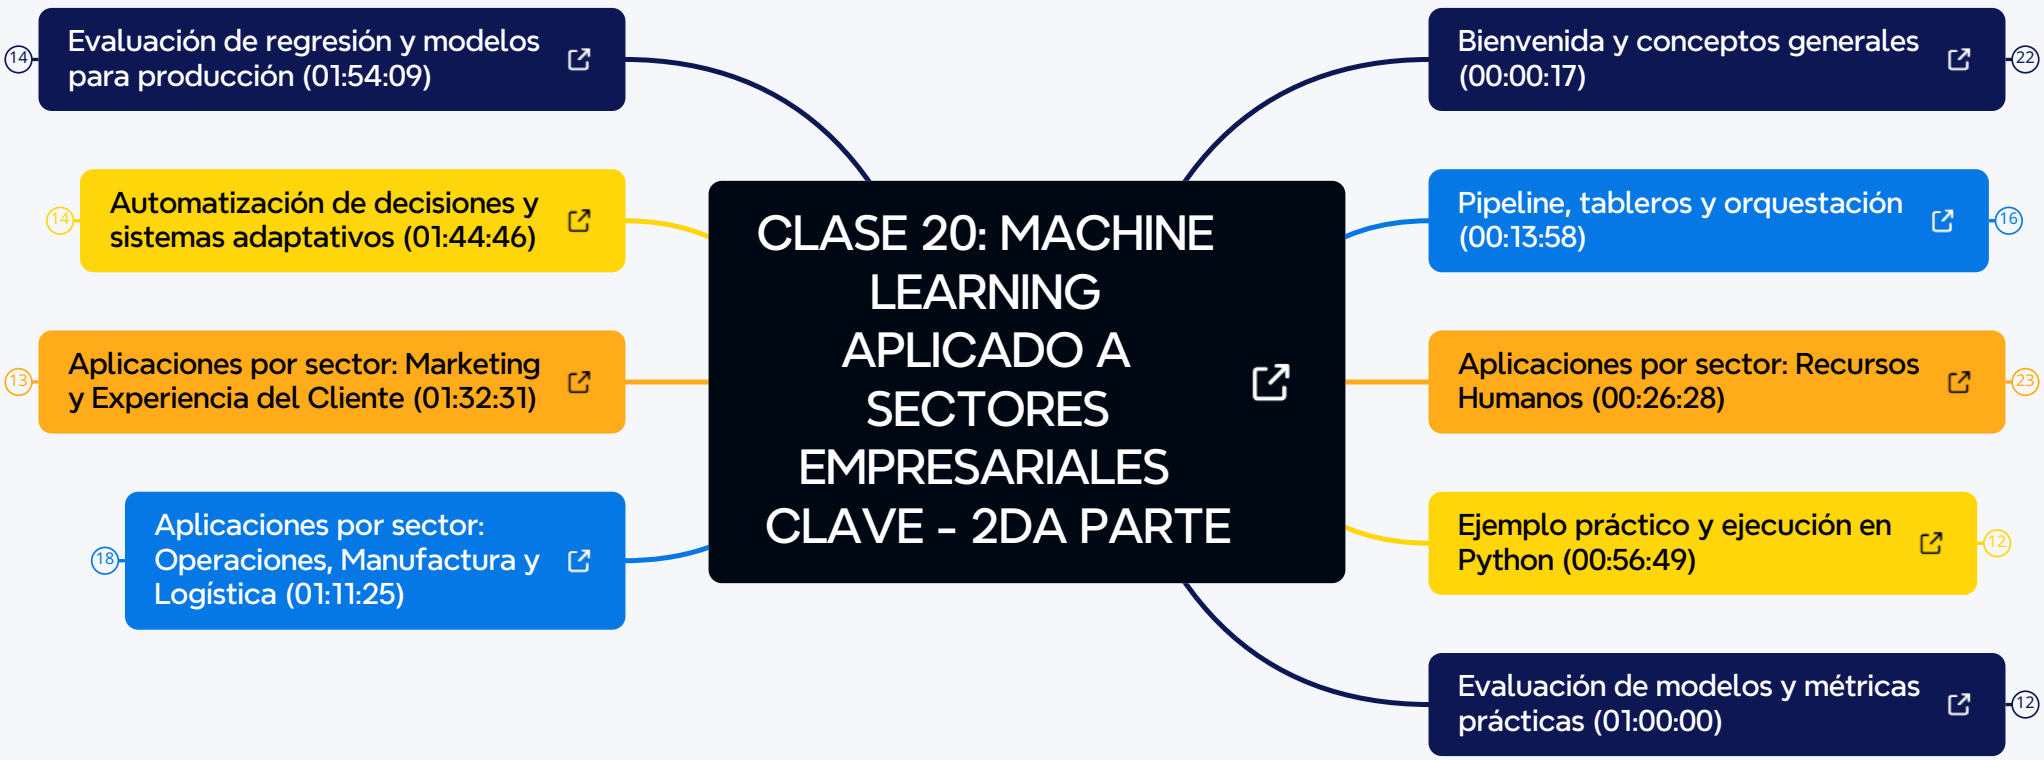
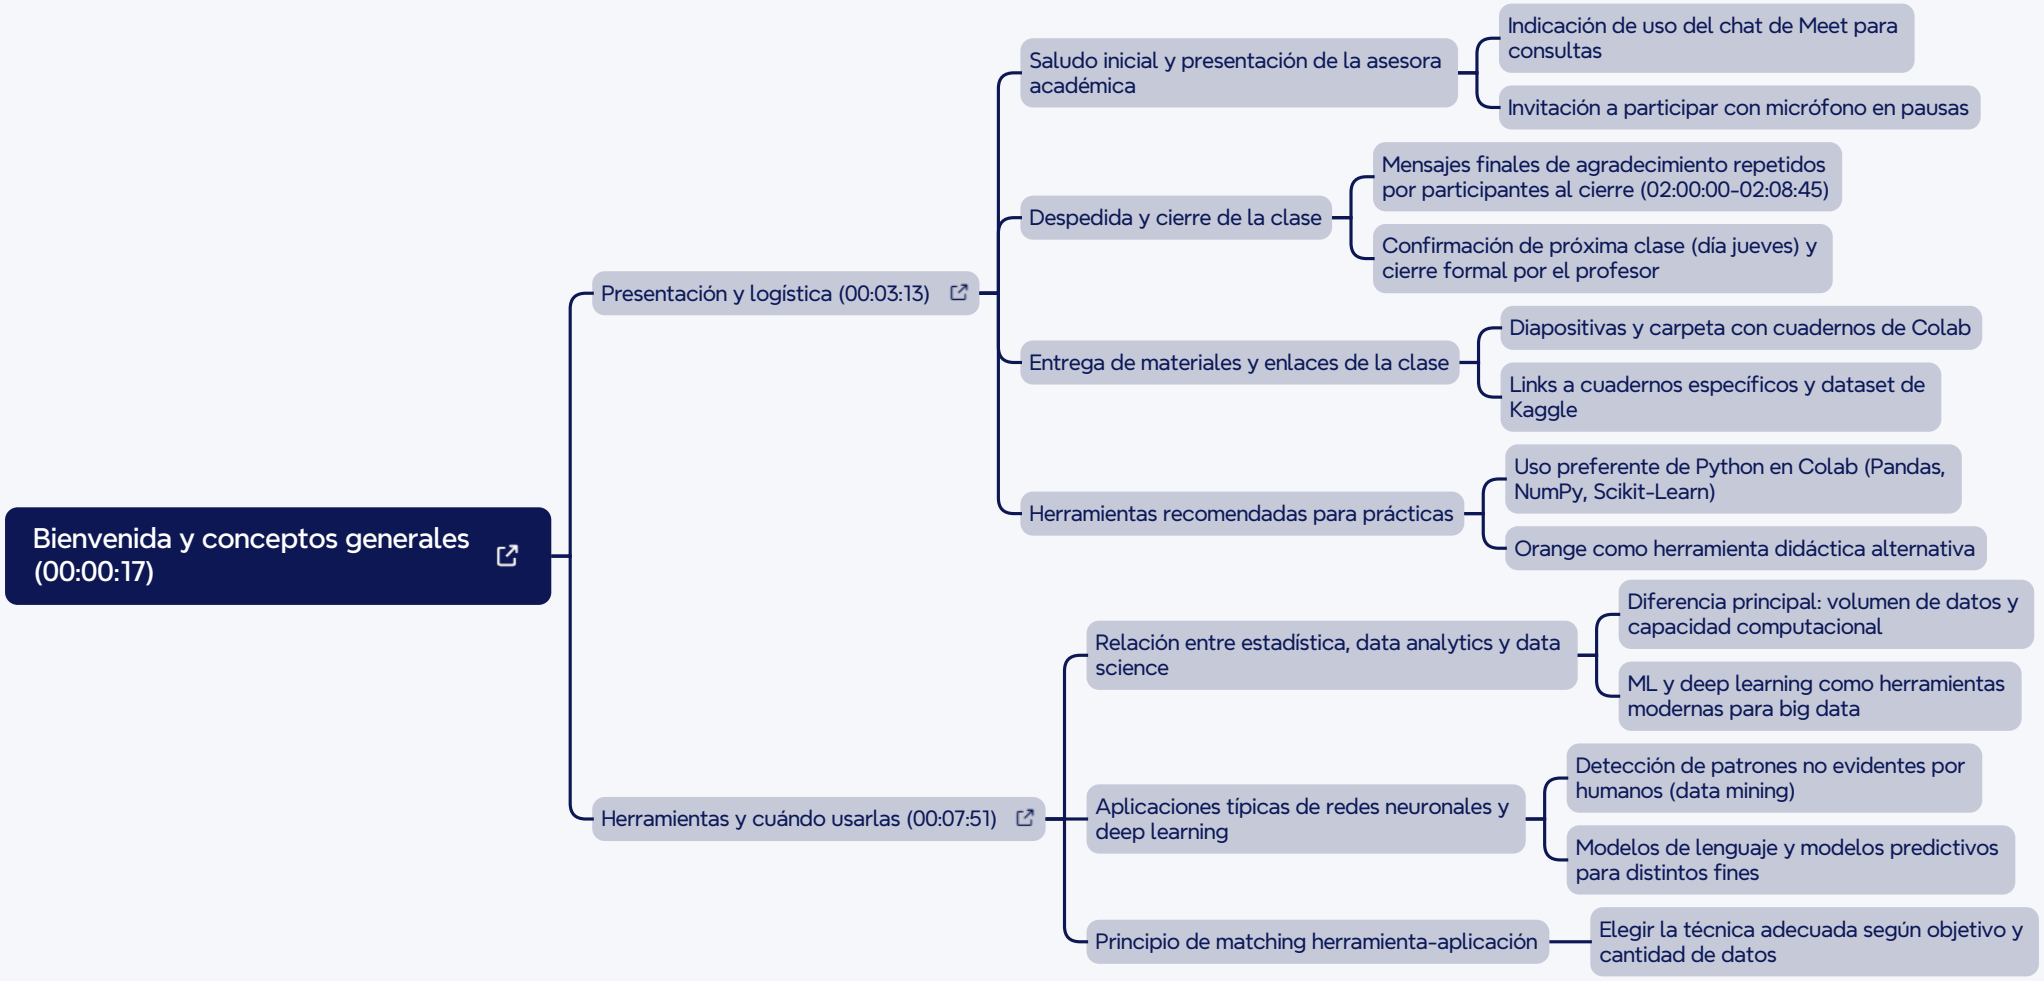
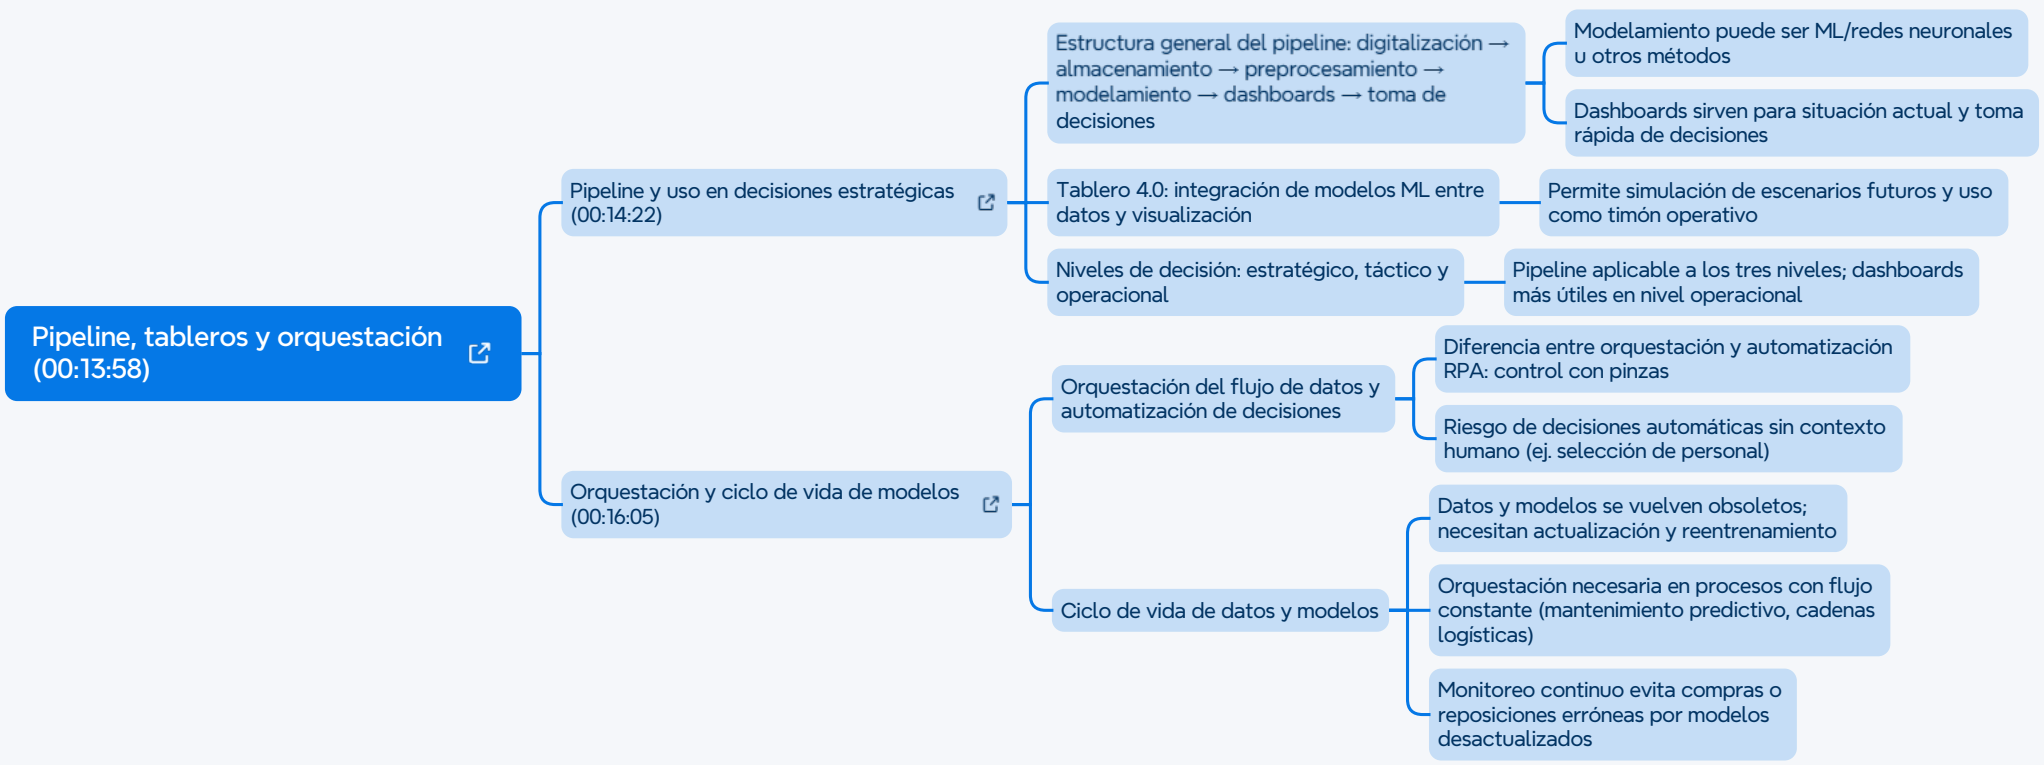
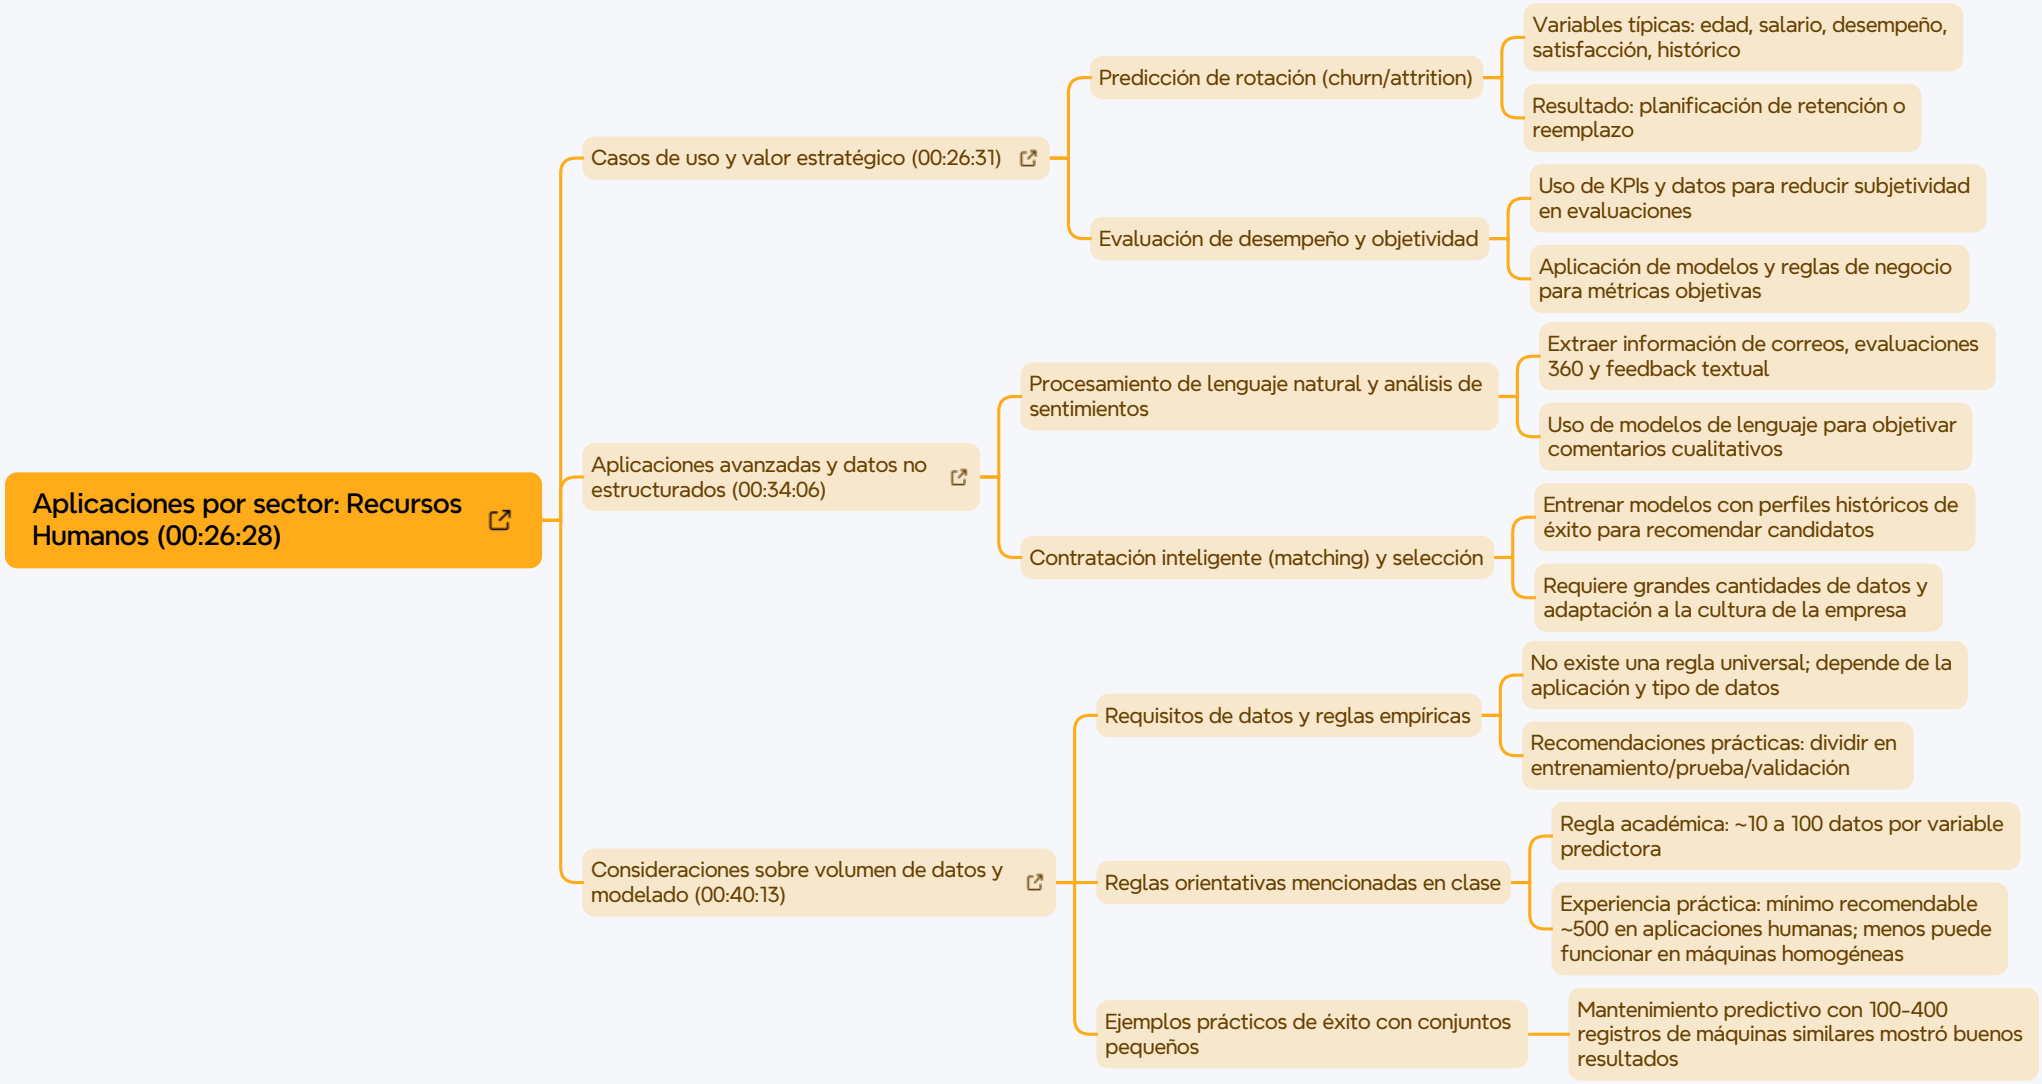
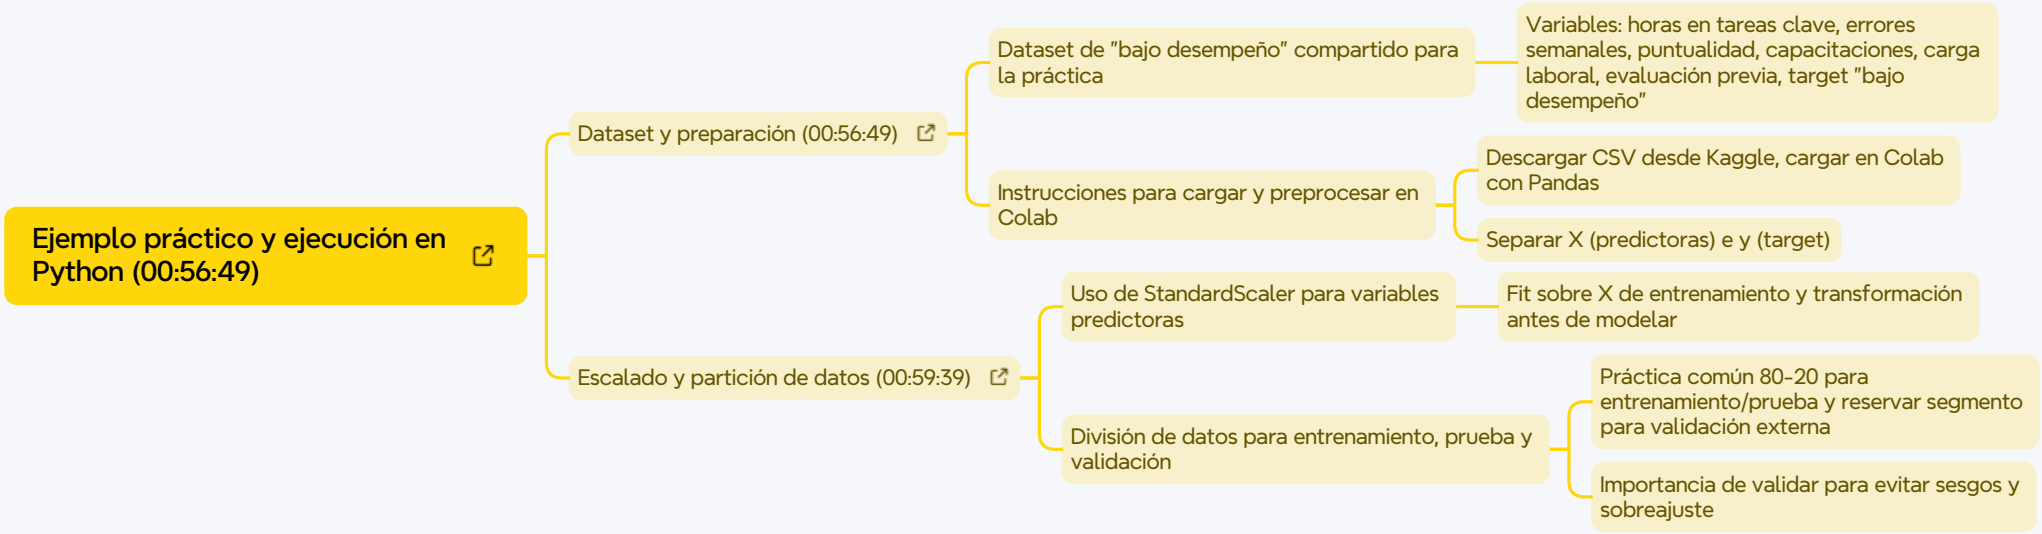
EDU MIN

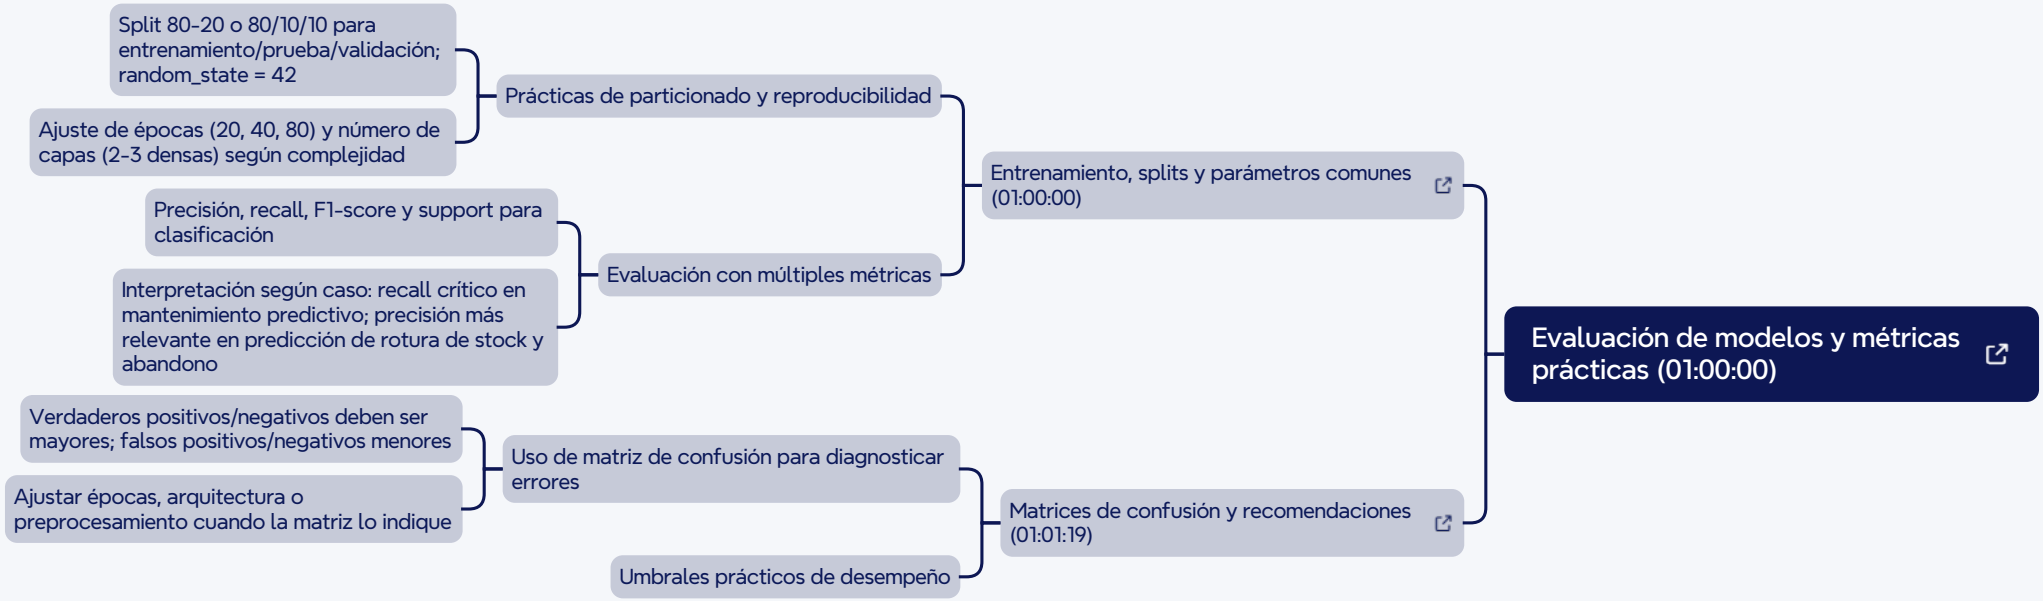

CLASE 20: MACHINE LEARNING APLICADO A SECTORES EMPRESARIALES CLAVE - 2DA PARTE
Evaluación de regresión y modelos para producción (01:54:09)
14
Automatización de decisiones y sistemas adaptativos (01:44:46)
14
Aplicaciones por sector: Marketing y Experiencia del Cliente (01:32:31)
13
Aplicaciones por sector: Operaciones, Manufactura y Logística (01:11:25)
18
Bienvenida y conceptos generales (00:00:17)
22
Pipeline, tableros y orquestación (00:13:58)
16
Aplicaciones por sector: Recursos Humanos (00:26:28)
23
Ejemplo práctico y ejecución en Python (00:56:49)
12
Evaluación de modelos y métricas prácticas (01:00:00)
12

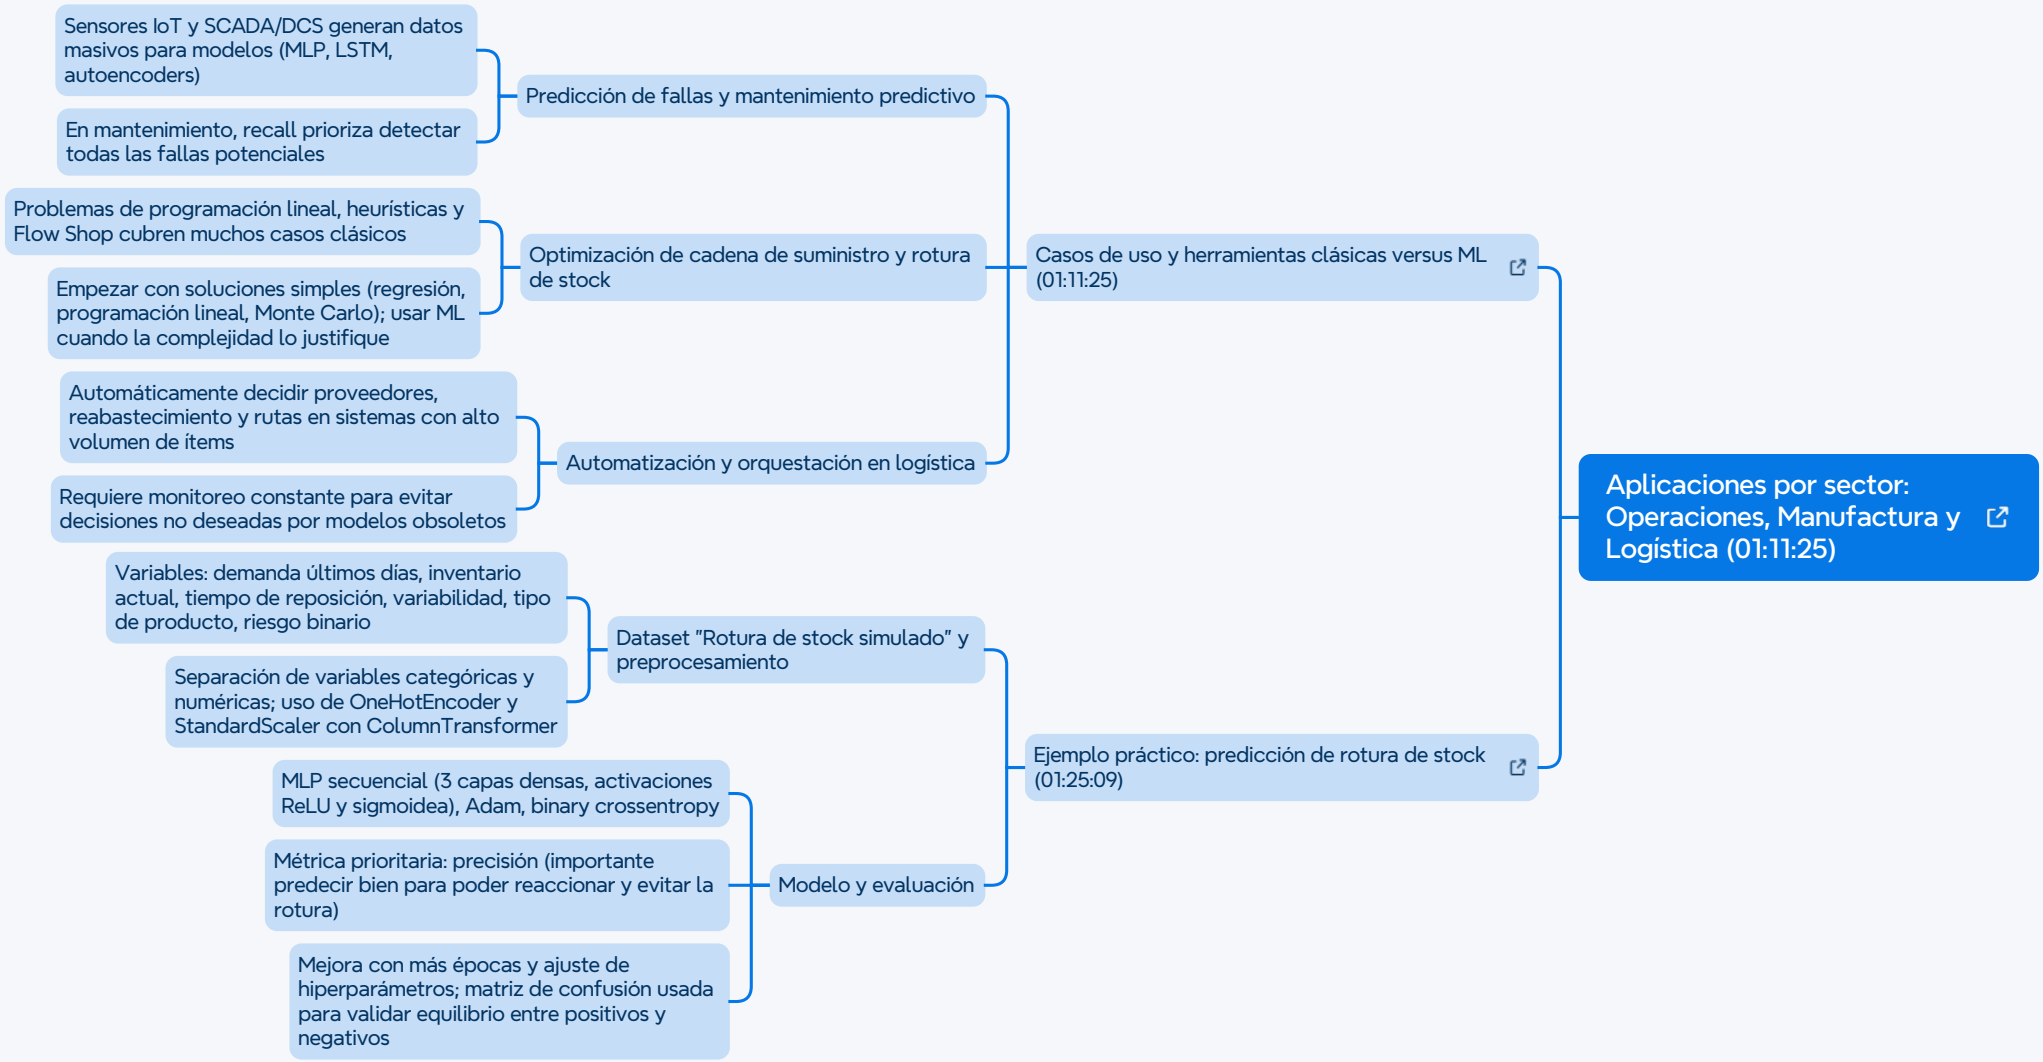

Bienvenida y conceptos generales (00:00:17)
Presentación y logística (00:03:13)
Saludo inicial y presentación de la asesora académica
Indicación de uso del chat de Meet para consultas
Invitación a participar con micrófono en pausas
Despedida y cierre de la clase
Mensajes finales de agradecimiento repetidos por participantes al cierre (02:00:00-02:08:45)
Confirmación de próxima clase (día jueves) y cierre formal por el profesor
Entrega de materiales y enlaces de la clase
Diapositivas y carpeta con cuadernos de Colab
Links a cuadernos específicos y dataset de Kaggle
Herramientas recomendadas para prácticas
Uso preferente de Python en Colab (Pandas, NumPy, Scikit-Learn)
Orange como herramienta didáctica alternativa
Herramientas y cuándo usarlas (00:07:51)
Relación entre estadística, data analytics y data science
Diferencia principal: volumen de datos y capacidad computacional
ML y deep learning como herramientas modernas para big data
Aplicaciones típicas de redes neuronales y deep learning
Detección de patrones no evidentes por humanos (data mining)
Modelos de lenguaje y modelos predictivos para distintos fines
Principio de matching herramienta-aplicación
Elegir la técnica adecuada según objetivo y cantidad de datos

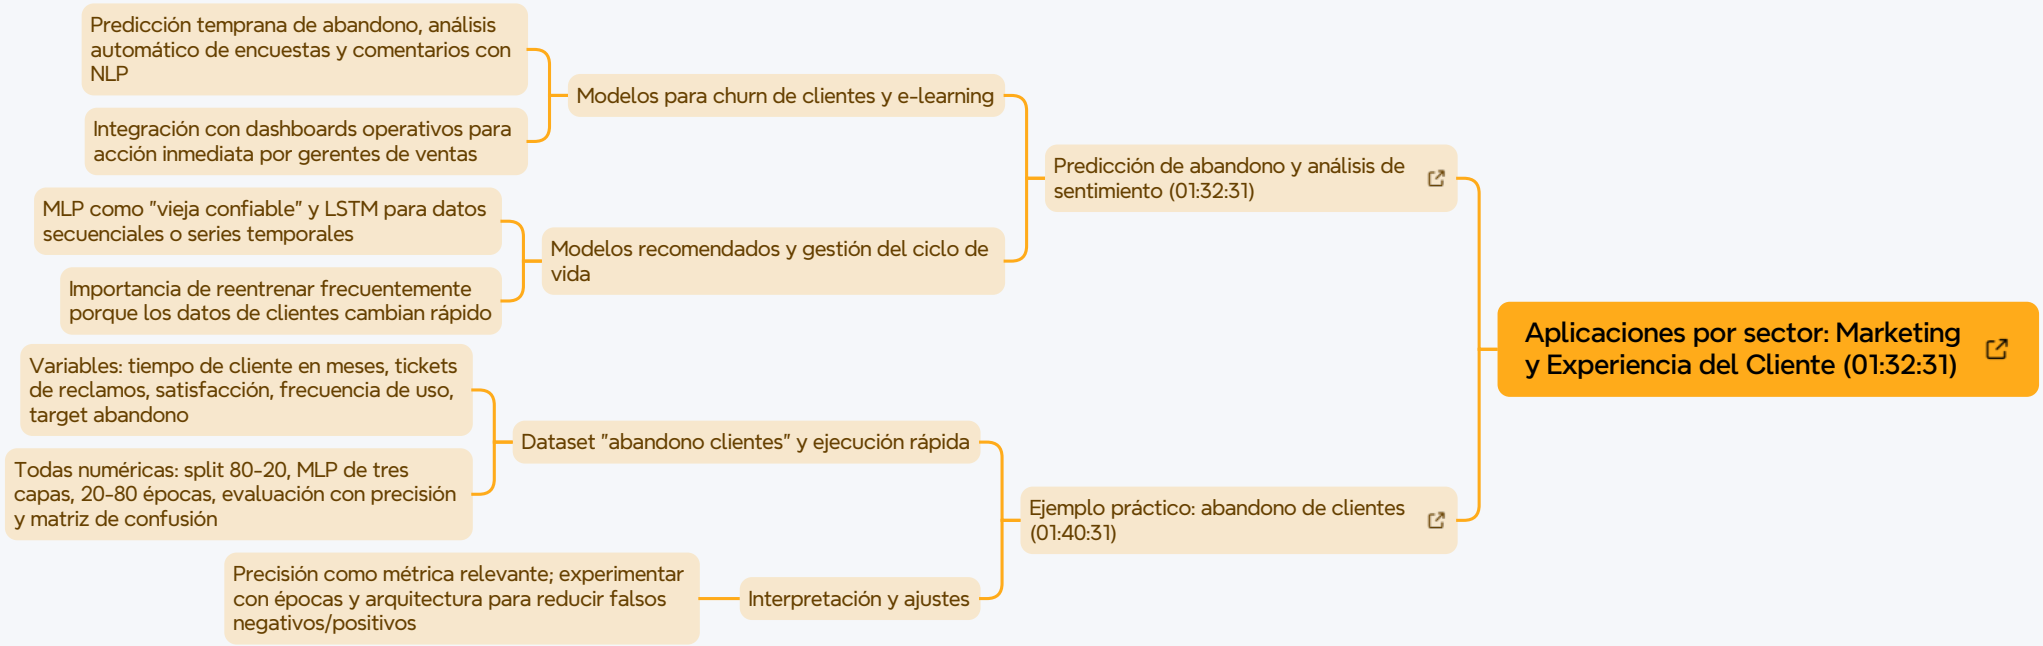

Pipeline, tableros y orquestación (00:13:58)
Pipeline y uso en decisiones estratégicas (00:14:22)
Estructura general del pipeline: digitalización → almacenamiento → preprocesamiento → modelamiento → dashboards → toma de decisiones
Modelamiento puede ser ML/redes neuronales u otros métodos
Dashboards sirven para situación actual y toma rápida de decisiones
Tablero 4.0: integración de modelos ML entre datos y visualización
Permite simulación de escenarios futuros y uso como timón operativo
Niveles de decisión: estratégico, táctico y operacional
Pipeline aplicable a los tres niveles; dashboards más útiles en nivel operacional
Orquestación y ciclo de vida de modelos (00:16:05)
Orquestación del flujo de datos y automatización de decisiones
Diferencia entre orquestación y automatización RPA: control con pinzas
Riesgo de decisiones automáticas sin contexto humano (ej. selección de personal)
Ciclo de vida de datos y modelos
Datos y modelos se vuelven obsoletos; necesitan actualización y reentrenamiento
Orquestación necesaria en procesos con flujo constante (mantenimiento predictivo, cadenas logísticas)
Monitoreo continuo evita compras o reposiciones erróneas por modelos desactualizados

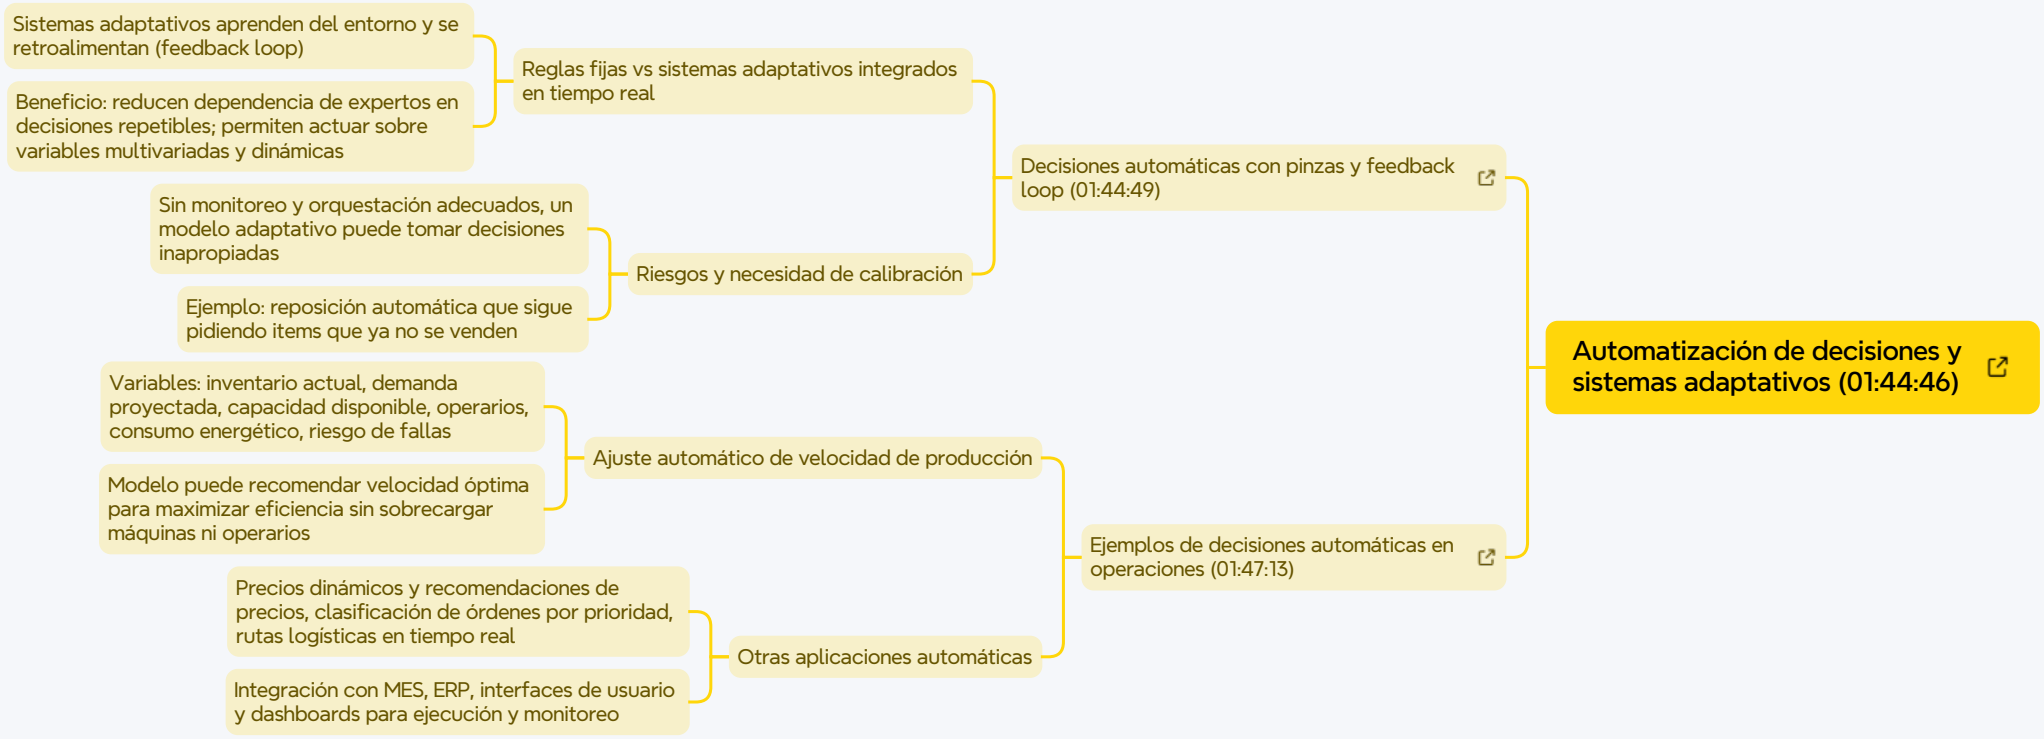

Aplicaciones por sector: Recursos Humanos (00:26:28)
Casos de uso y valor estratégico (00:26:31)
Predicción de rotación (churn/attrition)
Variables típicas: edad, salario, desempeño, satisfacción, histórico
Resultado: planificación de retención o reemplazo
Evaluación de desempeño y objetividad
Uso de KPIs y datos para reducir subjetividad en evaluaciones
Aplicación de modelos y reglas de negocio para métricas objetivas
Aplicaciones avanzadas y datos no estructurados (00:34:06)
Procesamiento de lenguaje natural y análisis de sentimientos
Extraer información de correos, evaluaciones 360 y feedback textual
Uso de modelos de lenguaje para objetivar comentarios cualitativos
Contratación inteligente (matching) y selección
Entrenar modelos con perfiles históricos de éxito para recomendar candidatos
Requiere grandes cantidades de datos y adaptación a la cultura de la empresa
Consideraciones sobre volumen de datos y modelado (00:40:13)
Requisitos de datos y reglas empíricas
No existe una regla universal; depende de la aplicación y tipo de datos
Recomendaciones prácticas: dividir en entrenamiento/prueba/validación
Reglas orientativas mencionadas en clase
Regla académica: ~10 a 100 datos por variable predictora
Experiencia práctica: mínimo recomendable ~500 en aplicaciones humanas; menos puede funcionar en máquinas homogéneas
Ejemplos prácticos de éxito con conjuntos pequeños
Mantenimiento predictivo con 100-400 registros de máquinas similares mostró buenos resultados

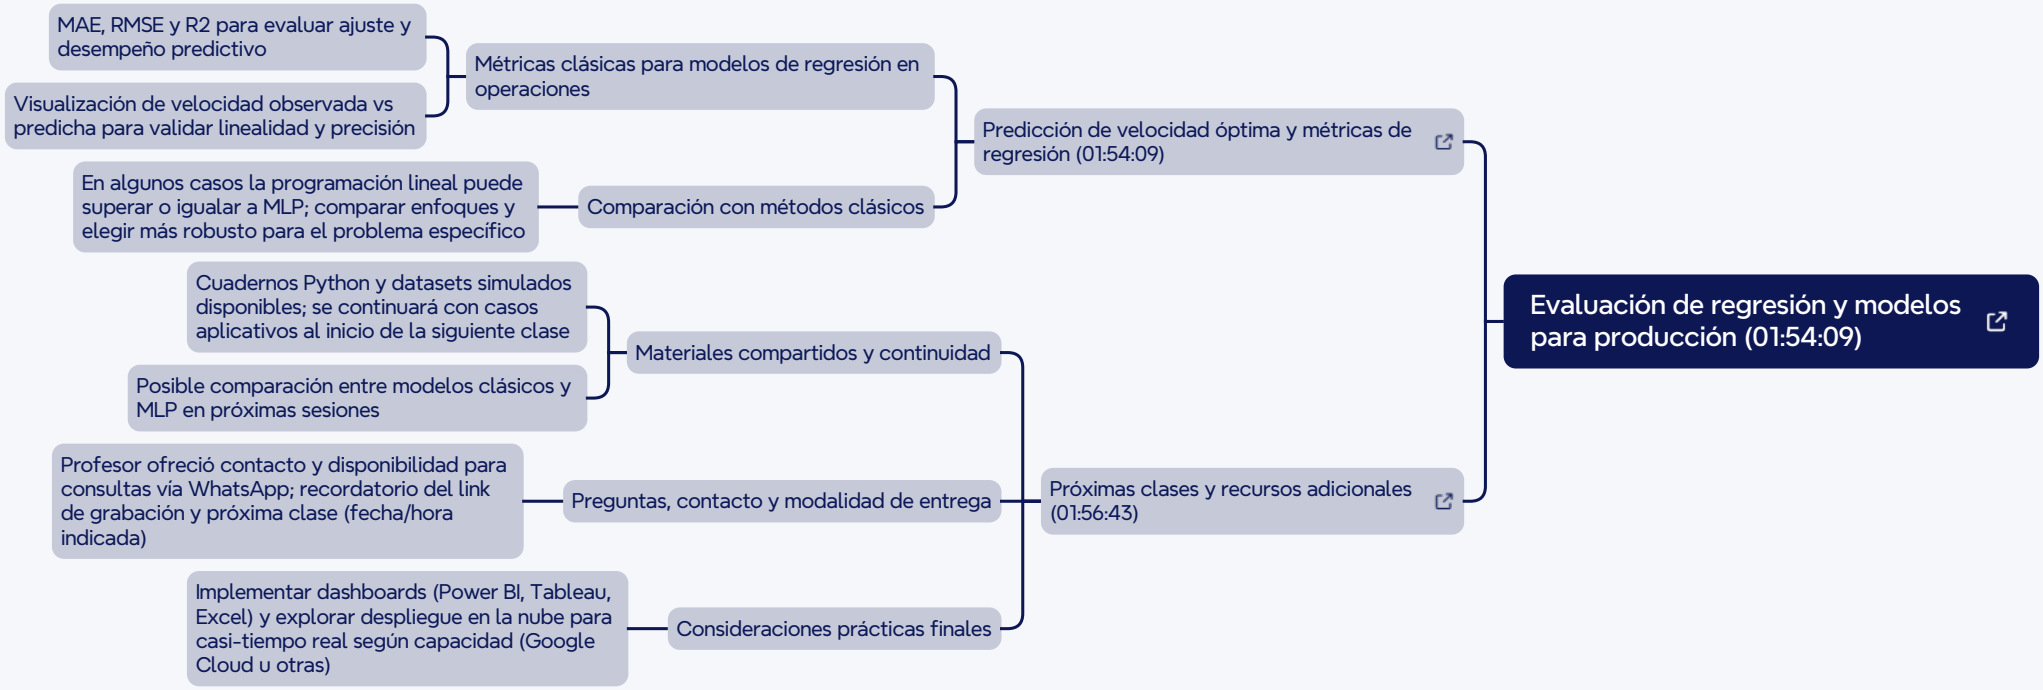

Ejemplo práctico y ejecución en Python (00:56:49)
Dataset y preparación (00:56:49)
Dataset de "bajo desempeño" compartido para la práctica
Variables: horas en tareas clave, errores semanales, puntualidad, capacitaciones, carga laboral, evaluación previa, target "bajo desempeño"
Instrucciones para cargar y preprocesar en Colab
Descargar CSV desde Kaggle, cargar en Colab con Pandas
Separar X (predictoras) e y (target)
Escalado y partición de datos (00:59:39)
Uso de StandardScaler para variables predictoras
Fit sobre X de entrenamiento y transformación antes de modelar
División de datos para entrenamiento, prueba y validación
Práctica común 80-20 para entrenamiento/prueba y reservar segmento para validación externa
Importancia de validar para evitar sesgos y sobreajuste


Evaluación de modelos y métricas prácticas (01:00:00)
Entrenamiento, splits y parámetros comunes (01:00:00)
Prácticas de particionado y reproducibilidad
Split 80-20 o 80/10/10 para entrenamiento/prueba/validación; random_state = 42
Ajuste de épocas (20, 40, 80) y número de capas (2-3 densas) según complejidad
Evaluación con múltiples métricas
Precisión, recall, F1-score y support para clasificación
Interpretación según caso: recall crítico en mantenimiento predictivo; precisión más relevante en predicción de rotura de stock y abandono
Matrices de confusión y recomendaciones (01:01:19)
Uso de matriz de confusión para diagnosticar errores
Verdaderos positivos/negativos deben ser mayores; falsos positivos/negativos menores
Ajustar épocas, arquitectura o preprocesamiento cuando la matriz lo indique
Umbrales prácticos de desempeño


Aplicaciones por sector: Operaciones, Manufactura y Logística (01:11:25)
Casos de uso y herramientas clásicas versus ML (01:11:25)
Predicción de fallas y mantenimiento predictivo
Sensores IoT y SCADA/DCS generan datos masivos para modelos (MLP, LSTM, autoencoders)
En mantenimiento, recall prioriza detectar todas las fallas potenciales
Optimización de cadena de suministro y rotura de stock
Problemas de programación lineal, heurísticas y Flow Shop cubren muchos casos clásicos
Empezar con soluciones simples (regresión, programación lineal, Monte Carlo); usar ML cuando la complejidad lo justifique
Automatización y orquestación en logística
Automáticamente decidir proveedores, reabastecimiento y rutas en sistemas con alto volumen de ítems
Requiere monitoreo constante para evitar decisiones no deseadas por modelos obsoletos
Ejemplo práctico: predicción de rotura de stock (01:25:09)
Dataset "Rotura de stock simulado" y preprocesamiento
Variables: demanda últimos días, inventario actual, tiempo de reposición, variabilidad, tipo de producto, riesgo binario
Separación de variables categóricas y numéricas; uso de OneHotEncoder y StandardScaler con ColumnTransformer
Modelo y evaluación
MLP secuencial (3 capas densas, activaciones ReLU y sigmoidea), Adam, binary crossentropy
Métrica prioritaria: precisión (importante predecir bien para poder reaccionar y evitar la rotura)
Mejora con más épocas y ajuste de hiperparámetros; matriz de confusión usada para validar equilibrio entre positivos y negativos


Aplicaciones por sector: Marketing y Experiencia del Cliente (01:32:31)
Predicción de abandono y análisis de sentimiento (01:32:31)
Modelos para churn de clientes y e-learning
Predicción temprana de abandono, análisis automático de encuestas y comentarios con NLP
Integración con dashboards operativos para acción inmediata por gerentes de ventas
Modelos recomendados y gestión del ciclo de vida
MLP como "vieja confiable" y LSTM para datos secuenciales o series temporales
Importancia de reentrenar frecuentemente porque los datos de clientes cambian rápido
Ejemplo práctico: abandono de clientes (01:40:31)
Dataset "abandono clientes" y ejecución rápida
Variables: tiempo de cliente en meses, tickets de reclamos, satisfacción, frecuencia de uso, target abandono
Todas numéricas: split 80-20, MLP de tres capas, 20-80 épocas, evaluación con precisión y matriz de confusión
Interpretación y ajustes
Precisión como métrica relevante; experimentar con épocas y arquitectura para reducir falsos negativos/positivos


Automatización de decisiones y sistemas adaptativos (01:44:46)
Decisiones automáticas con pinzas y feedback loop (01:44:49)
Reglas fijas vs sistemas adaptativos integrados en tiempo real
Sistemas adaptativos aprenden del entorno y se retroalimentan (feedback loop)
Beneficio: reducen dependencia de expertos en decisiones repetibles; permiten actuar sobre variables multivariadas y dinámicas
Riesgos y necesidad de calibración
Sin monitoreo y orquestación adecuados, un modelo adaptativo puede tomar decisiones inapropiadas
Ejemplo: reposición automática que sigue pidiendo items que ya no se venden
Ejemplos de decisiones automáticas en operaciones (01:47:13)
Ajuste automático de velocidad de producción
Variables: inventario actual, demanda proyectada, capacidad disponible, operarios, consumo energético, riesgo de fallas
Modelo puede recomendar velocidad óptima para maximizar eficiencia sin sobrecargar máquinas ni operarios
Otras aplicaciones automáticas
Precios dinámicos y recomendaciones de precios, clasificación de órdenes por prioridad, rutas logísticas en tiempo real
Integración con MES, ERP, interfaces de usuario y dashboards para ejecución y monitoreo


Evaluación de regresión y modelos para producción (01:54:09)
Predicción de velocidad óptima y métricas de regresión (01:54:09)
Métricas clásicas para modelos de regresión en operaciones
MAE, RMSE y R2 para evaluar ajuste y desempeño predictivo
Visualización de velocidad observada vs predicha para validar linealidad y precisión
Comparación con métodos clásicos
En algunos casos la programación lineal puede superar o igualar a MLP; comparar enfoques y elegir más robusto para el problema específico
Próximas clases y recursos adicionales (01:56:43)
Materiales compartidos y continuidad
Cuadernos Python y datasets simulados disponibles; se continuará con casos aplicativos al inicio de la siguiente clase
Posible comparación entre modelos clásicos y MLP en próximas sesiones
Preguntas, contacto y modalidad de entrega
Profesor ofreció contacto y disponibilidad para consultas vía WhatsApp; recordatorio del link de grabación y próxima clase (fecha/hora indicada)
Consideraciones prácticas finales
Implementar dashboards (Power BI, Tableau, Excel) y explorar despliegue en la nube para casi-tiempo real según capacidad (Google Cloud u otras)