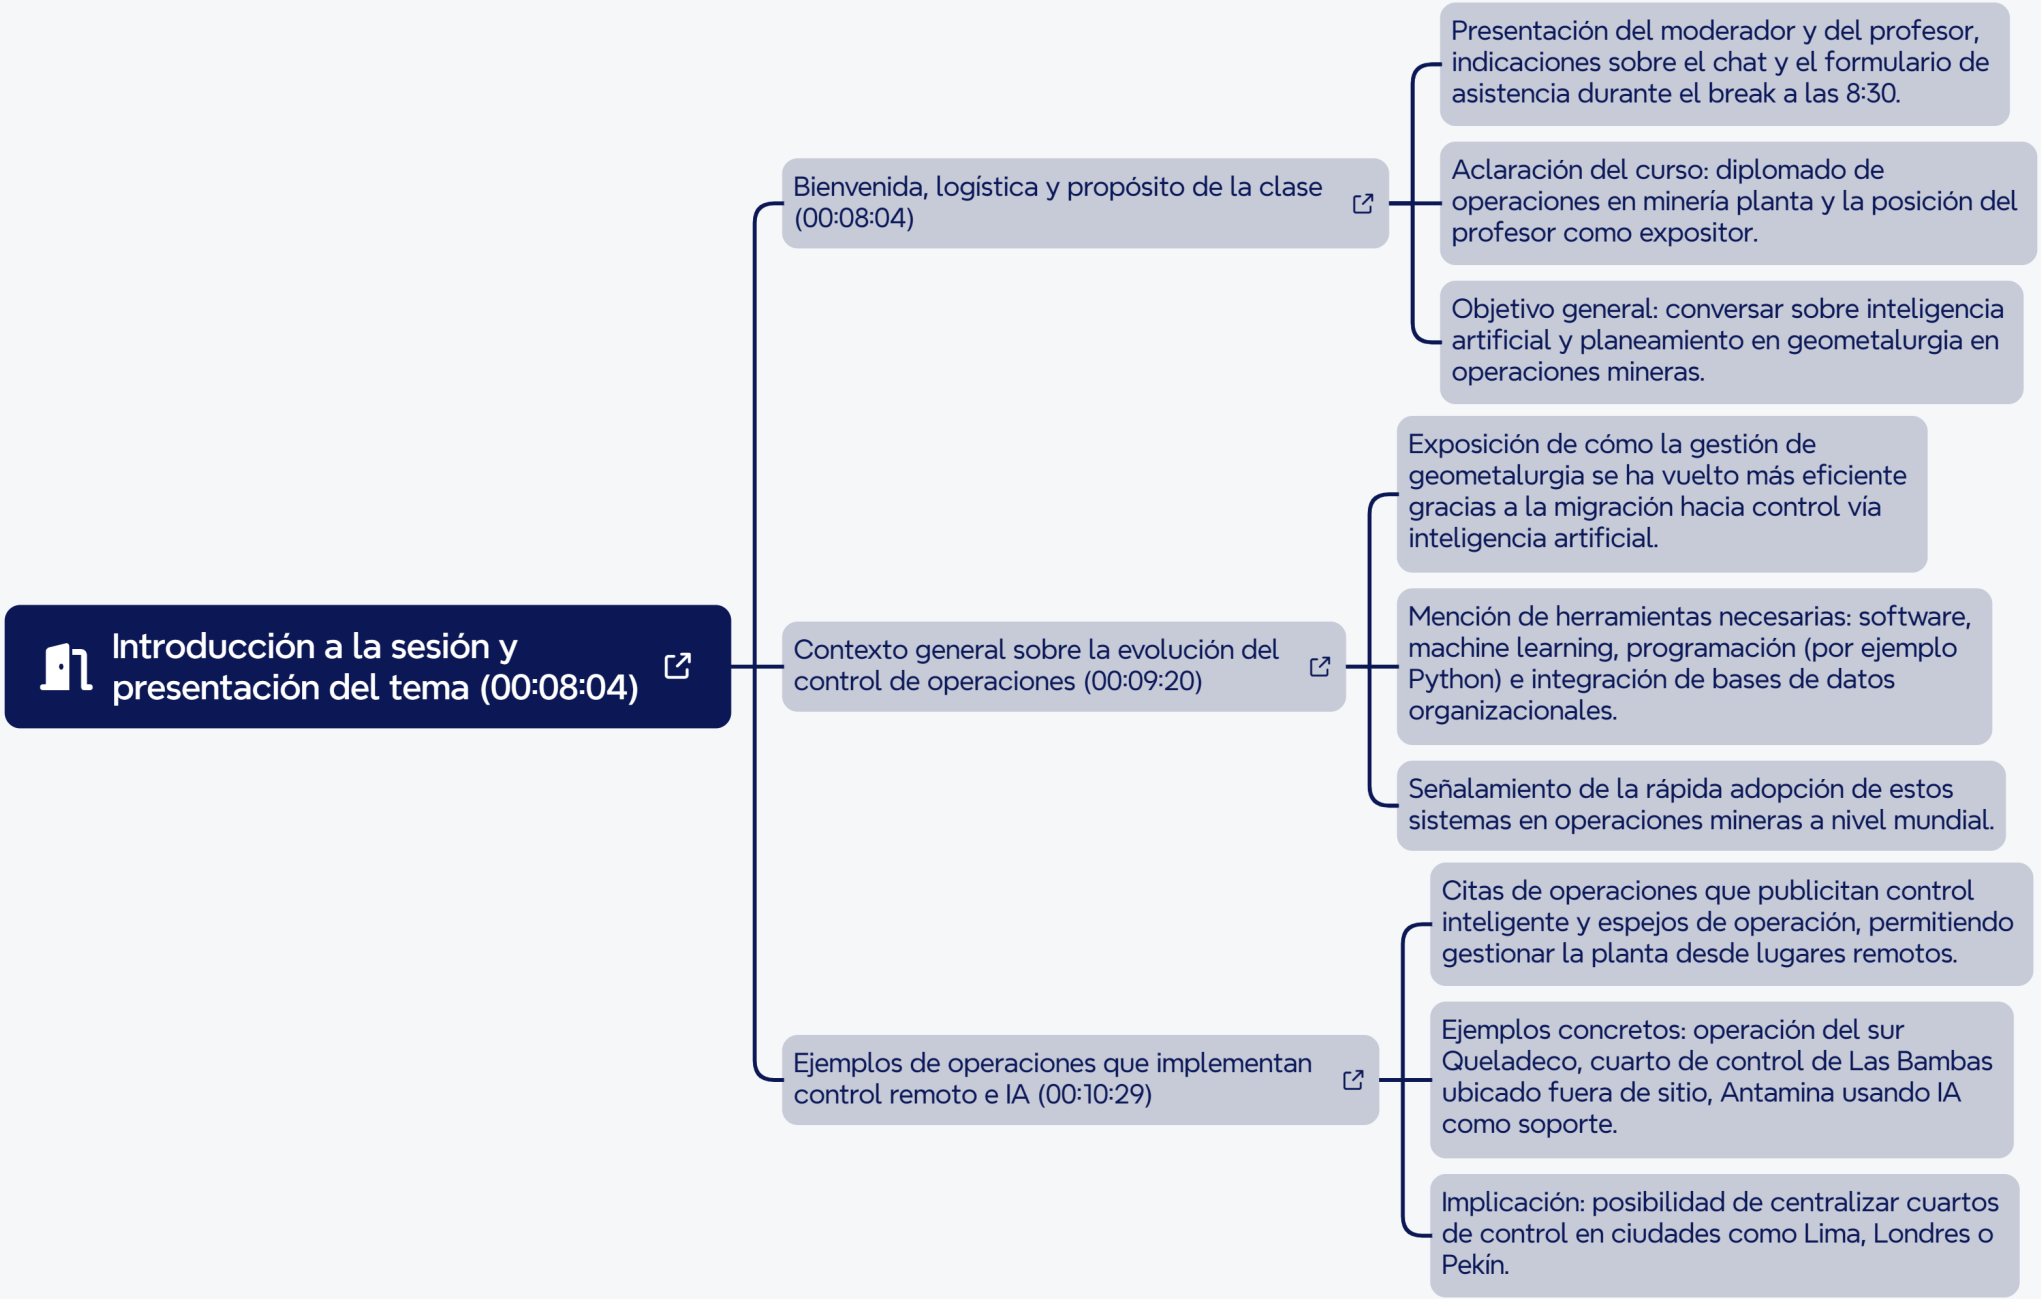
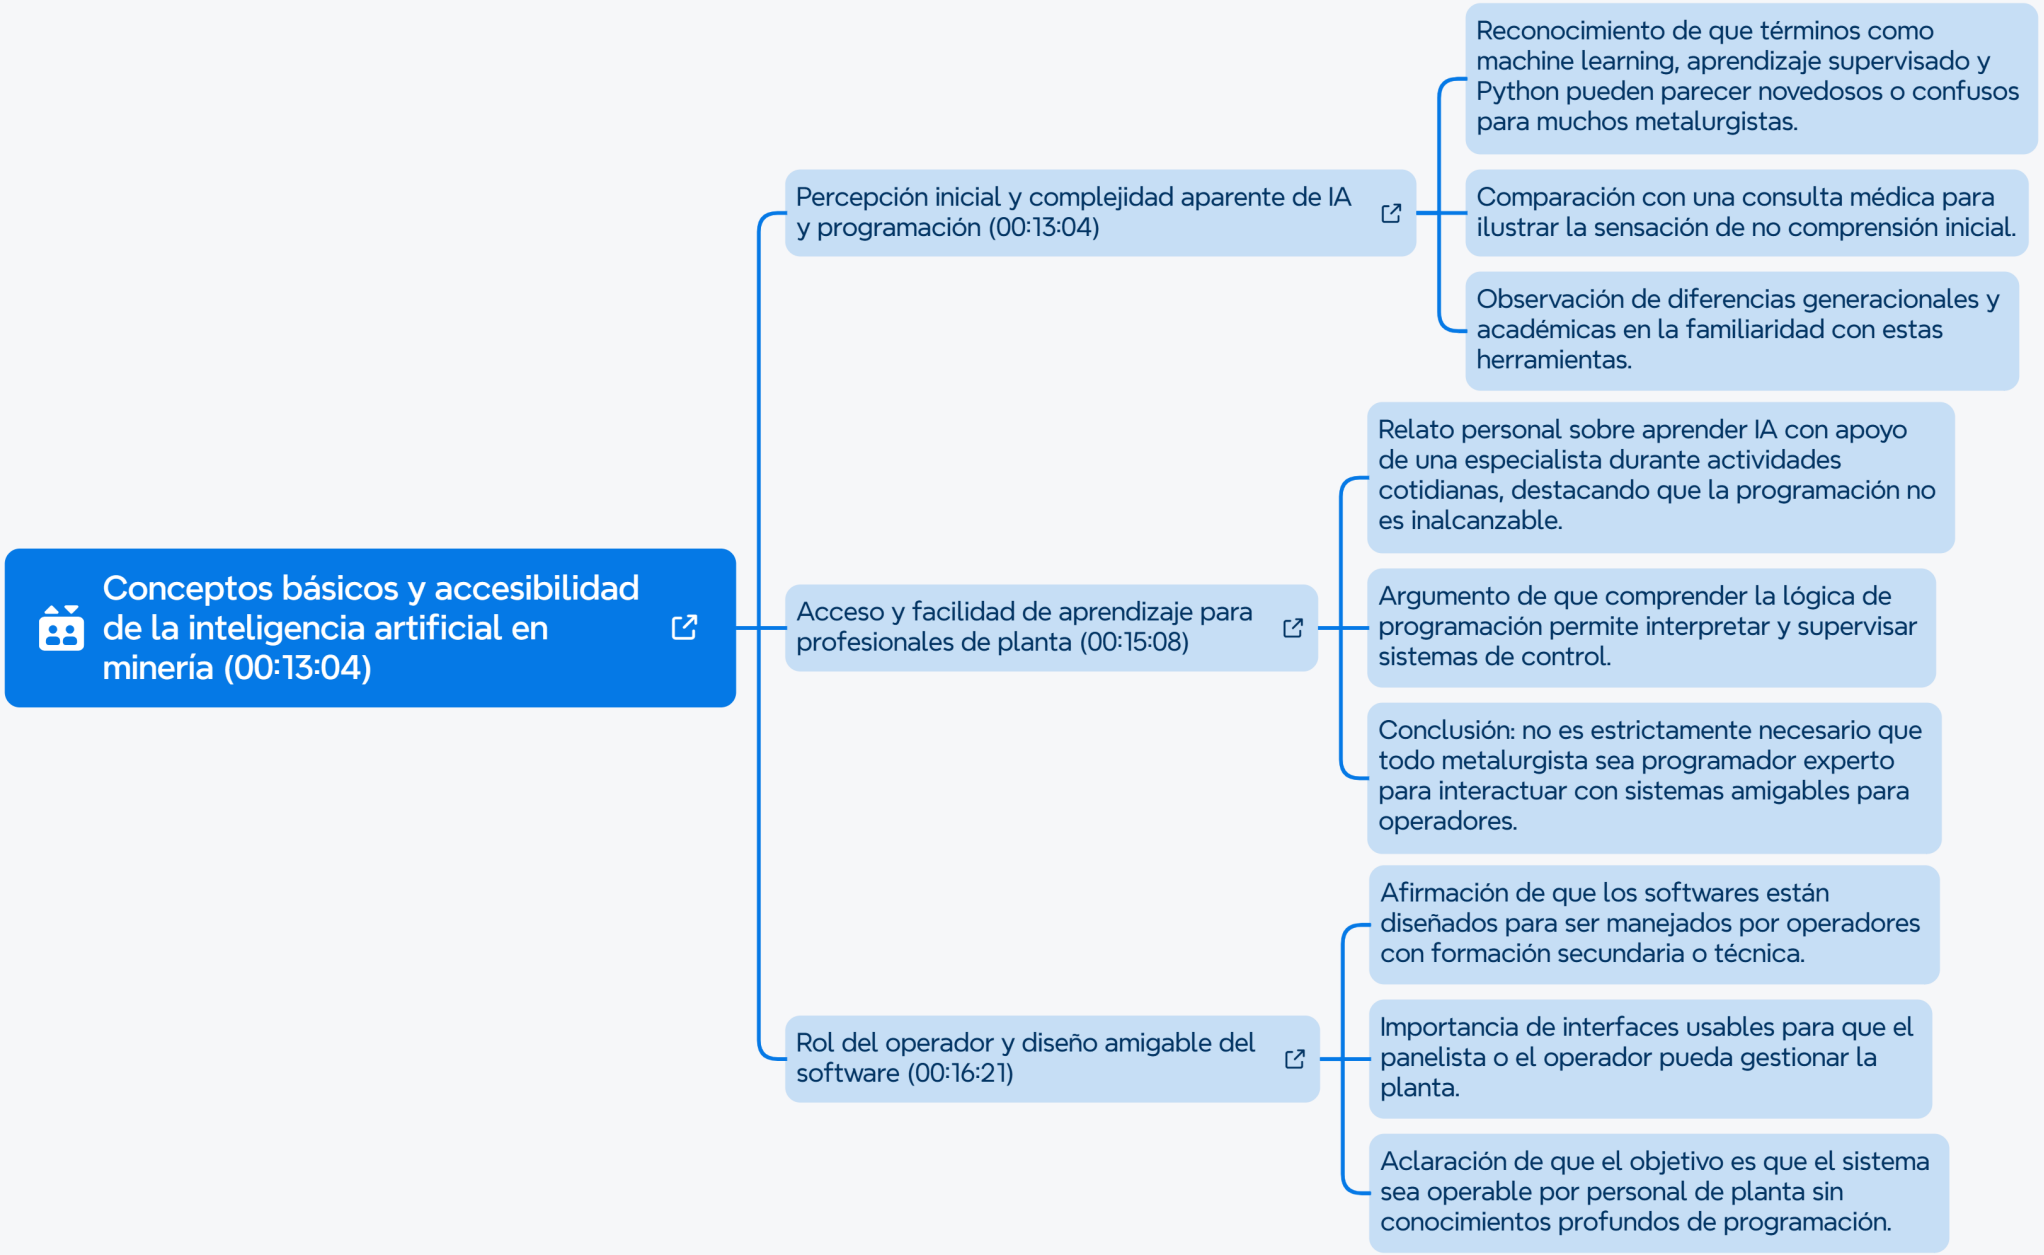

EDU MIN
CLASE 03: OPERACIONES EN MINERÍA: PLANTA - 1RA PARTE
Introducción a la sesión y presentación del tema (00:08:04)
Conceptos básicos y accesibilidad de la inteligencia artificial en minería (00:13:04)
Historia, arquitectura y ejemplos prácticos de sistemas expertos en planta (00:17:44)
Retos operativos, calibración y mantenimiento del sistema experto (00:29:04)
Software, plataformas y expansión del control remoto (00:35:08)
Aplicación práctica: variables críticas, datos y toma de decisiones por IA (00:36:34)
Modelamiento geometalúrgico, paquetes de software y velocidad de procesamiento (00:45:10)
Supervisión humana, limitaciones de la IA y aprendizaje supervisado (00:48:32)
Protocolos de seguridad, respaldo y gestión de fallos remotos (00:51:31)
Cierre de la sesión: preguntas, supervisión y perspectivas futuras (00:56:52)
Rol de la inteligencia artificial en la gestión operacional y geometalúrgica (01:00:00)
Impacto sobre roles humanos, planeamiento y gobernanza minera (01:04:03)
Modelos alternativos, consideraciones prácticas y cierre (02:28:49)
Resultados prácticos, integración en IGS y conclusiones (02:24:03)
Validación, entrenamiento y métricas de desempeño (02:19:02)
Metodología de modelado y elección del algoritmo (02:12:20)
Datos disponibles, retos de la base de datos y preparación (02:05:05)
Introducción al flujo de trabajo y objetivo del estudio (02:00:01)
Aspectos finales sobre la dinámica del sistema inteligente y requisitos de muestreo (01:56:35)
Casos prácticos y experiencias reales de aplicación en minería (01:50:13)
Flujo de trabajo: desde modelamiento hasta operación con machine learning (01:45:50)
Preparación de datos, modelamiento geometalúrgico y entrenamiento de sistemas inteligentes (01:35:18)
Automatización, tecnologías de control y beneficios operativos (01:24:13)
Implementación de inteligencia artificial en pequeña minería y minería artesanal (01:14:48)

EDU MIN


CLASE 03: OPERACIONES EN MINERÍA: PLANTA - 1RA PARTE
Introducción a la sesión y presentación del tema (00:08:04)
Conceptos básicos y accesibilidad de la inteligencia artificial en minería (00:13:04)
Historia, arquitectura y ejemplos prácticos de sistemas expertos en planta (00:17:44)
Retos operativos, calibración y mantenimiento del sistema experto (00:29:04)
Software, plataformas y expansión del control remoto (00:35:08)
Aplicación práctica: variables críticas, datos y toma de decisiones por IA (00:36:34)
Impacto sobre roles humanos, planeamiento y gobernanza minera (01:04:03)
Rol de la inteligencia artificial en la gestión operacional y geometalúrgica (01:00:00)
Cierre de la sesión: preguntas, supervisión y perspectivas futuras (00:56:52)
Protocolos de seguridad, respaldo y gestión de fallos remotos (00:51:31)
Supervisión humana, limitaciones de la IA y aprendizaje supervisado (00:48:32)
Modelamiento geometalúrgico, paquetes de software y velocidad de procesamiento (00:45:10)


Introducción a la sesión y presentación del tema (00:08:04)
Bienvenida, logística y propósito de la clase (00:08:04)
Presentación del moderador y del profesor, indicaciones sobre el chat y el formulario de asistencia durante el break a las 8:30.
Aclaración del curso: diplomado de operaciones en minería planta y la posición del profesor como expositor.
Objetivo general: conversar sobre inteligencia artificial y planeamiento en geometalurgia en operaciones mineras.
Contexto general sobre la evolución del control de operaciones (00:09:20)
Exposición de cómo la gestión de geometalurgia se ha vuelto más eficiente gracias a la migración hacia control vía inteligencia artificial.
Mención de herramientas necesarias: software, machine learning, programación (por ejemplo Python) e integración de bases de datos organizacionales.
Señalamiento de la rápida adopción de estos sistemas en operaciones mineras a nivel mundial.
Ejemplos de operaciones que implementan control remoto e IA (00:10:29)
Citas de operaciones que publicitan control inteligente y espejos de operación, permitiendo gestionar la planta desde lugares remotos.
Ejemplos concretos: operación del sur Queladeco, cuarto de control de Las Bambas ubicado fuera de sitio, Antamina usando IA como soporte.
Implicación: posibilidad de centralizar cuartos de control en ciudades como Lima, Londres o Pekín.


Conceptos básicos y accesibilidad de la inteligencia artificial en minería (00:13:04)
Percepción inicial y complejidad aparente de IA y programación (00:13:04)
Reconocimiento de que términos como machine learning, aprendizaje supervisado y Python pueden parecer novedosos o confusos para muchos metalurgistas.
Comparación con una consulta médica para ilustrar la sensación de no comprensión inicial.
Observación de diferencias generacionales y académicas en la familiaridad con estas herramientas.
Acceso y facilidad de aprendizaje para profesionales de planta (00:15:08)
Relato personal sobre aprender IA con apoyo de una especialista durante actividades cotidianas, destacando que la programación no es inalcanzable.
Argumento de que comprender la lógica de programación permite interpretar y supervisar sistemas de control.
Conclusión: no es estrictamente necesario que todo metalurgista sea programador experto para interactuar con sistemas amigables para operadores.
Rol del operador y diseño amigable del software (00:16:21)
Afirmación de que los softwares están diseñados para ser manejados por operadores con formación secundaria o técnica.
Importancia de interfaces usables para que el panelista o el operador pueda gestionar la planta.
Aclaración de que el objetivo es que el sistema sea operable por personal de planta sin conocimientos profundos de programación.

Historia, arquitectura y ejemplos prácticos de sistemas expertos en planta (00:17:44)

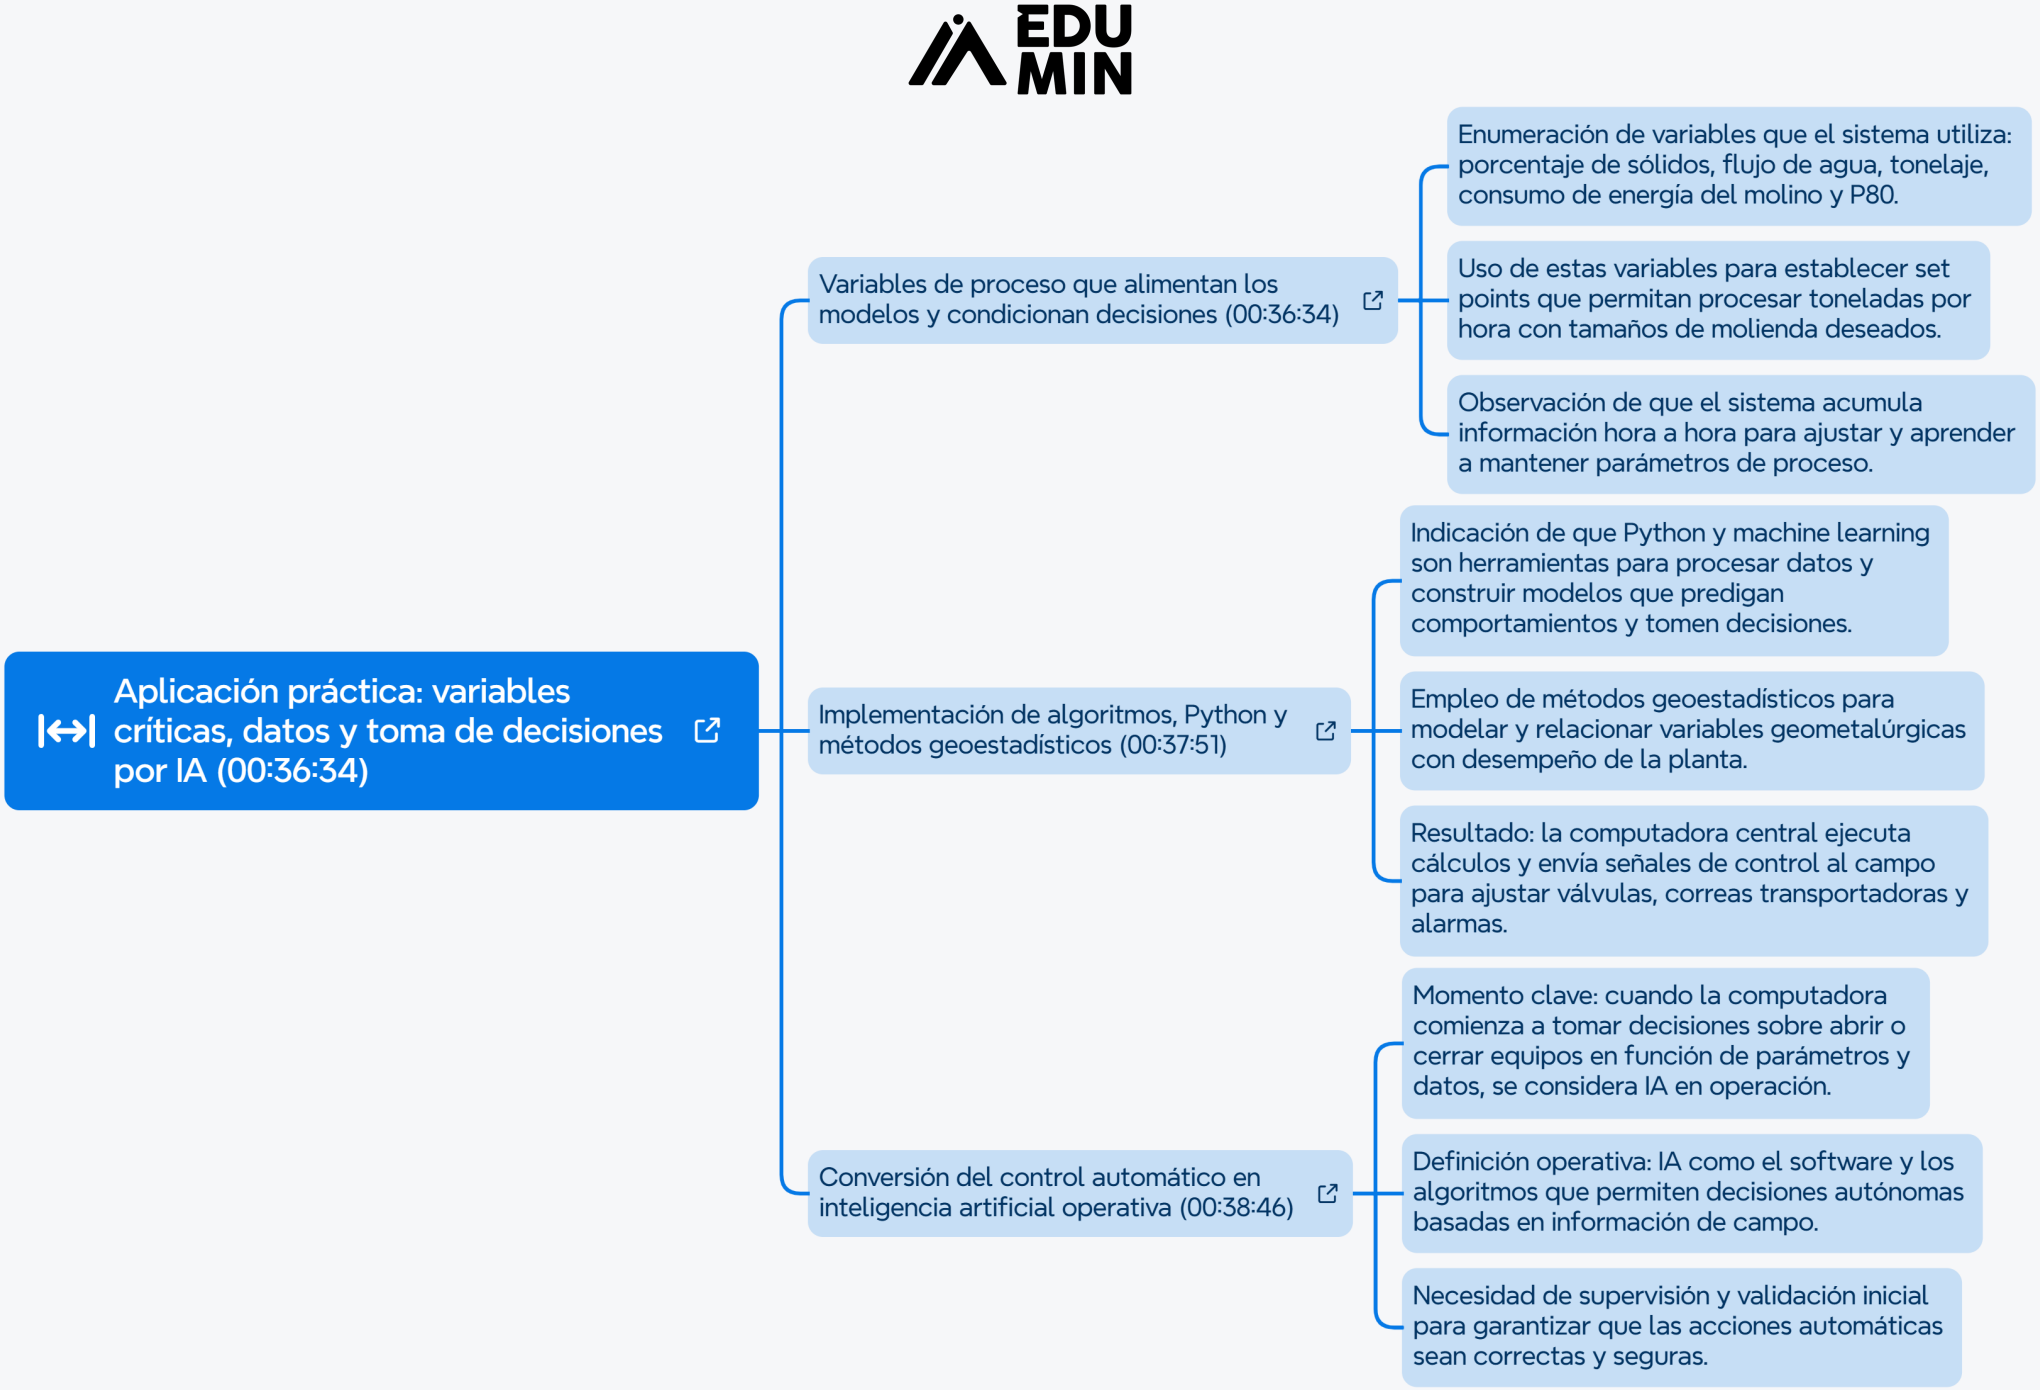
- Experiencia histórica: sistema experto en concentradora de Tintaya (00:17:44)
  - Narración de la ampliación de Tintaya y la instalación de un molino adicional con un sistema experto de control.
  - Participación en eventos académicos y presentación de esa experiencia cuando los sistemas expertos eran poco comprendidos por la audiencia.
  - Relato de cómo se modeló una relación simple de sólidos y agua para controlar la alimentación del molino.
- Funcionamiento básico del control automático con PLS/PLC y hardware asociado (00:19:26)
  - Explicación del cálculo de porcentaje de sólidos y cómo se traducía en tonelaje seco y cantidad de agua mediante programación lógica en PLC (PLS mencionado en la charla).
  - Descripción de las señales enviadas por el PLC para controlar válvulas y alimentadores, manteniendo proporciones de sólidos y agua.
  - Listado de hardware necesario: válvulas, actuadores, flujómetros, básculas (hidrómetros o belt weighers) y cableado para transmitir señales al PLC.
- Arquitectura del sistema experto y evolución tecnológica (00:24:44)
  - Concepto de arquitectura de control: configuración de dispositivos de control y enlaces entre mediciones y sistema de control.
  - Evolución: múltiples PLCs originalmente, calibración y necesidad de tuning del control para lidiar con fallos de actuadores o variaciones.
  - Importancia del departamento de control de proceso que integra metalurgistas, instrumentistas y electrónicos para mantener sistemas afinados.

Retos operativos, calibración y mantenimiento del sistema experto (00:29:04)

- Importancia del tuning y calibración del hardware y actuadores (00:29:04)
  - Explicación de que válvulas y actuadores pueden fallar o requerir ajuste fino para mantener variables dentro de rangos aceptables.
  - Descripción de cómo fallos en actuadores pueden producir sobrealimentación de agua o mineral, desestabilizando el circuito de control.
  - Necesidad de mantenimiento constante y ajuste del control para evitar degradación del rendimiento del sistema experto.
- Problemas históricos y aprendizaje del sistema (00:30:44)
  - Testimonio de que los sistemas expertos iniciales enfrentaron circuitos desordenados y fallos, pero con la acumulación de data el PLC aprendió a compensar en parte los defectos.
  - Limitación: la programación y bucles deben ser bien diseñados para que el sistema pueda autoajustarse ante variaciones del hardware.
  - Deducción: las plantas requieren equipos especializados para asegurar la confiabilidad del control automatizado.
- Organización del área de control de proceso en plantas modernas (00:31:11)
  - Descripción de la existencia de departamentos especializados con metalurgistas, instrumentistas y electrónicos dedicados al control de proceso.
  - Contraste con el pasado, donde los mismos profesionales debían aprender múltiples disciplinas y apañarse con programación y cableado.
  - Función actual: diseñar, configurar y mantener la arquitectura del sistema de control, integrando hardware, software y bases de datos.

Software, plataformas y expansión del control remoto (00:35:08)

- Plataformas y entornos de programación utilizados en control (00:35:08)
  - Mención de entornos Linux y Windows y elección según fabricante del sistema de control.
  - Función de la plataforma en la gestión de la base de datos que alimenta el sistema de control.
  - Observación de que la selección de la plataforma condiciona la arquitectura del software y las capacidades de integración.
- Transición desde control local a control remoto vía internet (00:39:37)
  - Descripción de cómo la información de planta viaja desde la mina a una computadora central ubicada en otra ciudad mediante internet.
  - Ejemplo: datos de tonelaje, flujo de agua, P80 y otras variables llegan digitalmente y el modelo central toma decisiones y envía señales al campo.
  - Consecuencia: posibilidad de ubicar el cuarto de control en Lima, Londres, Pekín o cualquier otra ubicación decidida por el propietario de la operación.
- Beneficios operativos y ahorro por centralización del cuarto de control (00:42:58)
  - Relato de colegas que trasladaron su cuarto de control a Lima, destacando ahorro en viajes, hospedaje y logística para el personal.
  - Implicación de que el centro de control centralizado optimiza recursos humanos y costos operativos.
  - Observación de que los cuartos de control actuales son más compactos y estructurados que antes, con menos pantallas y mayor eficiencia.


Aplicación práctica: variables críticas, datos y toma de decisiones por IA (00:36:34)
Variables de proceso que alimentan los modelos y condicionan decisiones (00:36:34)
Enumeración de variables que el sistema utiliza: porcentaje de sólidos, flujo de agua, tonelaje, consumo de energía del molino y P80.
Uso de estas variables para establecer set points que permitan procesar toneladas por hora con tamaños de molienda deseados.
Observación de que el sistema acumula información hora a hora para ajustar y aprender a mantener parámetros de proceso.
Implementación de algoritmos, Python y métodos geoestadísticos (00:37:51)
Indicación de que Python y machine learning son herramientas para procesar datos y construir modelos que predigan comportamientos y tomen decisiones.
Empleo de métodos geoestadísticos para modelar y relacionar variables geometalúrgicas con desempeño de la planta.
Resultado: la computadora central ejecuta cálculos y envía señales de control al campo para ajustar válvulas, correas transportadoras y alarmas.
Conversión del control automático en inteligencia artificial operativa (00:38:46)
Momento clave: cuando la computadora comienza a tomar decisiones sobre abrir o cerrar equipos en función de parámetros y datos, se considera IA en operación.
Definición operativa: IA como el software y los algoritmos que permiten decisiones autónomas basadas en información de campo.
Necesidad de supervisión y validación inicial para garantizar que las acciones automáticas sean correctas y seguras.

Modelamiento geometalúrgico, paquetes de software y velocidad de procesamiento (00:45:10)

- Herramientas para modelamiento y geometalurgia (00:45:10)
  - Enumeración de paquetes de modelamiento utilizados en la industria: Leapfrog, Datamine, Volcano (Volcan mencionado).
  - Comentario sobre la capacidad de estos paquetes para agilizar tareas de modelamiento geológico y cálculo de reservas.
- Aceleración del modelamiento con nuevas plataformas (00:45:46)
  - Afirmación de que lo que antes tardaba días o meses ahora puede realizarse en horas o días gracias a mejoras en software y capacidad de cómputo.
  - Ejemplo: modelar un yacimiento que antes demoraba 15 días ahora podría tomar 2 horas, o cálculos de reservas que antes requerían meses ahora en un día.
  - Implicación de que esta rapidez facilita iteraciones más frecuentes y decisiones de planeamiento más ágiles.
- Integración entre modelamiento y operación mediante IA (00:46:24)
  - Observación de que la inteligencia artificial se está implementando en distintas operaciones unitarias, desde perforación hasta planta de concentración.
  - Señalamiento de la necesidad de integrar modelos geometalúrgicos con sistemas de control para evitar sorpresas en operación.
  - Importancia de mantener la relación entre la predicción geológica y las respuestas de control automatizado en planta.

Supervisión humana, limitaciones de la IA y aprendizaje supervisado (00:48:32)

- Papel insustituible del conocimiento humano en geología y metalurgia (00:48:32)
  - Distinción entre la capacidad de cálculo de la IA y el conocimiento privilegiado del ser humano que interpreta muestras, litologías e inclusiones minerales.
  - Ejemplos: geólogo que identifica texturas, cristalinidad o inclusiones que pueden afectar el proceso y que la IA no detectará sin sensores específicos.
  - Conclusión: la experiencia humana es necesaria para interpretar contextos que aún no están codificados en los modelos.
- Necesidad de sensores y hardware para alimentar la IA con litología (00:50:26)
  - Explicación de que la IA puede ajustar reactivos o parámetros si recibe información litológica mediante hardware de escaneo en planta.
  - Observación de que la IA requiere aprendizaje y datos para asociar señales nuevas a modelos geometalúrgicos específicos.
  - Limitación: cambios de frente o condiciones no contempladas inicialmente exigirán supervisión humana hasta que el sistema aprenda.
- Aprendizaje supervisado y etapas de implementación (00:56:52)
  - Definición implícita: etapa inicial donde los operadores supervisan el aprendizaje del sistema para validar decisiones y evitar acciones erróneas.
  - Proceso gradual: el modelo acumula data y aprende a ajustar variables, reduciendo necesidad de intervención humana con el tiempo.
  - Enunciado de que la terminología técnica se explica en términos sencillos para facilitar la comprensión y posterior lectura de papers técnicos.

Protocolos de seguridad, respaldo y gestión de fallos remotos (00:51:31)

- Riesgos de caída de red o servidor en control remoto y su impacto (00:51:31)
  - Consulta sobre la complicación que implicaría una caída de servidor o red cuando el centro de control está lejos de la mina.
  - Reconocimiento de que tales eventos pueden detener la planta si no existen protocolos y sistemas de respaldo adecuados.
- Estrategias de respaldo: espejos de operación y protocolos de energía (00:52:15)
  - Explicación del uso de espejos (mirrors) de operación y sistemas duplicados para asegurar continuidad en caso de fallo.
  - Mecanismos de respaldo energético: grupos electrógenos y dispositivos que atenúan variaciones de tensión para evitar paradas inmediatas.
  - Ejemplo del pasado donde las caídas eléctricas generaban largos reinicios y caos operativo, contrastado con la mejora de hoy.
- Protocolos de seguridad digital y respuesta ante hackeos o fallos (00:54:44)
  - Mención de protocolos establecidos en sistemas inteligentes para cambiar a datos de respaldo o activar sistemas de contingencia cuando falla la data real.
  - Afirmación de que cada sistema tiene normas de seguridad digital y medidas automáticas para mantener la operación ante interrupciones.
  - Referencia a la necesidad de tiempos de reparación cortos (minutos) para restablecer operaciones normales mediante procedimientos automáticos y manuales.



Cierre de la sesión: preguntas, supervisión y perspectivas futuras (00:56:52)

Interacción con alumnos y preguntas sobre implementaciones (00:46:43)

- Invitación abierta a comentarios, experiencias y preguntas de los asistentes sobre la implementación de IA en planta.
- Participación de asistentes que reconocen la necesidad de enfrentarse a estas tecnologías en el futuro cercano.
- Reconocimiento de que la exposición busca dar fundamentos para entender papers técnicos posteriores.

Importancia del planeamiento geometalúrgico vinculado a IA (00:55:50)

- Afirmación de que para que la IA rinda frutos es necesario un planeamiento de minado y geometalúrgico adecuado y coordinado con la planta.
- Cambio de terminología: tendencia a hablar de planeamiento geometalúrgico como concepto más completo que el planeamiento de minado tradicional.
- Meta: extraer material de la mina con predictibilidad suficiente para que la planta no sufra sorpresas y la IA pueda operar eficazmente.

Etapas futuras y expectativas de aprendizaje (00:59:32)

- Reiteración de que el aprendizaje del modelo requiere suficiente información de variables y supervisión humana ante cambios de frente.
- Invitación a leer papers técnicos para profundizar en terminología y metodologías, una vez comprendidos los conceptos básicos expuestos.
- Cierre implícito en la continuidad del tema en sesiones posteriores, con énfasis en la implementación práctica y controlada de la inteligencia artificial en operaciones mineras.

Rol de la inteligencia artificial en la gestión operacional y geometalúrgica (01:00:00)

- Necesidad de poblar modelos con datos geológicos y metalúrgicos (01:00:06)
  - El software y la inteligencia artificial requieren incorporar la base de datos del modelo geometalúrgico para operar correctamente.
  - La información de frentes, cuerpos y modelos del yacimiento debe integrarse para que el sistema compare y actúe.
  - Sensores de campo, como escáneres XRF, alimentan en tiempo real datos de litología, alteración y leyes de metales para el sistema.
- Aprendizaje automático orientado a dosificación y cinética metalúrgica (01:01:39)
  - El sistema puede aprender la dosificación óptima de reactivos según la caracterización del frente y respuesta metalúrgica.
  - Las unidades geometalúrgicas tienen diferentes cinéticas (rápida o lenta) que el modelo debe reconocer y usar para operar.
  - La IA usa la información de caracterización para tomar decisiones de operación en planta automáticamente.
- Decisiones operativas automáticas y ajustes en planta (01:03:37)
  - La inteligencia artificial puede ordenar aumentar o reducir agua, reactivos y tonelaje según pronósticos de producción.
  - Puede indicar modificaciones físicas como reducir malla en chancado primario o ajustar molino SAG en respuesta a dureza.
  - Estas decisiones automatizadas implican la necesidad de robustez y verificación constante del modelo.

Impacto sobre roles humanos, planeamiento y gobernanza minera (01:04:03)

Efecto en el empleo de metalurgistas y necesidad de intervención humana (01:04:03)

- La automatización podría reducir tareas tradicionales de metalurgistas en decenas de años, aunque el concurso humano seguirá siendo necesario.
- El conocimiento del geólogo y metalurgista humano mantiene relevancia para validación y decisiones estratégicas.
- La implementación requiere mantener participación humana para supervisión y ajuste de modelos.

Mejora del planeamiento y riesgos de manipulación por la alta dirección (01:04:29)

- Integrar datos en IA genera planeamiento más estable y menos sorpresas si el humano no interfiere.
- Cambios en la alta dirección pueden inducir prácticas de descremado del mejor mineral para mostrar resultados a corto plazo.
- Alteraciones del plan minado por decisiones político-económicas provocan desajustes y problemas operativos a mediano plazo.

Aspectos sociales y manejo de frentes mineros (01:07:24)

- Restituir continuidad de frente a través de acuerdos con comunidades evita replegues operativos y paradas no planificadas.
- Formación de empresas comunales responsables y contratación de mano de obra local con capacitación técnica es propuesta para mitigar conflicto.
- Los problemas sociales suelen convertirse finalmente en costos monetarios dentro del OPEX y requieren soluciones sostenibles.

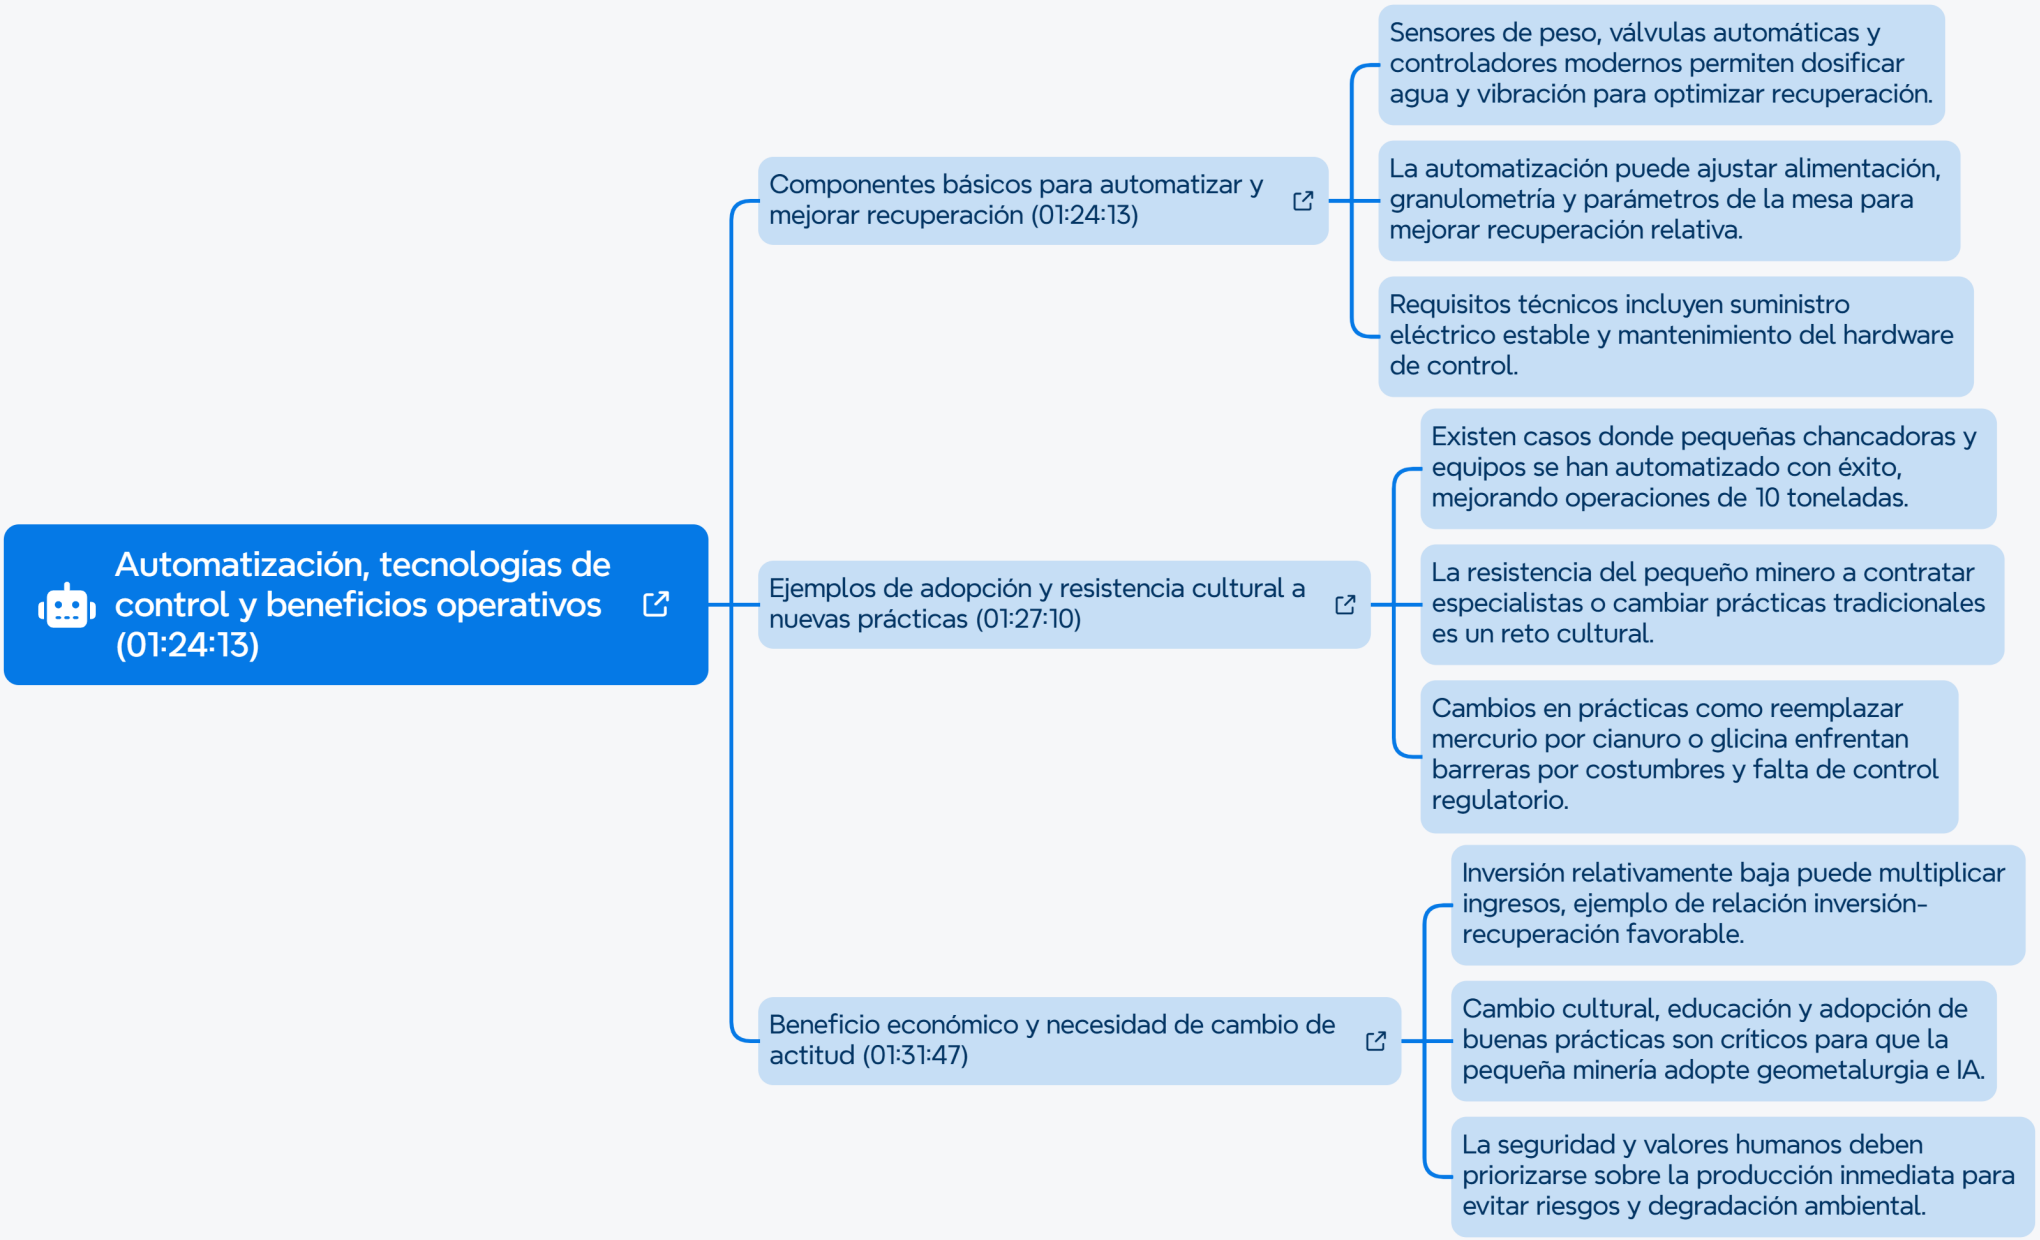
EDU MIN


CLASE 03: OPERACIONES EN MINERÍA: PLANTA - 1RA PARTE
Modelos alternativos, consideraciones prácticas y cierre (02:28:49)
Resultados prácticos, integración en IGS y conclusiones (02:24:03)
Validación, entrenamiento y métricas de desempeño (02:19:02)
Metodología de modelado y elección del algoritmo (02:12:20)
Datos disponibles, retos de la base de datos y preparación (02:05:05)
Introducción al flujo de trabajo y objetivo del estudio (02:00:01)
Aspectos finales sobre la dinámica del sistema inteligente y requisitos de muestreo (01:56:35)
Implementación de inteligencia artificial en pequeña minería y minería artesanal (01:14:48)
Automatización, tecnologías de control y beneficios operativos (01:24:13)
Preparación de datos, modelamiento geometalúrgico y entrenamiento de sistemas inteligentes (01:35:18)
Flujo de trabajo: desde modelamiento hasta operación con machine learning (01:45:50)
Casos prácticos y experiencias reales de aplicación en minería (01:50:13)

EDU MIN

Implementación de inteligencia artificial en pequeña minería y minería artesanal (01:14:48)

- Posibilidad de aplicar geometalurgia en pequeña minería con capacitación (01:15:52)
  - La pequeña minería puede practicar geometalurgia si recibe capacitación adecuada y orientación técnica.
  - Requiere contratar geólogo para levantamiento de yacimiento, muestreo y definición de perforaciones y explotaciones.
  - La caracterización permitirá entender tipo de mineralización y diseñar soluciones metalúrgicas apropiadas.
- Ejemplo práctico de mejora mediante caracterización y equipos simples (01:17:01)
  - Caso donde la caracterización reveló oro grueso y relaves con valores residuales que justificaron pruebas de gravimetría.
  - Instalación de mesa vibratoria, jig o espiral mejoró recuperación y permitió optar por lixiviación de relaves si conviene.
  - El coste de la caracterización y del equipo de segunda mano fue recuperado con aumento de recuperación y valor producido.
- Automatización y control remoto accesible para plantas pequeñas (01:23:10)
  - PLCs (PLS en la transcripción) y tarjetas de adquisición permiten controlar válvulas, motorizaciones y dosificaciones en mesas vibratorias.
  - Señales digitalizadas pueden transmitirse por internet para supervisión remota desde un celular o computadora.
  - Inversión estimada razonable (orden de miles de dólares) permite acceso a automatización y sistemas expertos en pequeña minería.

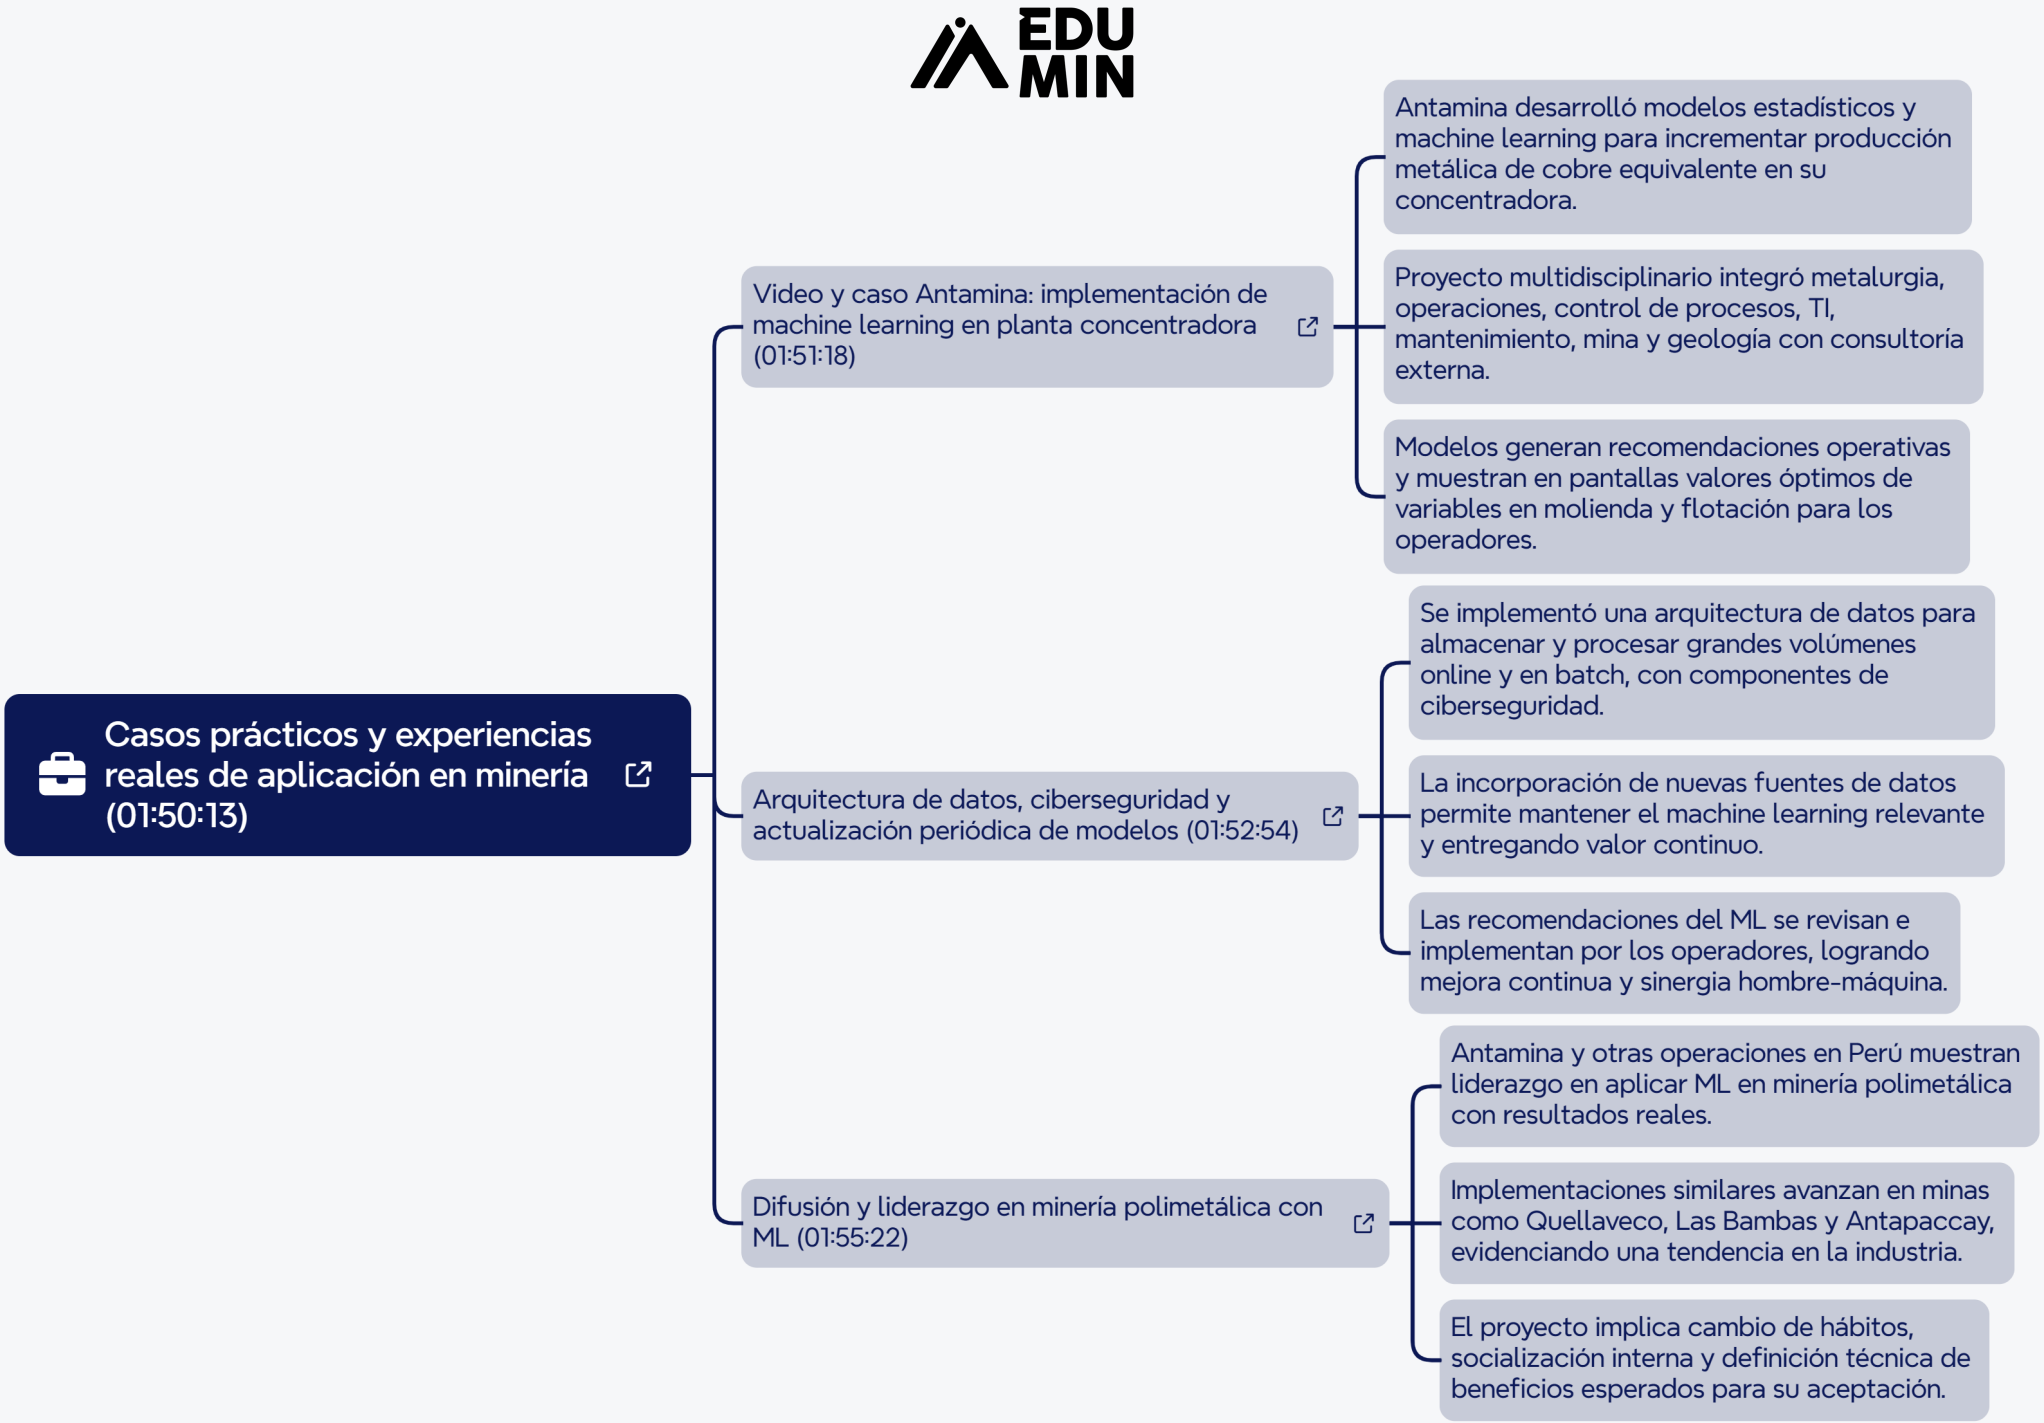

Automatización, tecnologías de control y beneficios operativos (01:24:13)
Componentes básicos para automatizar y mejorar recuperación (01:24:13)
Sensores de peso, válvulas automáticas y controladores modernos permiten dosificar agua y vibración para optimizar recuperación.
La automatización puede ajustar alimentación, granulometría y parámetros de la mesa para mejorar recuperación relativa.
Requisitos técnicos incluyen suministro eléctrico estable y mantenimiento del hardware de control.
Ejemplos de adopción y resistencia cultural a nuevas prácticas (01:27:10)
Existen casos donde pequeñas chancadoras y equipos se han automatizado con éxito, mejorando operaciones de 10 toneladas.
La resistencia del pequeño minero a contratar especialistas o cambiar prácticas tradicionales es un reto cultural.
Cambios en prácticas como reemplazar mercurio por cianuro o glicina enfrentan barreras por costumbres y falta de control regulatorio.
Beneficio económico y necesidad de cambio de actitud (01:31:47)
Inversión relativamente baja puede multiplicar ingresos, ejemplo de relación inversión-recuperación favorable.
Cambio cultural, educación y adopción de buenas prácticas son críticos para que la pequeña minería adopte geometalurgia e IA.
La seguridad y valores humanos deben priorizarse sobre la producción inmediata para evitar riesgos y degradación ambiental.

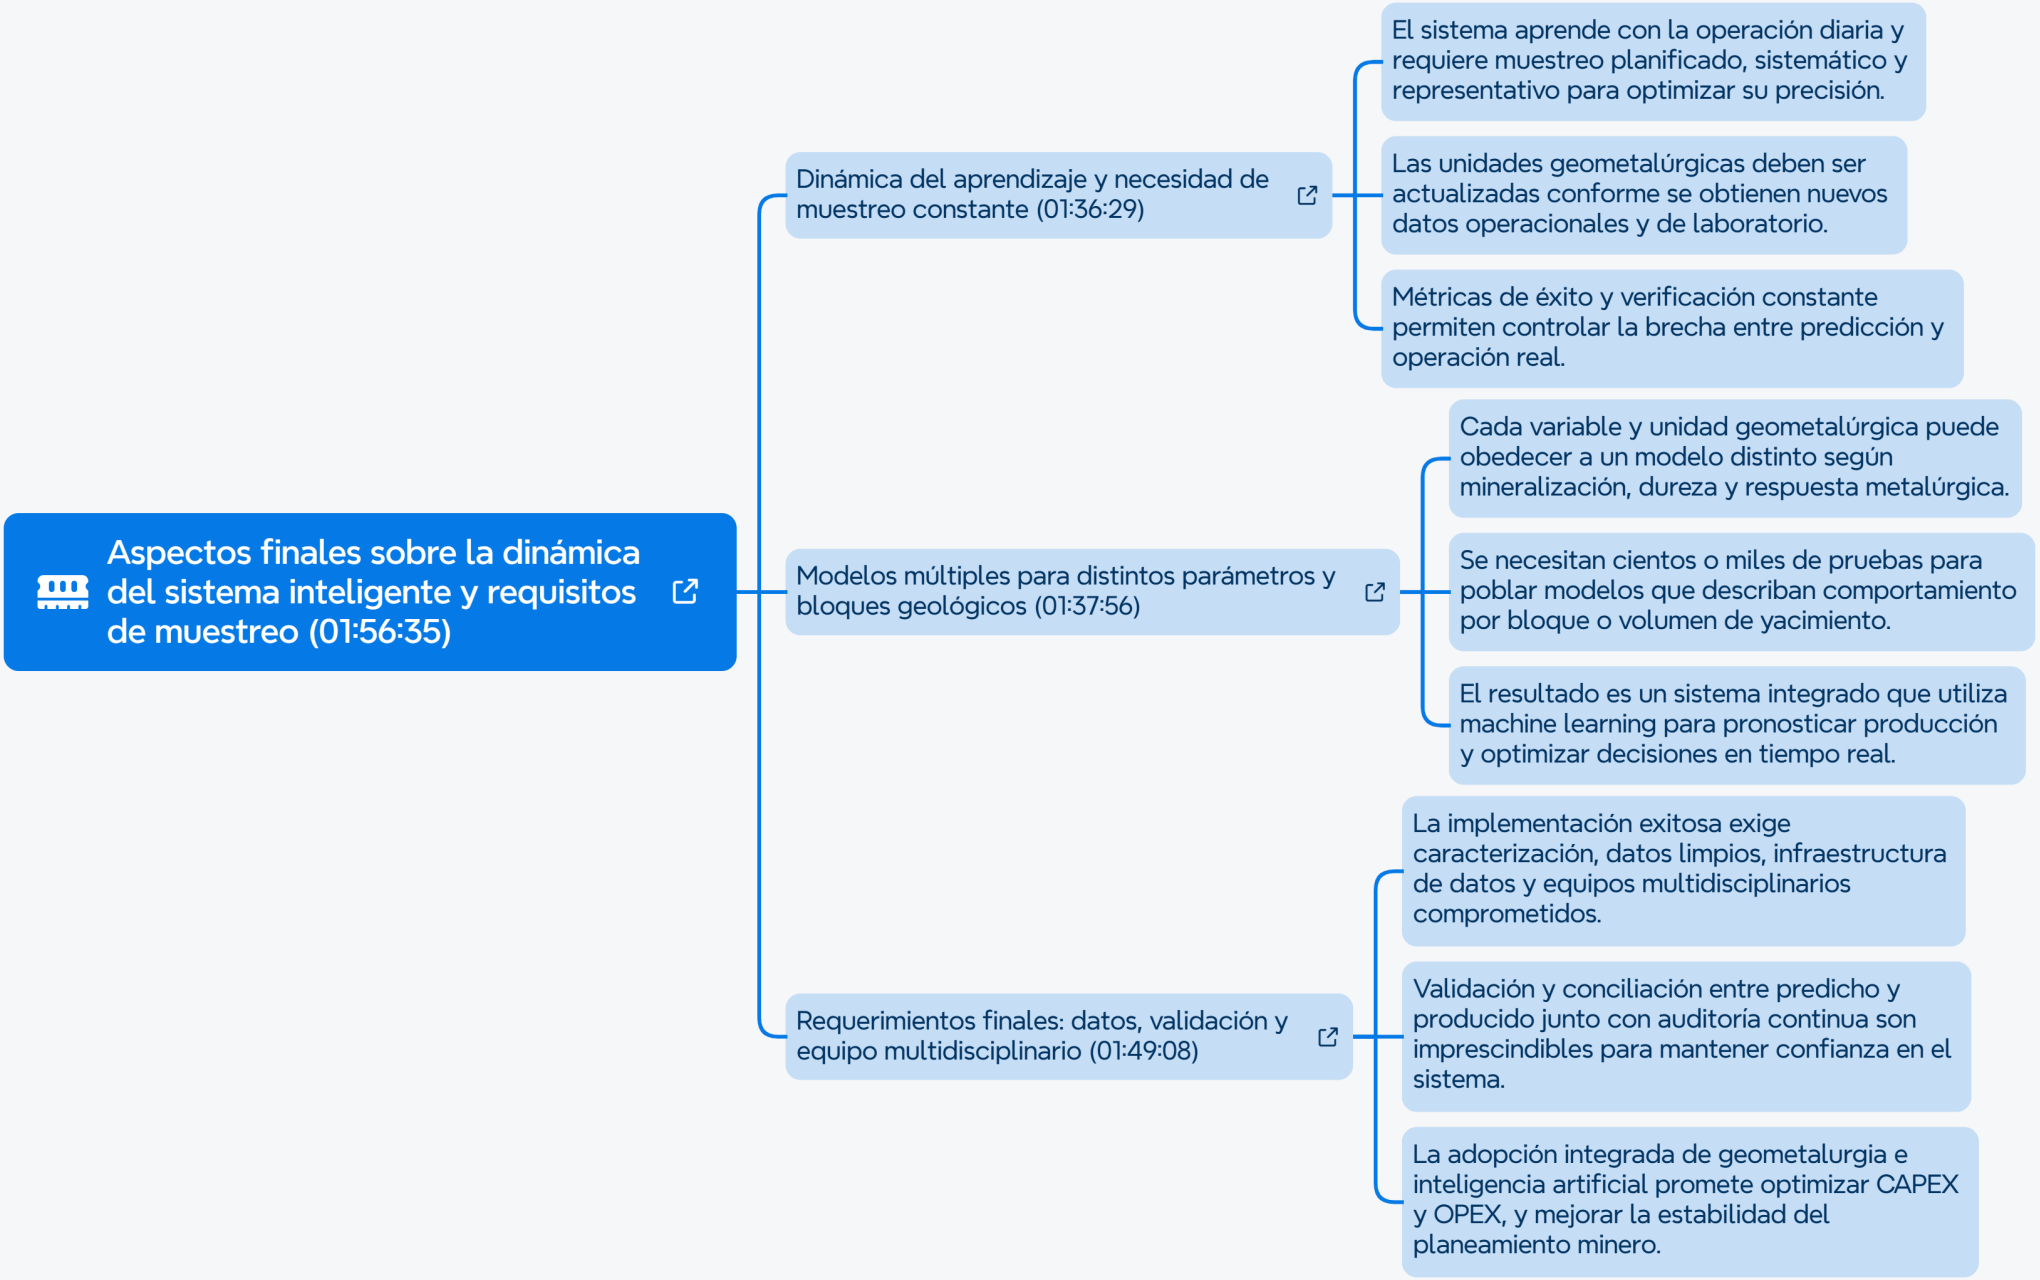
Preparación de datos, modelamiento geometalúrgico y entrenamiento de sistemas inteligentes (01:35:18)

- Integración de parámetros geológicos, mineralógicos y metalúrgicos (01:35:18)
  - La caracterización de yacimiento incluye geología, química, mineralogía, propiedades físicas, respuesta metalúrgica y geotecnia ambiental.
  - Cada parámetro (dureza, mineralogía, alteraciones) se debe recolectar y almacenar para que el sistema lo use en entrenamiento.
  - El sistema necesita identificar unidades geometalúrgicas y asociar respuestas metalúrgicas específicas para cada unidad.
- Creación y poblamiento de modelos y manejo de variables faltantes (01:37:42)
  - Millones de registros de pruebas y ensayos alimentan modelos estadísticos y de machine learning para predecir comportamientos.
  - Si una variable relevante (por ejemplo arcilla) no está en el modelo, las predicciones fallan y es necesario alimentar la información faltante.
  - La auditoría y conciliación entre predicho y producido permite identificar brechas y poblar el modelo con nueva información.
- Consideraciones de mantenimiento, paradas y datos operacionales (01:43:22)
  - Variables no metalúrgicas como paradas no programadas y fallas de hardware deben incorporarse al modelo como limitaciones.
  - Los datos de mantenimiento, disponibilidad de bombas y controladores son necesarios para que la IA gestione alteraciones operativas.
  - El muestreo continuo, sistemático y planificado garantiza la actualización del modelo y su optimización dinámica.

Flujo de trabajo: desde modelamiento hasta operación con machine learning (01:45:50)

- Proceso de modelamiento geometalúrgico y control de calidad de datos (01:45:50)
  - Se genera un modelo geometalúrgico mediante análisis geoestadístico y se limpian los datos antes de introducirlos en unidades geometalúrgicas.
  - El muestreo debe ser representativo, con selección adecuada, caracterización química, mineralógica y metalúrgica.
  - Se requiere control de calidad de datos (QA/QC) para asegurar integridad antes del entrenamiento de modelos.
- Parámetros críticos en concentración y su modelado (01:47:34)
  - Variables como litología, dureza, cinética de molienda y reología influyen en consumo energético y respuesta a flotación.
  - Modelos estiman parámetros para cada bloque geológico: recuperación, dureza, alteraciones penalizables y comportamiento reológico.
  - Estos parámetros se cargan en la arquitectura de datos que alimenta los modelos de machine learning.
- Implementación, actualización y auditoría de modelos en planta (01:49:47)
  - Una vez en operación, el sistema inteligente operará con información previa y nueva recolectada diariamente por análisis en línea.
  - Los modelos se actualizan periódicamente y se auditian conciliando predicciones con resultados reales para afinar su desempeño.
  - La metodología ágil y equipos multidisciplinarios facilitan hitos rápidos y capitalización temprana de beneficios, como se muestra en casos reales.


Casos prácticos y experiencias reales de aplicación en minería (01:50:13)
Video y caso Antamina: implementación de machine learning en planta concentradora (01:51:18)
Antamina desarrolló modelos estadísticos y machine learning para incrementar producción metálica de cobre equivalente en su concentradora.
Proyecto multidisciplinario integró metalurgia, operaciones, control de procesos, TI, mantenimiento, mina y geología con consultoría externa.
Modelos generan recomendaciones operativas y muestran en pantallas valores óptimos de variables en molienda y flotación para los operadores.
Arquitectura de datos, ciberseguridad y actualización periódica de modelos (01:52:54)
Se implementó una arquitectura de datos para almacenar y procesar grandes volúmenes online y en batch, con componentes de ciberseguridad.
La incorporación de nuevas fuentes de datos permite mantener el machine learning relevante y entregando valor continuo.
Las recomendaciones del ML se revisan e implementan por los operadores, logrando mejora continua y sinergia hombre-máquina.
Difusión y liderazgo en minería polimetálica con ML (01:55:22)
Antamina y otras operaciones en Perú muestran liderazgo en aplicar ML en minería polimetálica con resultados reales.
Implementaciones similares avanzan en minas como Quellaveco, Las Bambas y Antapaccay, evidenciando una tendencia en la industria.
El proyecto implica cambio de hábitos, socialización interna y definición técnica de beneficios esperados para su aceptación.


Aspectos finales sobre la dinámica del sistema inteligente y requisitos de muestreo (01:56:35)
Dinámica del aprendizaje y necesidad de muestreo constante (01:36:29)
El sistema aprende con la operación diaria y requiere muestreo planificado, sistemático y representativo para optimizar su precisión.
Las unidades geometalúrgicas deben ser actualizadas conforme se obtienen nuevos datos operacionales y de laboratorio.
Métricas de éxito y verificación constante permiten controlar la brecha entre predicción y operación real.
Modelos múltiples para distintos parámetros y bloques geológicos (01:37:56)
Cada variable y unidad geometalúrgica puede obedecer a un modelo distinto según mineralización, dureza y respuesta metalúrgica.
Se necesitan cientos o miles de pruebas para poblar modelos que describan comportamiento por bloque o volumen de yacimiento.
El resultado es un sistema integrado que utiliza machine learning para pronosticar producción y optimizar decisiones en tiempo real.
Requerimientos finales: datos, validación y equipo multidisciplinario (01:49:08)
La implementación exitosa exige caracterización, datos limpios, infraestructura de datos y equipos multidisciplinarios comprometidos.
Validación y conciliación entre predicho y producido junto con auditoría continua son imprescindibles para mantener confianza en el sistema.
La adopción integrada de geometalurgia e inteligencia artificial promete optimizar CAPEX y OPEX, y mejorar la estabilidad del planeamiento minero.

Introducción al flujo de trabajo y objetivo del estudio (02:00:01)

- Presentación del proceso desde MFT hasta simulación IGS (02:00:01)
  - Descripción de los tres parámetros obtenidos por MFT que se integran inicialmente en el modelo de bloques para simulación.
  - Papel del software propietario IGS (integrated geometallurgical simulator) en convertir parámetros cinéticos en leyes y recuperaciones finales.
  - Objetivo central del estudio: mejorar la resolución de la base de datos de parámetros cinéticos MFT para afinar estimaciones de producción.
- Motivación para ampliar resultados MFT mediante predicción (02:00:21)
  - Restricciones técnicas y económicas impiden realizar MFT en todas las muestras disponibles, limitando la cobertura de parámetros cinéticos.
  - Necesidad de estimar la posible respuesta metalúrgica en muestras no sometidas a MFT para incluirlas en el forecast de producción.
  - Idea de explotar correlaciones entre variables medidas y variables MFT para extrapolar resultados faltantes.
- Variables de interés y alcance de la estimación (02:02:20)
  - Tres parámetros cinéticos objetivo: recuperación máxima (Rmax), K promedio (velocidad de flotabilidad) y alfa (dispersión de flotabilidad).
  - Importancia práctica: estos parámetros alimentan simulaciones de flotación en IGS para obtener recuperación y ley de concentrado.
  - Alcance: estimación para cuatro fracciones minerales (cobre sulfurado, molibdenita, pirita y ganga no sulfurada), totalizando 12 variables objetivo.

Datos disponibles, retos de la base de datos y preparación (02:05:05)

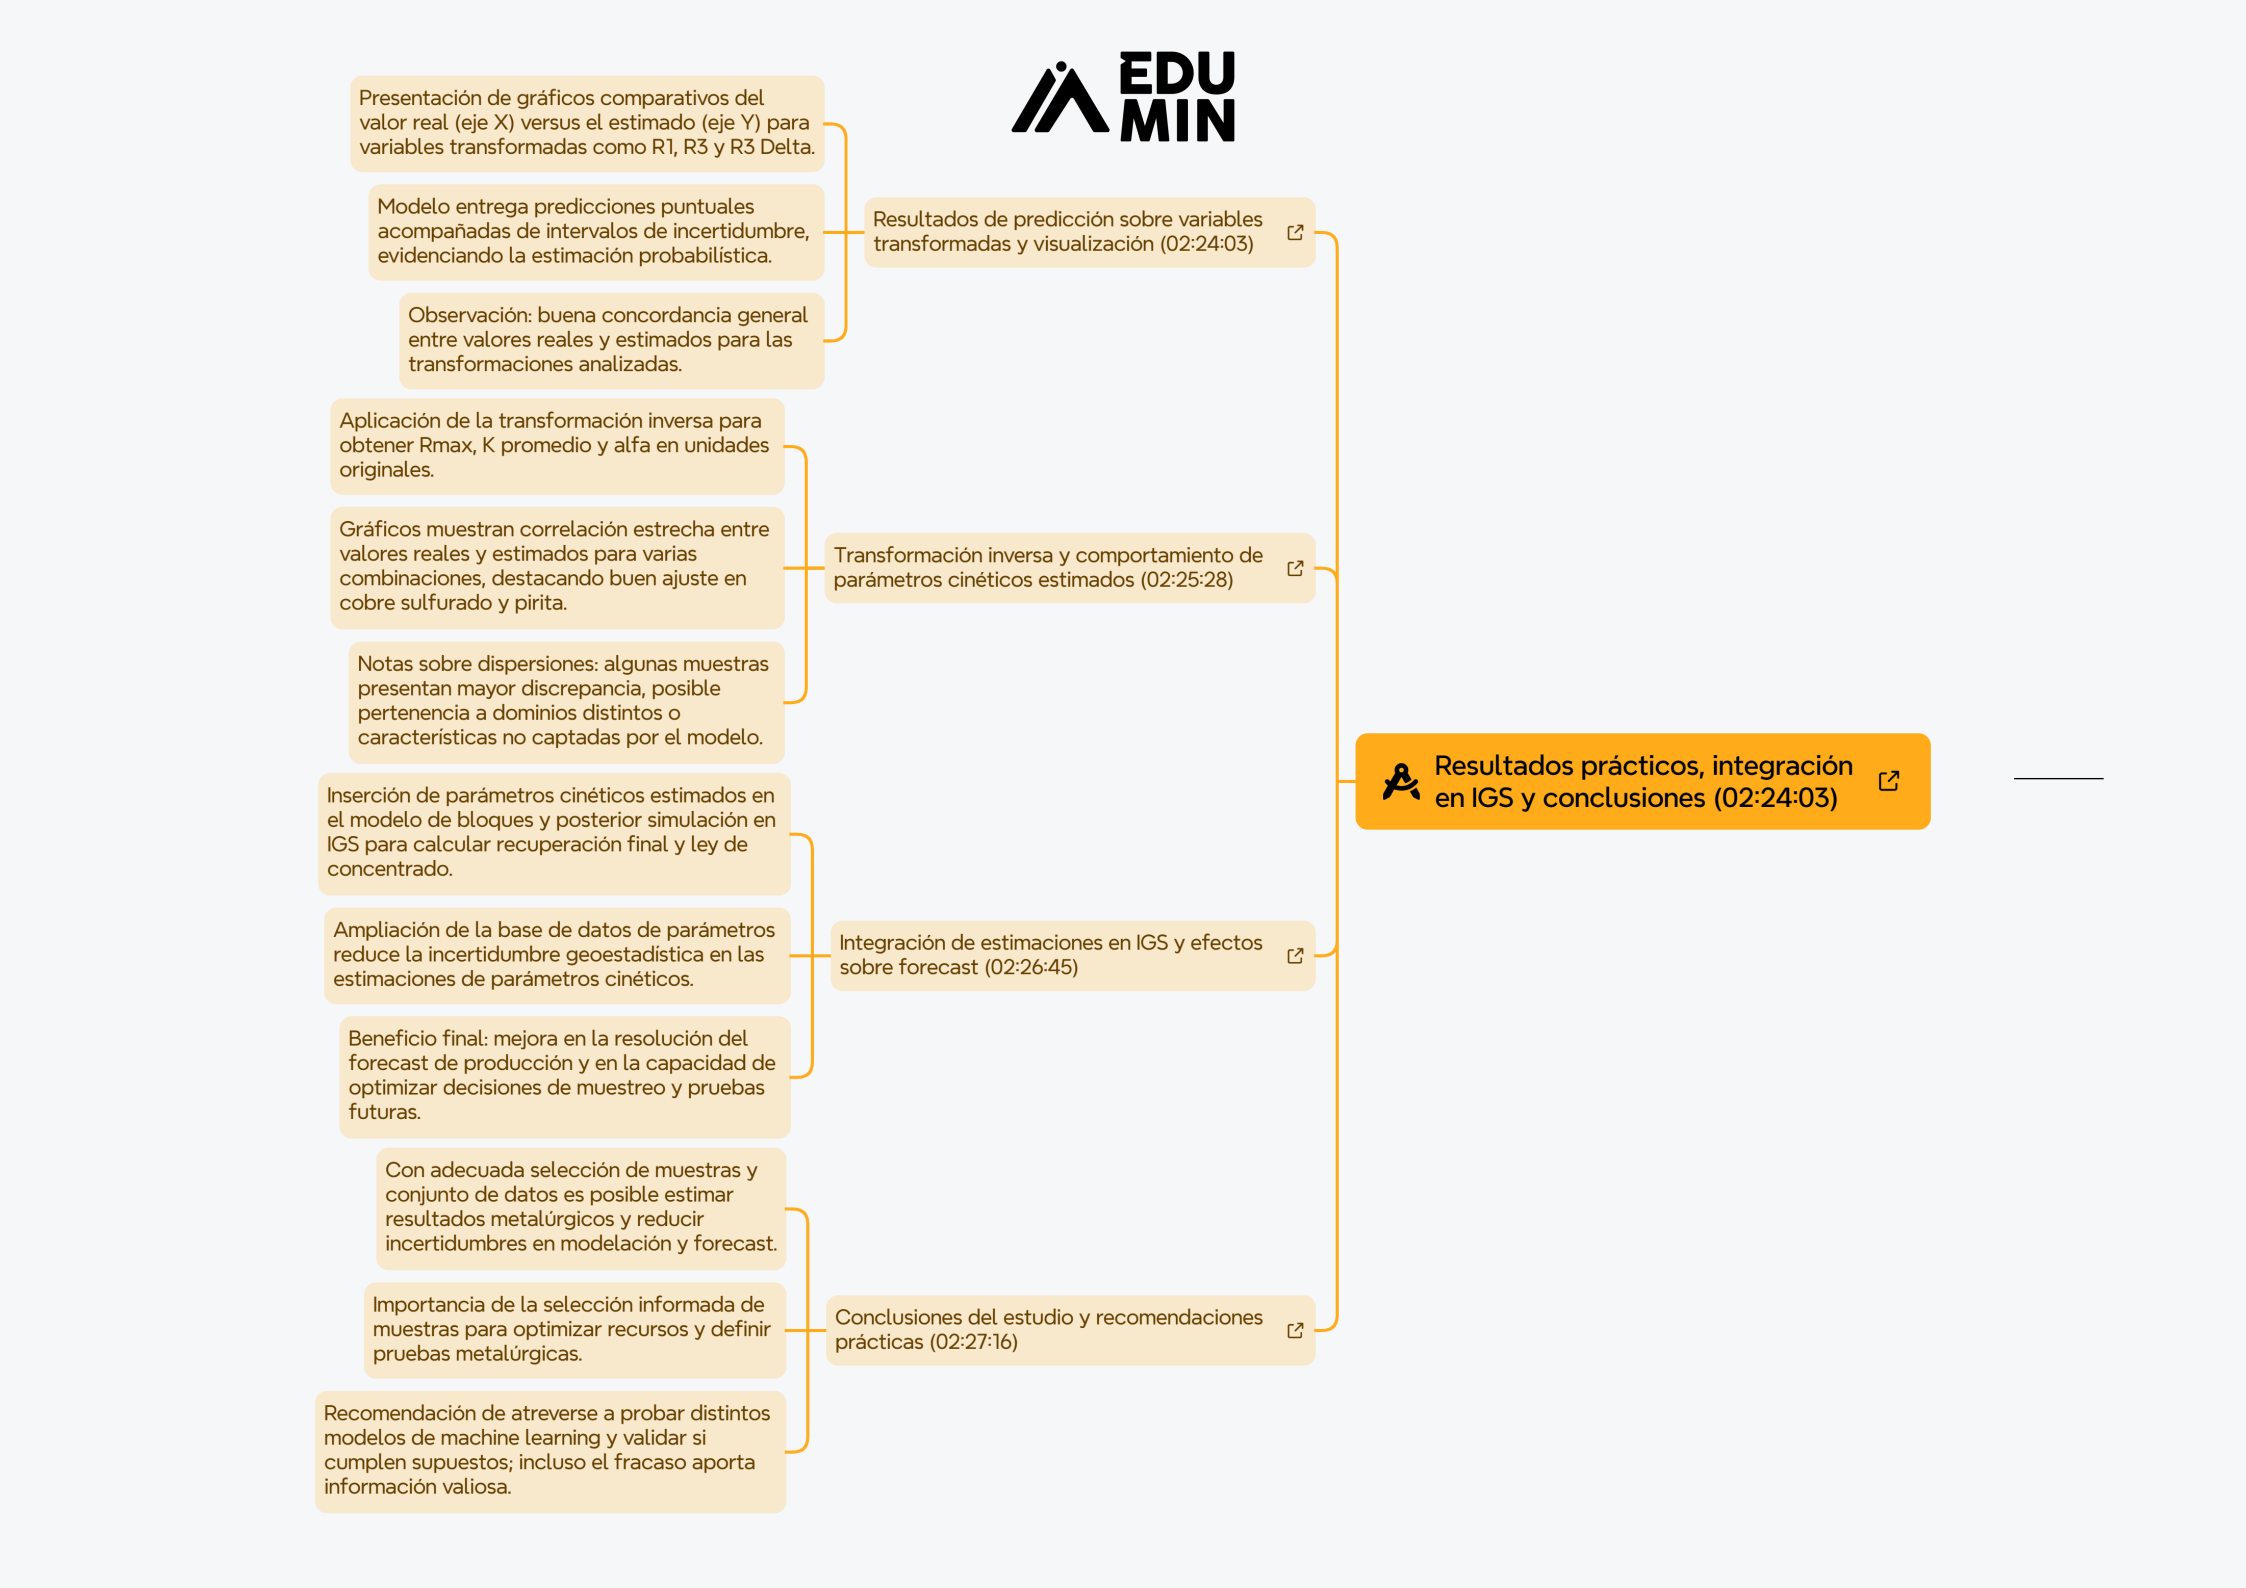
- Descripción de la base de datos y tipos de variables disponibles (02:05:05)
  - Amplia sábana de datos con más de 500 variables incluyendo geología, geometalurgia, caracterización y resultados metalúrgicos.
  - Ejemplos de variables: ubicación X-Z, litología, alteración, mineralogía, leyes de cabeza, pruebas de flotación estándar, difracción de rayos X e ICP.
  - Presencia de datos de pilotaje y balances que enriquecen la información para modelado.
- Problemas de completitud, faltantes y distribuciones de muestras (02:07:33)
  - Existencia de valores faltantes dispersos; algunas variables no medidas en todas las muestras.
  - Diferenciación clara entre 300 muestras con parámetros MFT y 700 muestras sin MFT que se desean estimar.
  - Importancia de identificar qué celdas están medidas (visto bueno) y cuáles no (X) para planificar imputación y modelado.
- Consideraciones sobre aditividad y transformaciones necesarias (02:09:01)
  - Distinción entre variables aditivas (por ejemplo, ley bajo ciertos supuestos) y no aditivas (por ejemplo, recuperación al mezclar bloques).
  - Problema de modelado geometalúrgico: muchas variables metalúrgicas no son aditivas y dificultan agregaciones en modelos de bloques.
  - Solución propuesta: transformar variables no aditivas a formas aditivas mediante transformaciones bidireccionales antes y después de la predicción.

Metodología de modelado y elección del algoritmo (02:12:20)

- Proceso general: transformaciones, modelado y reinversión (02:12:20)
  - Flujo: transformar variables originales a versiones aditivas, estimar estas transformaciones con el modelo de machine learning y aplicar la transformación inversa para obtener parámetros originales.
  - Justificación: trabajar sobre variables transformadas permite poblar modelo de bloques preservando condiciones de aditividad.
  - Resultado final: parámetros originales listos para integrar en simulaciones IGS y obtener forecast.
- Requisitos del modelo y desafíos que debe abordar (02:13:47)
  - Necesidad de manejar alta dimensionalidad, correlaciones complejas entre variables y mediciones con incertidumbre.
  - Capacidad para trabajar con valores faltantes y múltiples variables objetivo (las 12 variables cinéticas).
  - Preferencia por un modelo supervisado que aporte predicción y una medida de incertidumbre asociada.
- Selección del Proceso Gaussiano Valleciano con variables latentes (02:15:03)
  - Descomposición del nombre: proceso gaussiano (modelo probabilístico con estimación e incertidumbre), valleciano (regularización bayesiana para evitar sobreajuste), variables latentes (reducción dimensional manteniendo variabilidad).
  - Ventajas: entrega de predicción puntual y distribución de incertidumbre, incorpora información a priori para mayor robustez y evita overfitting.
  - Relación con técnicas conocidas: variables latentes similares a PCA pero integradas en el modelo probabilístico para capturar covarianzas complejas.

Validación, entrenamiento y métricas de desempeño (02:19:02)

- División de datos y estrategia de entrenamiento versus prueba (02:19:02)
  - Para entrenar se utilizan únicamente las 300 muestras con resultados MFT; las 700 sin MFT se reservarán para aplicar el modelo final.
  - Se separa internamente una porción de datos para validar modelo antes de imputar a muestras sin resultados.
  - Razonamiento: no se entrena con muestras sin MFT pues carecen de etiqueta contra la cual evaluar desempeño.
- Validación cruzada k-fold para robustecer evaluación (02:20:10)
  - Empleo de validación cruzada con k = 5 para evitar sesgos en la selección de entrenamiento y testing.
  - Procedimiento iterativo: en cada iteración se usan cuatro subconjuntos para entrenar y uno para testear, rotando hasta completar cinco iteraciones.
  - Resultado: promedio del rendimiento en las cinco iteraciones como estimador del desempeño general del modelo.
- Métrica de evaluación y análisis de bondad de ajuste (02:22:58)
  - Métrica principal: error cuadrático medio (ECM) que promedia las diferencias al cuadrado entre valor estimado y valor real.
  - Interpretación: valores de ECM más pequeños indican mayor precisión media del modelo en las estimaciones.
  - Complemento: además de ECM, el modelo entrega intervalos de incertidumbre que permiten evaluar precisión y dispersión de las predicciones.


Resultados prácticos, integración en IGS y conclusiones (02:24:03)
Resultados de predicción sobre variables transformadas y visualización (02:24:03)
Presentación de gráficos comparativos del valor real (eje X) versus el estimado (eje Y) para variables transformadas como R1, R3 y R3 Delta.
Modelo entrega predicciones puntuales acompañadas de intervalos de incertidumbre, evidenciando la estimación probabilística.
Observación: buena concordancia general entre valores reales y estimados para las transformaciones analizadas.
Transformación inversa y comportamiento de parámetros cinéticos estimados (02:25:28)
Aplicación de la transformación inversa para obtener Rmax, K promedio y alfa en unidades originales.
Gráficos muestran correlación estrecha entre valores reales y estimados para varias combinaciones, destacando buen ajuste en cobre sulfurado y pirita.
Notas sobre dispersiones: algunas muestras presentan mayor discrepancia, posible pertenencia a dominios distintos o características no captadas por el modelo.
Integración de estimaciones en IGS y efectos sobre forecast (02:26:45)
Inserción de parámetros cinéticos estimados en el modelo de bloques y posterior simulación en IGS para calcular recuperación final y ley de concentrado.
Ampliación de la base de datos de parámetros reduce la incertidumbre geoestadística en las estimaciones de parámetros cinéticos.
Beneficio final: mejora en la resolución del forecast de producción y en la capacidad de optimizar decisiones de muestreo y pruebas futuras.
Conclusiones del estudio y recomendaciones prácticas (02:27:16)
Con adecuada selección de muestras y conjunto de datos es posible estimar resultados metalúrgicos y reducir incertidumbres en modelación y forecast.
Importancia de la selección informada de muestras para optimizar recursos y definir pruebas metalúrgicas.
Recomendación de atreverse a probar distintos modelos de machine learning y validar si cumplen supuestos; incluso el fracaso aporta información valiosa.

Modelos alternativos, consideraciones prácticas y cierre (02:28:49)

- Preguntas frecuentes y aplicabilidad con menos variables (02:28:49)
  - Respuesta a duda común: no es obligatorio disponer de cientos de variables; modelos pueden aplicarse con pocas variables siempre que se cumplan supuestos.
  - Importancia de validar los supuestos del modelo para cada caso particular y ajustar la estrategia de muestreo si es necesario.
  - Enfatiza que la calidad y representatividad de las variables pueden ser más importantes que la cantidad absoluta.
- Otros modelos de machine learning empleados por SGS y su papel (02:29:25)
  - Mención de algoritmos alternativos: algoritmos filogenéticos especializados para interpretación y clasificación geológica.
  - Árboles de decisión potenciados (boosted trees) útiles para relaciones no lineales entre variables.
  - Indicación de que el modelo usado (proceso gaussiano valleciano) ha sido aplicado en otros objetivos y obtuvo reconocimientos en concursos internacionales.
- Cierre de la sesión, agradecimientos y llamadas a la acción (02:30:59)
  - Reconocimiento a colaboradores principales del desarrollo del modelo y mención de aporte intelectual y práctico.
  - Invitación a comunicarse para consultas adicionales y ofrecer contacto vía WhatsApp o correo para seguimiento.
  - Mensaje final animando a probar nuevas tecnologías de machine learning y experimentar con distintos enfoques en proyectos geometalúrgicos.